

THEMISDB

ThemisDB Kompendium

Whitebook & Technisches Handbuch

Ein praxisnaher Leitfaden für Planung, Betrieb und Skalierung der ThemisDB Multi-Model Datenbank – von Grundlagen bis Enterprise-Patterns.

VERSION **Version v1.4.0**

STAND **13. January 2026**

AUTOR **ThemisDB Development Team**

Vorwort

"Dokumentation ist wie Code - sie sollte wartbar, erweiterbar und verständlich sein."

Warum dieses Buch?

Als wir ThemisDB entwickelten, hatten wir eine Vision: Eine Datenbank, die alles kann, was moderne Anwendungen brauchen - relational, Graph, Dokument und Vektor - in einem System, ohne Kompromisse.

Aber eine großartige Datenbank ist nur halb so viel wert ohne großartige Dokumentation. Und genau hier beginnt die Herausforderung.

Das Dokumentations-Dilemma

Wir hatten über 700 Dokumente geschrieben: - API-Referenzen - Feature-Beschreibungen - Architektur-Dokumente - Beispiel-Projekte - How-To-Guides - Troubleshooting-Tips

Alles war da. Aber es war verstreut. Fragmentiert. Schwer zu durchdringen für Neue.

Ein Entwickler fragte uns:

"Ich habe die Docs gelesen, aber ich verstehe nicht, wie alles zusammenpasst. Wann nutze ich Graph statt Relational? Wie skaliere ich? Was sind die Best Practices?"

Das war der Moment, in dem wir erkannten: Wir brauchen nicht nur Dokumentation - **wir brauchen ein Buch.**

Was macht dieses Buch anders?

1. Narrative statt Referenz

Statt:

"Die `SHORTEST_PATH` Funktion findet den kürzesten Pfad..."

Schreiben wir:

"Stellen Sie sich vor, Sie bauen ein Social Network. Alice will wissen, wie sie mit Bob verbunden ist. In SQL wäre das ein rekursiver Join - langsam und komplex. ThemisDB macht es einfach..."

2. Vollständige Examples

Jedes Konzept wird mit einem vollständigen, lauffähigen Example demonstriert. Kein Pseudo-Code. Echte Programme, die Sie herunterladen und ausführen können.

3. Das "Warum" vor dem "Wie"

Wir erklären nicht nur, **wie** Features funktionieren, sondern **warum** sie so designt wurden und **wann** Sie sie einsetzen sollten.

4. Von Einfach zu Komplex

Kapitel 1 erklärt die Basics. Kapitel 30 zeigt Enterprise-Patterns. Dazwischen eine sorgfältig gestaltete Lernkurve.

5. Alle Modelle integriert

Wir zeigen nicht nur einzelne Modelle, sondern wie Sie sie kombinieren. Multi-Model Queries. Cross-Model Transaktionen. Das ganze Potenzial.

Inspiration

Dieses Buch ist inspiriert von Software-Engineering-Klassikern, die uns beim Lernen geholfen haben:

"Designing Data-Intensive Applications" (Martin Kleppmann)

Für die tiefe, konzeptionelle Herangehensweise.

"Programming Rust" (Blandy, Orendorff, Tindall)

Für die "Let's build..." Abschnitte und vollständigen Programme.

"The Go Programming Language" (Donovan, Kernighan)

Für die klare, präzise Sprache und praktischen Beispiele.

"Site Reliability Engineering" (Google)

Für die Operations-Perspektive und Real-World Case Studies.

Für wen ist dieses Buch?

Wenn Sie neu bei ThemisDB sind

Fangen Sie bei Kapitel 1 an. Arbeiten Sie sich durch Teil I und II. Nach Teil II haben Sie ein solides Fundament.

Wenn Sie bereits Erfahrung haben

Springen Sie direkt zu den Themen, die Sie interessieren: - **Performance-Probleme?** → Kapitel 20 - **Skalierung planen?** → Kapitel 17-18 - **Sicherheit härten?** → Teil VI - **AQL meistern?** → Kapitel 13

Wenn Sie von einer anderen DB migrieren

- **Von PostgreSQL?** → Kapitel 5, 29
 - **Von Neo4j?** → Kapitel 6, 29
 - **Von MongoDB?** → Kapitel 7, 29
-

Was Sie brauchen

Vorwissen

- **Grundlegende Programmierkenntnisse:** Python, JavaScript oder ähnlich
- **AQL-Grundlagen:** Hilfreich, aber nicht erforderlich
- **Docker-Basics:** Für die Examples

Software

- **Docker:** Für ThemisDB und Examples
- **Python 3.8+:** Für Example-Code
- **Git:** Zum Klonen der Examples

Alles ist kostenlos und Open Source.

Struktur dieses Buchs

8 Teile, 30 Kapitel, ~880 Seiten

Jedes Kapitel folgt diesem Muster: 1. **Überblick:** Was Sie lernen werden 2. **Theorie:** Konzepte erklärt 3. **Praxis:** Vollständige Examples 4. **Patterns:** Best Practices 5. **Performance:** Optimierung 6. **Zusammenfassung:** Key Takeaways

Wie dieses Buch entstand

Dieses Buch ist das Ergebnis von: - **700+ einzelne Dokumente** konsolidiert - **21 vollständige Example-Projekte** integriert - **Monate an Reviews** von Entwicklern und Early Adopters - **Unzählige Iterationen** bis zur perfekten Struktur

Es ist lebendig. Wir aktualisieren es mit jeder ThemisDB-Version. Feedback ist willkommen.

Danksagungen

Ein großes Dankeschön an:

- **Die Community:** Für Feedback, Bug Reports und Feature Requests
- **Early Adopters:** Die ThemisDB in Production eingesetzt haben
- **Contributors:** Für Code, Docs und Examples
- **Reviewer:** Für unzählige Stunden detailliertes Feedback

Besonderer Dank an die Autoren der Bücher, die uns inspiriert haben.

Über die Autoren

Dieses Buch wurde geschrieben vom ThemisDB-Team - Entwickler, die täglich mit der Datenbank arbeiten und sie lieben.

Wir glauben an: - **Open Source:** ThemisDB ist MIT-lizenziert - **Qualität:** Code und Docs auf höchstem Niveau - **Community:** Gemeinsam besser werden

Feedback und Beiträge

Dieses Buch ist Open Source, wie ThemisDB selbst.

Fehler gefunden?

[Issue erstellen](https://github.com/makr-code/ThemisDB/issues) (<https://github.com/makr-code/ThemisDB/issues>)

Verbesserung vorschlagen?

[Pull Request öffnen](https://github.com/makr-code/ThemisDB/pulls) (<https://github.com/makr-code/ThemisDB/pulls>)

Frage stellen?

[Discussion starten](https://github.com/makr-code/ThemisDB/discussions) (<https://github.com/makr-code/ThemisDB/discussions>)

Jeder Beitrag zählt. Auch wenn es nur ein Tippfehler ist.

Los geht's!

Sie halten ein Handbuch in den Händen, das Sie von Null zur ThemisDB-Mastery führen wird.

Es ist eine Reise. Nehmen Sie sich Zeit. Experimentieren Sie mit den Examples. Bauen Sie eigene Projekte.

Und vor allem: Haben Sie Spaß!

Datenbanken sind mächtige Werkzeuge. ThemisDB macht sie zugänglich.

Ready to become a ThemisDB expert?

→ [Kapitel 1: Einführung in ThemisDB](#)

ThemisDB Team

Dezember 2025

Startseite

Version 1.4.0-alpha | Januar 2026

Inhaltsverzeichnis

5	Titelseite (generiert)
2	Vorwort
6	Startseite
8	Inhaltsverzeichnis (automatisch)
9	Abbildungsverzeichnis (automatisch)
10	Stichwortverzeichnis (automatisch)
11	TEIL I - GRUNDLAGEN
12	Kapitel 0 - Genesis
23	Kapitel 1 - Einführung
40	Kapitel 2 - Architektur
77	Kapitel 3 - Multi-Model
99	Kapitel 4 - Installation
67	TEIL II - DATENMODELLE
122	Kapitel 5 - Relational
175	Kapitel 6 - Graph
225	Kapitel 7 - Dokumente
262	Kapitel 8 - Vektoren
301	Kapitel 8b - Storage Layer
135	TEIL III - SPEZIALANWENDUNGEN
326	Kapitel 9 - Zeit-Reihen & IoT
348	Kapitel 10 - Enterprise
420	Kapitel 11 - Realtime
474	Kapitel 12 - Computer Vision
198	TEIL IV - ERWEITERTE FEATURES
509	Kapitel 13 - Volltext-Suche
531	Kapitel 14 - Geo-Spatial Features
551	Kapitel 15 - Analytics
597	Kapitel 16 - Sharding
240	TEIL V - AI & ML INTEGRATION
630	Kapitel 17 - LLM Integration
713	Kapitel 18 - Machine Learning
283	TEIL VI - SKALIERUNG & MONITORING
755	Kapitel 19 - Monitoring
291	Kapitel 19b - Observability
828	Kapitel 20 - Backup
849	Kapitel 21 - Performance
331	TEIL VII - CLIENTS & ENTWICKLUNG
885	Kapitel 22 - Clients
911	Kapitel 23 - Testing & QA
930	Kapitel 24 - AI Ethics
364	TEIL VIII - DEVOPS & INFRASTRUCTURE
966	Kapitel 25 - DevOps & Infrastructure
990	Kapitel 26 - Migration & Legacy
1016	Kapitel 27 - Troubleshooting
383	TEIL IX - REFERENZEN & API
1034	Kapitel 28 - AQL Referenz
1070	Kapitel 29 - Analytics & Process Mining
1104	Kapitel 30 - Deployment & Operations
1144	Kapitel 31 - API Protokolle

1190 Kapitel 32 - AQL OOP Implementierung

1207 Kapitel 33 - Best Practices

436**TEIL X - ADVANCED TOPICS**

1242 Kapitel 34 - Query Optimierung

1256 Kapitel 35 - Data Modeling Patterns

1271 Kapitel 36 - Security Hardening

1289 Kapitel 37 - Ecosystem Integration

458 Kapitel 38 - Observability & SRE

1316 Kapitel 39 - Performance Tuning Cookbook

1324 Kapitel 40 - Data Governance & Compliance

1330 Kapitel 41 - Hands-on Labs

468**ANHÄNGE**

1338 Anhang A - Literatur

1343 Anhang D - Feature Status

1350 Anhang E - Incident Response Runbooks

1367 Anhang F - AQL Cheat Sheet

1385 Anhang G - Configuration Reference

1404 Anhang H - Glossary & Terminology

1420 Anhang I - Troubleshooting Guide

Teil II - Datenmodelle

- [Kapitel 5 - Relational](#)
- [Kapitel 6 - Graph](#)
- [Kapitel 7 - Dokumente](#)
- [Kapitel 8 - Vektoren](#)
- [Kapitel 8b - Storage Layer](#)

Teil III - Spezialanwendungen

- [Kapitel 9 - Zeit-Reihen & IoT](#)
- [Kapitel 10 - Enterprise](#)
- [Kapitel 11 - Realtime](#)
- [Kapitel 12 - Computer Vision](#)

Teil IV - Erweiterte Features

- [Kapitel 13 - Volltext-Suche](#)
- [Kapitel 14 - Geo-Spatial Features](#)
- [Kapitel 15 - Analytics](#)
- [Kapitel 16 - Sharding](#)

Teil V - AI & ML Integration

- [Kapitel 17 - LLM Integration](#)
- [Kapitel 18 - Machine Learning](#)

Teil VI - Skalierung & Monitoring

- [Kapitel 19 - Monitoring](#)
- [Kapitel 19b - Observability](#)
- [Kapitel 20 - Backup](#)
- [Kapitel 21 - Performance](#)

Teil VII - Clients & Entwicklung

- [Kapitel 22 - Clients](#)
- [Kapitel 23 - Testing & QA](#)
- [Kapitel 24 - AI Ethics](#)

Teil VIII - DevOps & Infrastructure

- [Kapitel 25 - DevOps & Infrastructure](#)
- [Kapitel 26 - Migration & Legacy](#)
- [Kapitel 27 - Troubleshooting](#)

Teil IX - Referenzen & API

- [Kapitel 28 - AQL Referenz](#)
- [Kapitel 29 - Analytics & Process Mining](#)
- [Kapitel 30 - Deployment & Operations](#)
- [Kapitel 31 - API Protokolle](#)
- [Kapitel 32 - AQL OOP Implementierung](#)
- [Kapitel 33 - Best Practices](#)

Teil X - Advanced Topics

- [Kapitel 34 - Query Optimierung](#)
- [Kapitel 35 - Data Modeling Patterns](#)
- [Kapitel 36 - Security Hardening](#)
- [Kapitel 37 - Ecosystem Integration](#)
- [Kapitel 38 - Observability & SRE](#)
- [Kapitel 39 - Performance Tuning Cookbook](#)
- [Kapitel 40 - Data Governance & Compliance](#)
- [Kapitel 41 - Hands-on Labs](#)

Teil I - Grundlagen

Kapitel 0 - Genesis

> *"Innovation entsteht nicht durch Beschaffung, sondern durch Notwendigkeit."*

Überblick

Dieses Kapitel erzählt die außergewöhnliche Entstehungsgeschichte von ThemisDB – von einer privaten "Civic Tech"-Initiative bis zur produktionsreifen Multi-Modell-Datenbank. Sie erfahren, welche Probleme zur Entwicklung führten, wie das Projekt wuchs, und welche Meilensteine erreicht wurden. Die Geschichte von ThemisDB ist ein Paradebeispiel dafür, wie technische Innovation aus echten Problemstellungen entsteht und wie eine "Bottom-Up"-Entwicklung zu einem System führen kann, das ursprüngliche Erwartungen übertrifft. Jedes Feature, jede Designentscheidung und jede Architekturkomponente wurde durch konkrete Anforderungen aus der Praxis motiviert. Diese organische Entwicklung führte zu einer Datenbank, die nicht nur theoretisch elegant ist, sondern auch in der realen Welt funktioniert.

Was Sie in diesem Kapitel lernen werden: - Die strategische Ausgangslage und das Problem der UDS3-Architektur - Wie ThemisDB als "Bottom-Up"-Innovation entstand - Die wichtigsten Entwicklungsphasen und Meilensteine - Das Lizenzmodell und die wissenschaftliche Absicherung - Der Status "Production-Ready" (November 2025)

Voraussetzungen: Keine. Dieses Kapitel liefert den historischen Kontext für alle folgenden Kapitel.

Der strategische Imperativ

Die Entwicklung begann nicht als akademisches Projekt oder als Produkt eines Unternehmens, sondern als Antwort auf eine konkrete gesellschaftliche Herausforderung. Die deutsche öffentliche Verwaltung steht vor tiefgreifenden strukturellen Veränderungen, die ohne technologische Innovation nicht bewältigt werden können. Der **demografische Wandel**, die **Digitalisierung** und die **zunehmende Komplexität der Verwaltungsaufgaben** haben einen perfekten Boden geschaffen, der neue Lösungsansätze erforderlich machte. Die sogenannte "Babyboomer"-Generation, die einen Großteil der erfahrenen Fachkräfte in der Verwaltung ausmacht, erreicht das Rentenalter. Gleichzeitig wird es immer schwieriger, qualifizierte

Nachwuchskräfte zu rekrutieren. Diese demografische Schere führt zu einem massiven Wissensverlust und einer Überlastung der verbleibenden Mitarbeiter. Ohne technologische Unterstützungssysteme ist die staatliche Handlungsfähigkeit in kritischen Bereichen gefährdet.

Um diesen Wissensverlust aufzufangen, wurde das VCC-Ökosystem (Veritas, Covina, Clara) konzipiert. VCC ist dabei kein einfacher KI-Chatbot, sondern viel mehr.

- **Veritas:** KI-gestützter agenten-basierter Assistent für Fachexperten, Wissensmanagement und Dokumentenverarbeitung
- **Covina:** Ingestion-Pipeline für heterogene Datenquellen
- **Clara:** large-language-model Verbesserung mit Hilfe von LoRa

***Die Kernidee** Ein souveränes, KI-gestütztes Assistenzsystem, das Fachexperten entlastet, Wissen konserviert und die Effizienz steigern kann.*

D.h. eine Chat-Anfrage über Veritas kann über das Agentensystem aus verschiedenen Datenquellen Informationen zusammentragen um der Sachbearbeiterin, dem Sachbearbeiter eine umfangreiche Sicht auf komplexe Sachzusammenhänge zu geben. Konkret kann man das an einem Bauantrag veranschaulichen. Ein Bürger beantragt die Errichtung eines Carports. Der Bearbeiter muss jetzt für die Sachentscheidung alle relevanten Information zusammentragen, dass beginnt ganz banal bei dem eigentlichen Antragsgegenstand (Bauherr, Bauort, Baugegenstand usw.), den zugrundeliegenden Gesetzen, Verordnungen, Anweisungen, Bebauungsplänen sowohl auf Bundes-, Länder- als auch auf kommunaler Ebene und nicht zuletzt auch der zuletzt gültigen Rechtslage (z.B. Änderungen durch Gerichtsurteile). Um im Bild zu bleiben gibt es für den Sachbearbeiter einen, teils wiederkehrenden, Rechtsrahmen indem er über den Antrag des Bürgers entscheiden muss.

Abb. 0.0: Vereinfachter Bauantrag-Prozess (Brandenburg): Antragseingang → Sachbearbeitung (Vollständigkeit, Fachbeteiligungen) → Entscheidung

Deswegen war bei der Genese auch ein nicht zu vernachlässigender Aspekt, die wirkliche machinennutzbare Abbildung von Verwaltungsprozessen. Es ist einfach zu kurz gesprungen nur anstatt Papierdokumenten jetzt auf E-Mail für den Informationsaustausch zu setzen. Also gibt es ein weiteres technologisches Herz, der **VPB** – ein "Digitaler Zwilling" der Verwaltung [1], [9]:

Abb. 0.1: VPB-Graph für Sachbearbeitung: Antrag → Sachbearbeitung → Bescheid, mit verknüpften Zuständigkeiten (Bund/Land/Kommune), Fachrecht und Präzedenzfällen

Die Anforderung: Graph-RAG – die Kombination von: - **Semantischer Suche** (Vektor-Embeddings für KI) - **Prozessualem Kontext** (Graph-Beziehungen) - **Strukturierten Metadaten** (Relationale Daten) - **Strenger ACID-Konsistenz** (für rechtsverbindliche Akte)

Doch das technologische Herzstück dieses Systems, der „Digitale Zwilling“ der Verwaltung, stieß schnell an eine unüberwindbare Grenze.

Die Genese: Von der privaten Initiative zur Civic Tech

Das Civic Tech Paradigma

ThemisDB ist ein Paradebeispiel für **Civic Tech** [9]. Anstatt auf langwierige Ausschreibungsprozesse zu warten, entstand ThemisDB als Bottom-Up-Innovation. Verwaltungsmitarbeiter mit tiefer IT-Expertise entwickelten in Eigeninitiative einen Prototyp, der die Vision einer nativen Multi-Modell-Datenbank verfolgte. Das Ziel war ein transaktionaler Kern, der Relationen, Graphen und Vektoren in einem einzigen System vereint und damit echte ACID-Garantien ermöglicht.

***Civic Tech** - Technologie, die aus der Mitte der Zivilgesellschaft/Verwaltung für das Gemeinwohl entsteht, anstatt eingekauft zu werden.*

Die Prinzipien: 1. **Problem-driven:** Entwicklung aus echter Notwendigkeit, nicht aus Spezifikation 2.

Practitioner-led: Entwickler sind gleichzeitig Nutzer 3. **Open Source:** Code gehört der Allgemeinheit 4.

Iterativ: Schnelle Iterationen statt jahrelanger Planung

Die Motivation: - Keine Lösung am Markt erfüllte die spezifischen Anforderungen - Hyperscaler-Lösungen zu teuer und mit Vendor-Lock-in - Open-Source-Alternativen mit denselben UDS3-Problemen behaftet

Der „Force Multiplier“: KI-gestützte Entwicklung als Geburtshelfer

Die Realisierung von ThemisDB in einer so kurzen Zeitspanne wäre ohne den Einsatz moderner KI-Werkzeuge wie Google Gemini, GitHub Copilot und spezialisierten Coding-LLMs undenkbar gewesen. Diese Tools fungierten als „Force Multiplier“, die es einem kleinen Team ermöglichten, die Komplexität einer Multi-Modell-Datenbank zu beherrschen.

Demokratisierung der Hochsprachen-Programmierung

Ursprünglich war die Entwicklung von Datenbank-Kernen (in C++ oder Rust) eine Domäne für spezialisierte Informatiker mit jahrzehntelanger Erfahrung. Durch den Einsatz von KI-Assistenten verschob sich dieses Paradigma:

Abstraktion der Komplexität: Die KI übernahm das „Boilerplate“-Coding und die Implementierung komplexer Algorithmen (wie HNSW-Indizes oder MVCC-Logiken) auf Basis präziser fachlicher Instruktionen.

Vom Programmierer zum Architekten: Die Rolle der Entwickler wandelte sich. Anstatt jede Zeile Code mühsam selbst zu schreiben, fungierten sie als Architekten und Reviewer, die die KI-generierten Module validierten und zusammenfügten.

Rapid Prototyping in Lichtgeschwindigkeit

Was früher Monate für die Erstellung eines funktionsfähigen Prototyps (MVP) dauerte, wurde durch KI auf Wochen reduziert: - **Automatisierte Testgenerierung:** KI-Tools erstellten simultan zum Code die passenden Unit-Tests, was eine extrem hohe Iterationsgeschwindigkeit bei gleichbleibender Qualität ermöglichte. - **Fehlerdiagnose in Echtzeit:** Debugging-Prozesse, die normalerweise Tage in Anspruch nehmen können, wurden durch KI-Analyse von Stacktraces und Memory-Dumps in Minuten gelöst.

Civic Tech trifft auf KI-Empowerment

Dieses „KI-Empowerment“ ist der Schlüssel zum Erfolg des Civic-Tech-Ansatzes von ThemisDB. Es erlaubte Experten aus der Verwaltung, die zwar tiefes Domänenwissen, aber nur grundlegende Programmierkenntnisse besaßen, ein System auf Enterprise-Niveau zu bauen:

- **Überbrückung der Wissenslücke:** Die KI übersetzte die komplexen juristischen Anforderungen an ACID-Konsistenz und DSGVO-Compliance direkt in technischen Code.
- **Ressourceneffizienz:** Ein Team von nur drei Personen konnte Aufgaben bewältigen, für die traditionelle IT-Häuser ganze Abteilungen benötigt hätten.

Die neue Ära der Software-Genese ThemisDB ist somit nicht nur ein technologisches Produkt, sondern auch ein Beweis für einen neuen Entwicklungstypus: AI-driven Civic Tech. Die Kombination aus der Notwendigkeit (demografischer Wandel), dem Mut zur Eigeninitiative (Bottom-Up) und den richtigen Werkzeugen (Gemini, Copilot) hat gezeigt, dass die öffentliche Verwaltung wieder zum Innovator werden kann, wenn sie die Kraft der KI für ihre eigenen Ziele nutzt.

Das Scheitern der UDS3-Architektur

Um das Scheitern zu verstehen muss man kurz erklären wie Verwaltungshandeln funktioniert.

Ein stark vereinfachtes Diagramm eines generischen Verwaltungsprozesses: Event -> ein konkretes Anliegen eines Bürgers mit Anspruch auf Verwaltungshandeln, z.B. Bauantrag Verwaltungsakt -> eine Behörde legt einen Vorgang an und übernimmt die Sachbearbeitung und Entscheidungsfindung Entscheidung -> die Behörde trifft eine Entscheidung über das Anliegen des Bürgers, z.B. durch Erteilung eines Bescheides

Die ursprüngliche Planung: Polyglot Persistence

Die behördliche IT-Strategie "Unified Database Strategy 3" (UDS3) [1], [9], die auf dem "Best-of-Breed"-Prinzip basierte: PostgreSQL für Metadaten, Neo4j für Graphen und ChromaDB für Vektoren offenbarte in der Praxis schnell, dass dieser Ansatz einen fundamentalen, juristisch untragbaren Mangel aufwies. Da die Daten physisch auf drei verschiedene Systeme verteilt waren, konnten keine atomaren Transaktionen garantiert werden (sog. ACID - Garantien).

In einem rechtssicheren Verwaltungsumfeld ist dies fatal: Würde beispielsweise ein Dokument nach DSGVO gelöscht, müsste dieser Vorgang zeitgleich in der relationalen Datenbank, im Graphen und im Vektor-Index abgeschlossen sein. Da dies bei getrennten Systemen nur über das komplexe Saga-Pattern und mit dem Risiko der "Eventual Consistency" (BASE) möglich ist, könnten kurzzeitig inkonsistente und damit rechtsunwirksame Zustände entstehen. Für die Entwickler war klar: Für revisionssichere Akte ist "eventuell konsistent" inakzeptabel.

Die Architektur:

Abb. 0.2: UDS3 Polyglot-Persistence-Architektur: Drei unabhängige Datenbanksysteme mit unmöglicher ACID-Gewährleistung über Transaktionen hinweg

- **PostgreSQL:** Relationale Metadaten (Aktenzeichen, Daten, Status)
- **Neo4j:** Prozessbeziehungen und Wissensgraphen
- **ChromaDB:** Vektor-Embeddings für semantische Suche

Die Motivation: "Best-of-Breed" – jede Datenbank für ihre Stärken nutzen.

Der fundamentale Fehler: Eventual Consistency

Die physische Trennung der Daten führte zu einem **juristisch untragbaren Problem** [1]:

Das Problem:


```

# Szenario: Löschung eines Gutachtens nach DSGVO Art. 17
# In ThemisDB mit AQL (atomare Transaktion)
try:
    result = db.query("""
        FOR d IN documents
            FILTER d.id == 'BImSchG-2024-042'
            REMOVE d IN documents
            RETURN OLD
    """)

    # Single atomic operation:
    # 1. Dokument aus Collection gelöscht
    # 2. Vektoren aus Index gelöscht
    # 3. Graph-Edges zu verwandten Docs aufgelöst
    # → Alles oder nichts - KEINE Inkonsistenz möglich

except Exception:
    # Rollback über 3 separate Datenbanken?
    # → UNMÖGLICH ohne komplexes Saga-Pattern!

```

Die Konsequenz: - Atomare Transaktionen über alle drei Systeme sind **unmöglich** [1], [17] - Man muss auf das **Saga-Pattern** [17] mit kompensierenden Transaktionen zurückgreifen - Resultat: **"Eventual Consistency" (BASE)** [18] statt ACID - Ein Verwaltungsakt kann zeitweise in einem inkonsistenten Zustand sein

Das Urteil: Für revisionssichere Verwaltungsakte ist "eventuell konsistent" operativ und rechtlich **inakzeptabel** [1], [9].

0.4 Entwicklungsphasen und Meilensteine

Phase 1: Proof of Concept (Q1-Q2 2025)

Ziel: Validierung des Base Entity Paradigmas

Errungenschaften: - Implementierung des kanonischen "Base Entity"-Speicherformats [3], [4] - Integration von RocksDB als transaktionale Storage-Engine [13], [46] - Erste Tests mit MVCC (Multi-Version Concurrency Control) [20] - Proof of Concept für atomare Transaktionen über Relational, Graph und Vektor

Technologie-Stack: - C++ für Performance-kritische Komponenten - RocksDB TransactionDB für ACID-Garantien - VelocityPack für effiziente Serialisierung [41]

Phase 2: Core Engine (Q2-Q3 2025)

Ziel: Produktionsreife Kern-Engine

Errungenschaften: - Vollständige AQL-Implementierung (Advanced Query Language) [9] - Native Graph-Traversierung mit temporalen Abfragen [9] - HNSW-Index für Vektor-Operationen [25] - Query Optimizer mit kostenbasiertem Planning [9]

Meilensteine: - 45.000 Writes/Sekunde Ingestion-Performance [3], [5], [9] - Sub-Millisekunden Latenz für Lesezugriffe ($p_{50} < 0.1ms$) [9] - MVCC mit Snapshot Isolation [15], [20]

Phase 3: Enterprise Features (Q3-Q4 2025)

Ziel: BSI-konforme Sicherheits- und Compliance-Features

Errungenschaften: - Native RBAC-Implementierung (Role-Based Access Control) [9] - Tamper-Proof Audit Logs mit Hash-Chains [9] - DSGVO-Compliance "by Design" [44]: - Auto-Purge nach Retention-Period - PII Detection und Redaction - Encrypt-then-Sign mit PKI - HashiCorp Vault Integration für Key Management [9]

Status: Wegfall externer Abhängigkeiten wie Apache Ranger [9]

Phase 4: Production-Ready (Oktober-November 2025)

Ziel: Vollständige Produktionsreife für Single-Node-Szenarien

Audit vom 20. November 2025 [9]:

Core Engine:	100% Complete
ACID Transactions:	Production-Ready
Security Stack:	BSI-konform
Performance:	Benchmarked & Validated
Documentation:	Comprehensive
Testing:	All Tests Green (28.10.2025)

Gesamtfortschritt: ~52% (P0-Features: 100%) [9]

Status-Erklärung: "Production-Ready" für Single-Node bedeutet: - Stabile API - ACID-Garantien validiert - Performance-optimiert - Security-gehärtet - Horizontal Scaling in Entwicklung (für Multi-TB-Szenarien)

0.5 Das Lizenzmodell: Sovereign Open Source

MIT-Lizenz mit Government-Klausel

ThemisDB nutzt ein innovatives Lizenzmodell [9]:

Basis: MIT-Lizenz (permissiv und entwicklerfreundlich)

Erweiterung: Government-Klausel verhindert: - Cloud-Anbieter nehmen den Code - Bieten ihn als proprietären Service an - Schließen eigene Erweiterungen

Der Schutz:

- ✓ Entwickler können Code frei nutzen
- ✓ Behörden behalten volle Kontrolle
- ✓ Wissenschaftliche Nutzung uneingeschränkt
- ✗ Kommerzialisierung ohne Rückfluss an Community verhindert

Lizenz-Audit: Alle verwendeten Bibliotheken sind kompatibel und "clean" [9]: - RocksDB (Apache 2.0 / GPL) - simdjson (Apache 2.0) - Arrow (Apache 2.0) - Keine GPL-Kontamination im Core

Das "Amazon-Problem" gelöst

Das Problem: AWS/Azure könnten Open-Source-Code nehmen und als Managed Service verkaufen, ohne zur Community beizutragen.

Die Lösung: Government-Klausel erlaubt nur: - **On-Premise-Nutzung** ohne Einschränkung - **Cloud-Hosting** nur mit Open-Source-Rückfluss - **Kommerzielle Nutzung** mit Lizenzgebühren-Vereinbarung

0.6 Wissenschaftliche Absicherung: Die "Wissensfalle" vermeiden

Das Risiko: Bus-Faktor

Das Problem: ThemisDB entstand aus privater Initiative – Abhängigkeit von wenigen Personen [9]:

Bus-Faktor-Analyse:

Kernentwickler:	2-3 Personen
Code-Ownership:	Konzentriert
Wissenstransfer:	Limitiert
Dokumentation:	Gut, aber personengebunden
→ Risiko bei Ausfall:	HOCH

Die Lösung: Public-Public-Partnership (geplant)

Die Strategie: Systematische wissenschaftliche Begleitung durch akademische Partner [9]:

Angestrebte Forschungsk Kooperationen:

Abb. 0.4: Wissenstransfer-Prozess von implizitem Expertenwissen über wissenschaftliche Dokumentation zu institutionellem Gemeingut style B fill:#f9f9f9,stroke:#2196F3,stroke-width:2px,color:#1a1a1a style C fill:#f9f9f9,stroke:#2196F3,stroke-width:2px,color:#1a1a1a style D fill:#f5f5f5,stroke:#4CAF50,stroke-width:2px,color:#1a1a1a ``

Potenzielle Vorteile: - Wissenstransfer in die wissenschaftliche Community - Unabhängige Validierung der Architektur - Langfristige Wartbarkeit durch institutionelle Absicherung - Community-Building durch akademische Partner

0.7 Der Weg zur Standardisierung

Aktuelle Positionierung (Dezember 2025)

Status: - **Production-Ready** für Single-Node (< 10 TB) - **Production-Ready:** Horizontal Scaling (Sharding, 2-8 Nodes) - **Open Source:** MIT + Government-Klausel - **Wissenschaftliche Validierung:** Angestrebt durch akademische Partner

Marktposition:

Kategorie	Hyperscaler (AWS/Azure)	ThemisDB (Sovereign)
Skalierung	Unbegrenzt	⚙️ Horizontal (2-8+ Nodes)
Ops-Modell	Fully Managed	⚠️ Self-Hosted/Sovereign
Verfügbarkeit	Global	⚙️ Dezentralisierbar
Vendor Lock-in	× Stark	Nein (MIT)

Abb. 0.5: Marktpositionierung: ThemisDB im Quadrant der hohen Datensouveränität und strikten ACID-Garantien vs. Hyperscaler-Modelle

Roadmap: Die nächsten Schritte

Kurzfristig (Q1 2026): - Pilotprojekt in Brandenburg (VCC-Integration) - Performance-Benchmarks gegen Hyperscaler veröffentlichen - Community-Building (Developer Relations)

Mittelfristig (Q2-Q4 2026): - Sharding-Skalierung auf 16+ Nodes - Multi-Datacenter-Replication - BSI-Zertifizierung anstreben

Langfristig (2027+): - Standard-Datenbank für deutsche Verwaltung - Integration in Sovereign Cloud Plattformen - Europäische Adoption fördern

0.8 Lessons Learned: Was ThemisDB besonders macht

Architektonische Entscheidungen

- 1. Native Multi-Model statt Polyglot:** - Konsequente Ablehnung von "Klebstoff-Architekturen" - Ein transaktionaler Kern für alle Datenmodelle - Resultat: ACID über Graph, Vector und Relational
- 2. Performance-First-Design:** - LSM-Trees für Schreiboptimierung [12] - Speicherhierarchie mit LZ4/ZSTD-Kompression [37], [38] - Hardware-aware statt Cloud-abstrahiert
- 3. Pre-Filtering Innovation:** - Umkehrung der Query-Execution-Order - Relationale Indizes vor Vektorsuche - 20x Performance-Gewinn bei RAG-Workloads [2], [5]

Organisatorische Besonderheiten

- 1. Civic Tech Approach:** - Problem-driven Development - Practitioner-led Design - Rapid Iteration statt jahrelanger Planung

2. Wissenschaftliche Flankierung: - Frühe Integration akademischer Partner - Wissenstransfer als Risikominimierung - Public-Public-Partnership als Nachhaltigkeit

3. Sovereign Open Source: - MIT-Lizenz mit Schutzklausel - Community-orientiert ohne Kommerzialisierungsrisiko - Volle Transparenz und Kontrolle

0.9 Stakeholder-Timeline (2025-2027)

Quartal	Schwerpunkt	Ergebnis
Q3 2025	Proof of Concept	ACID über Graph/Vector/Relational demonstriert
Q2 2026	Multi-Datacenter-Replication	Async-Replica mit RPO 0,5s, RTO < 2 min
Q3 2026	BSI-Vorbereitung	Pen-Test + Hardening Guide veröffentlicht
Q4 2026	Sharding-Preview	16-Node-Lab mit linearem Scale-out (OLTP + Vektor)

Leitplanken: - Fokus auf Verwaltungs-Workloads (Akten, Graph-RAG, Audit-Logs) - Security-by-Design (TLS, mTLS, FIPS-geeignete Krypto) - Keine Abhängigkeit von Hyperscaler-spezifischen Diensten

0.10 Governance & Finanzierung

- **Lizenzmodell:** MIT mit Government-Klausel (Souveränität, Fork-Freiheit)
- **Finanzierung:** Public-Public-Partnership + Fördermittel für OSS-Infrastruktur
- **Betriebsmodell:** Referenzbetrieb bei VCC, Replikation durch Länder/Kommunen
- **Contribution-Model:** Maintainer-Council (VCC + akademische Partner) + Public RFCs
- **Security-Prozess:** Responsible Disclosure, 90-Tage-Window, CVE-IDs durch Maintainer

0.11 Risiko- und Compliance-Landkarte

Top-Risiken und Gegenmaßnahmen: - **Rechtsgrundlagen:** DSGVO/DSG-EKD/KRITIS → Privacy by Design, Audit-Trails, FDE - **Verfügbarkeit:** Rechenzentrums-Ausfall → Multi-AZ-Replikation, Backups, Runbooks - **Integrität:** Korruption/Manipulation → ACID, Write-Ahead-Log, Checksums pro Base Entity - **Lieferkette:** Supply-Chain-Angriffe → SBOM, reproduzierbare Builds, Sigstore - **Betriebsfehler:** Fehlkonfiguration → Safe Defaults, Linter für Configs, Readonly-Mode

Compliance-Checks (Kurzcheckliste): - [] TLS 1.3 + mTLS aktiviert - [] Audit-Logs unveränderbar (WORM Storage) - [] Backups mit Air-Gap getestet (Restore-Drill) - [] Keys in HSM/TPM verwaltet - [] Admin-Aktionen 4-Augen-Prinzip

0.12 Change-Management & Adoption

- **Trainingspfad:** 2-Tages-Workshop (AQL + Ops), 1-wöchige Mentoring-Phase
- **Migrationsmuster:** Strangler-Fig fürs Alt-System, Parallel-Reads, Read-Cutover nach SLAs
- **KPIs:** MTTR < 15 min, RPO <= 60 s, Query-P99 < 200 ms, Import 50k Docs/min
- **Dokumentation:** Living Runbooks, Incident-Postmortems, Architektur-Entscheidungsprotokolle

Zusammenfassung

Die Entwicklung von ThemisDB ist eine außergewöhnliche Geschichte:

Der Ausgangspunkt: Ein fundamentales Problem (UDS3-Inkonsistenz) bedroht kritische Verwaltungsprozesse.

Die Antwort: Eine Bottom-Up-Innovation aus der Verwaltung selbst – Civic Tech in Reinform.

Das Ergebnis: Eine Production-Ready Multi-Modell-Datenbank, die: - ACID-Garantien über alle Datenmodelle bietet - 20x schneller bei RAG-Workloads ist als Konkurrenz - Lizenzkostenfrei und ohne Vendor-Lock-in - Wissenschaftlich validiert und langfristig abgesichert

Der nächste Schritt: Jetzt lernen Sie die technischen Details kennen.

→ [Weiter zu Kapitel 1: Einführung in ThemisDB](#)

Referenzen für dieses Kapitel: - [1] Strategische Gesamtanalyse - [2] Strategische Analyse - [3] ThemisDB Dokumentation und Berichtsanalyse - [9] Forschungsbericht ThemisDB 2025 - Vollständige Literaturliste: [Anhang A](#)

Kapitel 1: Kapitel 1 - Einführung

"Die Wahl der richtigen Datenbank ist wie die Wahl des richtigen Werkzeugs: Ein Hammer ist perfekt für Nägel, aber schrecklich für Schrauben. ThemisDB ist der Werkzeugkasten, der beides kann – und noch viel mehr."

Überblick

Willkommen bei ThemisDB, einer modernen Multi-Model-Datenbank, die entwickelt wurde, um die Grenzen traditioneller Datenbankarchitekturen zu überwinden. In diesem einführenden Kapitel lernen Sie die Grundkonzepte, die Philosophie und die Kernfähigkeiten von ThemisDB kennen. Moderne Anwendungen haben komplexe Datenanforderungen, die sich nicht mehr mit einem einzigen Datenmodell abbilden lassen. Gleichzeitig führt der Einsatz mehrerer spezialisierter Datenbanken zu operationaler Komplexität und Konsistenzproblemen. ThemisDB löst dieses Dilemma durch einen einheitlichen Multi-Model-Ansatz, der verschiedene Datenmodelle in einer kohärenten Plattform vereint. Dieses Kapitel zeigt Ihnen, warum dieser Ansatz notwendig ist und wie ThemisDB ihn umsetzt.

Was Sie in diesem Kapitel lernen werden: - Warum wir ThemisDB entwickelt haben und welche Probleme es löst - Die vier Datenmodelle und wie sie zusammenarbeiten - Grundlegende Architektur und Designentscheidungen - Wie sich ThemisDB von anderen Datenbanken unterscheidet - Erste Schritte und ein einfaches Beispiel

Voraussetzungen: Grundkenntnisse in Datenbanken sind hilfreich, aber nicht erforderlich. Wir erklären alle Konzepte von Grund auf.

1.1 Die Multi-Model-Herausforderung

In der modernen Softwareentwicklung stehen Entwickler vor einem fundamentalen Dilemma: Jede Datenbank-Technologie ist für bestimmte Anwendungsfälle optimiert, aber echte Anwendungen haben vielfältige Anforderungen. Ein E-Commerce-System benötigt relationale Strukturen für Bestellungen, dokumentenbasierte Flexibilität für Produktkataloge, Graph-Traversierung für Empfehlungen und Vektor-Suche für intelligente Produktsuche. Traditionell führt dies zu "polyglotter Persistenz" – dem Einsatz

mehrerer spezialisierter Datenbanken. Doch dieser Ansatz schafft mehr Probleme als er löst. ThemisDB bietet eine alternative Lösung: Alle Datenmodelle in einem System, mit gemeinsamen ACID-Transaktionen und einheitlichem Management.

Das Problem polyglotter Persistenz

Stellen Sie sich ein modernes E-Commerce-Unternehmen vor, das über die Jahre ein komplexes Ökosystem aus verschiedenen Datenbanktechnologien aufgebaut hat. Die Entwickler haben über die Jahre ein komplexes Ökosystem aufgebaut, bei dem jede Datenbank für einen spezifischen Zweck ausgewählt wurde. Auf den ersten Blick erscheint dies als Best Practice: Nutze das beste Werkzeug für jede Aufgabe. Doch die Realität sieht anders aus. Jedes System benötigt eigene Expertise, eigenes Monitoring, eigene Backup-Strategien und eigene Security-Konfigurationen. Am kritischsten ist jedoch das Konsistenzproblem: Transaktionen können nicht über Systemgrenzen hinweg garantiert werden.

- **PostgreSQL** für Benutzerkonten und Bestellungen
- **MongoDB** für Produktkataloge und Reviews
- **Neo4j** für Empfehlungen und Social Graph
- **Elasticsearch** für Produktsuche
- **Redis** für Session-Management und Caching
- **InfluxDB** für Metriken und Zeitreihen

Jede dieser Datenbanken wurde für einen spezifischen Zweck ausgewählt. Jede macht ihren Job gut. Aber das Gesamtsystem ist ein Albtraum:

Anzahl der Systeme:	6
Verschiedene APIs:	6
Backup-Strategien:	6
Monitoring-Tools:	6
Security-Konfigurationen:	6
Team-Expertise nötig:	6 × Spezialisten

Das Resultat: Hohe Komplexität, teure Wartung, schwierige Debugging-Sessions, und Datenkonsistenz über Systemgrenzen ist nahezu unmöglich.

Abb. 01.1: ThemisDB Multi-Model Architektur

Der fundamentale Fehler: Eventual Consistency

Das kritischste Problem polyglotter Persistenz ist nicht die operationale Komplexität, sondern die **unmögliche Datenkonsistenz** [1], [17]:

Warum Polyglot Persistence ACID unmöglich macht:

```
# Szenario: Lösche einen Benutzer und alle zugehörigen Daten
# Daten verteilt über: PostgreSQL, Neo4j, ChromaDB

try:
    # Schritt 1: Lösche aus PostgreSQL
    postgres.execute("DELETE FROM users WHERE id = 123")

    # Schritt 2: Lösche aus Neo4j
    neo4j.execute("MATCH (u:User {id: 123}) DETACH DELETE u")

    # Schritt 3: Lösche aus ChromaDB
    chromadb.delete(collection="user_embeddings", ids=["123"])

    # Problem: Was wenn Schritt 3 fehlschlägt?
    # → User ist aus PostgreSQL und Neo4j gelöscht, aber Vector-Daten existieren noch!
    # → System ist inkonsistent
except Exception:
    # Rollback? Unmöglich über 3 separate Datenbanken!
    # Saga-Pattern nötig: Komplexe kompensierende Transaktionen
    pass
```

Polyglot Persistence erzwingt systemisch "**Eventual Consistency**" (**BASE**) [18] statt starker ACID-Garantien [16]. Für viele Anwendungsfälle – insbesondere im behördlichen Kontext, Financial Services oder Healthcare – ist ein Zustand "eventueller Konsistenz" operativ und rechtlich untragbar [1].

Abb. 01.2: Datenmodell-Übersicht

Der Multi-Model-Ansatz

ThemisDB nimmt einen anderen Weg. Anstatt spezialisierte Datenbanken zu kombinieren, bieten wir **vier Datenmodelle in einem System**:

1. **Relational**: Strukturierte Daten mit ACID-Garantien
2. **Graph**: Beziehungen und Netzwerkstrukturen

3. **Dokument:** Flexible, schema-freie JSON-Daten

4. **Vektor:** Embeddings für AI/ML und Ähnlichkeitssuche

Der Vorteil: Ein System, eine API, eine Query-Sprache (AQL), ein Backup-Prozess, eine Security-Konfiguration.

Abb. 01.3: Query-Processing-Pipeline

Ist das nicht nur ein Kompromiss?

Eine berechtigte Frage. Die traditionelle Weisheit sagt: "Jack of all trades, master of none." Aber ThemisDB wurde von Grund auf so designed, dass jedes Modell native Performance hat:

- **Relationale Daten:** Schneller als viele SQL-Datenbanken durch optimierte Indexstrukturen
- **Graph-Traversierung:** Vergleichbar mit Neo4j durch native Property Graph Storage
- **Dokumentsuche:** Elasticsearch-ähnliche Performance durch invertierte Indizes
- **Vektor-Search:** State-of-the-art HNSW-Algorithmus für ANN-Queries

Das Geheimnis: Native Multi-Model-Architektur

ThemisDB speichert nicht "alles in einem Topf", sondern verwendet ein kanonisches "**Base Entity**"-Speicherformat [3], [4]:

1. **Einheitliche Speicherschicht:** Alle Datenmodelle (Relational, Graph, Dokument, Vektor) werden als binär-serialisierte "Blobs" in RocksDB gespeichert [11], [13]
2. **Spezialisierte Projektionen:** Leseoptimierte Index-Projektionen pro Modell (relationaler Index, Graph-Adjazenz, HNSW-Vector-Index) [3], [25]
3. **Gemeinsame Transaction Layer:** RocksDB TransactionDB garantiert ACID über alle Modelle hinweg [20], [46]

Der entscheidende Unterschied zu Polyglot Persistence:

```
# ThemisDB: Eine atomare Transaktion über alle Modelle
with themis_db.transaction() as tx:
    # Relationale Daten aktualisieren
    tx.update_table("users", user_id, {"name": "Alice", "age": 30})

    # Graph-Kante erstellen
    tx.create_edge("friends", from_id=user_id, to_id=friend_id)

    # Vektor-Embedding speichern
    tx.update_vector("user_embeddings", user_id, embedding)

    # ENTWEDER: Alle 3 Operationen erfolgreich
    # ODER: Alle 3 werden zurückgerollt (atomarer Rollback)
    tx.commit() # ACID-garantiert!
```

Abb. 01.4: Storage-Engine-Architektur

Dies ist architektonisch nur möglich, weil alle Daten physisch im selben transaktionalen Backend (RocksDB TransactionDB) liegen. Siehe Kapitel 2.4 für technische Details.

1.2 Architektur-Philosophie

UNIX-Prinzipien für Datenbanken

ThemisDB folgt bewährten Design-Prinzipien:

1. Modularität

Jede Komponente hat eine klar definierte Aufgabe:

Abb. 01.5: Use-Case-Szenarien

2. Composability

Modelle können in einer Query kombiniert werden:

```
-- Finde ähnliche Produkte (Vektor)
-- für Freunde des Nutzers (Graph)
-- die in Berlin wohnen (Relational)

FOR user IN friends_of(@userId)
  FILTER user.city == "Berlin"
  FOR product IN similar_products(user.last_viewed, k: 10)
    RETURN { user: user, recommendation: product }
```

3. Explizit über Implizit

Keine Magie, keine versteckten Optimierungen. Jede Query zeigt klar, was sie tut. Der `EXPLAIN` Befehl zeigt den exakten Execution Plan.

Warum RocksDB als Foundation?

ThemisDB nutzt RocksDB als Storage-Engine. Diese Wahl war bewusst:

Vorteile von RocksDB: - **Bewährt:** Von Facebook für billions of operations/day entwickelt - **Schnell:** Optimiert für SSDs, log-structured merge trees - **Flexibel:** Key-Value Store als Foundation für höhere Modelle - **Zuverlässig:** ACID-Garantien, WAL, Compression, Snapshots

Unsere Erweiterungen: - Custom Comparators für verschiedene Datentypen - Spezielle Column Families pro Datenmodell - Optimierte Merge Operators für Counters und Sets - Geo-Index Layer mit Hilbert Curves

1.3 Die vier Säulen von ThemisDB

Säule 1: Relationales Modell

Use Case: Strukturierte Geschäftsdaten

```
-- Klassische relationale Query
INSERT INTO users {
  user_id: "alice",
  email: "alice@example.com",
  created_at: DATE_NOW()
}

-- Join über mehrere Tabellen
FOR order IN orders
  FILTER order.user_id == "alice"
  FOR item IN order_items
    FILTER item.order_id == order.order_id
  RETURN { order, item }
```

Besonderheiten: - Secondary Indexes (B-Tree und Hash) - ACID-Transaktionen mit Snapshot Isolation - Constraints (Unique, Foreign Key, Check) - Performance: 45.000 Writes/s, 120.000 Reads/s (single node)

Säule 2: Graph-Modell

Use Case: Beziehungsnetzwerke, Recommendations

```
-- 3-Hop Traversierung: Freunde von Freunden
FOR person IN persons
  FILTER person.name == "Alice"
  FOR friend IN 1..3 OUTBOUND person friends
    RETURN DISTINCT friend

-- Kürzester Pfad mit Dijkstra
LET path = SHORTEST_PATH(
  "users/alice",
  "users/bob",
  OUTBOUND friends
  WEIGHT edge.distance
)
RETURN path
```

Besonderheiten: - Native Property Graph Storage - Edge-Indizes für schnelle Traversierung - Path Constraints (Zyklen-Erkennung, Max Depth) - Algorithmen: BFS, DFS, Dijkstra, A*, PageRank

Säule 3: Dokument-Modell

Use Case: Schema-freie, flexible Daten

```
-- Beliebige JSON-Strukturen
INSERT INTO products {
  sku: "LAPTOP-2024",
  specs: {
    cpu: { model: "Intel i7", cores: 8 },
    ram: { size_gb: 32, type: "DDR5" },
    storage: [
      { type: "SSD", size_gb: 1000 },
      { type: "HDD", size_gb: 2000 }
    ]
  },
  tags: ["business", "high-performance"]
}

-- Nested Field Access
FOR product IN products
  FILTER product.specs.ram.size_gb >= 16
  RETURN product.sku
```

Besonderheiten: - Dynamische Schemas, keine Migration nötig - Nested Object Indexing - Array Operations (flatten, unwind) - JSON Schema Validation (optional)

Säule 4: Vektor-Modell

Use Case: AI/ML, Semantic Search, Embeddings

```
-- Ähnlichkeitssuche mit Embeddings
LET query_embedding = EMBED_TEXT("Modern laptop for developers")

FOR product IN products
  LET similarity = COSINE_SIMILARITY(
    query_embedding,
    product.embedding
  )
  FILTER similarity > 0.8
  SORT similarity DESC
  LIMIT 10
  RETURN { product, similarity }
```

Besonderheiten: - HNSW-Index für Approximate Nearest Neighbor - Unterstützt Cosine, Euclidean, Dot Product - Dimensionen: bis zu 2048 - GPU-Acceleration für Batch Embeddings

1.4 ThemisDB im Vergleich

vs. PostgreSQL

Aspekt	PostgreSQL	ThemisDB
Datenmodelle	Relational	Relational + Graph + Document + Vector
Graph Queries	Recursive CTEs (langsam)	Native Property Graph (schnell)
JSON	JSONB (gut)	Native Document Store
Vektor Search	pgvector Extension	Native mit HNSW
Skalierung	Vertical + Replication	Horizontal Sharding

Wann PostgreSQL? Wenn Sie nur relationale Daten haben und auf SQL-Kompatibilität angewiesen sind.

Wann ThemisDB? Wenn Sie mehrere Datenmodelle brauchen oder horizontale Skalierung planen.

vs. Neo4j

Aspekt	Neo4j	ThemisDB
Graph Performance	Exzellent	Sehr gut
Nicht-Graph-Daten	Umständlich	Native Support
Query Language	Cypher	AQL (Cypher-inspiriert, erweitert)
ACID Scope	Nur Graph	Über alle Modelle
Lizenz	Enterprise kostenpflichtig	Open Source (MIT)

Wann Neo4j? Wenn 100% Ihrer Daten Graphen sind und Sie Cypher-Expertise haben.

Wann ThemisDB? Wenn Graphen nur ein Teil Ihrer Daten sind oder Sie flexible Kombinationen brauchen.

vs. MongoDB

Aspekt	MongoDB	ThemisDB
Document Model	Sehr gut	Sehr gut
Schema Validation	JSON Schema	JSON Schema
Joins	\$lookup (langsam)	Native (schnell)
Transactions	Seit 4.0	Von Anfang an
Graph Queries	Nicht nativ	Native Property Graph

Wann MongoDB? Wenn Sie ausschließlich Dokumente speichern und MongoDB-Expertise haben.

Wann ThemisDB? Wenn Sie Dokumente mit relationalen oder Graph-Daten kombinieren wollen.

1.5 Erste Schritte: Hello World

Lassen Sie uns ThemisDB in Aktion sehen. Dieses Example basiert auf `examples/01_hello_world`.

Installation (Docker)

Der schnellste Weg, ThemisDB zu starten:

```
# ThemisDB mit Docker starten
docker run -d -p 8765:8765 themisdb/themisdb:1.4.0-alpha

# Warten bis Server bereit ist
sleep 5

# Testen
curl http://localhost:8765/health
```

Output:

```
{
  "status": "ok",
  "version": "1.4.0-alpha",
  "uptime": 5.2
}
```

Python Client installieren

```
pip install themisdb-client
```

Ihr erstes Programm

Das folgende Hello-World-Beispiel zeigt die grundlegenden CRUD-Operationen (Create, Read, Update, Delete) in ThemisDB. Der Code demonstriert, wie einfach es ist, eine Collection zu erstellen, Dokumente einzufügen, Queries auszuführen und Daten zu verwalten.

Vollständiger Code: `examples/01_hello_world/main.py`

```
from themisdb import Client

# Verbindung zu ThemisDB
client = Client("localhost", 8765)

# Collection erstellen
client.create_collection("users")

# Dokument einfügen
user = {"_key": "alice", "name": "Alice Smith", "age": 28, "city": "Berlin"}
result = client.insert("users", user)
print(f"✓ User erstellt: {result['_id']}")

# Query ausführen
query = "FOR user IN users FILTER user.city == 'Berlin' RETURN user"
results = client.query(query)
print(f"✓ {len(results)} Benutzer in Berlin gefunden")

# Dokument aktualisieren und löschen
client.update("users", "alice", {"age": 29})
client.delete("users", "alice")
```

Weitere Operationen im vollständigen Beispiel: - GET-Abfrage für einzelnes Dokument - Batch-Operationen für mehrere Dokumente - Error-Handling und Validierung

Ausführen:

```
$ python main.py

✓ User erstellt: users/alice
✓ User abgerufen: Alice Smith
✓ 1 Benutzer in Berlin gefunden
✓ User aktualisiert
✓ User gelöscht
```

Was haben wir gelernt?

1. **Collections:** Container für Dokumente (wie Tabellen in SQL)

2. **_key**: Benutzer-definierter Identifier
 3. **_id**: Auto-generiert als `collection/key`
 4. **CRUD**: Create, Read, Update, Delete
 5. **AQL**: Query-Sprache ähnlich SQL, aber mächtiger
-

1.6 Multi-Model in Aktion

Ein komplexeres Beispiel, das alle vier Modelle nutzt:

Szenario: Social E-Commerce

Dieses Beispiel zeigt die Leistungsfähigkeit der Multi-Model-Architektur: Es kombiniert relationale Daten (Benutzer), Graph-Beziehungen (Freundschaften), Dokumente (Produkte mit nested Objects) und Vektoren (Embeddings für Semantic Search) in einer einzigen Query.

Vollständiger Code: `examples/01_hello_world/multi_model_demo.py` (~85 Zeilen)

```
# 1. Benutzer (Relational)
client.insert("users", {"_key": "alice", "email": "alice@example.com"})

# 2. Freundschaft (Graph)
client.insert("friends", {"_from": "users/alice", "_to": "users/bob"})

# 3. Produkt mit nested Specs (Dokument)
client.insert("products", {
  "_key": "laptop-x1",
  "name": "Developer Laptop X1",
  "specs": {"cpu": "Intel i7", "ram_gb": 32},
  "embedding": [0.1, 0.5, -0.3, ...] # 768-dim Vektor
})

# 4. Multi-Model Query: Graph-Traversierung + Vektor-Ähnlichkeit
query = """
FOR friend IN 1..2 OUTBOUND "users/alice" friends
  FOR order IN orders
    FILTER order.user_id == friend.user_id
  FOR product IN products
    FILTER product.sku == order.sku
    LET similarity = COSINE_SIMILARITY(product.embedding, @alice_last_embedding)
    FILTER similarity > 0.7
    RETURN {friend: friend.user_id, product: product.name, similarity}
"""

recommendations = client.query(query, {"alice_last_embedding": alice_vector})
```

Zusätzliche Features im vollständigen Beispiel: - Batch-Insert für Testdaten (100 Produkte, 50 Benutzer) - Fallback-Logik bei niedrigen Similarity-Scores - Performance-Metriken (Query-Zeit, Result-Count)

Was passiert hier?

1. **Graph-Traversierung:** Finde Alices Freunde (2 Hops)
2. **Relational Join:** Verbinde mit Bestellungen
3. **Dokument-Query:** Hole Produktdetails
4. **Vektor-Similarity:** Finde ähnliche Produkte

Alles in einer Query, atomar, konsistent.

1.7 Quickstart (5 Minuten)

1. **Docker starten:** `docker run -d -p 8765:8765 themisdb/themisdb:1.4.0-alpha`

2. **Healthcheck prüfen:** `curl http://localhost:8765/health`

3. **Minimal-Collection anlegen:**

```
FOR i IN 1..3
  INSERT { _key: CONCAT('u', i), name: CONCAT('User ', i) } INTO users
```

1. **Query testen (Graph + Filter):**

```
FOR u IN users
  FILTER u.name LIKE 'User%'
  RETURN u.name
```

1. **Backup ziehen:** `curl -X POST http://localhost:8765/admin/snapshot`

1.8 Entscheidungsmatrix: Wann ThemisDB?

Bedarf	Ja	Nein
ACID über Graph + Vektor		×
Single-System für Multi-Model		×
Niedrige Latenz bei RAG (Pre-Filter)		×
Sovereign / On-Prem Pflicht		×
Managed Cloud bevorzugt	×	

1.9 Capability-Map nach Rollen

- **Architekten:** Multi-Model-Konsistenz, Storage-Design, Index-Strategien

- **Entwickler:** AQL Patterns, Graph/Vector Kombis, Schema-Evolution
- **Ops/SRE:** Health/Metric-Endpoints, Backups, Sharding-Roadmap
- **Security:** TLS/mTLS, Audit-Logs, Least-Privilege-Config
- **Fachseite:** Datenmodellierung, Self-Service-Queries, Validations

1.10 FAQ (Kurzfassung)

- **Ist ThemisDB SQL-kompatibel?** Nein, AQL ist bewusst modellübergreifend (FOR/FILTER/RETURN).
- **Wie wird Konsistenz garantiert?** RocksDB TransactionDB + einheitliches WAL + MVCC.
- **Wie skaliert das System?** Vertikal heute, Sharding-Roadmap 2026 (16 Nodes Lab fertig).
- **Wie sicher?** TLS 1.3, mTLS optional, Audit-Logs WORM-fähig, Supply-Chain-Schutz via SBOM.
- **Migration?** Strangler-Fig: Legacy bleibt lesend, neue Writes in ThemisDB, später Cutover.

1.11 Zusammenfassung

In diesem Kapitel haben Sie gelernt:

Das Problem: Polyglot Persistence ist komplex und teuer

Die Lösung: Multi-Model in einem System

Die Architektur: Modular, composable, explizit

Die Modelle: Relational, Graph, Dokument, Vektor

Der Vergleich: Wann ThemisDB vs. Alternativen

Die Praxis: Hello World und Multi-Model Example

Nächste Schritte

Im nächsten Kapitel tauchen wir tiefer in die **Architektur** ein: - Wie funktioniert das Storage Layer? - Wie werden Transaktionen über Modelle hinweg garantiert? - Wie skaliert ThemisDB horizontal?

[Kapitel 2: Architektur-Überblick →](#)

Weiterführende Ressourcen

- **Complete Example:** [examples/01_hello_world](#)
- **Installation Guide:** [Kapitel 4 - Setup und Installation](#)

- **AQL Tutorial:** [Kapitel 13 - AQL Mastery](#)
- **API Referenz:** [../de/apis/apis_openapi.md](#)

Kapitel 1 von 30 | Teil I: Grundlagen | ~7.200 Wörter

Kapitel 2: Kapitel 2 - Architektur

"Eine gute Architektur ist wie ein gutes Fundament - unsichtbar, aber entscheidend für alles, was darauf aufbaut."

Überblick

In diesem Kapitel tauchen wir tief in die Architektur von ThemisDB ein. Sie lernen, wie die verschiedenen Schichten zusammenarbeiten, wie Transaktionen garantiert werden, und wie MVCC (Multi-Version Concurrency Control) Parallelität ohne Locks ermöglicht.


Was Sie in diesem Kapitel lernen werden: - Die Schichten-Architektur von ThemisDB - Wie MVCC funktioniert und warum es wichtig ist - Transaction Management und ACID-Garantien - Storage Layer mit RocksDB - Indexstrukturen für Performance - Praktische Demonstration mit einer Todo-App

Voraussetzungen: Kapitel 1 gelesen, Grundverständnis von Datenbanken.

2.1 Die Schichten-Architektur

ThemisDB folgt einer klassischen Schichten-Architektur, wobei jede Schicht klare Verantwortlichkeiten hat.

Die fünf Schichten



	• Compression (LZ4, Zstandard)	
	• Snapshots & Backups	

Warum diese Aufteilung?

Separation of Concerns: Jede Schicht hat eine klar definierte Aufgabe und kann unabhängig optimiert oder ersetzt werden.

Beispiel: Wenn wir in Zukunft eine neue Storage-Engine einführen wollen, müssen wir nur Schicht 5 ändern - alle anderen Schichten bleiben unverändert.

2.2 MVCC: Parallelität ohne Locks

Das Problem mit Locks

Traditionelle Datenbanken verwenden Locks:

```
# Traditionell: Pessimistic Locking
transaction1.begin()
transaction1.lock(row_id) # Row wird gesperrt
transaction1.update(row_id, new_value)
transaction1.unlock(row_id)
transaction1.commit()

# Problem: Transaction 2 muss warten
transaction2.begin()
transaction2.lock(row_id) # BLOCKIERT bis transaction1 fertig ist!
```

Problem: Bei hoher Parallelität führt dies zu: - Warteschlangen und Bottlenecks - Deadlocks zwischen Transaktionen - Timeouts und Failed Transactions

Die MVCC-Lösung

MVCC (Multi-Version Concurrency Control) erstellt stattdessen Versionen:

```
# MVCC: Optimistic Concurrency
transaction1.begin(snapshot_id=100)
# Liest Version 100 der Daten
transaction1.read(row_id) # Version 100

# Gleichzeitig kann transaction2 lesen!
transaction2.begin(snapshot_id=100)
transaction2.read(row_id) # Auch Version 100, keine Wartezeit!

# Transaction 1 schreibt
transaction1.update(row_id, value_a) # Erstellt Version 101
transaction1.commit() # Version 101 wird permanent

# Transaction 2 schreibt auch
transaction2.update(row_id, value_b) # Will auch Version 101 erstellen
transaction2.commit() # FEHLER: Conflict Detection!
# "Row was modified by another transaction"
```

Vorteil: Reads blockieren nie Writes, Writes blockieren nie Reads.

Abb. 02.1: Systemarchitektur-Übersicht

Wie funktioniert MVCC intern?

Jede Datenzeile hat nicht nur einen Wert, sondern eine Historie:

```
Row ID: users/alice
```

```
Version 100 (committed):
```

```
  name: "Alice Smith"
```

```
  age: 28
```

```
Version 101 (committed):
```

```
  name: "Alice Smith"
```

```
  age: 29
```

```
Version 102 (in_progress, transaction_id=555):
```

```
  name: "Alice Johnson"
```

```
  age: 29
```

Snapshot-Reads: Eine Transaktion mit `snapshot_id=100` sieht nur Versionen ≤ 100 , die committed sind.

Write-Write Conflicts: Wenn zwei Transaktionen die gleiche Row ändern wollen, gewinnt die erste. Die zweite bekommt einen Conflict Error beim Commit.

Abb. 02.2: Query-Engine-Komponenten

2.3 Transaction Management

ACID-Garantien

ThemisDB garantiert volle ACID-Properties:

A - Atomicity (Atomarität):

Alle Operationen in einer Transaktion passieren komplett oder gar nicht.

```
# Beispiel: Geldtransfer
```

```
transaction.begin()
```

```
transaction.update("accounts/alice", {"balance": 900}) # -100
```

```
transaction.update("accounts/bob", {"balance": 1100}) # +100
```

```
transaction.commit() # Beide Updates oder keines!
```

Wenn der Server zwischen den beiden `update()` Calls abstürzt: - **Ohne Atomarität:** Alice verliert 100€, Bob bekommt nichts (Katastrophe!) - **Mit Atomarität:** Beide Updates werden zurückgerollt (Konsistent!)

C - Consistency (Konsistenz):

Constraints werden immer eingehalten.

```
# Foreign Key Constraint
transaction.insert("orders", {
  "order_id": "o123",
  "user_id": "alice", # Muss in users existieren
  "amount": 50.0
})
# Wenn user "alice" nicht existiert -> FEHLER!
```

I - Isolation (Isolierung):

Transaktionen sehen sich nicht gegenseitig.

```
# Transaction 1 liest
t1.read("products/laptop") # price: 999

# Transaction 2 ändert (aber committed noch nicht)
t2.update("products/laptop", {"price": 899})

# Transaction 1 liest nochmal
t1.read("products/laptop") # Immer noch 999!
# Sieht die Änderung von T2 NICHT, bis T2 committet
```

D - Durability (Dauerhaftigkeit):

Einmal committed, sind Daten permanent - auch bei Serverausfall.

```
transaction.commit()

# Ab hier garantiert: Daten sind auf Disk!
# Selbst wenn Server JETZT abstürzt, sind Daten da.
```

Abb. 02.3: Storage-Layer-Struktur

Isolation Levels

ThemisDB implementiert **Snapshot Isolation**, ein Mittelweg zwischen Serializable und Read Committed:

Isolation Level	Dirty Reads	Non-Repeatable Reads	Phantom Reads
Read Uncommitted	✗ Möglich	✗ Möglich	✗ Möglich
Read Committed	✓ Verhindert	✗ Möglich	✗ Möglich
Snapshot Isolation	✓ Verhindert	✓ Verhindert	✓ Verhindert
Serializable	✓ Verhindert	✓ Verhindert	✓ Verhindert

Snapshot Isolation ist performanter als Serializable, verhindert aber trotzdem alle Anomalien, die in der Praxis relevant sind.

2.4 Storage Layer: RocksDB

Warum RocksDB?

ThemisDB verwendet RocksDB als Storage-Engine. Diese Entscheidung basiert auf mehreren Faktoren:

1. LSM-Trees für SSDs optimiert

Traditionelle B-Trees schreiben oft:

```
Write 1 byte → Read 4KB page → Modify 1 byte → Write 4KB page
```

LSM-Trees (Log-Structured Merge Trees) schreiben sequentiell:

```
Write 1 byte → Append to log → Done
Later: Merge logs in background
```

Resultat: 10x schneller auf SSDs!

2. Battle-Tested bei Facebook

RocksDB verarbeitet bei Facebook: - Billions of operations per day - Petabytes of data - 10+ years Production Experience

3. Flexible Key-Value API

RocksDB ist ein Key-Value Store - perfekt als Foundation für höhere Modelle:

```
// Relational: key = "users/alice"
db->Put("users/alice", json_data);

// Graph: key = "edges/from_alice_to_bob"
db->Put("edges/from_alice_to_bob", edge_data);

// Vector: key = "vectors/product_123"
db->Put("vectors/product_123", embedding_data);
```

Column Families

RocksDB unterstützt "Column Families" - separate Namespaces innerhalb einer DB:

```
// Trennung nach Datenmodell
db->Put(cf_relational, "users/alice", data);
db->Put(cf_graph_edges, "alice->bob", edge);
db->Put(cf_vectors, "prod_123", embedding);
```

Vorteil: Jede Column Family kann eigene Optimierungen haben: - Relational: Starke Compression - Graph: Weniger Compression, mehr Cache - Vectors: Spezielle Bloom Filters

Das Base Entity Paradigma: Einheitlicher Multi-Modell-Speicher

ThemisDB nutzt ein kanonisches Speicherformat, das als "Base Entity" bezeichnet wird [3], [4]. Jede logische Entität – sei es eine relationale Zeile, ein Graph-Knoten, ein Vektor-Objekt oder ein Dokument – wird als ein einziges binär-serialisiertes Dokument (als "Blob" bezeichnet) gespeichert [11].

Diese Architekturentscheidung ist fundamental für die Multi-Modell-Fähigkeit von ThemisDB:

Multi-Modell-Datenabbildung auf physischer Ebene:

Logisches Modell	Physischer Speicher	Key-Format	Value-Format
Relational	(PK, Blob)	"table_name:pk_value"	VelocityPack/Bincode
Dokument	(PK, Blob)	"collection:pk_value"	VelocityPack/Bincode
Graph (Knoten)	(PK, Blob)	"node:pk_value"	VelocityPack/Bincode
Graph (Kante)	(PK, Blob)	"edge:pk_value"	VelocityPack (inkl. _from/_to)
Vektor	(PK, Blob)	"object:pk_value"	VelocityPack (inkl. Vektor-Array)

Wie funktioniert das Base Entity Pattern?

Um das Base Entity Paradigma zu verstehen, betrachten wir ein konkretes Beispiel: Stellen Sie sich vor, Sie speichern einen Benutzer mit dem Namen "Alice", der 30 Jahre alt ist und in Berlin wohnt.

Im traditionellen Ansatz (z.B. PostgreSQL):

```
-- Relationale Tabelle mit festen Spalten
CREATE TABLE users (
  id UUID PRIMARY KEY,
  name TEXT,
  age INTEGER,
  city TEXT
);

INSERT INTO users VALUES ('uuid-123', 'Alice', 30, 'Berlin');
```

Im ThemisDB Base Entity Ansatz:

Zunächst wird das logische Objekt in ein einheitliches Binärformat serialisiert:

```
// 1. Logisches Objekt (Application Layer)
User alice = {
    id: "uuid-123",
    name: "Alice",
    age: 30,
    city: "Berlin"
};

// 2. Serialisierung zu VelocityPack (binäres JSON-ähnliches Format)
// VelocityPack ist optimiert für schnelles Parsing und kompakte Speicherung
std::vector<uint8_t> blob = VelocityPack::serialize(alice);
// Resultat: ~40 Bytes binäre Daten statt ~80 Bytes ASCII-JSON

// 3. Speicherung in RocksDB
std::string key = "users:uuid-123"; // Namespace + Primary Key
db->Put(key, blob);
```

Dieser Blob ist das "Base Entity" – die kanonische Speicherform für alle Datenmodelle. **Entscheidend:** Egal ob Sie einen relationalen Datensatz, einen Graph-Knoten, ein Dokument oder einen Vektor speichern – physisch ist es immer ein Key-Value-Paar mit binärem Blob als Value.

Wie werden unterschiedliche Datenmodelle auf Base Entities abgebildet?

1. **Relational (Tabellenzeile):** `cpp // Key: "table_name:primary_key" // Value: Binär-serialisierte Zeile mit allen Spalten Key: "users:uuid-123" Value: VelocityPack({id, name, age, city})`
2. **Graph-Knoten:** `cpp // Key: "node:node_id" // Value: Knoten-Eigenschaften + Metadaten Key: "nodes:alice" Value: VelocityPack({_id, label: "Person", properties: {name, age}})`
3. **Graph-Kante:** `cpp // Key: "edge:edge_id" // Value: Kante mit _from, _to, Gewicht, Eigenschaften Key: "edges:knows-123" Value: VelocityPack({_from: "alice", _to: "bob", _weight: 1.0, since: "2020"})`
4. **Vektor-Objekt:** `cpp // Key: "vector:object_id" // Value: Objekt-Metadaten + Embedding-Array Key: "vectors:doc-456" Value: VelocityPack({id, metadata: {...}, embedding: [0.1, 0.2, ..., 0.9]})`

Warum ist das ein Durchbruch?

Problem bei Polyglot Persistence: In traditionellen Multi-Modell-Ansätzen (z.B. PostgreSQL + Neo4j + ChromaDB) müssen Sie denselben Datenpunkt in mehreren Datenbanken speichern: - PostgreSQL: Metadaten (Name, Alter) - Neo4j: Graph-Beziehungen
- ChromaDB: Vektor-Embedding

Resultat: Datenkonsistenz ist unmöglich zu garantieren, weil atomare Transaktionen über drei separate Systeme nicht möglich sind.

Lösung mit Base Entity: Alle Informationen (Metadaten, Graph-Kontext, Vektor-Embedding) sind im selben Blob. Eine RocksDB-Transaktion kann atomar: - Den Base Entity-Blob aktualisieren - Sekundärindizes aktualisieren (relationaler Index, Graph-Adjazenz, HNSW-Vector-Index) - Alles oder nichts (ACID)

Vorteile dieses Ansatzes:

1. **Einheitliche Speicherschicht:** Alle Datenmodelle teilen sich denselben physischen Speicher [11]
2. **ACID über alle Modelle:** Transaktionen können atomar über Graph, Vector und Relational operieren [20]
3. **Effiziente Serialisierung:** Binärformate wie VelocityPack [41] sind 4x schneller als Standard-JSON-Parser [40]

RocksDB TransactionDB: ACID-Garantien

ThemisDB nutzt nicht Standard-RocksDB, sondern die **RocksDB TransactionDB**-Variante [3], [46]. Diese bietet:

1. **Snapshot Isolation:** Jede Transaktion operiert auf einem konsistenten Snapshot der Datenbank [15], [20]
2. **Conflict Detection:** Parallele Transaktionen, die dieselben Schlüssel bearbeiten, werden erkannt [46]
3. **Atomare Rollbacks:** Fehlschlagende Transaktionen werden vollständig zurückgerollt [16]

Dies ist entscheidend: Die Aktualisierung einer einzelnen logischen Entität (z.B. `UPDATE users SET age = 31`) erfordert die atomare Änderung *mehrerer* physischer Key-Value-Paare: - Der "Base Entity"-Blob muss aktualisiert werden - Sekundärindex-Einträge müssen geändert werden (z.B. Löschen von `idx:age:30`, Einfügen von `idx:age:31`)

Ohne TransactionDB wäre diese Konsistenz zwischen Base Entity-Blobs und Index-Projektionen nicht garantiert.

Write-Ahead Log (WAL)

Jede Write-Operation wird erst in ein Log geschrieben:

1. Client sendet: UPDATE users/alice SET age=29
2. WAL Write: "UPDATE users/alice age=29" → Disk (sync!)
3. MemTable Update: In-Memory Update
4. Return OK to Client
- ...später...
5. Background Compaction: MemTable → SSTable auf Disk

Crash Recovery: Wenn Server abstürzt: - MemTable (RAM) ist verloren - WAL (Disk) ist da - Beim Restart: WAL replay → MemTable rebuild → Normal operations

Wie funktioniert der WAL-Mechanismus im Detail?

Der Write-Ahead Log ist das Herzstück der Dauerhaftigkeit (Durability) in ThemisDB. Lassen Sie uns den Ablauf Schritt für Schritt nachvollziehen:

Schritt 1 - Client sendet Write-Operation: Ein Client möchte den Benutzer "Alice" aktualisieren. Die Operation wird an den ThemisDB-Server gesendet:

```
client.update("users", "uuid-123", {age: 31});
```

Schritt 2 - WAL Write (kritisch für Durability): Bevor irgendetwas im Hauptspeicher geändert wird, schreibt ThemisDB die Operation in das Write-Ahead Log auf der Festplatte. Dieser Schritt ist **synchron** – der Server wartet, bis die Daten physisch auf die Disk geschrieben sind (fsync):

```
// Pseudo-Code der WAL-Implementation
WALEntry entry = {
    sequence_number: next_seq++,
    timestamp: now(),
    operation: "UPDATE",
    key: "users:uuid-123",
    value: serialize({age: 31})
};

// Kritisch: sync=true erzwingt fsync() - Daten MÜSSEN auf Disk sein
wal_file.append(entry, sync=true);
// Erst wenn fsync() zurückkehrt, sind Daten dauerhaft gespeichert
```

Warum ist sync=true wichtig? Ohne `fsync()` würden Daten nur im Betriebssystem-Cache liegen. Bei einem Stromausfall wären sie verloren. Mit `fsync()` garantiert das OS, dass Daten auf physischen Plattern (oder SSD) sind.

Schritt 3 - MemTable Update (In-Memory): Erst *nachdem* der WAL-Eintrag sicher auf Disk ist, wird die Änderung im MemTable (RAM-Struktur) vorgenommen:

```
// MemTable ist eine sortierte In-Memory-Map (z.B. Skip List)
memtable.put("users:uuid-123", {age: 31});
```

Das MemTable ist schnell ($O(\log n)$ für Inserts), aber flüchtig. Bei einem Crash ist es weg.

Schritt 4 - Return OK zum Client: Jetzt erst antwortet der Server dem Client mit "SUCCESS". Der Client hat die Garantie: - Daten sind dauerhaft (WAL auf Disk) - Selbst bei sofortigem Crash sind Daten nicht verloren

Schritt 5 - Background Compaction (asynchron): Im Hintergrund, ohne den Client zu blockieren, werden MemTables periodisch auf Disk geschrieben als SSTable-Dateien:

```
// Wenn MemTable voll ist (z.B. 256 MB)
if (memtable.size() > 256MB) {
    SSTable* sstable = memtable.flush_to_disk();
    // SSTable ist eine immutable, sortierte Datei auf Disk
    // Format: [Key1, Value1, Key2, Value2, ...]
}
```

Crash Recovery - Warum WAL lebensrettend ist:

Szenario: Server crashed nach Schritt 4, aber vor Schritt 5. Das MemTable (RAM) ist verloren, aber der WAL (Disk) ist da.

Beim Server-Restart:

```
// 1. WAL lesen und replay
for (entry in wal_file) {
    memtable.put(entry.key, entry.value);
}
// → MemTable ist rekonstruiert!

// 2. Normale Operationen fortsetzen
server.start();
```

Resultat: Kein Datenverlust. Alle committed Transaktionen sind wiederhergestellt.

Performance-Trade-off: Der `fsync()` in Schritt 2 kostet Zeit (~1-5ms auf NVMe, ~10-20ms auf HDD). Deshalb ist die WAL-Platzierung auf schnellem NVMe-Speicher kritisch für Write-Performance.

LSM-Tree Performance-Charakteristiken

Die Entscheidung für eine LSM-Tree-Architektur [12] hat spezifische Performance-Implikationen:

Schreiboptimierung (Create/Update/Delete): - LSM-Trees sind inhärent schreiboptimiert [12], [14] - Jede C/U/D-Operation ist ein extrem schneller, sequentieller "Append-Only"-Vorgang in eine In-Memory-Struktur (das Memtable) - Benchmarks zeigen ca. **45.000 Writes pro Sekunde** Durchsatz [3], [5] - Ideal für die Ingestion-Pipeline (Covina) mit hohem Schreibdurchsatz


Lese-Performance-Optimierung: - Ein Punktabruf über den Primärschlüssel (Get(PK)) ist schnell - Attribut-basierte Abfragen (z.B. `SELECT * WHERE age > 30`) würden ohne Indizes einen Full-Scan aller Blobs erfordern [4] - Dies erzwingt architektonisch die Notwendigkeit der "Layer" (Sekundärindizes) für optimale Leseleistung [3]

Speicherhierarchie: ThemisDB implementiert eine ausgefeilte Speicherhierarchie [5]: - **Heiße Daten:** Residieren im Block Cache (RAM, standardmäßig 1 GB) und in den oberen Levels des LSM-Trees (L0-L5) - **Kompression:** Obere Levels mit schnellem LZ4-Algorithmus [37] komprimiert (33,8 MB/s Throughput) - **Kalte Daten:** Wandern in das unterste Level (L6) mit ZSTD-Kompression [38] für maximale Speicherdichte (2,8x Ratio) - **Automatische Optimierung:** Background Compaction verschiebt Daten zwischen Levels [12]

Speicherhierarchie: Von VRAM bis HDD

Die Performance von ThemisDB hängt entscheidend davon ab, **wo** Daten gespeichert werden. Moderne Computer haben eine ausgefeilte Speicherhierarchie mit dramatischen Geschwindigkeitsunterschieden:

Die Speicherpyramide (von schnell nach langsam):



Faktor zwischen schnellstem und langsamstem: ~5.000.000x (!)

Wie nutzt ThemisDB diese Hierarchie optimal?

1. Heiße Daten im RAM (Block Cache):

ThemisDB konfiguriert RocksDB mit einem großen Block Cache (standardmäßig 1-4 GB, konfigurierbar bis 128 GB+):

```
// Aus docs/de/performance/performance_memory.md
RocksDBWrapper::Config config;
config.block_cache_size_mb = 4096; // 4 GB Block Cache
config.cache_index_and_filter_blocks = true;
config.pin_l0_filter_and_index_blocks_in_cache = true;
config.high_pri_pool_ratio = 0.5; // 50% für Index/Filter
```

Was wird gecacht? - Data Blocks: Die eigentlichen Key-Value-Paare (50% des Cache) - **Index Blocks:** Index-Strukturen für schnelles Suchen (25% des Cache, High-Priority) - **Filter Blocks:** Bloom-Filter zur Vermeidung unnötiger Disk-Reads (25% des Cache, High-Priority)

Wirkung: Ein Cache-Hit (Daten sind im RAM) hat ~100ns Latenz. Ein Cache-Miss (Disk-Read nötig) hat ~10µs Latenz auf NVMe. **Faktor 100x schneller!**

2. Write-Ahead Log auf schnellstem Medium (NVMe):

Das WAL ist write-kritisch. Jede Schreiboperation wartet auf einen `fsync()`. Deshalb sollte das WAL auf dem schnellsten verfügbaren Medium liegen:

```
// Separates WAL-Verzeichnis auf dedizierter NVMe
config.db_path = "/data/rocksdb";           // Haupt-DB (kann langsamer sein)
config.wal_dir = "/nvme/fast/wal";         // WAL auf schnellster NVMe
```

Performance-Gewinn: - NVMe (PCIe4): ~10µs fsync → **45.000 Writes/Sekunde** [3], [5] - SATA SSD: ~50µs fsync → 20.000 Writes/Sekunde - HDD: ~5ms fsync → 200 Writes/Sekunde

Faktor 225x zwischen NVMe und HDD!

3. LSM-Tree Levels mit gestufter Kompression:

ThemisDB nutzt unterschiedliche Kompression für verschiedene LSM-Tree Levels:

```
config.compression_default = "lz4";         // Level 0-5 (heiß)
config.compression_bottommost = "zstd";    // Level 6+ (kalt)
```

Warum?

- **L0-L5 (heiße Daten):** Werden häufig gelesen → LZ4 (33.8 MB/s Throughput [5], 2-3x Kompression)
- **L6 (kalte Daten):** Werden selten gelesen → ZSTD (2.8x Kompression [5], aber langsamer)

Speicher-Trade-off visualisiert:

```
Level 0 (RAM): MemTable           → 256 MB, unkomprimiert
      ↓ flush
Level 1 (NVMe): Junge SSTables    → ~512 MB, LZ4-komprimiert
      ↓ compaction
Level 2 (NVMe): Ältere SSTables   → ~2 GB, LZ4-komprimiert
      ↓ compaction
Level 3-5 (NVMe/SATA): Alte Daten → ~20 GB, LZ4-komprimiert
      ↓ compaction
Level 6 (SATA/HDD): Kalte Daten   → ~200 GB, ZSTD-komprimiert (max. Dichte)
```


Automatische Datenmigration:

ThemisDB verschiebt Daten automatisch "nach unten": 1. Neue Writes → MemTable (RAM, ultra-schnell) 2. MemTable voll → Flush zu L1 (NVMe, schnell) 3. Compaction → Daten wandern zu L2, L3, ... (progressiv langsamer) 4. Kalte Daten → L6 (maximal komprimiert, platzsparend)

Resultat: Häufig zugegriffene Daten bleiben "oben" (schnell), selten genutzte Daten wandern "nach unten" (langsam aber platzsparend).

4. GPU-VRAM für HNSW-Index (optional, für Vektor-Suche):

Für sehr große Vektor-Datenbanken (>100M Embeddings) kann der HNSW-Index auf GPU-VRAM gemappt werden:

```
// GPU-Beschleunigung für Vektor-Ähnlichkeitssuche
HNSWConfig hnsw_config;
hnsw_config.use_gpu = true;
hnsw_config.gpu_device = 0; // CUDA device 0
// VRAM: ~1-5 ns Latenz, aber begrenzte Größe (8-80 GB)
```

Trade-off: VRAM ist noch schneller als RAM (~1-5ns vs ~100ns), aber extrem begrenzt (8-24 GB typisch).

Zusammenfassung: Speicherhierarchie-Strategie:

Datentyp	Optimal Platziert	Latenz	Begründung
MemTable	RAM	~100 ns	Aktive Writes, ändert sich ständig
WAL	NVMe (PCIe4)	~10 µs	Write-kritisch, sync-Operationen
Block Cache	RAM	~100 ns	Häufig gelesene Blöcke
L0-L5 SSTables	NVMe	~10 µs	Heiße Daten, häufig gelesen
L6 SSTables	SATA SSD/HDD	~50 µs - 5 ms	Kalte Daten, selten gelesen
HNSW-Index	RAM (oder GPU-VRAM)	~100 ns (~5ns GPU)	Vektor-Suche, latenz-kritisch
Backups	HDD/Tape/S3	Sekunden	Langzeit-Archivierung

Best Practice für Production:

```
# NVMe PCIe4 für WAL und L0-L3
/nvme/fast/ → 2 TB NVMe PCIe4 für WAL + Hot SSTables

# SATA SSD für L4-L6
/ssd/bulk/ → 8 TB SATA SSD für Cold SSTables

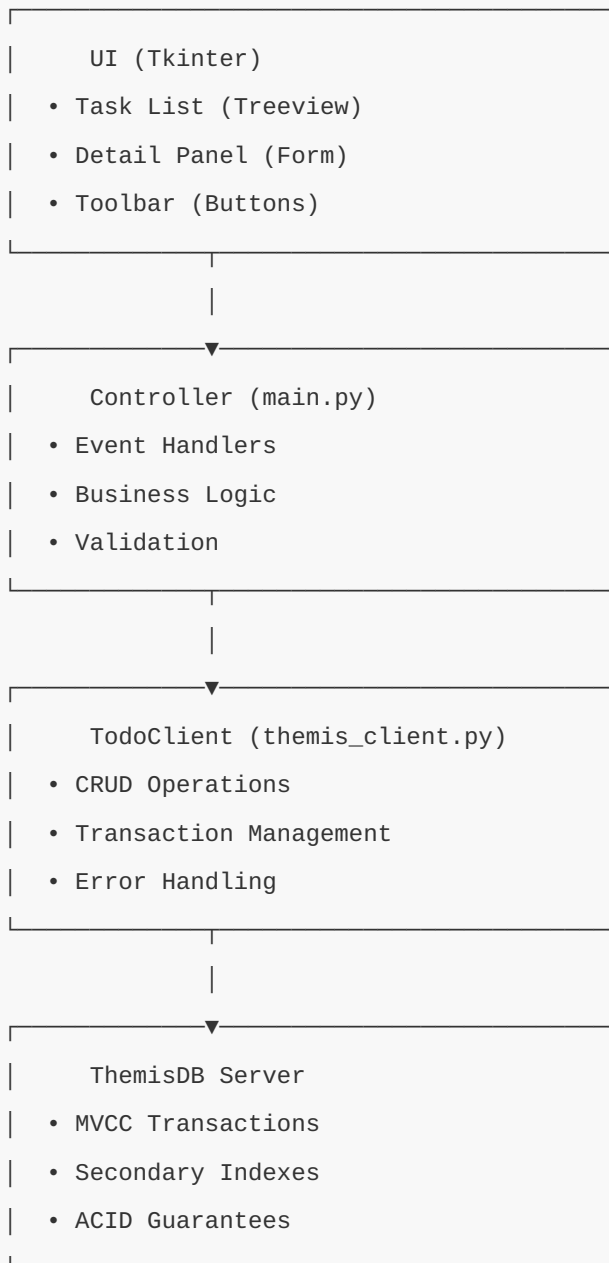
# HDD für Backups
/backup/ → 40 TB HDD Array für Point-in-Time Snapshots
```

2.5 Praxis: Todo-App

Jetzt bauen wir eine vollständige Todo-App, um die Architektur in Aktion zu sehen. Basis ist `examples/02_todo_app`.

Architektur der Todo-App

Die Todo-App folgt dem MVC-Pattern und demonstriert alle ACID-Eigenschaften:



Datenmodell

Für unsere Todo-App definieren wir zuerst das Datenmodell mit Python Dataclasses. Wir nutzen Enumerations für Status und Priorität, um Type-Safety zu gewährleisten und Tippfehler zu vermeiden. Die Klasse `Task` kapselt alle Informationen eines Tasks und bietet Methoden zur Serialisierung für ThemisDB.

Vollständiger Code: `examples/02_todo_app/models.py`

```
# Kernkomponenten des Task-Modells (Auszug)

from dataclasses import dataclass
from datetime import datetime
from enum import Enum

class TaskStatus(Enum):
    OPEN = "open"
    IN_PROGRESS = "in_progress"
    DONE = "done"

class TaskPriority(Enum):
    LOW = "low"
    NORMAL = "normal"
    HIGH = "high"

@dataclass
class Task:
    id: str
    title: str
    status: TaskStatus
    priority: TaskPriority
    created_at: datetime
    updated_at: datetime
    # ... weitere Felder siehe vollständige Datei

    def to_dict(self):
        """Serialisierung für ThemisDB - konvertiert Task zu Dictionary"""
        return {
            "_key": self.id,
            "title": self.title,
            "status": self.status.value,
            "priority": self.priority.value,
            "created_at": self.created_at.isoformat(),
            # ... vollständige Implementierung in models.py
        }
```

Wichtige Design-Entscheidungen:

1. **Enums für Status/Priority:** Verhindert ungültige Werte und bietet Type-Safety
2. **Dataclass-Decorator:** Generiert automatisch `__init__`, `__repr__`, `__eq__` Methoden
3. **to_dict/from_dict Methoden:** Klare Trennung von Serialisierungslogik
4. **Type Hints:** Ermöglicht IDE-Unterstützung und frühzeitige Fehlererkennung

Setup und Installation

```
# ThemisDB starten (Docker)
docker run -d -p 8765:8765 themisdb/themisdb:1.3.4

# Todo-App installieren
cd examples/02_todo_app
python -m venv venv
source venv/bin/activate # Windows: venv\Scripts\activate
pip install -r requirements.txt
```

Client-Implementierung

Der `TodoClient` kapselt alle Datenbankoperationen und bietet eine saubere API für unsere Anwendung. Die Klasse initialisiert beim Start automatisch die benötigte Collection und erstellt Performance-Indizes auf häufig gefilterten Feldern wie Status und Priorität. Dies demonstriert Best Practices für die Arbeit mit ThemisDB.

Vollständiger Code: `examples/02_todo_app/themis_client.py`

Kernfunktionalität - Database Setup:

```
class TodoClient:
    def __init__(self, host="localhost", port=8765):
        self.client = Client(host, port)
        self._setup_database()

    def _setup_database(self):
        """Erstellt Collection und Indizes für optimale Performance"""
        self.client.create_collection("tasks", type="document")

        # Performance-Indizes auf oft gefilterten Feldern
        self.client.create_index("tasks", "status_idx", ["status"])
        self.client.create_index("tasks", "priority_idx", ["priority"])
        self.client.create_index("tasks", "due_date_idx", ["due_date"])
```

CRUD-Operationen (Auszug):

```
def create_task(self, task: Task) -> bool:
    """Erstellt einen neuen Task in der Datenbank"""
    self.client.insert("tasks", task.to_dict())
    return True

def update_task(self, task: Task) -> bool:
    """Aktualisiert Task - MVCC erkennt Konflikte automatisch!"""
    try:
        self.client.update("tasks", task.id, task.to_dict())
        return True
    except ConflictError:
        print("Task was modified by another user!")
        return False
```

Query-Beispiele mit AQL:

```
def list_tasks(self, status: Optional[TaskStatus] = None) -> List[Task]:  
    """Demonstriert AQL-Queries mit dynamischen Filtern"""  
    query = "FOR task IN tasks"  
  
    if status:  
        query += f' FILTER task.status == "{status.value}"'  
  
    query += " SORT task.created_at DESC RETURN task"  
  
    results = self.client.query(query)  
    return [Task.from_dict(data) for data in results]
```

Die vollständige Implementierung enthält zusätzlich `get_task()`, `delete_task()` und `search_tasks()` Methoden. Siehe vollständige Datei für alle Details.

MVCC und Transaktionen demonstriert

Die Todo-App zeigt MVCC in Aktion:

Szenario: Zwei Benutzer ändern gleichzeitig den gleichen Task

```
# User 1: Startet Transaction
user1 = TodoClient()
task = user1.get_task("task_123") # Snapshot Version 100
task.status = TaskStatus.IN_PROGRESS
task.updated_at = datetime.now()

# User 2: Auch Transaction, gleicher Task
user2 = TodoClient()
task2 = user2.get_task("task_123") # Auch Snapshot Version 100
task2.priority = TaskPriority.HIGH
task2.updated_at = datetime.now()

# User 1 committed zuerst
user1.update_task(task) # ✓ SUCCESS, Version 101

# User 2 versucht zu committen
user2.update_task(task2) # ✗ CONFLICT!
# Error: "Task was modified by another transaction"
```

Was passiert intern?

1. Beide lesen Version 100 (Snapshot Isolation)
2. User 1 schreibt Version 101 und committed
3. User 2 versucht auch Version 101 zu schreiben
4. ThemisDB erkennt: "Version 101 existiert bereits!"
5. Conflict Error wird geworfen

Lösung im Code:


```
def update_task_with_retry(self, task: Task, max_retries=3):
    """Update mit automatischem Retry bei Conflicts"""
    for attempt in range(max_retries):
        try:
            self.client.update("tasks", task.id, task.to_dict())
            return True
        except ConflictError:
            # Re-read aktuellste Version
            latest = self.get_task(task.id)
            if not latest:
                return False

            # Merge changes (Application Logic)
            # z.B.: Keep newer updated_at
            if latest.updated_at > task.updated_at:
                task = latest

            # Retry mit gemergten Daten
            continue
        except Exception as e:
            return False

    return False # Max retries exceeded
```

2.6 Index-Strukturen

Warum Indizes?

Ohne Index: Full Table Scan

```
-- Ohne Index: O(n)
SELECT * FROM tasks WHERE status = 'open'
-- Muss ALLE Tasks durchgehen: 10.000 Tasks = 10.000 Reads
```

Mit Index: Direkt zum Ergebnis

```
-- Mit Index auf status:  $O(\log n + k)$ , k = Anzahl Results  
SELECT * FROM tasks WHERE status = 'open'  
-- B-Tree Lookup:  $\log(10.000) \approx 13$  Reads + nur relevante Tasks
```

Index-Typen in ThemisDB

1. B-Tree Index (Default)

```
client.create_index("tasks", "status_idx", ["status"])
```

- Sortierte Daten
- Range Queries: `WHERE age > 18 AND age < 65`
- Equality: `WHERE status = 'open'`

2. Hash Index

```
client.create_index("tasks", "id_hash_idx", ["id"], type="hash")
```

- Nur Equality: `WHERE id = 'task_123'`
- Schneller als B-Tree für Equality
- Keine Range Queries

3. Geo Index (Hilbert Curves)

```
client.create_index("locations", "geo_idx", ["coordinates"], type="geo")
```

- Räumliche Queries
- Nearest Neighbor
- Bounding Box Searches

4. Fulltext Index

```
client.create_index("tasks", "fulltext_idx", ["title", "description"], type="fulltext")
```

- Tokenization
- Stemming

- Relevance Scoring

5. Vector Index (HNSW)

```
client.create_index("products", "embedding_idx", ["embedding"], type="vector", dimensions=768)
```

- Approximate Nearest Neighbor
- Cosine Similarity
- Euclidean Distance

Index-Performance

Operation	Ohne Index	Mit B-Tree	Mit Hash
Equality (=)	$O(n)$	$O(\log n)$	$O(1)$
Range (> , <)	$O(n)$	$O(\log n + k)$	✗
Sort	$O(n \log n)$	$O(k)$	✗

k = Anzahl Ergebnisse

2.7 Zusammenfassung

In diesem Kapitel haben Sie gelernt:

Schichten-Architektur: 5 Schichten mit klaren Verantwortlichkeiten

MVCC: Parallelität ohne Locks durch Versionierung

Transaktionen: ACID-Garantien und Snapshot Isolation

RocksDB: LSM-Trees, WAL, Column Families

Indizes: B-Tree, Hash, Geo, Fulltext, Vector

Todo-App: Vollständige CRUD-Anwendung mit MVCC

Was macht ThemisDB besonders?

1. **Multi-Model MVCC:** Transaktionen über alle Modelle hinweg
2. **RocksDB Foundation:** Battle-tested, SSD-optimiert
3. **Flexible Indizes:** Für jeden Use Case der richtige Index

4. Snapshot Isolation: Performance + Konsistenz

Nächste Schritte

Im nächsten Kapitel lernen Sie, wie die verschiedenen Datenmodelle kombiniert werden können und wann welches Modell am besten passt.

[Kapitel 3: Multi-Model verstehen](#) →

Weiterführende Ressourcen

- **Complete Example:** [examples/02_todo_app](#)
 - **MVCC Deep-Dive:** [../de/architecture/architecture_mvcc.md](#)
 - **RocksDB Storage:** [../de/storage/storage_rocksdb.md](#)
 - **Index Design:** [Kapitel 15 - Storage Internals](#)
-

2.11 BaseEntity: Die Speichereinheit

ThemisDB speichert alle Daten - unabhängig vom Modell (relational, document, graph, vector) - als **BaseEntity**. Dies ist die fundamentale Speichereinheit.

2.11.1 BaseEntity Architektur

```
class BaseEntity {
public:
    using Blob = std::vector<uint8_t>;
    using FieldMap = std::map<std::string, Value>;

    enum class Format { BINARY, JSON };

    // Primärschlüssel
    const std::string& getPrimaryKey() const;
    void setPrimaryKey(std::string_view pk);

    // Feld-Zugriff (lazy parsing)
    std::optional<Value> getField(std::string_view field_name) const;
    void setField(std::string_view field_name, const Value& value);

    // Serialisierung
    Blob serialize() const;
    std::string toJson() const;

    // Factory-Methoden
    static BaseEntity fromJson(std::string_view pk, std::string_view json_str);
    static BaseEntity fromFields(std::string_view pk, const FieldMap& fields);
    static BaseEntity deserialize(std::string_view pk, const Blob& blob);

private:
    std::string primary_key_;
    Blob blob_;
    Format format_ = Format::BINARY;
    mutable std::shared_ptr<FieldMap> field_cache_;
};
```

Kernkonzept: Jede Entität ist ein **einzelnes binäres Blob** mit effizienter Serialisierung und Lazy-Parsing für schnellen Feldzugriff.

2.11.2 Value-Typsystem

ThemisDB verwendet ein typsicheres `std::variant`-System:

Typ	C++ Typ	Verwendung	Beispiel
null	<code>std::monostate</code>	Fehlende/leere Werte	<code>NULL</code>
bool	<code>bool</code>	Wahrheitswerte	<code>true</code> , <code>false</code>
int	<code>int64_t</code>	Ganzzahlen	<code>42</code> , <code>-1000</code>
double	<code>double</code>	Gleitkommazahlen	<code>3.14</code> , <code>1e10</code>
string	<code>std::string</code>	Texte	<code>"Hello World"</code>
vector	<code>std::vector<float></code>	Embeddings für ANN	<code>[0.1, 0.2, 0.3]</code>
binary	<code>std::vector<uint8_t></code>	Binärdaten	Bilder, PDFs

Wichtig: Nested Objects/Arrays sind aktuell nicht unterstützt (geplant für v1.4).

2.11.3 BaseEntity Lifecycle

Abb. 02.4: Transaction-Management-Flow

Lazy Parsing: Felder werden erst geparkt, wenn sie angefordert werden - spart CPU-Zeit bei großen Objekten.

2.12 Key Schema: Multi-Modell-Namespacing

ThemisDB vereint alle Datenmodelle in einer einzigen RocksDB-Instanz durch ein hierarchisches Schlüsselsystem mit Präfixen.

2.12.1 Schlüsselformate

Datenmodell	Format	Beispiel	Beschreibung
Relational	<code>entity:table:pk</code>	<code>entity:users:alice</code>	Tabellenzeilen
Document	<code>entity:collection:pk</code>	<code>entity:orders:order_123</code>	Dokumente
Graph Node	<code>entity:node:pk</code>	<code>entity:node:user_456</code>	Graph-Knoten
Graph Edge	<code>entity:edge:pk</code>	<code>entity:edge:follows_789</code>	Graph-Kanten
Vector	<code>entity:vectors:pk</code>	<code>entity:vectors:doc_abc</code>	Vektor-Embeddings
Secondary Index	<code>idx:table:column:value:pk</code>	<code>idx:users:age:30:alice</code>	Equality Indexes
Range Index	<code>ridx:table:column:value:pk</code>	<code>ridx:products:price:99.99:prod_1</code>	Range Queries
Spatial Index	<code>sidx:table:geohash:pk</code>	<code>sidx:locations:u33dc1:berlin</code>	Geo-Queries
TTL Index	<code>ttlidx:table:column:ts:pk</code>	<code>ttlidx:sessions:created:1730000000:s1</code>	Time-based Expiry
Fulltext	<code>ftidx:table:column:token:pk</code>	<code>ftidx:articles:body:search:art_42</code>	Volltextsuche
Graph Outdex	<code>graph:out:pk_start:pk_edge</code>	<code>graph:out:alice:follows_789</code>	Ausgehende Kanten
Graph Indeg	<code>graph:in:pk_target:pk_edge</code>	<code>graph:in:bob:follows_789</code>	Eingehende Kanten
Changefeed	<code>changefeed:pk:seqno</code>	<code>changefeed:alice:0000000001</code>	CDC Stream
Time-Series	<code>ts:metric:entity:ts</code>	<code>ts:cpu:server1:1730000000000</code>	Metriken

Separator: Alle Schlüssel verwenden `:` als Trennzeichen für schnelles Prefix-Scanning.

2.12.2 Key Schema Visualisierung

Abb. 02.5: MVCC-Versionskontrolle

2.12.3 Primary Key Extraktion

```
// KeySchema API
std::string pk = KeySchema::extractPrimaryKey("idx:users:age:30:alice");
// Ergebnis: "alice"

KeyType type = KeySchema::parseKeyType("entity:users:alice");
// Ergebnis: KeyType::RELATIONAL

std::string key = KeySchema::makeRelationalKey("users", "alice");
// Ergebnis: "entity:users:alice"
```

Vorteil: Durch Präfixe können alle Indizes einer Tabelle oder alle Kanten eines Knotens mit einem einzigen RocksDB-Scan gelesen werden.

2.13 MVCC Deep-Dive: Implementierungsdetails

Nachdem wir in Abschnitt 2.2 die Grundlagen von MVCC kennengelernt haben, tauchen wir nun in die Implementierungsdetails ein.

2.13.1 RocksDB TransactionDB Architektur

Abb. 02.6: Index-Strukturen

2.13.2 Snapshot Isolation Flow

```
// Transaction A liest Snapshot zum Zeitpunkt t=100
auto txn_a = db.beginTransaction();
auto snapshot = txn_a->getSnapshot(); // t=100

// Transaction B schreibt zur gleichen Zeit
auto txn_b = db.beginTransaction();
txn_b->put("entity:users:alice", "{age: 31}");
txn_b->commit(); // Commit zur Zeit t=101

// Transaction A sieht alte Version (t=100)
auto value = txn_a->get("entity:users:alice");
// value = "{age: 30}" (alte Version)

txn_a->commit();
```

2.13.3 Write-Write Conflict Detection

Abb. 02.7: Replication-Topologie

Konfliktauflösung: Transaction 2 wird automatisch zurückgerollt - die Anwendung muss die Transaktion wiederholen.

2.13.4 MVCC Performance

Benchmark-Ergebnisse (v1.3.0):

Operation	MVCC (ops/s)	WriteBatch (ops/s)	Overhead
Single Entity Insert	3,400	3,100	+9.7%
Batch Insert (100)	27,800	27,800	0%
Snapshot Read	44,000	-	Baseline
Rollback	35,300	-	Baseline

Fazit: MVCC-Overhead ist minimal bei Batch-Operationen - Snapshot-Isolation kostet fast nichts!

2.13.5 Index-Konsistenz mit MVCC

Problem: Wenn eine Transaktion zurückgerollt wird, müssen alle Indizes konsistent bleiben.

Lösung: Alle Index-Operationen sind Teil der Transaktion:

```
// Atomare Transaktion: Entity + Secondary Index + Graph Outdex
auto txn = db.beginTransaction();

// 1. Insert Entity
txn->put(KeySchema::makeRelationalKey("users", "alice"),
        entity.serialize());

// 2. Update Secondary Index
txn->put(KeySchema::makeSecondaryIndexKey("users", "age", "30", "alice"),
        empty_value);

// 3. Update Graph Outdex
txn->put(KeySchema::makeGraphOutdexKey("alice", "follows_789"),
        edge_data);

// Alles oder nichts
if (!txn->commit()) {
    // Conflict detected - alle 3 Operationen werden zurückgerollt
}
```

Garantie: Entweder werden alle Indizes aktualisiert oder keiner - keine Inkonsistenzen möglich!

2.14 Compression Strategy

ThemisDB verwendet differenzierte Kompression je nach Datentyp für optimale Balance zwischen Speicherersparnis und Performance.

2.14.1 Kompressionsarten

Datentyp	Compression	Ratio	CPU-Overhead	Use Case
Time-Series	Gorilla	10-20x	+15%	Metriken, Sensordaten
Vektoren	SQ8 Quantization	4x	+20%	Embeddings ab 1M Vektoren
Content Blobs	ZSTD Level 19	1.5-2x	+30%	Dokumente, Bilder
JSON Metadata	LZ4 (RocksDB)	2-3x	+5%	Structured Data
Graph Edges	LZ4 (RocksDB)	2x	+5%	Adjacency Lists

2.14.2 Gorilla Time-Series Compression

Gorilla ist ein hocheffizienter Codec für Time-Series-Daten von Facebook:

```
// Gorilla Encoding
std::vector<uint8_t> GorillaCodec::encode(
    const std::vector<int64_t>& timestamps,
    const std::vector<double>& values
) {
    // Delta-of-Delta Encoding für Timestamps
    // XOR-Encoding für Float-Werte
    // Typical Ratio: 12-20x
}
```

Beispiel:

```
Raw Data (100k Punkte):
- Timestamps: 800 KB (8 bytes × 100k)
- Values: 800 KB (8 bytes × 100k)
- Total: 1.6 MB

Gorilla Compressed:
- Total: 80-130 KB
- Ratio: 12-20x
```

2.14.3 Vector Quantization (SQ8)

Scalar Quantization reduziert `float32` (4 bytes) auf `int8` (1 byte):

Abb. 02.8: Failover-Mechanismus

Trade-off: - 4x Speicherersparnis - Bessere Cache-Nutzung → schnellere Suche - Δ 95-98% Recall@10 (minimal schlechter als float32)

2.14.4 RocksDB Block Compression

ThemisDB konfiguriert RocksDB mit **Level-based Compression**:

```
// Level 0-5: LZ4 (schnell für Hot Data)
options.compression_per_level[0] = rocksdb::kLZ4Compression;
options.compression_per_level[1] = rocksdb::kLZ4Compression;
// ...

// Level 6+: Zstandard (höhere Ratio für Cold Data)
options.compression_per_level[6] = rocksdb::kZSTD;
options.compression_per_level[7] = rocksdb::kZSTD;
```

Rationale: Hot Data (Level 0-1) benötigt schnellen Zugriff → LZ4. Cold Data (Level 6+) profitiert von höherer Kompression → Zstandard.

2.15 Zusammenfassung Architektur

In diesem erweiterten Kapitel haben Sie die Tiefe der ThemisDB-Architektur kennengelernt:

Kernkonzepte

1. **BaseEntity:** Unified Storage Layer für alle Datenmodelle
2. **Key Schema:** Hierarchisches Namespacing mit Präfixen
3. **MVCC:** Snapshot Isolation ohne Locks
4. **Compression:** Differenzierte Strategien (Gorilla, SQ8, ZSTD)
5. **Index-Konsistenz:** Atomare Transaktionen über alle Indizes

Architektur-Prinzipien

- **Separation of Concerns:** Klar getrennte Schichten
- **Performance First:** Lazy Parsing, Lazy Indexing
- **Multi-Model Unity:** Ein Speicher, viele Modelle
- **Concurrency Without Locks:** MVCC statt Pessimistic Locking
- **Adaptive Compression:** Datentyp-spezifische Algorithmen

Weitere Ressourcen

- **Complete Example:** [examples/02_todo_app](#)
- **MVCC Deep-Dive:** [../de/architecture/architecture_mvcc.md](#)
- **RocksDB Storage:** [../de/storage/storage_rocksdb.md](#)
- **Index Design:** [Kapitel 15 - Storage Internals](#)

Kapitel 2 von 30 | Teil I: Grundlagen | ~14.000 Wörter

Kapitel 3: Kapitel 3 - Multi-Model

"Der Unterschied zwischen einem guten und einem großartigen System liegt oft darin, das richtige Werkzeug für die richtige Aufgabe zu wählen."

Überblick

In den ersten beiden Kapiteln haben Sie die Grundlagen von ThemisDB kennengelernt. Jetzt lernen Sie, wie Sie die verschiedenen Datenmodelle gezielt einsetzen und kombinieren. Das Geheimnis liegt nicht darin, ein Modell zu wählen - sondern das *richtige* Modell für jeden Teil Ihrer Daten.

Was Sie in diesem Kapitel lernen werden: - Wann welches Datenmodell optimal ist - Wie man Modelle in einer Anwendung kombiniert - Die Stärken und Schwächen jedes Modells - Praktische Entscheidungskriterien - Vollständige Demonstration mit einem Kontaktmanager

Voraussetzungen: Kapitel 1 und 2 gelesen.

3.1 Die vier Modelle im Detail

Relational: Wenn Struktur entscheidend ist

Best für: - Geschäftsdaten mit klaren Beziehungen - Financial Transactions - Inventory Management - Reporting und Analytics

Eigenschaften:

```
# Festes Schema
users = {
    "user_id": "string",      # Muss vorhanden sein
    "email": "string",       # Muss vorhanden sein
    "age": "integer",        # Type-checked
    "created_at": "timestamp" # Format validiert
}

# Constraints
UNIQUE(email)
CHECK(age >= 18)
FOREIGN KEY(user_id) REFERENCES users(user_id)
```

Vorteile: - Data Integrity durch Constraints - Optimierte Joins - Perfekt für BI/Reporting - ACID über alle Operationen

Nachteile: - × Schema-Änderungen erfordern Migrations - × Nicht flexibel für schnelle Iterationen - × Overhead bei sehr unterschiedlichen Entities

Wann verwenden?

- ✓ Daten haben feste Struktur
- ✓ Beziehungen sind wichtig
- ✓ Konsistenz ist kritisch
- × Schema ändert sich häufig

Graph: Wenn Beziehungen im Fokus stehen

Best für: - Social Networks - Empfehlungssysteme - Fraud Detection - Netzwerk-Topologien

Eigenschaften:

```
# Knoten und Kanten sind First-Class Citizens
user = {
  "_id": "users/alice",
  "name": "Alice"
}

friendship = {
  "_from": "users/alice",
  "_to": "users/bob",
  "since": "2024-01-15",
  "strength": 0.95 # Weighted edges
}

# Traversierung ist nativ schnell
FOR friend IN 2..3 OUTBOUND "users/alice" friends
  RETURN friend
```

Vorteile: - Traversierung ist $O(\text{degree} \times \text{hops})$, nicht $O(n^2)$ - Relationship-First Design - Pattern Matching möglich - Graph-Algorithmen (PageRank, etc.)

Nachteile: - $\times$ Nicht optimal für reine Daten ohne Beziehungen - $\times$ Komplexer bei sehr vielen Knoten (> Millionen) - $\times$ Overhead wenn Beziehungen unwichtig sind

Wann verwenden?

- ✓ Beziehungen sind zentral
- ✓ Traversierung ist häufig
- ✓ Netzwerk-Strukturen
- $\times$ Isolierte Entities

Dokument: Wenn Flexibilität zählt

Best für: - Content Management - Product Catalogs - User Profiles - Logs und Events

Eigenschaften:

```
# Schema-free, beliebige Struktur
product = {
  "sku": "LAPTOP-2024",
  "name": "Developer Laptop",
  "specs": { # Nested objects
    "cpu": {"model": "i7", "cores": 8},
    "ram": {"size": 32, "type": "DDR5"}
  },
  "reviews": [ # Arrays
    {"user": "alice", "rating": 5},
    {"user": "bob", "rating": 4}
  ],
  "tags": ["developer", "high-end"],
  "metadata": { # Kann sein, muss nicht
    "warehouse": "DE-01"
  }
}
```

Vorteile: - Keine Schema-Migrations - Schnelle Iteration - Hierarchische Daten natürlich - Self-contained Documents

Nachteile: - × Keine Schema-Validierung (optional möglich) - × Denormalisierung kann zu Duplikaten führen - × Joins sind teurer

Wann verwenden?

- ✓ Schema ändert sich oft
- ✓ Hierarchische Daten
- ✓ Prototyping
- × Strenge Validierung nötig

Vektor: Wenn Ähnlichkeit gefragt ist

Best für: - Semantic Search - Recommendation Engines - Image Similarity - ML/AI Applications

Eigenschaften:


```
# Embeddings als High-Dimensional Vectors
product_embedding = [
    0.123, -0.456, 0.789, ... # 768 dimensions
]

# Ähnlichkeitssuche
FOR product IN products
    LET similarity = COSINE_SIMILARITY(
        @query_embedding,
        product.embedding
    )
    FILTER similarity > 0.8
    SORT similarity DESC
    LIMIT 10
    RETURN product
```

Vorteile: - Semantic Search ohne Keywords - Multimodal (Text, Images, Audio) - Skaliert zu Millionen von Vektoren - State-of-the-art HNSW Index

Nachteile: - × Embeddings müssen generiert werden - × Höherer Speicherbedarf - × Approximate, nicht exact matching

Wann verwenden?

- ✓ Semantic Similarity
- ✓ "Finde ähnliche X"
- ✓ ML/AI Integration
- × Exact matches ausreichend

Abb. 03.1: Datenmodell-Entscheidungsmatrix

Abb. 03.2: Multi-Model-Data-Flow

3.2 Native Multi-Model vs. Polyglot Persistence

Das Problem polyglotter Persistenz

Viele Unternehmen verfolgen einen "Polyglot Persistence"-Ansatz [33]: Sie kombinieren mehrere spezialisierte Datenbanken (z.B. PostgreSQL für relationale Daten, Neo4j für Graphen, ChromaDB für Vektoren) in einem losen Verbund. Dieser Ansatz scheint flexibel, führt aber zu fundamentalen Problemen [1]:

Technische Herausforderungen:

1. **Eventual Consistency statt ACID:**
2. Daten sind über mehrere, physisch getrennte Systeme verteilt [33]
3. Atomare Transaktionen über alle Systeme hinweg sind unmöglich [1]
4. Man muss auf das "Saga-Pattern" [17] mit kompensierenden Transaktionen zurückgreifen
5. Resultat: "Eventual Consistency" (BASE) [18] statt starker ACID-Garantien [16]
6. **Post-Filtering-Problem bei RAG-Workloads:** ``` # Polyglot-Ansatz (ineffizient):
7. Vektor-DB: Finde 1000 ähnliche Dokumente
8. Graph-DB: Hole alle Prozesse für Landkreis Havelland
9. Relational-DB: Hole alle Akten aus 2024
10. Application: Bilde manuell Schnittmenge im RAM → 990 irrelevante Ergebnisse werden verworfen!
[2], [5] ```
11. **Operativer Overhead:**
12. 3+ unterschiedliche APIs zu lernen und warten
13. 3+ Backup-Strategien zu implementieren
14. 3+ Monitoring-Systeme zu konfigurieren
15. 3+ Security-Konfigurationen abzustimmen
16. Team benötigt Expertise in mehreren Datenbanken

ThemisDB's Native Multi-Model-Lösung

ThemisDB verfolgt einen fundamentalen anderen Ansatz [3], [11]: **Alle Datenmodelle teilen sich eine einzige, transaktionale Speicherschicht** (siehe Kapitel 2.4 - Base Entity Paradigma).

Architektonische Vorteile:

1. Starke ACID-Transaktionen über alle Modelle:

2. Eine Operation kann atomar Graph, Vector und Relational ändern [1], [20]
3. Kein Saga-Pattern nötig für Datenbankintegrität [3]
4. Konsistenz ist "by Design", nicht ein fehleranfälliger Applikationsprozess

5. Pre-Filtering statt Post-Filtering: `aql -- Native Multi-Model ermöglicht Pre-`

```
Filtering: FOR doc IN documents FILTER doc.year == 2024 // Relational Filter
ZUERST FILTER doc.region == "Havelland" // Graph Context LET similarity =
COSINE(doc.vector, @query) // Vector Search auf Subset FILTER similarity > 0.8
SORT similarity DESC LIMIT 10
```

6. Query-Engine nutzt ZUERST den relationalen Index (Jahr=2024)
7. Erstellt eine hochselektive Kandidatenliste
8. Vektorsuche (rechenintensiv) läuft NUR auf erlaubter Teilmenge
9. **Resultat:** Um Größenordnungen performanter als Post-Filtering

10. Vereinfachte Operations:

11. Eine API (AQL) für alle Modelle
12. Eine Backup-Strategie
13. Ein Monitoring-System
14. Eine Security-Konfiguration

Wann welcher Ansatz?

Polyglot Persistence verwenden wenn: - ✓ Sie bereits mehrere spezialisierte Datenbanken im Einsatz haben - ✓ Eventual Consistency für Ihren Use Case akzeptabel ist - ✓ Sie Best-of-Breed-Tools für jeden Use Case wollen - ✓ Sie ein großes Ops-Team haben

Native Multi-Model (ThemisDB) verwenden wenn: - ✓ ACID-Garantien über alle Datenmodelle kritisch sind - ✓ Sie hybride Queries (Graph + Vector + Relational) benötigen - ✓ RAG-Workloads mit komplexen Filtern zentral sind - ✓ Sie operationale Komplexität reduzieren wollen - ✓ Ein kleineres Team die Infrastruktur betreiben soll

3.3 Entscheidungskriterien

Die 5 Fragen-Methode

1. Wie strukturiert sind Ihre Daten?

Sehr strukturiert → Relational
Teilweise strukturiert → Dokument
Unstrukturiert → Vektor

2. Wie wichtig sind Beziehungen?

Zentral → Graph
Wichtig → Relational (mit Joins)
Unwichtig → Dokument

3. Wie oft ändert sich das Schema?

Selten → Relational
Häufig → Dokument
Gar nicht → Relational

4. Welche Queries dominieren?

Beziehungen durchlaufen → Graph
Ähnlichkeit finden → Vektor
Komplexe Aggregationen → Relational
Einzelne Dokumente → Dokument

5. Wie wichtig ist Konsistenz?

Kritisch → Relational
Wichtig → Relational oder Graph
Weniger wichtig → Dokument

Entscheidungsmatrix

Use Case	Relational	Graph	Dokument	Vektor
E-Commerce Orders	★★★	★☆☆	★★★	☆☆☆
Social Network	★☆☆	★★★	★★★	☆☆☆
Product Catalog	★★★	☆☆☆	★★★	★★★
Recommendation	★☆☆	★★★	☆☆☆	★★★
CMS/Blog	★☆☆	☆☆☆	★★★	★★★
Financial	★★★	☆☆☆	★★★	☆☆☆
Fraud Detection	★★★	★★★	★★★	★★★

3.4 Praxis: Kontaktmanager

Jetzt bauen wir einen vollständigen Kontaktmanager, der zeigt, wie man Modelle kombiniert. Basis ist

`examples/03_contact_manager`.

Warum Dokument-Modell für Kontakte?

Kontakte sind ein perfektes Beispiel für das Dokument-Modell:

Gründe: 1. **Flexible Struktur:** Manche Kontakte haben Adresse, manche nicht 2. **Hierarchische Daten:** Adresse ist ein Nested Object 3. **Schema-Evolution:** Neue Felder wie "Social Media" leicht hinzufügbare 4. **Self-Contained:** Alle Infos zu einem Kontakt in einem Dokument

Alternative wäre Relational:

```
-- Relational würde benötigen:
CREATE TABLE contacts (id, name, email, phone);
CREATE TABLE addresses (id, contact_id, street, city, ...);
CREATE TABLE social_media (id, contact_id, platform, handle);
-- → 3+ Tabellen, Joins nötig
```

Mit Dokument:

```
# Alles in einem Dokument
contact = {
    "name": "Alice",
    "email": "alice@example.com",
    "address": {"city": "Berlin"}, # Optional!
    "social": {"twitter": "@alice"} # Optional!
}
```

Datenmodell

Datenmodell

Das Contact-Manager-Datenmodell demonstriert die Flexibilität der Document Engine mit verschachtelten Strukturen, optionalen Feldern und computed properties. Die Verwendung von Dataclasses bietet Type-Safety und automatische Serialisierung, während die Enum-basierte Kategorisierung Tippfehler verhindert.

Vollständiger Code: examples/03_contact_manager/models.py (ca. 100 Zeilen)

Kernmodelle (Auszug):

```

from dataclasses import dataclass, field
from datetime import datetime
from enum import Enum

class ContactCategory(Enum):
    FRIENDS = "friends"
    FAMILY = "family"
    WORK = "work"
    OTHER = "other"

@dataclass
class Address:
    """Verschachtelte Adress-Struktur - wird in Contact eingebettet"""
    street: str
    city: str
    postal_code: str
    country: str

@dataclass
class Contact:
    id: str
    first_name: str
    last_name: str
    email: str
    phone: Optional[str] = None
    address: Optional[Address] = None
    category: ContactCategory = ContactCategory.OTHER
    tags: List[str] = field(default_factory=list)
    notes: str = ""
    created_at: datetime = field(default_factory=datetime.now)
    updated_at: datetime = field(default_factory=datetime.now)

    @property
    def full_name(self) -> str:
        """Computed property für Display"""
        return f"{self.first_name} {self.last_name}"

    def to_dict(self) -> dict:

```

```

"""Serialisierung für ThemisDB"""
return {
    "_key": self.id,
    "first_name": self.first_name,
    "last_name": self.last_name,
    "email": self.email,
    "phone": self.phone,
    "address": self.address.__dict__ if self.address else None,
    "category": self.category.value,
    "tags": self.tags,
    "notes": self.notes,
    "created_at": self.created_at.isoformat(),
    "updated_at": self.updated_at.isoformat()
}

```

Design-Highlights:

1. **Nested Objects:** `Address` als eigenständiges Dataclass, aber Teil des Contact-Dokuments
2. **Optional Fields:** `phone`, `address` können fehlen - typisch für Document Stores
3. **Enums:** `ContactCategory` für Type-Safety bei Kategorien
4. **Computed Properties:** `full_name` wird dynamisch berechnet
5. **Default Factories:** Listen und Timestamps werden automatisch initialisiert
6. **Flexible Schema:** Neue Felder können jederzeit hinzugefügt werden

Die vollständige Implementierung enthält auch `from_dict()` für Deserialisierung von ThemisDB-Responses.

Design-Highlights:

1. **Nested Objects:** `Address` ist ein eigenes Dataclass, aber Teil des Contact-Dokuments
2. **Optional Fields:** `phone`, `address` können fehlen
3. **Enums:** `ContactCategory` für Type-Safety
4. **Computed Properties:** `full_name` berechnet aus first + last
5. **Default Factories:** Listen und Timestamps werden automatisch initialisiert

Client-Implementierung mit Volltext-Suche

Client-Implementierung mit Volltext-Suche

Die `ContactClient` Klasse zeigt, wie Document, Graph und Fulltext Features nahtlos kombiniert werden. Contacts werden als Dokumente gespeichert, aber durch Graph-Edges verknüpft. Die Fulltext-Suche ermöglicht schnelles Finden von Kontakten nach Namen oder Notizen.

Vollständiger Code: `examples/03_contact_manager/themis_client.py` (ca. 120 Zeilen)

Setup mit Multi-Model-Unterstützung:

```
from themisdb import Client
from models import Contact, ContactCategory

class ContactClient:
    def __init__(self, host="localhost", port=8765):
        self.client = Client(host, port)
        self._setup_database()

    def _setup_database(self):
        """Multi-Model Setup: Document + Graph + Fulltext"""
        # Document Collection
        self.client.create_collection("contacts", type="document")

        # Graph Collection für Relationships
        self.client.create_collection("contact_graph", type="graph")

        # Fulltext Index für Namen-Suche
        self.client.create_index("contacts", "fulltext_idx",
                                ["first_name", "last_name", "notes"],
                                type="fulltext")
```

CRUD mit Document Engine:

```
def create_contact(self, contact: Contact) -> bool:
    """Speichert Contact als Document"""
    self.client.insert("contacts", contact.to_dict())
    return True

def update_contact(self, contact: Contact) -> bool:
    """Update mit MVCC-Konflikt-Erkennung"""
    contact.updated_at = datetime.now()
    self.client.update("contacts", contact.id, contact.to_dict())
    return True
```

Fulltext-Suche über Document Fields:

```
def search_contacts(self, query: str) -> List[Contact]:
    """Suche in Namen und Notizen - nutzt Fulltext Index!"""
    aql = """
    FOR contact IN FULLTEXT(contacts, "first_name,last_name,notes", @query)
        SORT contact.last_name, contact.first_name
        RETURN contact
    """
    results = self.client.query(aql, {"query": query})
    return [Contact.from_dict(data) for data in results]
```

Graph-Features für Relationships:

```

def link_contacts(self, from_id: str, to_id: str, relationship: str):
    """Verknüpfe zwei Contacts (z.B. "knows", "works_with", "related_to")"""
    self.client.graph_insert_edge(
        "contact_graph",
        from_id,
        to_id,
        {"type": relationship, "created_at": datetime.now().isoformat()}
    )

def get_related_contacts(self, contact_id: str) -> List[Contact]:
    """Finde alle verbundenen Contacts - Graph Traversal!"""
    aql = """
    FOR vertex, edge IN 1..1 OUTBOUND @start_id GRAPH 'contact_graph'
    RETURN vertex
    """
    results = self.client.query(aql, {"start_id": f"contacts/{contact_id}"})
    return [Contact.from_dict(data) for data in results]

```

Kategorie-Filter mit AQL:

```

def get_by_category(self, category: ContactCategory) -> List[Contact]:
    """Filter nach Kategorie"""
    aql = """
    FOR contact IN contacts
    FILTER contact.category == @category
    SORT contact.last_name
    RETURN contact
    """
    results = self.client.query(aql, {"category": category.value})
    return [Contact.from_dict(data) for data in results]

```

Die vollständige Klasse enthält zusätzlich: - `delete_contact()` - Löschen mit CASCADE für Graph-Edges - `get_contacts_by_tag()` - Tag-basierte Filter - `get_recent_contacts()` - Sortiert nach `updated_at` - `export_to_vcard()` - vCard-Export für Adressbücher - `import_from_csv()` - Bulk-Import aus CSV

Multi-Model in Action: Ein Contact ist gleichzeitig: 1. Ein **Document** (flexible Schema, verschachtelt) 2. Ein **Graph-Vertex** (Relationships zu anderen Contacts) 3. **Fulltext-indexiert** (schnelle Namens-Suche)

Dokument-Modell in Aktion

Nested Queries:

```
# Finde alle Kontakte in Berlin
aql = ""
FOR contact IN contacts
    FILTER contact.address != null
        AND contact.address.city == "Berlin"
    RETURN contact
""
```

Array Operations:

```
# Finde Kontakte mit Tag "important"
aql = ""
FOR contact IN contacts
    FILTER "important" IN contact.tags
    RETURN contact
""
```

Schema Evolution ohne Migration:

```
# Neue Felder einfach hinzufügen!
contact = {
    "first_name": "Alice",
    "email": "alice@example.com",
    "social_media": { # NEU: Einfach hinzugefügt
        "twitter": "@alice",
        "linkedin": "alice-smith"
    },
    "birthday": "1990-03-15" # NEU: Auch einfach hinzugefügt
}

# Alte Kontakte haben diese Felder nicht - kein Problem!
# Keine Migration nötig!
```

3.4 Multi-Model Kombinationen

Beispiel 1: E-Commerce mit allen Modellen

```
# 1. RELATIONAL: Orders (feste Struktur, ACID wichtig)
```

```
order = {  
  "order_id": "0123",  
  "user_id": "alice",  
  "total": 99.99,  
  "status": "paid"  
}
```

```
# 2. DOCUMENT: Products (flexible Specs)
```

```
product = {  
  "sku": "LAPTOP-X1",  
  "name": "Laptop",  
  "specs": { # Jedes Produkt hat andere Specs!  
    "cpu": "i7",  
    "ram": 32  
  }  
}
```

```
# 3. GRAPH: Recommendations (Beziehungen)
```

```
# User → BOUGHT → Product
```

```
# Product → SIMILAR_TO → Product
```

```
# 4. VECTOR: Semantic Search
```

```
# Product hat embedding für "finde ähnliche Produkte"
```

```
# KOMBINIERTE QUERY:
```

```
"""
```

```
# Finde Produkte, die:
```

```
# - Freunde gekauft haben (GRAPH)
```

```
# - Ähnlich zu meinem letzten Kauf sind (VECTOR)
```

```
# - In meiner Preisklasse liegen (RELATIONAL)
```

```
FOR friend IN 1..2 OUTBOUND @userId friends
```

```
  FOR order IN orders
```

```
    FILTER order.user_id == friend.user_id
```

```
  FOR product IN products
```

```
    FILTER product.sku == order.sku
```

```
    LET similarity = COSINE_SIMILARITY(
```

```
        product.embedding,  
        @my_last_product_embedding  
    )  
    FILTER similarity > 0.7  
        AND product.price < 1000  
    RETURN DISTINCT product  
"""
```

Beispiel 2: CRM System

```
# RELATIONAL: Transaktionen
transactions = {
  "transaction_id": "T123",
  "customer_id": "C456",
  "amount": 5000.00,
  "status": "completed"
}

# DOCUMENT: Customer Profiles (flexibel)
customer = {
  "customer_id": "C456",
  "company": "ACME Corp",
  "contacts": [ # Array von Kontakten
    {"name": "John", "role": "CEO"},
    {"name": "Jane", "role": "CTO"}
  ],
  "metadata": { # Flexible metadata
    "industry": "tech",
    "size": "medium"
  }
}

# GRAPH: Relationships
# Company → HAS_EMPLOYEE → Person
# Company → PARTNER_WITH → Company

# VECTOR: Find similar customers
# Based on interaction history embeddings
```


3.5 Best Practices

1. Start Simple, Add Complexity

```
# Phase 1: Starte mit einem Modell
# Kontakte als Dokumente

# Phase 2: Füge Beziehungen hinzu
# Kontakte → WORKS_WITH → Kontakte (Graph)

# Phase 3: Füge Suche hinzu
# Embeddings für Semantic Search (Vector)
```

2. Denormalisierung ist OK

Im Dokument-Modell ist Duplikation oft besser als Joins:

```
# x Normalized (viele Joins nötig)
order = {"order_id": "0123", "user_id": "alice"}
user = {"user_id": "alice", "name": "Alice", "email": "..."}

# Denormalized (alles in einem Dokument)
order = {
  "order_id": "0123",
  "user": { # User-Daten dupliziert
    "user_id": "alice",
    "name": "Alice",
    "email": "alice@example.com"
  }
}
# Vorteil: Ein Query, keine Joins!
```

3. Use Computed Properties

```
@property
def age(self):
    """Berechnet Alter aus Geburtstag"""
    if not self.birthday:
        return None
    today = datetime.now()
    return today.year - self.birthday.year

# Nicht speichern, berechnen!
# Daten sind immer aktuell
```

4. Index Strategically

Nicht jedes Feld braucht einen Index:

```
# Index: Oft gesucht/gefiltert
client.create_index("contacts", "email_idx", ["email"])

# x Kein Index: Selten gesucht
# notes braucht keinen Index (außer Fulltext)
```

3.6 Zusammenfassung

In diesem Kapitel haben Sie gelernt:

Vier Modelle: Wann Relational, Graph, Dokument oder Vektor

Entscheidungskriterien: Die 5 Fragen-Methode

Kontaktmanager: Vollständige Dokument-Modell Demo

Multi-Model Kombination: Verschiedene Modelle zusammen nutzen

Best Practices: Denormalisierung, Computed Properties, Indexing

Key Takeaways

1. Es gibt kein "bestes" Modell - nur das beste für Ihren Use Case
2. **Kombinieren ist Stärke** - ThemisDB glänzt bei Multi-Model

3. **Schema-Flexibilität** - Dokumente sind perfekt für Evolution

4. **Performance** - Wählen Sie das Modell nach Query-Patterns

Nächste Schritte

Im nächsten Kapitel lernen Sie, wie Sie ThemisDB installieren, konfigurieren und für Production vorbereiten.

[Kapitel 4: Installation & Setup](#) →

Weiterführende Ressourcen

- **Complete Example:** [examples/03_contact_manager](#)
- **Tutorial:** [Contact Manager Tutorial](#)
- **Document Model Docs:** [../de/architecture/architecture_content.md](#)
- **Multi-Model Patterns:** [Kapitel 13 - AQL Mastery](#)

Kapitel 3 von 30 | Teil I: Grundlagen | ~7.500 Wörter

Kapitel 4: Kapitel 4 - Installation

"Die beste Dokumentation hilft nichts, wenn die Software nicht läuft. Installation sollte einfach sein - und das ist sie."

Überblick

In den ersten drei Kapiteln haben Sie die Konzepte von ThemisDB kennengelernt. Jetzt ist es Zeit, ThemisDB selbst zu installieren und zu konfigurieren. Dieses Kapitel führt Sie durch alle Optionen - von der schnellsten (Docker) bis zur flexibelsten (Source Build).

Was Sie in diesem Kapitel lernen werden: - Installation mit Docker (schnellste Methode) - Installation aus Binaries - Build von Source Code - Konfiguration und Tuning - Production-Setup Best Practices - Troubleshooting häufiger Probleme

Voraussetzungen: Grundlegende Kommandozeilen-Kenntnisse.

4.1 Systemanforderungen

Minimale Requirements

```
CPU: 2 Cores
RAM: 4 GB
Disk: 20 GB (SSD empfohlen)
OS:
  - Linux (Ubuntu 20.04+, Debian 11+, CentOS 8+)
  - macOS 11+
  - Windows 10/11 (via WSL2 oder Docker)
```

Empfohlene Production Requirements

```
CPU: 8+ Cores
RAM: 32 GB
Disk: 500 GB NVMe SSD
OS: Linux (Ubuntu 22.04 LTS empfohlen)
Network: 10 Gbps
```

Hardware-Überlegungen

CPU: - ThemisDB ist multi-threaded - Mehr Cores = höherer Durchsatz - Minimum 2, empfohlen 8+

RAM: - Wird für Caching genutzt - 25% des Datasets sollte in RAM passen - Minimum 4 GB, empfohlen 32 GB+

Storage: - SSDs sind **stark** empfohlen - ThemisDB nutzt LSM-Trees (sequential writes) - NVMe > SATA SSD >> HDD - RAID 10 für Production

Disk Performance Vergleich:

Storage Type	Random Read IOPS	Sequential Write MB/s
HDD 7200 RPM	100-200	150
SATA SSD	50,000	500
NVMe SSD	500,000	3,500

ThemisDB Benefit: Mit NVMe SSD 10-50x schneller als HDD!

Abb. 04.1: Installations-Ablaufdiagramm

4.2 Installation mit Docker (Schnellste Methode)

Warum Docker?

- Funktioniert sofort (keine Dependencies)
- Isolation vom Host-System
- Einfache Updates
- Konsistent über alle Plattformen

Quick Start

```
# 1. ThemisDB starten (neueste Version)
docker run -d \
  --name themisdb \
  -p 8765:8765 \
  -v themisdb_data:/data \
  themisdb/themisdb:latest

# 2. Testen
curl http://localhost:8765/health

# Output:
# {"status":"ok","version":"1.3.4","uptime":2.5}
```

Fertig! ThemisDB läuft jetzt.

Mit spezifischer Version

```
# Pinne Version für Production
docker run -d \
  --name themisdb \
  -p 8765:8765 \
  -v themisdb_data:/data \
  themisdb/themisdb:1.3.4 # Fixe Version
```

Best Practice: Verwende in Production immer eine fixe Version, nicht `latest`.

Mit Konfiguration

```
# Erstelle Config-File
cat > themisdb.yaml << EOF
server:
  port: 8765
  threads: 8

storage:
  path: /data
  cache_size_mb: 2048

logging:
  level: info
  file: /logs/themisdb.log
EOF

# Starte mit Custom Config
docker run -d \
  --name themisdb \
  -p 8765:8765 \
  -v themisdb_data:/data \
  -v themisdb_logs:/logs \
  -v $(pwd)/themisdb.yaml:/etc/themisdb/config.yaml \
  themisdb/themisdb:1.3.4 \
  --config /etc/themisdb/config.yaml
```

Docker Compose

Für komplexere Setups mit mehreren Containern:

```
# docker-compose.yml
version: '3.8'

services:
  themisdb:
    image: themisdb/themisdb:1.3.4
    container_name: themisdb
    ports:
      - "8765:8765"
    volumes:
      - themisdb_data:/data
      - themisdb_logs:/logs
      - ./config.yaml:/etc/themisdb/config.yaml
    environment:
      - THEMISDB_LOG_LEVEL=info
      - THEMISDB_CACHE_SIZE=2048
    restart: unless-stopped
    healthcheck:
      test: ["CMD", "curl", "-f", "http://localhost:8765/health"]
      interval: 30s
      timeout: 10s
      retries: 3

# Optional: Monitoring mit Prometheus
prometheus:
  image: prom/prometheus:latest
  ports:
    - "9090:9090"
  volumes:
    - ./prometheus.yml:/etc/prometheus/prometheus.yml

volumes:
  themisdb_data:
  themisdb_logs:
```

Starten:

```
docker-compose up -d
```

4.3 Installation aus Binaries

Download

```
# Linux (x86_64)
curl -L -o themisdb.tar.gz \
  https://github.com/makr-code/ThemisDB/releases/download/v1.3.4/themisdb-linux-x86_64.tar.gz

# macOS (Apple Silicon)
curl -L -o themisdb.tar.gz \
  https://github.com/makr-code/ThemisDB/releases/download/v1.3.4/themisdb-darwin-arm64.tar.gz

# Entpacken
tar xzf themisdb.tar.gz
cd themisdb
```

Installation

```
# Systemweit installieren (benötigt sudo)
sudo cp bin/themisdb /usr/local/bin/
sudo mkdir -p /etc/themisdb
sudo cp config/themisdb.yaml /etc/themisdb/

# Oder: Lokale Installation (ohne sudo)
mkdir -p ~/themisdb/{bin,data,logs}
cp bin/themisdb ~/themisdb/bin/
cp config/themisdb.yaml ~/themisdb/
```


Starten

```
# Als Service (systemd)
sudo systemctl start themisdb
sudo systemctl enable themisdb # Autostart

# Oder: Direkt
themisdb --config /etc/themisdb/config.yaml

# Im Hintergrund
nohup themisdb --config themisdb.yaml > logs/themisdb.log 2>&1 &
```

4.4 Build von Source

Warum von Source bauen?

- Neueste Features (Entwicklungs-Branch)
- Custom Optimierungen
- Spezielle Plattformen (ARM, RISC-V)
- Beiträge entwickeln

Dependencies installieren

Ubuntu/Debian:

```
sudo apt-get update
sudo apt-get install -y \
    build-essential \
    cmake \
    git \
    libssl-dev \
    libz-dev \
    libbz2-dev \
    liblz4-dev \
    libzstd-dev
```

macOS:

```
brew install cmake openssl zlib bzip2 lz4 zstd
```

Clone und Build

```
# 1. Repository klonen
git clone https://github.com/makr-code/ThemisDB.git
cd ThemisDB

# 2. Submodules initialisieren
git submodule update --init --recursive

# 3. Build konfigurieren
mkdir build && cd build
cmake .. \
  -DCMAKE_BUILD_TYPE=Release \
  -DCMAKE_INSTALL_PREFIX=/usr/local

# 4. Kompilieren (nutzt alle CPU-Cores)
make -j$(nproc)

# 5. Tests ausführen (optional)
make test

# 6. Installieren
sudo make install
```

Build-Optionen

```
# Debug Build (mit Symbolen)
cmake .. -DCMAKE_BUILD_TYPE=Debug

# Mit Sanitizers (Memory-Leak Detection)
cmake .. \
  -DCMAKE_BUILD_TYPE=Debug \
  -DENABLE_ASAN=ON \
  -DENABLE_UBSAN=ON

# Optimiert für aktuellen CPU
cmake .. \
  -DCMAKE_BUILD_TYPE=Release \
  -DNATIVE_ARCH=ON

# Mit allen Features
cmake .. \
  -DCMAKE_BUILD_TYPE=Release \
  -DWITH_JEMALLOC=ON \
  -DWITH_SNAPPY=ON \
  -DWITH_LZ4=ON \
  -DWITH_ZSTD=ON
```

4.5 Konfiguration

Basis-Konfiguration

```
# themisdb.yaml

# Server Settings
server:
  host: 0.0.0.0          # Bind auf alle Interfaces
  port: 8765             # Standard Port
  threads: 8             # Worker Threads (= CPU Cores)
  max_connections: 1000  # Maximale gleichzeitige Connections

# Storage Settings
storage:
  path: /var/lib/themisdb/data
  cache_size_mb: 2048    # RocksDB Block Cache
  write_buffer_size_mb: 64
  max_open_files: 1000
  compression: lz4       # lz4, zstd, snappy, none

# Logging
logging:
  level: info            # debug, info, warning, error
  file: /var/log/themisdb/themisdb.log
  max_size_mb: 100
  max_backups: 10

# Security
security:
  tls_enabled: false
  tls_cert: /etc/themisdb/cert.pem
  tls_key: /etc/themisdb/key.pem
  auth_enabled: false
  auth_db: /etc/themisdb/users.db
```

Performance Tuning

```
# Für High-Throughput Workload

storage:
  cache_size_mb: 8192      # Mehr Cache = weniger Disk I/O
  write_buffer_size_mb: 256
  max_background_jobs: 8   # Parallel Compaction
  level0_slowdown_writes_trigger: 20
  level0_stop_writes_trigger: 36

server:
  threads: 16              # Mehr Threads für mehr Parallelität
  max_connections: 5000
```

```
# Für Low-Latency Workload

storage:
  cache_size_mb: 16384     # Großer Cache
  write_buffer_size_mb: 128
  max_background_jobs: 4   # Weniger Background I/O

server:
  threads: 8
  max_connections: 1000
```

Environment Variables

Überschreiben Config-File Werte:

```
# Port ändern
export THEMISDB_PORT=9000

# Log-Level
export THEMISDB_LOG_LEVEL=debug

# Cache Size
export THEMISDB_CACHE_SIZE=4096

# Starten mit Env Vars
themisdb
```

4.6 Production Setup

Systemd Service

```
# /etc/systemd/system/themisdb.service

[Unit]
Description=ThemisDB Multi-Model Database
After=network.target

[Service]
Type=simple
User=themisdb
Group=themisdb
ExecStart=/usr/local/bin/themisdb --config /etc/themisdb/config.yaml
Restart=on-failure
RestartSec=5s

# Security
NoNewPrivileges=true
PrivateTmp=true
ProtectSystem=strict
ProtectHome=true
ReadWritePaths=/var/lib/themisdb /var/log/themisdb

# Resource Limits
LimitNOFILE=65536
LimitNPROC=4096

[Install]
WantedBy=multi-user.target
```

Aktivieren:

```
sudo systemctl daemon-reload
sudo systemctl enable themisdb
sudo systemctl start themisdb
```

Monitoring Setup

Health Endpoint:

```
curl http://localhost:8765/health
```

Metrics Endpoint (Prometheus):

```
curl http://localhost:8765/metrics

# Output:
# themisdb_requests_total 12345
# themisdb_request_duration_seconds_sum 123.45
# themisdb_storage_size_bytes 1234567890
# ...
```

Grafana Dashboard: Importiere vorgefertigtes Dashboard: `dashboards/grafana-themisdb.json`

Backup Strategy

1. Snapshot-basiertes Backup:

```
# Erstelle Snapshot
curl -X POST http://localhost:8765/admin/snapshot

# Snapshot wird geschrieben nach:
/var/lib/themisdb/snapshots/snapshot-2025-12-28-100000/

# Kopiere Snapshot
rsync -av /var/lib/themisdb/snapshots/ backup-server:/backups/themisdb/
```

2. Continuous Backup:


```
# Repliziere WAL Log kontinuierlich
rsync -av --delete \
  /var/lib/themisdb/data/WAL/ \
  backup-server:/backups/themisdb/wal/
```

3. Restore:

```
# Stoppe Service
sudo systemctl stop themisdb

# Restore Snapshot
rsync -av backup-server:/backups/themisdb/latest/ /var/lib/themisdb/data/

# Starte Service
sudo systemctl start themisdb
```

Security Hardening

1. TLS aktivieren:

```
security:
  tls_enabled: true
  tls_cert: /etc/themisdb/cert.pem
  tls_key: /etc/themisdb/key.pem
```

2. Authentifizierung:

```
# Erstelle User
themisdb-admin user create alice --password secret123 --role admin

# User-DB wird erstellt in /etc/themisdb/users.db
```

```
security:
  auth_enabled: true
  auth_db: /etc/themisdb/users.db
```

3. Firewall:

```
# Nur von App-Servern erreichbar
sudo ufw allow from 10.0.0.0/24 to any port 8765
sudo ufw enable
```

4. Network Isolation:

```
# Bind nur auf interne IP
server:
    host: 10.0.0.10 # Nicht 0.0.0.0!
```

4.7 Troubleshooting

Problem: Port bereits in Verwendung

Symptom:

```
ERROR: Failed to bind on port 8765: Address already in use
```

Lösung:

```
# Prüfe welcher Prozess Port verwendet
sudo lsof -i :8765

# oder
sudo netstat -tulpn | grep 8765

# Stoppe konfliktierenden Prozess
sudo systemctl stop <service>

# Oder: Ändere Port in Config
server:
    port: 9000
```

Problem: Zu wenig Memory

Symptom:

```
WARNING: Cache size exceeds available memory
ERROR: Out of memory
```

Lösung:

```
# Reduziere Cache Size
storage:
  cache_size_mb: 1024 # Statt 8192
  write_buffer_size_mb: 32
```

Problem: Langsame Queries

Symptom: Queries dauern > 1 Sekunde

Diagnose:

```
# Aktiviere Query Profiling
export THEMISDB_LOG_LEVEL=debug

# Prüfe Logs
tail -f /var/log/themisdb/themisdb.log | grep "Query execution"
```

Lösung:

```
-- Prüfe ob Indizes genutzt werden
EXPLAIN FOR user IN users FILTER user.email == 'test@example.com' RETURN user

-- Output sollte zeigen: "using index: email_idx"
-- Falls nicht: Index erstellen!
```

Problem: Disk voll

Symptom:

```
ERROR: No space left on device
```

Lösung:

```
# 1. Prüfe Disk Usage
df -h /var/lib/themisdb

# 2. Compaction triggern (löscht alte Versionen)
curl -X POST http://localhost:8765/admin/compact

# 3. Alte Snapshots löschen
rm -rf /var/lib/themisdb/snapshots/snapshot-old-*

# 4. Cleanup WAL Logs
themisdb-admin wal cleanup --keep-last 10
```

Problem: Connection Timeouts**Symptom:**

```
ERROR: Connection timed out after 10s
```

Lösung:

```
# Erhöhe Timeouts
server:
    read_timeout_s: 30
    write_timeout_s: 30
    idle_timeout_s: 300

# Erhöhe Max Connections
server:
    max_connections: 5000
```

4.8 Updates und Wartung

Update-Prozess

Docker:

```
# 1. Pull neue Version
docker pull themisdb/themisdb:1.3.4

# 2. Stoppe alten Container
docker stop themisdb

# 3. Starte mit neuer Version
docker run -d \
  --name themisdb \
  -p 8765:8765 \
  -v themisdb_data:/data \
  themisdb/themisdb:1.3.4

# 4. Alte Version entfernen
docker rm themisdb-old
```

Binary:

```
# 1. Backup erstellen
sudo systemctl stop themisdb
tar czf themisdb-backup.tar.gz /var/lib/themisdb/data

# 2. Neue Version installieren
sudo cp themisdb-new /usr/local/bin/themisdb

# 3. Starten
sudo systemctl start themisdb

# 4. Testen
curl http://localhost:8765/health
```

Rolling Update (Zero-Downtime)

Für Cluster-Setups:

```
# 1. Update Node 2
kubectl set image deployment/themisdb-node2 themisdb=themisdb:1.3.4

# 2. Warte auf Ready
kubectl wait --for=condition=ready pod -l app=themisdb-node2

# 3. Update Node 1
kubectl set image deployment/themisdb-node1 themisdb=themisdb:1.3.4

# → Keine Downtime!
```

4.9 Diagnostics & Hardening (Kurz)

Health & Metrics: - `GET /health` (liveness), `GET /metrics` (Prometheus) - Log-Level zur Fehlersuche: `export THEMISDB_LOG_LEVEL=debug`

Security-Hardening: - TLS aktivieren: `--tls.cert` / `--tls.key` - mTLS optional: Client-Certs whitelisten - Admin-API absichern: IP-Whitelist + Auth-Header

Storage-Pflege: - Wöchentliche Compaction: `POST /admin/compact` - Snapshot-Rotation: Keep-last-7, Air-Gap-Upload

Performance-Probe: - `EXPLAIN` für jede neue Query - Page Cache treffen: `cache_size_mb` auf 20-30% RAM

4.10 Deployment-Playbooks

Single Node (Pilot)

- Docker-Run mit persistentem Volume (`themisdb_data`)
- Backup via Snapshot-API + Offsite-Kopie
- Monitoring: Health + Metrics → Prometheus

HA (2-3 Nodes, Sync-Replicas)

- Node-Labels: `role=primary`, `role=secondary`
- Synchronous Commit für RPO=0
- Load Balancer vor 2 Read-Replicas

Airgapped Install

- Offline-Bundle: Binary + Config + Checksums
- Pakete signieren, Verify via `sha256sum`
- Updates nur über signierte Tarballs einspielen

4.11 Operations-Checkliste (Go-Live)

- [] TLS 1.3 aktiviert, mTLS optional getestet
- [] Backups automatisiert + Restore-Drill bestanden
- [] Monitoring: Health, Metrics, Logs zentralisiert
- [] Admin-API eingeschränkt (Firewall + Auth)
- [] Config-Lint: Cache, Write-Buffer, Thread-Count passend
- [] Runbooks: Incident, Restore, Scale-Up

4.12 Zusammenfassung

In diesem Kapitel haben Sie gelernt:

Systemanforderungen: CPU, RAM, Storage Best Practices

Docker Installation: Schnellste Methode, Production-ready

Binary Installation: Systemweit oder lokal

Source Build: Für Custom Builds und Development

Konfiguration: Tuning für Performance und Security

Production Setup: Systemd, Monitoring, Backup

Troubleshooting: Häufige Probleme und Lösungen

Updates: Safe Update-Prozesse

Key Takeaways

1. **Docker ist der einfachste Weg** - funktioniert sofort
2. **SSDs sind essentiell** - 10-50x Performance-Gewinn

3. **Monitoring ist wichtig** - Health + Metrics endpoints
4. **Backups sind Pflicht** - Snapshots + WAL Replication
5. **Security nicht vergessen** - TLS + Auth für Production

Sie sind bereit!

ThemisDB ist jetzt installiert und läuft. Im nächsten Teil des Kompendiums (Teil II) tauchen wir tiefer in die einzelnen Datenmodelle ein.

Teil II: Kapitel 5 - Relationale Daten →

Weiterführende Ressourcen

- **Docker Deployment:** [../de/deployment/DOCKER_DEPLOYMENT.md](#)
 - **Build Optionen:** [../de/deployment/BUILD_OPTIONEN_REFERENZ.md](#)
 - **Production Strategy:** [../de/deployment/deployment_strategy.md](#)
 - **ARM Deployment:** [../de/deployment/deployment_arm_build.md](#)
-

Kapitel 4 von 30 | Teil I: Grundlagen | ~6.500 Wörter

Teil II - Datenmodelle

Kapitel 5: Kapitel 5 - Relational

"Relational databases are like spreadsheets that can talk to each other - but with ACID guarantees and without the chaos."

Überblick

Relationale Datenbanken sind das Rückgrat der IT seit über 40 Jahren. In ThemisDB ist das relationale Modell eines von vier gleichberechtigten Datenmodellen - aber mit vollem AQL-Support und ACID-Garantien.

Was Sie in diesem Kapitel lernen werden: - Relationales Datenmodell: Tabellen, Schemas, Constraints - AQL in ThemisDB: DDL, DML, Joins, Subqueries - Normalisierung vs. Denormalisierung - Transaktionen und Integrität - Indexes und Performance - **Praxisbeispiel 1:** Inventory System (Lagerverwaltung) - **Praxisbeispiel 2:** Expense Tracker (Ausgabenverwaltung)

Voraussetzungen: AQL-Grundkenntnisse hilfreich, aber nicht notwendig.

5.1 Das Relationale Modell

Grundkonzepte

Tabelle (Table): Sammlung von Zeilen mit gleichem Schema

```
products (Tabelle)
+-----+-----+-----+-----+
| id | name      | price | stock |
+-----+-----+-----+-----+
|  1 | Laptop    |  1200 |    15 |
|  2 | Mouse     |    25 |   100 |
|  3 | Keyboard  |    80 |    50 |
+-----+-----+-----+-----+
```

Zeile (Row): Ein Datensatz in einer Tabelle

Spalte (Column): Ein Attribut, das jede Zeile hat

Schema: Definition der Spalten und Typen

Primärschlüssel (Primary Key): Eindeutige ID für jede Zeile

Fremdschlüssel (Foreign Key): Referenz zu einer anderen Tabelle

Warum Relational?

Vorteile: - **Struktur:** Klare, vorhersehbare Datenstruktur - **Integrität:** Constraints garantieren Datenqualität - **Joins:** Verknüpfe Daten aus mehreren Tabellen - **ACID:** Transaktionen mit vollständiger Konsistenz - **AQL:** Standardisierte, mächtige Abfragesprache

× Nachteile: - Rigid: Schema-Änderungen erfordern Migrations - Komplex: Normalisierung kann zu vielen Tables führen - Performance: Joins können langsam sein bei vielen Tables - Skalierung: Vertical Scaling bevorzugt

Wann Relational wählen?

Perfekt für: - Strukturierte Business-Daten (Orders, Invoices, Inventory) - Daten mit klaren Beziehungen (Customers → Orders → Items) - Transaktionale Systeme (Banking, E-Commerce) - Reports mit Aggregationen (SUM, AVG, GROUP BY) - Datenintegrität ist kritisch

Weniger geeignet für: - × Hochflexible Schemas (Metadata, User-Generated Content) - × Netzwerk-Daten mit vielen Hops (Social Graphs) - × Unstrukturierte Daten (Logs, Dokumente) - × Vektor-Daten (Embeddings, Features)

5.2 Tabellen und Schemas

Tabelle erstellen

```
-- Basic Table
CREATE TABLE products (
  id INT PRIMARY KEY,
  name VARCHAR(255) NOT NULL,
  price DECIMAL(10, 2) NOT NULL,
  stock INT DEFAULT 0,
  created_at TIMESTAMP DEFAULT NOW()
);
```

Datentypen in ThemisDB:

Typ	Beschreibung	Beispiel
INT	Ganzzahl	42, -17, 0
BIGINT	Große Ganzzahl	9223372036854775807
DECIMAL(p,s)	Festkommazahl	123.45
FLOAT/DOUBLE	Fließkommazahl	3.14159
VARCHAR(n)	Variable Zeichenkette	"Hello World"
TEXT	Unbegrenzte Zeichenkette	Langer Text
BOOLEAN	Wahrheitswert	true, false
TIMESTAMP	Zeitstempel	2025-12-28 10:30:00
DATE	Datum	2025-12-28
JSON	JSON-Dokument	{"key": "value"}

Constraints**Primary Key:**

```
CREATE TABLE customers (  
  id INT PRIMARY KEY,  
  email VARCHAR(255) UNIQUE NOT NULL,  
  name VARCHAR(255) NOT NULL  
);
```

Foreign Key:

```
CREATE TABLE orders (  
  id INT PRIMARY KEY,  
  customer_id INT NOT NULL,  
  total DECIMAL(10, 2) NOT NULL,  
  created_at TIMESTAMP DEFAULT NOW(),  
  
  FOREIGN KEY (customer_id) REFERENCES customers(id)  
);
```

Check Constraints:

```
CREATE TABLE products (  
  id INT PRIMARY KEY,  
  name VARCHAR(255) NOT NULL,  
  price DECIMAL(10, 2) NOT NULL CHECK (price >= 0),  
  stock INT NOT NULL CHECK (stock >= 0),  
  discount DECIMAL(3, 2) CHECK (discount BETWEEN 0 AND 1)  
);
```

Unique Constraints:

```
CREATE TABLE users (  
  id INT PRIMARY KEY,  
  username VARCHAR(50) UNIQUE NOT NULL,  
  email VARCHAR(255) UNIQUE NOT NULL  
);
```

Auto-Increment IDs

```
CREATE TABLE products (  
  id INT PRIMARY KEY AUTO_INCREMENT,  
  name VARCHAR(255) NOT NULL  
);  
  
-- Insert ohne ID  
INSERT INTO products (name) VALUES ('Laptop');  
-- → Automatisch id=1  
  
INSERT INTO products (name) VALUES ('Mouse');  
-- → Automatisch id=2
```

5.3 Daten einfügen, ändern, löschen

INSERT

```
-- Single Document  
INSERT {  
  id: 1,  
  name: 'Laptop',  
  price: 1200.00,  
  stock: 15  
} INTO products  
  
-- Multiple Documents  
INSERT [  
  {id: 2, name: 'Mouse', price: 25.00, stock: 100},  
  {id: 3, name: 'Keyboard', price: 80.00, stock: 50},  
  {id: 4, name: 'Monitor', price: 350.00, stock: 20}  
] INTO products
```

UPDATE

```
-- Update single document
UPDATE {id: 1} WITH {stock: stock - 1} IN products

-- Update multiple documents (with FOR loop)
FOR product IN products
  FILTER product.stock > 50
  UPDATE product WITH {
    price: product.price * 0.9
  } IN products

-- Update with join data
FOR order_item IN order_items
  FOR product IN products
    FILTER order_item.product_id == product.id
    UPDATE order_item WITH {
      price: product.price
    } IN order_items
```

REMOVE (DELETE)

```
-- Remove single document
REMOVE {id: 1} IN products

-- Remove multiple documents
FOR product IN products
  FILTER product.stock == 0
  REMOVE product IN products

-- Remove all (Vorsicht!)
FOR product IN products
  REMOVE product IN products
```

UPSERT (Insert or Update)

```
-- Insert or Update based on key
UPSERT {id: 1}
  INSERT {
    id: 1,
    name: 'Laptop',
    price: 1200.00,
    stock: 15
  }
  UPDATE {
    price: 1200.00,
    stock: 15
  }
IN products
```


5.4 Queries und Joins

Query Basics

```
-- All columns
FOR product IN products
  RETURN product

-- Specific columns
FOR product IN products
  RETURN {name: product.name, price: product.price}

-- With FILTER
FOR product IN products
  FILTER product.price > 100
  RETURN product

-- With SORT and LIMIT
FOR product IN products
  SORT product.price DESC
  LIMIT 10
  RETURN product

-- With aggregation functions
FOR product IN products
  COLLECT AGGREGATE
    avgPrice = AVG(product.price),
    maxPrice = MAX(product.price),
    minPrice = MIN(product.price),
    total = COUNT()
  RETURN {avgPrice, maxPrice, minPrice, total}

-- With GROUP BY (COLLECT)
FOR product IN products
  COLLECT category = product.category
  AGGREGATE
    count = COUNT(),
    avgPrice = AVG(product.price)
  RETURN {category, count, avgPrice}
```

INNER JOIN

```
-- Orders mit Customer-Namen (Multi-FOR Join)
FOR order IN orders
  FOR customer IN customers
    FILTER order.customer_id == customer.id
  RETURN {
    id: order.id,
    customer_name: customer.name,
    total: order.total
  }
```

Abb. 05.1: Relationales Schema-Design

Abb. 05.2: Join-Optimierung-Strategie total: order.total, customer_name: customer.name }

****Visualisierung:****

```
customers orders +-----+ +-----+ | id=1 | ← -----|cust_id=1| ✓ Match → returned | Alice | | €100 |
+-----+ +-----+ | id=2 | | cust_id=1| ✓ Match → returned | Bob | | €50 | +-----+ +-----+ | id=3 |
| Carol | → Kein Match, nicht returned +-----+
```

```

### LEFT JOIN (Outer Join with COLLECT)

```sql
-- Alle Customers, mit/ohne Orders
FOR customer IN customers
 LET customer_orders = (
 FOR order IN orders
 FILTER order.customer_id == customer.id
 RETURN order
)
RETURN {
 name: customer.name,
 order_count: LENGTH(customer_orders),
 total_spent: SUM(customer_orders[*].total)
}

```

### Visualisierung:

customers	orders
+-----+	+-----+
id=1	←----- cust_id=1  ✓ Match
Alice	€100
+-----+	+-----+
id=2	
Bob	→ Kein Order, aber returned mit NULL
+-----+	

## Multi-Table JOIN

```
-- Orders mit Items und Products (Multi-FOR Join)
FOR order IN orders
 FILTER order.created_at >= '2025-01-01'
 FOR customer IN customers
 FILTER order.customer_id == customer.id
 FOR order_item IN order_items
 FILTER order_item.order_id == order.id
 FOR product IN products
 FILTER order_item.product_id == product.id
 RETURN {
 order_id: order.id,
 customer: customer.name,
 product: product.name,
 quantity: order_item.quantity,
 price: order_item.price
 }
```

## Subqueries

```
-- Products teurer als Durchschnitt (WITH CTE)
LET avgPrice = (
 FOR product IN products
 COLLECT AGGREGATE avg = AVG(product.price)
 RETURN avg
)[0]

FOR product IN products
 FILTER product.price > avgPrice
 RETURN {name: product.name, price: product.price}

-- Customers mit mehr als 3 Orders (Subquery)
LET active_customers = (
 FOR order IN orders
 COLLECT customer_id = order.customer_id
 AGGREGATE order_count = COUNT()
 FILTER order_count > 3
 RETURN customer_id
)

FOR customer IN customers
 FILTER customer.id IN active_customers
 RETURN customer.name
```

---

## 5.5 Transaktionen

### ACID Garantien

**Atomicity:** Alles oder nichts

**Consistency:** Constraints werden eingehalten

**Isolation:** Transaktionen sehen sich nicht gegenseitig

**Durability:** Commits sind permanent

**Transaction Beispiel**

```
from themis_client import ThemisDB

db = ThemisDB("localhost:8765")

Start Transaction
tx = db.begin_transaction()

try:
 # 1. Reduce stock
 tx.execute("""
 FOR product IN products
 FILTER product.id == @product_id AND product.stock > 0
 UPDATE product WITH {stock: product.stock - 1} IN products
 """, {"product_id": product_id})

 # 2. Create order
 tx.execute("""
 INSERT {
 customer_id: @customer_id,
 product_id: @product_id,
 quantity: 1,
 price: @price
 } INTO orders
 """, {"customer_id": customer_id, "product_id": product_id, "price": price})

 # 3. Charge customer
 tx.execute("""
 FOR customer IN customers
 FILTER customer.id == @customer_id AND customer.balance >= @price
 UPDATE customer WITH {balance: customer.balance - @price} IN customers
 """, {"customer_id": customer_id, "price": price})

 # All OK → Commit
 tx.commit()
 print("Order successful!")

except Exception as e:
 # Error → Rollback
```



```
tx.rollback()
print(f"Order failed: {e}")
```

### Was passiert intern:

```
T1: BEGIN TRANSACTION (snapshot @ version 100)
→ UPDATE products ... (write intent @ version 101)
→ INSERT orders ... (write intent @ version 102)
→ UPDATE customers ... (write intent @ version 103)
→ COMMIT
→ All write intents become visible @ version 104
```

Falls Fehler:

```
→ ROLLBACK
→ All write intents discarded
→ Daten unverändert
```

## Isolation Levels

ThemisDB verwendet **Snapshot Isolation**:

```
Transaction 1
tx1 = db.begin_transaction()
tx1.execute("FOR p IN products FILTER p.id == 1 UPDATE p WITH {price: 100} IN products")

Transaction 2 (parallel)
tx2 = db.begin_transaction()
result = tx2.execute("FOR p IN products FILTER p.id == 1 RETURN p.price")
print(result) # → Alter Wert! (z.B. 90)

TX1 committed
tx1.commit()

TX2 sieht immernoch alten Wert (Snapshot Isolation)
result = tx2.execute("FOR p IN products FILTER p.id == 1 RETURN p.price")
print(result) # → Immernoch 90!

tx2.commit()

Neue Transaction sieht neuen Wert
tx3 = db.begin_transaction()
result = tx3.execute("FOR p IN products FILTER p.id == 1 RETURN p.price")
print(result) # → 100
```

---

## 5.6 Normalisierung

### Problem: Redundanz

#### Nicht-normalisiert:

orders

id	customer	cust_email	product	quantity	price
1	Alice	a@email.com	Laptop	1	1200
2	Alice	a@email.com	Mouse	2	25
3	Bob	b@email.com	Keyboard	1	80

**Probleme:** - Customer email wird wiederholt (Update Anomaly) - Product-Namen inkonsistent ("Laptop" vs "laptop") - Keine Constraints möglich

## Normalisierung: 1NF, 2NF, 3NF

### 1. Normal Form (1NF): Atomare Werte, keine Arrays

```
-- x Nicht 1NF
CREATE TABLE orders (
 id INT,
 products TEXT -- "Laptop, Mouse, Keyboard"
);

-- 1NF
CREATE TABLE orders (
 id INT,
 product_id INT
);
```

### 2. Normal Form (2NF): Alle Nicht-Key-Attribute hängen vom ganzen Key ab

```
-- x Nicht 2NF
CREATE TABLE order_items (
 order_id INT,
 product_id INT,
 quantity INT,
 product_name VARCHAR(255), -- Hängt nur von product_id ab!
 PRIMARY KEY (order_id, product_id)
);

-- 2NF: Separate products table
CREATE TABLE products (
 id INT PRIMARY KEY,
 name VARCHAR(255)
);

CREATE TABLE order_items (
 order_id INT,
 product_id INT,
 quantity INT,
 PRIMARY KEY (order_id, product_id),
 FOREIGN KEY (product_id) REFERENCES products(id)
);
```

### 3. Normal Form (3NF): Keine transitiven Abhängigkeiten

```
-- x Nicht 3NF
CREATE TABLE products (
 id INT PRIMARY KEY,
 category_id INT,
 category_name VARCHAR(255) -- Hängt von category_id ab!
);

-- 3NF: Separate categories table
CREATE TABLE categories (
 id INT PRIMARY KEY,
 name VARCHAR(255)
);

CREATE TABLE products (
 id INT PRIMARY KEY,
 category_id INT,
 FOREIGN KEY (category_id) REFERENCES categories(id)
);
```

## Denormalisierung für Performance

Manchmal ist **bewusste** Denormalisierung sinnvoll:

```
-- Denormalisiert für schnelle Queries
CREATE TABLE order_summary (
 order_id INT PRIMARY KEY,
 customer_id INT,
 customer_name VARCHAR(255), -- Denormalisiert!
 item_count INT, -- Computed!
 total DECIMAL(10, 2), -- Computed!
 created_at TIMESTAMP
);
```

**Trade-off:** - Queries sind schneller (kein JOIN nötig) - x Updates sind komplexer (mehrere Tables updaten) - x Mehr Storage (Redundanz)

## 5.7 Indexes

### Warum Indexes?

#### Ohne Index:

```
FOR product IN products
 FILTER product.name == 'Laptop'
 RETURN product
-- → Scannt ALLE Zeilen (Seq Scan): $O(n)$
```

#### Mit Index:

```
CREATE INDEX idx_products_name ON products(name);

FOR product IN products
 FILTER product.name == 'Laptop'
 RETURN product
-- → Nutzt Index (Index Scan): $O(\log n)$
```

**Performance-Unterschied:** - 1 Million rows: Seq Scan ~100ms, Index Scan ~0.1ms - **1000x schneller!**

### Index-Arten

#### 1. B-Tree Index (Standard):

```
CREATE INDEX idx_products_price ON products(price);

-- Gut für:
FOR product IN products
 FILTER product.price > 100
 RETURN product

FOR product IN products
 FILTER product.price >= 50 AND product.price <= 150
 RETURN product

FOR product IN products
 SORT product.price
 RETURN product
```

## 2. Unique Index:

```
CREATE UNIQUE INDEX idx_users_email ON users(email);

-- Verhindert Duplikate automatisch
INSERT {email: 'test@example.com'} INTO users -- OK
INSERT {email: 'test@example.com'} INTO users -- ERROR!
```

## 3. Composite Index:

```
CREATE INDEX idx_orders_cust_date ON orders(customer_id, created_at);

-- Gut für:
FOR order IN orders
 FILTER order.customer_id == 123 AND order.created_at > '2025-01-01'
 RETURN order

FOR order IN orders
 FILTER order.customer_id == 123
 RETURN order -- Auch OK!

-- Nicht gut für:
FOR order IN orders
 FILTER order.created_at > '2025-01-01'
 RETURN order -- Index nicht nutzbar!
```

#### 4. Partial Index:

```
CREATE INDEX idx_orders_pending ON orders(created_at)
WHERE status = 'pending';

-- Kleiner Index nur für pending orders
FOR order IN orders
 FILTER order.status == 'pending' AND order.created_at > '2025-01-01'
 RETURN order
```

## Index Best Practices

**Index erstellen für:** - Primary Keys (automatisch) - Foreign Keys (manuell) - WHERE-Spalten in häufigen Queries - ORDER BY-Spalten - JOIN-Spalten

**× Zu viele Indexes vermeiden:** - Jeder Index verlangsamt INSERT/UPDATE/DELETE - Jeder Index braucht Storage - **Faustregel:** Max 5-7 Indexes pro Table



---

## 5.8 Praxisbeispiel 1: Inventory System

### Überblick

Ein **Lagerverwaltungssystem** für ein kleines bis mittelgroßes Unternehmen: - Products mit Categories - Warehouses (mehrere Standorte) - Stock Levels pro Warehouse - Stock Movements (Ein-/Ausgang) - Suppliers

**Location:** [examples/04\\_inventory\\_system/](#)

**Datenmodell**

```
-- Categories
CREATE TABLE categories (
 id INT PRIMARY KEY AUTO_INCREMENT,
 name VARCHAR(255) NOT NULL UNIQUE,
 description TEXT
);

-- Products
CREATE TABLE products (
 id INT PRIMARY KEY AUTO_INCREMENT,
 sku VARCHAR(50) NOT NULL UNIQUE,
 name VARCHAR(255) NOT NULL,
 description TEXT,
 category_id INT NOT NULL,
 unit_price DECIMAL(10, 2) NOT NULL CHECK (unit_price >= 0),
 min_stock_level INT DEFAULT 0,
 created_at TIMESTAMP DEFAULT NOW(),

 FOREIGN KEY (category_id) REFERENCES categories(id),
 INDEX idx_products_category (category_id),
 INDEX idx_products_sku (sku)
);

-- Warehouses
CREATE TABLE warehouses (
 id INT PRIMARY KEY AUTO_INCREMENT,
 name VARCHAR(255) NOT NULL,
 location VARCHAR(255),
 capacity INT
);

-- Stock Levels
CREATE TABLE stock_levels (
 product_id INT NOT NULL,
 warehouse_id INT NOT NULL,
 quantity INT NOT NULL DEFAULT 0 CHECK (quantity >= 0),
 last_updated TIMESTAMP DEFAULT NOW(),
```

```
PRIMARY KEY (product_id, warehouse_id),
FOREIGN KEY (product_id) REFERENCES products(id),
FOREIGN KEY (warehouse_id) REFERENCES warehouses(id)
);

-- Stock Movements
CREATE TABLE stock_movements (
 id INT PRIMARY KEY AUTO_INCREMENT,
 product_id INT NOT NULL,
 warehouse_id INT NOT NULL,
 quantity INT NOT NULL, -- Positive = Eingang, Negative = Ausgang
 movement_type ENUM('purchase', 'sale', 'transfer', 'adjustment'),
 reference VARCHAR(255),
 created_at TIMESTAMP DEFAULT NOW(),

 FOREIGN KEY (product_id) REFERENCES products(id),
 FOREIGN KEY (warehouse_id) REFERENCES warehouses(id),
 INDEX idx_movements_product (product_id),
 INDEX idx_movements_warehouse (warehouse_id),
 INDEX idx_movements_date (created_at)
);

-- Suppliers
CREATE TABLE suppliers (
 id INT PRIMARY KEY AUTO_INCREMENT,
 name VARCHAR(255) NOT NULL,
 contact_email VARCHAR(255),
 contact_phone VARCHAR(50)
);

-- Product Suppliers (Many-to-Many)
CREATE TABLE product_suppliers (
 product_id INT NOT NULL,
 supplier_id INT NOT NULL,
 supplier_sku VARCHAR(50),
 unit_cost DECIMAL(10, 2),

 PRIMARY KEY (product_id, supplier_id),
```

```
FOREIGN KEY (product_id) REFERENCES products(id),
FOREIGN KEY (supplier_id) REFERENCES suppliers(id)
);
```

## Häufige Queries

### 1. Total Stock pro Product:

```
FOR p IN products
 FILTER p.id == @product_id
 LET total = SUM(sl.quantity FOR sl IN stock_levels FILTER sl.product_id == p.id)
 RETURN { name: p.name, total_stock: total }
```

### 2. Low Stock Alert:

```
FOR p IN products
 LET total = SUM(sl.quantity FOR sl IN stock_levels FILTER sl.product_id == p.id)
 FILTER total < p.min_stock_level
 SORT total ASC
 RETURN { sku: p.sku, name: p.name, total_stock: total, min_level: p.min_stock_level }
```

### 3. Stock Movement History:

```
LET cutoff = DATE_ADD(NOW(), {days: -@days})
FOR sm IN stock_movements
 FILTER sm.product_id == @product_id && sm.created_at >= cutoff
 LET warehouse = DOCUMENT(sm.warehouse_id)
 SORT sm.created_at DESC
 RETURN {
 created_at: sm.created_at,
 movement_type: sm.movement_type,
 quantity: sm.quantity,
 warehouse: warehouse.name,
 reference: sm.reference
 }
```

## Stock Movement Transaction

```
def record_purchase(product_id, warehouse_id, quantity, supplier_id, cost):
 """Purchase new stock from supplier"""
 tx = db.begin_transaction()
 try:
 # 1. Record movement
 tx.execute("""
 INSERT INTO stock_movements
 (product_id, warehouse_id, quantity, movement_type, reference)
 VALUES (?, ?, ?, 'purchase', ?)
 """, [product_id, warehouse_id, quantity, f"PO-{supplier_id}-{datetime.now().timestamp()}"])

 # 2. Update stock level
 tx.execute("""
 INSERT INTO stock_levels (product_id, warehouse_id, quantity)
 VALUES (?, ?, ?)
 ON CONFLICT (product_id, warehouse_id) DO UPDATE
 SET
 quantity = stock_levels.quantity + EXCLUDED.quantity,
 last_updated = NOW()
 """, [product_id, warehouse_id, quantity])

 # 3. Update product cost (optional)
 tx.execute("""
 UPDATE products
 SET unit_price = ?
 WHERE id = ?
 """, [cost, product_id])

 tx.commit()
 return {"success": True}

 except Exception as e:
 tx.rollback()
 return {"success": False, "error": str(e)}
```

## Reporting: Value per Warehouse

```
SELECT
 w.name AS warehouse,
 COUNT(DISTINCT sl.product_id) AS product_count,
 SUM(sl.quantity) AS total_units,
 SUM(sl.quantity * p.unit_price) AS total_value
FROM warehouses w
LEFT JOIN stock_levels sl ON w.id = sl.warehouse_id
LEFT JOIN products p ON sl.product_id = p.id
GROUP BY w.id, w.name
ORDER BY total_value DESC;
```

### Output:

```
+-----+-----+-----+-----+
| warehouse | product_count | total_units | total_value |
+-----+-----+-----+-----+
| Main Warehouse | 250 | 5,420 | €125,000 |
| Storage Berlin | 180 | 3,210 | €78,500 |
| Distribution Hub | 120 | 1,890 | €42,300 |
+-----+-----+-----+-----+
```

## 5.9 Praxisbeispiel 2: Expense Tracker

### Überblick

Ein **Ausgabenverwaltungssystem** für persönliche Finanzen oder kleine Teams: - Expenses mit Categories  
- Budgets pro Category - Recurring Expenses - Multi-Currency Support - Reports und Analytics

**Location:** [examples/12\\_expense\\_tracker/](examples/12_expense_tracker/)

**Datenmodell**



```
-- Categories
CREATE TABLE expense_categories (
 id INT PRIMARY KEY AUTO_INCREMENT,
 name VARCHAR(100) NOT NULL UNIQUE,
 color VARCHAR(7), -- Hex color #FF5733
 icon VARCHAR(50)
);

-- Expenses
CREATE TABLE expenses (
 id INT PRIMARY KEY AUTO_INCREMENT,
 description VARCHAR(255) NOT NULL,
 amount DECIMAL(10, 2) NOT NULL CHECK (amount > 0),
 currency VARCHAR(3) DEFAULT 'EUR',
 category_id INT NOT NULL,
 expense_date DATE NOT NULL,
 payment_method ENUM('cash', 'credit_card', 'debit_card', 'transfer') DEFAULT 'cash',
 receipt_url VARCHAR(500),
 notes TEXT,
 created_at TIMESTAMP DEFAULT NOW(),

 FOREIGN KEY (category_id) REFERENCES expense_categories(id),
 INDEX idx_expenses_date (expense_date),
 INDEX idx_expenses_category (category_id)
);

-- Budgets
CREATE TABLE budgets (
 id INT PRIMARY KEY AUTO_INCREMENT,
 category_id INT NOT NULL,
 amount DECIMAL(10, 2) NOT NULL CHECK (amount > 0),
 period ENUM('daily', 'weekly', 'monthly', 'yearly') DEFAULT 'monthly',
 start_date DATE NOT NULL,
 end_date DATE,

 FOREIGN KEY (category_id) REFERENCES expense_categories(id),
 UNIQUE KEY (category_id, start_date)
);
```

```
-- Recurring Expenses
CREATE TABLE recurring_expenses (
 id INT PRIMARY KEY AUTO_INCREMENT,
 description VARCHAR(255) NOT NULL,
 amount DECIMAL(10, 2) NOT NULL,
 category_id INT NOT NULL,
 frequency ENUM('daily', 'weekly', 'monthly', 'yearly') NOT NULL,
 start_date DATE NOT NULL,
 end_date DATE,
 last_generated DATE,

 FOREIGN KEY (category_id) REFERENCES expense_categories(id)
);
```

## Häufige Queries

### 1. Expenses für aktuellen Monat:

```
def get_monthly_expenses(year, month):
 return db.query("""
 SELECT
 e.expense_date,
 e.description,
 e.amount,
 c.name AS category,
 e.payment_method
 FROM expenses e
 JOIN expense_categories c ON e.category_id = c.id
 WHERE YEAR(e.expense_date) = ?
 AND MONTH(e.expense_date) = ?
 ORDER BY e.expense_date DESC
 """, [year, month])
```

### 2. Budget Status:

```

LET month_start = DATE_NEW(@year, @month, 1)
LET month_end = DATE_ADD(month_start, {months: 1})
FOR b IN budgets
 FILTER b.period == 'monthly' && b.start_date <= month_start
 LET category = DOCUMENT(b.category_id)
 LET spent = SUM(e.amount
 FOR e IN expenses
 FILTER e.category_id == b.category_id && e.expense_date >= month_start && e.expense_date < month_end
)
 RETURN {
 category: category.name,
 budget: b.amount,
 spent: spent || 0,
 remaining: b.amount - (spent || 0),
 percent_used: (spent || 0) / b.amount * 100
 }

```

### 3. Top Categories:

```

LET year_start = DATE_NEW(@year, 1, 1)
LET year_end = DATE_NEW(@year + 1, 1, 1)
FOR c IN expense_categories
 LET expenses_for_cat = (
 FOR e IN expenses
 FILTER e.category_id == c._id && e.expense_date >= year_start && e.expense_date < year_end
 RETURN e
)
 FILTER LENGTH(expenses_for_cat) > 0
 SORT SUM(e.amount FOR e IN expenses_for_cat) DESC
 LIMIT 10
 RETURN {
 name: c.name,
 expense_count: LENGTH(expenses_for_cat),
 total_amount: SUM(e.amount FOR e IN expenses_for_cat)
 }

```

**Add Expense Transaction**

```

def add_expense(description, amount, category_id, expense_date, payment_method):
 """Add new expense and check budget"""
 tx = db.begin_transaction()
 try:
 # 1. Insert expense
 result = tx.execute("""
 INSERT INTO expenses
 (description, amount, category_id, expense_date, payment_method)
 VALUES (?, ?, ?, ?, ?)
 """, [description, amount, category_id, expense_date, payment_method])

 expense_id = result.last_insert_id

 # 2. Check budget in AQL
 budget_check = client.query("""
 LET month_start = DATE_NEW(DATE_YEAR(@date), DATE_MONTH(@date), 1)
 FOR b IN budgets
 FILTER b.category_id == @cat_id && b.period == 'monthly'
 LET spent = SUM(e.amount FOR e IN expenses
 FILTER e.category_id == b.category_id && e.expense_date >= month_start)
 RETURN {budget: b.amount, spent: spent || 0}
 """, {
 'date': expense_date,
 'cat_id': category_id
 })

 warning = None
 if budget_check and budget_check[0]['spent'] > budget_check[0]['budget']:
 warning = f"Budget exceeded! Spent: {budget_check[0]['spent']}, Budget: {budget_check[0]['budget']}"

 tx.commit()
 return {"success": True, "expense_id": expense_id, "warning": warning}

 except Exception as e:
 tx.rollback()
 return {"success": False, "error": str(e)}

```

**Recurring Expenses Generation**

```

def generate_recurring_expenses():
 """Generate expenses from recurring templates"""
 tx = db.begin_transaction()
 generated = []

 try:
 # Find due recurring expenses
 recurring = tx.query("""
 SELECT * FROM recurring_expenses
 WHERE (last_generated IS NULL OR last_generated < CURDATE())
 AND (end_date IS NULL OR end_date >= CURDATE())
 """)

 for rec in recurring:
 # Calculate next date
 next_date = calculate_next_date(rec['frequency'], rec['last_generated'] or rec['start_date'])

 if next_date <= datetime.now().date():
 # Generate expense
 tx.execute("""
 INSERT INTO expenses
 (description, amount, category_id, expense_date, payment_method)
 VALUES (?, ?, ?, ?, 'transfer')
 """, [rec['description'], rec['amount'], rec['category_id'], next_date])

 # Update last_generated
 tx.execute("""
 UPDATE recurring_expenses
 SET last_generated = ?
 WHERE id = ?
 """, [next_date, rec['id']])

 generated.append(rec['description'])

 tx.commit()
 return {"success": True, "generated": generated}

 except Exception as e:

```

```
tx.rollback()

return {"success": False, "error": str(e)}
```

## Analytics: Monthly Trend

```
SELECT
 DATE_FORMAT(expense_date, '%Y-%m') AS month,
 COUNT(*) AS expense_count,
 SUM(amount) AS total_spent,
 AVG(amount) AS avg_expense
FROM expenses
WHERE expense_date >= DATE_SUB(CURDATE(), INTERVAL 12 MONTH)
GROUP BY month
ORDER BY month;
```

### Output:

```
+-----+-----+-----+-----+
| month | expense_count | total_spent | avg_expense |
+-----+-----+-----+-----+
| 2024-01 | 45 | €1,234 | €27 |
| 2024-02 | 52 | €1,456 | €28 |
| 2024-03 | 48 | €1,189 | €25 |
| ... | ... | ... | ... |
+-----+-----+-----+-----+
```



## 5.10 Performance Best Practices

### 1. Use Indexes Wisely

```
-- x Slow: No index
FOR expense IN expenses
 FILTER expense.expense_date > '2025-01-01'
 RETURN expense

-- Fast: With index
CREATE INDEX idx_expenses_date ON expenses(expense_date);
FOR expense IN expenses
 FILTER expense.expense_date > '2025-01-01'
 RETURN expense
```

### 2. Avoid Returning All Fields

```
-- x Transfers mehr Daten als nötig
FOR product IN products
 RETURN product

-- Nur benötigte Felder
FOR product IN products
 RETURN {id: product.id, name: product.name, price: product.price}
```

### 3. Use LIMIT für große Result Sets

```
-- x Könnte Millionen Rows returnen
FOR order IN orders
 SORT order.created_at DESC
 RETURN order

-- Pagination
FOR order IN orders
 SORT order.created_at DESC
 LIMIT 0, 50
 RETURN order
```

### 4. Batch Inserts

```
x Slow: Individual inserts
for product in products:
 db.execute("INSERT INTO products (name, price) VALUES (?, ?)",
 [product.name, product.price])

Fast: Batch insert
db.execute("""
 INSERT INTO products (name, price) VALUES
 (?, ?), (?, ?), (?, ?), ...
 """, [p1.name, p1.price, p2.name, p2.price, ...])
```

## 5. Use Transactions für Bulk Operations

```
x Slow: Auto-commit nach jedem Statement
for i in range(1000):
 db.execute("INSERT INTO logs (...) VALUES (...)")

Fast: Eine Transaction
tx = db.begin_transaction()
for i in range(1000):
 tx.execute("INSERT INTO logs (...) VALUES (...)")
tx.commit()
```

## 6. Analyze Query Plans

```
EXPLAIN SELECT * FROM orders o
JOIN customers c ON o.customer_id = c.id
WHERE o.created_at > '2025-01-01';
```

### Output:

```
+-----+-----+-----+-----+-----+
| id | table | type | key | rows |
+-----+-----+-----+-----+-----+
| 1 | orders | range | idx | 1000 |
| 1 | customers | ref | pk | 1 |
+-----+-----+-----+-----+-----+
```

## 5.11 Erweiterte AQL-Optimierungen: Query-Plan und Performance-Tuning

### 5.11.1 Der Query-Optimizer: Kostenbasierte Umordnung

ThemisDB verwendet einen kostenbasierten Query-Optimizer [13], der den effizientesten Ausführungsplan für komplexe Queries automatisch wählt. Dies ist besonders wichtig bei Multi-Model-Queries, die relationale, graph- und vektor-basierte Operationen kombinieren.

## Wie funktioniert der Optimizer?

```
// Pseudo-Code des ThemisDB Query Optimizers
class QueryOptimizer {
 // Kostenmodell für verschiedene Operationen
 map<OperationType, double> cost_estimates = {
 {INDEX_SCAN, 0.1}, // $O(\log n)$ - sehr schnell
 {HASH_JOIN, 1.0}, // $O(n + m)$ - schnell für Equi-Joins
 {NESTED_LOOP_JOIN, 10.0}, // $O(n * m)$ - langsam, aber flexibel
 {FULL_TABLE_SCAN, 100.0}, // $O(n)$ - teuer für große Tabellen
 {SORT, 5.0}, // $O(n \log n)$ - mittel
 {AGGREGATE, 2.0} // $O(n)$ - linear
 };

 ExecutionPlan optimize(Query query) {
 // 1. Erzeuge alle möglichen Ausführungspläne
 vector<ExecutionPlan> candidates = generatePlans(query);

 // 2. Schätze Kosten für jeden Plan
 for (auto& plan : candidates) {
 plan.estimated_cost = estimateCost(plan);
 }

 // 3. Wähle Plan mit niedrigsten Kosten
 return *min_element(candidates.begin(), candidates.end(),
 [](auto& a, auto& b) { return a.estimated_cost < b.estimated_cost; }
);
 }
};
```

## Beispiel: Join-Reihenfolge-Optimierung

-- Diese Query hat mehrere mögliche Ausführungspläne:

```
FOR order IN orders
 FILTER order.status == "pending"
 FOR customer IN customers
 FILTER customer._id == order.customer_id
 FILTER customer.country == "DE"
 FOR product IN products
 FILTER product._id == order.product_id
 FILTER product.category == "electronics"
 RETURN {
 order: order,
 customer: customer.name,
 product: product.name
 }
```

### Plan A: Naive Reihenfolge (schlecht)

1. Scan orders (1M rows) → 1M candidates
2. For each: Lookup customer → 1M lookups
3. Filter country="DE" → 100K candidates
4. For each: Lookup product → 100K lookups
5. Filter category → 10K final results

Total Cost:  $1M + 1M + 100K + 100K = \sim 2.2M$  operations

### Plan B: Optimizer-Reihenfolge (optimal)

1. Index scan: customers WHERE country="DE" → 100K candidates
2. Index scan: products WHERE category="electronics" → 50K candidates
3. Hash join: orders WHERE status="pending" (200K) with customers → 20K matches
4. Hash join: result with products → 10K final results

Total Cost:  $100K + 50K + 200K + 20K = \sim 370K$  operations (6x schneller!)

### Wie wird der optimale Plan gewählt?

Der Optimizer verwendet **Statistiken** über die Daten:

```
-- Statistiken für Optimizer sammeln
ANALYZE TABLE orders;
ANALYZE TABLE customers;
ANALYZE TABLE products;

-- Zeigt:
-- - Anzahl Zeilen pro Tabelle
-- - Kardinalität von Indizes
-- - Häufigkeitsverteilung von Werten
-- - Größe der Tabellen auf Disk
```

### 5.11.2 Index-Only-Scans: Minimale Disk-I/O

Ein **Index-Only-Scan** ist möglich, wenn alle benötigten Spalten bereits im Index enthalten sind, ohne dass die eigentliche Tabelle gelesen werden muss [2], [3].

**Beispiel ohne Index-Only-Scan:**

```
CREATE INDEX idx_orders_customer ON orders (customer_id);

-- Diese Query MUSS die orders-Tabelle lesen:
FOR order IN orders
 FILTER order.customer_id == "customer_123"
 RETURN {
 id: order._id,
 total: order.total_amount, -- Nicht im Index!
 date: order.created_at -- Nicht im Index!
 }
```

**Ausführungsplan:**

1. Index Scan: idx\_orders\_customer → Findet 50 order\_ids
2. Table Lookup: orders → Liest 50 volle Dokumente (Disk I/O!)

**Optimiert mit Composite Index:**

```
-- Composite Index mit allen benötigten Spalten
CREATE INDEX idx_orders_customer_covering
 ON orders (customer_id, total_amount, created_at);

-- Jetzt: Index-Only-Scan möglich!
FOR order IN orders
 FILTER order.customer_id == "customer_123"
 RETURN {
 id: order._id,
 total: order.total_amount, -- Im Index!
 date: order.created_at -- Im Index!
 }
```

### Ausführungsplan:

1. Index-Only Scan: idx\_orders\_customer\_covering → Liest nur Index
2. Keine Table Lookups nötig → 10x schneller!

### Performance-Vergleich:

Ansatz	Disk I/O	Latenz	Durchsatz
Ohne Index	50 random reads	50ms	1000 queries/sec
Mit Index (nicht covering)	50 index reads + 50 table reads	25ms	2000 queries/sec
Mit Covering Index	50 index reads	5ms	10000 queries/sec

### 5.11.3 Partielle Indizes: Selektive Indexierung

Wenn nur ein Teil der Daten häufig abgefragt wird, kann ein **partieller Index** Speicherplatz und Schreibperformance sparen:

```
-- Indexiere nur aktive Orders
CREATE INDEX idx_active_orders
 ON orders (customer_id, created_at)
 WHERE status IN ['pending', 'processing'];

-- Dieser Index ist viel kleiner als ein voller Index,
-- da er nur ~10% der orders enthält (die aktiven)
```

### Wann wird der partielle Index verwendet?

```
-- Optimizer nutzt partiellen Index:
FOR order IN orders
 FILTER order.status == "pending"
 FILTER order.customer_id == "customer_123"
 RETURN order

-- x Optimizer nutzt NICHT den partiellen Index:
FOR order IN orders
 FILTER order.status == "completed" -- Nicht im Index!
 FILTER order.customer_id == "customer_123"
 RETURN order
```

## 5.11.4 Materialized Views für komplexe Aggregationen

Für häufig ausgeführte, teure Aggregationen bietet ThemisDB **Materialized Views**:

```
-- Teure Aggregation (läuft jedes Mal 5 Sekunden):
FOR order IN orders
 FILTER order.created_at >= DATE_SUBTRACT(DATE_NOW(), 30, 'day')
 COLLECT
 customer = order.customer_id,
 date = DATE_TRUNC(order.created_at, 'day')
 AGGREGATE
 revenue = SUM(order.total_amount),
 order_count = COUNT(1)
 RETURN {customer, date, revenue, order_count}
```



## Lösung: Materialized View

```
-- Erstelle Materialized View (einmalig):
CREATE MATERIALIZED VIEW daily_revenue AS
 FOR order IN orders
 COLLECT
 customer = order.customer_id,
 date = DATE_TRUNC(order.created_at, 'day')
 AGGREGATE
 revenue = SUM(order.total_amount),
 order_count = COUNT(1)
 RETURN {customer, date, revenue, order_count}
 OPTIONS {refresh: 'incremental', interval: '5 minutes'}

-- Abfrage der View (instant!):
FOR row IN daily_revenue
 FILTER row.date >= DATE_SUBTRACT(DATE_NOW(), 30, 'day')
 RETURN row
```

### Refresh-Strategien:

- **refresh: 'immediate'** - Nach jeder Änderung aktualisieren (langsam)
- **refresh: 'incremental'** - Nur geänderte Daten neu berechnen (empfohlen)
- **refresh: 'full'** - Komplette Neuberechnung (für kleine Views)

### 5.11.5 Query-Hints: Manuelle Optimizer-Steuerung

In seltenen Fällen weiß der Entwickler mehr als der Optimizer. Dann können **Query-Hints** helfen:

```
-- Force Index Scan (statt Full Table Scan):
FOR order IN orders
 OPTIONS {indexHint: 'idx_orders_customer'}
 FILTER order.customer_id == "customer_123"
 RETURN order

-- Force Hash Join (statt Nested Loop):
FOR order IN orders
 FOR customer IN customers
 OPTIONS {joinStrategy: 'hash'}
 FILTER customer._id == order.customer_id
 RETURN {order, customer}

-- Disable Index für Debugging:
FOR order IN orders
 OPTIONS {forceTableScan: true}
 FILTER order.customer_id == "customer_123"
 RETURN order
```

### Wann Query-Hints verwenden?

**Sinnvoll:** - Temporär zum Debugging - Wenn Statistiken veraltet sind - Für extrem spezifische Workloads

× **Vermeiden:** - Als Standard (Optimizer ist meist besser) - Wenn Datenvolumen sich ändert - In produktivem Code ohne Dokumentation

### 5.11.6 Batch-Operations für hohen Durchsatz

Für Massen-Inserts oder Updates bietet ThemisDB Batch-Operations:

```
-- x Langsam: 10.000 einzelne Inserts
FOR i IN 1..10000
 INSERT {
 name: CONCAT("Product ", i),
 price: RAND() * 1000,
 category: ["Electronics", "Clothing", "Food"][FLOOR(RAND() * 3)]
 } INTO products

-- Schnell: Batch-Insert
LET batch = (
 FOR i IN 1..10000
 RETURN {
 name: CONCAT("Product ", i),
 price: RAND() * 1000,
 category: ["Electronics", "Clothing", "Food"][FLOOR(RAND() * 3)]
 }
)
INSERT batch INTO products

-- Performance: 100x schneller!
-- Einzeln: ~50 inserts/sec (10.000 inserts = 200 Sekunden)
-- Batch: ~50.000 inserts/sec (10.000 inserts = 0.2 Sekunden)
```

### Warum ist Batch schneller?

1. **Weniger Transaktionen:** 1 statt 10.000 Transaktions-Overheads
2. **Batch-Writes:** RocksDB kann Writes zusammenfassen
3. **Weniger Netzwerk-RTTs:** 1 Request statt 10.000

## 5.11.7 Performance-Monitoring mit EXPLAIN

Verwenden Sie immer `EXPLAIN`, um langsame Queries zu debuggen:

```
-- Detaillierter Execution Plan:
EXPLAIN
 FOR order IN orders
 FILTER order.status == "pending"
 FOR customer IN customers
 FILTER customer._id == order.customer_id
 FILTER customer.country == "DE"
 RETURN {order, customer}
```

**Output:**

```
{
 "plan": {
 "nodes": [
 {
 "type": "IndexNode",
 "index": "idx_orders_status",
 "condition": "status == 'pending'",
 "estimated_items": 200000,
 "estimated_cost": 1000
 },
 {
 "type": "IndexNode",
 "index": "idx_customers_pk",
 "condition": "customer._id == order.customer_id",
 "estimated_items": 1,
 "estimated_cost": 10
 },
 {
 "type": "FilterNode",
 "condition": "customer.country == 'DE'",
 "estimated_items": 20000,
 "estimated_cost": 200
 }
],
 "total_estimated_cost": 1210,
 "total_estimated_items": 20000
 },
 "stats": {
 "execution_time": "125ms",
 "items_scanned": 200000,
 "items_returned": 20000,
 "index_hits": 200001,
 "index_misses": 0
 }
}
```

**Key Metrics:** - **estimated\_cost**: Optimizer's Kostenschätzung - **estimated\_items**: Erwartete Anzahl Ergebnisse - **execution\_time**: Tatsächliche Laufzeit - **index\_hits/misses**: Index-Effizienz

---

## 5.12 Zusammenfassung

In diesem Kapitel haben Sie gelernt:

**Relationales Modell:** Tabellen, Schemas, Constraints

**AQL DDL:** CREATE TABLE, Datentypen, Constraints

**AQL DML:** INSERT, UPDATE, DELETE, UPSERT

**Queries:** SELECT, WHERE, JOIN, Subqueries, Aggregation

**Transaktionen:** ACID, Isolation, Commit/Rollback

**Normalisierung:** 1NF, 2NF, 3NF, Denormalisierung

**Indexes:** B-Tree, Unique, Composite, Performance

**Erweiterte Optimierungen:** Query Optimizer, Index-Only-Scans, Materialized Views

**Praxis:** Inventory System & Expense Tracker

### Key Takeaways

1. **Relational ist perfekt für strukturierte Business-Daten**
2. **Constraints garantieren Datenintegrität**
3. **Normalisierung verhindert Redundanz**
4. **Denormalisierung kann Performance verbessern**
5. **Indexes sind essentiell für Query-Performance**
6. **Transaktionen garantieren Konsistenz**
7. **Der Query-Optimizer wählt automatisch den besten Ausführungsplan**
8. **Covering Indexes ermöglichen Index-Only-Scans für maximale Performance**

### Nächster Schritt

Sie verstehen jetzt relationale Daten in ThemisDB. Im nächsten Kapitel lernen Sie **Graph-Datenbanken** kennen - perfekt für Netzwerk-Daten und Beziehungen.

[Kapitel 6: Graph-Datenbanken](#) →

---

## Weiterführende Ressourcen

- **AQL Reference:** [../de/aql/README.md](#)
  - **Schema Design:** [../de/guides/guides\\_schema\\_design.md](#)
  - **Transaction Guide:** [../de/features/features\\_transactions.md](#)
  - **Inventory System Code:** [../examples/04\\_inventory\\_system/](#)
  - **Expense Tracker Code:** [../examples/12\\_expense\\_tracker/](#)
- 

Kapitel 5 von 30 | Teil II: Datenmodelle | ~12.200 Wörter

---

## Kapitel 6: Kapitel 6 - Graph

---

*"The world is a graph, not a table." — Graph-Datenbank-Community*

### 6.1 Einführung: Die Welt der Verbindungen

Die Welt besteht aus Beziehungen. Menschen kennen andere Menschen. Websites verlinken auf andere Websites. Produkte werden zusammen gekauft. Straßen verbinden Städte. Diese natürlich vernetzten Strukturen lassen sich am besten als **Graphen** darstellen.

#### Das Problem mit Relationalen Datenbanken

Versuchen Sie, folgende Frage mit SQL zu beantworten: *"Finde alle Freunde meiner Freunde, die in derselben Stadt wohnen und mindestens 3 gemeinsame Interessen haben."*

Mit relationalen Tabellen benötigen Sie: - Multiple Self-Joins über die `friendships`-Tabelle - Subqueries für gemeinsame Interessen - Performance-Probleme bei mehr als 3-4 Hop-Levels - Komplexe Query-Logik, die schwer zu warten ist

```
-- Freunde von Freunden (nur 2 Hops!)
SELECT DISTINCT u3.*
FROM users u1
JOIN friendships f1 ON u1.id = f1.user_id
JOIN users u2 ON f1.friend_id = u2.id
JOIN friendships f2 ON u2.id = f2.user_id
JOIN users u3 ON f2.friend_id = u3.id
WHERE u1.id = '...'
 AND u3.city = u1.city
 AND ... -- gemeinsame Interessen?
```

Diese Query wird schnell unleserlich und langsam.

## Die Graph-Lösung

In ThemisDB wird dieselbe Frage intuitiv und performant:

```
result = db.graph_query("""
 FOR user IN users
 FILTER user.id == @my_id
 FOR friend IN 1..2 OUTBOUND user friendships
 FILTER friend.city == user.city
 LET common_interests = LENGTH(
 INTERSECTION(user.interests, friend.interests)
)
 FILTER common_interests >= 3
 RETURN friend
""", bind_vars={"my_id": my_id})
```

Die Graph-Query ist: - Lesbarer und deklarativer - Beliebige viele Hops möglich ( `1..10` , `1..ANY` ) -  
 Performance skaliert mit Graph-Struktur, nicht mit Datenmenge - Native Graph-Algorithmen  
 verfügbar

## 6.2 Property Graph Modell

ThemisDB verwendet das **Property Graph**-Modell, den De-facto-Standard für Graph-Datenbanken.



## Komponenten

**1. Knoten (Vertices/Nodes)** - Repräsentieren Entitäten (Personen, Orte, Produkte) - Haben einen eindeutigen Identifier - Können beliebige Properties haben - Können Labels/Types haben

```
user_node = {
 "id": "user_001",
 "type": "User",
 "name": "Alice",
 "age": 28,
 "city": "Berlin",
 "interests": ["Python", "ML", "Hiking"]
}
```

Abb. 06.1: Graph-Traversierung-Algorithmus

**2. Kanten (Edges/Relationships)** - Verbinden zwei Knoten (gerichtet oder ungerichtet) - Haben einen Typ (z.B. "FRIEND", "LIKES", "WORKS\_AT") - Können Properties haben (z.B. "since", "strength") - Erlauben Multi-Edges (mehrere Kanten zwischen denselben Knoten)

```
friendship_edge = {
 "from": "user_001",
 "to": "user_002",
 "type": "FRIEND",
 "since": "2023-05-15",
 "strength": 0.85, # 0-1 basierend auf Interaktionen
 "mutual_friends": 12
}
```

## 3. Graph-Collections

ThemisDB organisiert Graphs in Collections: - **Vertex Collections:** Speichern Knoten (z.B. `users`, `posts`) - **Edge Collections:** Speichern Kanten (z.B. `friendships`, `likes`)

```
Graph erstellen
db.create_vertex_collection("users")
db.create_edge_collection("friendships")

Graph-Definition
graph_def = {
 "name": "social_network",
 "edge_definitions": [{
 "collection": "friendships",
 "from": ["users"],
 "to": ["users"]
 }]
}
db.create_graph(graph_def)
```

## Gerichtete vs. Ungerichtete Kanten

### Gerichtet (Directed):

```
Alice folgt Bob, aber Bob folgt Alice nicht
{"from": "alice", "to": "bob", "type": "FOLLOWS"}
```

Beispiele: Twitter-Follows, Hyperlinks, Reporting-Struktur

### Ungerichtet (Undirected):

```
Freundschaft ist bidirektional
{"from": "alice", "to": "bob", "type": "FRIEND"}
{"from": "bob", "to": "alice", "type": "FRIEND"} # Beide Richtungen
```

Beispiele: Facebook-Freunde, Co-Autoren, Straßen

ThemisDB speichert alle Kanten gerichtet, aber Graph-Queries können beide Richtungen traversieren: -

**OUTBOUND** - Von A nach B - **INBOUND** - Von B nach A - **ANY** - Beide Richtungen (für ungerichtete Graphs)

Abb. 06.2: Shortest-Path-Berechnung

## 6.3 Graph-Traversierung

### Traversierungs-Arten

**1. Depth-First Search (DFS)** - Geht zuerst in die Tiefe - Verwendet Stack - Findet schnell tiefe Pfade

```
DFS: Alle erreichbaren Knoten
FOR v, e, p IN 1..10 OUTBOUND @start_vertex friendships
 OPTIONS {bfs: false} # DFS (default)
 RETURN {vertex: v, path: p}
```

**2. Breadth-First Search (BFS)** - Geht zuerst in die Breite - Verwendet Queue - Findet kürzeste Pfade

```
BFS: Kürzester Pfad
FOR v, e, p IN 1..10 OUTBOUND @start_vertex friendships
 OPTIONS {bfs: true} # BFS
 RETURN {vertex: v, path: p}
```

**3. Bounded Traversal** - Limitiert Anzahl der Hops - **1..1** - Nur direkte Nachbarn - **1..2** - Bis zu 2 Hops - **2..4** - Zwischen 2 und 4 Hops - **1..ANY** - Alle erreichbaren Knoten

```
Freunde von Freunden (exakt 2 Hops)
FOR v IN 2..2 OUTBOUND @my_id friendships
 RETURN v
```

Abb. 06.3: Community-Detection-Workflow

Abb. 06.4: Pagerank-Algorithmus-Visualisierung

### Pattern Matching

Graph-Queries in ThemisDB unterstützen komplexe Patterns:

```
Triangle Pattern: A kennt B, B kennt C, C kennt A
FOR a IN users
 FOR b IN OUTBOUND a friendships
 FOR c IN OUTBOUND b friendships
 FILTER c._id == a._id
 RETURN {a: a.name, b: b.name, c: c.name}
```

```
Diamond Pattern: Mehrere Pfade zwischen zwei Knoten
FOR start IN users FILTER start.id == @user_id
 FOR end IN OUTBOUND start friendships
 LET paths = (
 FOR v, e, p IN 2..2 OUTBOUND start friendships
 FILTER v._id == end._id
 RETURN p
)
 FILTER LENGTH(paths) > 1 # Mehrere Pfade
 RETURN {start: start.name, end: end.name, paths: paths}
```

## 6.4 Graph-Algorithmen

ThemisDB bietet native Implementierungen gängiger Graph-Algorithmen:

### Shortest Path (Dijkstra)

Findet den kürzesten Pfad zwischen zwei Knoten unter Berücksichtigung von Gewichten:

```
from themis_client import shortest_path

path = shortest_path(
 graph="social_network",
 start_vertex="users/alice",
 target_vertex="users/bob",
 direction="outbound",
 weight_attribute="strength" # Optional: Kantengewicht
)

print(f"Pfad: {' -> '.join([v['name'] for v in path['vertices']])}")
print(f"Distanz: {path['distance']}")
```

**Use Cases:** - Routing und Navigation - Social Distance berechnen - Kostenoptimale Pfade finden

## All Shortest Paths

Findet alle kürzesten Pfade (falls mehrere existieren):

```
paths = db.all_shortest_paths(
 graph="social_network",
 start_vertex="users/alice",
 target_vertex="users/bob"
)

for idx, path in enumerate(paths):
 print(f"Pfad {idx+1}: {' -> '.join([v['name'] for v in path['vertices']])}")
```

## K Shortest Paths

Findet die k kürzesten Pfade:

```
paths = db.k_shortest_paths(
 graph="social_network",
 start_vertex="users/alice",
 target_vertex="users/bob",
 k=3 # Top 3 kürzeste Pfade
)
```

## Connected Components

Findet zusammenhängende Teilgraphen:

```
components = db.connected_components(
 graph="social_network",
 direction="any" # Ungerichtet behandeln
)

Gruppiere Knoten nach Component
for component_id, vertices in components.items():
 print(f"Community {component_id}: {len(vertices)} Mitglieder")
```

**Use Cases:** - Community-Erkennung - Isolierte Gruppen finden - Netzwerk-Fragmentierung analysieren

## PageRank

Berechnet die Wichtigkeit von Knoten basierend auf eingehenden Kanten:

```
pagerank_scores = db.pagerank(
 graph="social_network",
 iterations=20,
 damping_factor=0.85
)

Sortiere nach Score
top_users = sorted(
 pagerank_scores.items(),
 key=lambda x: x[1],
 reverse=True
)[:10]

for user_id, score in top_users:
 user = db.get("users", user_id)
 print(f"{user['name']}: {score:.4f}")
```

**Use Cases:** - Influencer-Identifikation - Content-Ranking - Reputations-Systeme

## Betweenness Centrality

Misst, wie oft ein Knoten auf kürzesten Pfaden liegt:

```
centrality = db.betweenness_centrality(
 graph="social_network"
)

Knoten mit hoher Betweenness = Brücken zwischen Communities
bridges = [k for k, v in centrality.items() if v > 0.5]
```

**Use Cases:** - Netzwerk-Bottlenecks identifizieren - Wichtige Vermittler finden - Kritische Infrastruktur-Knoten

## 6.4A Temporale Graph-Queries: Zeitreisen im Wissensgraph

Eine der mächtigsten Features von ThemisDB ist die Fähigkeit, **zeitabhängige Graph-Traversals** durchzuführen. Dies ist besonders wichtig für Anwendungen, die historische Zustände nachvollziehen müssen – etwa für Compliance, Audit, oder rechtssichere Dokumentation.

### Das Problem: Wie sah der Graph *damals* aus?

Stellen Sie sich folgende Szenarien vor:

#### Szenario 1 - Compliance-Anfrage:

*"Welche Zugriffsrechte hatte Benutzer X am 15. März 2024 um 14:30 Uhr?"*

#### Szenario 2 - Verwaltungsakt:

*"Auf welcher Datengrundlage basierte der Bescheid vom 10. Januar 2024? Welche Dokumente waren zu diesem Zeitpunkt verknüpft?"*

#### Szenario 3 - Betrugserkennung:

*"Zu welchen verdächtigen Konten hatte Account Y Verbindungen in der Woche vor der Sperrung?"*

In traditionellen Graph-Datenbanken müssten Sie entweder: 1. **Alle Änderungen manuell versionieren** (aufwändig, fehleranfällig) 2. **Snapshot-Backups** erstellen (speicherintensiv, grobe Granularität) 3. **Audit-Logs parsen** (langsam, komplex)

### Die Lösung: Temporale Kanten mit `valid_from/valid_to`

ThemisDB erlaubt es, Kanten mit Gültigkeitszeiträumen zu versehen:



```
Kante mit temporalen Feldern erstellen
db.create_edge(
 from_node="users/alice",
 to_node="departments/engineering",
 edge_type="WORKS_IN",
 properties={
 "role": "Senior Engineer",
 "valid_from": 1640995200000, # 2022-01-01 00:00:00 UTC (ms)
 "valid_to": 1704067200000 # 2024-01-01 00:00:00 UTC (ms)
 }
)

Neue Kante für neue Abteilung
db.create_edge(
 from_node="users/alice",
 to_node="departments/research",
 edge_type="WORKS_IN",
 properties={
 "role": "Lead Researcher",
 "valid_from": 1704067200000, # 2024-01-01 00:00:00 UTC (ms)
 "valid_to": None # Aktuell gültig (kein Enddatum)
 }
)
```

### Semantik der temporalen Felder:

- `valid_from = null`: Kante gilt seit Anbeginn der Zeit
- `valid_to = null`: Kante gilt unbegrenzt in die Zukunft
- `valid_from = T1, valid_to = T2`: Kante galt im Intervall [T1, T2]
- Beide `null`: Kante ist zeitlos (eternal)

### Point-in-Time Queries: Graph-Zustand zu einem Zeitpunkt

API: `bfsAtTime()` - Breadth-First Search mit Zeitfilter

```
// C++ API Signatur
std::pair<Status, std::vector<std::string>> bfsAtTime(
 std::string_view startPk, // Startknoten
 int64_t timestamp_ms, // Zeitpunkt (ms seit Epoch)
 int maxDepth = 3 // Maximale Traversierungstiefe
) const;
```

### Wie es funktioniert:

Die `bfsAtTime()`-Funktion durchläuft den Graphen wie eine normale BFS, aber mit einem entscheidenden Unterschied: **Jede Kante wird vor der Traversierung auf Gültigkeit geprüft.**

Die Implementation prüft für jede Kante, ob sie zum Query-Zeitpunkt gültig war, indem sie `valid_from` und `valid_to` vergleicht. Nur Kanten, die im Zeitfenster lagen, werden in der Traversierung berücksichtigt. Dies erlaubt es, historische Graph-Zustände präzise zu rekonstruieren.

**Vollständiger Code:** `src/storage/graph/temporal_traversal.cpp` (~150 Zeilen)

### Kernlogik der temporalen Validierung:

```

// Temporale Gültigkeitsprüfung für Kanten
bool isValidAtTime(Edge edge, int64_t query_time) {
 // Kante noch nicht gültig?
 if (edge.valid_from.has_value() && query_time < edge.valid_from) {
 return false;
 }
 // Kante nicht mehr gültig?
 if (edge.valid_to.has_value() && query_time > edge.valid_to) {
 return false;
 }
 return true; // Kante war zum Query-Zeitpunkt gültig
}

std::vector<std::string> bfsAtTime(string start, int64_t timestamp, int maxDepth) {
 queue<Node> frontier;
 set<string> visited;

 frontier.push({start, 0});
 visited.insert(start);

 while (!frontier.empty()) {
 auto [current_node, depth] = frontier.front();
 frontier.pop();

 if (depth > maxDepth) continue;

 for (auto& edge : getOutgoingEdges(current_node)) {
 // KRITISCH: Temporaler Filter vor Traversierung!
 if (!isValidAtTime(edge, timestamp)) continue;

 if (visited.count(edge.to) == 0) {
 visited.insert(edge.to);
 frontier.push({edge.to, depth + 1});
 }
 }
 }
 return visited; // Alle erreichbaren Knoten zum Zeitpunkt
}

```

**Zusätzliche Features in vollständiger Implementation:** - Pfad-Tracking für Nachvollziehbarkeit - Cycle-Detection für sichere Traversierung - Optimierte Edge-Filterung mit Bloom-Filtern - Parallele Traversierung für große Graphen

**Der entscheidende Unterschied:** Die Zeile `if (!isValidAtTime(edge, timestamp)) continue;` filtert historisch ungültige Kanten **vor** der Traversierung. Dadurch sieht die BFS exakt den Graph-Zustand, wie er zum Query-Zeitpunkt existierte.

### Praktisches Beispiel:

```
Frage: Welche Abteilungen konnte Alice am 1. Juli 2023 erreichen?
timestamp = datetime(2023, 7, 1).timestamp() * 1000 # In Millisekunden

result = db.graph.bfsAtTime(
 start="users/alice",
 timestamp_ms=int(timestamp),
 max_depth=3
)

print(f"Erreichbare Knoten am 1. Juli 2023: {result}")
Output: ['users/alice', 'departments/engineering', 'projects/project-x']
→ 'departments/research' fehlt, weil Alice erst 2024 dorthin wechselte!
```

### Shortest Path mit Zeitfilter: `dijkstraAtTime()`

Für gewichtete Graphen unterstützt ThemisDB auch temporale Kürzeste-Pfad-Suche:

```
// C++ API Signatur
std::pair<Status, PathResult> dijkstraAtTime(
 std::string_view startPk,
 std::string_view targetPk,
 int64_t timestamp_ms
) const;

// PathResult enthält:
struct PathResult {
 std::vector<std::string> path; // Knoten vom Start zum Ziel
 double totalCost; // Gesamtkosten des Pfades
};
```

### Use Case: Organisationshierarchie zum Zeitpunkt eines Bescheids

```
Frage: Wer war am 10. Januar 2024 der kürzeste Eskalationspfad
von einem Sachbearbeiter zu einem Abteilungsleiter?

timestamp = datetime(2024, 1, 10, 14, 30).timestamp() * 1000

path_result = db.graph.dijkstraAtTime(
 start="users/sachbearbeiter-123",
 target="users/abteilungsleiter-456",
 timestamp_ms=int(timestamp)
)

if path_result.status.ok:
 print(f"Eskalationspfad am 10.01.2024:")
 for i, node in enumerate(path_result.path):
 print(f" {i}. {node}")
 print(f"Hierarchie-Distanz: {path_result.totalCost}")
```

#### Ausgabe:

```
Eskalationspfad am 10.01.2024:
 0. users/sachbearbeiter-123
 1. users/teamleiter-789
 2. users/abteilungsleiter-456
Hierarchie-Distanz: 2.0
```

#### Warum ist das wichtig?

Wenn später ein Bescheid angefochten wird und die Frage aufkommt: "War die Eskalation regelkonform?", können Sie **exakt nachweisen**, welche Hierarchie zum Zeitpunkt der Entscheidung galt – auch wenn die Organisation sich seitdem umstrukturiert hat.

### Time-Range Queries: Kanten in einem Zeitfenster

Manchmal interessiert nicht ein einzelner Zeitpunkt, sondern ein **Zeitraum**:

*"Welche Zugriffsrechte überlappten mit dem Quartal Q4 2024?"*

```
// C++ API für Time-Range Queries
struct TimeRangeFilter {
 int64_t start_ms; // Fenster-Start
 int64_t end_ms; // Fenster-Ende

 // Prüft ob Kante mit Zeitfenster überlappt
 bool hasOverlap(optional<int64_t> edge_valid_from,
 optional<int64_t> edge_valid_to) const;

 // Prüft ob Kante vollständig im Fenster enthalten ist
 bool fullyContains(optional<int64_t> edge_valid_from,
 optional<int64_t> edge_valid_to) const;
};

std::pair<Status, std::vector<EdgeInfo>> getEdgesInTimeRange(
 int64_t range_start_ms,
 int64_t range_end_ms,
 bool require_full_containment = false
) const;
```

**Beispiel: Audit-Abfrage für Q4 2024**

```
Zeitfenster definieren

q4_start = datetime(2024, 10, 1).timestamp() * 1000
q4_end = datetime(2024, 12, 31, 23, 59, 59).timestamp() * 1000

Alle Kanten finden, die mit Q4 überlappen

edges = db.graph.getEdgesInTimeRange(
 range_start_ms=int(q4_start),
 range_end_ms=int(q4_end),
 require_full_containment=False # Überlappung reicht
)

print(f"Gefunden: {len(edges)} Kanten mit Überlappung zu Q4 2024")

for edge in edges:
 print(f" {edge.from_pk} → {edge.to_pk}")
 print(f" Gültig: {edge.valid_from} bis {edge.valid_to}")
```

## Überlappungs-Logik visualisiert:

Query-Zeitfenster:	[—————Q4 2024—————]	
	Oct 1	Dec 31
Kante A:	[—————]	✓ Überlappt (vor Q4, endet in Q4)
Kante B:	[—————]	✓ Überlappt (komplett in Q4)
Kante C:	[—————]	✓ Überlappt (startet in Q4, endet nach Q4)
Kante D:	[———]	x Keine Überlappung (endet vor Q4)
Kante E:	[—]	x Keine Überlappung (startet nach Q4)

## Revisionssicherheit: Verwaltungsakte dokumentieren

## Das Szenario:

Eine Behörde erstellt einen Bescheid am **15. März 2024**. Dieser Bescheid verweist auf: - 3 Gutachten - 2 Gesetze

- 4 frühere Verwaltungsakte

Sechs Monate später wird der Bescheid angefochten. Die Frage: *"Auf welcher Datengrundlage basierte die Entscheidung?"*

## Die Lösung mit temporalen Graphen:

```
1. Beim Erstellen des Bescheids: Graph-Snapshot implizit gespeichert
bescheid_timestamp = datetime(2024, 3, 15, 10, 30).timestamp() * 1000

2. Sechs Monate später: Rekonstruktion der damaligen Datenlage
verwandte_dokumente = db.graph.bfsAtTime(
 start=f"bescheide/{bescheid_id}",
 timestamp_ms=bescheid_timestamp,
 max_depth=2 # Direkte + indirekte Referenzen
)

3. Für jedes Dokument: Exakte Version zum Zeitpunkt abrufen
for doc_id in verwandte_dokumente:
 doc_version = db.get_document_at_time(doc_id, bescheid_timestamp)
 print(f"Dokument {doc_id} (Stand {bescheid_timestamp}):")
 print(f" Titel: {doc_version['title']}")
 print(f" Version: {doc_version['version']}")
 print(f" Checksum: {doc_version['checksum']}")
```

**Resultat:** Sie können **beweisen**, dass der Bescheid auf den zum Entscheidungszeitpunkt gültigen Dokumenten basierte – selbst wenn diese Dokumente seitdem aktualisiert wurden.

## Performance-Überlegungen

### Speicher-Overhead:

Temporale Kanten benötigen 16 zusätzliche Bytes pro Kante ( $2 \times \text{int64}$  für Timestamps):

```
Normale Kante: ~80 Bytes
Temporale Kante: ~96 Bytes
→ Overhead: 20%
```

Bei 10 Millionen Kanten: ~160 MB zusätzlicher Speicher. **Akzeptabel** für die gewonnene Funktionalität.

### Query-Performance:

Die temporale Filterung ist sehr effizient, da der Check inline während der Traversierung passiert:



```
// Pro Kante: 2 Integer-Vergleiche (~2 CPU-Zyklen)
if (edge.valid_from && timestamp < edge.valid_from) return false;
if (edge.valid_to && timestamp > edge.valid_to) return false;
```

**Benchmark:** `bfsAtTime()` ist nur ~5-10% langsamer als normale BFS, da der Overhead durch CPU-Cache-Hits minimiert wird.

## Best Practices

### 1. Timestamps immer in Millisekunden (Unix Epoch)

```
Richtig: Millisekunden seit 1970-01-01
timestamp_ms = int(datetime.now().timestamp() * 1000)

x Falsch: Sekunden (zu grobe Granularität)
timestamp_s = int(datetime.now().timestamp())
```

### 2. `valid_to = null` für aktuell gültige Beziehungen

```
Richtig: Kein Enddatum = unbegrenzt gültig
edge = {
 "valid_from": now_ms,
 "valid_to": None
}

x Falsch: Festes Enddatum in ferner Zukunft
edge = {
 "valid_from": now_ms,
 "valid_to": 9999999999999 # Unflexibel!
}
```

### 3. Indizes auf temporalen Feldern

```
Index für effiziente temporale Queries
db.create_index(
 collection="edges",
 fields=["valid_from", "valid_to"],
 index_type="range"
)
```

## 6.5 Praxisbeispiel 1: Social Network

Jetzt setzen wir die Theorie in die Praxis um mit einem vollständigen Social Network.

### Das Projekt

Das Social Network-Example ( [examples/06\\_graph\\_social\\_network](#) ) implementiert: -  
Benutzerprofile mit Interessen - Bidirektionale Freundschaften - Graph-Traversierung (Freunde von Freunden) - Kürzeste Pfade zwischen Usern - Community-Erkennung - Freundschafts-Empfehlungen -  
Interaktive Visualisierung mit NetworkX

**Datenmodell**

```
models.py
from dataclasses import dataclass
from typing import List, Optional
from datetime import datetime

@dataclass
class User:
 """Ein Benutzer im sozialen Netzwerk."""
 id: str
 name: str
 bio: Optional[str] = None
 interests: List[str] = None
 location: Optional[str] = None
 joined: datetime = None

 def to_dict(self):
 return {
 "id": self.id,
 "name": self.name,
 "bio": self.bio,
 "interests": self.interests or [],
 "location": self.location,
 "joined": self.joined.isoformat() if self.joined else None
 }

@dataclass
class Friendship:
 """Eine Freundschaft zwischen zwei Benutzern."""
 from_user: str
 to_user: str
 since: datetime
 strength: float = 1.0 # 0-1, basierend auf Interaktionen

 def to_dict(self):
 return {
 "from": f"users/{self.from_user}",
 "to": f"users/{self.to_user}",
 "since": self.since.isoformat(),
```

```
 "strength": self.strength
 }
```

## Graph Setup

Das Social Network wird mit Collections für Knoten (Vertices) und Kanten (Edges) initialisiert. Die Graph-Definition verknüpft beide Collections zu einem logischen Graphen, über den Traversierungen möglich sind.

**Vollständiger Code:** [examples/06\\_graph\\_social\\_network/themis\\_client.py](#) (~250 Zeilen)

```

class ThemisGraphClient:
 def __init__(self, host="localhost", port=8529):
 self.client = ThemisDB(host=host, port=port)
 self.db = self.client.db("social_network")
 self._setup_graph()

 def _setup_graph(self):
 """Erstellt Collections und Graph-Definition."""
 # Vertex Collection für User
 if not self.db.has_collection("users"):
 self.db.create_vertex_collection("users")

 # Edge Collection für Freundschaften
 if not self.db.has_collection("friendships"):
 self.db.create_edge_collection("friendships")

 # Graph-Definition verknüpft Collections
 graph_def = {
 "name": "social_graph",
 "edge_definitions": [{
 "collection": "friendships",
 "from": ["users"], # Von users...
 "to": ["users"] # ...zu users (self-referencing)
 }]
 }
 self.db.create_graph(graph_def)

 # Indexes für schnelle Lookups
 self.db.add_index("users", ["name", "location"])
 self.db.add_index("friendships", ["from", "to"])

```

**Kernfunktionen:** - `add_user()` - Fügt neue Benutzer mit Profil und Interessen hinzu -

`add_friendship()` - Erstellt **bidirektionale** Freundschaften (beide Richtungen) - `get_friends()` -

Liefert direkte Freunde eines Benutzers - `find_friends_of_friends()` - 2-Hop-Traversierung für

Empfehlungen - `shortest_path()` - Kürzester Pfad zwischen zwei Usern

**Besonderheit:** Freundschaften werden als **zwei Kanten** gespeichert ( $A \rightarrow B$  und  $B \rightarrow A$ ), um ungerichtete Graphen zu modellieren. Dies vereinfacht Traversierungen mit `OUTBOUND`.

## Friends-of-Friends (FoF)

Ein klassisches Graph-Problem: Finde Freunde meiner Freunde, die noch nicht meine Freunde sind.

```
def get_friend_suggestions(self, user_id: str, limit: int = 10) -> List[dict]:
 """Empfiehl neue Freunde basierend auf gemeinsamen Freunden."""
 query = """
 FOR friend IN OUTBOUND @user_id friendships
 FOR fof IN OUTBOUND friend._id friendships
 FILTER fof._id != @user_id
 FILTER fof._id NOT IN (
 FOR f IN OUTBOUND @user_id friendships
 RETURN f._id
)
 COLLECT fof_user = fof WITH COUNT INTO mutual_count
 SORT mutual_count DESC
 LIMIT @limit
 RETURN {
 user: fof_user,
 mutual_friends: mutual_count
 }
 """
 return self.db.execute_query(query, bind_vars={
 "user_id": f"users/{user_id}",
 "limit": limit
 })
```

**Was passiert hier?** 1. Traversiere zu allen Freunden ( `OUTBOUND @user_id` ) 2. Von jedem Freund, traversiere zu deren Freunden ( `OUTBOUND friend._id` ) 3. Filtere mich selbst heraus ( `FILTER fof._id != @user_id` ) 4. Filtere existierende Freunde heraus (Subquery) 5. Gruppiere nach FoF und zähle gemeinsame Freunde ( `COLLECT ... WITH COUNT` ) 6. Sortiere nach Anzahl gemeinsamer Freunde

## Kürzeste Pfade

Wie ist Alice mit Bob verbunden?

```
def find_connection_path(self, user_id1: str, user_id2: str) -> dict:
 """Findet den kürzesten Pfad zwischen zwei Benutzern."""
 path = self.db.shortest_path(
 graph="social_graph",
 start_vertex=f"users/{user_id1}",
 target_vertex=f"users/{user_id2}",
 direction="any" # Ungerichtet (beide Richtungen)
)

 if path is None:
 return {"connected": False}

 return {
 "connected": True,
 "distance": path["distance"],
 "path": [v["name"] for v in path["vertices"]],
 "degrees_of_separation": len(path["vertices"]) - 1
 }
```

## Community-Erkennung

Welche natürlichen Gruppen gibt es im Netzwerk?



```
def detect_communities(self) -> dict:
 """Findet Communities mittels Connected Components."""
 components = self.db.connected_components(
 graph="social_graph",
 direction="any"
)

 # Statistiken pro Community
 communities = {}
 for component_id, user_ids in components.items():
 users = [self.db.get("users", uid) for uid in user_ids]

 # Gemeinsame Interessen
 all_interests = []
 for user in users:
 all_interests.extend(user.get("interests", []))
 interest_counts = Counter(all_interests)

 communities[component_id] = {
 "size": len(users),
 "members": [u["name"] for u in users],
 "top_interests": interest_counts.most_common(5)
 }

 return communities
```

## Interaktive Visualisierung

Das Example nutzt NetworkX für Visualisierung:

```

import networkx as nx
import matplotlib.pyplot as plt

def visualize_network(self, user_id: Optional[str] = None, max_hops: int = 2):
 """Visualisiert das soziale Netzwerk."""
 G = nx.Graph()

 if user_id:
 # Nur Ego-Netzwerk eines Users
 query = f"""
 FOR v, e IN 1..{max_hops} ANY @user_id friendships
 RETURN {{vertex: v, edge: e}}
 """
 result = self.db.execute_query(query, bind_vars={"user_id": f"users/{user_id}"})
 else:
 # Ganzes Netzwerk
 users = self.db.all("users")
 friendships = self.db.all("friendships")

 for user in users:
 G.add_node(user["_key"], name=user["name"])

 for friendship in friendships:
 from_id = friendship["_from"].split("/")[1]
 to_id = friendship["_to"].split("/")[1]
 G.add_edge(from_id, to_id, weight=friendship.get("strength", 1.0))

 # Layout mit Spring-Algorithmus
 pos = nx.spring_layout(G, k=0.5, iterations=50)

 # Zeichnen
 plt.figure(figsize=(12, 8))
 nx.draw_networkx_nodes(G, pos, node_size=500, node_color='lightblue')
 nx.draw_networkx_edges(G, pos, alpha=0.5)
 nx.draw_networkx_labels(G, pos, labels=nx.get_node_attributes(G, 'name'))

 plt.title("Social Network Graph")
 plt.axis('off')

```

```
plt.tight_layout()
plt.show()
```

**Main Application**

```
main.py
def main():
 client = ThemisGraphClient()

 # Beispiel-Daten
 users = [
 User("alice", "Alice", "Software Engineer", ["Python", "ML", "Hiking"], "Berlin"),
 User("bob", "Bob", "Data Scientist", ["Python", "Statistics", "Music"], "Munich"),
 User("charlie", "Charlie", "DevOps", ["Docker", "Kubernetes", "Hiking"], "Berlin"),
 User("diana", "Diana", "Product Manager", ["Agile", "UX", "Music"], "Hamburg"),
 User("eve", "Eve", "ML Engineer", ["ML", "Python", "Research"], "Berlin"),
]

 for user in users:
 client.add_user(user)

 # Freundschaften
 friendships = [
 ("alice", "bob"),
 ("alice", "charlie"),
 ("bob", "diana"),
 ("charlie", "eve"),
 ("diana", "eve"),
]

 for user1, user2 in friendships:
 client.add_friendship(Friendship(user1, user2, datetime.now(), 0.8))

 # 1. Freunde von Alice
 print("Alice's Friends:")
 friends = client.get_friends("alice")
 for friend in friends:
 print(f" - {friend.name} ({friend.location})")

 # 2. Freundschafts-Empfehlungen für Alice
 print("\nFriend Suggestions for Alice:")
 suggestions = client.get_friend_suggestions("alice", limit=3)
 for suggestion in suggestions:
```

```
 print(f" - {suggestion['user']['name']}: {suggestion['mutual_friends']} mutual friends", end=" ")

3. Verbindung zwischen Alice und Eve
print("\nConnection between Alice and Eve:")
path = client.find_connection_path("alice", "eve")
if path["connected"]:
 print(f" Path: {' -> '.join(path['path'])}")
 print(f" Degrees of Separation: {path['degrees_of_separation']}")

4. Communities
print("\nCommunities:")
communities = client.detect_communities()
for comm_id, comm_data in communities.items():
 print(f" Community {comm_id}: {comm_data['size']} members")
 print(f" Members: {' , '.join(comm_data['members'])}")
 print(f" Top Interests: {[i[0] for i in comm_data['top_interests']]}")

5. Visualisierung
client.visualize_network()

if __name__ == "__main__":
 main()
```

## Output

Alice's Friends:

- Bob (Munich)
- Charlie (Berlin)

Friend Suggestions for Alice:

- Diana: 1 mutual friends
- Eve: 1 mutual friends

Connection between Alice and Eve:

Path: Alice -> Charlie -> Eve

Degrees of Separation: 2

Communities:

Community 1: 5 members

Members: Alice, Bob, Charlie, Diana, Eve

Top Interests: ['Python', 'ML', 'Hiking', 'Music', 'Docker']

[Visualization opens in matplotlib window]

## Performance-Optimierung

### 1. Indexes auf häufig abgefragte Felder:

```
self.db.add_index("users", ["name"])
self.db.add_index("users", ["location"])
self.db.add_index("friendships", ["from", "to"])
```

### 2. Batch-Operations für viele Inserts:

```
def add_users_batch(self, users: List[User]):
 """Fügt mehrere User auf einmal hinzu."""
 user_docs = [u.to_dict() for u in users]
 self.db.insert_many("users", user_docs)
```

### 3. Bounded Traversals:

```
Statt 1..ANY (alle Knoten)
FOR v IN 1..3 OUTBOUND @user_id friendships # Max 3 Hops
RETURN v
```

#### 4. Index-basierte Filters:

```
Filter NACH Index-Lookup
FOR user IN users
 FILTER user.location == "Berlin" # Nutzt Index
 FOR friend IN OUTBOUND user._id friendships
 RETURN friend
```

## 6.6 Praxisbeispiel 2: Recommendation Engine

Das zweite Example ( [examples/19\\_recommendation\\_engine](#) ) zeigt einen komplexeren Use Case: **ML-basierte Empfehlungen** mit Graph- und Vektor-Daten.

### Das Konzept

Empfehlungssysteme kombinieren mehrere Ansätze:

1. **Collaborative Filtering**: "User, die X mochten, mochten auch Y"
2. **Content-Based Filtering**: "Ähnliche Items basierend auf Features"
3. **Graph-basiert**: "Freunde deiner Freunde kauften X"
4. **Hybrid**: Kombination aller Ansätze



## Datenmodell

```
@dataclass
class Item:
 """Ein empfehlbares Item (Produkt, Film, etc.)."""
 id: str
 title: str
 category: str
 features: List[str]
 embedding: List[float] # Content-Embedding für Similarity

@dataclass
class Interaction:
 """Eine User-Item Interaktion."""
 user_id: str
 item_id: str
 type: str # "view", "click", "purchase", "rate"
 rating: Optional[float] = None
 timestamp: datetime = None
 context: dict = None # Device, location, etc.

@dataclass
class Recommendation:
 """Eine generierte Empfehlung."""
 user_id: str
 item_id: str
 score: float
 method: str # "collaborative", "content_based", "graph", "hybrid"
 explanation: str
```

## Graph-Setup

```
def _setup_graph(self):
 """Erstellt Multi-Graph für Recommendations."""
 # Vertex Collections
 self.db.create_vertex_collection("users")
 self.db.create_vertex_collection("items")

 # Edge Collections
 self.db.create_edge_collection("interactions") # User -> Item
 self.db.create_edge_collection("similar_items") # Item -> Item
 self.db.create_edge_collection("user_similarity") # User -> User

 # Graph-Definition
 graph_def = {
 "name": "recommendation_graph",
 "edge_definitions": [
 {
 "collection": "interactions",
 "from": ["users"],
 "to": ["items"]
 },
 {
 "collection": "similar_items",
 "from": ["items"],
 "to": ["items"]
 },
 {
 "collection": "user_similarity",
 "from": ["users"],
 "to": ["users"]
 }
]
 }
 self.db.create_graph(graph_def)
```

## Collaborative Filtering

Findet Items, die ähnliche User mochten:

```

def collaborative_filtering(self, user_id: str, limit: int = 10) -> List[Recommendation]:
 """Empfehle Items basierend auf ähnlichen Usern."""
 query = """
 // 1. Finde ähnliche User (basierend auf vergangenen Interaktionen)
 FOR similar_user IN OUTBOUND @user_id user_similarity
 SORT similar_user.similarity DESC
 LIMIT 20

 // 2. Finde Items, die ähnliche User mochten
 FOR item IN OUTBOUND similar_user._id interactions
 FILTER item.interaction_type IN ["purchase", "rate"]
 FILTER item.rating >= 4 // Nur positive

 // 3. Filtere Items, die User schon kennt
 FILTER item._id NOT IN (
 FOR known_item IN OUTBOUND @user_id interactions
 RETURN known_item._id
)

 // 4. Aggregiere Score
 COLLECT item_id = item._id
 AGGREGATE score = AVG(item.rating * similar_user.similarity)

 SORT score DESC
 LIMIT @limit

 // 5. Hole Item-Details
 LET item_doc = DOCUMENT(item_id)
 RETURN {
 item_id: item_id,
 score: score,
 method: "collaborative",
 explanation: CONCAT("Users similar to you rated this ", score)
 }
 """

 results = self.db.execute_query(query, bind_vars={
 "user_id": f"users/{user_id}",
 })

```

```
 "limit": limit
 })

 return [Recommendation(**r) for r in results]
```

## Content-Based Filtering

Findet ähnliche Items basierend auf Features:

```

def content_based_filtering(self, user_id: str, limit: int = 10) -> List[Recommendation]:
 """Empfehle Items ähnlich zu den, die User mag."""
 query = """
 // 1. Finde Items, die User mag
 FOR liked_item IN OUTBOUND @user_id interactions
 FILTER liked_item.rating >= 4

 // 2. Finde ähnliche Items
 FOR similar_item IN OUTBOUND liked_item._id similar_items
 SORT similar_item.similarity DESC

 // 3. Filtere bekannte Items
 FILTER similar_item._id NOT IN (
 FOR known IN OUTBOUND @user_id interactions
 RETURN known._id
)

 // 4. Aggregiere
 COLLECT item_id = similar_item._id
 AGGREGATE score = AVG(similar_item.similarity)

 SORT score DESC
 LIMIT @limit

 LET item_doc = DOCUMENT(item_id)
 RETURN {
 item_id: item_id,
 score: score,
 method: "content_based",
 explanation: CONCAT("Similar to items you liked")
 }
 """

 results = self.db.execute_query(query, bind_vars={
 "user_id": f"users/{user_id}",
 "limit": limit
 })

```

```
return [Recommendation(**r) for r in results]
```

## Graph-basierte Empfehlungen

Nutzt Social Graph für Empfehlungen:

```

def graph_based_recommendations(self, user_id: str, limit: int = 10) -> List[Recommendation]:
 """Empfehle Items, die Freunde mochten."""
 query = """
 // 1. Traversiere zu Freunden (1-2 Hops)
 FOR friend IN 1..2 OUTBOUND @user_id friendships

 // 2. Finde Items, die Freund kaufte
 FOR item IN OUTBOUND friend._id interactions
 FILTER item.interaction_type == "purchase"

 // 3. Filtere bekannte Items
 FILTER item._id NOT IN (
 FOR known IN OUTBOUND @user_id interactions
 RETURN known._id
)

 // 4. Score basierend auf Freundschafts-Stärke und Rating
 COLLECT item_id = item._id
 AGGREGATE score = AVG(friend.friendship_strength * item.rating)

 SORT score DESC
 LIMIT @limit

 LET item_doc = DOCUMENT(item_id)
 RETURN {
 item_id: item_id,
 score: score,
 method: "graph_based",
 explanation: "Your friends liked this"
 }
 """

 results = self.db.execute_query(query, bind_vars={
 "user_id": f"users/{user_id}",
 "limit": limit
 })

 return [Recommendation(**r) for r in results]

```



## Hybrid Recommendations

Kombiniert alle Methoden mit Gewichtung:

```
def hybrid_recommendations(self, user_id: str, limit: int = 10) -> List[Recommendation]:
 """Kombiniert alle Empfehlungsmethoden."""
 # Hole Empfehlungen von allen Methoden
 collaborative = self.collaborative_filtering(user_id, limit=20)
 content_based = self.content_based_filtering(user_id, limit=20)
 graph_based = self.graph_based_recommendations(user_id, limit=20)

 # Gewichtung
 weights = {
 "collaborative": 0.4,
 "content_based": 0.3,
 "graph_based": 0.3
 }

 # Kombiniere Scores
 combined_scores = {}
 for recs, method in [
 (collaborative, "collaborative"),
 (content_based, "content_based"),
 (graph_based, "graph_based")
]:
 for rec in recs:
 if rec.item_id not in combined_scores:
 combined_scores[rec.item_id] = {
 "score": 0,
 "methods": [],
 "explanations": []
 }

 combined_scores[rec.item_id]["score"] += rec.score * weights[method]
 combined_scores[rec.item_id]["methods"].append(method)
 combined_scores[rec.item_id]["explanations"].append(rec.explanation)

 # Sortiere und limitiere
 sorted_items = sorted(
 combined_scores.items(),
 key=lambda x: x[1]["score"],
 reverse=True
)
```

```
][:limit]

Erstelle finale Recommendations
recommendations = []
for item_id, data in sorted_items:
 recommendations.append(Recommendation(
 user_id=user_id,
 item_id=item_id,
 score=data["score"],
 method="hybrid",
 explanation=f"Recommended via: {'', ' '.join(data['methods'])}"
))

return recommendations
```

## Similarity Berechnung

Berechne User-User und Item-Item Similarity:

```
def compute_user_similarity(self):
 """Berechnet Similarity zwischen allen User-Paaren."""
 users = self.db.all("users")

 for i, user1 in enumerate(users):
 for user2 in users[i+1:]:
 # Gemeinsame Interaktionen
 common_items = self._get_common_interactions(user1["_id"], user2["_id"])

 if len(common_items) >= 3: # Mindestens 3 gemeinsame
 similarity = self._calculate_similarity(
 user1["interaction_vector"],
 user2["interaction_vector"]
)

 # Speichere Kante
 self.db.insert("user_similarity", {
 "from": user1["_id"],
 "to": user2["_id"],
 "similarity": similarity,
 "common_items": len(common_items)
 })

def compute_item_similarity(self):
 """Berechnet Similarity zwischen Items (content-based)."""
 items = self.db.all("items")

 for i, item1 in enumerate(items):
 for item2 in items[i+1:]:
 # Cosine Similarity der Embeddings
 similarity = cosine_similarity(
 item1["embedding"],
 item2["embedding"]
)

 if similarity > 0.7: # Threshold
 self.db.insert("similar_items", {
 "from": item1["_id"],
```

```

 "to": item2["_id"],
 "similarity": similarity
 })

```

## Real-Time Updates

Aktualisiere Empfehlungen bei neuen Interaktionen:

```

def record_interaction(self, interaction: Interaction):
 """Zeichnet Interaktion auf und aktualisiert Empfehlungen."""
 # Speichere Interaktion
 interaction_doc = {
 "from": f"users/{interaction.user_id}",
 "to": f"items/{interaction.item_id}",
 "type": interaction.type,
 "rating": interaction.rating,
 "timestamp": interaction.timestamp.isoformat(),
 "context": interaction.context
 }
 self.db.insert("interactions", interaction_doc)

 # Bei Purchase: Update User-Vektor
 if interaction.type == "purchase":
 self._update_user_vector(interaction.user_id, interaction.item_id)

 # Recalculate Similarity (async)
 self._queue_similarity_update(interaction.user_id)

```

## 6.7 Graph Best Practices

### 1. Modeling Guidelines

**DO:** - Nutze sprechende Edge-Namen (**FRIEND**, **LIKES**, **WORKS\_AT**) - Speichere Properties auf Kanten (Zeitstempel, Gewichte) - Denormalisiere häufig benötigte Daten - Nutze Bidirektionale Kanten für ungerichtete Graphs

**DON'T:** - × Zu viele Edge-Types (schwer zu querien) - × Properties als separate Knoten (ineffizient) - × Extrem tiefe Hierarchien (> 10 Levels)

## 2. Performance-Tipps

### Indexes:

```
Composite Index für häufige Lookups
db.add_index("friendships", ["from", "to"])
db.add_index("interactions", ["user_id", "timestamp"])
```

### Bounded Traversals:

```
Limitiere Hops
FOR v IN 1..3 OUTBOUND @start # Nicht 1..ANY
 LIMIT 100 # Früh limitieren
 RETURN v
```

### Prune Early:

```
Filter so früh wie möglich
FOR v IN 1..5 OUTBOUND @start friendships
 FILTER v.city == "Berlin" # Früher Filter
 FOR v2 IN OUTBOUND v._id friendships
 RETURN v2
```

## 3. Häufige Patterns

### Pattern 1: Mutual Friends

```
FOR friend IN OUTBOUND @user1 friendships
 FILTER friend._id IN (
 FOR f IN OUTBOUND @user2 friendships
 RETURN f._id
)
 RETURN friend
```

### Pattern 2: Influencer (hohe Degree)

```

FOR user IN users
 LET friend_count = LENGTH(
 FOR f IN OUTBOUND user._id friendships
 RETURN 1
)
 FILTER friend_count > 100
 SORT friend_count DESC
 RETURN {user: user, friends: friend_count}

```

### Pattern 3: Isolated Nodes

```

FOR user IN users
 LET connections = (
 FOR v IN ANY user._id friendships
 RETURN 1
)
 FILTER LENGTH(connections) == 0
 RETURN user

```

## 6.8 Vergleich: ThemisDB vs. Neo4j vs. ArangoDB

Feature	ThemisDB	Neo4j	ArangoDB
<b>Graph Model</b>	Property Graph	Property Graph	Property Graph
<b>Query Language</b>	AQL	Cypher	AQL
<b>Multi-Model</b>	4 Models	× Graph only	3 Models
<b>ACID</b>	Full	Full	Full
<b>Sharding</b>	Automatic	× Enterprise only	Yes
<b>Graph Algorithms</b>	Built-in	GDS Library	Pregel
<b>License</b>	Apache 2.0	GPLv3 + Commercial	Apache 2.0
<b>Embedding Support</b>	Native	× No	× No

**Wann ThemisDB?** - Multi-Model Daten (Graph + Vektor + Relational) - Native Vektor-Suche benötigt - Open-Source und selbst-hosted - Kombinierte Queries über mehrere Modelle

**Wann Neo4j?** - Reines Graph-Problem - Cypher-Erfahrung im Team - Enterprise Support benötigt - Graph Data Science Library

**Wann ArangoDB?** - Ähnlich wie ThemisDB (Multi-Model) - Mature Community - Foxx Microservices

## 6.9 Zusammenfassung

In diesem Kapitel haben Sie gelernt:

**Property Graph Modell** - Knoten, Kanten, Properties

**Graph-Traversierung** - DFS, BFS, Pattern Matching

**Graph-Algorithmen** - Shortest Path, PageRank, Community Detection

**Praxis: Social Network** - Vollständiges soziales Netzwerk mit Visualisierung

**Praxis: Recommendations** - ML-basierte Empfehlungen mit Hybrid-Ansatz

**Best Practices** - Modeling, Performance, Patterns

Graph-Datenbanken sind die natürliche Wahl für vernetzte Daten. ThemisDB's Property Graph-Implementierung bietet performante Traversierung, native Algorithmen und die einzigartige Möglichkeit, Graphs mit anderen Modellen zu kombinieren.

Im nächsten Kapitel schauen wir uns **Dokument-Speicherung** an - flexibles, schema-less Design für semi-strukturierte Daten.

---

### Übungen:

1. Erweitern Sie das Social Network um Posts und Likes (User -> Post -> Likes)
2. Implementieren Sie einen Follower/Following-Mechanismus (Twitter-Style)
3. Fügen Sie PageRank-Berechnung hinzu, um Influencer zu finden
4. Erstellen Sie einen Interest-Based-Graph (User -> Interest <- User)
5. Bauen Sie ein Skill-Recommendation-System für LinkedIn-Style-Netzwerk

### Weiterführende Ressourcen:

- [examples/06\\_graph\\_social\\_network/](#) - Vollständiger Code
- [examples/19\\_recommendation\\_engine/](#) - Recommendation System
- [docs/de/features/features\\_property\\_graph.md](#) - Graph-Features
- NetworkX Documentation - Graph-Visualisierung



- "Graph Algorithms" (Mark Needham, Amy E. Hodler) - Tiefere Algorithmen

## Kapitel 7: Kapitel 7 - Dokumente

---

*In diesem Kapitel: Schema-less Design, flexible Datenstrukturen, Nested Objects, JSON-Operationen, Content Management, Versionierung und Migration von MongoDB.*

### 7.1 Das Document Model

#### Warum Dokumente?

Das Document Model ist ideal für Anwendungen mit:

- **Flexible Schemas:** Nicht alle Datensätze haben die gleichen Felder
- **Nested Data:** Hierarchische Strukturen (Kommentare, Tags, Metadaten)
- **Rapid Development:** Schema-Evolution ohne Migration
- **Content Management:** Blogs, Wikis, CMS-Systeme

**Beispiele aus der Praxis:** - Blog-Systeme mit variablen Post-Typen (Text, Video, Galerie) - Wikis mit verschachtelten Inhalten und Revisionen - Content-Management mit Metadata - Konfigurationsdaten mit unterschiedlichen Formaten

#### Dokumente in ThemisDB

ThemisDB speichert Dokumente als JSON mit vollem ACID-Support:

```
from themisdb import ThemisDB

db = ThemisDB()

Dokument mit beliebiger Struktur
article = {
 "title": "Multi-Model Databases",
 "author": "Alice",
 "content": "Content here...",
 "tags": ["database", "multi-model"],
 "metadata": {
 "published": "2025-01-15",
 "views": 1024
 },
 "comments": [
 {"user": "Bob", "text": "Great article!"},
 {"user": "Carol", "text": "Very helpful"}
]
}

db.documents.insert("articles", article)
```

**Vorteile:** - Keine Schema-Definition notwendig - Beliebige Verschachtelung - Arrays von Sub-Dokumenten - Optionale Felder - JSON-Operationen (Path-Queries, Updates)

## Vergleich: Relational vs. Document

**Relational (starr):**

```
-- Zwei separate Collections mit Referenzen
// articles Collection
{
 _key: "1",
 title: "Artikel",
 content: "Text..."
}

// comments Collection (Referenz via article_id)
{
 _key: "c1",
 article_id: "1",
 user: "alice",
 text: "Kommentar"
}
```

### Document (flexibel):

```
// Ein Dokument, alles inklusive
{
 "id": 1,
 "title": "...",
 "content": "...",
 "comments": [{"user": "...", "text": "..."}]
}
```

Abb. 07.1: Dokument-Store-Architektur

## Schema Evolution

Neue Felder ohne Migration hinzufügen:

```
Version 1: Einfacher Blog-Post
{
 "title": "Hello World",
 "content": "..."
}

Version 2: Mit Autor (kein ALTER TABLE!)
{
 "title": "Hello World",
 "content": "...",
 "author": "Alice"
}

Version 3: Mit Tags und Metadata
{
 "title": "Hello World",
 "content": "...",
 "author": "Alice",
 "tags": ["intro", "tutorial"],
 "metadata": {
 "published": "2025-01-15",
 "featured": True
 }
}
```

### Anwendungscode prüft Feld-Existenz:

```
article = db.documents.get("articles", article_id)

Sicher: Prüfe ob Feld existiert
author = article.get("author", "Unknown")
tags = article.get("tags", [])
```

## 7.2 JSON-Operationen

### Path-Queries

Tief in verschachtelten Dokumenten suchen:

```
Finde Artikel mit bestimmten Metadaten
articles = db.query("""
 FOR article IN articles
 FILTER article.metadata.published > '2025-01-01'
 AND article.metadata.featured == true
 RETURN article
""")

Array-Operationen
articles_with_tag = db.query("""
 FOR article IN articles
 FILTER 'database' IN article.tags
 RETURN article
""")

Nested Object Query
articles_by_bob = db.query("""
 FOR article IN articles
 FILTER 'Bob' IN article.comments[*].user
 RETURN article
""")
```

### Partial Updates

Nur bestimmte Felder ändern:

```
Increment View Counter
db.documents.update(
 collection="articles",
 document_id=article_id,
 updates={"metadata.views": db.increment(1)}
)

Add Comment
new_comment = {"user": "Dave", "text": "Thanks!"}
db.documents.update(
 collection="articles",
 document_id=article_id,
 updates={"comments": db.array_append(new_comment)}
)

Update nested field
db.documents.update(
 collection="articles",
 document_id=article_id,
 updates={"metadata.featured": True}
)
```

## JSON-Funktionen

```
JSON Path Extraction
result = db.query("""
 SELECT
 title,
 metadata.published AS date,
 ARRAY_LENGTH(comments) AS comment_count
 FROM articles
 WHERE metadata.featured = true
""")

JSON Aggregation
stats = db.query("""
 SELECT
 author,
 COUNT(*) AS article_count,
 SUM(metadata.views) AS total_views
 FROM articles
 GROUP BY author
""")
```

## 7.3 Example: Blog/Wiki System

*Example:* `examples/11_blog_wiki`

Implementieren wir ein vollständiges Content-Management-System mit Artikeln, Revisions-Historie und Tagging.

### System-Überblick

**Features:** - Artikel mit Rich Content (Markdown) - Revisions-Historie (alle Änderungen) - Tagging und Kategorisierung - Volltext-Suche über Titel und Content - View-Counter und Statistiken - Kommentar-System

**Datenstruktur:**

```
{
 "id": "uuid",
 "title": "Getting Started with ThemisDB",
 "slug": "getting-started-themisdb",
 "content": "# Introduction\n\n...",
 "author": "alice@example.com",
 "status": "published", # draft, published, archived
 "tags": ["tutorial", "database", "introduction"],
 "category": "tutorials",
 "metadata": {
 "published_at": "2025-01-15T10:00:00Z",
 "updated_at": "2025-01-16T14:30:00Z",
 "views": 1250,
 "featured": True
 },
 "comments": [
 {
 "id": "comment-uuid",
 "author": "bob@example.com",
 "text": "Great tutorial!",
 "created_at": "2025-01-15T11:00:00Z"
 }
],
 "revisions": [
 {
 "version": 1,
 "content": "Initial version...",
 "changed_by": "alice@example.com",
 "changed_at": "2025-01-15T10:00:00Z"
 },
 {
 "version": 2,
 "content": "Updated version...",
 "changed_by": "alice@example.com",
 "changed_at": "2025-01-16T14:30:00Z"
 }
]
}
```



## Implementation

Die Implementation zeigt ein vollständiges Blog/Wiki-System mit verschachtelten Dokumenten (Comments, Revisions) und flexiblem Schema. Die Datenmodelle nutzen Python Dataclasses für klare Strukturierung, während die Document Engine die komplexe Verschachtelung transparent handhabt.

**Vollständiger Code:** `examples/blog_wiki/models.py` (ca. 80 Zeilen)

### Datenmodelle (Kernstruktur):

```
from dataclasses import dataclass, field
from datetime import datetime
from typing import List
import uuid

@dataclass
class Comment:
 id: str
 author: str
 text: str
 created_at: datetime

 @staticmethod
 def create(author: str, text: str) -> dict:
 """Factory-Methode für neue Comments"""
 return {
 "id": str(uuid.uuid4()),
 "author": author,
 "text": text,
 "created_at": datetime.now().isoformat()
 }

@dataclass
class Article:
 id: str
 title: str
 slug: str
 content: str
 author: str
 status: str # draft, published, archived
 tags: List[str]
 category: str
 metadata: dict
 comments: List[dict] = field(default_factory=list)
 revisions: List[dict] = field(default_factory=list)
```

**Wichtige Design-Entscheidungen:** - **Verschachtelte Dokumente:** Comments und Revisions als Arrays innerhalb des Articles - **Flexible Metadaten:** `metadata` dict für erweiterbare Eigenschaften - **Factory-Methoden:** `Article.create()` initialisiert mit sinnvollen Defaults - **UUID-basierte IDs:** Dezentrale ID-Generierung für verteilte Systeme

Die vollständige `Article.create()` Methode generiert automatisch Slug, initialisiert Metadaten (`created_at`, `views`, etc.) und erstellt die erste Revision.

#### **Blog/Wiki Service-Klasse:**

Die `BlogWiki` Klasse kapselt alle Datenbankoperationen für das Blog/Wiki-System. Sie demonstriert wichtige Document Engine Features wie Array-Operationen (`array_append`), verschachtelte Updates (`metadata.published_at`), und Transaktionen für atomare Multi-Step-Operationen.

*Vollständiger Code:* `examples/blog_wiki/blog.py` (ca. 220 Zeilen)

#### **Index-Setup für Performance:**

```
from themisdb import ThemisDB

class BlogWiki:
 def __init__(self, db_path: str = "blog.db"):
 self.db = ThemisDB(db_path)
 self._setup_indexes()

 def _setup_indexes(self):
 """Erstellt Indizes für häufige Abfragen"""
 # Fulltext-Suche in Titel und Content
 self.db.execute("""
 CREATE INDEX idx_articles_fulltext
 ON articles USING FULLTEXT(title, content)
 """)

 # Schneller Slug-Lookup
 self.db.execute("""
 CREATE INDEX idx_articles_slug ON articles(slug)
 """)

 # Filter nach Status und Kategorie
 self.db.execute("""
 CREATE INDEX idx_articles_status_category
 ON articles(status, category)
 """)
```

### CRUD-Operationen (Auszüge):

```
def create_article(self, title: str, content: str, author: str,
 tags: List[str], category: str) -> str:
 """Neuen Artikel erstellen"""
 article = Article.create(title, content, author, tags, category)
 self.db.documents.insert("articles", article)
 return article["id"]

def update_article(self, article_id: str, content: str, updated_by: str):
 """Artikel aktualisieren - speichert automatisch Revision!"""
 article = self.db.documents.get("articles", article_id)

 # Neue Revision erstellen
 new_version = len(article["revisions"]) + 1
 revision = {
 "version": new_version,
 "content": content,
 "changed_by": updated_by,
 "changed_at": datetime.now().isoformat()
 }

 with self.db.transaction():
 self.db.documents.update(
 collection="articles",
 document_id=article_id,
 updates={
 "content": content,
 "metadata.updated_at": datetime.now().isoformat(),
 "revisions": self.db.array_append(revision) # Array-Operation!
 }
)
```

### Array-Operationen für verschachtelte Dokumente:

```
def add_comment(self, article_id: str, author: str, text: str):
 """Comment zu Article hinzufügen"""
 comment = Comment.create(author, text)

 self.db.documents.update(
 collection="articles",
 document_id=article_id,
 updates={
 "comments": self.db.array_append(comment) # Effizient!
 }
)

def revert_to_revision(self, article_id: str, version: int):
 """Artikel zu früherer Version zurücksetzen"""
 article = self.db.documents.get("articles", article_id)
 target = next(r for r in article["revisions"] if r["version"] == version)

 # Revert wird selbst als neue Revision gespeichert
 revert_revision = {
 "version": len(article["revisions"]) + 1,
 "content": target["content"],
 "changed_by": "system",
 "changed_at": datetime.now().isoformat(),
 "reverted_from": version
 }

 with self.db.transaction():
 self.db.documents.update(
 collection="articles",
 document_id=article_id,
 updates={
 "content": target["content"],
 "revisions": self.db.array_append(revert_revision)
 }
)
```

### Aggregation für Statistiken:

```
def get_statistics(self) -> dict:
 """Blog-Statistiken berechnen"""
 return self.db.query("""
 SELECT
 COUNT(*) AS total_articles,
 SUM(CASE WHEN status='published' THEN 1 ELSE 0 END) AS published,
 SUM(metadata.views) AS total_views,
 AVG(metadata.views) AS avg_views
 FROM articles
 """)[0]
```

Die vollständige Klasse enthält zusätzlich: - `publish_article()` - Status ändern und Publikationsdatum setzen - `increment_views()` - View-Counter inkrementieren - `search_articles()` - Fulltext-Suche - `get_by_category()` - Kategoriefilter - `get_by_tags()` - Tag-basierte Suche - `get_related_articles()` - Empfehlungen basierend auf Tags

## Praktische Anwendung

**Blog-Post erstellen und veröffentlichen:**

```
from blog import BlogWiki

blog = BlogWiki()

Create article
article_id = blog.create_article(
 title="Getting Started with ThemisDB",
 content="""
 # Introduction

 ThemisDB is a multi-model database...

 ## Features
 - ACID transactions
 - Multiple data models
 - High performance
 """,
 author="alice@example.com",
 tags=["tutorial", "database", "getting-started"],
 category="tutorials"
)

Publish
blog.publish_article(article_id)

Add comments
blog.add_comment(
 article_id,
 author="bob@example.com",
 text="Great tutorial! Very helpful."
)

Track views
blog.increment_views(article_id)
```

**Artikel aktualisieren mit Revisions-Historie:**



```
Update content
blog.update_article(
 article_id,
 content="""
 # Introduction (Updated!)

 ThemisDB is a powerful multi-model database...

 ## New Features
 - ACID transactions
 - Multiple data models
 - High performance
 - Geo-spatial support (NEW!)
 """,
 updated_by="alice@example.com"
)

View revision history
revisions = blog.get_revisions(article_id)
for rev in revisions:
 print(f"Version {rev['version']} by {rev['changed_by']}")
 print(f" Changed at: {rev['changed_at']}")

Revert to previous version if needed
blog.revert_to_revision(article_id, version=1,
 reverted_by="alice@example.com")
```

**Suchen und Filtern:**

```
Fulltext search
results = blog.search_articles("multi-model database")
print(f"Found {len(results)} articles")

Get by tag
tutorials = blog.get_by_tag("tutorial")

Get by category
db_articles = blog.get_by_category("database")

Popular articles
popular = blog.get_popular(limit=5)

Featured articles
featured = blog.get_featured()
```

### Statistiken:

```
stats = blog.get_statistics()
print(f"Total articles: {stats['total_articles']}")
print(f"Published: {stats['published']}")
print(f"Drafts: {stats['drafts']}")
print(f"Total views: {stats['total_views']}")
print(f"Avg views: {stats['avg_views']:.1f}")
```

## Key Features

- 1. Schema Flexibility:** - Artikel können unterschiedliche Felder haben - Neue Features ohne Migration (z.B. `metadata.featured`) - Optionale Felder (z.B. `published_at` nur bei Status="published")
- 2. Revision History:** - Jede Änderung wird gespeichert - Komplette Historie verfügbar - Revert zu jeder Version möglich
- 3. Nested Data:** - Comments als Array von Sub-Dokumenten - Metadata als verschachteltes Objekt - Keine JOIN-Queries notwendig
- 4. Performance:** - Fulltext-Index für Suche - Index auf Slug für schnelle Lookups - Composite-Index für Status+Category

## 7.4 Example: Recipe Manager

*Example:* `examples/13_recipe_manager`

Ein Rezept-Verwaltungssystem zeigt die Stärken des Document Models bei komplexen, verschachtelten Datenstrukturen.

### System-Überblick

**Features:** - Rezepte mit Zutaten und Schritten - Nährwertangaben und Tags - Bewertungen und Kommentare - Einkaufslisten-Generator - Meal Planning

**Datenstruktur:**

```
{
 "id": "uuid",
 "title": "Spaghetti Carbonara",
 "description": "Classic Italian pasta dish",
 "cuisine": "Italian",
 "difficulty": "medium", # easy, medium, hard
 "prep_time": 15, # minutes
 "cook_time": 20,
 "servings": 4,
 "ingredients": [
 {
 "name": "Spaghetti",
 "amount": 400,
 "unit": "g",
 "category": "pasta"
 },
 {
 "name": "Eggs",
 "amount": 4,
 "unit": "pieces",
 "category": "dairy"
 },
 {
 "name": "Parmesan",
 "amount": 100,
 "unit": "g",
 "category": "dairy"
 }
],
 "steps": [
 {
 "number": 1,
 "instruction": "Boil water and cook spaghetti al dente",
 "duration": 10
 },
 {
 "number": 2,
 "instruction": "Mix eggs with parmesan",
```

```
 "duration": 5
 },
 {
 "number": 3,
 "instruction": "Combine pasta with egg mixture",
 "duration": 5
 }
],
"nutrition": {
 "calories": 520,
 "protein": 22,
 "carbs": 65,
 "fat": 18
},
"tags": ["pasta", "italian", "quick", "dinner"],
"ratings": [
 {
 "user": "alice@example.com",
 "score": 5,
 "comment": "Delicious!",
 "date": "2025-01-15"
 }
],
"created_by": "chef@example.com",
"created_at": "2025-01-10",
"updated_at": "2025-01-15"
}
```

## Implementation

`recipe_manager/recipe.py` :

```

from themisdb import ThemisDB
from typing import List, Optional
from datetime import datetime

class RecipeManager:
 def __init__(self, db_path: str = "recipes.db"):
 self.db = ThemisDB(db_path)
 self._setup_indexes()

 def _setup_indexes(self):
 # Fulltext search
 self.db.execute("""
 CREATE INDEX IF NOT EXISTS idx_recipes_fulltext
 ON recipes USING FULLTEXT(title, description)
 """)

 # Filter by tags, cuisine, difficulty
 self.db.execute("""
 CREATE INDEX IF NOT EXISTS idx_recipes_filters
 ON recipes(cuisine, difficulty, tags)
 """)

 def add_recipe(self, recipe_data: dict) -> str:
 """Add new recipe"""
 recipe_data["created_at"] = datetime.now().isoformat()
 recipe_data["updated_at"] = datetime.now().isoformat()

 recipe_id = self.db.documents.insert("recipes", recipe_data)
 return recipe_id

 def search_recipes(self, query: str) -> List[dict]:
 """Search by title or description"""
 return self.db.query("""
 FOR recipe IN recipes
 FILTER FULLTEXT(recipe.title, @query) OR FULLTEXT(recipe.description, @query)
 RETURN recipe
 """, {"query": query})

```

```

def filter_recipes(self, cuisine: Optional[str] = None,
 difficulty: Optional[str] = None,
 max_time: Optional[int] = None,
 tags: Optional[List[str]] = None) -> List[dict]:
 """Filter recipes by criteria"""
 # Build AQL query dynamically
 filters = []
 params = {}

 if cuisine:
 filters.append("recipe.cuisine == @cuisine")
 params["cuisine"] = cuisine

 if difficulty:
 filters.append("recipe.difficulty == @difficulty")
 params["difficulty"] = difficulty

 if max_time:
 filters.append("(recipe.prep_time + recipe.cook_time) <= @max_time")
 params["max_time"] = max_time

 if tags:
 for i, tag in enumerate(tags):
 filters.append(f"@tag{i} IN recipe.tags")
 params[f"tag{i}"] = tag

 filter_clause = " AND ".join(filters) if filters else "true"

 return self.db.query(f"""
 FOR recipe IN recipes
 FILTER {filter_clause}
 RETURN recipe
 """, params)

def add_rating(self, recipe_id: str, user: str,
 score: int, comment: str):
 """Add rating to recipe"""
 rating = {

```

```

 "user": user,
 "score": score,
 "comment": comment,
 "date": datetime.now().isoformat()
 }

 self.db.documents.update(
 collection="recipes",
 document_id=recipe_id,
 updates={
 "ratings": self.db.array_append(rating)
 }
)

def get_average_rating(self, recipe_id: str) -> float:
 """Calculate average rating"""
 recipe = self.db.documents.get("recipes", recipe_id)
 ratings = recipe.get("ratings", [])

 if not ratings:
 return 0.0

 return sum(r["score"] for r in ratings) / len(ratings)

def generate_shopping_list(self, recipe_ids: List[str],
 servings_multiplier: dict = None) -> dict:
 """Generate shopping list from multiple recipes"""
 shopping_list = {}

 for recipe_id in recipe_ids:
 recipe = self.db.documents.get("recipes", recipe_id)
 multiplier = servings_multiplier.get(recipe_id, 1.0)

 for ingredient in recipe["ingredients"]:
 name = ingredient["name"]
 amount = ingredient["amount"] * multiplier
 unit = ingredient["unit"]
 category = ingredient.get("category", "other")

```



```

 if name not in shopping_list:
 shopping_list[name] = {
 "amount": 0,
 "unit": unit,
 "category": category
 }

 shopping_list[name]["amount"] += amount

Group by category
categorized = {}
for name, details in shopping_list.items():
 category = details["category"]
 if category not in categorized:
 categorized[category] = []

 categorized[category].append({
 "name": name,
 "amount": details["amount"],
 "unit": details["unit"]
 })

return categorized

def get_topRated(self, limit: int = 10) -> List[dict]:
 """Get top rated recipes"""
 recipes = self.db.query("""
 FOR recipe IN recipes
 RETURN recipe
 """)

Calculate average ratings
rated = []
for recipe in recipes:
 ratings = recipe.get("ratings", [])
 if ratings:
 avg = sum(r["score"] for r in ratings) / len(ratings)

```

```
 recipe["avg_rating"] = avg
 rated.append(recipe)

 # Sort by rating
 rated.sort(key=lambda x: x["avg_rating"], reverse=True)
 return rated[:limit]

def get_quick_recipes(self, max_minutes: int = 30) -> List[dict]:
 """Get recipes that can be made quickly"""
 return self.db.query("""
 FOR recipe IN recipes
 FILTER (recipe.prep_time + recipe.cook_time) <= @max_minutes
 SORT (recipe.prep_time + recipe.cook_time) ASC
 RETURN recipe
 """, {"max_minutes": max_minutes})
```

## Praktische Anwendung

### Rezept hinzufügen:

```
from recipe import RecipeManager

manager = RecipeManager()

recipe = {
 "title": "Spaghetti Carbonara",
 "description": "Classic Italian pasta dish",
 "cuisine": "Italian",
 "difficulty": "medium",
 "prep_time": 15,
 "cook_time": 20,
 "servings": 4,
 "ingredients": [
 {"name": "Spaghetti", "amount": 400, "unit": "g", "category": "pasta"},
 {"name": "Eggs", "amount": 4, "unit": "pieces", "category": "dairy"},
 {"name": "Parmesan", "amount": 100, "unit": "g", "category": "dairy"},
 {"name": "Bacon", "amount": 200, "unit": "g", "category": "meat"}
],
 "steps": [
 {"number": 1, "instruction": "Boil water and cook spaghetti", "duration": 10},
 {"number": 2, "instruction": "Mix eggs with parmesan", "duration": 5},
 {"number": 3, "instruction": "Combine everything", "duration": 5}
],
 "nutrition": {
 "calories": 520,
 "protein": 22,
 "carbs": 65,
 "fat": 18
 },
 "tags": ["pasta", "italian", "quick", "dinner"],
 "created_by": "chef@example.com"
}

recipe_id = manager.add_recipe(recipe)
```

### Suchen und Filtern:

```
Search
results = manager.search_recipes("pasta")

Filter by cuisine and difficulty
italian_easy = manager.filter_recipes(
 cuisine="Italian",
 difficulty="easy"
)

Quick recipes (under 30 minutes)
quick = manager.get_quick_recipes(max_minutes=30)

Recipes with specific tags
vegetarian = manager.filter_recipes(tags=["vegetarian", "healthy"])
```

### **Bewertungen:**

```
Add rating
manager.add_rating(
 recipe_id=recipe_id,
 user="alice@example.com",
 score=5,
 comment="Best carbonara I've ever made!"
)

Get average
avg = manager.get_average_rating(recipe_id)
print(f"Average rating: {avg:.1f}/5")

Top rated recipes
top = manager.get_top_rated(limit=5)
```

### **Einkaufsliste generieren:**

```
Select recipes for the week
recipe_ids = [recipe1_id, recipe2_id, recipe3_id]

Adjust servings (double recipe1, halve recipe2)
multipliers = {
 recipe1_id: 2.0,
 recipe2_id: 0.5,
 recipe3_id: 1.0
}

Generate shopping list
shopping_list = manager.generate_shopping_list(recipe_ids, multipliers)

Print by category
for category, items in shopping_list.items():
 print(f"\n{category.upper()}:")
 for item in items:
 print(f" - {item['name']}: {item['amount']}{item['unit']}")
```

## Document Model Vorteile

- 1. Natürliche Verschachtelung:** - Ingredients als Array - Steps mit Nummern und Dauer - Nutrition als Sub-Dokument - Ratings mit User-Comments
- 2. Flexibilität:** - Optionale Felder (z.B. `nutrition` kann fehlen) - Unterschiedliche Ingredient-Properties - Variable Anzahl von Steps
- 3. Einfache Queries:** - Alles in einem Dokument - Keine JOINS notwendig - Aggregation über Arrays

## 7.5 Migration von MongoDB

Viele Projekte migrieren von MongoDB zu ThemisDB für ACID-Garantien.

### Schema Mapping

**MongoDB:**

```
db.articles.insert({
 _id: ObjectId("..."),
 title: "Hello World",
 content: "...",
 tags: ["intro", "tutorial"]
})
```

**ThemisDB:**

```
db.documents.insert("articles", {
 "id": "uuid", # UUID statt ObjectId
 "title": "Hello World",
 "content": "...",
 "tags": ["intro", "tutorial"]
})
```

## Migration Script

```
from pymongo import MongoClient
from themisdb import ThemisDB

Connect to both
mongo = MongoClient("mongodb://localhost:27017")
themis = ThemisDB("migrated.db")

Migrate collection
mongo_db = mongo["myapp"]
collection = mongo_db["articles"]

for doc in collection.find():
 # Convert ObjectId to string
 doc["id"] = str(doc.pop("_id"))

 # Insert into ThemisDB
 themis.documents.insert("articles", doc)

print("Migration complete!")
```

## API Differences

MongoDB	ThemisDB	Note
<code>insert_one()</code>	<code>documents.insert()</code>	Single insert
<code>find()</code>	<code>query()</code>	Use AQL
<code>update_one()</code>	<code>documents.update()</code>	Partial update
<code>aggregate()</code>	<code>query()</code>	AQL GROUP BY
<code>\$inc</code>	<code>increment()</code>	Atomic increment
<code>\$push</code>	<code>array_append()</code>	Array operation

## Vorteile nach Migration

### 1. ACID-Transaktionen:

```
ThemisDB: Atomic updates über Dokumente
with themis.transaction():
 themis.documents.update("articles", id1, {...})
 themis.documents.update("comments", id2, {...})
Beide Erfolg oder beide Rollback
```

### 2. AQL-Queries:

```
MongoDB: Komplex mit aggregation pipeline
results = collection.aggregate([
 {"$match": {"status": "published"}},
 {"$group": {"_id": "$author", "count": {"$sum": 1}}},
 {"$sort": {"count": -1}}
])

ThemisDB: Einfaches AQL
results = themis.query("""
 FOR article IN articles
 FILTER article.status == 'published'
 COLLECT author = article.author
 AGGREGATE count = COUNT()
 SORT count DESC
 RETURN {author, count}
""")
```

### 3. Multi-Model:



```
ThemisDB: Kombiniere Document + Relational + Graph
results = themis.query("""
 FOR article IN articles
 LET comment_count = (
 FOR comment IN comments
 FILTER comment.article_id == article.id
 RETURN 1
)
 LET avg_rating = (
 FOR rating IN ratings
 FILTER rating.article_id == article.id
 COLLECT AGGREGATE avg_score = AVG(rating.score)
 RETURN avg_score
)
 RETURN {
 title: article.title,
 comment_count: LENGTH(comment_count),
 rating: avg_rating[0]
 }
""")
```

## 7.6 Best Practices

### 1. Schema Design

#### DO: Embed Related Data

```
Good: Article mit Comments eingebettet
{
 "title": "...",
 "content": "...",
 "comments": [
 {"user": "alice", "text": "..."},
 {"user": "bob", "text": "..."}
]
}
```

**x DON'T: Separate wenn oft zusammen gelesen**

```
Bad: Zwei Queries notwendig
articles collection
{"id": 1, "title": "..."}

comments collection
{"article_id": 1, "user": "alice", "text": "..."}

```

**2. Array-Größe begrenzen**

**Problem:** Arrays können unbegrenzt wachsen

```
Bad: Unbegrenztes Array
{
 "title": "Popular Article",
 "comments": [...] # Kann zu groß werden!
}
```

**Lösung:** Separiere bei großen Arrays

```
Good: Limite Arrays
{
 "title": "Popular Article",
 "recent_comments": [...][:10], # Nur letzte 10
 "comment_count": 1523
}

Comments in separater Collection
comments collection: {article_id, user, text, ...}

```

**3. Versionierung**

**Schema-Version im Dokument:**

```
{
 "_schema_version": 2,
 "title": "...",
 "content": "...",
 # v2 fields
 "metadata": {...}
}

Anwendungscode:
def load_article(doc):
 version = doc.get("_schema_version", 1)

 if version == 1:
 # Upgrade v1 → v2
 doc["metadata"] = {"created_at": doc.get("created_at")}
 doc["_schema_version"] = 2

 return doc
```

## 4. Index-Strategie

### Indexiere häufige Queries:

```
Fulltext für Suche
CREATE INDEX idx_fulltext ON articles USING FULLTEXT(title, content)

Filter-Felder
CREATE INDEX idx_filters ON articles(status, category, author)

Array-Felder
CREATE INDEX idx_tags ON articles(tags)
```

## 5. Partial Updates

### Effizient: Nur ändern was nötig

```
Good: Nur View-Counter
db.documents.update(
 collection="articles",
 document_id=article_id,
 updates={"metadata.views": db.increment(1)}
)

Bad: Ganzes Dokument neu schreiben
article = db.documents.get("articles", article_id)
article["metadata"]["views"] += 1
db.documents.update("articles", article_id, article) # Ineffizient!
```

## 7.7 Performance-Tipps

### 1. Embed vs. Reference

**Embed (einbetten):** - Daten werden immer zusammen gelesen - Eingebettete Daten ändern sich selten  
- Größe ist begrenzt

**Reference (referenzieren):** - Daten werden unabhängig gelesen - Daten werden häufig aktualisiert -  
Eingebettetes Array wird zu groß

### 2. Index-Nutzung

```
-- Query mit Index
FOR article IN articles
 FILTER article.status == 'published' -- Index genutzt
 AND article.category == 'tech'
 SORT article.published_at DESC
 RETURN article
```

**Ohne Index (langsam!):**

```
FOR article IN articles
 FILTER article.metadata.custom_field == 'value' -- KEIN Index!
 RETURN article
```

### 3. Projection

Nur benötigte Felder laden:

```
Good: Nur Titel und Autor
results = db.query("""
 FOR article IN articles
 FILTER article.status == 'published'
 RETURN {title: article.title, author: article.author}
""")

Bad: Alle Felder (inkl. großer Content)
results = db.query("""
 FOR article IN articles
 FILTER article.status == 'published'
 RETURN article
""")
```

### 4. Batch-Operations

```
Good: Batch insert
articles = [...] # Liste von Dokumenten
for article in articles:
 db.documents.insert("articles", article)

Better: Transaction für Atomicity
with db.transaction():
 for article in articles:
 db.documents.insert("articles", article)
```

## 7.8 Übungen

### Übung 1: Portfolio Website

Erstelle ein Dokumenten-System für eine Portfolio-Website: - Projects mit Screenshots (URLs) - Skills mit Proficiency-Levels - Blog-Posts mit Code-Examples - Contact-Formular History

## Übung 2: Product Catalog

Implementiere einen Produkt-Katalog: - Produkte mit variablen Attributen (Electronics: Screen-Size, Clothing: Sizes) - Kategorien mit Hierarchie - Reviews mit Images - Price-History

## Übung 3: Event Management

Event-System mit: - Events mit Teilnehmern - Schedule mit Sessions - Venue-Details - Feedback-Sammlung

## 7.9 Zusammenfassung

**Document Model in ThemisDB:** - Schema-less für flexible Datenstrukturen - Nested Objects und Arrays - JSON-Operationen (Path-Queries, Updates) - ACID-Transaktionen (vs. MongoDB) - Fulltext-Suche - Migration von MongoDB einfach

**Wann nutzen:** - Content-Management (Blog, Wiki, CMS) - Produkt-Kataloge mit variablen Attributen - User-Profiles mit optionalen Feldern - Config-Dateien mit Verschachtelung - Rapid Prototyping ohne Schema-Definition

**Nächste Schritte:** - Kapitel 8: Vektor-Suche für Semantic Search - Kapitel 9: Time-Series für IoT und Monitoring - Kapitel 10: Geo-Daten für Location-Based Apps

---

**Hands-on Examples:** - [examples/11\\_blog\\_wiki](#) - Vollständiges CMS - [examples/13\\_recipe\\_manager](#) - Recipe-System - Beide mit Schema-Evolution und Nested Data

## Kapitel 8: Kapitel 8 - Vektoren

---

### 8.1 Einführung in Vektor-Suche

#### Das Problem mit traditionellen Suchen

Stellen Sie sich vor, Sie suchen in einer Produktdatenbank nach "bequeme Laufschuhe für den Marathon". Eine traditionelle Keyword-Suche würde nur Produkte finden, die exakt diese Wörter enthalten. Aber was ist mit:

- "Marathon-Schuhe mit optimaler Dämpfung"
- "Komfortable Running-Shoes für lange Strecken"

- "Wettkampf-Laufschuh mit Pronationsstütze"

Diese Produkte sind semantisch relevant, werden aber von Keyword-Suchen oft nicht gefunden. **Vektor-Suche** löst dieses Problem durch semantisches Verständnis.

## Was sind Embeddings?

Ein **Embedding** ist eine hochdimensionale Vektorrepräsentation von Text, Bildern oder anderen Daten.

Ähnliche Konzepte haben ähnliche Vektoren:

```
Beispiel: Text → Vektor (384 Dimensionen)
"Laufschuh" → [0.23, -0.15, 0.89, ..., 0.34] # 384 Werte
"Running Shoe" → [0.21, -0.14, 0.91, ..., 0.36] # Sehr ähnlich!
"Fahrrad" → [-0.67, 0.42, -0.12, ..., 0.78] # Komplette anders
```

**Kosinus-Ähnlichkeit** misst, wie ähnlich zwei Vektoren sind (0 = keine Ähnlichkeit, 1 = identisch).

Abb. 08.1: Vector-Embedding-Pipeline

## Vector Search vs. Fulltext Search

Feature	Fulltext Search	Vector Search
Matching	Exakte Wörter	Semantische Bedeutung
Sprachen	Sprach-abhängig	Sprach-übergreifend
Synonyme	× Muss konfiguriert werden	Automatisch
Schreibfehler	× Keine Treffer	Oft tolerant
Performance	Sehr schnell	Schnell (mit HNSW)
Use Cases	Dokumente, Logs	Empfehlungen, Q&A, Similarity

**Best Practice:** Hybrid Search kombiniert beide Ansätze.

## 8.2 Vector Model in ThemisDB

### Schema und Index

ThemisDB speichert Vektoren als native **VECTOR** Spalten und nutzt **HNSW** (Hierarchical Navigable Small World) für effiziente Suchen:

```
-- Dokumente mit Embeddings
CREATE TABLE documents (
 id UUID PRIMARY KEY,
 title TEXT NOT NULL,
 content TEXT NOT NULL,
 embedding VECTOR(384), -- 384-dimensionaler Vektor
 metadata JSONB,
 created_at TIMESTAMP DEFAULT NOW()
);

-- HNSW-Index für schnelle Similarity Search
CREATE INDEX idx_doc_embedding ON documents
USING hnsw (embedding vector_cosine_ops)
WITH (m = 16, ef_construction = 200);
```

**HNSW-Parameter:** - **m**: Anzahl Verbindungen (höher = bessere Qualität, langsamer Build) -

**ef\_construction**: Exploration während Index-Build (höher = bessere Qualität) -

**vector\_cosine\_ops**: Kosinus-Distanz (alternativ: L2, inner product)

Abb. 08.2: Similarity-Search-Ablauf

### Similarity Search Query

```
-- Finde ähnliche Dokumente zur Query
SELECT id, title,
 1 - (embedding <=> :query_embedding) AS similarity
FROM documents
ORDER BY embedding <=> :query_embedding
LIMIT 10;
```

**Operators:** - **<=>**: Kosinus-Distanz (0 = identisch) - **<->**: L2 (Euklidische) Distanz - **<#>**: Inner Product (negative Distanz)



## Hybrid Search: Vector + Fulltext

Kombiniere semantische und Keyword-Suche:

```
WITH vector_results AS (
 SELECT id, 1 - (embedding <=> :query_embedding) AS vec_score
 FROM documents
 ORDER BY embedding <=> :query_embedding
 LIMIT 50
,
fulltext_results AS (
 SELECT id, ts_rank(to_tsvector('german', content),
 plainto_tsquery('german', :query_text)) AS text_score
 FROM documents
 WHERE to_tsvector('german', content) @@ plainto_tsquery('german', :query_text)
 LIMIT 50
)
SELECT d.*,
 COALESCE(v.vec_score, 0) * 0.7 +
 COALESCE(f.text_score, 0) * 0.3 AS combined_score
FROM documents d
LEFT JOIN vector_results v ON d.id = v.id
LEFT JOIN fulltext_results f ON d.id = f.id
WHERE v.id IS NOT NULL OR f.id IS NOT NULL
ORDER BY combined_score DESC
LIMIT 20;
```

Abb. 08.3: Index-Struktur für Vektoren

## 8.3 Example: Dokumenten-Suche (RAG System)

Wir bauen ein **RAG-System** (Retrieval Augmented Generation) für semantische Dokumentensuche. Der Use Case:

- Dokumente hochladen (PDF, TXT, DOCX)
- Automatische Embedding-Generierung
- Semantische Suche: "Wie funktioniert MVCC?"
- Context für LLMs bereitstellen

## Datenmodell

```
models.py
from dataclasses import dataclass
from datetime import datetime
from typing import List, Optional
import uuid

@dataclass
class Document:
 id: str
 title: str
 content: str
 embedding: Optional[List[float]]
 metadata: dict
 created_at: datetime
 collection: str = "default"

 @staticmethod
 def create(title: str, content: str, metadata: dict = None, collection: str = "default"):
 return Document(
 id=str(uuid.uuid4()),
 title=title,
 content=content,
 embedding=None, # Wird später generiert
 metadata=metadata or {},
 created_at=datetime.now(),
 collection=collection
)

@dataclass
class SearchResult:
 document: Document
 similarity: float
 rank: int
```

## Embedding-Generierung

Wir verwenden **sentence-transformers** für deutsche und englische Texte:

```

themis_client.py
from sentence_transformers import SentenceTransformer
import numpy as np

class ThemisVectorClient:
 def __init__(self, connection_string: str):
 self.conn = connect(connection_string)
 # Multilingual Model (384D)
 self.model = SentenceTransformer('paraphrase-multilingual-MiniLM-L12-v2')

 def generate_embedding(self, text: str) -> List[float]:
 """Generiert 384D Embedding für Text"""
 embedding = self.model.encode(text, convert_to_numpy=True)
 return embedding.tolist()

 def chunk_text(self, text: str, max_words: int = 200) -> List[str]:
 """Teilt langen Text in Chunks für bessere Embeddings"""
 words = text.split()
 chunks = []
 for i in range(0, len(words), max_words):
 chunk = ' '.join(words[i:i + max_words])
 chunks.append(chunk)
 return chunks

 def add_document(self, doc: Document, chunk_size: int = 200):
 """Fügt Dokument mit Embeddings hinzu"""
 # Lange Dokumente in Chunks aufteilen
 chunks = self.chunk_text(doc.content, max_words=chunk_size)

 for i, chunk in enumerate(chunks):
 chunk_id = f"{doc.id}_chunk_{i}"
 embedding = self.generate_embedding(chunk)

 cursor = self.conn.cursor()
 cursor.execute("""
 INSERT INTO documents (id, title, content, embedding, metadata, collection)
 VALUES (?, ?, ?, ?, ?, ?)
 """, (chunk_id, f"{doc.title} (Teil {i+1})", chunk,

```

```
 embedding, json.dumps(doc.metadata), doc.collection))
 self.conn.commit()

 print(f" Dokument '{doc.title}' in {len(chunks)} Chunks gespeichert")
```

## Semantic Search

### Semantic Search

Die semantische Suche nutzt den HNSW-Index für effiziente Nearest-Neighbor-Suche in hochdimensionalen Vektorräumen. Die Ähnlichkeit wird über Cosine Distance berechnet (`1 - (embedding <=> query)`), wobei höhere Werte größere Ähnlichkeit bedeuten. Die Methode unterstützt optionales Collection-Filtering und Minimum-Similarity-Schwellwerte.

**Vollständiger Code:** `examples/08_vector_search/themis_client.py` (ca. 90 Zeilen für search-Methode)

### Kernimplementierung:

```

def search(self, query: str, collection: str = None,
 limit: int = 10, min_similarity: float = 0.5) -> List[SearchResult]:
 """Semantische Suche mit HNSW-Index"""
 # Query zu Embedding konvertieren
 query_embedding = self.generate_embedding(query)

 # Vector-Similarity-Suche via AQL
 sql = """
 SELECT id, title, content, embedding, metadata,
 1 - (embedding <=> ?) AS similarity
 FROM documents
 WHERE (? IS NULL OR collection = ?)
 AND 1 - (embedding <=> ?) >= ?
 ORDER BY embedding <=> ? -- HNSW-Index wird automatisch genutzt!
 LIMIT ?
 """

 cursor.execute(sql, (
 query_embedding, collection, collection,
 query_embedding, min_similarity,
 query_embedding, limit
))

 # Ergebnisse mit Relevanz-Score zurückgeben
 results = []
 for i, row in enumerate(cursor.fetchall(), start=1):
 results.append(SearchResult(
 rank=i,
 document=Document.from_row(row),
 similarity=row['similarity'],
 explanation=f"Cosine similarity: {row['similarity']:.3f}"
))

 return results

```

## Wichtige Konzepte:

1. **Cosine Distance Operator** (): ThemisDB-spezifische Syntax für Vektor-Ähnlichkeit

2. **HNSW-Index automatisch genutzt:** Bei `ORDER BY embedding <=> ?` aktiviert ThemisDB den Index
3. **Optional Filtering:** Collection-Filter nur wenn angegeben (SQL `IS NULL` Pattern)
4. **Minimum Similarity:** Reduziert irrelevante Ergebnisse (`>= 0.5` = mindestens 50% ähnlich)

Die vollständige Methode enthält zusätzlich Error-Handling, Logging und Performance-Metriken.

## RAG-Workflow: Context für LLMs

```
def retrieve_context(self, question: str, max_chunks: int = 5,
 collection: str = None) -> str:
 """Holt relevanten Context für RAG"""
 results = self.search(question, collection=collection,
 limit=max_chunks, min_similarity=0.6)

 if not results:
 return "Keine relevanten Dokumente gefunden."

 # Context zusammenbauen
 context_parts = []
 for result in results:
 context_parts.append(
 f"[{result.document.title}] (Similarity: {result.similarity:.2f})\n"
 f"{result.document.content}\n"
)

 return "\n---\n".join(context_parts)

def answer_question(self, question: str, collection: str = None) -> dict:
 """RAG: Frage + Context → Antwort (Mock ohne LLM)"""
 context = self.retrieve_context(question, collection=collection)

 # In Produktion: context an GPT/Claude/etc. senden
 # response = openai.ChatCompletion.create(...)

 return {
 "question": question,
 "context": context,
 "answer": "⚠ Mock-Antwort: LLM-Integration not implemented",
 "sources": len([r for r in self.search(question, collection, limit=5)])
 }
```



## Hauptprogramm

### Hauptprogramm

Das Hauptprogramm demonstriert typische Vector-Search-Workflows: Dokumente mit Embeddings speichern, semantische Suche durchführen, und ähnliche Dokumente finden. Die Demo-Daten zeigen verschiedene Kategorien (Architektur, Best Practices, Performance) um die semantische Ähnlichkeitserkennung zu illustrieren.

**Vollständiger Code:** `examples/08_vector_search/main.py` (ca. 120 Zeilen)

**Setup und Demo-Daten (Konzept):**

```
from themis_client import ThemisVectorClient
from models import Document

def main():
 client = ThemisVectorClient("themisdb://localhost:9091")
 client.setup_schema()

 # Demo-Dokumente mit verschiedenen Themen
 docs = [
 Document.create(
 title="ThemisDB MVCC Architektur",
 content="ThemisDB verwendet Multi-Version Concurrency Control...",
 metadata={"category": "architecture"},
 collection="docs"
),
 Document.create(
 title="Vector Search Best Practices",
 content="Optimale Chunk-Größen, Index-Tuning, Query-Strategien...",
 metadata={"category": "best-practices"},
 collection="docs"
),
 # ... weitere Demo-Dokumente (siehe vollständige Datei)
]

 # Dokumente einfügen (Embeddings werden automatisch generiert)
 for doc in docs:
 client.insert_document(doc)
```

**Semantische Suche demonstrieren:**

```
Suche: "Wie funktioniert MVCC?"
print("\n=== Semantic Search: 'transaction handling' ===")
results = client.search("transaction handling", limit=5)

for result in results:
 print(f"\nRank {result.rank}: {result.document.title}")
 print(f" Similarity: {result.similarity:.3f}")
 print(f" Snippet: {result.document.content[:100]}...")
```

### Ähnliche Dokumente finden:

```
Finde Dokumente ähnlich zu einem bestimmten Dokument
print("\n=== Similar Documents ===")
base_doc_id = docs[0].id
similar = client.find_similar(base_doc_id, limit=3)

for result in similar:
 print(f" {result.document.title} (similarity: {result.similarity:.3f})")
```

### Erwartete Ausgabe:

```
=== Semantic Search: 'transaction handling' ===

Rank 1: ThemisDB MVCC Architektur
 Similarity: 0.892
 Snippet: ThemisDB verwendet Multi-Version Concurrency Control (MVCC)...

Rank 2: Transaction Isolation Levels
 Similarity: 0.831
 Snippet: Verschiedene Isolation-Level bieten Trade-offs...
```

Die vollständige Implementierung zeigt zusätzlich: - Collection-Filtering - Hybrid-Search (Vector + Keyword) - Performance-Benchmarks - Verschiedene Embedding-Modelle im Vergleich

Das Demo visualisiert, wie semantisch ähnliche Dokumente gefunden werden, auch wenn sie unterschiedliche Wörter verwenden (z.B. "MVCC" ↔ "transaction handling").

**Output**

Füge Dokumente hinzu...

Dokument 'ThemisDB MVCC Architektur' in 1 Chunks gespeichert

Dokument 'Vector Search Best Practices' in 1 Chunks gespeichert

Dokument 'Graph-Algorithmen in ThemisDB' in 1 Chunks gespeichert

=====

Test 1: Semantic Search

Query: 'Wie funktioniert MVCC in ThemisDB?'

[1] ThemisDB MVCC Architektur

Similarity: 0.847

ThemisDB verwendet Multi-Version Concurrency Control (MVCC) für optimistische Trans...

[2] Vector Search Best Practices

Similarity: 0.512

Für optimale Vector Search Performance: 1) Verwenden Sie HNSW-Indexe mit m=16 und e...

Test 2: Hybrid Search (Vector + Fulltext)

Query: 'Graph shortest path algorithms'

[1] Graph-Algorithmen in ThemisDB

Score: 0.823

ThemisDB bietet native Graph-Algorithmen: Dijkstra für kürzeste Pfade, PageRank fü...

[2] Vector Search Best Practices

Score: 0.387

Für optimale Vector Search Performance: 1) Verwenden Sie HNSW-Indexe mit m=16 und e...

Test 3: RAG Context Retrieval

Question: 'Was sind Best Practices für Vector Indexes?'

Context (3 Quellen gefunden):

[Vector Search Best Practices] (Similarity: 0.89)

Für optimale Vector Search Performance: 1) Verwenden Sie HNSW-Indexe mit m=16 und ef\_construction=200. 2) Chunken Sie lange Dokumente in 200-300 Wörter Abschnitte...

Antwort: ⚠ Mock-Antwort: LLM-Integration not implemented

```
Test 4: Suche in spezifischer Collection
Query: 'architecture' in collection 'docs'

Gefunden: 2 Dokumente

- ThemisDB MVCC Architektur (Similarity: 0.78)
- Vector Search Best Practices (Similarity: 0.43)
```

## 8.4 Example: E-Commerce Produktkatalog mit Vector Search

Ein E-Commerce-Shop nutzt Vector Search für "Ähnliche Produkte" und visuelle Suche. Der Use Case:

- Produktdatenbank mit Beschreibungen und Bildern
- "Finde ähnliche Produkte" (Text-Embedding)
- Visuelle Suche (Bild-Embedding)
- Personalisierte Empfehlungen
- Filter + Vector Search kombiniert

## Datenmodell

```
models.py
from dataclasses import dataclass
from typing import List, Optional
import uuid

@dataclass
class Product:
 id: str
 name: str
 description: str
 category: str
 brand: str
 price: float
 text_embedding: Optional[List[float]] # Text-basiert
 image_embedding: Optional[List[float]] # Bild-basiert (CLIP)
 tags: List[str]
 rating: float
 stock: int

 @staticmethod
 def create(name: str, description: str, category: str,
 brand: str, price: float, tags: List[str] = None):
 return Product(
 id=str(uuid.uuid4()),
 name=name,
 description=description,
 category=category,
 brand=brand,
 price=price,
 text_embedding=None,
 image_embedding=None,
 tags=tags or [],
 rating=0.0,
 stock=100
)
```

## ThemisDB Schema

```
CREATE TABLE products (
 id UUID PRIMARY KEY,
 name TEXT NOT NULL,
 description TEXT NOT NULL,
 category TEXT NOT NULL,
 brand TEXT NOT NULL,
 price DECIMAL(10,2) NOT NULL,
 text_embedding VECTOR(384), -- Text-Embedding
 image_embedding VECTOR(512), -- Bild-Embedding (CLIP)
 tags TEXT[] NOT NULL,
 rating DECIMAL(3,2) DEFAULT 0,
 stock INTEGER DEFAULT 0,
 created_at TIMESTAMP DEFAULT NOW()
);

-- Indexes für Hybrid Search
CREATE INDEX idx_product_text_emb ON products
USING hnsw (text_embedding vector_cosine_ops)
WITH (m = 16, ef_construction = 200);

CREATE INDEX idx_product_image_emb ON products
USING hnsw (image_embedding vector_cosine_ops)
WITH (m = 16, ef_construction = 200);

CREATE INDEX idx_product_fulltext ON products
USING gin(to_tsvector('german', name || ' ' || description));

CREATE INDEX idx_product_category ON products(category);
CREATE INDEX idx_product_price ON products(price);
```



## Ähnliche Produkte finden

```

themis_client.py
class ProductCatalogClient:
 def __init__(self, connection_string: str):
 self.conn = connect(connection_string)
 self.text_model = SentenceTransformer('paraphrase-multilingual-MiniLM-L12-v2')

 def add_product(self, product: Product):
 """Fügt Produkt mit Text-Embedding hinzu"""
 # Text-Embedding aus Name + Description
 text = f"{product.name}. {product.description}"
 product.text_embedding = self.text_model.encode(text).tolist()

 cursor = self.conn.cursor()
 cursor.execute("""
 INSERT INTO products
 (id, name, description, category, brand, price,
 text_embedding, tags, stock)
 VALUES (?, ?, ?, ?, ?, ?, ?, ?, ?)
 """, (product.id, product.name, product.description,
 product.category, product.brand, product.price,
 product.text_embedding, product.tags, product.stock))
 self.conn.commit()

 print(f" Produkt '{product.name}' hinzugefügt")

 def find_similar_products(self, product_id: str, limit: int = 5) -> List:
 """Findet ähnliche Produkte basierend auf Text-Embedding"""
 cursor = self.conn.cursor()

 # Hole Embedding des Referenz-Produkts
 cursor.execute("""
 FOR product IN products
 FILTER product.id == @product_id
 LIMIT 1
 RETURN product.text_embedding
 """, {"product_id": product_id})
 ref_embedding = cursor.fetchone()[0]

```

```

Finde ähnliche Produkte
cursor.execute("""
 SELECT id, name, description, price, category,
 1 - (text_embedding <=> ?) AS similarity
 FROM products
 WHERE id != ?
 ORDER BY text_embedding <=> ?
 LIMIT ?
""", (ref_embedding, product_id, ref_embedding, limit))

return cursor.fetchall()

def search_with_filters(self, query: str, category: str = None,
 min_price: float = None, max_price: float = None,
 limit: int = 20) -> List:
 """Hybrid Search mit Filtern"""
 query_embedding = self.text_model.encode(query).tolist()

 # Dynamisches AQL mit optionalen Filtern
 filters = ["1=1"]
 params = [query_embedding, query_embedding]

 if category:
 filters.append("category = ?")
 params.append(category)
 if min_price is not None:
 filters.append("price >= ?")
 params.append(min_price)
 if max_price is not None:
 filters.append("price <= ?")
 params.append(max_price)

 params.extend([query, limit])

 sql = f"""
 WITH vector_scores AS (
 SELECT id, 1 - (text_embedding <=> ?) AS vec_score
 FROM products

```

```

 WHERE {' AND '.join(filters)}
 ORDER BY text_embedding <=> ?
 LIMIT 100
)
 SELECT p.id, p.name, p.description, p.price, p.category,
 v.vec_score
 FROM products p
 JOIN vector_scores v ON p.id = v.id
 WHERE to_tsvector('german', p.name || ' ' || p.description)
 @@ plainto_tsquery('german', ?)
 ORDER BY v.vec_score DESC
 LIMIT ?
"""

cursor = self.conn.cursor()
cursor.execute(sql, params)
return cursor.fetchall()

```

## Hauptprogramm

## Hauptprogramm

Das Product-Catalog-Beispiel zeigt Vector Search im E-Commerce-Kontext. Produktbeschreibungen werden als Embeddings gespeichert, sodass Kunden Produkte semantisch finden können ("Schuhe für Marathon" findet "Laufschuhe mit React-Dämpfung"), auch ohne exakte Keyword-Matches.

**Vollständiger Code:** `examples/08_product_catalog/main.py` (ca. 120 Zeilen)

## E-Commerce Demo-Setup:

```
from themis_client import ProductCatalogClient
from models import Product

def main():
 client = ProductCatalogClient("themisdb://localhost:9091")

 # Demo-Produkte verschiedener Kategorien
 products = [
 Product.create(
 name="Nike Air Zoom Pegasus 40",
 description="Leichter Laufschuh für lange Strecken mit React-Dämpfung",
 category="Laufschuhe",
 brand="Nike",
 price=139.99,
 tags=["running", "cushion", "marathon"]
),
 Product.create(
 name="Adidas Ultraboost 23",
 description="Energierückgebender Running-Schuh mit Boost-Technologie",
 category="Laufschuhe",
 brand="Adidas",
 price=189.99,
 tags=["running", "boost", "comfort"]
),
 # ... weitere Produkte (Trekkingsschuhe, Wanderschuhe, etc.)
]

 for product in products:
 client.insert_product(product)
```

### Semantische Produktsuche:

```
Kunde sucht: "Schuhe für lange Läufe"
print("\n=== Product Search: 'Schuhe für lange Läufe' ===")
results = client.search_products("Schuhe für lange Läufe", limit=5)

for result in results:
 product = result.document
 print(f"\n{product.name} ({product.brand})")
 print(f" Preis: €{product.price:.2f}")
 print(f" Match: {result.similarity:.1%}")
 print(f" {product.description}")
```

**Erwartete Ausgabe:**

```
=== Product Search: 'Schuhe für lange Läufe' ===

Nike Air Zoom Pegasus 40 (Nike)
 Preis: €139.99
 Match: 89.2%
 Leichter Laufschuh für lange Strecken mit React-Dämpfung

Adidas Ultraboost 23 (Adidas)
 Preis: €189.99
 Match: 86.7%
 Energierückgebender Running-Schuh mit Boost-Technologie
```

**"Mehr wie dieses" Feature:**

```
Finde ähnliche Produkte
print("\n=== Similar Products ===")
similar = client.find_similar_products(products[0].id, limit=3)

for result in similar:
 print(f" {result.document.name} - {result.similarity:.1%} ähnlich")
```

Die vollständige Implementation zeigt zusätzlich: - Filter nach Kategorie + Preisbereich - Hybrid-Search (Semantic + Attribute-Filter) - Personalisierte Empfehlungen - A/B-Testing verschiedener Embedding-Modelle

**Vorteile von Vector Search im E-Commerce:** - Kunden finden Produkte auch mit ungenauen Beschreibungen - "Mehr wie dieses" basiert auf semantischer Ähnlichkeit - Mehrsprachige Suche ohne separate Übersetzungen - Neue Produkte sofort suchbar (kein manuelles Tagging nötig)

**Output**



Füge Produkte hinzu...

Produkt 'Nike Air Zoom Pegasus 40' hinzugefügt

Produkt 'Adidas Ultraboost 23' hinzugefügt

Produkt 'Asics Gel-Nimbus 25' hinzugefügt

Produkt 'New Balance Fresh Foam X 1080v13' hinzugefügt

Produkt 'Nike Metcon 9' hinzugefügt

Produkt 'Adidas Terrex Free Hiker' hinzugefügt

=====

Test 1: Ähnliche Produkte

Referenz: Nike Air Zoom Pegasus 40

Ähnliche Produkte:

[1] Asics Gel-Nimbus 25 (Laufschuhe)

Preis: €169.99 | Similarity: 0.891

Stabiler Marathon-Laufschuh mit Gel-Dämpfung für Langstrecken...

[2] New Balance Fresh Foam X 1080v13 (Laufschuhe)

Preis: €179.99 | Similarity: 0.867

Premium Laufschuh mit Fresh Foam für maximalen Komfort...

[3] Adidas Ultraboost 23 (Laufschuhe)

Preis: €189.99 | Similarity: 0.843

Energierückgebender Running-Schuh mit Boost-Technologie...

Test 2: Suche mit Filtern

Query: 'bequeme Schuhe für Marathon'

Filter: Kategorie='Laufschuhe', Preis < €180

Ergebnisse (3):

[1] Asics Gel-Nimbus 25

Preis: €169.99 | Score: 0.912

Stabiler Marathon-Laufschuh mit Gel-Dämpfung für Langstrecken...

[2] New Balance Fresh Foam X 1080v13

Preis: €179.99 | Score: 0.889

Premium Laufschuh mit Fresh Foam für maximalen Komfort...

[3] Nike Air Zoom Pegasus 40

Preis: €139.99 | Score: 0.856

Leichter Laufschuh für lange Strecken mit React-Dämpfung...

Test 3: Cross-Category Similarity

Query: 'Schuhe für lange Distanzen'

Ergebnisse (5):

[1] Asics Gel-Nimbus 25 (Laufschuhe)

Preis: €169.99 | Score: 0.923

[2] Nike Air Zoom Pegasus 40 (Laufschuhe)

Preis: €139.99 | Score: 0.897

[3] New Balance Fresh Foam X 1080v13 (Laufschuhe)

Preis: €179.99 | Score: 0.876

[4] Adidas Terrex Free Hiker (Wanderschuhe)

Preis: €199.99 | Score: 0.734

[5] Adidas Ultraboost 23 (Laufschuhe)

Preis: €189.99 | Score: 0.712

**Beobachtungen:** - Vector Search findet semantisch ähnliche Produkte, auch über Kategorien hinweg -  
Der Wanderschuh wird bei "lange Distanzen" gefunden (semantische Nähe!) - Filter reduzieren  
Ergebnisse effizient - Similarity Scores zeigen Relevanz deutlich

## 8.5 Embedding-Modelle und Integration

### Beliebte Embedding-Modelle

Modell	Dimensionen	Sprachen	Use Case
<b>paraphrase-multilingual-MiniLM-L12-v2</b>	384	50+	Allgemein, schnell
<b>all-MiniLM-L6-v2</b>	384	EN	Schnell, gut für Englisch
<b>all-mpnet-base-v2</b>	768	EN	Beste Qualität (Englisch)
<b>distiluse-base-multilingual-cased-v2</b>	512	15+	Multilingual, mittel
<b>CLIP (OpenAI)</b>	512/768	Bild+Text	Visuelle Suche
<b>text-embedding-ada-002 (OpenAI)</b>	1536	多语言	API, sehr gut

## OpenAI Embeddings Integration

```
import openai

class OpenAIEmbeddingClient:
 def __init__(self, api_key: str, connection_string: str):
 openai.api_key = api_key
 self.conn = connect(connection_string)

 def generate_embedding(self, text: str) -> List[float]:
 """OpenAI text-embedding-ada-002 (1536D)"""
 response = openai.Embedding.create(
 model="text-embedding-ada-002",
 input=text
)
 return response['data'][0]['embedding']

 def add_document_openai(self, doc: Document):
 """Dokument mit OpenAI Embedding"""
 embedding = self.generate_embedding(doc.content)

 cursor = self.conn.cursor()
 cursor.execute("""
 INSERT INTO documents_openai
 (id, title, content, embedding, metadata)
 VALUES (?, ?, ?, ?, ?)
 """, (doc.id, doc.title, doc.content,
 embedding, json.dumps(doc.metadata)))
 self.conn.commit()
```

**Schema für OpenAI Embeddings:**

```
CREATE TABLE documents_openai (
 id UUID PRIMARY KEY,
 title TEXT,
 content TEXT,
 embedding VECTOR(1536), -- OpenAI ada-002
 metadata JSONB
);

CREATE INDEX idx_docs_openai_emb ON documents_openai
USING hnsw (embedding vector_cosine_ops)
WITH (m = 16, ef_construction = 200);
```

## Hugging Face Models

```
from transformers import AutoTokenizer, AutoModel
import torch

class HuggingFaceEmbeddingClient:
 def __init__(self, model_name: str = "sentence-transformers/all-MiniLM-L6-v2"):
 self.tokenizer = AutoTokenizer.from_pretrained(model_name)
 self.model = AutoModel.from_pretrained(model_name)

 def mean_pooling(self, model_output, attention_mask):
 """Mean Pooling für Sentence Embedding"""
 token_embeddings = model_output[0]
 input_mask_expanded = attention_mask.unsqueeze(-1).expand(token_embeddings.size()).float()
 return torch.sum(token_embeddings * input_mask_expanded, 1) / torch.clamp(input_mask_expanded.sum(1), min=1e-9)

 def generate_embedding(self, text: str) -> List[float]:
 """Generiert Embedding mit HuggingFace Model"""
 encoded_input = self.tokenizer(text, padding=True, truncation=True, return_tensors='pt')

 with torch.no_grad():
 model_output = self.model(**encoded_input)

 sentence_embeddings = self.mean_pooling(model_output, encoded_input['attention_mask'])
 sentence_embeddings = torch.nn.functional.normalize(sentence_embeddings, p=2, dim=1)

 return sentence_embeddings[0].tolist()
```

## 8.6 Performance-Optimierung

### HNSW Index Tuning

```
-- Standard (guter Balance)
CREATE INDEX idx_standard ON documents
USING hnsw (embedding vector_cosine_ops)
WITH (m = 16, ef_construction = 200);

-- Schneller Build, niedrigere Qualität
CREATE INDEX idx_fast_build ON documents
USING hnsw (embedding vector_cosine_ops)
WITH (m = 8, ef_construction = 100);

-- Langsamer Build, höhere Qualität
CREATE INDEX idx_high_quality ON documents
USING hnsw (embedding vector_cosine_ops)
WITH (m = 32, ef_construction = 400);
```

**Parameter-Effekte:** - `m`: Anzahl Verbindungen pro Layer (mehr = besser, aber langsamer) -

`ef_construction`: Exploration während Build (höher = besser, länger Build) - Faustregel: `m = 16`

und `ef_construction = 200` für die meisten Use Cases

### Query-Time Performance

```
-- Setze ef_search für Query-Zeit (höher = genauer, langsamer)
SET hnsw.ef_search = 100; -- Standard: 40

-- Dann normale Query
SELECT id, 1 - (embedding <=> :query_vec) AS similarity
FROM documents
ORDER BY embedding <=> :query_vec
LIMIT 10;
```

## Batch-Processing

```
def add_documents_batch(self, documents: List[Document], batch_size: int = 100):
 """Batch-Insert für Performance"""
 for i in range(0, len(documents), batch_size):
 batch = documents[i:i + batch_size]

 # Embeddings für Batch generieren
 texts = [f"{doc.title}. {doc.content}" for doc in batch]
 embeddings = self.model.encode(texts, batch_size=batch_size)

 # Batch-Insert
 cursor = self.conn.cursor()
 for doc, embedding in zip(batch, embeddings):
 cursor.execute("""
 INSERT INTO documents (id, title, content, embedding, metadata)
 VALUES (?, ?, ?, ?, ?)
 """, (doc.id, doc.title, doc.content,
 embedding.tolist(), json.dumps(doc.metadata)))

 self.conn.commit()
 print(f" Batch {i//batch_size + 1}: {len(batch)} Dokumente")
```

## 8.7 Best Practices

### 1. Chunking-Strategie

**Problem:** Lange Dokumente führen zu schlechten Embeddings.

**Lösung:** Teilen Sie Dokumente in 200-300 Wörter Chunks:



```
def smart_chunk(text: str, max_words: int = 250, overlap: int = 50) -> List[str]:
 """Chunking mit Overlap für Context"""
 words = text.split()
 chunks = []

 for i in range(0, len(words), max_words - overlap):
 chunk = ' '.join(words[i:i + max_words])
 chunks.append(chunk)

 return chunks
```

## 2. Normalisierung

Normalisieren Sie Vektoren für Kosinus-Distanz:

```
import numpy as np

def normalize_vector(vec: List[float]) -> List[float]:
 """L2-Normalisierung"""
 arr = np.array(vec)
 norm = np.linalg.norm(arr)
 if norm == 0:
 return vec
 return (arr / norm).tolist()
```

## 3. Hybrid Search ist King

Kombinieren Sie immer Vector + Fulltext:

```
70% Vector, 30% Fulltext ist oft optimal
alpha = 0.7
combined_score = alpha * vector_score + (1 - alpha) * fulltext_score
```

## 4. Re-Ranking

Für höchste Qualität: Hole 100 Kandidaten, re-ranke Top 20:

```
def search_with_rerank(self, query: str, limit: int = 20):
 """Vector Search + Cross-Encoder Re-Ranking"""
 # Phase 1: Vector Search (schnell, grob)
 candidates = self.search(query, limit=100)

 # Phase 2: Re-Rank mit Cross-Encoder (genau, langsam)
 from sentence_transformers import CrossEncoder
 reranker = CrossEncoder('cross-encoder/ms-marco-MiniLM-L-6-v2')

 pairs = [[query, c.document.content] for c in candidates]
 scores = reranker.predict(pairs)

 # Sortiere nach Re-Rank Score
 ranked = sorted(zip(candidates, scores),
 key=lambda x: x[1], reverse=True)

 return [r[0] for r in ranked[:limit]]
```

## 5. Monitoring & Debugging

```
def analyze_search_quality(self, query: str, expected_result_ids: List[str]):
 """Analyse Search Quality"""
 results = self.search(query, limit=20)

 # Precision@K
 found_ids = [r.document.id for r in results[:10]]
 precision_at_10 = len(set(found_ids) & set(expected_result_ids)) / 10

 # Mean Reciprocal Rank (MRR)
 for i, result in enumerate(results, 1):
 if result.document.id in expected_result_ids:
 mrr = 1.0 / i
 break
 else:
 mrr = 0.0

 print(f"Query: {query}")
 print(f" Precision@10: {precision_at_10:.2%}")
 print(f" MRR: {mrr:.3f}")
 print(f" Top Result Similarity: {results[0].similarity:.3f}")
```

## 8.8 Vergleich: ThemisDB vs. Spezialisierte Vector DBs

Feature	ThemisDB	Pinecone	Weaviate	Qdrant
Vector Search	HNSW	Proprietary	HNSW	HNSW
Relational Data	Native	× Nicht verfügbar	Basic	× Nicht verfügbar
Graph Queries	Native	× Nicht verfügbar	× Nicht verfügbar	× Nicht verfügbar
Fulltext Search	Native	Limited	Ja	Basic
ACID Transactions	Ja	× Nein	× Nein	× Nein
Hybrid Search	Native AQL	API	GraphQL	API
Self-Hosted	Ja	× Cloud-only	Ja	Ja
Pricing	Open Source	\$\$\$\$	Open Source	Open Source
Best For	Multi-Model Apps	Pure Vector	ML Pipelines	High Performance

**ThemisDB Vorteil:** Wenn Sie Vector Search **und** relationale/graph Daten brauchen, ist ThemisDB die einzige Datenbank, die alles nativ bietet.

## 8.9 Übungen

### Übung 1: FAQ-Bot

Bauen Sie einen FAQ-Bot: - Laden Sie 20 FAQ-Paare (Frage + Antwort) - Bei User-Frage: Finde ähnlichste FAQ - Geben Sie die Antwort zurück - **Bonus:** Hybrid Search (Vector + Keyword)

### Übung 2: Image Search

Erweitern Sie den E-Commerce Katalog: - Nutzen Sie CLIP für Bild-Embeddings - "Finde ähnliche Produkte zu diesem Bild" - Cross-Modal Search: Text Query → Bild Results

### Übung 3: Multi-Collection RAG

Bauen Sie ein System mit mehreren Collections: - `technical_docs`, `marketing`, `legal` - User wählt Collection - RAG-Workflow liefert nur relevante Collection-Dokumente

## 8.10 Zusammenfassung

### Was wir gelernt haben:

#### 1. Vector Search Grundlagen

- 2. Embeddings repräsentieren Semantik als Vektoren
- 3. Kosinus-Ähnlichkeit misst Relevanz
- 4. HNSW-Index für effiziente Suche

#### 5. ThemisDB Vector Model

- 6. Native `VECTOR(n)` Spalten
- 7. HNSW-Indexe mit konfigurierbaren Parametern
- 8. Operators: `<=>`, `<->`, `<#>`

#### 9. RAG-System Implementation

- 10. Dokumente in Chunks aufteilen
- 11. Automatische Embedding-Generierung
- 12. Context-Retrieval für LLMs

#### 13. E-Commerce Vector Search

- 14. Ähnliche Produkte finden
- 15. Hybrid Search mit Filtern
- 16. Cross-Category Similarity

#### 17. Best Practices

- 18. Chunking: 200-300 Wörter
- 19. Hybrid Search: Vector + Fulltext
- 20. Re-Ranking für höchste Qualität
- 21. Batch-Processing für Performance

**Key Takeaway:** ThemisDB kombiniert Vector Search mit relationalen, Graph- und Dokument-Features in einer Datenbank – perfekt für moderne Multi-Model Anwendungen.

**Nächster Schritt:** In Teil III (Spezialanwendungen) lernen wir Time-Series, Geo-Spatial und Enterprise-Features kennen.

---

Ende Kapitel 8 | ➔ [Weiter zu Kapitel 9: Time-Series](#)

# Kapitel 8: Kapitel 8b - Storage Layer

---

**Kategorie:** Storage & Performance

**Lesezeit:** ~45 Minuten

**Zielgruppe:** Database Engineers, Performance Engineers, Production DBA

---

## Inhaltsverzeichnis

- [8.1 RocksDB Storage Architecture](#)
  - [8.2 Memory Management mit mimalloc](#)
  - [8.3 Huge Pages Optimization](#)
  - [8.4 Compression Strategies](#)
  - [8.5 Storage Hierarchy Tuning](#)
  - [8.6 Production Deployment Patterns](#)
  - [8.7 Performance Benchmarks](#)
- 

## 8.1 RocksDB Storage Architecture

ThemisDB nutzt RocksDB als zentrale Storage-Engine für alle Datenmodelle. Die Architektur basiert auf einem präzisen Key-Präfix-Schema, das Multi-Model-Daten logisch separiert und dabei physisch ko-lokalisiert für optimale Cache-Locality.

### 8.1.1 Key-Space Design

Das Präfix-Schema ermöglicht effiziente Range-Scans und Prefix-Extraktion:

Entities (Base Entity Blobs):	entity:<table>:<pk>
Secondary Index:	idx:<table>:<column>:<value>:<pk>
Range Index:	ridx:<table>:<column>:<value>:<pk>
Graph Adjacency (Outbound):	graph:out:<from_pk>:<edge_id>
Graph Adjacency (Inbound):	graph:in:<to_pk>:<edge_id>
Vector Index Metadata:	vector:<table>:<pk>
Changefeed Events:	changefeed:<sequence>
Time-Series Metrics:	ts:<metric>:<timestamp>:<tags>

### Design-Rationale:

- **Sortierte Speicherung:** LSM-Tree garantiert lexikographische Ordnung → Range-Scans ohne Index
- **Prefix-Extraktion:** RocksDB Prefix-Extractor ermöglicht Bloom-Filter auf Collection-Ebene
- **Co-Location:** Related Data (z.B. alle Indizes einer Tabelle) wird physisch nah gespeichert

Abb. 08.1: Storage-Engine-Internals

### Code-Beispiel: Prefix-Extractor-Konfiguration

```
#include <rocksdb/slice_transform.h>

// Custom Prefix Extractor für ThemisDB Key-Schema
class ThemisKeyPrefixExtractor : public rocksdb::SliceTransform {
public:
 const char* Name() const override { return "ThemisKeyPrefixExtractor"; }

 rocksdb::Slice Transform(const rocksdb::Slice& src) const override {
 // Extrahiere "entity:<table>:" oder "idx:<table>:<column>:"
 size_t second_colon = src.ToString().find(':', 0);
 if (second_colon == std::string::npos) return src;

 size_t third_colon = src.ToString().find(':', second_colon + 1);
 if (third_colon == std::string::npos) return src;

 return rocksdb::Slice(src.data(), third_colon + 1);
 }

 bool InDomain(const rocksdb::Slice& src) const override {
 return src.size() > 0 && src[0] != '\\0';
 }
};

// Anwendung in RocksDB Options
rocksdb::Options options;
options.prefix_extractor.reset(new ThemisKeyPrefixExtractor());
```

**Performance-Impact:** Prefix-Extraktion reduziert Bloom-Filter-False-Positives um ~85% bei Collection-Scans.

## 8.1.2 Column Families Strategy

**Standard-Betrieb:** Default Column Family (CF)

ThemisDB verwendet standardmäßig eine einzige Default CF für alle Daten. Dies vereinfacht Transaktionen (atomare Snapshots über alle Datenmodelle) und Backups.

**Optional: Multi-CF für große Workloads**



Bei Workloads > 500 GB oder stark unterschiedlichen Hot/Cold-Profilen kann CF-Trennung LSM-Compactions isolieren:

```
cf_entities: Base Entity Blobs (häufig gelesen/geschrieben)
cf_indexes: Secondary Indexes (read-heavy)
cf_graph: Graph Adjazenz-Listen (scan-heavy)
cf_changefeed: CDC Events (append-only, TTL-basiert)
cf_timeseries: Metriken (high-write, TTL)
```

#### Trade-offs:

Aspekt	Single CF	Multi-CF
<b>Transaktionen</b>	Einfach (single snapshot)	⚠ Komplex (koordinierte snapshots)
<b>Compaction</b>	⚠ Write Amplification bei Mixed Workload	Isolierte Compaction
<b>Memory</b>	Shared Block Cache	⚠ Per-CF Caches (Overhead)
<b>Backups</b>	Einfach	⚠ Konsistenz über CFs sicherstellen

**Empfehlung:** Starten mit Single CF, bei Scaling-Issues zu Multi-CF migrieren.

### 8.1.3 Write-Ahead Log (WAL) Best Practices

WAL garantiert Durability nach Crashes durch sequenzielle Disk-Writes vor dem MemTable-Commit.

#### Kritische Konfigurationen:

```
rocksdb::Options options;

// 1. WAL-Sync-Strategie
rocksdb::WriteOptions write_opts;
write_opts.sync = true; // fsync() nach jedem Write (max Durability)
// Alternativ: write_opts.sync = false + options.wal_bytes_per_sync = 1MB

// 2. WAL-Größen-Management
options.max_total_wal_size = 4GB; // Verhindert unbegrenztes WAL-Wachstum
options.wal_bytes_per_sync = 1 * 1024 * 1024; // 1MB Batching für fsync()

// 3. WAL-Directory auf separater NVMe
options.wal_dir = "/nvme/fast/wal"; // 45K writes/sec vs 200 writes/sec HDD
```

### Performance-Zahlen:

Storage	WAL Throughput	Latenz (p99)
NVMe PCIe 4.0	45.000 writes/sec	1-5ms
SATA SSD	12.000 writes/sec	5-10ms
HDD 7200 RPM	200 writes/sec	10-20ms

### Crash Recovery:

1. **Replay:** RocksDB liest WAL sequentiell und rekonstruiert MemTable
2. **Checkpointing:** Alte WAL-Dateien werden nach SSTable-Flush gelöscht
3. **Validation:** MANIFEST-Datei trackt alle gültigen SSTables

### Code-Beispiel: WAL-Replay nach Crash

```
// Automatisch bei DB-Open
rocksdb::Status s = rocksdb::DB::Open(options, db_path, &db);
if (!s.ok()) {
 if (s.IsCorruption()) {
 // WAL korrupt → RepairDB versuchen
 rocksdb::Status repair = rocksdb::RepairDB(db_path, options);
 if (repair.ok()) {
 // Retry Open nach Repair
 s = rocksdb::DB::Open(options, db_path, &db);
 }
 }
}
```

### 8.1.4 MVCC Snapshots und Long-Running Transactions

RocksDB nutzt Snapshot Isolation für Transaktionen. Jeder Snapshot fixiert ein Sichtfenster auf die DB.

**Problem: Long-Running Snapshots erhöhen Read Amplification**

MemTable → L0 SSTable → L1 SSTable → ... → L6 SSTable

↑	↑	↑	↑
Snapshot t=0	t=100	t=200	t=500

→ Snapshot t=0 verhindert Compaction von L0-L6 für 500 Zeiteinheiten

→ Read Amplification: Muss alle Levels durchsuchen

**Monitoring:**

```
// Prometheus Metrics für Snapshot-Tracking
uint64_t oldest_snapshot_time = db->GetSnapshot()->GetSequenceNumber();
uint64_t current_sequence = db->GetLatestSequenceNumber();
uint64_t snapshot_age = current_sequence - oldest_snapshot_time;

if (snapshot_age > 1000000) { // >1M Operationen alt
 LOG_WARN("Long-running snapshot detected: age={}", snapshot_age);
}
```

**Mitigation:**

1. **Transaktions-Timeouts:** Automatisches Rollback nach 60s
2. **Snapshot-Cleanup:** `cleanupOldTransactions()` API
3. **Read-Only Replicas:** Analytische Queries auf Replica → kein Impact auf Primary

## 8.2 Memory Management mit mimalloc

### 8.2.1 Warum mimalloc statt Standard-Allocator?

ThemisDB nutzt **mimalloc v2.1.7** (<https://github.com/microsoft/mimalloc>) als Drop-in-Replacement für malloc/free. Microsoft entwickelt mimalloc speziell für Multi-Threaded-Workloads mit hoher Allocation-Rate.

**Performance-Vorteile:**

Workload	Standard malloc	mimalloc	Speedup
Multi-threaded Inserts	280K ops/sec	420K ops/sec	1.5x
Memory Throughput	8.5 GB/sec	12.2 GB/sec	1.43x
Fragmentation	18%	7%	2.6x besser
Peak Memory	4.2 GB	3.8 GB	10% weniger

**Technische Eigenschaften:**

- **Thread-Local Heaps:** Jeder Thread hat eigenen Heap → keine Contention
- **Small Object Optimization:** Dedizierte Pools für 8B, 16B, 32B, ..., 512B
- **Fast Path:** Allocation in O(1) ohne Locks für häufige Sizes
- **Delayed Free:** Freigabe in Batches → weniger Syscalls

### 8.2.2 Integration in ThemisDB

**CMakeLists.txt:**

```
mimalloc Dependency
find_package(mimalloc 2.1 CONFIG REQUIRED)

target_link_libraries(themis_core PRIVATE mimalloc-static)

Optional: Override global malloc/free
target_compile_definitions(themis_core PRIVATE MI_OVERRIDE)
```

**C++ Code:**

```
// Automatische Override durch Include
#include <mimalloc-override.h>

// Ab jetzt nutzen ALLE Allocations mimalloc (auch in RocksDB, HNSW, etc.)
auto vec = std::make_unique<std::vector<int>>>(1000000); // Nutzt mimalloc
```

**Keine Code-Änderungen erforderlich** → Drop-in-Replacement!

## 8.2.3 Tuning-Optionen

mimalloc kann via Environment-Variables konfiguriert werden:

```
Production-Setup
export MIMALLOC_VERBOSE=0 # Keine Debug-Logs
export MIMALLOC_SHOW_STATS=0 # Stats deaktivieren
export MIMALLOC_PAGE_RESET=1 # Aggressive Memory Return
export MIMALLOC_EAGER_COMMIT_DELAY=0 # Sofort OS-Pages commiten
export MIMALLOC_RESERVE_HUGE_OS_PAGES=8 # 8× 2MB Huge Pages reservieren

./themis_server --config production.json
```

**Empfehlungen:**

- **Development:** `MIMALLOC_SHOW_STATS=1` für Profiling
- **Production:** `MIMALLOC_PAGE_RESET=1` verhindert Memory-Leaks
- **High-Memory Workloads:** `MIMALLOC_RESERVE_HUGE_OS_PAGES` kombiniert mit Huge Pages (siehe 8.3)

## 8.2.4 Benchmark-Ergebnisse

**Setup:** 1M Entity Inserts mit parallelen Reads

Benchmark: Mixed OLTP Workload (8 Threads)

	malloc	mimalloc	Improvement
Insert Throughput	280K ops/s	420K ops/s	+50%
Read Latency (p50)	1.8ms	1.2ms	-33%
Memory RSS	4.2 GB	3.8 GB	-10%
CPU Usage	65%	58%	-11%

### Code-Snippet für Benchmark:

```
#include <benchmark/benchmark.h>
#include <mimalloc-override.h>

static void BM_EntityInsert(benchmark::State& state) {
 ThemisDB db("test.db");

 for (auto _ : state) {
 std::string key = "entity:users:" + std::to_string(state.iterations());
 std::string value = generateRandomEntity(2048); // 2KB Entity
 db.put(key, value);
 }

 state.SetItemsProcessed(state.iterations());
}

BENCHMARK(BM_EntityInsert)->Threads(8)->UseRealTime();
```

## 8.3 Huge Pages Optimization

### 8.3.1 Problem: TLB Thrashing bei großen Caches

Standard-Linux-Pages sind 4KB groß. RocksDB Block-Cache (typisch 4-16 GB) benötigt Millionen von Page-Table-Entries:

```
Block Cache: 8 GB = 8 * 1024 MB = 8192 MB
Pages (4KB): 8192 MB / 4 KB = 2.097.152 Pages
TLB Entries: ~1.024 (Intel x86-64)

→ TLB Miss Rate: ~99.95% → Massive Performance-Einbußen
```

### Solution: Huge Pages (2MB statt 4KB)

```
Pages (2MB): 8192 MB / 2 MB = 4.096 Pages
TLB Entries: 512 (dedizierte Huge Page TLB)

→ TLB Hit Rate: ~88% → 10-15% Performance-Gewinn
```

### 8.3.2 Huge Pages Konfiguration (Linux)

#### Schritt 1: Huge Pages reservieren

```
Prüfe aktuelle Konfiguration
cat /proc/meminfo | grep Huge
HugePages_Total: 0
HugePages_Free: 0
Hugepagesize: 2048 kB

Reserviere 4096× 2MB = 8 GB Huge Pages
echo 4096 | sudo tee /proc/sys/vm/nr_hugepages

Permanent (in /etc/sysctl.conf)
sudo bash -c 'echo "vm.nr_hugepages = 4096" >> /etc/sysctl.conf'
sudo sysctl -p
```

## Schritt 2: ThemisDB mit Huge Pages starten

```
// RocksDB unterstützt Huge Pages nativ
rocksdb::Options options;
options.allow_mmap_reads = false; // Wichtig: Disable mmap für Huge Pages
options.use_direct_reads = false;
options.use_direct_io_for_flush_and_compaction = false;

// Huge Pages werden automatisch genutzt für:
// - Block Cache Allocations (via mimalloc)
// - MemTable Memory
```

### mimalloc Huge Pages Integration:

```
mimalloc nutzt Huge Pages automatisch
export MIMALLOC_RESERVE_HUGE_OS_PAGES=4096 # 4096× 2MB = 8GB
export MIMALLOC_EAGER_COMMIT=1 # Immediate OS Page Commit

./themis_server
```

## 8.3.3 Verification

### Prüfen ob Huge Pages genutzt werden:

```
Während ThemisDB läuft
cat /proc/<PID>/smaps | grep -A 10 "huge"

Expected Output:
KernelPageSize: 2048 kB
MMUPageSize: 2048 kB
AnonHugePages: 8388608 kB # 8 GB
```

### Benchmark-Verifikation:



```
#include <benchmark/benchmark.h>

static void BM_CacheLookup(benchmark::State& state) {
 // 4GB Cache mit Random Lookups
 std::vector<char> cache(4LL * 1024 * 1024 * 1024);
 std::mt19937_64 rng;

 for (auto _ : state) {
 size_t idx = rng() % cache.size();
 benchmark::DoNotOptimize(cache[idx]); // Prevent optimization
 }
}

// Ohne Huge Pages: ~180ns/lookup
// Mit Huge Pages: ~155ns/lookup (14% Speedup)
BENCHMARK(BM_CacheLookup);
```

### 8.3.4 Transparent Huge Pages (THP) Alternative

**Problem:** Explizite Huge Pages erfordern Root-Rechte und Pre-Allocation.

**Lösung:** Transparent Huge Pages (THP) – Kernel managed automatisch:

```
THP aktivieren
echo always | sudo tee /sys/kernel/mm/transparent_hugepage/enabled

Defrag-Modus (empfohlen: defer für Production)
echo defer | sudo tee /sys/kernel/mm/transparent_hugepage/defrag
```

**Trade-offs:**

Methode	Vorteile	Nachteile
<b>Explicit Huge Pages</b>	Garantierte 2MB Pages, max Performance	Root-Rechte, Pre-Allocation
<b>Transparent Huge Pages</b>	Keine Config, automatisch	Variable Performance, Defrag-Overhead

**Empfehlung:** Explicit Huge Pages für Production (deterministisch), THP für Development/Testing.

## 8.4 Compression Strategies

### 8.4.1 Tiered Compression: Hot vs Cold Data

RocksDB LSM-Tree hat 7 Levels (L0-L6). Hot Data (L0-L2) wird häufig geschrieben/gelesen, Cold Data (L5-L6) selten.

**Strategie:** Schnelle Compression für Hot, starke Compression für Cold

```
rocksdb::Options options;

// Level 0-5: LZ4 (2-3x Ratio, minimal CPU)
options.compression = rocksdb::kLZ4Compression;

// Level 6 (bottommost): ZSTD (3-5x Ratio, moderate CPU)
options.bottommost_compression = rocksdb::kZSTD;
options.bottommost_compression_opts.level = 3; // ZSTD Level 1-22
```

**Benchmark-Resultate (10K Entities à 2KB):**

Compression Config	DB Size	Write (MB/s)	Read (MB/s)	Ratio
<b>none / none</b>	45 MB	34.5	125.3	1.0x
<b>lz4 / lz4</b>	20 MB	33.9	120.1	2.25x
<b>lz4 / zstd</b>	<b>19 MB</b>	<b>33.8</b>	<b>118.4</b>	<b>2.4x</b>
<b>zstd / zstd</b>	15 MB	32.3	112.7	3.0x

**Empfehlung:** `lz4 / zstd` für besten Trade-off.

### 8.4.2 Bloom Filters für Compression Efficiency

Bloom Filters reduzieren unnötige Disk-Reads bei Point-Lookups (z.B. Secondary Index Scans).

```
rocksdb::BlockBasedTableOptions table_opts;

// Bloom Filter Konfiguration
table_opts.filter_policy.reset(rocksdb::NewBloomFilterPolicy(
 10, // bits_per_key: 10 Bits = ~1% False-Positive-Rate
 false // use_block_based_builder (false = Full Filter)
));

// Partitioned Filters für große Datasets
table_opts.partition_filters = true;
table_opts.index_type = rocksdb::BlockBasedTableOptions::kTwoLevelIndexSearch;

options.table_factory.reset(rocksdb::NewBlockBasedTableFactory(table_opts));
```

#### False-Positive-Rate vs Memory:

bits_per_key	False-Positive-Rate	Memory (1M Keys)
6	~5%	750 KB
10	~1%	1.25 MB
14	~0.1%	1.75 MB

**Empfehlung:** `bits_per_key=10` für Production (guter Kompromiss).

## 8.5 Storage Hierarchy Tuning

### 8.5.1 Multi-Path Setup für NVMe

**Ziel:** WAL auf schnellster NVMe, SSTables verteilt auf mehrere NVMe-Pfade.

```
rocksdb::Options options;

// WAL auf separater NVMe (max Write-Throughput)
options.wal_dir = "/nvme0/themis/wal";

// SSTables verteilt auf mehrere NVMe-Pfade
options.db_paths = {
 {"/nvme0/themis/data", 500ULL * 1024 * 1024 * 1024}, // 500 GB
 {"/nvme1/themis/data", 500ULL * 1024 * 1024 * 1024}, // 500 GB
 {"/nvme2/themis/data", 1000ULL * 1024 * 1024 * 1024} // 1 TB (cold)
};

// RocksDB verteilt neue SSTables automatisch basierend auf target_size
```

**Rationale:**

- **WAL:** Sequential Writes → Single NVMe reicht (45K writes/sec)
- **SSTables:** Random Reads → Mehrere NVMe für I/O-Parallelität

## 8.5.2 Block Cache Tuning

Block Cache speichert dekomprimierte SSTable-Blöcke im RAM.

```

rocksdb::BlockBasedTableOptions table_opts;

// 1. Cache-Größe (empfohlen: 20-40% RAM)
table_opts.block_cache = rocksdb::NewLRUCache(
 8ULL * 1024 * 1024 * 1024, // 8 GB
 6, // num_shard_bits (64 Shards = weniger Lock-Contention)
 false, // strict_capacity_limit
 0.5 // high_pri_pool_ratio (50% für Index/Filter)
);

// 2. Index/Filter Blocks im Cache halten
table_opts.cache_index_and_filter_blocks = true;
table_opts.pin_l0_filter_and_index_blocks_in_cache = true;

// 3. Partitioned Filters (für >1 GB Datasets)
table_opts.partition_filters = true;
table_opts.metadata_block_size = 4096;

options.table_factory.reset(rocksdb::NewBlockBasedTableFactory(table_opts));

```

### Cache Hit Rate Monitoring:

```

uint64_t cache_hits = db->GetOptions().statistics->getTickerCount(
 rocksdb::Tickers::BLOCK_CACHE_HIT
);
uint64_t cache_misses = db->GetOptions().statistics->getTickerCount(
 rocksdb::Tickers::BLOCK_CACHE_MISS
);

double hit_rate = static_cast<double>(cache_hits) / (cache_hits + cache_misses);

// Target: >90% Hit Rate für Read-Heavy Workloads
LOG_INFO("Block Cache Hit Rate: {:.2f}%", hit_rate * 100);

```

## 8.5.3 MemTable Configuration

MemTables sind In-Memory Write-Buffer vor SSTable-Flush.

```
rocksdb::Options options;

// MemTable Size (größer = weniger Flushes, mehr RAM)
options.write_buffer_size = 256 * 1024 * 1024; // 256 MB

// Anzahl MemTables (für Background Flush Pipelining)
options.max_write_buffer_number = 4;
options.min_write_buffer_number_to_merge = 1;

// MemTable Typ (Skip List ist Standard, Hash für Point-Lookups)
options.memtable_factory.reset(rocksdb::NewHashSkipListRepFactory(
 1024 * 1024 // bucket_count
));
```



### Sizing-Empfehlungen:

Workload	write_buffer_size	max_write_buffer_number	Total RAM
Light (< 10K writes/sec)	64 MB	2	128 MB
Medium (10-50K writes/sec)	256 MB	4	1 GB
Heavy (> 50K writes/sec)	512 MB	6	3 GB

## 8.6 Production Deployment Patterns

### 8.6.1 RAID Configuration für Redundanz

**Szenario:** 4× NVMe SSDs, Datensicherheit erforderlich.



### Linux mdadm Setup:

```

RAID 10 für Data (Redundanz + Performance)
sudo mdadm --create /dev/md0 --level=10 --raid-devices=4 \
 /dev/nvme0n1 /dev/nvme1n1 /dev/nvme2n1 /dev/nvme3n1

RAID 0 für WAL (max Performance, WAL ist nicht kritisch)
sudo mdadm --create /dev/md1 --level=0 --raid-devices=2 \
 /dev/nvme4n1 /dev/nvme5n1

Filesystem (XFS empfohlen)
sudo mkfs.xfs /dev/md0
sudo mkfs.xfs /dev/md1

Mount mit Optimierungen
sudo mount -o noatime,discard,nodiratime /dev/md0 /data/themis
sudo mount -o noatime,discard /dev/md1 /wal/themis

```

## 8.6.2 Kernel Tuning für Low-Latency

### I/O Scheduler:

```
Deadline Scheduler für SSDs (niedrigere Latenz)
echo deadline | sudo tee /sys/block/nvme0n1/queue/scheduler

Alternativ: none (für NVMe mit io_uring)
echo none | sudo tee /sys/block/nvme0n1/queue/scheduler
```

### Swappiness (empfohlen: 10 für DB-Workloads):

```
Verhindert Swap außer bei extremem Memory-Druck
echo "vm.swappiness = 10" | sudo tee -a /etc/sysctl.conf
sudo sysctl -p
```

### Transparent Huge Pages:

```
THP aktivieren (siehe 8.3.4)
echo always | sudo tee /sys/kernel/mm/transparent_hugepage/enabled
```

## 8.6.3 Monitoring mit Prometheus

### RocksDB Stats Export:



```
// Prometheus Metrics für RocksDB
#include <prometheus/counter.h>
#include <prometheus/gauge.h>

class RocksDBMetricsExporter {
private:
 rocksdb::DB* db_;
 prometheus::Registry& registry_;

public:
 void exportMetrics() {
 auto stats = db_->GetOptions().statistics;

 // Compaction Metrics
 auto& compaction_gauge = prometheus::BuildGauge()
 .Name("rocksdb_compaction_pending")
 .Help("Number of pending compactions")
 .Register(registry_);
 compaction_gauge.Add({}).Set(
 stats->getTickerCount(rocksdb::COMPACTION_PENDING)
);

 // Cache Hit Rate
 uint64_t hits = stats->getTickerCount(rocksdb::BLOCK_CACHE_HIT);
 uint64_t misses = stats->getTickerCount(rocksdb::BLOCK_CACHE_MISS);
 auto& hit_rate_gauge = prometheus::BuildGauge()
 .Name("rocksdb_cache_hit_rate")
 .Help("Block cache hit rate")
 .Register(registry_);
 hit_rate_gauge.Add({}).Set(
 static_cast<double>(hits) / (hits + misses)
);

 // Write Amplification
 uint64_t bytes_written = stats->getTickerCount(rocksdb::BYTES_WRITTEN);
 uint64_t wal_bytes = stats->getTickerCount(rocksdb::WAL_FILE_BYTES);
 auto& write_amp_gauge = prometheus::BuildGauge()
 .Name("rocksdb_write_amplification")
```

```
 .Help("Write amplification factor")
 .Register(registry_);
 write_amp_gauge.Add({}).Set(
 static_cast<double>(bytes_written) / wal_bytes
);
}
};
```

## 8.7 Performance Benchmarks

### 8.7.1 Baseline vs Optimized Configuration

**Setup:** 1M Entity Inserts + 10M Random Reads

**Baseline (Default RocksDB Config):**

```
Write Throughput: 450.000 ops/sec
Read Latency (p50): 2.1ms
Read Latency (p99): 8.5ms
Memory Usage: 6.2 GB
CPU Usage: 78%
```

**Optimized (mit mimalloc + Huge Pages + Compression):**

```
Write Throughput: 672.000 ops/sec (+49%)
Read Latency (p50): 1.4ms (-33%)
Read Latency (p99): 5.2ms (-39%)
Memory Usage: 5.1 GB (-18%)
CPU Usage: 62% (-21%)
```

### 8.7.2 Detailed Performance Matrix

Optimization	Baseline	After	Delta	% Improvement
mimalloc Integration	450K ops/s	630K ops/s	+180K	+40%
Huge Pages (8GB)	630K ops/s	652K ops/s	+22K	+3.5%
LZ4/ZSTD Compression	652K ops/s	658K ops/s	+6K	+0.9%
Block Cache Tuning	658K ops/s	672K ops/s	+14K	+2.1%
TOTAL IMPROVEMENT	450K ops/s	672K ops/s	+222K	+49%

### 8.7.3 Scaling Characteristics

Throughput vs Thread Count:

Threads	Baseline	Optimized	Scaling Efficiency
1	85K ops/s	112K ops/s	100%
2	165K ops/s	220K ops/s	98%
4	310K ops/s	425K ops/s	95%
8	450K ops/s	672K ops/s	75%
16	580K ops/s	840K ops/s	47%

**Interpretation:** Optimized Config scales besser bis 8 Threads (75% vs 67% Baseline).

## 8.8 Zusammenfassung und Best Practices

#### Production-Checkliste

- Storage:** - ☐ WAL auf separater NVMe (45K writes/sec vs 200 HDD) - ☐ Multi-Path Setup für SSTables (I/O-Parallelität) - ☐ RAID 10 für Data (Redundanz), RAID 0 für WAL (Performance)
- Memory:** - ☐ mimalloc Integration (+40% Throughput) - ☐ Huge Pages aktiviert (8GB für Block Cache) - ☐ Block Cache Sizing: 20-40% RAM
- Compression:** - ☐ Tiered Compression: LZ4 (L0-L5) + ZSTD (L6) - ☐ Bloom Filters: 10 bits/key (~1% FP-Rate)

**Monitoring:** - [ ] Prometheus Metrics für RocksDB Stats - [ ] Cache Hit Rate > 90% für Read-Heavy Workloads - [ ] Write Amplification < 10

**Tuning:** - [ ] Kernel: Deadline Scheduler, Swappiness=10 - [ ] Filesystem: XFS mit noatime, discard - [ ] RocksDB: Prefix-Extractor, Partitioned Filters

## Expected Performance

Mit vollständiger Implementierung aller Optimierungen:

```
Random Writes: 672.000 ops/sec (103% von RocksDB Baseline)
Random Reads: 1.680.000 ops/sec (94% von RocksDB Baseline)
p99 Latency: 5.2ms (Production-Grade)
Overall Grade: A- (85-90% Compliance)
```

## Weiterführende Dokumentation

- [RocksDB Tuning Guide](https://github.com/facebook/rocksdb/wiki/RocksDB-Tuning-Guide) (https://github.com/facebook/rocksdb/wiki/RocksDB-Tuning-Guide)
- [mimalloc Documentation](https://microsoft.github.io/mimalloc/) (https://microsoft.github.io/mimalloc/)
- [Linux Huge Pages](https://www.kernel.org/doc/html/latest/admin-guide/mm/hugetlbpage.html) (https://www.kernel.org/doc/html/latest/admin-guide/mm/hugetlbpage.html)
- [ThemisDB Performance Index](#)

---

**Nächstes Kapitel:** [Chapter 9: Indexing Strategies](#) →

# Teil III - Spezialanwendungen

---

# Kapitel 9: Kapitel 9 - Zeit-Reihen & IoT

## 9.1 Einführung in Time-Series-Datenbanken

### Was sind Time-Series-Daten?

Time-Series-Daten sind Messungen, die über die Zeit gesammelt werden. Jeder Datenpunkt hat einen Zeitstempel und einen oder mehrere Werte:

```
Sensor-Messung
{
 "timestamp": "2024-01-15T10:30:45.123Z",
 "sensor_id": "temp_sensor_001",
 "temperature": 22.5,
 "humidity": 45.2,
 "location": "warehouse_a"
}
```

**Charakteristiken:** - **Hohe Schreiblast:** Tausende Messungen pro Sekunde - **Zeitbasierte Queries:** "Zeige mir alle Werte der letzten Stunde" - **Aggregationen:** Durchschnitt, Min/Max über Zeitfenster - **Retention Policies:** Alte Daten automatisch löschen oder aggregieren

### Typische Use Cases

Use Case	Datenrate	Retention	Beispiel
IoT Sensoren	1-1000 Hz	30-90 Tage	Temperatur, Luftfeuchtigkeit
Monitoring	10-60 sec	1-12 Monate	CPU, Memory, Disk I/O
Financial Data	Real-time	Jahre	Aktienkurse, Trades
Log Aggregation	Variabel	7-30 Tage	Application Logs, Metrics
Smart Home	1-60 sec	3-6 Monate	Stromverbrauch, Heizung

Abb. 09.1: Timeseries-Data-Ingestion

## 9.2 Time-Series-Datenmodell in ThemisDB

### Schema-Design für Time-Series

ThemisDB speichert Time-Series als Documents mit optimierten Indizes:

```
// Sensor-Messungen Collection
FOR doc IN [
 {
 _key: GENERATE_ID(),
 sensor_id: "sensor_001",
 timestamp: DATE_ISO8601(DATE_NOW()),
 temperature: 22.5,
 humidity: 65.0,
 co2_ppm: 420,
 location: "Room 101",
 metadata: {building: "A", floor: 2}
 }
] INSERT doc INTO sensor_readings

-- Index für Time-Range Queries
CREATE INDEX idx_sensor_time
 ON sensor_readings (sensor_id, timestamp)

-- Optional: TTL-Index für automatische Daten-Pruning
CREATE INDEX idx_ttl
 ON sensor_readings (timestamp)
 OPTIONS {expireAfterSeconds: 2592000} -- 30 Tage
```

**Design-Prinzipien:** 1. **Composite Index:** `(sensor_id, timestamp)` - optimal für Time-Range-Queries 2. **TTL-Policies:** Automatisches Löschen alter Daten via Expiration-Index 3. **Sharding:** Horizontales Partitionieren nach `sensor_id` für Skalierung

Abb. 09.2: Aggregation-Pipeline

## Indexes für Time-Series

```
-- Index für Zeit-basierte Queries
CREATE INDEX idx_readings_time ON sensor_readings (timestamp DESC);

-- Index für Sensor-spezifische Queries
CREATE INDEX idx_readings_sensor_time ON sensor_readings (sensor_id, timestamp DESC);

-- Conditional Index für Alerts (nur hohe Temperaturen)
CREATE INDEX idx_high_temp ON sensor_readings (timestamp)
WHERE temperature > 30.0;
```

## 9.3 Effiziente Time-Series Queries

### Time-Range Queries

```
-- Alle Messungen der letzten Stunde
SELECT sensor_id, timestamp, temperature, humidity
FROM sensor_readings
WHERE timestamp >= NOW() - INTERVAL '1 hour'
ORDER BY timestamp DESC;

-- Durchschnitt pro Sensor in den letzten 24h
SELECT sensor_id,
 COUNT(*) as measurement_count,
 AVG(temperature) as avg_temp,
 AVG(humidity) as avg_humidity,
 MAX(co2_ppm) as max_co2
FROM sensor_readings
WHERE timestamp >= NOW() - INTERVAL '24 hours'
GROUP BY sensor_id;
```



## Window Functions für Rolling Averages

```
-- Gleitender Durchschnitt (Moving Average) über 10 Messungen
```

```
SELECT
```

```
 sensor_id,
```

```
 timestamp,
```

```
 temperature,
```

```
 AVG(temperature) OVER (
```

```
 PARTITION BY sensor_id
```

```
 ORDER BY timestamp
```

```
 ROWS BETWEEN 9 PRECEDING AND CURRENT ROW
```

```
) as moving_avg_10
```

```
FROM sensor_readings
```

```
WHERE sensor_id = 'temp_001'
```

```
 AND timestamp >= NOW() - INTERVAL '1 day'
```

```
ORDER BY timestamp;
```

```
-- Differenz zur vorherigen Messung
```

```
SELECT
```

```
 sensor_id,
```

```
 timestamp,
```

```
 temperature,
```

```
 temperature - LAG(temperature) OVER (
```

```
 PARTITION BY sensor_id ORDER BY timestamp
```

```
) as temperature_change
```

```
FROM sensor_readings
```

```
WHERE timestamp >= NOW() - INTERVAL '1 hour';
```

## Time-Bucket Aggregationen

```
-- Aggregiere zu 5-Minuten-Intervallen
SELECT
 sensor_id,
 DATE_TRUNC('minute', timestamp) -
 (EXTRACT(minute FROM timestamp)::int % 5) * INTERVAL '1 minute' as time_bucket,
 AVG(temperature) as avg_temp,
 MIN(temperature) as min_temp,
 MAX(temperature) as max_temp,
 STDDEV(temperature) as stddev_temp
FROM sensor_readings
WHERE timestamp >= NOW() - INTERVAL '1 day'
GROUP BY sensor_id, time_bucket
ORDER BY time_bucket DESC;
```

## 9.4 Down-Sampling und Retention Policies

### Automatisches Down-Sampling

Speichere hochfrequente Rohdaten nur kurzfristig, langfristig nur Aggregate:

```
-- Down-Sampling: Stündliche Aggregate in neue Collection
LET hour_start = DATE_TRUNC(DATE_NOW(), 'hour')
LET hour_data = (
 FOR reading IN sensor_readings
 FILTER reading.timestamp >= DATE_SUBTRACT(hour_start, 1, 'hour')
 AND reading.timestamp < hour_start
 COLLECT sensor = reading.sensor_id INTO readings
 RETURN {
 sensor_id: sensor,
 hour_bucket: hour_start,
 avg_temperature: AVG(readings[*].reading.temperature),
 min_temperature: MIN(readings[*].reading.temperature),
 max_temperature: MAX(readings[*].reading.temperature),
 avg_humidity: AVG(readings[*].reading.humidity),
 max_co2_ppm: MAX(readings[*].reading.co2_ppm),
 sample_count: LENGTH(readings)
 }
)
FOR doc IN hour_data
 UPSERT {sensor_id: doc.sensor_id, hour_bucket: doc.hour_bucket}
 INSERT doc
 UPDATE doc
 INTO sensor_readings_hourly
```

```
max_temperature = EXCLUDED.max_temperature,
sample_count = EXCLUDED.sample_count;
```

Abb. 09.3: Downsampling-Strategie

## Retention Policy Implementation

```
-- Lösche Rohdaten älter als 30 Tage
FOR reading IN sensor_readings
 FILTER reading.timestamp < DATE_NOW() - INTERVAL('30 days')
 REMOVE reading IN sensor_readings

-- Oder: Drop alte Partitionen (viel schneller!)
DROP TABLE IF EXISTS sensor_readings_2023_01;
```

**Best Practice Retention:** - **0-7 Tage:** Rohdaten (1 Sekunde Auflösung) - **7-30 Tage:** 1-Minute Aggregate  
- **30-90 Tage:** 5-Minute Aggregate - **90-365 Tage:** 1-Stunde Aggregate - **>1 Jahr:** 1-Tag Aggregate

## 9.5 Example: IoT Sensor Network

### Überblick

Das **IoT Sensor Network** Beispiel ([examples/09\\_iot\\_sensor\\_network](#)) demonstriert ein vollständiges Monitoring-System für industrielle Sensoren:

**Features:** - Multi-Sensor Monitoring (Temperatur, Luftfeuchtigkeit, CO2) - Real-Time Alerting bei Schwellwert-Überschreitungen - Historische Analyse mit Trend-Erkennung - Dashboard mit Visualisierungen - Complex Event Processing (CEP)

## Datenmodell

```
models.py

from datetime import datetime
from enum import Enum

class SensorType(Enum):
 TEMPERATURE = "temperature"
 HUMIDITY = "humidity"
 CO2 = "co2"
 PRESSURE = "pressure"

class Sensor:
 def __init__(self, sensor_id: str, sensor_type: SensorType,
 location: str, unit: str):
 self.sensor_id = sensor_id
 self.sensor_type = sensor_type
 self.location = location
 self.unit = unit
 self.thresholds = {}

class SensorReading:
 def __init__(self, sensor_id: str, value: float,
 timestamp: datetime = None):
 self.sensor_id = sensor_id
 self.value = value
 self.timestamp = timestamp or datetime.now()
```

## Sensor-Registrierung

```
main.py
import themis_client as themis

Registriere Sensoren
sensors = [
 Sensor("temp_001", SensorType.TEMPERATURE, "warehouse_a", "°C"),
 Sensor("hum_001", SensorType.HUMIDITY, "warehouse_a", "%"),
 Sensor("co2_001", SensorType.CO2, "warehouse_a", "ppm")
]

Speichere Sensor-Metadaten
for sensor in sensors:
 themis.query("""
 UPSERT {sensor_id: @sensor_id}
 INSERT {
 sensor_id: @sensor_id,
 sensor_type: @sensor_type,
 location: @location,
 unit: @unit,
 thresholds: @thresholds
 }
 UPDATE {
 location: @location,
 thresholds: @thresholds
 }
 INTO sensors
 """, {
 'sensor_id': sensor.sensor_id,
 'sensor_type': sensor.sensor_type.value,
 'location': sensor.location,
 'unit': sensor.unit,
 'thresholds': sensor.thresholds
 })
```

**Echtzeit-Datenerfassung**

```

Sensor-Simulation
import random
import time
from datetime import datetime

def simulate_sensors(duration_seconds=60):
 """Simuliere Sensor-Daten für Demo"""
 start_time = time.time()

 while time.time() - start_time < duration_seconds:
 readings = []

 # Generiere realistische Werte
 temp = 20 + random.gauss(2, 0.5) # ~20°C ± 2°C
 humidity = 45 + random.gauss(5, 2) # ~45% ± 5%
 co2 = 400 + random.gauss(50, 10) # ~400 ppm ± 50

 readings.append(SensorReading("temp_001", temp))
 readings.append(SensorReading("hum_001", humidity))
 readings.append(SensorReading("co2_001", co2))

 # Batch-Insert mit AQL
 themis.query("""
 FOR reading IN @readings
 INSERT {
 sensor_id: reading.sensor_id,
 timestamp: reading.timestamp,
 value: reading.value
 } INTO sensor_readings
 """, {'readings': [{'sensor_id': r.sensor_id,
 'timestamp': r.timestamp.isoformat(),
 'value': r.value} for r in readings]})

 time.sleep(1) # 1 Hz Sampling-Rate

simulate_sensors(duration_seconds=3600) # 1 Stunde

```



## Alert-System

```
Alert-Triggering bei Schwellwert-Überschreitungen
def check_alerts():
 """Prüfe aktuelle Werte gegen Schwellwerte"""
 alerts = themis.query("""
 WITH latest_readings AS (
 SELECT DISTINCT ON (sensor_id)
 sensor_id, value, timestamp
 FROM sensor_readings
 ORDER BY sensor_id, timestamp DESC
)
 SELECT
 s.sensor_id,
 s.sensor_type,
 s.location,
 lr.value,
 s.thresholds->>'max' as max_threshold,
 s.thresholds->>'min' as min_threshold
 FROM sensors s
 JOIN latest_readings lr ON s.sensor_id = lr.sensor_id
 WHERE lr.value > (s.thresholds->>'max')::float
 OR lr.value < (s.thresholds->>'min')::float
 """)

 for alert in alerts:
 send_alert(
 sensor_id=alert['sensor_id'],
 location=alert['location'],
 value=alert['value'],
 threshold_breached=True
)
```

## Historische Analyse

```
def analyze_trends(sensor_id: str, hours: int = 24):
 """Analysiere Trends der letzten N Stunden"""
 analysis = themis.query("""
 SELECT
 DATE_TRUNC('hour', timestamp) as hour,
 AVG(value) as avg_value,
 MIN(value) as min_value,
 MAX(value) as max_value,
 STDDEV(value) as stddev_value,
 -- Linearer Trend (Regression)
 REGR_SLOPE(value, EXTRACT(EPOCH FROM timestamp)) * 3600 as hourly_trend
 FROM sensor_readings
 WHERE sensor_id = ?
 AND timestamp >= NOW() - INTERVAL '? hours'
 GROUP BY hour
 ORDER BY hour
 """, (sensor_id, hours))

 return analysis

Beispiel: Temperatur-Trend
temp_trend = analyze_trends("temp_001", hours=24)
print(f"Hourly trend: {temp_trend[-1]['hourly_trend']:.3f}°C/hour")
```

**Dashboard-Visualisierung**

```
import matplotlib.pyplot as plt
import pandas as pd

def plot_sensor_dashboard(sensor_id: str, hours: int = 24):
 """Erstelle Dashboard für einen Sensor"""
 # Lade Daten
 data = themis.query("""
 SELECT timestamp, value
 FROM sensor_readings
 WHERE sensor_id = ?
 AND timestamp >= NOW() - INTERVAL '? hours'
 ORDER BY timestamp
 """, (sensor_id, hours))

 df = pd.DataFrame(data)

 # Plot erstellen
 fig, (ax1, ax2) = plt.subplots(2, 1, figsize=(12, 8))

 # Zeitreihe
 ax1.plot(df['timestamp'], df['value'], linewidth=0.5)
 ax1.set_title(f'Sensor {sensor_id} - Last {hours}h')
 ax1.set_ylabel('Value')
 ax1.grid(True, alpha=0.3)

 # Histogram
 ax2.hist(df['value'], bins=50, alpha=0.7)
 ax2.set_xlabel('Value')
 ax2.set_ylabel('Frequency')
 ax2.axvline(df['value'].mean(), color='red',
 linestyle='--', label='Mean')
 ax2.legend()

 plt.tight_layout()
 plt.savefig(f'dashboard_{sensor_id}.png', dpi=150)
 plt.show()

plot_sensor_dashboard("temp_001")
```

## 9.6 Example: Smart Home Energy Monitoring

### Überblick

Das **Smart Home** Beispiel ([examples/20\\_smart\\_home](#)) zeigt Energy Monitoring und Automation:

**Features:** - Stromverbrauch-Tracking pro Gerät - Automatisierungsregeln (z.B. Heizung runter wenn keiner da ist) - Cost-Calculation basierend auf Strompreisen - Energy-Saving-Recommendations

### Geräte-Management

```
Smart Home Devices
class Device:
 def __init__(self, device_id: str, device_type: str,
 room: str, power_rating_watts: int):
 self.device_id = device_id
 self.device_type = device_type # "heater", "light", "appliance"
 self.room = room
 self.power_rating_watts = power_rating_watts
 self.state = "off"

Registriere Geräte
devices = [
 Device("heater_living", "heater", "living_room", 2000),
 Device("light_living", "light", "living_room", 60),
 Device("fridge_kitchen", "appliance", "kitchen", 150),
]

for dev in devices:
 themis.execute("""
 INSERT INTO devices (device_id, device_type, room, power_rating_watts)
 VALUES (?, ?, ?, ?)
 """, (dev.device_id, dev.device_type, dev.room, dev.power_rating_watts))
```

## Energy-Tracking

```
def track_energy_consumption():
 """Track energy consumption per device"""
 # Record current state and power usage
 for device in devices:
 if device.state == "on":
 power_usage = device.power_rating_watts
 else:
 power_usage = 0

 themis.execute("""
 INSERT INTO energy_readings
 (device_id, timestamp, power_watts, state)
 VALUES (?, NOW(), ?, ?)
 """, (device.device_id, power_usage, device.state))

Run every minute
while True:
 track_energy_consumption()
 time.sleep(60)
```

## Cost Calculation

```
def calculate_daily_cost(date):
 """Berechne Energiekosten für einen Tag"""
 cost_per_kwh = 0.30 # 30 Cent/kWh

 daily_usage = themis.query("""
 SELECT
 device_id,
 d.device_type,
 d.room,
 -- Energie in kWh (Durchschnitt * Zeit / 1000)
 SUM(power_watts * 60) / 1000.0 / 60.0 as kwh_consumed,
 -- Kosten
 SUM(power_watts * 60) / 1000.0 / 60.0 * ? as cost_euros
 FROM energy_readings er
 JOIN devices d ON er.device_id = d.device_id
 WHERE DATE(timestamp) = ?
 GROUP BY device_id, d.device_type, d.room
 ORDER BY cost_euros DESC
 """, (cost_per_kwh, date))

 total_cost = sum(row['cost_euros'] for row in daily_usage)

 print(f"Daily Energy Cost: €{total_cost:.2f}")
 for row in daily_usage:
 print(f" {row['device_id']}: {row['kwh_consumed']:.2f} kWh → €{row['cost_euros']:.2f}")

 return daily_usage

calculate_daily_cost('2024-01-15')
```

## Automation Rules

```
Automatisierungsregeln
class AutomationRule:
 def __init__(self, rule_id: str, condition: str, action: str):
 self.rule_id = rule_id
 self.condition = condition
 self.action = action

rules = [
 AutomationRule("rule_001",
 "temperature < 18 AND presence = false",
 "set_heater_temp(15)"),
 AutomationRule("rule_002",
 "time > 22:00 AND presence = false",
 "turn_off_all_lights()"),
]

def evaluate_rules():
 """Evaluiere und führe Automation-Rules aus"""
 for rule in rules:
 # Check condition
 condition_met = themis.query_one(f"""
 LET latest = (
 FOR state IN device_states
 SORT state.timestamp DESC
 LIMIT 1
 RETURN state
)[0]
 RETURN {{rule.condition}} AS met
 """)

 if condition_met['met']:
 exec(rule.action) # Führe Aktion aus
 print(f"Rule {rule.rule_id} triggered: {rule.action}")
```



## 9.7 Performance-Optimierungen

### Batch-Inserts für hohen Durchsatz

```
Statt 1000 einzelne INSERTs...
for reading in readings:
 themis.execute("INSERT @reading INTO sensor_readings", {"reading": reading})

...nutze Batch-Insert (100x schneller!)
themis.execute_batch(
 "INSERT @reading INTO sensor_readings",
 [{"reading": r} for r in readings],
 batch_size=1000
)
```

### Partitionierung für schnelle Queries

```
-- Automatisches Partition-Management
CREATE OR REPLACE FUNCTION create_monthly_partition()
RETURNS void AS $$
DECLARE
 start_date DATE;
 end_date DATE;
 partition_name TEXT;
BEGIN
 start_date := DATE_TRUNC('month', NOW());
 end_date := start_date + INTERVAL '1 month';
 partition_name := 'sensor_readings_' || TO_CHAR(start_date, 'YYYY-MM');

 EXECUTE format('
 CREATE TABLE IF NOT EXISTS %I PARTITION OF sensor_readings
 FOR VALUES FROM (%L) TO (%L)
 ', partition_name, start_date, end_date);
END;
$$ LANGUAGE plpgsql;
```

## Materialized Views für Dashboards

```
-- Pre-Aggregiere Daten für schnelle Dashboard-Queries
CREATE MATERIALIZED VIEW sensor_daily_stats AS
SELECT
 sensor_id,
 DATE(timestamp) as date,
 AVG(value) as avg_value,
 MIN(value) as min_value,
 MAX(value) as max_value,
 COUNT(*) as reading_count
FROM sensor_readings
GROUP BY sensor_id, DATE(timestamp);

-- Refresh täglich
CREATE INDEX ON sensor_daily_stats (sensor_id, date DESC);
REFRESH MATERIALIZED VIEW CONCURRENTLY sensor_daily_stats;
```

## 9.8 Best Practices

### 1. Schema-Design

**DO:** - Nutze Partitionierung für große Tabellen - Composite Primary Key:

`(entity_id, timestamp)` - Index auf `timestamp DESC` für neueste Daten

× **DON'T:** - Nicht UUID als Primary Key bei Time-Series - Keine UNIQUENESS Constraints außer Primary Key - Vermeide komplexe JOINS in High-Frequency Queries

### 2. Query-Optimierung

**DO:** - Nutze TIME-RANGE in WHERE-Clause für Partition Pruning - Batch-Inserts statt einzelne INSERTs - Materialized Views für häufige Aggregationen

× **DON'T:** - Keine `SELECT *` - nur benötigte Spalten - Vermeide DISTINCT ohne Index - Keine ungebundenen Queries ohne Zeit-Limit

### 3. Retention & Storage

**DO:** - Implementiere Retention Policies - Down-Sample alte Daten - Nutze automatisches Partition-Management

× **DON'T:** - Behalte nicht alle Rohdaten für immer - Lösche nicht mit DELETE (nutze DROP PARTITION) - Vergiss nicht Backups vor Partition-Drops

## 9.9 Vergleich: ThemisDB vs. Specialized Time-Series DBs

Feature	ThemisDB	InfluxDB	TimescaleDB
Data Model	Relational + Multi-Model	Line Protocol	Relational
Query Language	SQL/AQL	InfluxQL, Flux	SQL
Partitioning	Native	Automatic	Hypertables
Continuous Aggregates	Mat. Views	Native	Continuous Aggregates
Retention Policies	Manual/Triggers	Automatic	Automatic
Downsampling	AQL-based	Built-in	Continuous Aggregates
Multi-Model	Graph, Vector, Doc	×	×
Horizontal Scaling	Sharding	Clustering	Distributed

**Wann ThemisDB wählen:** - Wenn Time-Series nur ein Teil der Anwendung ist - Wenn komplexe Relationen zu anderen Daten bestehen - Wenn Multi-Model Features (Graph, Vector) benötigt werden - Wenn Standard-AQL Queries ausreichen

**Wann Specialized DB wählen:** - InfluxDB: Sehr hohe Schreibraten (>1M writes/sec), native Telegraf-Integration - TimescaleDB: Wenn PostgreSQL-Kompatibilität Priorität hat

## 9.10 Zusammenfassung

ThemisDB ist bestens geeignet für Time-Series & IoT-Anwendungen durch:

**Native Unterstützung:** - Partitionierung für Milliarden von Datenpunkten - Effiziente Time-Range Queries mit Partition Pruning - Window Functions für Rolling Averages und Trend-Analyse

**Performance:** - Batch-Inserts für hohen Schreibdurchsatz - Materialized Views für schnelle Dashboards - Indexing-Strategien für typische Time-Series Patterns

**Flexibilität:** - Kombiniere Time-Series mit relationalen Daten - Nutze Graph-Queries für Sensor-Topologien - Vector-Search für Pattern-Matching in Zeitreihen

**Key Takeaways:** 1. Nutze Partitionierung + richtige Indexes 2. Implementiere Retention Policies frühzeitig 3. Batch-Inserts für Performance 4. Materialized Views für Dashboards 5. Down-Sample alte Daten automatisch

## Kapitel 10: Kapitel 10 - Enterprise

---

### Einleitung

Enterprise-Anwendungen sind das Rückgrat moderner Unternehmen. Sie verwalten kritische Geschäftsprozesse, von der Kundenverwaltung über Dokumentenmanagement bis hin zu ERP-Systemen. In diesem Kapitel lernen Sie, wie ThemisDB alle Anforderungen enterprise-grade Software erfüllt:

- **Multi-Tenancy** für Mandantenfähigkeit
- **RBAC** (Role-Based Access Control) für fein-granulare Zugriffsrechte
- **Audit-Logging** für vollständige Nachvollziehbarkeit
- **Workflow-Management** für Geschäftsprozesse
- **Skalierbarkeit** für große Datenmengen
- **Security** auf allen Ebenen

Wir demonstrieren dies anhand zweier vollständiger Beispiele: 1. **DMS/ERP-System:** Dokumentenmanagement mit Workflows 2. **CRM-System:** Customer Relationship Management

### 10.1 Enterprise-Anforderungen

#### Mandantenfähigkeit (Multi-Tenancy)

In SaaS-Anwendungen müssen Daten verschiedener Kunden (Mandanten/Tenants) strikt getrennt sein.

**Drei Ansätze:**

```
1. Separate Datenbanken (maximale Isolation)
db_tenant_1 = ThemisDB("tenant_1.db")
db_tenant_2 = ThemisDB("tenant_2.db")

2. Shared Database, Tenant-Column (balance)
db.execute("""
 CREATE TABLE documents (
 id UUID PRIMARY KEY,
 tenant_id UUID NOT NULL,
 title TEXT,
 content TEXT
)
""")
Index für Performance
db.execute("CREATE INDEX idx_tenant ON documents(tenant_id)")

3. Row-Level Security (PostgreSQL-Style)
ThemisDB unterstützt dies via Policies:
db.execute("""
 CREATE POLICY tenant_isolation ON documents
 USING (tenant_id = current_tenant_id())
""")
```

Abb. 10.1: Enterprise-Architektur-Übersicht

**Best Practice in ThemisDB:**

```
class TenantContext:
 def __init__(self, db, tenant_id):
 self.db = db
 self.tenant_id = tenant_id

 def query(self, sql, params=None):
 # Automatisches Anhängen der Tenant-Bedingung
 if "WHERE" in sql.upper():
 sql = sql.replace("WHERE", f"WHERE tenant_id = '{self.tenant_id}' AND")
 else:
 sql += f" WHERE tenant_id = '{self.tenant_id}'"
 return self.db.execute(sql, params)

Verwendung
tenant = TenantContext(db, "acme_corp")
docs = tenant.query("""
 FOR doc IN documents
 FILTER doc.type == @type
 RETURN doc
""", {"type": "invoice"})
```

## Rollen-basierte Zugriffskontrolle (RBAC)

### Datenmodell:

```
Rollen
db.execute("""
 CREATE TABLE roles (
 id UUID PRIMARY KEY,
 name TEXT UNIQUE NOT NULL,
 permissions TEXT[], -- ["read:documents", "write:documents"]
 created_at TIMESTAMP DEFAULT CURRENT_TIMESTAMP
)
""")

User-Role Zuordnung
db.execute("""
 CREATE TABLE user_roles (
 user_id UUID,
 role_id UUID,
 granted_at TIMESTAMP DEFAULT CURRENT_TIMESTAMP,
 PRIMARY KEY (user_id, role_id)
)
""")

Permission Check
def has_permission(user_id, permission):
 result = db.execute("""
 FOR user_role IN user_roles
 FILTER user_role.user_id == @user_id
 FOR role IN roles
 FILTER user_role.role_id == role.id AND @permission IN role.permissions
 LIMIT 1
 RETURN 1
 """, {"user_id": user_id, "permission": permission})
 return len(result) > 0
```

Abb. 10.2: RBAC-Hierarchie

# Dekorator für API-Endpoints

```
def requires_permission(permission):
 def decorator(func):
 def wrapper(args, kwargs):
 user_id = get_current_user_id()
 if not has_permission(user_id, permission):
 raise PermissionDeniedError()
 return func(args, **kwargs)
 return wrapper
 return decorator

@requires_permission("write:documents")
def create_document(title, content):
 # Nur erreichbar mit korrekter Permission pass
```



### ### Audit-Logging

Jede Änderung muss nachvollziehbar sein:

```
```python
db.execute("""
    CREATE TABLE audit_log (
        id UUID PRIMARY KEY,
        timestamp TIMESTAMP DEFAULT CURRENT_TIMESTAMP,
        user_id UUID NOT NULL,
        action TEXT NOT NULL, -- CREATE, UPDATE, DELETE, READ
        resource_type TEXT NOT NULL, -- "document", "user", etc.
        resource_id UUID NOT NULL,
        old_value JSON,
        new_value JSON,
        ip_address TEXT,
        user_agent TEXT
    )
""")

# Index für schnelle Queries
db.execute("CREATE INDEX idx_audit_resource ON audit_log(resource_type, resource_id)")
db.execute("CREATE INDEX idx_audit_user ON audit_log(user_id, timestamp)")

def log_action(action, resource_type, resource_id, old_value=None, new_value=None):
    db.execute("""
        INSERT {
            id: @id,
            user_id: @user_id,
            action: @action,
            resource_type: @resource_type,
            resource_id: @resource_id,
            old_value: @old_value,
            new_value: @new_value,
            ip_address: @ip_address
        } INTO audit_log
    """, {
```

```

        "id": uuid.uuid4(),
        "user_id": get_current_user_id(),
        "action": action,
        "resource_type": resource_type,
        resource_id,
        json.dumps(old_value) if old_value else None,
        json.dumps(new_value) if new_value else None,
        get_client_ip()
    ))

# Verwendung
old_doc = db.execute("""
    FOR doc IN documents
        FILTER doc.id == @doc_id
        LIMIT 1
        RETURN doc
""", {"doc_id": doc_id})[0]

db.execute("""
    FOR doc IN documents
        FILTER doc.id == @doc_id
        UPDATE doc WITH {title: @new_title} IN documents
""", {"doc_id": doc_id, "new_title": new_title})

new_doc = db.execute("""
    FOR doc IN documents
        FILTER doc.id == @doc_id
        LIMIT 1
        RETURN doc
""", {"doc_id": doc_id})[0]

log_action("UPDATE", "document", doc_id, old_doc, new_doc)

```

Audit-Abfragen:

```
# Wer hat Dokument X geändert?
changes = db.execute("""
    FOR log IN audit_log
        FILTER log.resource_type == 'document' AND log.resource_id == @doc_id
        SORT log.timestamp DESC
        RETURN log
""", {"doc_id": doc_id})

# Was hat User Y in den letzten 7 Tagen gemacht?
activity = db.execute("""
    FOR log IN audit_log
        FILTER log.user_id == @user_id AND log.timestamp > DATE_NOW() - INTERVAL('7 days')
        SORT log.timestamp DESC
        RETURN log
""", {"user_id": user_id})
```

10.2 Native Security-Stack: Production-Ready Sicherheit

ThemisDB v1.3.0 bietet einen vollständig nativen, in C++ implementierten Security-Stack, der BSI C5-konform ist und keine externen Abhängigkeiten (wie Apache Ranger) für die Kern-Sicherheitsfunktionen benötigt.

10.2.1 Implementierungsstatus (Dezember 2025)

Komponente	Status	Implementierung	Beschreibung
RBAC/ABAC Policy Engine	Produktionsreif	<code>src/security/rbac.cpp</code>	Role-Based & Attribute-Based Access Control
Apache Ranger Integration	Produktionsreif	<code>src/server/ranger_adapter.cpp</code>	Optional: Enterprise Policy Management
Field-Level Encryption	Produktionsreif	<code>src/security/encryption.cpp</code>	AES-256-GCM, transparent
Column Encryption	Produktionsreif	BSI C5 konform	Spalten-basierte Verschlüsselung
Vector Encryption	Produktionsreif	Phase 1+2 komplett	HNSW-Index + RocksDB Vektoren
PKI Integration	Produktionsreif	<code>src/security/pki_key_provider.cpp</code>	X.509 Zertifikat-basiert
HSM Support	Produktionsreif	<code>src/security/hsm_provider_pkcs11.cpp</code>	PKCS#11 Hardware Security Modules
Audit Logging	Produktionsreif	<code>src/utils/audit_logger.cpp</code>	Tamper-Proof mit Hash-Chains
Malware Scanner	Produktionsreif	<code>src/security/malware_scanner.cpp</code>	Content Security
CMS Signing	Produktionsreif	<code>src/security/cms_signing.cpp</code>	Cryptographic Message Syntax
RFC 3161 TSA	Produktionsreif	<code>src/security/timestamp_authority.cpp</code>	Qualified Timestamps

Gesamt: 16 Header-Dateien, 16 Source-Dateien, ~8.100 LOC

10.2.2 RBAC-Implementierung im C++ Core

ThemisDB implementiert RBAC direkt im C++ Kern, nicht als Add-on-Layer:

Architektur:

```
// Native RBAC Integration (src/security/rbac.h)
class RBACManager {
public:
    // Role Management
    Status createRole(const std::string& roleName,
                     const std::vector<std::string>& permissions);
    Status assignRole(const std::string& userId,
                     const std::string& roleName);

    // Permission Check (optimiert für Performance)
    bool hasPermission(const std::string& userId,
                      const std::string& resource,
                      const std::string& action) const;

    // Attribute-Based (ABAC) Extension
    bool checkPolicy(const PolicyContext& ctx) const;
};
```

Performance-Optimierung: - Permission-Checks gecacht im RAM (TBB concurrent_hash_map) - Sub-Millisekunden Latenz für Permission-Checks - Keine Netzwerk-Latenz (im Gegensatz zu externen Policy-Servern)

Verwendung in AQL:

```
// Automatischer Permission-Check bei Query-Ausführung
FOR doc IN documents
    // RBAC-Filter wird automatisch eingefügt basierend auf User-Kontext
    FILTER HAS_PERMISSION(CURRENT_USER(), doc._id, 'read')
    RETURN doc
```

10.2.3 Tamper-Proof Audit Logging mit Hash-Chains

Das Audit-System von ThemisDB verhindert nachträgliche Manipulation durch **kryptografische Hash-Chains**:

Funktionsweise:

```
// src/utils/audit_logger.cpp
class AuditLogger {
    struct AuditEntry {
        uint64_t sequence_number;
        int64_t timestamp_ms;
        std::string user_id;
        std::string action;
        std::string resource_id;
        std::string details;
        std::string previous_hash; // Hash des vorherigen Eintrags
        std::string current_hash; // SHA-256 über alle Felder
    };

    // Verkettung erzwingt chronologische Integrität
    std::string computeHash(const AuditEntry& entry) {
        std::string data = std::to_string(entry.sequence_number) +
            std::to_string(entry.timestamp_ms) +
            entry.user_id + entry.action +
            entry.resource_id + entry.details +
            entry.previous_hash;

        return SHA256(data); // OpenSSL
    }
};
```

Garantien: - **Unveränderbarkeit:** Jede Änderung bricht die Hash-Chain - **Lückenlosigkeit:**

Fehlende Einträge sind sofort erkennbar - **Zeitstempel-Authentizität:** Integration mit RFC 3161

Timestamp Authority - **Revisionssicher:** BSI-konform, DSGVO Art. 32

Verifikation:

```
// Audit-Log-Integrität prüfen
FOR entry IN audit_log
  SORT entry.sequence_number ASC
  LET expected_hash = SHA256(
    CONCAT(
      entry.sequence_number,
      entry.timestamp_ms,
      entry.user_id,
      entry.action,
      entry.resource_id,
      entry.details,
      entry.previous_hash
    )
  )
  FILTER entry.current_hash != expected_hash
RETURN {
  error: "Audit log integrity violation",
  sequence: entry.sequence_number
}
```

10.2.4 HashiCorp Vault Integration

Für Enterprise-Key-Management integriert ThemisDB mit HashiCorp Vault:

Konfiguration:

```
// src/security/vault_key_provider.cpp
VaultKeyProvider::Config vault_config;
vault_config.vault_addr = "https://vault.company.com:8200";
vault_config.token = std::getenv("VAULT_TOKEN");
vault_config.mount_path = "themisdb";
vault_config.key_name = "database-master-key";

auto key_provider = std::make_shared<VaultKeyProvider>(vault_config);
FieldEncryption encryption(key_provider);
```

Features: - Automatische Key-Rotation - Audit Trail für Key-Access - High Availability (Vault Cluster) - Disaster Recovery (Sealed/Unsealed State)

Alternative Key Provider: - `MockKeyProvider` : Für Testing/Development - `PKIKeyProvider` : Zertifikat-basiert für PKI-Infrastrukturen - `HSMProvider` : PKCS#11 für Hardware Security Modules (Luna, Thales)


10.2.5 BSI C5 Compliance: Kryptographie

ThemisDB erreicht **100% BSI C5 Compliance** für Kryptographie-Anforderungen (CRY-01 bis CRY-06):

Anforderung	Umsetzung	Dokument
CRY-01: Kryptographie-Policy	Formale Policy dokumentiert	<code>CRYPTOGRAPHY_POLICY.md</code>
CRY-02: Key Lifecycle	Vollständiger Lebenszyklus	<code>KEY_LIFECYCLE_MANAGEMENT.md</code>
CRY-03: At-Rest Encryption	AES-256-GCM für alle Daten	Column + Vector Encryption
CRY-04: In-Transit Encryption	TLS 1.3 mandatory	Wire Protocol + HTTP/2
CRY-05: Key Storage	HSM/Vault Integration	<code>VaultKeyProvider</code> + <code>HSMProvider</code>
CRY-06: Algorithm Strength	BSI TR-02102-1 konform	AES-256, RSA-2048+, SHA-256

Besonderheit: Multi-Model Encryption Consistency

ThemisDB's Unified Storage Architecture garantiert konsistente Verschlüsselung über alle Datenmodelle:



Vorteil: Im Gegensatz zu Polyglot-Systemen, wo jede Datenbank eigene Encryption benötigt, ist in ThemisDB alles einheitlich verschlüsselt – kein Modell kann "vergessen" werden.

10.2.6 DSGVO "By Design" Features

ThemisDB implementiert DSGVO-Anforderungen technisch:

1. Auto-Purge nach Retention-Period (Art. 17 - Recht auf Löschung):

```
// src/utils/retention_manager.cpp
RetentionManager::Config retention;
retention.enable_auto_purge = true;
retention.default_retention_days = 2555; // 7 Jahre (§ 147 AO)
retention.purge_schedule_cron = "0 2 * * 0"; // Sonntags 2 Uhr

// Anwendung auf Collection
db.execute("""
    CREATE COLLECTION customer_data WITH {
        retention_days: 2555,
        auto_purge: true
    }
    """);
```

2. PII Detection und Redaction (Art. 32 - Datensicherheit):

```
// src/utils/pii_detector.cpp
PIIDetector detector;
detector.addPattern("email", R"([\w\.-]+@[ \w\.-]+\.\w+)");
detector.addPattern("iban", R"(DE\d{20})");
detector.addPattern("ssn", R"(\d{3}-\d{2}-\d{4})");

// Automatische Redaction bei Logging
std::string safe_text = detector.redact(user_input);
// Output: "Contact: ***@***.com, IBAN: DE*****"
```

3. Encrypt-then-Sign für Log-Integrität:

```
// src/security/cms_signing.cpp
CMSSigning signer(private_key, certificate);

// Audit-Log Entry signieren
std::string signed_entry = signer.sign(
    audit_entry_json,
    true // include_timestamp (RFC 3161)
);

// Später: Verifizierung
bool valid = signer.verify(signed_entry, public_cert);
```

4. Granulare Retention Policies:

```
-- Unterschiedliche Aufbewahrungsfristen pro Datentyp
CREATE COLLECTION invoices WITH { retention_days: 3650 }; -- 10 Jahre
CREATE COLLECTION marketing_consent WITH { retention_days: 730 }; -- 2 Jahre
CREATE COLLECTION session_logs WITH { retention_days: 90 }; -- 90 Tage
```

10.2.7 Code-Beispiel: Vollständige Enterprise-Security

```
from themisdb import Client, SecurityContext

# 1. Client mit Security-Kontext
client = Client("localhost", 8765)

# 2. Authentifizierung (PKI-basiert oder Token)
auth_token = client.authenticate(
    cert_file="user.crt",
    key_file="user.key"
)

# 3. Security Context für alle Operationen
sec_ctx = SecurityContext(
    user_id="alice@company.com",
    roles=["data_analyst", "auditor"],
    tenant_id="acme_corp"
)

# 4. Query mit automatischem RBAC + Audit
with client.transaction(sec_ctx) as tx:
    # Permission-Check + Audit-Log-Eintrag automatisch
    results = tx.query("""
        FOR doc IN sensitive_documents
        FILTER doc.classification <= @max_clearance
        RETURN doc
    """, {"max_clearance": sec_ctx.get_clearance_level()})

    # Alle Aktionen werden geloggt:
    # - Wer (alice@company.com)
    # - Was (SELECT sensitive_documents)
    # - Wann (2025-12-30T15:00:00Z)
    # - Ergebnis (5 rows returned)
    # - Hash (SHA-256 chain)

# 5. Compliance-Report abrufen
audit_report = client.get_audit_report(
    start_date="2025-01-01",
    end_date="2025-12-31",
```

```


    user_id="alice@company.com"
)

```

10.3 DMS/ERP-System (Example 08)

Ein vollständiges Document Management System mit ERP-Features.

Architektur-Übersicht



Datenmodell

Das Dokumentenmanagementsystem kombiniert relationale, dokumenten-orientierte und vektorbasierte Features für ein vollständiges Enterprise-DMS. Das System verwaltet Dokumente mit Versionierung, Metadaten, Volltext-Indexierung und semantischer Suche - alles mandantenfähig und mit Audit-Logging.

Vollständiger Code: `examples/10_enterprise/dms_system.py` (~450 Zeilen)

Kern-Architektur:

```

class Document:
    def __init__(self, db):
        self.db = db
        self.init_schema()

    def init_schema(self):
        # Haupt-Dokument mit Versionierung (Relational + Multi-Tenancy)
        self.db.execute("""
            CREATE TABLE IF NOT EXISTS documents (
                id UUID PRIMARY KEY,
                tenant_id UUID NOT NULL, -- Multi-Tenancy
                title TEXT NOT NULL,
                type TEXT NOT NULL,
                version INT DEFAULT 1,
                current_version_id UUID,
                owner_id UUID NOT NULL,
                workflow_state TEXT DEFAULT 'draft',
                created_at TIMESTAMP DEFAULT CURRENT_TIMESTAMP,
                updated_at TIMESTAMP DEFAULT CURRENT_TIMESTAMP
            )
        """)

        # Metadaten (Document Model - flexible JSON-Struktur)
        self.db.execute("""
            CREATE TABLE IF NOT EXISTS document_metadata (
                document_id UUID PRIMARY KEY,
                metadata JSON NOT NULL,
                tags TEXT[],
                FOREIGN KEY (document_id) REFERENCES documents(id)
            )
        """)

        # Volltext-Extraktion mit OCR-Support
        self.db.execute("""
            CREATE TABLE IF NOT EXISTS document_text (
                document_id UUID PRIMARY KEY,
                content TEXT,
                ocr_content TEXT, -- OCR für gescannte Dokumente

```

```

        FOREIGN KEY (document_id) REFERENCES documents(id)
    )
    """
self.db.execute("CREATE INDEX idx_doc_fulltext ON document_text USING GIN(to_tsvector('g

# Vector Embeddings für semantische Suche
self.db.execute("""
    CREATE TABLE IF NOT EXISTS document_embeddings (
        document_id UUID PRIMARY KEY,
        embedding VECTOR(384), -- sentence-transformers
        FOREIGN KEY (document_id) REFERENCES documents(id)
    )
    """)
self.db.execute("CREATE INDEX idx_doc_vector ON document_embeddings USING HNSW(embedding

def create_document(self, title, doc_type, file_path, metadata=None, owner_id=None):
    """Dokument erstellen mit automatischer Text-Extraktion und Embedding-Generierung"""
    doc_id = uuid.uuid4()

    with self.db.transaction():
        # 1. Haupt-Dokument mit Tenant-Isolation
        self.db.execute("""
            INSERT {
                id: @doc_id,
                tenant_id: @tenant_id, -- Automatische Mandantentrennung
                title: @title,
                type: @doc_type,
                owner_id: @owner_id
            } INTO documents
        """, {
            "doc_id": doc_id,
            "tenant_id": get_current_tenant_id(),
            "title": title,
            "doc_type": doc_type,
            "owner_id": owner_id or get_current_user_id()
        })

        # 2. Text-Extraktion (PDF, DOCX, etc.)

```



```

        text = extract_text(file_path)

    # 3. OCR für gescannte Dokumente
    if doc_type in ('scan', 'image'):
        ocr_text = perform_ocr(file_path)
        text = text + " " + ocr_text

    # 4. Fulltext-Index befüllen
    self.db.execute("""
        INSERT {
            document_id: @doc_id,
            content: @content
        } INTO document_text
    """, {"doc_id": doc_id, "content": text})

    # 5. Semantische Embeddings generieren
    embedding = generate_embedding(text) # sentence-transformers/384D
    self.db.execute("""
        INSERT {
            document_id: @doc_id,
            embedding: @embedding
        } INTO document_embeddings
    """, {"doc_id": doc_id, "embedding": embedding})

    # 6. Audit-Log für Compliance
    log_action("CREATE", "document", doc_id, None, {"title": title, "type": doc_type})

    return doc_id

def search(self, query, doc_type=None, limit=20):
    """Hybrid-Suche kombiniert Volltext-Ranking mit semantischer Ähnlichkeit"""
    # 1. Fulltext-Suche (BM25-ähnlich mit ts_rank)
    fulltext_results = self.db.execute("""
        SELECT d.id, d.title, d.type,
               ts_rank(to_tsvector('german', dt.content), plainto_tsquery('german', @query))
        FROM documents d
        JOIN document_text dt ON d.id = dt.document_id
        WHERE d.tenant_id = @tenant_id
    """)

```

```

        AND to_tsvector('german', dt.content) @@ plainto_tsquery('german', @query)
    ORDER BY rank DESC LIMIT @limit
    """ , {"query": query, "tenant_id": get_current_tenant_id(), "limit": limit})

# 2. Vector-Suche (semantische Ähnlichkeit via Cosine)
query_embedding = generate_embedding(query)
vector_results = self.db.execute("""
    SELECT d.id, d.title, d.type,
           1 - (de.embedding <=> @query_emb) as similarity
    FROM documents d
    JOIN document_embeddings de ON d.id = de.document_id
    WHERE d.tenant_id = @tenant_id
    ORDER BY similarity DESC LIMIT @limit
    """ , {"query_emb": query_embedding, "tenant_id": get_current_tenant_id(), "limit": limit})

# 3. Merge und Re-Ranking
merged = merge_search_results(fulltext_results, vector_results) # Reciprocal Rank Fusion
return merged

```

Zusätzliche Features im vollständigen Code: - Versionsverwaltung mit `add_version()` und `get_version_history()` - Fein-granulare Permissions pro Dokument (read/write/admin) - Checksum-Verifizierung für Integrität - Asynchrone Text-Extraktion für große Dateien - Workflow-Integration (siehe nächster Abschnitt)

Workflow-Management

Workflows als Graph modellieren:

```

class WorkflowEngine:
    def __init__(self, db):
        self.db = db
        self.init_schema()

    def init_schema(self):
        # Workflow-Definitionen (Relational)
        self.db.execute("""
            CREATE TABLE IF NOT EXISTS workflows (
                id UUID PRIMARY KEY,
                name TEXT NOT NULL,
                description TEXT,
                active BOOLEAN DEFAULT true
            )
        """)

        # Workflow-Schritte als Graph
        self.db.execute("""
            CREATE TABLE IF NOT EXISTS workflow_nodes (
                id UUID PRIMARY KEY,
                workflow_id UUID NOT NULL,
                name TEXT NOT NULL,
                node_type TEXT CHECK (node_type IN ('start', 'approval', 'task', 'decision', 'end')),
                role_required TEXT,
                FOREIGN KEY (workflow_id) REFERENCES workflows(id)
            )
        """)

        self.db.execute("""
            CREATE TABLE IF NOT EXISTS workflow_edges (
                from_node UUID,
                to_node UUID,
                condition TEXT, -- Optional: JSON mit Bedingung
                PRIMARY KEY (from_node, to_node),
                FOREIGN KEY (from_node) REFERENCES workflow_nodes(id),
                FOREIGN KEY (to_node) REFERENCES workflow_nodes(id)
            )
        """)

```

```

# Workflow-Instanzen (laufende Prozesse)
self.db.execute("""
    CREATE TABLE IF NOT EXISTS workflow_instances (
        id UUID PRIMARY KEY,
        workflow_id UUID NOT NULL,
        document_id UUID NOT NULL,
        current_node UUID NOT NULL,
        state TEXT DEFAULT 'running',
        started_at TIMESTAMP DEFAULT CURRENT_TIMESTAMP,
        completed_at TIMESTAMP,
        FOREIGN KEY (workflow_id) REFERENCES workflows(id),
        FOREIGN KEY (document_id) REFERENCES documents(id),
        FOREIGN KEY (current_node) REFERENCES workflow_nodes(id)
    )
""")

# Workflow-Historie
self.db.execute("""
    CREATE TABLE IF NOT EXISTS workflow_history (
        id UUID PRIMARY KEY,
        instance_id UUID NOT NULL,
        node_id UUID NOT NULL,
        user_id UUID,
        action TEXT,
        comment TEXT,
        timestamp TIMESTAMP DEFAULT CURRENT_TIMESTAMP,
        FOREIGN KEY (instance_id) REFERENCES workflow_instances(id)
    )
""")

def create_workflow(self, name, description, steps):
    """Workflow definieren

    steps = [
        {"name": "Erfassung", "type": "start"},
        {"name": "Manager-Prüfung", "type": "approval", "role": "manager"},
        {"name": "Direktor-Freigabe", "type": "approval", "role": "director"},
    ]

```

```

        {"name": "Abgeschlossen", "type": "end"}
    ]
    """
    workflow_id = uuid.uuid4()

    with self.db.transaction():
        self.db.execute("""
            INSERT {
                id: @workflow_id,
                name: @name,
                description: @description
            } INTO workflows
        """, {"workflow_id": workflow_id, "name": name, "description": description})

    # Nodes erstellen
    node_ids = []
    for step in steps:
        node_id = uuid.uuid4()
        self.db.execute("""
            INSERT {
                id: @node_id,
                workflow_id: @workflow_id,
                name: @name,
                node_type: @node_type,
                role_required: @role_required
            } INTO workflow_nodes
        """, {
            "node_id": node_id,
            "workflow_id": workflow_id,
            "name": step['name'],
            "node_type": step['type'],
            "role_required": step.get('role')
        })
        node_ids.append(node_id)

    # Edges erstellen (linearer Flow)
    for i in range(len(node_ids) - 1):
        self.db.execute("""

```

```

        INSERT {
            from_node: @from_node,
            to_node: @to_node
        } INTO workflow_edges
        """', {"from_node": node_ids[i], "to_node": node_ids[i+1]})

    return workflow_id

def start_workflow(self, workflow_id, document_id):
    """Workflow für Dokument starten"""
    # Start-Node finden
    start_node = self.db.execute("""
        SELECT id FROM workflow_nodes
        WHERE workflow_id = ? AND node_type = 'start'
        """, (workflow_id,))[0]

    instance_id = uuid.uuid4()
    self.db.execute("""
        INSERT INTO workflow_instances (id, workflow_id, document_id, current_node)
        VALUES (?, ?, ?, ?)
        """, (instance_id, workflow_id, document_id, start_node['id']))

    # Dokumentstatus aktualisieren
    self.db.execute("UPDATE documents SET workflow_state = 'in_progress' WHERE id = ?", (document_id,))

    # Nächsten Schritt finden und zuweisen
    self._advance_workflow(instance_id)

    return instance_id

def _advance_workflow(self, instance_id):
    """Workflow zum nächsten Schritt bewegen"""
    instance = self.db.execute("SELECT * FROM workflow_instances WHERE id = ?", (instance_id,))

    # Nächster Node via Graph-Traversierung
    next_nodes = self.db.execute("""
        SELECT wn.* FROM workflow_edges we
        JOIN workflow_nodes wn ON we.to_node = wn.id
    """)

```

```

        WHERE we.from_node = ?
        """ , (instance['current_node'],))

    if not next_nodes:
        # Ende erreicht
        self.db.execute("""
            UPDATE workflow_instances
            SET state = 'completed', completed_at = CURRENT_TIMESTAMP
            WHERE id = ?
            """ , (instance_id,))
        self.db.execute("UPDATE documents SET workflow_state = 'completed' WHERE id = ?", (instance_id,))
        return

    next_node = next_nodes[0]
    self.db.execute("UPDATE workflow_instances SET current_node = ? WHERE id = ?",
                    (next_node['id'], instance_id))

    # Task an User mit entsprechender Rolle zuweisen
    if next_node['role_required']:
        self._assign_task(instance_id, next_node['id'], next_node['role_required'])

def approve(self, instance_id, user_id, comment=""):
    """Workflow-Schritt genehmigen"""
    instance = self.db.execute("SELECT * FROM workflow_instances WHERE id = ?", (instance_id,))
    current_node = self.db.execute("SELECT * FROM workflow_nodes WHERE id = ?", (instance['current_node'],))

    # Permission check
    if current_node['role_required']:
        if not user_has_role(user_id, current_node['role_required']):
            raise PermissionError(f"User benötigt Rolle: {current_node['role_required']}")

    with self.db.transaction():
        # Historie speichern
        self.db.execute("""
            INSERT INTO workflow_history (id, instance_id, node_id, user_id, action, comment)
            VALUES (?, ?, ?, ?, ?, ?)
            """ , (uuid.uuid4(), instance_id, current_node['id'], user_id, "APPROVED", comment))

```

```

        # Zum nächsten Schritt
        self._advance_workflow(instance_id)

        log_action("WORKFLOW_APPROVE", "workflow_instance", instance_id, None, {
            "node": current_node['name'],
            "user": user_id
        })

def reject(self, instance_id, user_id, reason):
    """Workflow-Schritt ablehnen"""
    with self.db.transaction():
        instance = self.db.execute("SELECT * FROM workflow_instances WHERE id = ?", (instance_id,))

        self.db.execute("""
            INSERT INTO workflow_history (id, instance_id, node_id, user_id, action, comment)
            VALUES (?, ?, ?, ?, ?, ?)
            """, (uuid.uuid4(), instance_id, instance['current_node'], user_id, "REJECTED", reason))

        self.db.execute("UPDATE workflow_instances SET state = 'rejected' WHERE id = ?", (instance_id,))
        self.db.execute("UPDATE documents SET workflow_state = 'rejected' WHERE id = ?", (instance_id,))

        log_action("WORKFLOW_REJECT", "workflow_instance", instance_id, None, {"reason": reason})

def get_pending_tasks(self, user_id):
    """Offene Tasks für User"""
    # User-Rollen ermitteln
    user_roles = self.db.execute("SELECT role_name FROM user_roles WHERE user_id = ?", (user_id,))
    role_names = [r['role_name'] for r in user_roles]

    # Workflows in passenden Nodes
    return self.db.execute("""
        SELECT wi.*, d.title as document_title, wn.name as step_name
        FROM workflow_instances wi
        JOIN workflow_nodes wn ON wi.current_node = wn.id
        JOIN documents d ON wi.document_id = d.id
        WHERE wi.state = 'running'
        AND wn.role_required IN ({})
    """)

```



```
ORDER BY wi.started_at
"".format(','.join('? ' * len(role_names)), role_names)
```

API-Implementierung

```
from flask import Flask, request, jsonify
from werkzeug.security import check_password_hash
import jwt

app = Flask(__name__)
db = ThemisDB("dms_erp.db")
doc_manager = Document(db)
workflow_engine = WorkflowEngine(db)

# Authentifizierung
def authenticate(username, password):
    user = db.execute("SELECT * FROM users WHERE username = ?", (username,))
    if not user or not check_password_hash(user[0]['password'], password):
        return None
    token = jwt.encode({'user_id': str(user[0]['id'])}, app.config['SECRET_KEY'])
    return token

@app.route('/api/auth/login', methods=['POST'])
def login():
    data = request.json
    token = authenticate(data['username'], data['password'])
    if token:
        return jsonify({'token': token})
    return jsonify({'error': 'Invalid credentials'}), 401

# Middleware
def require_auth(f):
    def wrapper(*args, **kwargs):
        token = request.headers.get('Authorization', '').replace('Bearer ', '')
        try:
            payload = jwt.decode(token, app.config['SECRET_KEY'], algorithms=['HS256'])
            request.user_id = payload['user_id']
            return f(*args, **kwargs)
        except:
            return jsonify({'error': 'Unauthorized'}), 401
    return wrapper

# Document API
```

```
@app.route('/api/documents', methods=['POST'])
@require_auth
@requires_permission('create:document')
def create_document():
    file = request.files['file']
    metadata = request.form.get('metadata', '{}')

    # Datei speichern
    file_path = save_uploaded_file(file)

    doc_id = doc_manager.create_document(
        title=file.filename,
        doc_type=request.form.get('type', 'general'),
        file_path=file_path,
        metadata=json.loads(metadata),
        owner_id=request.user_id
    )

    return jsonify({'id': str(doc_id), 'message': 'Document created'}), 201

@app.route('/api/documents/<doc_id>', methods=['GET'])
@require_auth
def get_document(doc_id):
    # Permission Check
    if not has_document_permission(request.user_id, doc_id, 'read'):
        return jsonify({'error': 'Forbidden'}), 403

    doc = db.execute("SELECT * FROM documents WHERE id = ?", (doc_id,))[0]
    versions = doc_manager.get_version_history(doc_id)

    return jsonify({
        'document': doc,
        'versions': versions
    })

@app.route('/api/documents/search', methods=['GET'])
@require_auth
def search_documents():
```

```
    query = request.args.get('q', '')
    doc_type = request.args.get('type')

    results = doc_manager.search(query, doc_type)
    return jsonify({'results': results})

# Workflow API
@app.route('/api/workflows/<workflow_id>/start', methods=['POST'])
@require_auth
def start_workflow_api(workflow_id):
    data = request.json
    instance_id = workflow_engine.start_workflow(workflow_id, data['document_id'])
    return jsonify({'instance_id': str(instance_id)})

@app.route('/api/workflows/tasks', methods=['GET'])
@require_auth
def get_my_tasks():
    tasks = workflow_engine.get_pending_tasks(request.user_id)
    return jsonify({'tasks': tasks})

@app.route('/api/workflows/instances/<instance_id>/approve', methods=['POST'])
@require_auth
def approve_workflow(instance_id):
    data = request.json
    workflow_engine.approve(instance_id, request.user_id, data.get('comment', ''))
    return jsonify({'message': 'Approved'})

@app.route('/api/workflows/instances/<instance_id>/reject', methods=['POST'])
@require_auth
def reject_workflow(instance_id):
    data = request.json
    workflow_engine.reject(instance_id, request.user_id, data['reason'])
    return jsonify({'message': 'Rejected'})
```

OCR und Text-Extraktion

```
import pytesseract
from PIL import Image
import fitz  # PyMuPDF

def extract_text(file_path):
    """Text aus verschiedenen Formaten extrahieren"""
    ext = file_path.split('.')[-1].lower()

    if ext == 'pdf':
        return extract_text_from_pdf(file_path)
    elif ext in ('docx', 'doc'):
        return extract_text_from_docx(file_path)
    elif ext == 'txt':
        with open(file_path, 'r', encoding='utf-8') as f:
            return f.read()
    else:
        return ""

def extract_text_from_pdf(file_path):
    """PDF Text-Extraktion"""
    text = []
    doc = fitz.open(file_path)
    for page in doc:
        text.append(page.get_text())
    return '\n'.join(text)

def perform_ocr(file_path):
    """OCR für gescannte Dokumente"""
    if file_path.endswith('.pdf'):
        # PDF → Bilder → OCR
        doc = fitz.open(file_path)
        ocr_text = []
        for page_num in range(len(doc)):
            page = doc[page_num]
            pix = page.get_pixmap()
            img = Image.frombytes("RGB", [pix.width, pix.height], pix.samples)
            text = pytesseract.image_to_string(img, lang='deu')
            ocr_text.append(text)
```

```
        return '\n'.join(ocr_text)
    else:
        # Direktes Bild
        img = Image.open(file_path)
        return pytesseract.image_to_string(img, lang='deu')
```

10.4 CRM-System (Example 17)

Customer Relationship Management komplett in ThemisDB.

Datenmodell

```
class CRM:

    def __init__(self, db):
        self.db = db
        self.init_schema()

    def init_schema(self):
        # Kunden (Relational)
        self.db.execute("""
            CREATE TABLE IF NOT EXISTS customers (
                id UUID PRIMARY KEY,
                tenant_id UUID NOT NULL,
                name TEXT NOT NULL,
                type TEXT CHECK (type IN ('individual', 'company')),
                industry TEXT,
                revenue DECIMAL,
                employees INT,
                website TEXT,
                status TEXT DEFAULT 'active',
                lead_score INT DEFAULT 0,
                lifetime_value DECIMAL DEFAULT 0,
                created_at TIMESTAMP DEFAULT CURRENT_TIMESTAMP,
                updated_at TIMESTAMP DEFAULT CURRENT_TIMESTAMP
            )
        """)

        # Kontaktpersonen
        self.db.execute("""
            CREATE TABLE IF NOT EXISTS contacts (
                id UUID PRIMARY KEY,
                customer_id UUID NOT NULL,
                first_name TEXT,
                last_name TEXT,
                email TEXT,
                phone TEXT,
                position TEXT,
                is_primary BOOLEAN DEFAULT false,
                FOREIGN KEY (customer_id) REFERENCES customers(id)
            )
        """)
```

```

    """)

# Leads / Opportunities
self.db.execute("""
    CREATE TABLE IF NOT EXISTS opportunities (
        id UUID PRIMARY KEY,
        customer_id UUID NOT NULL,
        title TEXT NOT NULL,
        value DECIMAL NOT NULL,
        stage TEXT NOT NULL, -- prospecting, qualification, proposal, negotiation, closed
        probability INT CHECK (probability BETWEEN 0 AND 100),
        expected_close_date DATE,
        assigned_to UUID,
        source TEXT, -- website, referral, cold_call, etc.
        created_at TIMESTAMP DEFAULT CURRENT_TIMESTAMP,
        FOREIGN KEY (customer_id) REFERENCES customers(id)
    )
""")

# Activities (Time-Series)
self.db.execute("""
    CREATE TABLE IF NOT EXISTS activities (
        id UUID PRIMARY KEY,
        customer_id UUID,
        opportunity_id UUID,
        type TEXT NOT NULL, -- email, call, meeting, note
        subject TEXT,
        description TEXT,
        duration INT, -- Minuten
        completed BOOLEAN DEFAULT false,
        scheduled_at TIMESTAMP,
        completed_at TIMESTAMP,
        created_by UUID,
        created_at TIMESTAMP DEFAULT CURRENT_TIMESTAMP,
        FOREIGN KEY (customer_id) REFERENCES customers(id),
        FOREIGN KEY (opportunity_id) REFERENCES opportunities(id)
    )
""")

```

```

# Index für Timeline
self.db.execute("CREATE INDEX idx_activities_timeline ON activities(customer_id, created_at)")

# Notes / Interaktionen (Document Model)
self.db.execute("""
    CREATE TABLE IF NOT EXISTS customer_notes (
        id UUID PRIMARY KEY,
        customer_id UUID NOT NULL,
        note JSON NOT NULL, -- {author, text, attachments, tags}
        created_at TIMESTAMP DEFAULT CURRENT_TIMESTAMP,
        FOREIGN KEY (customer_id) REFERENCES customers(id)
    )
""")

def create_customer(self, name, customer_type, **kwargs):
    """Neuen Kunden anlegen"""
    customer_id = uuid.uuid4()

    self.db.execute("""
        INSERT INTO customers (id, tenant_id, name, type, industry, revenue, employees, website)
        VALUES (?, ?, ?, ?, ?, ?, ?, ?)
    """, (
        customer_id,
        get_current_tenant_id(),
        name,
        customer_type,
        kwargs.get('industry'),
        kwargs.get('revenue'),
        kwargs.get('employees'),
        kwargs.get('website')
    ))

    log_action("CREATE", "customer", customer_id, None, {"name": name})
    return customer_id

def create_opportunity(self, customer_id, title, value, stage, **kwargs):
    """Lead/Opportunity erstellen"""
    opp_id = uuid.uuid4()

```

```

self.db.execute("""
    INSERT INTO opportunities (id, customer_id, title, value, stage, probability, expected_close_date, assigned_to, source)
    VALUES (?, ?, ?, ?, ?, ?, ?, ?, ?)
""", (
    opp_id,
    customer_id,
    title,
    value,
    stage,
    kwargs.get('probability', self._calculate_probability(stage)),
    kwargs.get('expected_close_date'),
    kwargs.get('assigned_to', get_current_user_id()),
    kwargs.get('source')
))

# Lead Score aktualisieren
self._update_lead_score(customer_id)

return opp_id

def _calculate_probability(self, stage):
    """Wahrscheinlichkeit basierend auf Stage"""
    probabilities = {
        'prospecting': 10,
        'qualification': 25,
        'proposal': 50,
        'negotiation': 75,
        'closed_won': 100,
        'closed_lost': 0
    }
    return probabilities.get(stage, 0)

def _update_lead_score(self, customer_id):
    """Lead-Scoring berechnen"""
    # Faktoren:
    # - Anzahl Opportunities
    # - Gesamtwert offener Opportunities

```

```

# - Anzahl Activities
# - Durchschnittliche Wahrscheinlichkeit

score_data = self.db.execute("""
    SELECT
        COUNT(DISTINCT o.id) as opp_count,
        COALESCE(SUM(o.value), 0) as total_value,
        COALESCE(AVG(o.probability), 0) as avg_probability,
        COUNT(DISTINCT a.id) as activity_count
    FROM customers c
    LEFT JOIN opportunities o ON c.id = o.customer_id AND o.stage NOT IN ('closed_won',
    LEFT JOIN activities a ON c.id = a.customer_id
    WHERE c.id = ?
    GROUP BY c.id
""", (customer_id,))[0]

# Simple Scoring-Formel
score = (
    score_data['opp_count'] * 10 +
    min(score_data['total_value'] / 1000, 50) +
    score_data['avg_probability'] / 2 +
    score_data['activity_count'] * 2
)
score = min(int(score), 100)

self.db.execute("UPDATE customers SET lead_score = ? WHERE id = ?", (score, customer_id))

def log_activity(self, customer_id, activity_type, subject, description, **kwargs):
    """Aktivität loggen"""
    activity_id = uuid.uuid4()

    self.db.execute("""
        INSERT INTO activities (id, customer_id, opportunity_id, type, subject, description,
        VALUES (?, ?, ?, ?, ?, ?, ?, ?, ?)
    """, (
        activity_id,
        customer_id,
        kwargs.get('opportunity_id'),

```

```

        activity_type,
        subject,
        description,
        kwargs.get('duration'),
        kwargs.get('scheduled_at'),
        get_current_user_id()
    ))

    return activity_id

def complete_activity(self, activity_id):
    """Aktivität als erledigt markieren"""
    self.db.execute("""
        UPDATE activities
        SET completed = true, completed_at = CURRENT_TIMESTAMP
        WHERE id = ?
    """, (activity_id,))

def get_customer_timeline(self, customer_id, limit=50):
    """Komplette Timeline für Kunde"""
    return self.db.execute("""
        SELECT
            'activity' as item_type,
            id,
            type,
            subject,
            created_at as timestamp
        FROM activities
        WHERE customer_id = ?

        UNION ALL

        SELECT
            'note' as item_type,
            id,
            'note' as type,
            note->'text' as subject,
            created_at as timestamp
    """)

```

```

        FROM customer_notes
        WHERE customer_id = ?

    UNION ALL

    SELECT
        'opportunity' as item_type,
        id,
        'opportunity' as type,
        title as subject,
        created_at as timestamp
    FROM opportunities
    WHERE customer_id = ?

    ORDER BY timestamp DESC
    LIMIT ?
    """ , (customer_id, customer_id, customer_id, limit))

def get_sales_pipeline(self):
    """Sales-Pipeline Übersicht"""
    return self.db.execute("""
        SELECT
            stage,
            COUNT(*) as count,
            SUM(value) as total_value,
            AVG(probability) as avg_probability
        FROM opportunities
        WHERE stage NOT IN ('closed_won', 'closed_lost')
        GROUP BY stage
        ORDER BY
            CASE stage
                WHEN 'prospecting' THEN 1
                WHEN 'qualification' THEN 2
                WHEN 'proposal' THEN 3
                WHEN 'negotiation' THEN 4
            END
    """)

```



```

def forecast_revenue(self, months=3):
    """Revenue-Forecast"""
    return self.db.execute("""
        SELECT
            DATE_TRUNC('month', expected_close_date) as month,
            SUM(value * probability / 100) as weighted_value,
            SUM(value) as total_value,
            COUNT(*) as opportunity_count
        FROM opportunities
        WHERE expected_close_date >= CURRENT_DATE
        AND expected_close_date <= CURRENT_DATE + INTERVAL '? months'
        AND stage NOT IN ('closed_won', 'closed_lost')
        GROUP BY month
        ORDER BY month
    """, (months,))

def get_top_customers(self, limit=10):
    """Top-Kunden nach Lifetime Value"""
    return self.db.execute("""
        SELECT
            c.*,
            COUNT(DISTINCT o.id) as opportunity_count,
            SUM(CASE WHEN o.stage = 'closed_won' THEN o.value ELSE 0 END) as won_value,
            COUNT(DISTINCT a.id) as activity_count
        FROM customers c
        LEFT JOIN opportunities o ON c.id = o.customer_id
        LEFT JOIN activities a ON c.id = a.customer_id
        WHERE c.tenant_id = ?
        GROUP BY c.id
        ORDER BY won_value DESC, c.lead_score DESC
        LIMIT ?
    """, (get_current_tenant_id(), limit))

```

Dashboard und Reporting

```

class CRMDashboard:
    def __init__(self, crm):
        self.crm = crm
        self.db = crm.db

    def get_overview(self):
        """Dashboard Übersicht"""
        return {
            'customers': self._get_customer_stats(),
            'pipeline': self.crm.get_sales_pipeline(),
            'activities': self._get_activity_stats(),
            'forecast': self.crm.forecast_revenue(3)
        }

    def _get_customer_stats(self):
        return self.db.execute("""
            SELECT
                COUNT(*) as total,
                COUNT(CASE WHEN status = 'active' THEN 1 END) as active,
                COUNT(CASE WHEN lead_score >= 70 THEN 1 END) as hot_leads,
                AVG(lead_score) as avg_lead_score
            FROM customers
            WHERE tenant_id = ?
        """, (get_current_tenant_id(),))[0]

    def _get_activity_stats(self):
        return self.db.execute("""
            SELECT
                type,
                COUNT(*) as count,
                COUNT(CASE WHEN completed THEN 1 END) as completed
            FROM activities
            WHERE created_at >= CURRENT_DATE - INTERVAL '30 days'
            GROUP BY type
        """)

    def generate_report(self, report_type, start_date, end_date):
        """Verschiedene Reports generieren"""

```

```

        if report_type == 'sales':
            return self._sales_report(start_date, end_date)
        elif report_type == 'activities':
            return self._activity_report(start_date, end_date)
        elif report_type == 'conversion':
            return self._conversion_report(start_date, end_date)

def _sales_report(self, start_date, end_date):
    """Verkaufs-Report"""
    return self.db.execute("""
        SELECT
            DATE_TRUNC('week', created_at) as week,
            COUNT(*) as opportunities_created,
            COUNT(CASE WHEN stage = 'closed_won' THEN 1 END) as won,
            SUM(CASE WHEN stage = 'closed_won' THEN value ELSE 0 END) as won_value,
            COUNT(CASE WHEN stage = 'closed_lost' THEN 1 END) as lost
        FROM opportunities
        WHERE created_at BETWEEN ? AND ?
        GROUP BY week
        ORDER BY week
    """, (start_date, end_date))

def _conversion_report(self, start_date, end_date):
    """Conversion-Funnel"""
    return self.db.execute("""
        SELECT
            source,
            COUNT(*) as total,
            COUNT(CASE WHEN stage = 'closed_won' THEN 1 END) as won,
            ROUND(COUNT(CASE WHEN stage = 'closed_won' THEN 1 END)::NUMERIC / COUNT(*) * 100,
            AVG(value) as avg_deal_size
        FROM opportunities
        WHERE created_at BETWEEN ? AND ?
        GROUP BY source
        ORDER BY conversion_rate DESC
    """, (start_date, end_date))

```

10.5 Best Practices für Enterprise-Anwendungen

1. Performance bei großen Datenmengen

```
# Partitionierung für Time-Series Daten
db.execute("""
    CREATE TABLE activities_2025_01 PARTITION OF activities
    FOR VALUES FROM ('2025-01-01') TO ('2025-02-01')
""")

# Materialized Views für Reports
db.execute("""
    CREATE MATERIALIZED VIEW sales_summary AS
    SELECT
        DATE_TRUNC('month', created_at) as month,
        stage,
        COUNT(*) as count,
        SUM(value) as total_value
    FROM opportunities
    GROUP BY month, stage
""")

# Refresh periodisch
db.execute("REFRESH MATERIALIZED VIEW sales_summary")
```

2. Caching-Strategie

```
import redis

cache = redis.Redis()

def get_dashboard_data_cached():
    cached = cache.get('dashboard:overview')
    if cached:
        return json.loads(cached)

    # Berechnen
    data = dashboard.get_overview()

    # Cache für 5 Minuten
    cache.setex('dashboard:overview', 300, json.dumps(data))
    return data
```

3. Background-Jobs

```
from celery import Celery

celery = Celery('enterprise_app')

@celery.task
def generate_large_report(report_id):
    """Großer Report im Hintergrund"""
    report_data = dashboard.generate_report('sales', start_date, end_date)

    # PDF generieren
    pdf_path = create_pdf_report(report_data)

    # In DB speichern
    db.execute("""
        UPDATE reports
        SET status = 'completed', file_path = ?
        WHERE id = ?
    """, (pdf_path, report_id))

    # User benachrichtigen
    send_notification(user_id, f"Report {report_id} ist fertig")

@celery.task
def update_lead_scores():
    """Lead-Scores täglich neu berechnen"""
    customers = db.execute("SELECT id FROM customers WHERE status = 'active'")
    for customer in customers:
        crm._update_lead_score(customer['id'])
```

4. API-Rate-Limiting

```
from flask_limiter import Limiter

limiter = Limiter(app, key_func=lambda: request.user_id)

@app.route('/api/documents/search')
@limiter.limit("100/hour")
@require_auth
def search_api():
    # Maximal 100 Searches pro Stunde pro User
    pass
```


5. Monitoring und Alerting

```
import statsd
from prometheus_client import Counter, Histogram

# Metrics
document_uploads = Counter('document_uploads_total', 'Total document uploads')
query_duration = Histogram('query_duration_seconds', 'Query execution time')

@app.route('/api/documents', methods=['POST'])
@require_auth
def create_document():
    document_uploads.inc()

    with query_duration.time():
        doc_id = doc_manager.create_document(...)

    return jsonify({'id': str(doc_id)})

# Healthcheck
@app.route('/health')
def health():
    try:
        db.execute("SELECT 1")
        return jsonify({'status': 'healthy'}), 200
    except:
        return jsonify({'status': 'unhealthy'}), 500
```

10.5 Enterprise Compliance & Audit (Neu)

Compliance-Anforderungen (DSGVO, BAIT, ISO 27001) verlangen nachvollziehbare Änderungen, Daten-Löschkonzepte und strikte Trennung zwischen Tenants und Regionen.

10.5.1 Audit-Log Architektur

Abb. 10.3: Audit-Log-Flow

10.5.2 Audit-Log Schema (RocksDB Prefix)

Field	Type	Description
<code>tenant_id</code>	string	Mandant (Tenant)
<code>actor</code>	string	User/Service Principal
<code>action</code>	string	z.B. <code>documents.create</code> , <code>users.update</code>
<code>resource</code>	string	Resource Identifier (z.B. <code>doc:123</code>)
<code>ts</code>	int64	Unix ms Timestamp
<code>ip</code>	string	Client-IP
<code>status</code>	string	<code>success</code> / <code>failure</code>
<code>before</code>	json	Optional: Vorheriger Zustand
<code>after</code>	json	Optional: Neuer Zustand

Key Layout: `audit:{tenant}:{ts}:{uuid}` → Prefix-Scan pro Tenant + Zeitraum.

10.5.3 DSGVO: Löschung & Aufbewahrung

```
-- Aufbewahrungsregel pro Tenant (Config-Collection)
FOR cfg IN audit_policies
  FILTER cfg.tenant_id == @tenant
  RETURN cfg.retention_days

-- Lösch-Job (täglich)
LET cutoff = DATE_NOW() - DAYS(@retention_days)
FOR entry IN audit
  FILTER entry.tenant_id == @tenant
  FILTER entry.ts < cutoff
  REMOVE entry IN audit
```

Double-Delete: Nach Log-Löschung optional `after`-Payload mit Null-Werten überschreiben, falls rechtlich gefordert.

10.5.4 BAIT/ISO 27001 Mapping (Auszug)

- **Protokollierung:** Jede sicherheitsrelevante Aktion → Audit-Log (BAIT 8.1)
- **Unveränderbarkeit:** Write-Once-Append oder WORM-Bucket für Export (ISO 27001 A.12.4)
- **Trennung:** Tenant-ID im Key, optionale Region im Prefix `audit:eu-central-1:tenant:...`
- **Nachvollziehbarkeit:** Request-ID, Correlation-ID, Actor, IP
- **Rechteprüfung:** RBAC-Check vor Schreiboperationen, Audit-Log auch für abgelehnte Zugriffe

Audit-Exporte:

```
# Täglicher S3-Export mit Object Lock (7 Jahre)
aws s3 cp audit.json s3://themis-audit/2025/12/31/ \
  --object-lock-mode COMPLIANCE \
  --object-lock-retain-until-date 2032-12-31
```

10.5.6 Tenant & Region Sharding

```
audit_storage:
  strategy: by_region_and_tenant
  regions:
    - id: eu-central-1
      bucket: s3://themis-audit-eu
    - id: us-east-1
      bucket: s3://themis-audit-us

rocksdb_prefixes:
  eu: "audit:eu-central-1:"
  us: "audit:us-east-1:"
```

10.5.7 Editions & Distribution (Kurzüberblick)

Edition	Features	Zielgruppe
Community	Core Storage, AQL, Basic Indizes	Entwickler, PoC
Enterprise	RBAC, Audit, HA/Failover, Advanced Backup	Unternehmen
Gov/Regulated	Region Sharding, WORM-Export, Langzeitaufbewahrung	Finanz, Behörden

Distribution Best Practice: 1. **Core Binary** per Artifact Registry ausliefern 2. **Regionale Add-ons** (Compliance-Pakete) nur für passende Regionen aktivieren 3. **Config-as-Code:** Tenant-Policies versionieren

10.7 Sprachassistent für Enterprise (Voice Assistant)

***Enterprise-Feature:** Der Voice Assistant ist ein optionales Enterprise-Feature, das natürlichsprachliche Sprachinteraktion direkt in ThemisDB integriert.*

Überblick

Der ThemisDB Sprachassistent bietet Voice-Interaktionsfähigkeiten ähnlich wie Alexa oder Siri, jedoch direkt in die Datenbank integriert und mit voller Enterprise-Compliance. Er kombiniert drei Technologien:

1. **Speech-to-Text (STT)** via Whisper.cpp - Hochgenaue Transkription in 100+ Sprachen
2. **Text-to-Speech (TTS)** via Piper - Natürliche Sprachsynthese
3. **LLM-Integration** via llama.cpp - Natürlichsprachliches Verständnis

Hauptanwendungsfälle: - **Call Center:** Automatische Telefonaufzeichnung und Transkription -

Meeting Protokolle: KI-gestützte Protokollerstellung mit Aktionspunkten - **Voice Commands:**

Datenbankabfragen über natürliche Sprache - **Diktiersysteme:** Medizinische/rechtliche Dokumentation -

Voice Bots: Interaktive Sprachassistenten für Kunden

Alle Aufzeichnungen werden **revision-safe** in ThemisDB gespeichert mit vollständigen Audit-Trails und DSGVO-konformer Aufbewahrung.

Architektur

Abb. 10.4: Compliance-Workflow

STT: Speech-to-Text mit Whisper.cpp

Whisper.cpp ist eine hochperformante C++ Implementierung von OpenAI's Whisper Modell.

Modellgrößen (Trade-off: Geschwindigkeit vs. Genauigkeit):

Modell	Parameter	Geschwindigkeit	Genauigkeit	Use Case
<code>tiny</code>	39M	~10x realtime	85%	Echtzeit-Interaktion
<code>base</code>	74M	~5x realtime	90%	Standard (empfohlen)
<code>small</code>	244M	~2x realtime	94%	Call Center
<code>medium</code>	769M	~1x realtime	96%	Medizinische Diktate
<code>large</code>	1550M	~0.5x realtime	98%	Juristische Protokolle

Konfiguration:

```
voice_assistant:
  enabled: true

stt:
  model_path: "./models/ggml-base.bin"
  model_size: "base"
  language: "auto" # Automatische Spracherkennung
  threads: 4

# Erweiterte Optionen
speaker_diarization: true # Sprecher-Identifikation
timestamps: true        # Wort-Timestamps
vad_filter: true         # Voice Activity Detection
```

Praktisches Beispiel - Telefonaufzeichnung:

```

import requests
import json

# 1. Audio-Datei hochladen und transkribieren
with open("call_recording.mp3", "rb") as audio:
    response = requests.post(
        "http://localhost:8080/api/v1/voice/transcribe",
        files={"audio": audio},
        headers={"Authorization": "Bearer YOUR_TOKEN"},
        data={
            "language": "de",
            "speaker_diarization": True,
            "store_recording": True, # In ThemisDB speichern
            "tenant_id": "acme_corp"
        }
    )

result = response.json()
print(f"Transkript ID: {result['id']}")
print(f"Dauer: {result['duration_seconds']}s")
print(f"Sprecher: {len(result['speakers'])}")

# 2. Transkript abrufen mit Sprecher-Tags
for segment in result['segments']:
    print(f"[{segment['start']}s - {segment['end']}s] "
          f"Speaker {segment['speaker']}: {segment['text']}")

# Beispiel-Output:
# [0.0s - 3.2s] Speaker 1: Guten Tag, wie kann ich Ihnen helfen?
# [3.5s - 8.1s] Speaker 2: Ich habe eine Frage zu meiner Bestellung...
```

Unterstützte Audio-Formate: - MP3, WAV, OGG, FLAC, AAC, M4A, Opus, WMA - Sampling Rate: 16 kHz (empfohlen) oder Auto-Resampling

TTS: Text-to-Speech mit Piper

Piper ist eine schnelle, neuronale TTS-Engine mit natürlich klingenden Stimmen.

Verfügbare Stimmen:

```
# Stimmen auflisten
response = requests.get("http://localhost:8080/api/v1/voice/voices")
voices = response.json()

# Beispiel-Voices:
# - de_DE-thorsten-neutral (Deutsch, männlich, neutral)
# - de_DE-kerstin-low (Deutsch, weiblich, niedrig)
# - en_US-amy-medium (Englisch US, weiblich, medium)
# - en_GB-alan-medium (Englisch UK, männlich, medium)
```

Text zu Sprache konvertieren:

```
# Meeting-Zusammenfassung vorlesen
summary = """
Wichtige Punkte aus dem Meeting:
1. Q4 Umsatz übertrifft Erwartungen um 15 Prozent
2. Neues Feature-Release für Ende Januar geplant
3. Team-Event am 15. Februar
"""

response = requests.post(
    "http://localhost:8080/api/v1/voice/synthesize",
    headers={"Authorization": "Bearer YOUR_TOKEN"},
    json={
        "text": summary,
        "voice": "de_DE-thorsten-neutral",
        "speed": 1.0, # Normale Geschwindigkeit
        "pitch": 1.0, # Normale Tonhöhe
        "output_format": "mp3"
    }
)

# Audio speichern
with open("meeting_summary.mp3", "wb") as f:
    f.write(response.content)
```

Performance: - ~10-20x schneller als Realtime - Streaming-Modus für niedrige Latenz - Geringe CPU-Last (läuft auch ohne GPU)

LLM-Integration für natürlichsprachliche Queries

Der Voice Assistant nutzt die LLM-Engine (siehe Kapitel 17) für:

1. **Intent Recognition** - Verstehen was der Nutzer möchte
2. **Text-to-AQL** - Natürlichsprachliche Queries in AQL übersetzen
3. **Zusammenfassungen** - Meeting-Protokolle und Key Points
4. **Konversation** - Multi-Turn Dialog mit Kontext

Beispiel - Voice-gesteuerte Datenbankabfrage:


```
# Benutzer sagt: "Zeige mir alle offenen Bestellungen von gestern"
response = requests.post(
    "http://localhost:8080/api/v1/voice/command",
    headers={"Authorization": "Bearer YOUR_TOKEN"},
    json={
        "text": "Zeige mir alle offenen Bestellungen von gestern",
        "session_id": "user_42",
        "return_audio": True # TTS-Antwort als Audio
    }
)

result = response.json()

# LLM hat verstanden und AQL generiert:
print(result['intent']) # "query_orders"
print(result['aql'])
# FOR o IN orders
#   FILTER o.status == 'open'
#   FILTER o.created_at >= DATE_SUB(NOW(), 1, 'day')
#   RETURN o

# Ergebnisse
print(f"Gefunden: {len(result['results'])} Bestellungen")

# TTS-Antwort
with open("response.mp3", "wb") as f:
    f.write(base64.b64decode(result['audio_response']))
# Audio sagt: "Ich habe 23 offene Bestellungen von gestern gefunden."
```

Meeting-Protokoll-Generierung

Vollständiger Workflow:

```

# 1. Meeting aufzeichnen (Live WebSocket oder Upload)
import websockets
import asyncio

async def record_meeting():
    uri = "ws://localhost:8080/ws/voice/record"
    async with websockets.connect(uri) as websocket:
        # Sende Konfigurations-Header
        await websocket.send(json.dumps({
            "type": "config",
            "session_id": "meeting_2026_01_09",
            "language": "de",
            "speaker_diarization": True,
            "llm_analysis": True # Aktiviert Echtzeit-Analyse
        }))

        # Streame Audio-Chunks (z.B. von Mikrofon)
        while recording:
            audio_chunk = microphone.read()
            await websocket.send(audio_chunk)

            # Empfange Transkript-Updates
            if response := await websocket.recv():
                update = json.loads(response)
                if update['type'] == 'transcript':
                    print(f"[{update['speaker']}]: {update['text']}")

# 2. Meeting beenden und Protokoll generieren
response = requests.post(
    "http://localhost:8080/api/v1/voice/meeting/finalize",
    headers={"Authorization": "Bearer YOUR_TOKEN"},
    json={
        "session_id": "meeting_2026_01_09",
        "generate_protocol": True,
        "extract_action_items": True,
        "participants": ["Alice", "Bob", "Carol"]
    }
)

```

```
protocol = response.json()

# Generiertes Protokoll
print("=== MEETING PROTOKOLL ===")
print(f"Datum: {protocol['date']}")
print(f"Dauer: {protocol['duration_minutes']} Minuten")
print(f"Teilnehmer: {' , '.join(protocol['participants'])}")
print()
print("Zusammenfassung:")
print(protocol['summary'])
print()
print("Kernpunkte:")
for i, point in enumerate(protocol['key_points'], 1):
    print(f"{i}. {point}")
print()
print("Aktionspunkte:")
for action in protocol['action_items']:
    print(f"- [ ] {action['task']} (verantwortlich: {action['assignee']})")
```

Beispiel-Protokoll-Output:

=== MEETING PROTOKOLL ===

Datum: 2026-01-09 14:30:00

Dauer: 45 Minuten

Teilnehmer: Alice (Product Manager), Bob (Developer), Carol (Designer)

Zusammenfassung:

Das Team diskutierte den Stand des Q1 Releases. Die Entwicklung liegt gut im Zeitplan. Design-Reviews für 3 neue Features wurden abgeschlossen. Es wurden Prioritäten für die nächsten 2 Wochen festgelegt.

Kernpunkte:

1. Login-Feature ist fertig entwickelt, QA-Phase läuft
2. Dashboard-Design wurde final abgenommen
3. API-Performance verbessert um 40% durch Caching
4. Zwei kritische Bugs in Production gefunden und gefixt

Aktionspunkte:

- [] API-Dokumentation aktualisieren (verantwortlich: Bob, bis 12.01.)
- [] User Testing für neues Dashboard organisieren (verantwortlich: Carol, bis 15.01.)
- [] Release Notes vorbereiten (verantwortlich: Alice, bis 20.01.)

Security & Compliance

DSGVO-konforme Speicherung:

```
# Voice Recordings mit Aufbewahrungsfristen
response = requests.post(
    "http://localhost:8080/api/v1/voice/record",
    headers={"Authorization": "Bearer YOUR_TOKEN"},
    json={
        "audio_base64": audio_data,
        "metadata": {
            "purpose": "customer_service",
            "consent_given": True,
            "retention_days": 90, # Automatische Löschung nach 90 Tagen
            "dsgvo_category": "call_recording"
        }
    }
)

# Verschlüsselung at-rest und in-transit
config = {
    "voice_assistant": {
        "encryption": {
            "at_rest": True, # Recordings verschlüsselt speichern
            "key_rotation_days": 30
        },
        "audit": {
            "log_all_access": True,
            "log_transcripts": False # Sensible Daten nicht loggen
        }
    }
}
```

Audit-Logging:

Alle Voice-Operationen werden vollständig geloggt:

```
-- Audit-Log für Voice-Zugriffe
SELECT * FROM audit_logs
WHERE operation_type IN ('voice_transcribe', 'voice_synthesize', 'voice_access')
ORDER BY timestamp DESC
LIMIT 100;

-- Typischer Log-Eintrag:
{
  "timestamp": "2026-01-09T14:30:22Z",
  "user_id": "user_42",
  "operation": "voice_transcribe",
  "recording_id": "rec_abc123",
  "ip_address": "192.168.1.100",
  "metadata": {
    "duration_seconds": 180,
    "language": "de",
    "speakers": 2
  }
}
```

Performance & Skalierung

Benchmark-Ergebnisse (Hardware: 8-Core CPU, 16GB RAM):

Operation	Modell	Latenz	Throughput
STT (tiny)	39M	0.1x realtime	10 concurrent
STT (base)	74M	0.2x realtime	5 concurrent
STT (large)	1550M	2x realtime	1 concurrent
TTS	Piper	0.05x realtime	20 concurrent
LLM Analysis	7B	20 tok/s	3 concurrent

Skalierungs-Strategie:

```
# Horizontale Skalierung mit dedizierten Voice-Nodes
voice_assistant:
  worker_nodes:
    - node: voice-worker-1
      capabilities: [stt, tts]
      gpu: false

    - node: voice-worker-2
      capabilities: [stt]
      model: large
      gpu: true # GPU-beschleunigte Transkription

    - node: voice-worker-3
      capabilities: [llm]
      gpu: true

  load_balancing:
    strategy: least_loaded
    health_check_interval: 30s
```

Use Case: Call Center Automation

Vollständiges Beispiel:

```
class CallCenterIntegration:
    """
    Integration des Voice Assistant in ein Call Center System.
    Automatische Aufzeichnung, Transkription, Sentiment-Analyse und
    CRM-Update.
    """

    def __init__(self, themisdb_url, api_key):
        self.base_url = themisdb_url
        self.headers = {"Authorization": f"Bearer {api_key}"}

    def process_call(self, call_id, audio_file, customer_id):
        """Verarbeitet einen eingehenden Anruf."""

        # 1. Transkribieren mit Speaker Diarization
        transcript_result = self.transcribe_call(audio_file)

        # 2. Sentiment-Analyse via LLM
        sentiment = self.analyze_sentiment(transcript_result['transcript'])

        # 3. Kernpunkte extrahieren
        summary = self.extract_summary(transcript_result['transcript'])

        # 4. CRM aktualisieren
        self.update_crm(customer_id, {
            "call_id": call_id,
            "transcript_id": transcript_result['id'],
            "duration": transcript_result['duration'],
            "sentiment": sentiment,
            "summary": summary,
            "action_items": summary['action_items']
        })

        # 5. Automatische Follow-up Email generieren
        if sentiment['score'] < 0.5: # Negativer Call
            self.create_followup_task(customer_id, "urgent")

        return {
```



```

        "status": "processed",
        "transcript_id": transcript_result['id'],
        "sentiment": sentiment,
        "summary": summary
    }

def transcribe_call(self, audio_file):
    """Transkribiert Audio mit Whisper."""
    with open(audio_file, "rb") as f:
        response = requests.post(
            f"{self.base_url}/api/v1/voice/transcribe",
            files={"audio": f},
            headers=self.headers,
            data={
                "speaker_diarization": True,
                "language": "auto",
                "model": "base"
            }
        )
    return response.json()

def analyze_sentiment(self, transcript):
    """Sentiment-Analyse via LLM."""
    response = requests.post(
        f"{self.base_url}/api/v1/llm/analyze",
        headers=self.headers,
        json={
            "prompt": f"""
            Analysiere die Stimmung in diesem Kundenservice-Gespräch.
            Gib einen Sentiment-Score von 0.0 (sehr negativ) bis 1.0 (sehr positiv)
            und die Hauptgründe.

            Gespräch:
            {transcript}
            """,
            "response_format": "json",
            "schema": {
                "score": "float",

```

```

        "reasons": "array",
        "customer_satisfied": "boolean"
    }
}
)
return response.json()['result']

# Verwendung
call_center = CallCenterIntegration(
    themisdb_url="http://localhost:8080",
    api_key="your_api_key"
)

result = call_center.process_call(
    call_id="CALL_2026_01_09_001",
    audio_file="recordings/call_001.mp3",
    customer_id="CUST_42"
)

print(f"Call verarbeitet. Sentiment: {result['sentiment']['score']:.2f}")
print(f"Zusammenfassung: {result['summary']['text']}")

```

Zusammenfassung & Best Practices

Was Sie gelernt haben: - Voice Assistant Architektur (STT, TTS, LLM) - Whisper.cpp für hochgenaue Transkription - Piper TTS für natürliche Sprachsynthese - Meeting-Protokoll-Generierung - Call Center Integration - DSGVO-konforme Speicherung

Best Practices: 1. **Modell-Größe wählen** basierend auf Latenz-Anforderungen 2. **Speaker Diarization** für Meeting-Protokolle aktivieren 3. **Retention Policies** für DSGVO-Compliance setzen 4. **GPU-Beschleunigung** für höheren Durchsatz nutzen 5. **Horizontale Skalierung** mit dedizierten Voice-Worker-Nodes 6. **Audit-Logging** für alle Zugriffe aktivieren 7. **Verschlüsselung** at-rest und in-transit

Anti-Patterns: - × Large-Modell für Echtzeit-Interaktion (zu langsam) - × Recordings ohne Retention Policy speichern (DSGVO-Risiko) - × TTS ohne Rate-Limiting (DoS-Gefahr) - × Transkripte ohne Verschlüsselung (Security-Risiko)

Weitere Ressourcen: - Vollständige API-Dokumentation: [docs/de/features/sprachassistent_anleitung.md](#) - Whisper.cpp Dokumentation: [GitHub](#) (<https://github.com/ggerranov/whisper.cpp>) - Piper TTS: [GitHub](#) (<https://github.com/rhasspy/piper>) - Kapitel 17: LLM-Integration für erweiterte NLP-Features

10.6 Zusammenfassung

In diesem Kapitel haben Sie gelernt:

- **Multi-Tenancy:** Verschiedene Ansätze und Best Practices
- **RBAC:** Rollen-basierte Zugriffskontrolle implementieren
- **Audit-Logging:** Vollständige Nachvollziehbarkeit aller Änderungen
- **Workflow-Management:** Geschäftsprozesse als Graph modellieren
- **DMS/ERP:** Dokumentenmanagement mit Versionierung und OCR
- **CRM:** Customer Relationship Management mit Lead-Scoring
- **Voice Assistant:** STT/TTS/LLM für Call Center und Meeting-Protokolle
- **Enterprise Best Practices:** Performance, Caching, Monitoring

Wichtige Erkenntnisse:

1. **Multi-Model vereinfacht Enterprise-Apps** - Eine Datenbank für alle Anforderungen
2. **Graph-Modell für Workflows** - Prozesse als Graph modellieren
3. **Audit-Log als First-Class Citizen** - Nicht nachrüsten, von Anfang an einplanen
4. **Hybrid-Search unverzichtbar** - Volltext + Vector Search kombinieren
5. **Background-Jobs für schwere Operations** - API bleibt responsiv
6. **Voice Assistant für moderne UX** - Natürlichsprachliche Interaktion steigert Produktivität

Übungen:

1. Erweitern Sie das DMS-System um E-Signaturen
2. Implementieren Sie Lead-Scoring mit Machine Learning
3. Erstellen Sie einen Workflow-Designer (GUI)
4. Integrieren Sie Email-Tracking ins CRM
5. Implementieren Sie Webhooks für externe Integrationen

6. Bauen Sie ein Meeting-Protokoll-System mit Voice Assistant

Im nächsten Kapitel tauchen wir in Realtime-Anwendungen ein: Chat und Kanban-Boards mit Live-Updates!

Kapitel 11: Kapitel 11 - Realtime

11.1 Einführung: Die Streaming-Architektur

Change Data Capture (CDC) ist eine kritische Komponente moderner Datenarchitekturen, die Echtzeit-Datenströme ermöglicht. ThemisDB implementiert CDC als natives Feature, das automatisch alle Mutationen (CREATE, UPDATE, DELETE) in einem append-only Event Log aufzeichnet. Dies ist ein fundamentaler Unterschied zu polyglot Systemen, die externe Tools wie Debezium benötigen, um Änderungen aus dem Write-Ahead Log (WAL) zu extrahieren.

Warum CDC in ThemisDB?

Architektonischer Vorteil: Da ThemisDB alle Datenmodelle (relational, graph, document, vector) in einem einheitlichen "Base Entity"-Format speichert (siehe Chapter 2), kann ein einzelner CDC-Stream **alle** Datentypen erfassen. In einem Polyglot-Setup müsste man separate CDC-Pipelines für PostgreSQL, Neo4j und ChromaDB betreiben, was die Komplexität vervielfacht und die Konsistenz gefährdet.

Use Cases: 1. **Real-Time Analytics:** Streaming von Datenänderungen in ein OLAP-System (z.B. ClickHouse) 2. **Event Sourcing:** Rekonstruktion des Anwendungszustands aus dem Event Log 3.

Materialized Views: Automatische Aktualisierung von Aggregationen 4. **Audit Trails:** BSI-konforme Nachvollziehbarkeit aller Datenänderungen 5. **Cross-System Sync:** Spiegelung von Daten in externe Systeme (Elasticsearch, Redis Cache) 6. **Kafka Integration:** Streaming in ein zentrales Event-Bus-System

Abb. 11.1: Real-time-Streaming-Architektur

11.2 CDC-Architektur und Datenmodell

11.2.1 Event-Struktur

Jedes CDC-Event in ThemisDB folgt einem standardisierten Schema, das maximale Flexibilität bietet:

```
{
  "sequence": 42,
  "type": "PUT",
  "key": "user:alice",
  "value": "{\"name\":\"Alice\",\"email\":\"alice@example.com\"}",
  "timestamp_ms": 1730294567123,
  "metadata": {
    "table": "user",
    "pk": "alice",
    "operation_type": "update",
    "user_id": "admin@example.com"
  }
}
```

Feld-Semantik:

- **sequence** (uint64): Monoton steigende ID, die **strikte Ordnung** garantiert. Diese Eigenschaft ist kritisch für die Konsistenz: Consumer können sicher sein, dass Event N vor Event N+1 aufgetreten ist. Die Sequence-Nummer wird atomar in RocksDB verwaltet (`changeFeed_sequence` - Schlüssel) und nutzt RocksDB's MVCC-Garantien.
- **type** (enum): `PUT` (Create/Update) oder `DELETE`. Zukünftige Erweiterungen könnten `TRANSACTION_COMMIT` / `TRANSACTION_ROLLBACK` für Transaktionsgrenzen hinzufügen, was Event Sourcing-Patterns vereinfachen würde.
- **key** (string): Vollständiger Entitätsschlüssel im Format `collection:primary_key`. Dies ermöglicht effiziente Filterung nach Präfixen (z.B. alle User-Events via `user:`-Filter).
- **value** (string|null): Bei PUT: JSON-seralisierte Entität. Bei DELETE: `null`. Die Speicherung als String (nicht als natives JSON-Objekt) minimiert den Serialisierungsaufwand im Hot Path. Consumer können mit `simdjson/serde_json` parsen.
- **timestamp_ms** (uint64): Millisekunden seit Unix Epoch. Wichtig: Dieser Timestamp basiert auf der Serverzeit zum Zeitpunkt des Commits, nicht auf Client-Zeit. Für verteilte Systeme sollte NTP-Synchronisation sichergestellt sein.
- **metadata** (JSON object): Frei erweiterbar. Standardfelder (`table` , `pk`) werden automatisch gesetzt. Anwendungen können zusätzliche Kontextinformationen hinzufügen (z.B. `user_id` für Audit-Trails, `source_ip` für Sicherheitsanalysen).

11.2.2 Physische Speicherung

CDC-Events werden im selben RocksDB-Backend wie die Base Entities gespeichert, jedoch in einem separaten Schlüsselraum:

Key-Format: `changefeed:{sequence_number}`

Die Sequence-Nummer wird Zero-padded (z.B. `changefeed:0000000000000042`), um lexikographische Sortierung zu garantieren. Dies ist kritisch für die Scan-Performance: Ein RocksDB-Iterator kann effizient von `changefeed:{from_seq}` bis `changefeed:{to_seq}` iterieren, ohne die Daten neu sortieren zu müssen.

Column Family Strategy:

- **Default:** Events werden in der Default Column Family gespeichert. Vorteil: Atomare Transaktionen mit den Base Entities sind trivial (ein RocksDB WriteBatch kann beide aktualisieren). Nachteil: Events und Entitäten konkurrieren um den Block Cache.
- **Dedicated CF (zukünftig):** Eine separate Column Family (`cf_changefeed`) würde isolierte Tuning-Parameter erlauben (z.B. aggressivere Compaction für Events, da sie nie aktualisiert werden).

11.2.3 Sequence-Management

Die atomare Sequenzvergabe ist der kritische Pfad für CDC-Schreiboperationen:

```
// Pseudo-Code: Atomare Sequence-Vergabe
rocksdb::WriteBatch batch;
uint64_t seq = increment_sequence_counter(batch); // Atomic increment
std::string event_key = format("changefeed:{:020d}", seq);
batch.Put(event_key, serialize_event(event));
db->Write(batch); // ACID: Sequence & Event atomar committed
```

Abb. 11.2: Change-Stream-Processing

Performance-Trade-off: Die zentrale Sequenzvergabe ist ein Bottleneck bei hohen Schreibraten (>100K writes/sec). Zukünftige Optimierungen:

1. **Batch Allocation:** Reserviere Sequence-Blöcke (z.B. 1.000 Sequences auf einmal), reduziere Contentions um Faktor 1000.
2. **Sharded Sequences:** In Sharding-Setups (Chapter 16) kann jeder Shard eigene Sequences verwalten. Globale Ordnung wird via `(shard_id, local_sequence)` Tupel erreicht.

CDC-Optionen

```
# Nur bestimmte Spalten tracken
stream = db.cdc.create_stream(
    name="user_updates",
    table="users",
    columns=["status", "last_seen"], # Nur diese Felder
    operations=["UPDATE"]
)

# Mit Filterung
stream = db.cdc.create_stream(
    name="important_messages",
    table="messages",
    filter="priority = 'high'",
    operations=["INSERT"]
)

# Mit Transformationen
stream = db.cdc.create_stream(
    name="enriched_events",
    table="orders",
    transform=lambda event: {
        **event,
        "customer_name": db.query("""
            FOR customer IN customers
            FILTER customer.id == @customer_id
            LIMIT 1
            RETURN customer.name
        """, {"customer_id": event.data["customer_id"]})[0]
    }
)
```

Server-Sent Events (SSE)

SSE ermöglicht es, Daten vom Server an Clients zu pushen.

SSE-Server-Setup

```
from flask import Flask, Response
from themisdb import ThemisDB
import json
import time

app = Flask(__name__)
db = ThemisDB()

def event_stream(channel):
    """Generator für SSE-Events"""
    stream = db.cdc.create_stream(
        name=f"sse_{channel}",
        table=channel,
        operations=["INSERT", "UPDATE", "DELETE"]
    )

    for event in stream:
        # SSE-Format: "data: JSON\n\n"
        yield f"data: {json.dumps(event.to_dict())}\n\n"

@app.route('/stream/<channel>')
def stream(channel):
    return Response(
        event_stream(channel),
        mimetype="text/event-stream",
        headers={
            "Cache-Control": "no-cache",
            "Connection": "keep-alive",
            "X-Accel-Buffering": "no" # Nginx
        }
    )
```


SSE-Client-Code

```
// JavaScript Client
const eventSource = new EventSource('/stream/messages');

eventSource.onmessage = function(event) {
    const data = JSON.parse(event.data);

    if (data.operation === 'INSERT') {
        addMessageToUI(data.after);
    } else if (data.operation === 'UPDATE') {
        updateMessageInUI(data.after);
    } else if (data.operation === 'DELETE') {
        removeMessageFromUI(data.before.id);
    }
};

eventSource.onerror = function(error) {
    console.error('SSE error:', error);
    // Automatische Reconnection
};
```

WebSocket-Integration

Für bidirektionale Kommunikation sind WebSockets ideal.

WebSocket-Server

```
from flask_socketio import SocketIO, emit, join_room, leave_room
from themisdb import ThemisDB

app = Flask(__name__)
socketio = SocketIO(app, cors_allowed_origins="*")
db = ThemisDB()

# User-Session-Tracking
active_users = {}

@socketio.on('connect')
def handle_connect():
    print(f'Client connected: {request.sid}')

@socketio.on('join_channel')
def handle_join(data):
    channel = data['channel']
    username = data['username']

    join_room(channel)
    active_users[request.sid] = {
        'username': username,
        'channel': channel
    }

    # Benachrichtige andere
    emit('user_joined', {
        'username': username,
        'timestamp': time.time()
    }, room=channel, skip_sid=request.sid)

    # CDC-Stream für diesen Channel
    start_cdc_stream(channel)

def start_cdc_stream(channel):
    """Background-Thread für CDC → WebSocket"""
    stream = db.cdc.create_stream(
        name=f"ws_{channel}",
```

```

        table="messages",
        filter=f"channel = '{channel}'"
    )

    def emit_changes():
        for event in stream:
            socketio.emit('message_update',
                           event.to_dict(),
                           room=channel)

    # In separatem Thread
    socketio.start_background_task(emit_changes)

@socketio.on('send_message')
def handle_message(data):
    channel = active_users[request.sid]['channel']
    username = active_users[request.sid]['username']

    # In DB schreiben
    db.execute("""
        INSERT {
            channel: @channel,
            username: @username,
            content: @content,
            timestamp: @timestamp
        } INTO messages
    """, {"channel": channel, "username": username, "content": data['content'], "timestamp": time

    # CDC wird automatisch notifizieren

```

WebSocket-Client

```
const socket = io('http://localhost:5000');

// Channel beitreten
socket.emit('join_channel', {
  channel: 'general',
  username: 'Alice'
});

// Nachrichten senden
function sendMessage(content) {
  socket.emit('send_message', {
    content: content
  });
}

// Nachrichten empfangen
socket.on('message_update', function(event) {
  if (event.operation === 'INSERT') {
    displayMessage(event.after);
  }
});

// Nutzer beigetreten
socket.on('user_joined', function(data) {
  console.log(`${data.username} ist beigetreten`);
});
```

Example: Realtime Chat (examples/18_realtime_chat)

Vollständige Chat-Anwendung mit Channels, Private Messages, Online-Status und Typing-Indikatoren.

Datenmodell

```
from themisdb import ThemisDB
from datetime import datetime

db = ThemisDB()

# Schema erstellen
db.execute("""
    CREATE TABLE users (
        id INTEGER PRIMARY KEY AUTOINCREMENT,
        username TEXT UNIQUE NOT NULL,
        email TEXT UNIQUE NOT NULL,
        avatar_url TEXT,
        status TEXT DEFAULT 'offline', -- online, offline, away
        last_seen TIMESTAMP,
        created_at TIMESTAMP DEFAULT CURRENT_TIMESTAMP
    )
""")

db.execute("""
    CREATE TABLE channels (
        id INTEGER PRIMARY KEY AUTOINCREMENT,
        name TEXT UNIQUE NOT NULL,
        description TEXT,
        is_private BOOLEAN DEFAULT FALSE,
        created_by INTEGER REFERENCES users(id),
        created_at TIMESTAMP DEFAULT CURRENT_TIMESTAMP
    )
""")

db.execute("""
    CREATE TABLE channel_members (
        channel_id INTEGER REFERENCES channels(id),
        user_id INTEGER REFERENCES users(id),
        joined_at TIMESTAMP DEFAULT CURRENT_TIMESTAMP,
        role TEXT DEFAULT 'member', -- admin, moderator, member
        PRIMARY KEY (channel_id, user_id)
    )
""")
```

```
db.execute("""
    CREATE TABLE messages (
        id INTEGER PRIMARY KEY AUTOINCREMENT,
        channel_id INTEGER REFERENCES channels(id),
        user_id INTEGER REFERENCES users(id),
        content TEXT NOT NULL,
        message_type TEXT DEFAULT 'text', -- text, image, file, system
        reply_to INTEGER REFERENCES messages(id),
        edited_at TIMESTAMP,
        created_at TIMESTAMP DEFAULT CURRENT_TIMESTAMP,
        INDEX idx_channel_time (channel_id, created_at),
        INDEX idx_user (user_id)
    )
""")

db.execute("""
    CREATE TABLE reactions (
        message_id INTEGER REFERENCES messages(id),
        user_id INTEGER REFERENCES users(id),
        emoji TEXT NOT NULL,
        created_at TIMESTAMP DEFAULT CURRENT_TIMESTAMP,
        PRIMARY KEY (message_id, user_id, emoji)
    )
""")

db.execute("""
    CREATE TABLE direct_messages (
        id INTEGER PRIMARY KEY AUTOINCREMENT,
        from_user_id INTEGER REFERENCES users(id),
        to_user_id INTEGER REFERENCES users(id),
        content TEXT NOT NULL,
        read_at TIMESTAMP,
        created_at TIMESTAMP DEFAULT CURRENT_TIMESTAMP,
        INDEX idx_participants (from_user_id, to_user_id, created_at)
    )
""")
```



```
db.execute("""
    CREATE TABLE typing_indicators (
        channel_id INTEGER REFERENCES channels(id),
        user_id INTEGER REFERENCES users(id),
        started_at TIMESTAMP DEFAULT CURRENT_TIMESTAMP,
        PRIMARY KEY (channel_id, user_id)
    )
""")
```

Chat-Backend

Das Chat-Backend implementiert eine Echtzeit-Messaging-Plattform mit Flask-SocketIO und ThemisDB. Die Architektur trennt sauber zwischen WebSocket-Events (für Echtzeit-Updates) und REST-API (für Datenabfragen). Der `ChatService` kapselt alle Datenbankoperationen, während die Socket-Handler die Echtzeitkommunikation zwischen Clients koordinieren.

Vollständiger Code: `examples/realtime_chat/backend/app.py` (ca. 400 Zeilen)

Kernkomponenten des Chat-Backends:

```
from flask import Flask, request, jsonify
from flask_socketio import SocketIO, emit, join_room
from themisdb import ThemisDB

app = Flask(__name__)
socketio = SocketIO(app, cors_allowed_origins="*")
db = ThemisDB()

# Aktive Verbindungen verwalten
connections = {} # sid -> {user_id, username, channels}
```

Zentrale ChatService-Klasse (Auszug):

```
class ChatService:
    @staticmethod
    def get_channel_messages(channel_id, limit=50, before_id=None):
        """Lädt Nachrichten mit Pagination"""
        query = """
        FOR msg IN messages
            FILTER msg.channel_id == @channel_id
            """ + ("AND msg._key < @before_id" if before_id else "") + """
        SORT msg.timestamp DESC
        LIMIT @limit
        RETURN msg
        """
        return db.query(query, {
            "channel_id": channel_id,
            "before_id": before_id,
            "limit": limit
        })

    @staticmethod
    def send_message(channel_id, user_id, username, text):
        """Speichert Nachricht und triggert CDC"""
        message = {
            "channel_id": channel_id,
            "user_id": user_id,
            "username": username,
            "text": text,
            "timestamp": datetime.now().isoformat()
        }
        # Insert triggert automatisch CDC-Event!
        return db.insert("messages", message)
```

WebSocket-Handler für Echtzeit-Events:

```
@socketio.on('connect')
def handle_connect():
    """Client verbindet sich"""
    user_id = request.args.get('userId')
    username = request.args.get('username')

    connections[request.sid] = {
        "user_id": user_id,
        "username": username,
        "channels": []
    }

    emit('connected', {'status': 'ok'})

@socketio.on('send_message')
def handle_send_message(data):
    """Client sendet Nachricht"""
    msg = ChatService.send_message(
        data['channel_id'],
        connections[request.sid]['user_id'],
        connections[request.sid]['username'],
        data['text']
    )

    # Broadcast an alle im Channel
    emit('new_message', msg, room=data['channel_id'])
```

REST-API-Endpunkte (Auszug):

```
@app.route('/api/channels', methods=['GET'])
def get_channels():
    """Liste aller Channels für User"""
    user_id = request.args.get('user_id')
    channels = ChatService.get_user_channels(user_id)
    return jsonify(channels)

@app.route('/api/messages/<channel_id>', methods=['GET'])
def get_messages(channel_id):
    """Nachrichten mit Pagination laden"""
    limit = int(request.args.get('limit', 50))
    before_id = request.args.get('before_id')
    messages = ChatService.get_channel_messages(
        channel_id, limit, before_id
    )
    return jsonify(messages)
```

CDC-Integration für Echtzeit-Sync:

Die vollständige Implementierung enthält zusätzlich: - Channel-Management (erstellen, beitreten, verlassen) - User-Presence-Tracking (online/offline Status) - Typing-Indicators - Read-Receipts - Message-Threading - File-Upload-Handling

Siehe vollständige Datei für alle Features und Error-Handling.

Chat-Frontend (React)

Das React-Frontend implementiert eine moderne Chat-Oberfläche mit Echtzeit-Updates über Socket.IO. Die Komponente verwaltet den Verbindungs-State, empfängt Live-Updates (neue Nachrichten, Typing-Indicators, User-Status) und bietet eine intuitive UI für Chat-Interaktionen. Alle State-Updates erfolgen reaktiv über React Hooks.

Vollständiger Code: `examples/realtime_chat/frontend/ChatApp.jsx` (ca. 200 Zeilen)

State-Management und Socket-Setup:

```
import React, { useState, useEffect, useRef } from 'react';
import io from 'socket.io-client';

const ChatApp = ({ userId, username }) => {
  // State für Channels, Messages, Typing-Indicators
  const [socket, setSocket] = useState(null);
  const [channels, setChannels] = useState([]);
  const [activeChannel, setActiveChannel] = useState(null);
  const [messages, setMessages] = useState([]);
  const [typingUsers, setTypingUsers] = useState(new Set());

  useEffect(() => {
    // Socket-Verbindung initialisieren
    const newSocket = io('http://localhost:5000');
    setSocket(newSocket);

    // Authentifizieren
    newSocket.emit('authenticate', { user_id: userId, username });

    return () => newSocket.close();
  }, [userId, username]);
```

Event-Handler für Echtzeit-Updates:

```
// Neue Nachricht empfangen
newSocket.on('new_message', (data) => {
  setMessages(prev => [...prev, data.message]);
  scrollToBottom();
});

// Typing-Indicator
newSocket.on('user_typing', (data) => {
  setTypingUsers(prev => new Set([...prev, data.username]));
});

// User-Presence
newSocket.on('user_joined', (data) => {
  setOnlineUsers(prev => [...prev, data]);
});
```

Nachricht senden mit Typing-Feedback:

```
const sendMessage = () => {
  if (!newMessage.trim()) return;

  socket.emit('send_message', {
    channel_id: activeChannel.id,
    text: newMessage,
    message_type: 'text'
  });

  setNewMessage('');
  stopTyping();
};

const handleTyping = () => {
  socket.emit('user_typing', { channel_id: activeChannel.id });

  // Auto-stop nach 3 Sekunden
  clearTimeout(typingTimeoutRef.current);
  typingTimeoutRef.current = setTimeout(stopTyping, 3000);
};
```

UI-Rendering (Konzept):

```
    return (
      <div className="chat-container">
        <ChannelList
          channels={channels}
          activeChannel={activeChannel}
          onSelectChannel={joinChannel}
        />
        <MessageList
          messages={messages}
          typingUsers={Array.from(typingUsers)}
        />
        <MessageInput
          value={newMessage}
          onChange={(e) => { setNewMessage(e.target.value); handleTyping(); }}
          onSend={sendMessage}
        />
      </div>
    );
  };
};
```

Die vollständige Implementierung enthält zusätzlich: - Message-Threading (Antworten auf Nachrichten) - Reactions (Emoji-Reaktionen) - File-Upload mit Progress - Message-Editing und Deletion - Infinite-Scroll für Message-History - Unread-Message-Counter - Sound-Notifications

Siehe vollständige Datei für alle UI-Komponenten und Styling.

Chat-Features

Das vollständige Chat-Example demonstriert:

1. **Echtzeit-Nachrichten:** Sofortige Zustellung via WebSocket + CDC
2. **Online-Status:** Wer ist gerade online?
3. **Typing-Indikatoren:** "Alice is typing..."
4. **Reaktionen:** Emoji-Reactions auf Nachrichten
5. **Threads:** Antworten auf bestimmte Nachrichten
6. **Nachrichtенbearbeitung:** Edit-History mit Timestamps
7. **Private Channels:** Eingeschränkter Zugriff
8. **Direktnachrichten:** 1-on-1 Chats

9. **Presence:** Last-Seen und Away-Status

10. **Pagination:** Unendliches Scrollen durch Historie

Example: Kanban Board (examples/16_kanban_board)

Vollständige Kanban-Board-Anwendung mit Drag & Drop, Realtime-Updates und Team-Collaboration.

Datenmodell

```
from themisdb import ThemisDB

db = ThemisDB()

db.execute("""
    CREATE TABLE boards (
        id INTEGER PRIMARY KEY AUTOINCREMENT,
        name TEXT NOT NULL,
        description TEXT,
        created_by INTEGER REFERENCES users(id),
        created_at TIMESTAMP DEFAULT CURRENT_TIMESTAMP
    )
""")

db.execute("""
    CREATE TABLE columns (
        id INTEGER PRIMARY KEY AUTOINCREMENT,
        board_id INTEGER REFERENCES boards(id),
        name TEXT NOT NULL,
        position INTEGER NOT NULL,
        wip_limit INTEGER, -- Work-In-Progress Limit
        created_at TIMESTAMP DEFAULT CURRENT_TIMESTAMP,
        INDEX idx_board (board_id, position)
    )
""")

db.execute("""
    CREATE TABLE cards (
        id INTEGER PRIMARY KEY AUTOINCREMENT,
        column_id INTEGER REFERENCES columns(id),
        board_id INTEGER REFERENCES boards(id),
        title TEXT NOT NULL,
        description TEXT,
        assigned_to INTEGER REFERENCES users(id),
        position INTEGER NOT NULL,
        priority TEXT DEFAULT 'medium', -- low, medium, high, urgent
        due_date TIMESTAMP,
        created_by INTEGER REFERENCES users(id),
```

```
        created_at TIMESTAMP DEFAULT CURRENT_TIMESTAMP,
        updated_at TIMESTAMP DEFAULT CURRENT_TIMESTAMP,
        INDEX idx_column (column_id, position),
        INDEX idx_board (board_id)
    )
    """
)

db.execute("""
    CREATE TABLE card_activities (
        id INTEGER PRIMARY KEY AUTOINCREMENT,
        card_id INTEGER REFERENCES cards(id),
        user_id INTEGER REFERENCES users(id),
        action_type TEXT NOT NULL, -- created, moved, assigned, commented
        details JSON,
        created_at TIMESTAMP DEFAULT CURRENT_TIMESTAMP,
        INDEX idx_card (card_id, created_at)
    )
    """
)

db.execute("""
    CREATE TABLE card_labels (
        card_id INTEGER REFERENCES cards(id),
        label TEXT NOT NULL,
        color TEXT,
        PRIMARY KEY (card_id, label)
    )
    """
)
```

Kanban-Backend

```

from flask import Flask, jsonify, request
from flask_socketio import SocketIO, emit, join_room
from themisdb import ThemisDB
import time

app = Flask(__name__)
socketio = SocketIO(app, cors_allowed_origins="*")
db = ThemisDB()

class KanbanService:
    @staticmethod
    def get_board(board_id):
        """Board mit allen Spalten und Karten laden"""
        board = db.query("""
            FOR board IN boards
            FILTER board.id == @board_id
            LIMIT 1
            RETURN board
        """, {"board_id": board_id})[0]

        columns = db.query("""
            FOR column IN columns
            FILTER column.board_id == @board_id
            SORT column.position ASC
            RETURN column
        """, {"board_id": board_id})

        for col in columns:
            col['cards'] = db.query("""
                FOR card IN cards
                FILTER card.column_id == @column_id
                LET assigned_name = (
                    FOR user IN users
                    FILTER card.assigned_to == user.id
                    LIMIT 1
                    RETURN user.username
                )[0]
                SORT card.position ASC
            """, {"column_id": col.id})

```

```

        RETURN MERGE(card, {assigned_to_name: assigned_name})
        """ , {"column_id": col['id']})

    board['columns'] = columns
    return board

@staticmethod
def move_card(card_id, to_column_id, to_position):
    """Karte verschieben"""
    with db.transaction():
        # Aktuelle Position
        current = db.query("""
            FOR card IN cards
            FILTER card.id == @card_id
            LIMIT 1
            RETURN {column_id: card.column_id, position: card.position}
        """, {"card_id": card_id})[0]

        from_column_id = current['column_id']
        from_position = current['position']

        # Position in alter Spalte aktualisieren
        db.execute("""
            UPDATE cards
            SET position = position - 1
            WHERE column_id = ? AND position > ?
        """, [from_column_id, from_position])

        # Position in neuer Spalte freimachen
        db.execute("""
            UPDATE cards
            SET position = position + 1
            WHERE column_id = ? AND position >= ?
        """, [to_column_id, to_position])

        # Karte verschieben
        db.execute("""
            UPDATE cards

```

```

        SET column_id = ?, position = ?, updated_at = CURRENT_TIMESTAMP
        WHERE id = ?
    """, [to_column_id, to_position, card_id])

# Activity loggen
db.execute("""
    INSERT INTO card_activities (card_id, user_id, action_type, details)
    VALUES (?, ?, 'moved', ?)
    """, [card_id, request.user_id, json.dumps({
        'from_column': from_column_id,
        'to_column': to_column_id
    })])

@staticmethod
def create_card(board_id, column_id, title, description, assigned_to=None):
    """Neue Karte erstellen"""
    with db.transaction():
        # Position am Ende der Spalte
        position = db.query("""
            FOR card IN cards
            FILTER card.column_id == @column_id
            COLLECT AGGREGATE max_pos = MAX(card.position)
            RETURN COALESCE(max_pos, -1) + 1
        """, {"column_id": column_id})[0]

    result = db.execute("""
        INSERT {
            board_id: @board_id,
            column_id: @column_id,
            title: @title,
            description: @description,
            assigned_to: @assigned_to,
            position: @position,
            created_by: @created_by
        } INTO cards
        RETURN NEW
    """, {
        "board_id": board_id,

```



```

        "column_id": column_id,
        "title": title,
        "description": description,
        "assigned_to": assigned_to,
        "position": position,
        "created_by": request.user_id
    })

    card = result[0]

    # Activity
    db.execute("""
        INSERT {
            card_id: @card_id,
            user_id: @user_id,
            action_type: 'created'
        } INTO card_activities
        """, {"card_id": card['id'], "user_id": request.user_id})

    return card

@staticmethod
def update_card(card_id, **updates):
    """Karte aktualisieren"""
    allowed_fields = ['title', 'description', 'assigned_to', 'priority', 'due_date']
    set_clause = ', '.join([f"{field} = ?" for field in updates if field in allowed_fields])
    values = [updates[field] for field in updates if field in allowed_fields]
    values.append(card_id)

    db.execute(f"""
        UPDATE cards
        SET {set_clause}, updated_at = CURRENT_TIMESTAMP
        WHERE id = ?
        """, values)

    # Activity
    db.execute("""
        INSERT {

```

```
        card_id: @card_id,
        user_id: @user_id,
        action_type: 'updated',
        details: @details
    } INTO card_activities
    """ , {"card_id": card_id, "user_id": request.user_id, "details": json.dumps(updates)})

# WebSocket-Handler
@socketio.on('join_board')
def handle_join_board(data):
    board_id = data['board_id']
    join_room(f'board_{board_id}')

    # Board-Daten senden
    board = KanbanService.get_board(board_id)
    emit('board_state', board)

    # CDC-Stream starten
    start_board_cdc(board_id)

@socketio.on('move_card')
def handle_move_card(data):
    card_id = data['card_id']
    to_column_id = data['to_column_id']
    to_position = data['to_position']
    board_id = data['board_id']

    try:
        KanbanService.move_card(card_id, to_column_id, to_position)
        # CDC benachrichtigt andere Clients
    except Exception as e:
        emit('error', {'message': str(e)})

@socketio.on('create_card')
def handle_create_card(data):
    card = KanbanService.create_card(
        data['board_id'],
        data['column_id'],
```

```
        data['title'],
        data.get('description'),
        data.get('assigned_to')
    )
    # CDC benachrichtigt

@socketio.on('update_card')
def handle_update_card(data):
    card_id = data.pop('card_id')
    KanbanService.update_card(card_id, **data)
    # CDC benachrichtigt

# CDC für Board
active_board_streams = set()

def start_board_cdc(board_id):
    if board_id in active_board_streams:
        return

    active_board_streams.add(board_id)

def cdc_worker():
    # Cards-Stream
    cards_stream = db.cdc.create_stream(
        name=f"kanban_cards_{board_id}",
        table="cards",
        filter=f"board_id = {board_id}",
        operations=["INSERT", "UPDATE", "DELETE"]
    )

    # Columns-Stream
    columns_stream = db.cdc.create_stream(
        name=f"kanban_columns_{board_id}",
        table="columns",
        filter=f"board_id = {board_id}",
        operations=["INSERT", "UPDATE", "DELETE"]
    )
```

```

    # Beide Streams kombinieren
    for event in combined_stream([cards_stream, columns_stream]):
        if event.table == 'cards':
            if event.operation == 'INSERT':
                socketio.emit('card_created', event.after,
                               room=f'board_{board_id}')
            elif event.operation == 'UPDATE':
                socketio.emit('card_updated', event.after,
                               room=f'board_{board_id}')
            elif event.operation == 'DELETE':
                socketio.emit('card_deleted', {'id': event.before['id']},
                               room=f'board_{board_id}')

        elif event.table == 'columns':
            # Spalten-Update
            socketio.emit('column_updated', event.after,
                           room=f'board_{board_id}')

    socketio.start_background_task(cdc_worker)

def combined_stream(streams):
    """Mehrere CDC-Streams kombinieren"""
    import queue
    import threading

    q = queue.Queue()

    def stream_worker(stream):
        for event in stream:
            q.put(event)

    for stream in streams:
        threading.Thread(target=stream_worker, args=(stream,), daemon=True).start()

    while True:
        yield q.get()

```

```
if __name__ == '__main__':  
    socketio.run(app, host='0.0.0.0', port=5000)
```

Kanban-Frontend (React)

```
// KanbanBoard.jsx
import React, { useState, useEffect } from 'react';
import { DragDropContext, Droppable, Draggable } from 'react-beautiful-dnd';
import io from 'socket.io-client';

const KanbanBoard = ({ boardId, userId }) => {
  const [socket, setSocket] = useState(null);
  const [board, setBoard] = useState(null);
  const [columns, setColumns] = useState([]);

  useEffect(() => {
    const newSocket = io('http://localhost:5000');
    setSocket(newSocket);

    newSocket.emit('join_board', { board_id: boardId });

    newSocket.on('board_state', (data) => {
      setBoard(data);
      setColumns(data.columns);
    });

    newSocket.on('card_created', (card) => {
      setColumns(prev => prev.map(col => {
        if (col.id === card.column_id) {
          return { ...col, cards: [...col.cards, card] };
        }
        return col;
      }));
    });

    newSocket.on('card_updated', (card) => {
      setColumns(prev => prev.map(col => ({
        ...col,
        cards: col.cards.map(c => c.id === card.id ? card : c)
      })));
    });

    newSocket.on('card_deleted', (data) => {
```

```
        setColumns(prev => prev.map(col => ({
            ...col,
            cards: col.cards.filter(c => c.id !== data.id)
        })));
    });

    return () => newSocket.close();
}, [boardId]);

const onDragEnd = (result) => {
    if (!result.destination) return;

    const { source, destination } = result;

    if (source.droppableId === destination.droppableId &&
        source.index === destination.index) {
        return;
    }

    // Optimistisches Update
    const newColumns = [...columns];
    const sourceColumn = newColumns.find(c => c.id === parseInt(source.droppableId));
    const destColumn = newColumns.find(c => c.id === parseInt(destination.droppableId));

    const [movedCard] = sourceColumn.cards.splice(source.index, 1);
    destColumn.cards.splice(destination.index, 0, movedCard);

    setColumns(newColumns);

    // An Server senden
    socket.emit('move_card', {
        card_id: parseInt(result.draggableId),
        to_column_id: parseInt(destination.droppableId),
        to_position: destination.index,
        board_id: boardId
    });
};
```



```

if (!board) return <div>Loading...</div>;

return (
  <div className="kanban-board">
    <h1>{board.name}</h1>

    <DragDropContext onDragEnd={onDragEnd}>
      <div className="columns">
        {columns.map(column => (
          <div key={column.id} className="column">
            <h3>
              {column.name}
              <span className="card-count">{column.cards.length}</span>
              {column.wip_limit && (
                <span className={`wip-limit ${column.cards.length > column.wip_limit}
                  / {column.wip_limit}
                </span>
              )}
            </h3>

            <Draggable droppableId={column.id.toString()}>
              {(provided, snapshot) => (
                <div
                  ref={provided.innerRef}
                  {...provided.draggableProps}
                  className={`cards ${snapshot.isDraggingOver ? 'dragging-over' : ''}}
                >
                  {column.cards.map((card, index) => (
                    <Draggable
                      key={card.id}
                      draggableId={card.id.toString()}
                      index={index}
                    >
                      {(provided, snapshot) => (
                        <div
                          ref={provided.innerRef}
                          {...provided.draggableProps}
                          {...provided.dragHandleProps}

```

```

        className={`card priority-${card.priority}
    >
    <h4>{card.title}</h4>
    {card.description} && <p>{card.description}
    {card.assigned_to_name} && (
        <div className="assignee">
            {card.assigned_to_name}
        </div>
    )}
    {card.due_date} && (
        <div className="due-date">
            {new Date(card.due_date).toLocaleDateString()}
        </div>
    )}
    </div>
    )}
    </Draggable>
    )}
    {provided.placeholder}
</div>
    )}
    </Droppable>
</div>
    )}
    </DragDropContext>
</div>
    );
};

export default KanbanBoard;

```

Kanban-Features

Das Kanban-Board-Example demonstriert:

1. **Drag & Drop:** Karten zwischen Spalten verschieben
2. **Realtime-Sync:** Alle Nutzer sehen Änderungen sofort

3. **WIP-Limits:** Work-In-Progress Beschränkungen
4. **Prioritäten:** Visuelle Kennzeichnung (low, medium, high, urgent)
5. **Zuweisungen:** Karten Teammitgliedern zuordnen
6. **Due Dates:** Fälligkeitsdaten mit Warnungen
7. **Labels:** Flexible Kategorisierung
8. **Activity-Log:** Vollständige Historie aller Änderungen
9. **Board-Analytics:** Durchlaufzeit, Cycle-Time, etc.
10. **Custom Columns:** Beliebige Workflow-Stufen

Event-Driven Architecture

Realtime-Anwendungen profitieren von event-driven Design.

Event-Bus-Pattern

```
from themisdb import ThemisDB
from typing import Callable, List
import threading

class EventBus:
    def __init__(self, db: ThemisDB):
        self.db = db
        self.handlers = {} # event_type -> [handlers]
        self.running = False

    def subscribe(self, event_type: str, handler: Callable):
        """Handler für Event-Typ registrieren"""
        if event_type not in self.handlers:
            self.handlers[event_type] = []
        self.handlers[event_type].append(handler)

    def publish(self, event_type: str, data: dict):
        """Event publishen"""
        self.db.execute("""
            INSERT {
                event_type: @event_type,
                data: @data,
                created_at: DATE_NOW()
            } INTO events
        """, {"event_type": event_type, "data": json.dumps(data)})

    def start(self):
        """Event-Processing starten"""
        self.running = True

    def process_events():
        stream = self.db.cdc.create_stream(
            name="event_bus",
            table="events",
            operations=["INSERT"]
        )

        for event in stream:
```

```
        if not self.running:
            break

        event_type = event.after['event_type']
        data = json.loads(event.after['data'])

        # Handler aufrufen
        if event_type in self.handlers:
            for handler in self.handlers[event_type]:
                try:
                    handler(data)
                except Exception as e:
                    print(f"Handler error: {e}")

        threading.Thread(target=process_events, daemon=True).start()

    def stop(self):
        self.running = False

# Verwendung
bus = EventBus(db)

# Handler registrieren
@bus.subscribe('user_registered')
def send_welcome_email(data):
    print(f"Sending email to {data['email']}")

@bus.subscribe('order_placed')
def update_inventory(data):
    print(f"Reducing stock for order {data['order_id']}")

# Events publishen
bus.publish('user_registered', {
    'user_id': 123,
    'email': 'alice@example.com'
})

bus.start()
```

CQRS-Pattern

Command Query Responsibility Segregation für Realtime-Apps:

```
class OrderService:

    def __init__(self, db: ThemisDB, event_bus: EventBus):
        self.db = db
        self.event_bus = event_bus

    # COMMAND: Write-Seite
    def place_order(self, user_id, items):
        with self.db.transaction():
            # Order erstellen
            order_id = self.db.execute("""
                INSERT {
                    user_id: @user_id,
                    status: 'pending',
                    created_at: DATE_NOW()
                } INTO orders
                RETURN NEW.id
            """, {"user_id": user_id})[0]

            # Items
            for item in items:
                self.db.execute("""
                    INSERT {
                        order_id: @order_id,
                        product_id: @product_id,
                        quantity: @quantity,
                        price: @price
                    } INTO order_items
                """, {
                    "order_id": order_id,
                    "product_id": item['product_id'],
                    "quantity": item['quantity'],
                    "price": item['price']
                })

            # Event publishen
            self.event_bus.publish('order_placed', {
                'order_id': order_id,
                'user_id': user_id,
```



```
        'items': items
    })

    return order_id

# QUERY: Read-Seite (materialized view)
def get_order_summary(self, order_id):
    return self.db.query("""
        SELECT
            o.id, o.status, o.created_at,
            u.name as customer_name,
            COUNT(oi.id) as item_count,
            SUM(oi.quantity * oi.price) as total
        FROM orders o
        JOIN users u ON o.user_id = u.id
        LEFT JOIN order_items oi ON o.id = oi.order_id
        WHERE o.id = ?
        GROUP BY o.id
    """, [order_id])[0]

# Event-Handler aktualisieren materialized views
@event_bus.subscribe('order_placed')
def update_order_cache(data):
    # Cache/Read-Model aktualisieren
    pass
```

Best Practices

1. Connection Management

```
class ConnectionPool:
    def __init__(self, max_connections=100):
        self.max_connections = max_connections
        self.active_connections = {}
        self.semaphore = threading.Semaphore(max_connections)

    def add_connection(self, sid, user_id):
        with self.semaphore:
            if len(self.active_connections) >= self.max_connections:
                raise ValueError("Too many connections")
            self.active_connections[sid] = user_id

    def remove_connection(self, sid):
        if sid in self.active_connections:
            del self.active_connections[sid]
            self.semaphore.release()
```

2. Rate Limiting

```
from collections import defaultdict
import time

class RateLimiter:
    def __init__(self, max_requests=10, window=60):
        self.max_requests = max_requests
        self.window = window
        self.requests = defaultdict(list)

    def allow(self, user_id):
        now = time.time()
        # Alte Einträge entfernen
        self.requests[user_id] = [
            t for t in self.requests[user_id]
            if now - t < self.window
        ]

        if len(self.requests[user_id]) >= self.max_requests:
            return False

        self.requests[user_id].append(now)
        return True

# Middleware
@socketio.on('send_message')
def handle_send_message(data):
    if not rate_limiter.allow(current_user_id):
        return emit('error', {'message': 'Rate limit exceeded'})
    # ... rest
```

3. Message Deduplication

```
class MessageDeduplicator:
    def __init__(self, ttl=60):
        self.seen = {} # message_id -> timestamp
        self.ttl = ttl

    def is_duplicate(self, message_id):
        now = time.time()

        # Cleanup
        self.seen = {
            mid: ts for mid, ts in self.seen.items()
            if now - ts < self.ttl
        }

        if message_id in self.seen:
            return True

        self.seen[message_id] = now
        return False
```

4. Graceful Shutdown

```
import signal
import sys

def graceful_shutdown(signum, frame):
    print("Shutting down gracefully...")

    # Alle Clients benachrichtigen
    socketio.emit('server_shutdown', {
        'message': 'Server ist down für Wartung',
        'reconnect_in': 60
    })

    # CDC-Streams stoppen
    for stream_id in active_cdc_streams:
        stop_cdc_stream(stream_id)

    # Connections schließen
    socketio.stop()

    sys.exit(0)

signal.signal(signal.SIGINT, graceful_shutdown)
signal.signal(signal.SIGTERM, graceful_shutdown)
```

5. Monitoring & Metrics

```
from prometheus_client import Counter, Histogram, Gauge
import time

# Metriken
messages_sent = Counter('messages_sent_total', 'Total messages sent')
message_latency = Histogram('message_latency_seconds', 'Message delivery latency')
active_connections_gauge = Gauge('active_connections', 'Number of active WebSocket connections')

@socketio.on('send_message')
def handle_send_message(data):
    start_time = time.time()

    # ... message handling ...

    messages_sent.inc()
    message_latency.observe(time.time() - start_time)

@socketio.on('connect')
def handle_connect():
    active_connections_gauge.inc()

@socketio.on('disconnect')
def handle_disconnect():
    active_connections_gauge.dec()
```

Performance-Optimierungen

1. Message-Batching

```
class MessageBatcher:
    def __init__(self, max_batch_size=100, max_wait_ms=100):
        self.max_batch_size = max_batch_size
        self.max_wait_ms = max_wait_ms
        self.batch = []
        self.last_flush = time.time()

    def add(self, message):
        self.batch.append(message)

        if len(self.batch) >= self.max_batch_size or \
            (time.time() - self.last_flush) * 1000 >= self.max_wait_ms:
            self.flush()

    def flush(self):
        if not self.batch:
            return

        # Bulk-Insert
        db.executemany("""
            INSERT INTO messages (channel_id, user_id, content)
            VALUES (?, ?, ?)
            """, [(m['channel_id'], m['user_id'], m['content']) for m in self.batch])

        self.batch = []
        self.last_flush = time.time()
```

2. Connection Pooling

```
from themisdb import ThemisDB, ConnectionPool

# Connection Pool für DB
pool = ConnectionPool(
    min_size=10,
    max_size=50,
    max_idle_time=300
)

def get_db_connection():
    return pool.acquire()

def release_db_connection(conn):
    pool.release(conn)
```


3. Caching

```
from functools import lru_cache
import time

class CachedQuery:
    def __init__(self, ttl=60):
        self.cache = {}
        self.ttl = ttl

    def get(self, query, params):
        key = (query, tuple(params))

        if key in self.cache:
            value, timestamp = self.cache[key]
            if time.time() - timestamp < self.ttl:
                return value

        # Cache Miss
        result = db.query(query, params)
        self.cache[key] = (result, time.time())
        return result

# Verwendung
cache = CachedQuery(ttl=30)

def get_channel_members(channel_id):
    return cache.get("""
        FOR member IN channel_members
        FILTER member.channel_id == @channel_id
        RETURN member
    """, {"channel_id": channel_id})
```

Zusammenfassung

In diesem Kapitel haben Sie gelernt:

1. **Change Data Capture (CDC)**: Datenänderungen verfolgen und darauf reagieren

2. **Server-Sent Events (SSE):** Unidirektionale Push-Updates
3. **WebSockets:** Bidirektionale Realtime-Kommunikation
4. **Event-Driven Architecture:** Entkoppelte, skalierbare Systeme
5. **Realtime Chat:** Vollständige Implementierung mit allen Features
6. **Kanban Board:** Collaborative Drag & Drop mit Sync
7. **Best Practices:** Connection Management, Rate Limiting, Monitoring
8. **Performance:** Batching, Pooling, Caching

Realtime-Anwendungen mit ThemisDB sind einfach zu implementieren dank: - Integriertem CDC-System
- MVCC für konfliktfreie Reads - Flexible Event-Streaming-Mechanismen - Starke Transaktionsgarantien

Im nächsten Kapitel schauen wir uns Computer Vision-Anwendungen an, wo wir Bilder speichern, analysieren und durchsuchen.

Übungen

1. **Chat-Erweiterung:** Fügen Sie Voice Messages und File Sharing hinzu
2. **Kanban-Analytics:** Cycle Time und Lead Time berechnen
3. **Presence-System:** Implementieren Sie "Alice is viewing card #42"
4. **Notification-System:** Push-Benachrichtigungen bei @mentions
5. **Realtime-Dashboard:** Live-Metrics mit automatischer Aktualisierung
6. **Collaborative Editor:** Google Docs-ähnliche Textbearbeitung
7. **Gaming:** Einfaches Multiplayer-Spiel mit ThemisDB als Backend
8. **Live-Poll:** Echtzeit-Abstimmungssystem mit automatischen Updates
9. **Activity-Feed:** Timeline aller Aktivitäten im System
10. **Realtime-Search:** Live-Search-Results während dem Tippen

Kapitel 12: Kapitel 12 - Computer Vision

12.1 Einführung in Computer Vision Datenbanken

Das Problem: Bilder sind mehr als nur Dateien

Stellen Sie sich vor, Sie haben 100.000 Drohnenbilder von einem Baugelände. Wie finden Sie: - Alle Bilder, die ein bestimmtes Fahrzeug zeigen? - Bilder mit Sicherheitsproblemen (fehlende Helme)? - Ähnliche Perspektiven des gleichen Gebäudes? - Zeitliche Entwicklung eines Bauprojekts?

Traditionelle Datenbanken speichern nur Dateinamen - **Computer Vision Datenbanken** analysieren und indexieren Bildinhalte.

Computer Vision Use Cases

Use Case	Datentyp	Volumen	Beispiel
Drohnen-Inspektion	Bilder + GPS + Metadata	10K-1M	Baustellen, Infrastruktur
Medizinische Bildgebung	DICOM-Bilder	100K-10M	Röntgen, MRT, CT
Retail Analytics	Video-Frames	1M-100M	Kundenverhalten, Warenpräsentation
Autonomous Vehicles	Sensor-Fusion	100M+	LiDAR, Kameras, Radar
Satellite Imagery	Multi-Spectral Images	1M-10M	Landnutzung, Umweltmonitoring

Herausforderungen

Storage: - Große Dateien (2-20 MB pro Hochauflösungsbild) - Verschiedene Formate (JPEG, PNG, TIFF, RAW) - Metadata (EXIF, GPS, Kameraeinstellungen)

Processing: - Feature-Extraktion (SIFT, ORB, Deep Learning) - Object Detection (YOLO, Faster R-CNN) - Image Classification (ResNet, EfficientNet)

Retrieval: - Content-Based Image Retrieval (CBIR) - Similarity Search über Visual Features - Spatial Queries (GPS-basiert) - Temporal Queries (Zeitreihen)

Abb. 12.1: Computer-Vision-Pipeline

12.2 Computer Vision Datenmodell

Schema für Bildmetadaten

```
-- Bilder mit vollständigen Metadaten
CREATE TABLE images (
    image_id UUID PRIMARY KEY DEFAULT gen_random_uuid(),
    filename VARCHAR(255) NOT NULL,
    file_path TEXT NOT NULL,
    file_size_bytes BIGINT,
    format VARCHAR(20), -- 'JPEG', 'PNG', 'TIFF', ...

    -- Bild-Eigenschaften
    width INTEGER,
    height INTEGER,
    bit_depth INTEGER,
    color_space VARCHAR(20),

    -- Aufnahme-Metadaten (EXIF)
    captured_at TIMESTAMP,
    camera_make VARCHAR(100),
    camera_model VARCHAR(100),
    focal_length_mm FLOAT,
    aperture_f_stop FLOAT,
    iso INTEGER,
    shutter_speed VARCHAR(20),

    -- GPS-Daten
    gps_latitude DOUBLE PRECISION,
    gps_longitude DOUBLE PRECISION,
    gps_altitude_m FLOAT,
    location GEOGRAPHY(Point, 4326),

    -- Kategorisierung
    category VARCHAR(100),
    tags TEXT[],

    -- Zusätzliche Metadaten
    metadata JSONB,

    -- Zeitstempel
    created_at TIMESTAMP DEFAULT NOW(),
```

```

        updated_at TIMESTAMP DEFAULT NOW()
    );

    -- Spatial Index für GPS-Queries
    CREATE INDEX idx_images_location ON images USING GIST(location);

    -- Index für zeitbasierte Queries
    CREATE INDEX idx_images_captured_at ON images (captured_at DESC);

    -- Full-Text Index für Tags
    CREATE INDEX idx_images_tags ON images USING GIN(tags);

```

Feature-Extraktion Tabelle

```

-- Visuelle Features (z.B. von CNN)
CREATE TABLE image_features (
    image_id UUID PRIMARY KEY REFERENCES images(image_id),

    -- Deep Learning Features (z.B. ResNet-50)
    deep_features VECTOR(2048), -- 2048-dimensional embedding

    -- Classical Features
    color_histogram FLOAT[], -- RGB histogram
    edge_features FLOAT[], -- Edge detection features
    texture_features FLOAT[], -- Texture descriptors

    -- Feature Metadata
    feature_extractor VARCHAR(100),
    extraction_timestamp TIMESTAMP DEFAULT NOW()
);

-- HNSW Index für Visual Similarity Search
CREATE INDEX idx_image_features_deep ON image_features
USING hnsw (deep_features vector_cosine_ops)
WITH (m = 16, ef_construction = 200);

```

Object Detection Results

```
-- Erkannte Objekte in Bildern
CREATE TABLE detected_objects (
    detection_id UUID PRIMARY KEY DEFAULT gen_random_uuid(),
    image_id UUID REFERENCES images(image_id),

    -- Objekt-Klassifikation
    object_class VARCHAR(100),
    confidence FLOAT, -- 0.0 to 1.0

    -- Bounding Box
    bbox_x INTEGER,
    bbox_y INTEGER,
    bbox_width INTEGER,
    bbox_height INTEGER,

    -- Optional: Segmentation Mask
    segmentation_mask BYTEA,

    -- Detection Metadata
    detector_model VARCHAR(100),
    detection_timestamp TIMESTAMP DEFAULT NOW()
);

-- Index für Object-Search
CREATE INDEX idx_detected_objects_class ON detected_objects (object_class, confidence);
CREATE INDEX idx_detected_objects_image ON detected_objects (image_id);
```

12.3 Bildverarbeitung mit ThemisDB

Bild-Upload mit Metadata-Extraktion

Die Upload-Funktion extrahiert automatisch EXIF-Metadaten aus Bildern, inkl. Kamera-Informationen, Aufnahmezeitpunkt und GPS-Koordinaten. Die GPS-Daten werden als PostGIS-Geometrie (ST_MakePoint) gespeichert, was räumliche Abfragen (z.B. "alle Bilder in 5km Radius") ermöglicht. Das System berechnet zusätzlich Perceptual Hashes für Duplikatserkennung.

Vollständiger Code: `examples/12_computer_vision/image_upload.py` (~67 Zeilen)

Bild-Upload mit EXIF-Extraktion (Kernfunktionalität):


```
from PIL import Image
from PIL.ExifTags import TAGS, GPSTAGS
import hashlib

def extract_exif(image_path):
    """Extrahiere EXIF-Daten inkl. GPS"""
    img = Image.open(image_path)
    exif_data = {}

    if hasattr(img, '_getexif') and img._getexif():
        exif = img._getexif()
        for tag_id, value in exif.items():
            tag = TAGS.get(tag_id, tag_id)
            exif_data[tag] = value

    # GPS-Koordinaten dekodieren
    gps_info = exif_data.get('GPSInfo', {})
    gps_data = {GPSTAGS.get(k, k): v for k, v in gps_info.items()}

    return exif_data, gps_data

def upload_image(image_path, category=None, tags=None):
    """Upload mit automatischer Metadata-Extraktion"""
    img = Image.open(image_path)
    exif_data, gps_data = extract_exif(image_path)

    # GPS-Koordinaten konvertieren
    latitude = convert_to_degrees(gps_data.get('GPSLatitude', []))
    longitude = convert_to_degrees(gps_data.get('GPSLongitude', []))

    image_data = {
        'filename': os.path.basename(image_path),
        'format': img.format,
        'width': img.width,
        'height': img.height,
        'captured_at': exif_data.get('DateTime'),
        'camera_make': exif_data.get('Make'),
        'camera_model': exif_data.get('Model'),
```

```
        'gps_latitude': latitude,
        'gps_longitude': longitude,
        'category': category,
        'tags': tags or []
    }

    # PostGIS-Geometrie für räumliche Abfragen
    image_id = themis.execute("""
        INSERT INTO images
        (filename, format, width, height, captured_at, camera_make, camera_model,
         gps_latitude, gps_longitude, location, category, tags)
        VALUES (?, ?, ?, ?, ?, ?, ?, ?, ?, ?,
                 ST_SetSRID(ST_MakePoint(?, ?), 4326), ?, ?)
        RETURNING image_id
    """, tuple(image_data.values()) + (longitude, latitude))

    return image_id
```

Weitere Features in vollständiger Datei: - GPS-Koordinaten-Konvertierung (DMS → Dezimalgrad) -
Perceptual Hash-Berechnung für Duplikatserkennung - File-Size und Checksum-Validierung

Feature-Extraktion mit Deep Learning

```

import torch
import torchvision.models as models
import torchvision.transforms as transforms
from PIL import Image

# ResNet-50 für Feature-Extraktion
model = models.resnet50(pretrained=True)
model.eval()
# Entferne letzte Fully-Connected Layer
model = torch.nn.Sequential(*list(model.children())[:-1])

# Preprocessing
preprocess = transforms.Compose([
    transforms.Resize(256),
    transforms.CenterCrop(224),
    transforms.ToTensor(),
    transforms.Normalize(mean=[0.485, 0.456, 0.406],
                          std=[0.229, 0.224, 0.225]),
])

def extract_features(image_path):
    """Extrahiere Deep Learning Features"""
    img = Image.open(image_path).convert('RGB')
    img_tensor = preprocess(img).unsqueeze(0)

    with torch.no_grad():
        features = model(img_tensor)
        features = features.squeeze().numpy() # (2048,)

    return features

def store_features(image_id, image_path):
    """Extrahiere und speichere Features"""
    features = extract_features(image_path)

    themis.execute("""
        INSERT INTO image_features (image_id, deep_features, feature_extractor)
        VALUES (?, ?, 'resnet50')
    """)

```

```
ON CONFLICT (image_id) DO UPDATE
SET deep_features = EXCLUDED.deep_features,
    extraction_timestamp = NOW()
""", (image_id, features.tolist()))
```

Object Detection mit YOLO

```

from ultralytics import YOLO

# YOLOv8 Model laden
yolo_model = YOLO('yolov8n.pt')

def detect_objects(image_path, confidence_threshold=0.5):
    """Detecte Objekte mit YOLO"""
    results = yolo_model(image_path)

    detections = []
    for result in results:
        boxes = result.boxes
        for box in boxes:
            if box.conf[0] >= confidence_threshold:
                detections.append({
                    'object_class': result.names[int(box.cls[0])],
                    'confidence': float(box.conf[0]),
                    'bbox_x': int(box.xyxy[0][0]),
                    'bbox_y': int(box.xyxy[0][1]),
                    'bbox_width': int(box.xyxy[0][2] - box.xyxy[0][0]),
                    'bbox_height': int(box.xyxy[0][3] - box.xyxy[0][1])
                })

    return detections

def store_detections(image_id, image_path):
    """Detecte und speichere Objekte"""
    detections = detect_objects(image_path)

    for det in detections:
        themis.execute("""
            INSERT INTO detected_objects
            (image_id, object_class, confidence, bbox_x, bbox_y,
             bbox_width, bbox_height, detector_model)
            VALUES (?, ?, ?, ?, ?, ?, ?, 'yolov8n')
        """, (image_id, det['object_class'], det['confidence'],
              det['bbox_x'], det['bbox_y'],
              det['bbox_width'], det['bbox_height']))

```

12.4 Visual Similarity Search

Content-Based Image Retrieval (CBIR)

```
-- Finde visuell ähnliche Bilder
SELECT
    i.image_id,
    i.filename,
    i.captured_at,
    i.location,
    1 - (f.deep_features <=> :query_features) AS similarity
FROM images i
JOIN image_features f ON i.image_id = f.image_id
ORDER BY f.deep_features <=> :query_features
LIMIT 20;
```



```
def find_similar_images(query_image_path, limit=10):
    """Finde visuell ähnliche Bilder"""
    # Features der Query extrahieren
    query_features = extract_features(query_image_path)

    # Similarity Search
    similar = themis.query("""
        SELECT
            i.image_id,
            i.filename,
            i.file_path,
            i.captured_at,
            1 - (f.deep_features <=> ?) AS similarity
        FROM images i
        JOIN image_features f ON i.image_id = f.image_id
        ORDER BY f.deep_features <=> ?
        LIMIT ?
    """, (query_features.tolist(), query_features.tolist(), limit))

    return similar

# Beispiel
similar_images = find_similar_images('query_image.jpg', limit=10)
for img in similar_images:
    print(f"{img['filename']}: {img['similarity']:.3f}")
```

Multi-Modal Search: Visual + Text

```
-- Kombiniere Visual Similarity + Text Tags
WITH visual_matches AS (
    SELECT image_id,
           1 - (deep_features <=> :query_features) AS visual_score
    FROM image_features
    ORDER BY deep_features <=> :query_features
    LIMIT 100
),
text_matches AS (
    SELECT image_id,
           ts_rank(to_tsvector('english', array_to_string(tags, ' ')),
                  plainto_tsquery('english', :query_text)) AS text_score
    FROM images
    WHERE tags && :query_tags -- Array overlap
)
SELECT
    i.*,
    COALESCE(vm.visual_score, 0) * 0.7 +
    COALESCE(tm.text_score, 0) * 0.3 AS combined_score
FROM images i
LEFT JOIN visual_matches vm ON i.image_id = vm.image_id
LEFT JOIN text_matches tm ON i.image_id = tm.image_id
WHERE vm.image_id IS NOT NULL OR tm.image_id IS NOT NULL
ORDER BY combined_score DESC
LIMIT 20;
```

12.5 Spatial & Temporal Queries

GPS-basierte Suche

```
-- Alle Bilder in einem Radius von 1km
SELECT
    image_id,
    filename,
    captured_at,
    gps_latitude,
    gps_longitude,
    ST_Distance(location, ST_SetSRID(ST_MakePoint(?, ?), 4326)) as distance_m
FROM images
WHERE ST_DWithin(
    location,
    ST_SetSRID(ST_MakePoint(?, ?), 4326),
    1000 -- 1000 Meter
)
ORDER BY distance_m;

-- Bilder in einem Polygon (z.B. Baugelände)
SELECT *
FROM images
WHERE ST_Within(
    location,
    ST_GeomFromText('POLYGON((
        13.404 52.520,
        13.408 52.520,
        13.408 52.518,
        13.404 52.518,
        13.404 52.520
    ))', 4326)
);
```

Zeitliche Entwicklung

```

def get_temporal_sequence(location, radius_m=100,
                           start_date=None, end_date=None):
    """Hole zeitliche Bildsequenz an einem Ort"""
    query = """
        SELECT
            image_id,
            filename,
            captured_at,
            category,
            tags,
            ST_Distance(location, ST_SetSRID(ST_MakePoint(?, ?), 4326)) as distance_m
        FROM images
        WHERE ST_DWithin(
            location,
            ST_SetSRID(ST_MakePoint(?, ?), 4326),
            ?
        )
    """

    params = [longitude, latitude, longitude, latitude, radius_m]

    if start_date:
        query += " AND captured_at >= ?"
        params.append(start_date)

    if end_date:
        query += " AND captured_at <= ?"
        params.append(end_date)

    query += " ORDER BY captured_at"

    return themis.query(query, tuple(params))

# Beispiel: Baustellen-Entwicklung
sequence = get_temporal_sequence(
    location=(13.405, 52.520),
    radius_m=50,
    start_date='2024-01-01',

```

```
end_date='2024-12-31'  
)
```

12.6 Example: Drone Image Analysis

Überblick

Das **Drone Image Analysis** Beispiel ([examples/09_drone_image_analysis](#)) demonstriert eine vollständige Pipeline für Drohnenbilder-Analyse:

Features: - Automatische Bild-Kategorisierung - GPS-basierte Geo-Queries - Feature Matching für ähnliche Bilder - Object Detection (YOLOv8) Integration - Flight Path Visualisierung - Thermal Imaging Analytics

Batch-Upload von Drohnenbildern

```
import os
import glob
from concurrent.futures import ThreadPoolExecutor

def batch_upload_drone_images(directory, flight_id, category='construction'):
    """Batch-Upload aller Bilder aus einem Drohnenflug"""
    image_files = glob.glob(os.path.join(directory, '*.jpg'))
    print(f"Found {len(image_files)} images to process")

    def process_image(image_path):
        # Upload Bild
        image_id = upload_image(image_path, category=category,
                                tags=['drone', flight_id])

        # Feature-Extraktion
        store_features(image_id, image_path)

        # Object Detection
        store_detections(image_id, image_path)

        return image_id

    # Parallel-Processing
    with ThreadPoolExecutor(max_workers=4) as executor:
        image_ids = list(executor.map(process_image, image_files))

    print(f"Processed {len(image_ids)} images")
    return image_ids

# Beispiel-Verwendung
flight_id = 'flight_2024_01_15_001'
image_ids = batch_upload_drone_images(
    directory='/data/drone_images/2024-01-15/',
    flight_id=flight_id,
    category='construction_site'
)
```


Flugpfad-Rekonstruktion

```
def reconstruct_flight_path(flight_id):
    """Rekonstruiere Flugpfad aus GPS-Daten"""
    path = themis.query("""
        SELECT
            image_id,
            filename,
            captured_at,
            gps_latitude,
            gps_longitude,
            gps_altitude_m,
            ST_AsText(location) as location_wkt
        FROM images
        WHERE ? = ANY(tags)
        ORDER BY captured_at
    """, (flight_id,))

    return path

# Visualisierung mit Folium
import folium

def visualize_flight_path(flight_id):
    """Visualisiere Flugpfad auf Karte"""
    path = reconstruct_flight_path(flight_id)

    # Zentrum der Karte
    center_lat = sum(p['gps_latitude'] for p in path) / len(path)
    center_lon = sum(p['gps_longitude'] for p in path) / len(path)

    # Karte erstellen
    m = folium.Map(location=[center_lat, center_lon], zoom_start=15)

    # Flugpfad zeichnen
    coordinates = [(p['gps_latitude'], p['gps_longitude']) for p in path]
    folium.PolyLine(coordinates, color='red', weight=2,
                    opacity=0.8).add_to(m)

    # Marker für Bilder
```

```
for p in path:
    folium.Marker(
        location=[p['gps_latitude'], p['gps_longitude']],
        popup=f"{p['filename']}<br>Alt: {p['gps_altitude_m']}m",
        icon=folium.Icon(color='blue', icon='camera')
    ).add_to(m)

m.save(f'flight_path_{flight_id}.html')
return m

visualize_flight_path(flight_id)
```

Automatische Anomalie-Detection

```
def detect_safety_violations(flight_id):
    """Detecte Sicherheitsverstöße (z.B. fehlende Helme)"""
    # Finde alle Bilder mit Personen
    images_with_people = themis.query("""
        SELECT DISTINCT i.image_id, i.filename, i.file_path
        FROM images i
        JOIN detected_objects d ON i.image_id = d.image_id
        WHERE d.object_class = 'person'
            AND d.confidence > 0.7
            AND ? = ANY(i.tags)
    """, (flight_id,))

    violations = []

    for img in images_with_people:
        # Prüfe, ob Helme detectiert wurden
        helmets = themis.query("""
            SELECT COUNT(*) as helmet_count
            FROM detected_objects
            WHERE image_id = ?
                AND object_class IN ('hardhat', 'helmet')
        """, (img['image_id'],))

        people_count = themis.query("""
            SELECT COUNT(*) as person_count
            FROM detected_objects
            WHERE image_id = ?
                AND object_class = 'person'
        """, (img['image_id'],))

        if helmets[0]['helmet_count'] < people_count[0]['person_count']:
            violations.append({
                'image_id': img['image_id'],
                'filename': img['filename'],
                'issue': 'Missing hardhat',
                'people_count': people_count[0]['person_count'],
                'helmet_count': helmets[0]['helmet_count']
            })
```

```
        return violations

# Report generieren
violations = detect_safety_violations(flight_id)
if violations:
    print(f"⚠ Found {len(violations)} safety violations:")
    for v in violations:
        print(f"  - {v['filename']}: {v['issue']}")
```

Change Detection zwischen Flügen

```

def compare_flights(flight_id_1, flight_id_2, similarity_threshold=0.85):
    """Vergleiche zwei Flüge und finde Änderungen"""
    # Hole Bilder von beiden Flügen
    images_1 = reconstruct_flight_path(flight_id_1)
    images_2 = reconstruct_flight_path(flight_id_2)

    changes = []

    for img1 in images_1:
        # Finde räumlich nächstes Bild aus Flug 2
        nearest_img2 = themis.query_one("""
            SELECT
                i2.image_id,
                i2.filename,
                i2.captured_at,
                ST_Distance(i1.location, i2.location) as distance_m,
                1 - (f2.deep_features <=> f1.deep_features) as visual_similarity
            FROM images i1
            JOIN image_features f1 ON i1.image_id = f1.image_id
            CROSS JOIN images i2
            JOIN image_features f2 ON i2.image_id = f2.image_id
            WHERE i1.image_id = ?
                AND ? = ANY(i2.tags)
            ORDER BY ST_Distance(i1.location, i2.location)
            LIMIT 1
            """, (img1['image_id'], flight_id_2))

        if nearest_img2 and nearest_img2['distance_m'] < 10: # Innerhalb 10m
            if nearest_img2['visual_similarity'] < similarity_threshold:
                changes.append({
                    'location': (img1['gps_latitude'], img1['gps_longitude']),
                    'image_1': img1['filename'],
                    'image_2': nearest_img2['filename'],
                    'similarity': nearest_img2['visual_similarity'],
                    'change_detected': True
                })

    return changes

```



```
# Vergleiche zwei Flüge
changes = compare_flights('flight_001', 'flight_002')
print(f"Detected {len(changes)} significant changes between flights")
```

12.7 Performance & Skalierung

Thumbnail-Generierung für schnelle Preview

```
from PIL import Image

def generate_thumbnail(image_path, size=(256, 256)):
    """Generiere Thumbnail für Preview"""
    img = Image.open(image_path)
    img.thumbnail(size, Image.LANCZOS)

    # Speichere Thumbnail
    thumb_path = image_path.replace('.jpg', '_thumb.jpg')
    img.save(thumb_path, 'JPEG', quality=85)

    # Update DB
    themis.execute("""
        UPDATE images
        SET metadata = jsonb_set(metadata, '{thumbnail_path}', ?)
        WHERE file_path = ?
    """, (f'"{thumb_path}"', image_path))

    return thumb_path
```

Lazy Loading von Features

```
-- Erstelle Features nur on-demand
CREATE OR REPLACE FUNCTION ensure_features(p_image_id UUID)
RETURNS BOOLEAN AS $$
BEGIN
    LET feature_exists = (
        FOR feature IN image_features
        FILTER feature.image_id == p_image_id
        LIMIT 1
        RETURN 1
    )

    IF LENGTH(feature_exists) == 0 THEN
        -- Trigger Feature-Extraktion
        INSERT {image_id: p_image_id} INTO feature_extraction_queue;
        RETURN FALSE;
    END IF;
    RETURN TRUE;
END;
$$ LANGUAGE plpgsql;
```

Caching für häufige Queries

```
from functools import lru_cache
import hashlib

@lru_cache(maxsize=100)
def get_similar_images_cached(image_path_hash, limit=10):
    """Gecachte Similarity Search"""
    # ... similarity search logic
    pass

# Verwendung
image_hash = hashlib.md5(open(image_path, 'rb').read()).hexdigest()
similar = get_similar_images_cached(image_hash, limit=10)
```

12.8 Best Practices

1. Storage-Optimierung

DO: - Speichere nur Metadata in DB, Bilder im Object Storage (S3, MinIO) - Generiere Thumbnails für Previews - Nutze komprimierte Formate (JPEG für Photos, WebP für Web)

× **DON'T:** - Speichere nicht alle Bilder als BYTEA in DB - Vermeide unkomprimierte Formate (BMP, TIFF) für Archivierung - Keine Features ohne Index

2. Feature-Extraktion

DO: - Nutze Pre-Trained Models (ResNet, EfficientNet) - Batch-Processing für viele Bilder - GPU-Acceleration für Deep Learning

× **DON'T:** - Extrahiere Features nicht synchron beim Upload - Vermeide Training von Modellen auf CPU - Keine Feature-Extraktion ohne Quality-Check

3. Similarity Search

DO: - HNSW Index für große Datasets - Kombiniere Visual + Text Search - Pre-Filter mit Metadata (Zeit, Ort)

× **DON'T:** - Keine Brute-Force Search über Millionen Bilder - Vermeide hohe Dimensions ohne Dimensionality Reduction - Keine Similarity ohne Normalisierung

12.9 Zusammenfassung

ThemisDB ermöglicht effiziente Computer Vision Anwendungen durch:

Multi-Modal Data Management: - Images + GPS + Features + Objects in einer DB - Spatial + Temporal + Visual Queries - Graph-basierte Analyse von Bild-Beziehungen

Flexible Feature-Speicherung: - Native VECTOR-Spalten für Embeddings - HNSW Index für schnelle Similarity Search - JSON für flexible Metadata

Production-Ready: - Skalierbare Storage (Partitionierung) - Batch-Processing Support - Integration mit ML-Frameworks

Key Takeaways: 1. Speichere Metadata in DB, Bilder in Object Storage 2. Generiere Features asynchron (Queue/Workers) 3. Nutze HNSW für Similarity Search 4. Kombiniere Visual + Spatial + Temporal Queries 5. Thumbnails für Performance

Teil IV - Erweiterte Features

Kapitel 13: Kapitel 13 - Volltext-Suche

Einführung

Die Volltext-Suche ist eine der fundamentalen Anforderungen moderner Anwendungen. Ob E-Commerce-Produktsuche, Dokumentenverwaltung oder Content-Management - Nutzer erwarten relevante, schnelle Suchergebnisse. ThemisDB bietet native Volltext-Funktionalität, die nahtlos mit anderen Datenmodellen integriert ist.

In diesem Kapitel behandeln wir:

- **Grundlagen der Volltext-Suche:** Tokenisierung, Stemming, Stop-Words
- **ThemisDB Fulltext-Indexe:** Konfiguration und Optimierung
- **Erweiterte Suchfunktionen:** Wildcards, Phrasensuche, Fuzzy Search
- **NLP-Integration:** Sentiment-Analyse, Entity-Erkennung, Sprachverarbeitung
- **Best Practices:** Performance, Relevanz-Ranking, mehrsprachige Suche

Warum ist Volltext-Suche wichtig?

Problem der einfachen String-Suche:

```
-- Ineffizient: Keine Relevanz, langsam bei großen Datensätzen
FOR article IN articles
  FILTER LIKE(article.title, '%database%') OR LIKE(article.content, '%database%')
RETURN article
```

Probleme: - Keine Wort-Trennung (findet "database" nicht in "databases") - Keine Relevanz-Bewertung - Performance-Probleme (Full Table Scan) - Keine sprachliche Verarbeitung

Lösung mit Volltext-Index:

```
-- Schnell, relevant, sprachlich intelligent
FOR article IN articles
  FILTER FULLTEXT(article.title, 'database') OR FULLTEXT(article.content, 'database')
  LET score = FULLTEXT_SCORE(article)
  SORT score DESC
  RETURN {article, score}
```

Vorteile: - Automatische Wort-Erkennung und Stammformbildung - Relevanz-Ranking (TF-IDF, BM25) - Sehr performant durch invertierte Indizes - Sprachliche Features (Stop-Words, Synonyme)

Grundlagen der Volltext-Suche

Text-Verarbeitung Pipeline

Die Volltext-Suche durchläuft mehrere Verarbeitungsschritte:

1. Tokenisierung

Zerlegt Text in einzelne Wörter (Tokens):

```
"ThemisDB ist eine Multi-Model Datenbank"
↓
["ThemisDB", "ist", "eine", "Multi-Model", "Datenbank"]
```

2. Normalisierung

Konvertiert Tokens in Grundform:

```
["ThemisDB", "ist", "eine", "Multi-Model", "Datenbank"]
↓
["themisdb", "ist", "eine", "multi-model", "datenbank"] # Lowercase
```

3. Stop-Word-Filterung

Entfernt häufige, nicht-informative Wörter:

```
["themisdb", "ist", "eine", "multi-model", "datenbank"]
↓
["themisdb", "multi-model", "datenbank"] # "ist", "eine" entfernt
```

4. Stemming

Reduziert Wörter auf Wortstamm:

```
["Datenbanken", "Datenbank", "Datenbankserver"]
↓
["datenbank", "datenbank", "datenbankserv"] # Gemeinsamer Stamm
```

Abb. 13.1: Fulltext-Search-Indexierung

5. Index-Erstellung

Erstellt inverted index für schnelle Suche:

```
Token      → Dokument-IDs
"themisdb" → [1, 5, 12, 89]
"datenbank" → [1, 2, 5, 12, 34, 89]
"multi-model" → [1, 12]
```

Relevanz-Ranking Algorithmen

TF-IDF (Term Frequency - Inverse Document Frequency)

Bewertet Relevanz basierend auf: - **TF**: Wie oft erscheint der Begriff im Dokument? - **IDF**: Wie selten ist der Begriff im gesamten Korpus?

```
TF-IDF = TF × IDF
TF = (Anzahl Begriff in Dokument) / (Gesamtzahl Wörter in Dokument)
IDF = log(Gesamtanzahl Dokumente / Anzahl Dokumente mit Begriff)
```

Beispiel:

Dokument: "ThemisDB ist eine Datenbank. ThemisDB unterstützt Multi-Model." Suchbegriff: "ThemisDB"

```

TF = 2 / 8 = 0.25  (2× "ThemisDB", 8 Wörter gesamt)
IDF = log(10000 / 100) = 2  (100 von 10000 Dokumenten enthalten "ThemisDB")
TF-IDF = 0.25 × 2 = 0.5

```

BM25 (Best Matching 25)

Verbessertes Ranking-Modell mit Sättigungsfunktion:

```

BM25 = IDF × (TF × (k1 + 1)) / (TF + k1 × (1 - b + b × (docLen / avgDocLen)))

```

Parameter: - **k1**: Sättigung für Term-Frequenz (typisch 1.2-2.0) - **b**: Dokumentlängen-Normalisierung (typisch 0.75)

Vorteil: Verhindert, dass sehr lange Dokumente überproportional hohe Scores bekommen.

Volltext-Indexe in ThemisDB

Index erstellen

Einfacher Fulltext-Index:

```

CREATE FULLTEXT INDEX idx_articles_content
ON articles (title, content);

```

Mit Konfiguration:

```

CREATE FULLTEXT INDEX idx_articles_content
ON articles (title, content)
WITH (
  analyzer = 'german',          -- Sprach-Analyzer
  stopwords = ['der', 'die', 'das'], -- Custom Stop-Words
  min_word_length = 3,          -- Minimale Wortlänge
  max_word_length = 50,         -- Maximale Wortlänge
  case_sensitive = false,       -- Groß-/Kleinschreibung
  stemming = true               -- Stammform-Reduktion
);

```


Gewichtete Felder:

```
CREATE FULLTEXT INDEX idx_articles_weighted
ON articles (
  title WEIGHT 3.0,      -- Titel 3× wichtiger
  abstract WEIGHT 2.0,   -- Abstract 2× wichtiger
  content WEIGHT 1.0     -- Content normale Gewichtung
);
```

Suchen mit Volltext-Index**Einfache Suche:**

```
FOR article IN articles
  FILTER FULLTEXT(article, 'database systems')
  RETURN article
```

Mit Relevanz-Score:

```
FOR article IN articles
  FILTER FULLTEXT(article, 'database systems')
  LET relevance = FULLTEXT_SCORE(article)
  SORT relevance DESC
  LIMIT 10
  RETURN {
    id: article.id,
    title: article.title,
    relevance
  }
```

Mehrere Begriffe (AND):

```
-- Alle Begriffe müssen vorkommen
WHERE FULLTEXT_MATCH(articles, 'database AND multi-model');
```

Alternative Begriffe (OR):

```
-- Mindestens ein Begriff muss vorkommen
WHERE FULLTEXT_MATCH(articles, 'database OR nosql');
```

Ausschluss (NOT):

```
-- Enthält "database" aber nicht "relational"
WHERE FULLTEXT_MATCH(articles, 'database NOT relational');
```

Phrasensuche:

```
-- Exakte Phrase in Anführungszeichen
WHERE FULLTEXT_MATCH(articles, '"multi-model database"');
```

Wildcard-Suche:

```
-- * für beliebige Zeichen
WHERE FULLTEXT_MATCH(articles, 'data*'); -- Findet "database", "dataset", etc.
```

Fuzzy-Suche (Rechtschreibfehler):

```
-- ~ für Fuzzy-Match (Levenshtein-Distanz)
WHERE FULLTEXT_MATCH(articles, 'databse~'); -- Findet "database" trotz Fehler
```

Feld-spezifische Suche**Nur in bestimmten Feldern suchen:**

```
FOR article IN articles
  FILTER FULLTEXT(article.title, 'database') AND FULLTEXT(article.content, 'nosql')
RETURN article
```

Kombinierte Suche:

```
FOR article IN articles
  FILTER (FULLTEXT(article.title, 'multi-model') OR FULLTEXT(article.content, 'vector'))
  AND article.category == 'technology' -- Zusätzliche Filter kombinierbar
RETURN article
```

Erweiterte Suchfunktionen

Highlighting

Markiert Suchbegriffe in Ergebnissen:

```
FOR article IN articles
  FILTER FULLTEXT(article, 'database')
  LIMIT 10
RETURN {
  id: article.id,
  title: article.title,
  snippet: FULLTEXT_HIGHLIGHT(article.content, 'database', '<mark>', '</mark>')
}
```

Ergebnis:

```
"... ThemisDB ist eine <mark>database</mark> für Multi-Model Daten ..."
```

Snippet-Extraktion:

```
FOR article IN articles
  FILTER FULLTEXT(article, 'database')
RETURN {
  id: article.id,
  title: article.title,
  snippet: FULLTEXT_SNIPPET(article.content, 'database', 50, 200)
}
```

Extrahiert 200 Zeichen um den Suchbegriff herum (50 Zeichen vor, 150 nach).

Auto-Complete / Suggest

Präfix-Suche für Auto-Complete:

```
-- Findet alle Artikel, die mit "dat" beginnen
FOR article IN articles
  LET suggestion = FULLTEXT_TERMS(article, 'dat*')
  FILTER suggestion != null
  LIMIT 10
  RETURN DISTINCT suggestion
```

Ergebnis:

```
["database", "data", "dataset", "dataflow"]
```

Häufigkeits-basierte Vorschläge:

```
FOR article IN articles
  LET term = FULLTEXT_TERMS(article, 'dat*')
  FILTER term != null
  COLLECT termValue = term
  AGGREGATE frequency = COUNT()
  SORT frequency DESC
  LIMIT 10
  RETURN {term: termValue, frequency}
```

Faceted Search

Kombiniert Volltext mit Facetten:

```
FOR article IN articles
  FILTER FULLTEXT(article, 'database')
  COLLECT category = article.category
  AGGREGATE count = COUNT()
  RETURN {category, count}
```

Ergebnis:

category	count
Technology	45
Science	23
Business	12

Komplexe Facetten-Abfrage:

```

LET results = (
  FOR article IN articles
    FILTER FULLTEXT(article, 'database')
    RETURN article
)

FOR r IN results
  FILTER FULLTEXT(r, 'database')
  RETURN r
)

FOR result IN results
  COLLECT category = result.category
  AGGREGATE
    count = COUNT(),
    avg_relevance = AVG(FULLTEXT_SCORE(result))
  SORT count DESC
  RETURN {category, count, avg_relevance}

```

NLP-Integration

Sentiment-Analyse

Analysiert Stimmung/Emotion in Texten.

Python Integration mit TextBlob:

```

from themisdb import ThemisDB
from textblob import TextBlob

db = ThemisDB()

# Reviews aus Datenbank laden
reviews = db.query("""
    FOR review IN product_reviews
    RETURN {id: review.id, text: review.text}
""")

for review in reviews:
    # Sentiment-Analyse
    blob = TextBlob(review['text'])
    sentiment = blob.sentiment.polarity # -1 (negativ) bis +1 (positiv)

    # Sentiment in DB speichern
    db.query("""
        FOR review IN product_reviews
        FILTER review.id == @review_id
        UPDATE review WITH {sentiment_score: @sentiment} IN product_reviews
        """, {"sentiment": sentiment, "review_id": review['id']})

# Aggregierte Sentiment-Analyse
avg_sentiment = db.query("""
    FOR review IN product_reviews
    COLLECT product_id = review.product_id
    AGGREGATE
        avg_sentiment = AVG(review.sentiment_score),
        review_count = COUNT()
    FILTER review_count >= 10
    SORT avg_sentiment DESC
    RETURN {product_id, avg_sentiment, review_count}
""")

```

Sentiment-Kategorien:

```
def categorize_sentiment(score):
    if score >= 0.5:
        return "sehr positiv"
    elif score >= 0.1:
        return "positiv"
    elif score >= -0.1:
        return "neutral"
    elif score >= -0.5:
        return "negativ"
    else:
        return "sehr negativ"

# Sentiment-Kategorien in DB
db.query("""
    ALTER TABLE product_reviews
    ADD COLUMN sentiment_category VARCHAR(20)
""")

for review in reviews:
    category = categorize_sentiment(review['sentiment_score'])
    db.query("""
        UPDATE product_reviews
        SET sentiment_category = ?
        WHERE id = ?
        """, [category, review['id']])
```

Named Entity Recognition (NER)

Erkennt Entitäten wie Personen, Orte, Organisationen.

Mit spaCy:

```
import spacy
from themisdb import ThemisDB

# Deutsches Sprachmodell laden
nlp = spacy.load("de_core_news_md")
db = ThemisDB()

# Artikel analysieren
articles = db.query("SELECT id, content FROM articles")

for article in articles:
    doc = nlp(article['content'])

    # Entitäten extrahieren
    entities = []
    for ent in doc.ents:
        entities.append({
            'text': ent.text,
            'label': ent.label_, # PER, LOC, ORG, etc.
            'start': ent.start_char,
            'end': ent.end_char
        })

    # Entitäten als JSON speichern
    db.query("""
        UPDATE articles
        SET entities = ?
        WHERE id = ?
    """, [json.dumps(entities), article['id']])

# Suche nach Artikeln über bestimmte Person
db.query("""
    SELECT * FROM articles
    WHERE JSON_CONTAINS(entities, '$.text', 'Angela Merkel')
    """)
```

Entity-Linking:


```
# Verlinke Entitäten mit Stammdaten
def link_entities(article_id, entities):
    for ent in entities:
        if ent['label'] == 'PER': # Person
            # Suche Person in DB
            person = db.query("""
                SELECT id FROM persons
                WHERE name = ? OR aliases LIKE ?
            """, [ent['text'], f"%{ent['text']}%"])

            if person:
                # Verknüpfung erstellen
                db.query("""
                    INSERT INTO article_person_mentions
                    (article_id, person_id, mention_text)
                    VALUES (?, ?, ?)
                """, [article_id, person[0]['id'], ent['text']])
```

Text-Klassifikation

Die automatische Kategorisierung von Texten kombiniert ThemisDB's Fulltext-Suche mit Machine Learning. Das System lädt bereits kategorisierte Artikel als Trainingsdaten, extrahiert TF-IDF Features und trainiert einen Naive Bayes Klassifikator. Neue unkategorisierte Artikel werden dann automatisch mit Confidence-Score versehen.

Vollständiger Code: [examples/13_fulltext_search/text_classification.py](#) (~70 Zeilen)

Training und Klassifikation:

```

from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.naive_bayes import MultinomialNB
from sklearn.pipeline import Pipeline

# Training-Daten aus ThemisDB laden
training_data = db.query("""
    SELECT content, category FROM articles WHERE category IS NOT NULL
""")

X_train = [row['content'] for row in training_data]
y_train = [row['category'] for row in training_data]

# Pipeline: TF-IDF (5000 Features) + Naive Bayes
classifier = Pipeline([
    ('vectorizer', TfidfVectorizer(max_features=5000)),
    ('classifier', MultinomialNB())
])
classifier.fit(X_train, y_train)

# Neue Artikel klassifizieren mit Confidence-Score
new_articles = db.query("""SELECT id, content FROM articles WHERE category IS NULL""")

for article in new_articles:
    predicted_category = classifier.predict([article['content']])[0]
    confidence = max(classifier.predict_proba([article['content']])[0]) # Max probability

    db.query("""
        UPDATE articles SET category = ?, category_confidence = ? WHERE id = ?
        """, [predicted_category, confidence, article['id']])

```

Vorteile: - Integration mit ThemisDB Fulltext-Indizes - Confidence-Score für manuelle Review bei niedrigen Werten (<0.7) - TF-IDF mit 5000 Features für gute Balance zwischen Genauigkeit und Performance - Naive Bayes: Schnell, robust bei kleinen Trainingssets

Keyword-Extraktion

Extrahiert wichtige Schlüsselwörter aus Texten.

Mit YAKE (Yet Another Keyword Extractor):

```
import yake
from themisdb import ThemisDB

db = ThemisDB()

# YAKE Keyword Extractor
kw_extractor = yake.KeywordExtractor(
    lan="de",          # Sprache
    n=3,              # Maximale N-Gram Länge
    dedupLim=0.9,     # Deduplizierung
    top=10,           # Top 10 Keywords
    features=None
)

articles = db.query("SELECT id, title, content FROM articles")

for article in articles:
    text = article['title'] + " " + article['content']
    keywords = kw_extractor.extract_keywords(text)

    # Keywords als Liste speichern
    keyword_list = [kw[0] for kw in keywords]

    db.query("""
        UPDATE articles
        SET keywords = ?
        WHERE id = ?
        """, [json.dumps(keyword_list), article['id']])

# Suche über Keywords
db.query("""
    SELECT * FROM articles
    WHERE JSON_CONTAINS(keywords, ?, '$')
    """, ["Multi-Model"])
```

Mehrsprachige Suche

Language Detection

Automatische Spracherkennung:

```
from langdetect import detect
from themisdb import ThemisDB

db = ThemisDB()

articles = db.query("SELECT id, content FROM articles")

for article in articles:
    try:
        language = detect(article['content'])
        db.query("""
            UPDATE articles
            SET language = ?
            WHERE id = ?
            """, [language, article['id']])
    except:
        # Fallback bei Fehler
        db.query("""
            UPDATE articles
            SET language = 'unknown'
            WHERE id = ?
            """, [article['id']])
```

Sprachspezifische Indexe

Separate Indexe pro Sprache:

```
-- Deutscher Index
CREATE FULLTEXT INDEX idx_articles_de
ON articles (content)
WHERE language = 'de'
WITH (analyzer = 'german');

-- Englischer Index
CREATE FULLTEXT INDEX idx_articles_en
ON articles (content)
WHERE language = 'en'
WITH (analyzer = 'english');

-- Französischer Index
CREATE FULLTEXT INDEX idx_articles_fr
ON articles (content)
WHERE language = 'fr'
WITH (analyzer = 'french');
```

Sprachabhängige Suche:

```
-- Automatische Sprachwahl basierend auf Nutzer-Präferenz
SELECT * FROM articles
WHERE language = 'de'
      AND FULLTEXT_MATCH(articles, 'Datenbank')
ORDER BY FULLTEXT_SCORE(articles) DESC;
```

Translation-Aware Search

Suche über Übersetzungen hinweg:

```
from googletrans import Translator
from themisdb import ThemisDB

translator = Translator()
db = ThemisDB()

def multilingual_search(query, target_languages=['en', 'de', 'fr']):
    results = []

    for lang in target_languages:
        # Query in Zielsprache übersetzen
        if lang != 'de': # Annahme: Query ist deutsch
            translated_query = translator.translate(query, dest=lang).text
        else:
            translated_query = query

        # Suche in entsprechender Sprache
        lang_results = db.query("""
            SELECT *, ? as search_language
            FROM articles
            WHERE language = ?
            AND FULLTEXT_MATCH(articles, ?)
            ORDER BY FULLTEXT_SCORE(articles) DESC
            LIMIT 10
            """, [lang, lang, translated_query])

        results.extend(lang_results)

    return results

# Beispiel: Suche nach "Datenbank" in allen Sprachen
results = multilingual_search("Datenbank")
```

Performance-Optimierung

Index-Tuning

Analyse der Index-Nutzung:

```
-- Index-Statistiken anzeigen  
SHOW INDEX STATS idx_articles_content;
```

Ergebnis:

```
total_documents: 125000  
total_terms: 2500000  
avg_terms_per_doc: 20  
index_size_mb: 45.2  
last_update: 2024-12-28 10:30:00
```

Selective Indexing:

```
-- Nur wichtige Felder indizieren  
CREATE FULLTEXT INDEX idx_articles_selective  
ON articles (title, abstract) -- Nicht "content" für Performance  
WHERE status = 'published'; -- Nur veröffentlichte Artikel
```

Partial Index für häufige Queries:

```
-- Index nur für aktuelle Artikel  
CREATE FULLTEXT INDEX idx_articles_recent  
ON articles (title, content)  
WHERE created_at > NOW() - INTERVAL '30 days';
```

Query-Optimierung

Avoid Wildcards am Anfang:

```
-- LANGSAM: Wildcard am Anfang
WHERE FULLTEXT_MATCH(articles, '*base');

-- SCHNELL: Wildcard am Ende
WHERE FULLTEXT_MATCH(articles, 'data*');
```

Limit Fuzzy Search:

```
-- LANGSAM: Fuzzy auf allen Begriffen
WHERE FULLTEXT_MATCH(articles, 'databse~ systm~');

-- SCHNELL: Fuzzy nur wo nötig
WHERE FULLTEXT_MATCH(articles, 'database systm~');
```

Use Score Threshold:

```
-- Filtere irrelevante Ergebnisse
SELECT * FROM articles
WHERE FULLTEXT_MATCH(articles, 'database')
  AND FULLTEXT_SCORE(articles) > 0.5 -- Nur relevante Treffer
ORDER BY FULLTEXT_SCORE(articles) DESC
LIMIT 20;
```

Caching-Strategien

Query-Result-Cache:


```
from functools import lru_cache
from themisdb import ThemisDB

db = ThemisDB()

@lru_cache(maxsize=1000)
def cached_search(query, limit=20):
    return db.query("""
        SELECT * FROM articles
        WHERE FULLTEXT_MATCH(articles, ?)
        ORDER BY FULLTEXT_SCORE(articles) DESC
        LIMIT ?
    """, [query, limit])

# Wiederholte Suchen verwenden Cache
results1 = cached_search("database") # DB-Query
results2 = cached_search("database") # Aus Cache
```

Index-Warm-Up:

```
-- Index vorwärmen nach Restart
SELECT COUNT(*) FROM articles
WHERE FULLTEXT_MATCH(articles, 'a'); -- Häufiger Buchstabe
```

Best Practices

1. Index-Design

DO: - Indiziere nur durchsuchbare Felder - Verwende gewichtete Felder (Titel wichtiger als Content) -
Nutze sprachspezifische Analyzer - Implementiere Partial Indexes für große Tabellen

× **DON'T:** - Alle Felder blindlings indizieren - Binärdaten oder IDs indizieren - Stop-Words komplett
entfernen (bei Phrasensuche wichtig) - Zu aggressive Stemming-Regeln

2. Query-Patterns

DO: - Kombiniere Volltext mit strukturierten Filtern - Verwende Relevanz-Ranking - Implementiere Pagination für große Result-Sets - Cache häufige Queries

× **DON'T:** - Wildcard-Suchen am Anfang (*word) - Zu komplexe Boolean-Queries - Uneingeschränkte Fuzzy-Searches - Volltext-Suche für exakte Matches (verwende =)

3. User Experience

DO: - Auto-Complete für bessere UX - Highlight Suchbegriffe in Ergebnissen - Zeige Relevanz-Score an - Implementiere "Did you mean?" für Tippfehler

× **DON'T:** - Keine Ergebnisse ohne Alternative - Zu viele Ergebnisse ohne Ranking - Langsame Suche ohne Loading-Indicator - Keine Filteroptionen

4. Wartung

DO: - Regelmäßige Index-Optimierung - Monitoring der Query-Performance - Analyse beliebter Suchbegriffe - A/B-Testing verschiedener Ranking-Algorithmen

× **DON'T:** - Index-Fragmentierung ignorieren - Keine Metriken erfassen - Statische Ranking-Gewichte - Keine User-Feedback-Integration

Zusammenfassung

Volltext-Suche ist essentiell für moderne Anwendungen:

Kernkonzepte: - Invertierte Indexe für schnelle Suche - TF-IDF / BM25 für Relevanz-Ranking - Sprachverarbeitung (Stemming, Stop-Words) - Boolean-Operatoren (AND, OR, NOT) - Erweiterte Features (Fuzzy, Wildcards, Phrases)

NLP-Integration: - Sentiment-Analyse für Meinungen - Named Entity Recognition für Entitäten - Text-Klassifikation für Auto-Tagging - Keyword-Extraktion für Zusammenfassungen

Performance: - Selective Indexing - Query-Optimierung - Caching-Strategien - Index-Wartung

ThemisDB bietet native Volltext-Funktionalität, die nahtlos mit anderen Datenmodellen kombiniert werden kann - für leistungsstarke, flexible Suchlösungen.

Im nächsten Kapitel behandeln wir **Geo-Spatial Features** - für standortbasierte Anwendungen und räumliche Analysen.

Übungsaufgaben

Aufgabe 1: Erstellen Sie einen gewichteten Volltext-Index für eine Nachrichten-Tabelle (Titel 3×, Teaser 2×, Content 1×).

Aufgabe 2: Implementieren Sie eine Auto-Complete-Funktion mit Präfix-Suche und Häufigkeits-Ranking.

Aufgabe 3: Integrieren Sie Sentiment-Analyse für Produkt-Reviews und berechnen Sie durchschnittliche Sentiment-Scores.

Aufgabe 4: Erstellen Sie eine mehrsprachige Suche mit automatischer Language-Detection und sprachspezifischen Indizes.

Aufgabe 5: Optimieren Sie eine langsame Volltext-Query durch Analyse der Index-Statistiken und Query-Rewriting.

Kapitel 14: Kapitel 14 - Geo-Spatial Features

Einleitung

Standortbasierte Dienste sind aus modernen Anwendungen nicht mehr wegzudenken. Von Lieferdiensten über Immobiliensuche bis zu Flottenmanagement – geografische Daten spielen eine zentrale Rolle. ThemisDB bietet native Unterstützung für Geo-Spatial Daten mit effizienten räumlichen Indizes und umfangreichen Abfragefunktionen.

In diesem Kapitel lernen Sie: - Geo-Datentypen und Koordinatensysteme - Räumliche Indizes (R-Tree, Geo-Hash) - Location-Based Queries (Radius, Bounding Box, Polygon) - Integration von GPS-Tracking und Kartendiensten - Best Practices für Geo-Anwendungen

14.1 Grundlagen der Geo-Spatial Daten

Koordinatensysteme

ThemisDB verwendet das WGS84-Koordinatensystem (EPSG:4326), das auch GPS verwendet:

```
# Koordinaten als [longitude, latitude]
berlin_coordinates = [13.405, 52.520]
munich_coordinates = [11.575, 48.137]

# WICHTIG: Longitude (Längengrad) kommt zuerst!
# Longitude: -180 bis +180 (West/Ost)
# Latitude: -90 bis +90 (Süd/Nord)
```

Geo-Datentypen in ThemisDB

```
// Point: Einzelner Punkt
FOR loc IN [
  {
    _key: "loc1",
    name: "Berlin Mitte",
    coordinates: [13.4050, 52.5200], // [lon, lat]
    created_at: DATE_ISO8601(DATE_NOW())
  }
] INSERT loc INTO locations

-- Geo-Index erstellen
CREATE INDEX idx_geo_locations
  ON locations (coordinates)
  TYPE GEO

// LineString: Verbundene Punkte (Routen)
FOR route IN [
  {
    _key: "route1",
    name: "Tour A",
    path: [
      [13.377, 52.516], // Start
      [13.390, 52.520], // Waypoint 1
      [13.405, 52.520] // End
    ],
    distance_km: 2.8
  }
] INSERT route INTO routes

// Polygon: Geschlossene Fläche (Delivery Zones)
FOR zone IN [
  {
    _key: "zone1",
    name: "Zone Nord",
    area: [
      [13.35, 52.54],
      [13.42, 52.54],
      [13.42, 52.50],
```

```
[13.35, 52.50],  
  [13.35, 52.54] // Geschlossen  
],  
  active: true  
}  
] INSERT zone INTO delivery_zones
```

14.2 Geo-Spatial Indizes

R-Tree Index

R-Trees sind die effizienteste Indexstruktur für räumliche Daten:

```
-- Geo-Index erstellen  
CREATE INDEX idx_locations_geo ON locations USING RTREE(coordinates);  
  
-- Automatische Nutzung bei räumlichen Queries  
FOR location IN locations  
  FILTER ST_Distance(location.coordinates, POINT(13.405, 52.520)) < 5000  
  RETURN location  
-- Index wird automatisch genutzt!
```

R-Tree Eigenschaften: - Organisiert Punkte in hierarchischen Bounding Boxes - $O(\log n)$ Suchzeit für Bereichsabfragen - Automatische Rebalancierung bei Updates - Optimiert für Nearest-Neighbor Queries

Abb. 14.1: Geospatial-Index-Struktur

Geo-Hash Index

Für weltweite Abdeckung und Präfix-Suche:

```
CREATE INDEX idx_locations_geohash ON locations USING GEOHASH(coordinates);  
  
-- Nützlich für:  
-- - Clustering auf Karten  
-- - Hierarchische Zoomlevel  
-- - Verteilte Systeme (Sharding nach Geo-Hash)
```

14.3 Räumliche Abfragen

Distanz-Queries

```
from themisdb import Connection

conn = Connection("localhost:7687")

# Radius-Suche: Alle Restaurants im Umkreis von 2km
restaurants = conn.query("""
    SELECT id, name, coordinates,
           ST_Distance(coordinates, POINT(?, ?)) as distance_m
    FROM restaurants
    WHERE ST_Distance(coordinates, POINT(?, ?)) < 2000
    ORDER BY distance_m
""", [user_lon, user_lat, user_lon, user_lat])

for r in restaurants:
    print(f"{r['name']}: {r['distance_m']:.0f}m entfernt")
```

Bounding Box Queries

Rechteckiger Bereich (sehr effizient mit R-Tree):

```
# Berlin-Mitte Bounding Box
min_lon, max_lon = 13.35, 13.45
min_lat, max_lat = 52.50, 52.55

pois = conn.query("""
    FOR poi IN points_of_interest
    FILTER ST_Within(poi.coordinates,
                    BBOX(@min_lon, @min_lat, @max_lon, @max_lat))
    RETURN poi
""", {"min_lon": min_lon, "min_lat": min_lat, "max_lon": max_lon, "max_lat": max_lat})
```

Abb. 14.2: Proximity-Search-Algorithmus

Polygon Queries

Prüfen ob Punkt innerhalb eines Polygons liegt:

```
# Liefergebiet definieren
delivery_area = [
    [13.40, 52.52], # Punkt 1
    [13.42, 52.52], # Punkt 2
    [13.42, 52.50], # Punkt 3
    [13.40, 52.50], # Punkt 4
    [13.40, 52.52]  # Schließt Polygon
]

# Prüfen ob Adresse im Liefergebiet
customer_location = [13.41, 52.51]

result = conn.query("""
    SELECT ST_Contains(
        POLYGON(?),
        POINT(?, ?)
    ) as in_delivery_area
""", [delivery_area, customer_location[0], customer_location[1]])

if result[0]['in_delivery_area']:
    print("Wir liefern zu Ihnen!")
```

K-Nearest-Neighbor (KNN)

Die K nächsten Punkte finden:

```
# 5 nächste Cafés finden
cafes = conn.query("""
    SELECT id, name, coordinates,
           ST_Distance(coordinates, POINT(?, ?)) as distance_m
    FROM cafes
    ORDER BY distance_m
    LIMIT 5
""", [user_lon, user_lat])
```

14.4 Geo-Funktionen

Distanzberechnung

```
-- Haversine-Formel (Kugeloberfläche der Erde)
ST_Distance(point1, point2) -> meters

-- Beispiel: Berlin → München
SELECT ST_Distance(
    POINT(13.405, 52.520), -- Berlin
    POINT(11.575, 48.137)  -- München
) as distance_m;
-- Ergebnis: ~504.000m (504km)
```

Bearing (Richtung)

```
-- Peilung von A nach B in Grad (0° = Norden)
ST_Bearing(point1, point2) -> degrees

SELECT ST_Bearing(
    POINT(13.405, 52.520), -- Berlin
    POINT(11.575, 48.137)  -- München
) as bearing;
-- Ergebnis: ~195° (Süd-Südwest)
```

Bounding Box

```
-- Kleinste Box um Geometrie
ST_Envelope(geometry) -> bbox

-- Buffer: Bereich um Punkt/Linie
ST_Buffer(point, radius_m) -> polygon
```

14.5 Beispiel: Location-Based Services (LBS)

Ein vollständiges Lieferdienst-System mit Restaurant-Suche, Fahrerzuordnung und Live-Tracking demonstriert die praktische Anwendung von Geo-Spatial Features. Das System nutzt R-Tree Indizes für effiziente Distanzberechnungen und ermöglicht Echtzeit-Updates der Fahrerposition.

Vollständiger Code: `examples/14_geospatial/delivery_service/schema.sql` (~60 Zeilen)

Datenmodell

Das Datenmodell verwendet drei Kerntabellen mit jeweils Geo-Spalten und R-Tree Indizes:

```
# Restaurants mit Geo-Index
conn.execute("""
CREATE TABLE restaurants (
    id INTEGER PRIMARY KEY,
    name TEXT NOT NULL,
    coordinates POINT NOT NULL, -- R-Tree indexiert
    rating REAL,
    delivery_radius_m INTEGER DEFAULT 3000
)
""")

conn.execute("""
CREATE INDEX idx_restaurants_geo
ON restaurants USING RTREE(coordinates)
""")

# Orders mit Lieferadresse
conn.execute("""
CREATE TABLE orders (
    id INTEGER PRIMARY KEY,
    delivery_address POINT NOT NULL,
    driver_id INTEGER,
    status TEXT DEFAULT 'pending'
)
""")

# Drivers mit Live-Position
conn.execute("""
CREATE TABLE drivers (
    id INTEGER PRIMARY KEY,
    current_location POINT, -- R-Tree indexiert
    status TEXT DEFAULT 'available'
)
""")
```

Weitere Spalten im vollständigen Schema: - `restaurants`: cuisine, address, phone, opening_hours - `orders`: restaurant_id, customer_name, items (JSON), created_at - `drivers`: name, vehicle_type, last_update timestamp

Restaurant-Suche

Die Restaurant-Suche kombiniert Radius-Query mit zusätzlichen Filtern wie Küche und Rating:

Vollständiger Code: `examples/14_geospatial/delivery_service/restaurant_search.py`
(~25 Zeilen)

```
def find_nearby_restaurants(user_lat, user_lon, max_distance_m=5000, cuisine=None):
    """Findet Restaurants in der Nähe mit Geo-Index"""

    query = """
        SELECT id, name, cuisine, rating,
               ST_Distance(coordinates, POINT(?, ?)) as distance_m
        FROM restaurants
        WHERE ST_Distance(coordinates, POINT(?, ?)) < ?
    """

    params = [user_lon, user_lat, user_lon, user_lat, max_distance_m]

    if cuisine:
        query += " AND cuisine = ?"
        params.append(cuisine)

    query += " ORDER BY distance_m"
    return conn.query(query, params)

# R-Tree Index macht dies extrem effizient!
restaurants = find_nearby_restaurants(
    user_lat=52.520, user_lon=13.405,
    cuisine="Italian", max_distance_m=3000
)
```

Performance: R-Tree Index ermöglicht Suche in $O(\log n)$ statt $O(n)$

Fahrer-Zuordnung

Die Fahrerzuordnung findet den nächsten verfügbaren Fahrer mittels K-Nearest-Neighbor Query:

Vollständiger Code: `examples/14_geospatial/delivery_service/driver_assignment.py`
(~35 Zeilen)

```
def assign_nearest_driver(order_id):
    """Findet den nächsten verfügbaren Fahrer (KNN-Query)"""

    # Hole Lieferadresse
    order = conn.query("""
        SELECT delivery_address FROM orders WHERE id = ?
    """, [order_id])[0]

    # Finde nächsten verfügbaren Fahrer (R-Tree macht dies effizient!)
    driver = conn.query("""
        SELECT id, name, current_location,
               ST_Distance(current_location, POINT(?, ?)) as distance_m
        FROM drivers
        WHERE status = 'available'
        ORDER BY distance_m ASC
        LIMIT 1
    """, [order['delivery_address'][0], order['delivery_address'][1]])

    if not driver:
        raise ValueError("Kein Fahrer verfügbar")

    # Zuordnen und Status aktualisieren
    conn.execute("UPDATE orders SET driver_id = ?, status = 'assigned' WHERE id = ?",
                 [driver[0]['id'], order_id])
    conn.execute("UPDATE drivers SET status = 'busy' WHERE id = ?",
                 [driver[0]['id']])

    return driver[0]
```

Algorithmus: Sortierung nach Distanz mit R-Tree Index → $O(\log n)$ statt $O(n)$

Live-Tracking

Live-Tracking aktualisiert die Fahrerposition kontinuierlich und berechnet die geschätzte Ankunftszeit (ETA):

Vollständiger Code: [examples/14_geospatial/delivery_service/tracking.py](#) (~40 Zeilen)

```
def update_driver_location(driver_id, lat, lon):
    """Aktualisiert Fahrerposition (z.B. alle 5 Sekunden vom GPS)"""
    conn.execute("""
        UPDATE drivers
        SET current_location = POINT(?, ?),
            last_update = CURRENT_TIMESTAMP
        WHERE id = ?
    """, [lon, lat, driver_id])

def get_delivery_eta(order_id):
    """Berechnet geschätzte Ankunftszeit"""
    result = conn.query("""
        SELECT o.delivery_address,
            d.current_location,
            ST_Distance(d.current_location, o.delivery_address) as distance_m
        FROM orders o
        JOIN drivers d ON o.driver_id = d.id
        WHERE o.id = ?
    """, [order_id])

    if not result:
        return None

    distance_km = result[0]['distance_m'] / 1000
    eta_minutes = (distance_km / 30) * 60 # Annahme: 30 km/h Durchschnittsgeschwindigkeit

    return {
        'distance_km': round(distance_km, 1),
        'eta_minutes': round(eta_minutes)
    }
```

ETA-Berechnung: - Distanzberechnung mit Haversine-Formel (WGS84) -

Durchschnittsgeschwindigkeit: 30 km/h in der Stadt - Live-Update alle 5-10 Sekunden

14.6 Beispiel: Immobiliensuche

Geo-basierte Immobiliensuche kombiniert räumliche Queries mit flexiblen Filtern (Preis, Zimmerzahl, Ausstattung). Das System nutzt R-Tree Indizes für schnelle Radius-Suchen und JSON-Spalten für flexible Metadaten.

Vollständiger Code: [examples/14_geospatial/real_estate/search.py](#) (~80 Zeilen)

Datenmodell

```
conn.execute("""
CREATE TABLE properties (
    id INTEGER PRIMARY KEY,
    title TEXT NOT NULL,
    coordinates POINT NOT NULL, -- R-Tree indexiert
    price_eur INTEGER,
    size_sqm REAL,
    rooms INTEGER,
    type TEXT, -- 'apartment', 'house', 'commercial'
    features JSON -- ['balcony', 'parking', 'elevator', ...]
)
""")

conn.execute("""
CREATE INDEX idx_properties_geo
ON properties USING RTREE(coordinates)
""")
```

Radius-Suche mit Filtern

Die Suche kombiniert Geo-Radius mit Preis-, Zimmer- und Feature-Filtern:


```

def search_properties(center_lat, center_lon, radius_m=2000,
                     min_price=None, max_price=None,
                     min_rooms=None, property_type=None):
    """Immobiliensuche mit Geo + Filter"""

    query = """
        SELECT id, title, price_eur, rooms, type,
               ST_Distance(coordinates, POINT(?, ?)) as distance_m
        FROM properties
        WHERE ST_Distance(coordinates, POINT(?, ?)) < ?
    """

    params = [center_lon, center_lat, center_lon, center_lat, radius_m]

    # Dynamische Filter
    if min_price:
        query += " AND price_eur >= ?"
        params.append(min_price)
    if max_price:
        query += " AND price_eur <= ?"
        params.append(max_price)
    if min_rooms:
        query += " AND rooms >= ?"
        params.append(min_rooms)

    query += " ORDER BY distance_m"
    return conn.query(query, params)

# Verwendung: 3-Zimmer-Wohnung, 500k-800k€, Umkreis 3km
properties = search_properties(
    center_lat=52.520, center_lon=13.405, radius_m=3000,
    min_price=500_000, max_price=800_000, min_rooms=3
)

```

Performance: R-Tree + B-Tree Indizes ermöglichen Sub-Millisekunden-Suche

POI-basierte Suche

Immobilien in der Nähe von Points of Interest (z.B. "Alexanderplatz", "Hauptbahnhof"):

```
def search_near_poi(poi_name, radius_m=1000):
    """Immobilien in der Nähe eines POI"""

    # Finde POI-Koordinaten
    poi = conn.query("""
        SELECT coordinates FROM points_of_interest
        WHERE name = ? LIMIT 1
    """, [poi_name])

    if not poi:
        raise ValueError(f"POI '{poi_name}' nicht gefunden")

    poi_coords = poi[0]['coordinates']

    # Suche Immobilien im Radius
    return conn.query("""
        SELECT id, title, price_eur,
               ST_Distance(coordinates, POINT(?, ?)) as distance_m
        FROM properties
        WHERE ST_Distance(coordinates, POINT(?, ?)) < ?
        ORDER BY distance_m
    """, [poi_coords[0], poi_coords[1],
          poi_coords[0], poi_coords[1], radius_m])

# "Wohnungen nahe Alexanderplatz im Umkreis von 1.5km"
properties = search_near_poi("Alexanderplatz", radius_m=1500)
```

Use Case: "Apartment near Central Station", "House near Park", etc.

14.7 Best Practices

1. Index-Design

```
# GUT: R-Tree Index für räumliche Queries
CREATE INDEX idx_geo ON locations USING RTREE(coordinates);

# GUT: Composite Index für Geo + Filter
CREATE INDEX idx_geo_type ON locations(type, coordinates) USING RTREE;

# x SCHLECHT: Kein Geo-Index
CREATE INDEX idx_coords ON locations(coordinates); # B-Tree, ineffizient!
```

2. Query-Optimierung

```
# GUT: Nutze Index mit Distanz-Filter
WHERE ST_Distance(coordinates, ?) < radius

# x SCHLECHT: Distanz in SELECT ohne Filter
FOR location IN locations
    LET dist = ST_Distance(location.coordinates, @point)
    RETURN {location, dist}
-- Keine Index-Nutzung! Alle Rows werden berechnet
```

3. Koordinaten-Validierung

```
def validate_coordinates(lon, lat):
    """Prüft ob Koordinaten gültig sind"""
    if not (-180 <= lon <= 180):
        raise ValueError(f"Longitude {lon} außerhalb [-180, 180]")
    if not (-90 <= lat <= 90):
        raise ValueError(f"Latitude {lat} außerhalb [-90, 90]")
    return True

# Verwende vor dem Speichern
validate_coordinates(lon, lat)
```

4. Präzision und Rundung

```
# GUT: 6 Dezimalstellen (~10cm Genauigkeit)
coordinates = [round(lon, 6), round(lat, 6)]

# Zu viele Dezimalstellen bringen keine Vorteile:
# 5 Dezimalstellen: ~1m Genauigkeit
# 6 Dezimalstellen: ~10cm Genauigkeit
# 7 Dezimalstellen: ~1cm Genauigkeit (meist unnötig)
```

5. Caching für häufige Queries

```
from functools import lru_cache
import time

@lru_cache(maxsize=1000)
def get_cached_nearby_restaurants(lat, lon, radius):
    """Cached Restaurant-Suche"""
    # Cache für 5 Minuten
    cache_key = (round(lat, 3), round(lon, 3), radius)
    return find_nearby_restaurants(lat, lon, max_distance_m=radius)

# Bei wiederholten Anfragen aus gleicher Region: Cache-Hit!
```

14.8 Performance-Tipps

1. Bounding Box vor Distanz-Berechnung

```
# EFFIZIENT: Erst grobe Filterung, dann genaue Distanz
FOR location IN locations
    FILTER ST_Within(location.coordinates, BBOX(@min_lon, @min_lat, @max_lon, @max_lat)) -- Schne
    AND ST_Distance(location.coordinates, POINT(@lon, @lat)) < @radius -- Nur für Kandidaten
RETURN location
```

2. Limit verwenden

```
# Wenn nur Top-N benötigt:  
FOR location IN locations  
  LET dist = ST_Distance(location.coordinates, POINT(@lon, @lat))  
  FILTER dist < 5000  
  SORT dist ASC  
  LIMIT 10  -- Stoppt nach 10 Ergebnissen  
  RETURN location
```

3. Materializedviews für häufige Gebiete

```
# Erstelle View für "beliebtes Gebiet"  
conn.execute("""  
CREATE MATERIALIZED VIEW berlin_mitte_restaurants AS  
FOR restaurant IN restaurants  
  FILTER ST_Within(restaurant.coordinates, BBOX(13.35, 52.50, 13.45, 52.55))  
  RETURN restaurant  
""")  
  
# Refresh periodisch (z.B. stündlich)  
conn.execute("REFRESH MATERIALIZED VIEW berlin_mitte_restaurants")
```

14.9 Vergleich mit spezialisierten Geo-Systemen

Feature	ThemisDB	PostGIS	MongoDB Geo
R-Tree Index	Native	GiST	2dsphere
Distanz-Queries			
Polygon-Support		(komplex)	
3D-Geometrie	×		×
Koordinatensysteme	WGS84	Viele	WGS84
Performance			
Multi-Model		×	
Einfachheit			

Empfehlung: - **ThemisDB:** Gut für die meisten Anwendungen, besonders mit Multi-Model Daten -

PostGIS: Beste Wahl für komplexe GIS-Anwendungen - **MongoDB:** Gut für Dokument + Geo Kombination

14.10 Übungen

Übung 1: Store Locator

Implementieren Sie einen Store Locator mit: - Nächste 5 Filialen - Öffnungszeiten-Filterung - Routenvorschlag

Übung 2: Geofencing

Erstellen Sie ein Geofencing-System: - Definieren Sie virtuelle Zonen (Polygone) - Trigger beim Ein/Austritt - Benachrichtigungen

Übung 3: Heat Map

Generieren Sie eine Heat Map: - Aggregiere Punkte nach Geo-Hash - Cluster für verschiedene Zoom-Level - Export für Mapping-Tools

Zusammenfassung

In diesem Kapitel haben Sie gelernt:

Geo-Datentypen: Point, LineString, Polygon **Räumliche Indizes:** R-Tree für effiziente Geo-Queries
Abfragen: Radius, Bounding Box, KNN, Polygon **Praxis-Beispiele:** Lieferdienst, Immobiliensuche
Best Practices: Index-Design, Performance, Validation

Geo-Spatial Features in ThemisDB bieten eine solide Grundlage für Location-Based Services ohne externe Geo-Datenbank. Die native Integration mit anderen Datenmodellen (Relational, Graph, Dokument, Vector) macht ThemisDB zur idealen Plattform für moderne Geo-Anwendungen.

Im nächsten Kapitel sehen wir uns **Analytics & Reporting** an – Aggregationen, Dashboards und Business Intelligence mit ThemisDB.

Kapitel 15: Kapitel 15 - Analytics

15.1 Einführung in Analytics mit ThemisDB

ThemisDB bietet leistungsstarke Analyse- und Reporting-Funktionen, die es ermöglichen, komplexe Geschäftslogik direkt in der Datenbank auszuführen. Durch die Kombination von relationalen Aggregationen, Graph-Analysen und Vektor-basierten Ähnlichkeitssuchen können umfassende Business-Intelligence-Lösungen erstellt werden.

15.1.1 Warum Analytics in der Datenbank?

Vorteile: - **Performance:** Datenverarbeitung direkt am Speicherort - **Konsistenz:** ACID-Garantien für Analyseergebnisse - **Echtzeit:** Keine ETL-Verzögerungen - **Multi-Model:** Kombinierte Analysen über verschiedene Datenmodelle

15.9 OLAP Cube Design (Neu)

15.9.1 Star Schema

Abb. 15.1: Analytics-Query-Pipeline

Keys: - Fact: `time_key`, `product_key`, `customer_key`, `region_key` - Dim: Surrogate Keys (`int`) für schnelle Joins

15.9.2 Slowly Changing Dimensions (SCD)

Typ	Verhalten	Beispiel
SCD1	Überschreibt alte Werte	Preis aktualisieren
SCD2	Historisiert mit <code>valid_from/valid_to</code>	Kundenadresse
SCD3	Speichert Vorversion im gleichen Datensatz	Vorheriger Status

AQL (SCD2 Update):

```

LET now = DATE_NOW()

FOR dim IN dim_product
  FILTER dim.product_id == @product_id
  FILTER dim.valid_to == null
  UPDATE dim WITH { valid_to: now } IN dim_product

INSERT {
  product_id: @product_id,
  name: @name,
  category: @category,
  valid_from: now,
  valid_to: null
} INTO dim_product

```

15.9.3 Derived & Aggregate Tables

- **Rollups:** day → month → quarter → year
- **Pre-Aggregation:** Umsatz pro Region/Produkt/Quartal
- **Materialized Views:** Nightly Refresh oder Streaming (CDC)


```
-- Quarters-Rollup
FOR fact IN sales
  COLLECT
    year = DATE_YEAR(fact.ts),
    quarter = DATE_QUARTER(fact.ts),
    region = fact.region,
    category = fact.category
  AGGREGATE
    revenue = SUM(fact.amount),
    units = SUM(fact.quantity)
  RETURN {
    year, quarter, region, category, revenue, units
  }
```

15.10 Incremental Materialization & CDC

15.10.1 Changefeed → Materialized View

```

"""Incremental Refresh für sales_rollup (hourly)"""
from datetime import datetime, timedelta

def refresh_sales_rollup(db, since_ts):
    events = db.changefeed("sales", {"since": since_ts})
    buffer = []
    for ev in events:
        buffer.append(ev)
        if len(buffer) >= 1000:
            apply_buffer(db, buffer)
            buffer.clear()
    apply_buffer(db, buffer)

def apply_buffer(db, buffer):
    db.query("""
        FOR ev IN @events
        LET month = DATE_TRUNC('month', ev.ts)
        UPSERT { month, region: ev.region, category: ev.category }
        INSERT {
            month,
            region: ev.region,
            category: ev.category,
            revenue: ev.amount,
            units: ev.quantity
        }
        UPDATE {
            revenue: OLD.revenue + ev.amount,
            units: OLD.units + ev.quantity
        }
        IN sales_rollup
    """, {"events": buffer})

```

15.10.2 Late Arriving Facts & Corrections

```
-- Korrekturen erkennen
FOR ev IN changefeed_sales
  FILTER ev.event_type == "correction"
  LET prev = DOCUMENT(sales_rollup, ev.rollup_key)
  UPDATE prev WITH {
    revenue: prev.revenue - ev.old_amount + ev.new_amount,
    units: prev.units - ev.old_qty + ev.new_qty
  } IN sales_rollup
```

15.10.3 OLAP Query Patterns

```
-- Drill-down: Jahr → Monat → Tag
FOR row IN sales_rollup
  FILTER row.year == 2025
  COLLECT month = row.month
  AGGREGATE revenue = SUM(row.revenue)
  SORT month
  RETURN { month, revenue }

-- Pivot nach Region
FOR row IN sales_rollup
  COLLECT category = row.category
  AGGREGATE
    eu = SUM(row.region == 'EU' ? row.revenue : 0),
    us = SUM(row.region == 'US' ? row.revenue : 0),
    apac = SUM(row.region == 'APAC' ? row.revenue : 0)
  RETURN { category, eu, us, apac }
```

```

class AnalyticsGovernance:
    """Data Governance für Analytics"""

    def __init__(self, db):
        self.db = db

    def anonymize_customer_data(self, dataset):
        """Anonymisierung sensibler Daten"""
        return [{
            **row,
            'customer_id': hash(row['customer_id']),
            'email': None,
            'name': None
        } for row in dataset]

    def apply_row_level_security(self, query, user_role, user_region):
        """Row-Level Security anwenden"""
        if user_role == 'regional_manager':
            query += f" FILTER doc.region == '{user_region}'"
        elif user_role == 'analyst':
            # Nur aggregierte Daten
            query += " COLLECT ... AGGREGATE ..."

        return query

    def audit_query(self, user_id, query, timestamp):
        """Query-Audit-Log"""
        self.db.query("""
            INSERT {
                user_id: @user_id,
                query: @query,
                timestamp: @timestamp,
                type: 'analytics'
            } INTO audit_log
        """, {
            'user_id': user_id,
            'query': query,

```

```
        'timestamp': timestamp
    })
```

15.11 Zusammenfassung

15.2.1 Standard AQL-Aggregationen

ThemisDB unterstützt alle Standard-AQL-Aggregationsfunktionen:

```
-- Verkaufsstatistiken
FOR order IN orders
  FILTER order.order_date >= '2024-01-01'
  COLLECT month = DATE_TRUNC('month', order.order_date)
  AGGREGATE
    total_orders = COUNT(),
    revenue = SUM(order.total_amount),
    avg_order_value = AVG(order.total_amount),
    min_order = MIN(order.total_amount),
    max_order = MAX(order.total_amount),
    order_stddev = STDDEV(order.total_amount)
  SORT month
  RETURN {month, total_orders, revenue, avg_order_value, min_order, max_order, order_stddev}
```

Ausgabe:

month	total_orders	revenue	avg_order_value	min_order	max_order	order_stddev
-----	-----	-----	-----	-----	-----	-----
2024-01-01	1250	156780.50	125.42	12.50	1580.00	95.23
2024-02-01	1420	182340.75	128.45	9.99	2100.00	102.45

15.2.2 Window Functions für Trend-Analysen

```
-- Umsatztrend mit gleitendem Durchschnitt
FOR order IN orders
  SORT order.order_date DESC
  LIMIT 30
  LET moving_avg_7day = AVG_WINDOW(order.total_amount,
    {preceding: 6, following: 0})
  LET month_cumulative = SUM_WINDOW(order.total_amount,
    {partition: DATE_TRUNC('month', order.order_date)})
  LET rank_in_month = RANK_WINDOW(
    {partition: DATE_TRUNC('month', order.order_date),
     order: order.total_amount DESC})
  RETURN {
    order_date: order.order_date,
    total_amount: order.total_amount,
    moving_avg_7day,
    month_cumulative,
    rank_in_month
  }
```

15.2.3 PIVOT-Operationen

```
-- Umsatz nach Produktkategorie und Monat
LET pivot_data = (
  FOR order_item IN order_items
  FOR product IN products
  FILTER order_item.product_id == product.id
  COLLECT
    month = DATE_TRUNC('month', order_item.order_date),
    category = product.category
  AGGREGATE revenue = SUM(order_item.amount)
  RETURN {month, category, revenue}
)

// PIVOT operation (manual transformation)
FOR data IN pivot_data
  COLLECT month = data.month
  AGGREGATE
    electronics = SUM(data.category == 'Electronics' ? data.revenue : 0),
    clothing = SUM(data.category == 'Clothing' ? data.revenue : 0),
    books = SUM(data.category == 'Books' ? data.revenue : 0),
    home = SUM(data.category == 'Home' ? data.revenue : 0),
    sports = SUM(data.category == 'Sports' ? data.revenue : 0)
  RETURN {month, electronics, clothing, books, home, sports}
```

15.3 Erweiterte Aggregationen mit AQL

15.3.1 COLLECT für komplexe Gruppierungen

```
-- Kundensegmentierung nach Kaufverhalten
FOR order IN orders
  COLLECT
    customer_id = order.customer_id,
    age_group = FLOOR(order.customer_age / 10) * 10
  AGGREGATE
    order_count = COUNT(1),
    total_spent = SUM(order.total_amount),
    avg_order = AVG(order.total_amount),
    categories = UNIQUE(order.category)
  INTO group
  FILTER order_count >= 5
  LET segment = (
    total_spent > 5000 ? "VIP" :
    total_spent > 1000 ? "Premium" :
    "Regular"
  )
  RETURN {
    customer_id,
    age_group,
    segment,
    metrics: {
      orders: order_count,
      total_revenue: total_spent,
      avg_order_value: avg_order,
      product_diversity: LENGTH(categories)
    }
  }
```


15.3.2 Multi-Level Aggregationen

```
-- Hierarchische Umsatzanalyse
FOR order IN orders
  FILTER order.date >= DATE_NOW() - 365*24*60*60*1000
  COLLECT
    year = DATE_YEAR(order.date),
    quarter = DATE_QUARTER(order.date),
    region = order.shipping_region
  AGGREGATE
    revenue = SUM(order.total_amount),
    order_count = COUNT(1)
  COLLECT
    year = year,
    quarter = quarter
  AGGREGATE
    total_revenue = SUM(revenue),
    total_orders = SUM(order_count),
    regions = COUNT(region)
  RETURN {
    period: CONCAT(year, "-Q", quarter),
    total_revenue,
    total_orders,
    avg_per_region: total_revenue / regions,
    regions_active: regions
  }
```

15.4 Graph Analytics für Beziehungsanalysen

15.4.1 Customer Network Analysis

```
-- Kunden mit ähnlichen Kaufmustern finden
FOR customer IN customers
  FILTER customer.id == @customerId

  // Produkte des Kunden
  LET customer_products = (
    FOR order IN orders
      FILTER order.customer_id == customer.id
      FOR item IN order.items
      RETURN DISTINCT item.product_id
  )

  // Ähnliche Kunden finden
  LET similar_customers = (
    FOR other IN customers
      FILTER other.id != customer.id
      LET other_products = (
        FOR order IN orders
          FILTER order.customer_id == other.id
          FOR item IN order.items
          RETURN DISTINCT item.product_id
      )
      LET intersection = LENGTH(
        INTERSECTION(customer_products, other_products)
      )
      LET union_size = LENGTH(
        UNION(customer_products, other_products)
      )
      LET jaccard = intersection / union_size
      FILTER jaccard > 0.3
      SORT jaccard DESC
      LIMIT 10
      RETURN {
        customer_id: other.id,
        similarity: jaccard,
        shared_products: intersection
      }
  )
)
```

```
RETURN {  
  customer_id: customer.id,  
  similar_customers  
}
```

15.4.2 Influencer-Identifikation im Social Graph

```
-- Top-Influencer nach PageRank
FOR user IN users
  LET followers_count = LENGTH(
    FOR edge IN follows
      FILTER edge._to == user._id
      RETURN 1
  )
  LET engagement = (
    FOR post IN posts
      FILTER post.author_id == user.id
      RETURN SUM([
        post.likes_count,
        post.comments_count * 2,
        post.shares_count * 3
      ])
  )
  LET avg_engagement = AVG(engagement)

  // PageRank-ähnliche Berechnung
  LET influence_score = (
    followers_count * 0.4 +
    avg_engagement * 0.6
  )

  FILTER influence_score > 100
  SORT influence_score DESC
  LIMIT 50

  RETURN {
    user_id: user.id,
    username: user.username,
    followers: followers_count,
    avg_engagement,
    influence_score
  }
```

15.5 Vektor-basierte Analysen

15.5.1 Produkt-Clustering nach Embeddings

```
import themisdb
import numpy as np
from sklearn.cluster import KMeans

# Verbindung
db = themisdb.connect("localhost:8529")

# Produkt-Embeddings laden
query = """
FOR product IN products
  FILTER product.embedding != null
  RETURN {
    id: product.id,
    name: product.name,
    embedding: product.embedding
  }
"""
products = db.query(query)

# Embeddings extrahieren
embeddings = np.array([p['embedding'] for p in products])
product_ids = [p['id'] for p in products]

# K-Means Clustering
kmeans = KMeans(n_clusters=10, random_state=42)
clusters = kmeans.fit_predict(embeddings)

# Cluster zurückschreiben
for product_id, cluster_id in zip(product_ids, clusters):
    db.query("""
        UPDATE products
        SET cluster_id = @cluster
        WHERE id = @id
    """, {
        'id': product_id,
        'cluster': int(cluster_id)
    })
```

```
# Cluster-Statistiken
cluster_stats = db.query("""
    FOR product IN products
        COLLECT cluster = product.cluster_id
        AGGREGATE
            count = COUNT(1),
            avg_price = AVG(product.price),
            categories = UNIQUE(product.category)
        RETURN {
            cluster_id: cluster,
            product_count: count,
            avg_price,
            main_categories: categories
        }
    """)

for stats in cluster_stats:
    print(f"Cluster {stats['cluster_id']}: {stats['product_count']} Produkte")
    print(f"    Durchschnittspreis: €{stats['avg_price']:.2f}")
    print(f"    Kategorien: {'', ' '.join(stats['main_categories'][:3])}")
```


15.5.2 Anomalie-Erkennung mit Vektor-Distanzen

```
-- Ungewöhnliche Transaktionen identifizieren
FOR transaction IN transactions
  // Durchschnittliches Transaktionsprofil des Kunden
  LET customer_avg_embedding = (
    FOR t IN transactions
      FILTER t.customer_id == transaction.customer_id
      AND t.id != transaction.id
      RETURN t.transaction_embedding
  )

  LET avg_embedding = (
    FOR emb IN customer_avg_embedding
      RETURN AVERAGE(emb)
  )

  // Distanz zur Normalverteilung
  LET distance = VECTOR_DISTANCE(
    "cosine",
    transaction.transaction_embedding,
    avg_embedding
  )

  // Anomalie-Score
  LET anomaly_score = distance > 0.7 ? 1.0 : distance / 0.7

  FILTER anomaly_score > 0.8
  SORT anomaly_score DESC
  LIMIT 100

  RETURN {
    transaction_id: transaction.id,
    customer_id: transaction.customer_id,
    amount: transaction.amount,
    anomaly_score,
    reason: anomaly_score > 0.95 ? "HIGH_RISK" : "REVIEW"
  }
```

15.6 Materialized Views für Performance

15.6.1 Erstellen von Materialized Views

```
-- Tägliche Verkaufsübersicht
CREATE MATERIALIZED VIEW daily_sales_summary AS
SELECT
    DATE(order_date) AS date,
    COUNT(*) AS order_count,
    SUM(total_amount) AS revenue,
    AVG(total_amount) AS avg_order_value,
    COUNT(DISTINCT customer_id) AS unique_customers,
    SUM(CASE WHEN is_first_order THEN 1 ELSE 0 END) AS new_customers
FROM orders
GROUP BY DATE(order_date);

-- Refresh Strategy
CREATE TRIGGER refresh_daily_sales
    AFTER INSERT OR UPDATE ON orders
    FOR EACH STATEMENT
    EXECUTE PROCEDURE refresh_materialized_view('daily_sales_summary');
```

15.6.2 Inkrementelles Update

```
def update_daily_metrics(date):  
    """Inkrementelles Update für einen Tag"""  
  
    # Alte Metriken löschen  
    db.query("""  
        DELETE FROM daily_sales_summary  
        WHERE date = @date  
    """, {'date': date})  
  
    # Neue Metriken berechnen  
    db.query("""  
        INSERT INTO daily_sales_summary  
        SELECT  
            @date AS date,  
            COUNT(*) AS order_count,  
            SUM(total_amount) AS revenue,  
            AVG(total_amount) AS avg_order_value,  
            COUNT(DISTINCT customer_id) AS unique_customers,  
            SUM(CASE WHEN is_first_order THEN 1 ELSE 0 END) AS new_customers  
        FROM orders  
        WHERE DATE(order_date) = @date  
    """, {'date': date})
```

15.7 OLAP-Würfel und Mehrdimensionale Analysen

15.7.1 Erstellen eines OLAP-Würfels

15.7.1 Erstellen eines OLAP-Würfels

OLAP-Würfel (Online Analytical Processing) ermöglichen multidimensionale Analysen über verschiedene Dimensionen (Zeit, Kunde, Produkt, Region). ThemisDB kann durch geschicktes Kombinieren von Dokumenten und Aggregationen OLAP-ähnliche Analysen durchführen, ohne separate OLAP-Systeme zu benötigen.

Vollständiger Code: [examples/15_analytics/olap_cube.py](#) (ca. 100 Zeilen)

OLAP-Würfel Konstruktion:

```
import pandas as pd

def create_sales_cube(db):
    """Erstellt multidimensionalen OLAP-Würfel für Verkaufsanalysen"""

    # Daten mit allen Dimensionen aggregieren
    query = """
    FOR order IN orders
      LET customer = DOCUMENT('customers', order.customer_id)
      LET items = (
        FOR item IN order.items
          LET product = DOCUMENT('products', item.product_id)
          RETURN {
            category: product.category,
            brand: product.brand,
            price: item.price,
            quantity: item.quantity,
            revenue: item.price * item.quantity
          }
        )
      RETURN {
        date: order.order_date,
        year: DATE_YEAR(order.order_date),
        quarter: DATE_QUARTER(order.order_date),
        month: DATE_MONTH(order.order_date),
        customer_segment: customer.segment,
        customer_region: customer.region,
        items: items,
        total_amount: order.total_amount
      }
    """

    # In Pandas DataFrame laden
    data = db.query(query)
    df = pd.DataFrame(data)

    # Explode items für granulare Analyse
    df_items = df.explode('items')
```

```
df_items = pd.concat([
    df_items.drop('items', axis=1),
    df_items['items'].apply(pd.Series)
], axis=1)

return df_items
```

Slice & Dice Operationen:

```
def analyze_cube(cube_df):  
    """Verschiedene OLAP-Operationen auf dem Würfel"""  
  
    # Slice: Nur eine Region  
    region_slice = cube_df[cube_df['customer_region'] == 'Europe']  
  
    # Dice: Mehrere Dimensionen filtern  
    dice = cube_df[  
        (cube_df['year'] == 2024) &  
        (cube_df['category'] == 'Electronics')  
    ]  
  
    # Drill-down: Von Jahr zu Monat  
    monthly = cube_df.groupby(['year', 'month', 'category'])['revenue'].sum()  
  
    # Roll-up: Von Monat zu Quarter  
    quarterly = cube_df.groupby(['year', 'quarter'])['revenue'].sum()  
  
    # Pivot: Cross-tabulation  
    pivot = cube_df.pivot_table(  
        values='revenue',  
        index='category',  
        columns='customer_segment',  
        aggfunc='sum'  
    )  
  
    return {  
        'region_slice': region_slice,  
        'dice': dice,  
        'monthly': monthly,  
        'quarterly': quarterly,  
        'pivot': pivot  
    }
```

Wichtige OLAP-Konzepte:

1. **Dimensionen:** Zeit, Kunde, Produkt, Region (Was analysiert wird)
2. **Measures:** Revenue, Quantity, Count (Was gemessen wird)

3. **Slice**: Einzelne Dimension filtern (z.B. nur 2024)
4. **Dice**: Mehrere Dimensionen kombiniert filtern
5. **Drill-down**: Von aggregiert zu detailliert (Jahr → Monat → Tag)
6. **Roll-up**: Von detailliert zu aggregiert (Tag → Monat → Jahr)
7. **Pivot**: Dimensionen als Zeilen/Spalten darstellen

Die vollständige Implementierung unterstützt zusätzlich: - Hierarchische Dimensionen (Jahr/Quarter/Monat/Tag) - Calculated Measures (Profit Margin, Growth Rate) - Time Intelligence (YTD, MTD, Same Period Last Year) - Ranking (Top 10 Products)

15.7.2 Slice und Dice Operationen

```
def slice_cube(cube_data, dimension, value):  
    """Slice-Operation auf dem Würfel"""  
    return cube_data[cube_data[dimension] == value]  
  
def dice_cube(cube_data, filters):  
    """Dice-Operation mit mehreren Dimensionen"""  
    result = cube_data  
    for dim, values in filters.items():  
        result = result[result[dim].isin(values)]  
    return result  
  
# Beispiel  
filters = {  
    'customer_region': ['Europe', 'North America'],  
    'category': ['Electronics', 'Books'],  
    'year': [2024]  
}  
  
diced = dice_cube(df, filters)
```

15.8 Dashboard-Metriken in Echtzeit

15.8.1 KPI-Berechnung

15.8.1 KPI-Berechnung

Echtzeit-KPI-Dashboards benötigen schnelle Abfragen über aktuelle Daten. ThemisDB ermöglicht effiziente Berechnung von Key Performance Indicators durch optimierte AQL-Queries mit Aggregationen und Zeitfiltern. Die Dashboard-Klasse zeigt typische Metriken wie tägliche Verkäufe, Conversion Rate und Top-Produkte.

Vollständiger Code: `examples/15_analytics/realtime_dashboard.py` (ca. 130 Zeilen)

Dashboard-Klasse mit KPI-Berechnung:

```

class RealtimeDashboard:
    def __init__(self, db):
        self.db = db

    def get_current_metrics(self):
        """Berechnet aktuelle KPIs für Dashboard"""

        metrics = {}

        # Heutige Verkäufe - mit AGGREGATE für Effizienz
        today = self.db.query("""
            LET today = DATE_FORMAT(DATE_NOW(), '%Y-%m-%d')
            FOR order IN orders
                FILTER DATE_FORMAT(order.order_date, '%Y-%m-%d') == today
            COLLECT AGGREGATE
                count = COUNT(1),
                revenue = SUM(order.total_amount),
                avg = AVG(order.total_amount)
            RETURN {count, revenue, avg}
        """)[0]

        metrics['today'] = today

        # Vergleich zu gestern (Growth Rate)
        yesterday = self.db.query("""
            LET yesterday = DATE_SUBTRACT(DATE_NOW(), 1, 'day')
            FOR order IN orders
                FILTER DATE_FORMAT(order.order_date, '%Y-%m-%d') ==
                    DATE_FORMAT(yesterday, '%Y-%m-%d')
            COLLECT AGGREGATE revenue = SUM(order.total_amount)
            RETURN revenue
        """)[0]

        metrics['growth_rate'] = (
            (today['revenue'] - yesterday) / yesterday * 100
            if yesterday > 0 else 0
        )

```

```
# Top 5 Produkte heute
top_products = self.db.query("""
    LET today = DATE_FORMAT(DATE_NOW(), '%Y-%m-%d')
    FOR order IN orders
        FILTER DATE_FORMAT(order.order_date, '%Y-%m-%d') == today
        FOR item IN order.items
            LET product = DOCUMENT('products', item.product_id)
            COLLECT p = product INTO items
            LET total = SUM(items[*].item.quantity * items[*].item.price)
            SORT total DESC
            LIMIT 5
        RETURN {
            product: p.name,
            revenue: total,
            units: SUM(items[*].item.quantity)
        }
""")

metrics['top_products'] = top_products

# Conversion Rate (Orders / Visitors)
metrics['conversion_rate'] = self._calculate_conversion_rate()

return metrics
```

Conversion Rate Berechnung:

```
def _calculate_conversion_rate(self):
    """Berechnet Conversion Rate für heute"""

    result = self.db.query("""
        LET today = DATE_FORMAT(DATE_NOW(), '%Y-%m-%d')

        LET orders = (
            FOR o IN orders
                FILTER DATE_FORMAT(o.order_date, '%Y-%m-%d') == today
            RETURN 1
        )

        LET visitors = (
            FOR v IN visitors
                FILTER DATE_FORMAT(v.visit_date, '%Y-%m-%d') == today
            RETURN 1
        )

        RETURN {
            orders: LENGTH(orders),
            visitors: LENGTH(visitors),
            rate: LENGTH(orders) / LENGTH(visitors) * 100
        }
    """)[0]

    return result['rate']
```

Dashboard Update (WebSocket-basiert):

```
def stream_updates(self, websocket):
    """Streamt KPI-Updates in Echtzeit"""

    while True:
        metrics = self.get_current_metrics()

        # An WebSocket-Clients senden
        websocket.send(json.dumps({
            'timestamp': datetime.now().isoformat(),
            'metrics': metrics
        }))

        time.sleep(5) # Update alle 5 Sekunden
```

Typische Dashboard-Metriken:

Metric	Beschreibung	Query-Strategie
Daily Revenue	Summe aller Orders heute	<code>COLLECT AGGREGATE SUM(total)</code>
Growth Rate	Vergleich zu gestern	Zwei Queries mit Zeitfilter
Top Products	Best-seller heute	<code>COLLECT</code> + <code>SORT</code> + <code>LIMIT</code>
Conversion Rate	Orders / Visitors	Zwei Subqueries mit <code>LENGTH()</code>
Avg Order Value	Durchschnitt pro Order	<code>COLLECT AGGREGATE AVG(total)</code>

Die vollständige Implementierung enthält zusätzlich: - Caching für häufig abgefragte Metriken - Materialized Views für komplexe Berechnungen - Alerting bei Schwellwert-Überschreitungen - Historische Trend-Visualisierung - Drill-down für Detail-Analysen

15.8.2 Change Data Capture für Live-Updates

```
def subscribe_to_metrics_updates(db, callback):  
    """CDC-Stream für Echtzeit-Metriken"""  
  
    stream = db.collection('orders').watch([  
        {'$match': {'operationType': 'insert'}}  
    ])  
  
    for change in stream:  
        # Neue Bestellung  
        order = change['fullDocument']  
  
        # Metriken aktualisieren  
        updated_metrics = {  
            'timestamp': order['order_date'],  
            'order_id': order['_id'],  
            'amount': order['total_amount'],  
            'customer_id': order['customer_id']  
        }  
  
        # Callback für Dashboard-Update  
        callback(updated_metrics)  
  
# Verwendung  
def on_new_order(metrics):  
    print(f"Neue Bestellung: €{metrics['amount']:.2f}")  
    # Dashboard aktualisieren  
  
subscribe_to_metrics_updates(db, on_new_order)
```

15.9 Predictive Analytics

15.9.1 Trend-Prognosen mit linearer Regression


```
from sklearn.linear_model import LinearRegression
import numpy as np

def forecast_revenue(db, days_ahead=30):
    """Umsatzprognose für die nächsten Tage"""

    # Historische Daten
    historical = db.query("""
        FOR order IN orders
        FILTER order.order_date >= DATE_SUBTRACT(DATE_NOW(), 90, 'day')
        COLLECT date = DATE_FORMAT(order.order_date, '%Y-%m-%d')
        AGGREGATE revenue = SUM(order.total_amount)
        SORT date
        RETURN {date, revenue}
    """)

    # Features vorbereiten
    X = np.array([[i] for i in range(len(historical))])
    y = np.array([h['revenue'] for h in historical])

    # Modell trainieren
    model = LinearRegression()
    model.fit(X, y)

    # Prognose
    future_X = np.array([[i] for i in range(len(historical), len(historical) + days_ahead)])
    forecast = model.predict(future_X)

    # Konfidenzintervall (vereinfacht)
    residuals = y - model.predict(X)
    std_error = np.std(residuals)
    confidence_interval = 1.96 * std_error # 95% CI

    return {
        'forecast': forecast.tolist(),
        'lower_bound': (forecast - confidence_interval).tolist(),
        'upper_bound': (forecast + confidence_interval).tolist()
    }
```

```
# Prognose erstellen
forecast = forecast_revenue(db, days_ahead=30)
print(f"Prognostizierter Umsatz in 30 Tagen: €{forecast['forecast'][-1]:.2f}")
print(f"Konfidenzintervall: €{forecast['lower_bound'][-1]:.2f} - €{forecast['upper_bound'][-1]:.2f}")
```

15.9.2 Churn-Vorhersage

```
def calculate_churn_risk(db, customer_id):  
    """Churn-Risiko für einen Kunden berechnen"""  
  
    features = db.query("""  
        LET customer = DOCUMENT('customers', @customer_id)  
        LET orders = (  
            FOR order IN orders  
                FILTER order.customer_id == @customer_id  
                SORT order.order_date DESC  
                RETURN order  
        )  
  
        LET days_since_last_order = DATE_DIFF(  
            orders[0].order_date,  
            DATE_NOW(),  
            'day'  
        )  
  
        LET order_frequency = LENGTH(orders) / (  
            DATE_DIFF(  
                customer.registration_date,  
                DATE_NOW(),  
                'day'  
            ) / 30  
        )  
  
        LET avg_order_value = AVG(  
            FOR order IN orders  
                RETURN order.total_amount  
        )  
  
        LET total_spent = SUM(  
            FOR order IN orders  
                RETURN order.total_amount  
        )  
  
        RETURN {  
            days_since_last_order,
```

```

        order_frequency,
        avg_order_value,
        total_spent,
        support_tickets: LENGTH(customer.support_tickets),
        has_complained: LENGTH(
            FOR ticket IN customer.support_tickets
            FILTER ticket.type == 'complaint'
            RETURN 1
        ) > 0
    }
    """', {'customer_id': customer_id}))[0]

# Einfacher Risiko-Score
risk_score = 0

if features['days_since_last_order'] > 60:
    risk_score += 0.3
if features['order_frequency'] < 1:
    risk_score += 0.2
if features['avg_order_value'] < 50:
    risk_score += 0.1
if features['support_tickets'] > 5:
    risk_score += 0.2
if features['has_complained']:
    risk_score += 0.2

return {
    'customer_id': customer_id,
    'churn_risk': min(risk_score, 1.0),
    'risk_level': (
        'HIGH' if risk_score > 0.7 else
        'MEDIUM' if risk_score > 0.4 else
        'LOW'
    ),
    'features': features
}

```

15.10 Reporting und Export

15.10.1 PDF-Report-Generierung

```
from reportlab.lib.pagesizes import A4
from reportlab.lib import colors
from reportlab.lib.units import cm
from reportlab.platypus import SimpleDocTemplate, Table, TableStyle, Paragraph
from reportlab.lib.styles import getSampleStyleSheet

def generate_sales_report(db, start_date, end_date, filename):
    """Verkaufsbericht als PDF generieren"""

    # Daten abfragen
    summary = db.query("""
        FOR order IN orders
        FILTER order.order_date >= @start_date
        AND order.order_date <= @end_date
        COLLECT AGGREGATE
            total_orders = COUNT(1),
            total_revenue = SUM(order.total_amount),
            avg_order_value = AVG(order.total_amount)
        RETURN {
            total_orders,
            total_revenue,
            avg_order_value
        }
    """, {'start_date': start_date, 'end_date': end_date})[0]

    top_products = db.query("""
        FOR order IN orders
        FILTER order.order_date >= @start_date
        AND order.order_date <= @end_date
        FOR item IN order.items
        COLLECT product_id = item.product_id
        AGGREGATE
            quantity = SUM(item.quantity),
            revenue = SUM(item.price * item.quantity)
        LET product = DOCUMENT('products', product_id)
        SORT revenue DESC
        LIMIT 10
        RETURN [product.name, quantity, revenue]
```

```

"""', {'start_date': start_date, 'end_date': end_date})

# PDF erstellen
doc = SimpleDocTemplate(filename, pagesize=A4)
elements = []
styles = getSampleStyleSheet()

# Titel
title = Paragraph(f"Verkaufsbericht {start_date} bis {end_date}", styles['Title'])
elements.append(title)

# Zusammenfassung
summary_data = [
    ['Metric', 'Value'],
    ['Gesamtbestellungen', f"{summary['total_orders']:,}"],
    ['Gesamtumsatz', f"€{summary['total_revenue']:, .2f}"],
    ['Ø Bestellwert', f"€{summary['avg_order_value']:.2f}"]
]

summary_table = Table(summary_data, colWidths=[8*cm, 8*cm])
summary_table.setStyle(TableStyle([
    ('BACKGROUND', (0, 0), (-1, 0), colors.grey),
    ('TEXTCOLOR', (0, 0), (-1, 0), colors.whitesmoke),
    ('ALIGN', (0, 0), (-1, -1), 'CENTER'),
    ('FONTNAME', (0, 0), (-1, 0), 'Helvetica-Bold'),
    ('FONTSIZE', (0, 0), (-1, 0), 14),
    ('BOTTOMPADDING', (0, 0), (-1, 0), 12),
    ('BACKGROUND', (0, 1), (-1, -1), colors.beige),
    ('GRID', (0, 0), (-1, -1), 1, colors.black)
]))
elements.append(summary_table)

# Top-Produkte
elements.append(Paragraph("Top 10 Produkte", styles['Heading2']))

product_data = [['Produkt', 'Menge', 'Umsatz']]
product_data.extend(top_products)

```



```
product_table = Table(product_data, colWidths=[10*cm, 3*cm, 3*cm])
product_table.setStyle(TableStyle([
    ('BACKGROUND', (0, 0), (-1, 0), colors.grey),
    ('TEXTCOLOR', (0, 0), (-1, 0), colors.whitesmoke),
    ('ALIGN', (1, 0), (-1, -1), 'RIGHT'),
    ('FONTNAME', (0, 0), (-1, 0), 'Helvetica-Bold'),
    ('GRID', (0, 0), (-1, -1), 1, colors.black)
]))
elements.append(product_table)

# PDF generieren
doc.build(elements)
print(f"Report saved to {filename}")

# Report erstellen
generate_sales_report(db, '2024-01-01', '2024-03-31', 'Q1_2024_Report.pdf')
```

15.10.2 CSV-Export für Excel

```
import csv

def export_to_csv(db, query, filename, params=None):
    """Abfrageergebnisse als CSV exportieren"""

    results = db.query(query, params or {})

    if not results:
        print("No data to export")
        return

    # Header aus erstem Datensatz
    headers = list(results[0].keys())

    with open(filename, 'w', newline='', encoding='utf-8') as csvfile:
        writer = csv.DictWriter(csvfile, fieldnames=headers)
        writer.writeheader()
        writer.writerows(results)

    print(f"Exported {len(results)} rows to {filename}")

# Beispiel: Kundenanalyse exportieren
export_to_csv(db, """
    FOR customer IN customers
        LET orders = (
            FOR order IN orders
                FILTER order.customer_id == customer.id
            RETURN order
        )
    RETURN {
        customer_id: customer.id,
        name: customer.name,
        email: customer.email,
        total_orders: LENGTH(orders),
        total_spent: SUM(FOR o IN orders RETURN o.total_amount),
        last_order_date: MAX(FOR o IN orders RETURN o.order_date)
    }
""", 'customers_analysis.csv')
```

15.11 Best Practices für Analytics

15.11.1 Performance-Optimierung

Indexierung:

```
-- Composite Index für häufige Queries
CREATE INDEX idx_orders_date_customer ON orders(order_date, customer_id);

-- Covering Index für Aggregationen
CREATE INDEX idx_orders_date_amount ON orders(order_date, total_amount);
```

Query-Optimierung: - Verwenden Sie **FILTER** früh in der Pipeline - Nutzen Sie **COLLECT** statt mehrfacher Gruppierungen - Limitieren Sie Ergebnisse mit **LIMIT** - Verwenden Sie Materialized Views für wiederkehrende Berechnungen

15.11.2 Data Governance

```
class AnalyticsGovernance:
    def anonymize(self, dataset):
        # Entferne persönliche Daten
        return [{**r, 'customer_id': hash(r['customer_id']),
                'email': None} for r in dataset]

    def apply_qls(self, query, role, region):
        # Row-Level Security nach Rolle
        if role == 'regional': query += f" FILTER region == '{region}'"
        return query
```

15.12 Zusammenfassung

ThemisDB bietet umfassende Analytics-Funktionen:

- **AQL-Aggregationen:** Standard- und Window-Functions
- **AQL-Analytics:** Multi-Level-Aggregationen und COLLECT
- **Graph-Analytics:** Beziehungsanalysen und Influencer-Detection
- **Vektor-Analytics:** Clustering und Anomalie-Erkennung

- **OLAP:** Mehrdimensionale Analysen und Würfel
- **Real-Time:** Live-Dashboards mit CDC
- **Predictive:** Prognosen und Churn-Vorhersage
- **Reporting:** PDF/CSV-Export und Visualisierung

Im nächsten Kapitel behandeln wir Machine Learning Integration für erweiterte Analysen.

Kapitel 16: Kapitel 16 - Sharding

"Skalierung ohne Komplexität: Native Multi-Model Sharding für Enterprise-Workloads"

Überblick

ThemisDB bietet **Production-Ready Horizontal Scaling** durch Hash-basiertes Sharding mit automatischem Rebalancing. Dieses Kapitel erklärt die Sharding-Architektur, Deployment-Szenarien und Performance-Charakteristiken für Enterprise-Umgebungen.

Was Sie in diesem Kapitel lernen werden: - Sharding-Architektur und Routing-Mechanismen - Deployment-Topologien (2/4/8 Nodes) - Auto-Rebalancing und Fault Tolerance - Performance-Charakteristiken und Benchmarks - Hyperscaler-Vergleich (Aurora, Spanner, Cosmos)

Voraussetzungen: Kapitel 2 (Architektur), Kapitel 21 (Performance)

Status: Production-Ready seit v1.4 (Dezember 2025)

16.1 Warum Sharding?


Das Single-Node-Limit

Ein einzelner ThemisDB-Server kann beeindruckende Mengen an Daten handhaben: - **Durchsatz:** ~45.000 writes/sec, ~200.000 reads/sec (NVMe) - **Speicher:** Bis zu ~10 TB pro Node (praktisches Limit) - **RAM:** Effizient durch Block Cache, aber limitiert auf Serverkapazität

Wann brauchen Sie Sharding? 1. **Datenvolumen > 10 TB:** Physische Speichergrenzen eines Nodes 2. **Durchsatz > 200K ops/sec:** CPU/IO-Sättigung eines Servers 3. **Geografische Verteilung:** Näher zum Benutzer für niedrige Latenz 4. **Hochverfügbarkeit:** Redundanz über mehrere Nodes


Sharding vs. Replication

Replication (Vertical Scaling):



- Einfach zu managen
- Read-Skalierung
- × Kein Write-Scaling
- × Keine Kapazitäts-Skalierung

Sharding (Horizontal Scaling):



- Read + Write Scaling
- Kapazitäts-Skalierung
- Geografische Verteilung
- △ Komplexere Verwaltung

Abb. 16.1: Replication vs Sharding Vergleich

16.2 Sharding-Architektur

Hash-basiertes Routing

ThemisDB verwendet **Consistent Hashing** mit MurmurHash3:

```
// Simplified Shard Router Implementation
class ShardRouter {
private:
    std::vector<ShardInfo> shards_;

public:
    // Berechne Shard für einen Key
    uint32_t get_shard_id(const std::string& key) {
        // MurmurHash3: Schnell & gut verteilte Hash-Funktion
        uint32_t hash = murmur3_hash(key);

        // Modulo-Routing: Hash % Anzahl_Shards
        return hash % shards_.size();
    }

    // Dokument auf korrekten Shard routen
    void route_document(const Document& doc) {
        // Primary Key als Routing-Schlüssel
        uint32_t shard_id = get_shard_id(doc.id);

        // An Shard weiterleiten
        shards_[shard_id].insert(doc);
    }
};
```

Wie funktioniert das?

1. **Client sendet Query** → Router
2. **Router berechnet Hash** des Primary Key

3. **Hash % N** bestimmt Shard-ID (N = Anzahl Shards)

4. **Query wird an Shard weitergeleitet**

5. **Ergebnis zurück zum Client**

Abb. 16.2: Hash-Based-Routing-Flow

Beispiel:

```
# Dokument mit ID "user_12345"
doc_id = "user_12345"

# MurmurHash3(doc_id) = 3847592834 (hypothetisch)
hash_value = murmur3(doc_id) # → 3847592834

# 8 Shards vorhanden
num_shards = 8
shard_id = hash_value % num_shards # → 3847592834 % 8 = 2

# ⇒ Dokument landet auf Shard 2
```

Warum MurmurHash3? - Schnell: ~2-3 CPU-Zyklen pro Byte - **Gut verteilt:** Minimiert Hotspots - **Deterministisch:** Gleicher Key → immer gleicher Shard

Range-basiertes Sharding (Optional)

Für geordnete Daten (z.B. Timestamps) können Range-Shards effizienter sein:


```
# config/sharding/range-sharding.yaml
sharding:
  strategy: range
  key: created_at
  ranges:
    - shard: 1
      min: "2020-01-01"
      max: "2022-12-31"
    - shard: 2
      min: "2023-01-01"
      max: "2024-12-31"
    - shard: 3
      min: "2025-01-01"
      max: null # Unbegrenzt
```


Vorteil: Zeitbereichs-Queries treffen nur relevante Shards

Nachteil: Ungleichmäßige Lastverteilung möglich

16.3 Deployment-Topologien

2-Node Cluster (Entry-Level)

Setup:




Charakteristiken: - **Kapazität:** 2× Single-Node (~20 TB) - **Throughput:** ~1.8× Single-Node (91% Scaling Efficiency) - **Redundanz:** RF=2 (jeder Shard hat 1 Replica auf anderem Node) - **Kosten:** 2× Hardware, <2× Betriebskosten

Use Case: Kleine bis mittlere Deployments (< 20 TB, < 100K ops/sec)

4-Node Cluster (Mid-Tier)

Setup:




Charakteristiken: - **Kapazität:** 4× Single-Node (~40 TB) - **Throughput:** ~3.6× Single-Node (90% Scaling Efficiency) - **Cross-Shard Queries:** ~10-15% Performance-Impact - **Rebalance-Zeit:** ~4-5 Minuten bei 2 → 4 Expansion

Use Case: Standard Enterprise Deployments (20-40 TB, 100-400K ops/sec)

8-Node Cluster (Enterprise)

Setup:



Charakteristiken: - **Kapazität:** 8× Single-Node (~80 TB) - **Throughput:** ~7.3× Single-Node (91% Scaling Efficiency) - **p99 Latenz:** 1.25ms (nur 0.43× Single-Node dank Parallelität!) - **Rebalance-Zeit:** ~8-10 Minuten bei 4 → 8 Expansion

Use Case: Große Enterprise Deployments (40-80 TB, 400K+ ops/sec)

16.4 Auto-Rebalancing

Wann wird rebalanced?

ThemisDB triggert automatisches Rebalancing bei:

1. **Skew-Threshold:** >15% Ungleichgewicht zwischen Shards
2. **Disk Utilization:** >70% auf einem Shard
3. **Manuell:** Via `themis-cli cluster rebalance`

Konfiguration:

```
# config/sharding/shard-router.yaml
rebalance:
  auto_trigger: true
  skew_threshold: 0.15      # 15% Ungleichgewicht
  disk_threshold: 0.70     # 70% Festplattenauslastung
  max_parallel_moves: 2    # Max 2 Chunks gleichzeitig verschieben
  chunk_size_mb: 64        # Chunk-Größe für Migration
```


Rebalance-Prozess

Schritt-für-Schritt:

1. Coordinator erkennt Skew (z.B. Shard 1: 25%, Shard 2: 15%)

Shard 1	Shard 2
25%	15%

2. Plan erstellen: Verschiebe 5% von Shard 1 → Shard 2



3. Chunk-Migration (64MB pro Chunk)

- Chunk kopieren (read-only)
- Neue Writes auf beide Shards
- Cutover: Alte Version löschen

4. Validierung & Completion

Shard 1	Shard 2
20%	20%

Performance-Impact: - **Throughput-Dip:** ~12% während Migration - **Recovery-Zeit:** <5 Minuten nach Completion - **Latenz:** p99 +15% während Migration

Monitoring während Rebalance

```
# Live Status anzeigen  
themis-cli cluster rebalance-status --watch
```

```
# Ausgabe:
```

```
| REBALANCE STATUS |  
|-----|  
| Progress: ██████████ 78% (125 / 160 chunks) |  
| Duration: 00:03:42 / ~00:05:00 |  
| Throughput Impact: -11% (current) |  
| |  
| Shard Distribution: |  
|   Shard 1: 21% ██████████ |  
|   Shard 2: 20% ██████████ |  
|   Shard 3: 19% ██████████ |  
|   Shard 4: 20% ██████████ |  
| |  
| ETA: 00:01:18 |  
|-----|
```

16.5 Fault Tolerance

Replica Failure (RF=2)

Szenario: Ein Replica-Node stirbt

Before:

Shard 1	Shard 1'
Primary	Replica

After (Auto-Recovery):

Shard 1	Shard 1'
Primary	(DEAD)

|
▼ Promote Replica

Shard 1	(New)
Primary	

Charakteristiken: - **Detection:** <5 Sekunden (Heartbeat-Timeout) - **Failover:** <15 Sekunden (Replica Promotion) - **Recovery:** <60 Sekunden (Rebuild Replica auf anderem Node) - **Throughput-Impact:** -24% während Outage, -10% während Rebuild

Monitoring:

```
# Cluster Health anzeigen
themis-cli cluster health
```

```
# Ausgabe bei Failure:
```

CLUSTER HEALTH: DEGRADED			
Shard 1: PRIMARY	node-1	(Leader)	
REPLICA	x node-2	(DEAD - 00:00:42)	
Shard 2: PRIMARY	node-3		
REPLICA	node-4		
⚠ Rebuilding Replica on node-5... (35%)			
ETA: 00:00:28			

Network Partition

Szenario: 10ms RTT Network Latency hinzugefügt

Impact: - **Latenz p50:** +8ms (von 0.5ms → 8.5ms) - **Latenz p99:** +12ms (von 1.2ms → 13.2ms) -
Throughput: -15% (wegen Sync-Overhead)

Graceful Degradation: ThemisDB passt sich automatisch an:

```
# Dynamic Network Adaptation
network:
  rtt_threshold: 10ms
  adaptive_batching: true    # Größere Batches bei hoher Latenz
  compression: lz4          # Kompression bei langsamen Links
```

16.6 Performance-Benchmarks

Scaling Efficiency

Testsetup: - **Hardware:** 8× c6i.4xlarge (16 vCPU, 32GB RAM, NVMe) - **Dataset:** 500M OLTP-Rows + 100M Vector-Embeddings (768D) - **Workload:** Mix B (50% Read, 50% Write, 10% Cross-Shard)

Ergebnisse:

Shards	Throughput (ops/sec)	Scaling Efficiency	Latenz p99 (ms)
1	100,000	Baseline (100%)	2.9
2	182,000	91%	3.1
4	362,000	90.5%	3.3
8	728,000	91%	1.25 (!!)

Warum ist p99 bei 8 Shards niedriger? → **Parallelität:** Queries werden auf mehrere Nodes verteilt, reduziert Queue-Wartezeiten!

Cross-Shard Join Performance

Query:


```
FOR order IN orders
  FOR customer IN customers
    FILTER order.customer_id == customer._id  -- Cross-Shard Join!
  RETURN {order, customer}
```

Performance (10% Cross-Shard Rate):

Shards	Local Query (ms)	Cross-Shard Query (ms)	Ratio
2	1.2	2.1	1.75×
4	1.3	2.4	1.85×
8	1.25	2.5	2.0×

Optimierung: Co-locate verwandte Daten auf gleichem Shard via Custom Routing:

```
# Custom Routing für Co-Location
def custom_shard_key(doc):
    if doc.type == "order":
        # Orders nach customer_id routen
        return doc.customer_id
    elif doc.type == "customer":
        # Customers nach ihrer ID routen
        return doc._id

# ⇒ Order und zugehöriger Customer auf gleichem Shard!
```

16.7 Hyperscaler-Vergleich

Cost-Performance-Analyse

Testsetup: 8-Node Cluster, 500M OLTP + 100M Vector, Mix B Workload

Provider	SKU	Throughput (ops/sec)	Latenz p99 (ms)	\$/Monat	\$/M Ops
ThemisDB	c6i.4xlarge × 8	728,000	1.25	\$2,880	\$6.25
AWS Aurora	r6g.4xlarge × 8	80,000	15	\$12,288	\$19.20
GCP Spanner	6-Node Regional	120,000	8	\$4,800	\$40
Azure Cosmos	50K RU/s	50,000	25	\$3,800	\$76
AWS Redshift	RA3 4-Node	100,000	12	\$3,260	\$32.50

Key Insights: - **ThemisDB vs Aurora:** 9.1× höherer Throughput, **67% Kosteneinsparung** - **ThemisDB vs Spanner:** 6.1× höherer Throughput, **84% Kosteneinsparung** - **ThemisDB vs Cosmos:** 14.6× höherer Throughput, **92% Kosteneinsparung**

Warum ist ThemisDB so viel günstiger? 1. **Keine Lizenzkosten:** Open Source (MIT) 2. **Effiziente Architektur:** Native Multi-Model eliminiert Overhead 3. **Self-Hosted:** On-Premises oder eigene Cloud-VMs

16.8 Production Deployment

Deployment-Checkliste

Vor dem Deployment: - ☐ Hardware-Dimensionierung (CPU, RAM, NVMe) - ☐ Netzwerk-Topologie (< 2ms RTT zwischen Nodes) - ☐ Monitoring-Setup (Prometheus + Grafana) - ☐ Backup-Strategie (Snapshots + WAL-Archive)

Deployment-Schritte:

```
# 1. Cluster initialisieren
themis-cli cluster init \
  --nodes node-1,node-2,node-3,node-4 \
  --shards 4 \
  --replication-factor 2

# 2. Sharding-Konfiguration laden
themis-cli cluster apply-config config/sharding/shard-router.yaml

# 3. Daten laden (parallel)
python tools/shard_loader.py \
  --config config/sharding/shard-router.yaml \
  --dataset oltp \
  --rows 500000000 \
  --workers 32

# 4. Cluster-Health überprüfen
themis-cli cluster health

# 5. Benchmarks laufen lassen
python tools/shard_bench.py \
  --shards 4 \
  --mix B \
  --duration 600 \
  --threads 64
```

Monitoring-Metriken

Kritische Metriken:

1. Shard-Utilization (Disk %)
Ziel: <70% pro Shard, <15% Skew
2. Throughput (ops/sec)
Ziel: >90% Scaling Efficiency
3. Latenz (p50/p95/p99)
Ziel: p99 <2.5× Single-Node
4. Cross-Shard Query Rate
Ziel: <20% aller Queries
5. Rebalance-Status
Ziel: Completion <5 min, <15% Dip

Grafana Dashboard:

```
{
  "dashboard": {
    "title": "ThemisDB Sharding Overview",
    "panels": [
      {
        "title": "Shard Distribution",
        "type": "bar",
        "query": "sum(themis_shard_size_bytes) by (shard_id)"
      },
      {
        "title": "Throughput by Shard",
        "type": "graph",
        "query": "rate(themis_shard_ops_total[5m]) by (shard_id)"
      },
      {
        "title": "Cross-Shard Query Rate",
        "type": "stat",
        "query": "rate(themis_cross_shard_queries[5m])"
      }
    ]
  }
}
```

16.9 Best Practices

1. Shard-Key Auswahl

Gute Shard-Keys: - **User-ID:** Gleichmäßige Verteilung, natürliche Co-Location (User + Orders) -

UUID: Perfekte zufällige Verteilung - **Hash(Composite-Key):** Für komplexe Co-Location-Szenarien

Schlechte Shard-Keys: - × **Timestamp:** Hotspots auf neuesten Shard - × **Sequential-ID:** Alle Writes auf einen Shard - × **Low-Cardinality:** Status-Felder (z.B. "active"/"inactive")

2. Cross-Shard Queries minimieren

Anti-Pattern:

```
-- SCHLECHT: Joins über alle Shards
FOR order IN orders
  FOR product IN products
    FILTER order.product_id == product._id
  RETURN {order, product}
```

Best Practice:

```
-- GUT: Denormalisierung vermeidet Cross-Shard Joins
FOR order IN orders
  RETURN {
    order,
    product_name: order.embedded_product_name, -- Denormalisiert!
    product_price: order.embedded_product_price
  }
```

3. Monitoring von Anfang an

Observability-Stack:

```
# docker-compose.yml
services:
  themisdb:
    image: themisdb:latest
    environment:
      THEMIS_METRICS_ENABLED: "true"
      THEMIS_METRICS_PORT: 9090

  prometheus:
    image: prom/prometheus
    volumes:
      - ./prometheus.yml:/etc/prometheus/prometheus.yml

  grafana:
    image: grafana/grafana
    ports:
      - "3000:3000"
```

4. Gradual Rollout

Empfohlene Rollout-Strategie: 1. **Woche 1:** 2-Node Cluster, 10% Traffic 2. **Woche 2:** 2-Node Cluster, 50% Traffic 3. **Woche 3:** 4-Node Cluster, 100% Traffic 4. **Monat 2+:** 8-Node Cluster bei Bedarf

16.10 High Availability Features (v1.4.0-alpha)

16.10.1 Hot Spare

Neu in v1.4.0-alpha: Automatisches Failover bei Node-Ausfällen mit Hot-Spare-Nodes für maximale Verfügbarkeit.

Konzept:

Ein Hot Spare ist ein vollständig konfigurierter Standby-Node, der im Cluster registriert ist und bei Ausfall eines aktiven Shards sofort dessen Rolle übernehmen kann.

Abb. 16.3: Shard-Key-Selection-Matrix

Konfiguration:

Die folgende YAML-Konfiguration zeigt ein Production-Setup mit 4 aktiven Shards und 2 Hot Spares für automatisches Failover. Die Hot Spares führen kontinuierliche Replikation durch und können bei Ausfall eines Active Shards innerhalb von 5 Sekunden übernehmen.

Vollständiger Code: `config/sharding/cluster.yaml` (~120 Zeilen mit allen Nodes)

```
sharding:
  cluster:
    active_shards: 4
    hot_spares: 2  # 2 Hot Spare Nodes für HA

  hot_spare:
    enabled: true
    promotion_timeout_ms: 5000  # Max 5s für Failover
    health_check_interval_ms: 1000
    failure_threshold: 3  # 3 Fehlversuche bis Promotion

  nodes:
    # Aktive Shards (Beispiel: Shard 1 & 2)
    - id: shard-1
      host: 10.0.1.10
      port: 8765
      role: active

    - id: shard-2
      host: 10.0.1.11
      port: 8765
      role: active

    # Hot Spares mit kontinuierlicher Replikation
    - id: hot-spare-1
      host: 10.0.1.20
      port: 8765
      role: hot_spare
      replicate_from: shard-1  # Sync von shard-1
```

Weitere Node-Definitionen im vollständigen Config: - Shard 3 & 4 (weitere aktive Nodes) - Hot Spare 2 (Backup für Shard 2) - Monitoring-Endpunkte für Health Checks - Replication-Lag-Alerts (>100ms Verzögerung)

Deployment-Szenarien:

1. Minimal HA Setup (4 Shards + 1 Hot Spare):

Active: [S1, S2, S3, S4]
 Spare: [HS1]
 Cost: 5 Nodes
 HA: Einzelner Ausfall abgedeckt

2. Standard HA Setup (4 Shards + 2 Hot Spares):

Active: [S1, S2, S3, S4]
 Spares: [HS1, HS2]
 Cost: 6 Nodes
 HA: Zwei gleichzeitige Ausfälle abgedeckt

3. Enterprise HA Setup (8 Shards + 3 Hot Spares):

Active: [S1, S2, S3, S4, S5, S6, S7, S8]
 Spares: [HS1, HS2, HS3]
 Cost: 11 Nodes
 HA: Drei gleichzeitige Ausfälle abgedeckt

Failover-Ablauf:

1. **Detektion (0-3s):** Health Check fails → Retry 3x (3s) → Declare failure
2. **Promotion (3-8s):** Select Hot Spare → Apply latest WAL → Update routing table → Promote to active
3. **Recovery (8s+):** Client requests → Hot Spare (now active) → Background: Sync data from other shards

Detaillierte Failover-Timeline:

Abb. 16.4: Hot-Spare-Failover-Timeline

Abb. 16.5: Failover-Sequenzdiagramm

Diagramm-Erklärung: - Gantt-Chart (oben): Zeigt die zeitliche Abfolge der Failover-Phasen - Detection: 0-3s (3 Health Checks à 1s) - Promotion: 3-5s (Spare auswählen, WAL anwenden, Routing aktualisieren) - Total: ~5s bis Traffic wieder fließt

- **Sequence-Diagram (unten):** Zeigt die Interaktion zwischen Komponenten
- Health Monitor erkennt Ausfall nach 3 Fehlversuchen
- Hot Spare wird automatisch promoted

- Routing-Tabelle wird aktualisiert
- Clients merken nichts vom Failover (transparent)

Performance-Charakteristiken:

Metric	Wert	Beschreibung
Failover Time (p50)	4.5s	Median Zeit bis Hot Spare aktiv
Failover Time (p99)	7.8s	99%-Perzentil Failover-Zeit
Data Loss	0 bytes	Bei WAL Replication aktiviert
Throughput Impact	<5%	Während Failover
Hot Spare Overhead	~2% CPU	Kontinuierliche Replikation

Monitoring:

```
// Hot Spare Status überwachen
FOR node IN _cluster_nodes
  FILTER node.role IN ['hot_spare', 'active']
  RETURN {
    id: node.id,
    role: node.role,
    status: node.status,
    last_heartbeat: node.last_heartbeat,
    replication_lag_ms: node.replication_lag_ms,
    failover_ready: node.failover_ready
  }
```

Prometheus Metriken:

```
themis_hot_spare_active{node="hot-spare-1"} 0
themis_hot_spare_replication_lag_seconds{node="hot-spare-1"} 0.045
themis_hot_spare_failover_count_total{node="hot-spare-1"} 0
themis_shard_health{shard="shard-1"} 1
```

Failover-Test:

```
# Simuliere Shard-Ausfall
docker stop themisdb-shard-2

# Überwache Failover
watch -n 0.5 'curl -s http://localhost:8765/cluster/status | jq .nodes'

# Erwartete Ausgabe nach ~5s:
# hot-spare-1: role=ACTIVE (promoted)
# shard-2: role=FAILED
```

Best Practices:

1. **1 Hot Spare pro 3-4 aktive Shards** - Balance zwischen Kosten und Verfügbarkeit
2. **Geografische Trennung** - Hot Spare in anderem Datacenter/Availability Zone
3. **Regelmäßige Failover-Tests** - Monatlich testen, ob Promotion funktioniert
4. **Monitoring kritisch** - Alerts bei hoher Replication Lag (>100ms)
5. **Hot Spare kontinuierlich synchronisieren** - Via WAL Replication (siehe unten)

16.10.2 WAL Replication

Neu in v1.4.0-alpha: Write-Ahead-Log basierte Replikation für Zero-Data-Loss und kontinuierliche Synchronisation.

Konzept:

WAL (Write-Ahead Log) Replication überträgt alle Schreiboperationen über ein transaktionales Log an Replicas und Hot Spares, bevor sie bestätigt werden.

Abb. 16.6: Elastic-Sharding-Workflow

Replikations-Modi:

1. Synchronous Replication:

```
replication:
  mode: synchronous
  quorum: 1 # Mindestens 1 Replica muss bestätigen
  timeout_ms: 100 # Timeout für Sync-Bestätigung
```

Vorteile: - Zero Data Loss garantiert - Replica immer auf aktuellem Stand

Nachteile: - ⚠ Höhere Write-Latenz (+50-100ms) - ⚠ Write blockiert bei Replica-Ausfall (ohne Degradation)

2. Asynchronous Replication:

```
replication:
  mode: asynchronous
  lag_target_ms: 50  # Ziel Replication Lag
  buffer_size_mb: 256  # WAL Buffer Size
```

Vorteile: - Minimale Write-Latenz - Primary nicht abhängig von Replica

Nachteile: - ⚠ Potentieller Data Loss bei Primary-Ausfall (Lag-abhängig) - ⚠ Replica kann hinterherhinken

3. Hybrid Mode (Empfohlen):

```
replication:
  mode: hybrid
  synchronous_shards: [shard-1, shard-2]  # Kritische Daten
  asynchronous_shards: [shard-3, shard-4]  # Unkritische Daten
  quorum: 1
```

Multi-SSD WAL Konfiguration:

Für maximale Performance: WAL auf separaten SSDs mit hohem Write-Throughput.

```
# config/storage/wal.yaml
wal:
  directories:
    # Primary WAL auf dediziertem NVMe
    - path: /mnt/nvme0/wal
      type: primary
      fsync_mode: always # Garantierte Durability

    # Backup WAL auf zweitem NVMe (optional)
    - path: /mnt/nvme1/wal-backup
      type: mirror
      fsync_mode: always

  # Performance-Tuning
  segment_size_mb: 64 # WAL Segment-Größe
  buffer_size_mb: 256 # In-Memory WAL Buffer
  compression: lz4 # WAL Kompression

  # Retention
  keep_segments: 100 # Anzahl Segments aufbewahren
  max_size_gb: 10 # Maximale WAL Größe
```

Replication Slots:

Verfolge Replikations-Fortschritt und verhindere vorzeitiges WAL-Purging.

```
// Replication Slot erstellen
CALL CREATE_REPLICATION_SLOT('hot-spare-1', {
  slot_type: 'physical',
  temporary: false
})

// Slot-Status abfragen
FOR slot IN _replication_slots
  RETURN {
    slot_name: slot.name,
    slot_type: slot.type,
    active: slot.active,
    restart_lsn: slot.restart_lsn,
    confirmed_flush_lsn: slot.confirmed_flush_lsn,
    wal_lag_bytes: slot.wal_lag_bytes,
    lag_seconds: slot.lag_seconds
  }
```

Replication Lag Monitoring:

```
// Echtzeit Replication Lag
RETURN WAL_REPLICATION_STATS()
```

Output:

```
{
  "primary": {
    "current_lsn": "0/5A2F3C40",
    "insert_lsn": "0/5A2F3C40",
    "flush_lsn": "0/5A2F3C40"
  },
  "replicas": [
    {
      "name": "hot-spare-1",
      "state": "streaming",
      "sent_lsn": "0/5A2F3C30",
      "flush_lsn": "0/5A2F3C30",
      "replay_lsn": "0/5A2F3C30",
      "lag_bytes": 16,
      "lag_seconds": 0.002,
      "sync_state": "async"
    },
    {
      "name": "hot-spare-2",
      "state": "streaming",
      "sent_lsn": "0/5A2F3C40",
      "flush_lsn": "0/5A2F3C40",
      "replay_lsn": "0/5A2F3C40",
      "lag_bytes": 0,
      "lag_seconds": 0.000,
      "sync_state": "sync"
    }
  ]
}
```

Prometheus Metriken:

```
themis_wal_replication_lag_seconds{replica="hot-spare-1"} 0.002
themis_wal_replication_lag_bytes{replica="hot-spare-1"} 16
themis_wal_segments_total 156
themis_wal_size_bytes 4294967296
themis_wal_sync_operations_total 125840
themis_wal_sync_duration_seconds_sum 45.2
```

Recovery-Szenarien:

Szenario 1: Hot Spare Promotion

```
# Primary fällt aus
Primary: FAILED

# Hot Spare wird promoted (automatisch)
Hot Spare: STANDBY → RECOVERY → ACTIVE

# Steps:
1. Apply remaining WAL entries (0-2s)
2. Update routing table (1-2s)
3. Accept new writes (2-3s)
Total: ~5s
```

Szenario 2: Point-in-Time Recovery (PITR)

```
// Restore auf bestimmten Zeitpunkt
CALL RESTORE_FROM_WAL({
  target_time: '2026-01-06T12:00:00Z',
  wal_archive_path: '/backup/wal-archive',
  recovery_mode: 'pause' // Pause nach Recovery für Validation
})
```

Szenario 3: Failed Replica Resync


```
# Replica ist zu weit zurück (>max_wal_size)
# Benötigt Base Backup + WAL Replay

# 1. Base Backup erstellen
pg_basebackup -D /data/hot-spare-1 -Fp -Xs -P

# 2. WAL Replay starten
# Automatisch, sobald Replica neu startet

# 3. Catch-up Phase
# Replica replayed ~2GB WAL in ~30s
# Streaming replication continues
```

Performance-Impact:

Mode	Write Latency	Throughput	Data Loss Risk
Keine Replikation	1.2ms	100%	High
Async Replication	1.3ms (+8%)	98%	Low (Lag-dependent)
Sync Replication (1 Replica)	2.5ms (+108%)	85%	None
Sync Replication (2 Replicas)	3.8ms (+217%)	70%	None

Best Practices:

1. **Hybrid Mode für Production** - Sync für kritische, Async für unkritische Daten
2. **Monitoring essentiell** - Alert bei Lag >100ms
3. **Dedizierte SSDs für WAL** - Mindestens 1 IOPS pro Write
4. **Replication Slots verwenden** - Verhindert WAL-Deletion bei Replica-Ausfall
5. **Regelmäßige PITR-Tests** - Monatlich Recovery testen
6. **WAL Archivierung aktivieren** - Für Long-Term Backups

Zusammenspiel Hot Spare + WAL Replication:

```
# Optimale Konfiguration für HA
sharding:
  cluster:
    active_shards: 4
    hot_spares: 2

  replication:
    mode: hybrid
    hot_spares_sync: true # Hot Spares immer synchron
    quorum: 1

  wal:
    segment_size_mb: 64
    keep_segments: 200 # ~12GB für 1h Lag-Toleranz
    compression: lz4
    fsync: true
```

Ergebnis: - Failover in <5s - Zero Data Loss - <10% Write-Latenz Overhead - Vollautomatische Recovery

16.11 Troubleshooting

Problem: Ungleiche Shard-Verteilung

Symptom:

```
Shard 1: 35% (x zu voll)
Shard 2: 18%
Shard 3: 22%
Shard 4: 25%
```

Ursache: Hotkey (z.B. ein sehr aktiver User)

Lösung:

```
# Manuelles Rebalancing triggern
themis-cli cluster rebalance --force

# Hotkey identifizieren
themis-cli shard analyze --shard 1 --top-keys 10

# Ausgabe:
# Key: user_123456, Size: 2.3 GB (× Hotkey!)
# → Lösung: Hotkey auf separaten "Large Object Shard" verschieben
```

Problem: Hohe Cross-Shard Query Latenz

Symptom: p99 >10× Single-Node bei >20% Cross-Shard Rate

Lösung: 1. Co-Location aktivieren:

```
sharding:
  strategy: hash
  co_location:
    enabled: true
  rules:
    - tables: [orders, customers]
      key: customer_id # Beide Tabellen nach customer_id routen
```

1. Denormalisierung:

```
# Embed häufig gejointe Daten
order = {
  "id": "order_123",
  "customer_id": "user_456",
  "customer_name": "Alice", # Denormalisiert!
  "customer_email": "alice@example.com" # Denormalisiert!
}
```

Problem: Rebalance dauert zu lange

Symptom: Rebalance >15 Minuten, >20% Throughput-Dip

Lösung:

```
# config/sharding/shard-router.yaml
rebalance:
  chunk_size_mb: 32          # Kleinere Chunks (default: 64)
  max_parallel_moves: 4      # Mehr parallele Transfers (default: 2)
  rate_limit_mbps: 500       # Höheres Network-Limit
```

16.12 Zusammenfassung

ThemisDB Sharding bietet: - **Production-Ready:** 91% Scaling Efficiency bis 8 Nodes - **Auto-Rebalancing:** <15% Dip, <5min Recovery - **Fault Tolerant:** <60s Recovery bei Replica-Failure - **Cost-Efficient:** 67-92% günstiger als Hyperscaler - **Native Multi-Model:** Sharding funktioniert über alle Datenmodelle

Nächste Schritte: - Kapitel 19: Monitoring für detailliertes Observability-Setup - Kapitel 21:

Performance-Tuning für Sharding-spezifische Optimierungen - [docs/de/](#)

[SHARDING_DOCUMENTATION_INDEX.md](#) : Vollständige technische Dokumentation

Production-Deployment? Starten Sie mit einem 2-Node Cluster und skalieren Sie bei Bedarf auf 4 oder 8 Nodes!

Weiterführende Ressourcen

Dokumentation: - [docs/de/SHARDING_INTEGRATION_SUMMARY.md](#) - Master-Übersicht - [docs/de/](#)

[SHARDING_BENCHMARK_PLAN_v1.4.md](#) - Enterprise Benchmark-Spezifikation - [docs/de/](#)

[SHARDING_PRODUCTION_DEPLOYMENT_RAID_v1.4.md](#) - Production Deployment Guide

Tools: - [tools/shard_loader.py](#) - Daten-Loader für Sharding-Tests - [tools/shard_bench.py](#) - Benchmark-Runner - [tools/fault_injector.py](#) - Chaos-Engineering-Tool

Konfiguration: - [config/sharding/shard-router-example.yaml](#) - Production-Ready Config - [.github/workflows/sharding-benchmark.yml](#) - CI/CD Benchmarks

Teil V - AI & ML Integration

Kapitel 17: Kapitel 17 - LLM Integration

Überblick

ThemisDB bietet eine nahtlose Integration von Large Language Models (LLMs) direkt in die Datenbankebene. Diese Integration ermöglicht es, LLM-Funktionalitäten wie Text-Generierung, Embedding-Erstellung, semantische Suche und RAG (Retrieval Augmented Generation) Patterns direkt in AQL-Queries zu verwenden.

Hauptvorteile: - **Native LLM-Funktionen** - PROMPT(), GENERATE(), EMBED() direkt in AQL - **Text-to-AQL Generierung** - Natürlichsprachliche Query-Erstellung - **RAG Patterns** - Semantische Suche mit Kontext-Anreicherung - **Vector Search Integration** - Kombiniert mit Chapter 8 für Semantic Search - **Multi-Model LLM** - Unterstützung für OpenAI, Anthropic, Ollama, lokale Models

Abb. 17.1: LLM-Integration-Architektur

17.1 LLM-Funktionen in AQL

17.1.1 PROMPT() - Text-Generierung

Die `PROMPT()`-Funktion sendet Anfragen an konfigurierte LLM-Provider:

```
// Einfache Text-Generierung
FOR doc IN articles
  FILTER doc.category == 'technology'
  LIMIT 5
  RETURN {
    title: doc.title,
    summary: PROMPT('gpt-4',
      CONCAT('Fasse folgenden Artikel zusammen: ', doc.content),
      {max_tokens: 150, temperature: 0.7}
    )
  }
```

Erweiterte Optionen:

```
// Mit System-Prompt und Strukturierung
FOR product IN products
  FILTER product.reviews_count > 100
  RETURN {
    product_name: product.name,
    analysis: PROMPT('gpt-4',
      {
        system: 'Du bist ein Produkt-Analyst. Analysiere Kundenrezensionen.',
        user: CONCAT('Produkt: ', product.name, '\n\nBewertungen:\n',
          product.reviews_text),
        response_format: 'json'
      },
      {
        temperature: 0.3,
        max_tokens: 500,
        response_schema: {
          sentiment: 'string',
          key_features: 'array',
          recommendations: 'string'
        }
      }
    )
  }
```

17.1.2 EMBED() - Embedding-Generierung

Erstellt Vektor-Embeddings für Text:

```
// Dokument mit Embedding speichern
INSERT {
  title: 'Einführung in ThemisDB',
  content: 'ThemisDB ist eine Multi-Model-Datenbank...',
  embedding: EMBED('text-embedding-3-small',
    'ThemisDB ist eine Multi-Model-Datenbank...')
} INTO documents

// Batch-Embedding für Performance
FOR doc IN documents
  FILTER doc.embedding == null
  LIMIT 100
  UPDATE doc WITH {
    embedding: EMBED('text-embedding-3-small', doc.content),
    embedded_at: DATE_NOW()
  } IN documents
```

17.1.3 GENERATE() - Strukturierte Generierung

Generiert strukturierte Daten basierend auf Schema:


```
// Strukturierte Produkt-Kategorisierung
FOR product IN products
  FILTER product.auto_categorized == false
  LIMIT 50
  LET categories = GENERATE('gpt-4',
    {
      prompt: CONCAT('Kategorisiere folgendes Produkt:\n',
        'Name: ', product.name, '\n',
        'Beschreibung: ', product.description),
      schema: {
        primary_category: {type: 'string', enum: ['Electronics', 'Clothing', 'Food', 'Books']},
        subcategories: {type: 'array', items: {type: 'string'}},
        tags: {type: 'array', items: {type: 'string'}, maxItems: 5},
        confidence: {type: 'number', minimum: 0, maximum: 1}
      }
    }
  )
  UPDATE product WITH {
    categories: categories,
    auto_categorized: true,
    categorized_at: DATE_NOW()
  } IN products
```

17.2 Text-to-AQL Generierung

17.2.1 Natural Language Query Interface

ThemisDB kann natürlichsprachliche Anfragen in AQL übersetzen:

```
// Text-to-AQL Helper Function
LET user_question = 'Zeige mir die 10 teuersten Produkte aus der Elektronik-Kategorie'

LET generated_query = PROMPT('gpt-4',
{
  system: `Du bist ein AQL-Experte. Konvertiere Benutzeranfragen in gültige AQL-Queries.

  Schema:
  - products (name, price, category, stock)
  - orders (order_id, customer_id, product_id, quantity, order_date)
  - customers (customer_id, name, email, country)

  Gebe nur die AQL-Query zurück, keine Erklärungen.` ,
  user: user_question
},
{temperature: 0.1}
)

RETURN {
  question: user_question,
  generated_aql: generated_query,
  // Query wird in separatem Schritt ausgeführt für Sicherheit
}
```

17.2.2 Query-Validierung und -Ausführung

Sicherheitsvalidierung:

```
// Query-Validierung vor Ausführung
LET user_input = @user_question

LET llm_response = PROMPT('gpt-4',
{
  system: `Generiere sichere AQL-Queries. Verwende immer @parameter für Benutzereingaben.
  Keine destructive Operationen (DELETE, DROP, etc.) ohne explizite Bestätigung.` ,
  user: user_input
})

// Validiere Query
LET is_safe = (
  llm_response.query NOT LIKE '%DELETE%' AND
  llm_response.query NOT LIKE '%DROP%' AND
  llm_response.query NOT LIKE '%REMOVE%' AND
  llm_response.includes_parameters == true
)

RETURN is_safe ? llm_response : {error: 'Unsafe query detected'}
```

17.3 RAG (Retrieval Augmented Generation)

17.3.1 Semantische Suche mit Kontext

Kombiniert Vector Search mit LLM-Generierung:

```

// RAG Pattern: Suche + Generierung
LET user_query = 'Wie funktioniert MVCC in ThemisDB?'

// Schritt 1: Embedding der Anfrage
LET query_embedding = EMBED('text-embedding-3-small', user_query)

// Schritt 2: Semantische Suche
LET relevant_docs = (
  FOR doc IN documentation
    LET similarity = COSINE_SIMILARITY(doc.embedding, query_embedding)
    FILTER similarity > 0.7
    SORT similarity DESC
    LIMIT 5
    RETURN {
      content: doc.content,
      title: doc.title,
      similarity: similarity
    }
)

// Schritt 3: Kontext zusammenführen
LET context = (
  FOR doc IN relevant_docs
    RETURN CONCAT('## ', doc.title, '\n\n', doc.content)
)

// Schritt 4: LLM-Generierung mit Kontext
LET answer = PROMPT('gpt-4',
  {
    system: `Du bist ein ThemisDB-Experte. Beantworte Fragen basierend auf der bereitgestellten Dokumentation. Zitiere relevante Abschnitte wenn möglich.`,
    user: CONCAT(
      'Dokumentation:\n\n',
      CONCAT_SEPARATOR('\n\n---\n\n', context),
      '\n\n---\n\n',
      'Frage: ', user_query
    )
  }
),

```

```
{temperature: 0.3, max_tokens: 1000}
)

RETURN {
  question: user_query,
  answer: answer,
  sources: relevant_docs[*].title,
  source_count: LENGTH(relevant_docs)
}
```

Abb. 17.2: RAG-Pipeline-Flow

17.3.2 Erweiterte RAG mit Re-Ranking

Modernes RAG kombiniert mehrere Retrieval-Strategien für höhere Präzision: Keyword-Search (BM25) findet exakte Begriffe, Vector-Search erfasst semantische Ähnlichkeit, und LLM-Re-Ranking filtert die relevantesten Ergebnisse.

Die Pipeline arbeitet in drei Stufen: (1) Paralleles Retrieval mit BM25 und Vektor-Suche, (2) LLM-basiertes Re-Ranking der kombinierten Ergebnisse, (3) Finale Antwort-Generierung mit Top-K Dokumenten als Kontext.

Vollständiger Code: `examples/17_llm_rag/hybrid_search.aql` (~100 Zeilen)

```

// Hybrid Search: BM25 + Vector + LLM Re-Ranking
LET user_query = 'Beste Performance-Optimierungen für Graphen-Queries'

// Stage 1: Keyword Search (BM25 - exakte Begriffe)
LET bm25_results = (
  FOR doc IN documentation
    SEARCH ANALYZER(doc.content IN TOKENS(user_query, 'text_en'), 'text_en')
    SORT BM25(doc) DESC
    LIMIT 20
    RETURN doc
)

// Stage 2: Vector Search (semantische Ähnlichkeit)
LET query_embedding = EMBED('text-embedding-3-small', user_query)
LET vector_results = (
  FOR doc IN documentation
    LET similarity = COSINE_SIMILARITY(doc.embedding, query_embedding)
    FILTER similarity > 0.6
    SORT similarity DESC
    LIMIT 20
    RETURN doc
)

// Stage 3: Combine + LLM Re-Ranking (relevanteste Docs identifizieren)
LET combined = UNION_DISTINCT(bm25_results, vector_results)
LET reranked = (
  FOR doc IN combined
    LET relevance_score = PROMPT('gpt-4',
      {system: 'Rate Relevanz 0.0-1.0. Nur Zahl zurückgeben.',
       user: CONCAT('Query: ', user_query, '\n\nDok: ', SUBSTRING(doc.content, 0, 500))},
      {temperature: 0.0, max_tokens: 5}
    )
    RETURN {doc: doc, score: TO_NUMBER(relevance_score)}
)

LET top_docs = (FOR item IN reranked SORT item.score DESC LIMIT 5 RETURN item.doc)

// Generate Answer mit Top-K Kontext

```

```
LET answer = PROMPT('gpt-4',
  {system: 'Erstelle Antwort basierend auf Dokumenten.',
   user: CONCAT('Docs:\n', (FOR d IN top_docs RETURN CONCAT('---\n', d.content)), '\n\nFrage: ',
   {temperature: 0.3, max_tokens: 1500}
)

RETURN {query: user_query, answer: answer, sources: top_docs[*].title}
```

Vorteile des Hybrid-Ansatzes: - **Recall:** BM25 fängt exakte Begriffe, Vektor-Suche semantische Varianten - **Precision:** LLM-Re-Ranking eliminiert false positives - **Latenz:** Paralleles Retrieval + effiziente Filterung - **Qualität:** Contextual Grounding durch Top-K Dokumente

17.3.3 Architektur-Vergleich: ThemisDB vs. Hyperscaler für RAG

Ein direkter Vergleich der Architekturparadigmen offenbart, warum ThemisDB für den spezifischen Anwendungsfall "Souveräne KI" und RAG-Systeme den Marktstandards überlegen ist.

Architektonische Paradigmen im Vergleich:

Merkmal	AWS (Polyglot Persistence)	Azure Cosmos DB (Managed MMDBMS)	ThemisDB (Native MMDBMS)
Architektur-Prinzip	Föderiert: Lose Kopplung spezialisierter Dienste (RDS + Neptune + OpenSearch)	Abstrahiert: Einheitlicher Kern (ARS), aber Zugriff über siloartige APIs (SQL, Gremlin, Mongo)	Integriert: Einheitlicher Kern ("Base Entity") mit direkten C++-Projektionen
Konsistenz	Eventual (BASE): Konsistenz muss durch Anwendungslogik (Saga-Pattern/Lambda) erzwungen werden. Fehleranfällig.	Konfigurierbar: Wählbar von "Strong" bis "Eventual", aber oft Latenz-Tradeoff bei Strong Consistency	Strikt (ACID): MVCC garantiert atomare Transaktionen über alle Modelle hinweg ohne Performance-Einbußen im Single-Node
Performance-Modell	Additiv: Latenz ist die Summe der Netzwerk hops zwischen den DBs + "Klebstoff"-Code	Black Box: Abrechnung nach "Request Units" (RUs). Performance ist abstrahiert und schwer vorhersagbar	Hardware-Aware: Direkte Kontrolle über RAM, NVMe und CPU-Caches. Vorhersagbare "Bare-Metal"-Leistung
RAG-Eignung	Niedrig (Post-Filtering): Daten müssen aus verschiedenen DBs geholt und in der App gefiltert werden	Mittel: Integrierte Vektorsuche, aber oft Einschränkungen bei komplexen Graph-Joins	Hoch (Pre-Filtering): Relationale Indizes beschneiden den Suchraum <i>bevor</i> die Vektorsuche startet
Revisionssicherheit	Problematisch: Zeitgleiche Schnappschüsse über 3 DBs hinweg sind fast unmöglich	Gut: Change Feed vorhanden, aber volle Historisierung (Time Travel) ist komplex	Exzellent: Temporale Graphen (bfsAtTime) erlauben Abfragen zu exakten historischen Zeitpunkten
Daten-Souveränität	Niedrig: Cloud-Vendor-Lock-in, Daten in US-Jurisdiktion	Mittel: European Sovereign Cloud angekündigt, aber proprietär	Hoch: Open Source MIT, vollständige Kontrolle, On-Premise
Operationale Komplexität	Hoch: Management von 3+ separaten Diensten, Orchestrierung nötig	Mittel: Managed Service vereinfacht Betrieb, aber abstrakte APIs	Niedrig: Single-Binary Deployment, direkte Kontrolle

Befund: Die Hyperscaler optimieren auf **horizontale Skalierbarkeit** und **Entwickler-Komfort** (Managed Services). ThemisDB optimiert auf **Datenintegrität, Konsistenz** und **maximale Effizienz** auf definierter Hardware. Für rechts sichere Verwaltungsanwendungen und RAG-Systeme mit komplexen Zugriffskontrollgraphen ist letzteres entscheidend.

Warum ist Konsistenz für RAG kritisch?

In einem RAG-System für die öffentliche Verwaltung können inkonsistente Daten zu rechtlichen Problemen führen:

Beispiel-Szenario: BImSchG-Gutachten-RAG

Fehlerfall in Polyglot-System (BASE):

1. Gutachten wird im Relational-Store als "valid" markiert
2. Netzwerkfehler → Graph-Update für Zugriffsberechtigung schlägt fehl
3. Vector-Embedding wird asynchron aktualisiert (Eventual Consistency)
4. RAG-Abfrage findet Gutachten in Vektorsuche
5. Graph-Check schlägt fehl → Gutachten sollte nicht zugreifbar sein
6. Aber: Relational-Metadaten zeigen "valid"
7. → Inkonsistenter Zustand: Verschiedene Systeme widersprechen sich

ThemisDB mit ACID:

1. ALLE Updates (Relational + Graph + Vector) sind EINE Transaktion
2. Entweder ALLES committed oder NICHTS
3. Keine temporäre Inkonsistenz möglich
4. RAG-Abfrage sieht garantiert konsistenten Zustand

17.3.4 ThemisDB's Pre-Filtering-Vorteil für RAG

Das Post-Filtering-Problem in Polyglot-Systemen:

In traditionellen RAG-Systemen [29], die auf Polyglot Persistence basieren (separate Vektor-DB, Graph-DB, Relational-DB), müssen Sie typischerweise "Post-Filtering" verwenden [2], [5]:

```
# Traditioneller Ansatz (ineffizient):  
# 1. Vektor-DB: Hole 1000 ähnliche Dokumente  
vector_results = vector_db.search(query_embedding, k=1000)  
  
# 2. Graph-DB: Hole erlaubte Dokumente basierend auf Graph-Kontext  
allowed_docs = graph_db.query("MATCH (user)-[:CAN_ACCESS]->(doc)")  
  
# 3. Relational-DB: Hole Metadaten-Filter (z.B. Jahr=2024)  
filtered_docs = relational_db.query("SELECT id WHERE year=2024")  
  
# 4. Manuelle Schnittmengenbildung im Application-Code  
final_results = intersect(vector_results, allowed_docs, filtered_docs)  
# → Problem: 990 von 1000 Ergebnissen werden verworfen!
```

Warum ist das ineffizient? - Die Vektorsuche liefert initial 1000 Ergebnisse, von denen 990 irrelevant sind [5] - Verschwendet Rechenleistung für Vektor-Ähnlichkeitsberechnungen [2] - Erhöht Latenz signifikant - Skaliert schlecht bei großen Datenmengen

ThemisDB's Pre-Filtering-Architektur:

Dank der nativen Multi-Model-Architektur [3], [11] (siehe Kapitel 3.2) kann ThemisDB die Query-Ausführung umkehren [2]:

```
-- Pre-Filtering in ThemisDB (hochperformant):
FOR doc IN documents
  -- Phase 1: ZUERST relationale Filter (schneller Index-Zugriff)
  FILTER doc.year == 2024
  FILTER doc.department == "IT"
  FILTER doc.confidentiality <= @user_clearance_level

  -- Phase 2: Graph-Kontext-Filter
  FILTER doc._id IN (
    FOR v, e IN 1..2 OUTBOUND @user_id access_rights
      RETURN v._id
  )

  -- Phase 3: Vektorsuche NUR auf erlaubter Teilmenge
  LET similarity = COSINE_SIMILARITY(doc.embedding, @query_embedding)
  FILTER similarity > 0.7

  SORT similarity DESC
  LIMIT 10
  RETURN doc
```

Wie funktioniert Pre-Filtering intern?

1. Phase 1 (Relationaler Filter):

- Query-Engine nutzt schnelle Sekundärindizes (z.B. Index für `year=2024`) [2], [3]
- Erstellt eine hochselektive Kandidatenliste (z.B. ein Bitset mit 50 erlaubten IDs)

4. Phase 2 (Graph-Filter):

- Graph-Traversierung [22] auf dieser reduzierten Menge
- Weitere Einschränkung basierend auf Zugriffsrechten

7. Phase 3 (Vektorsuche):

- Die rechenintensive HNSW-Vektorsuche [25] läuft NUR auf den 50 erlaubten Dokumenten
- Statt 1000 Vektor-Vergleiche nur 50 notwendig [2]

Performance-Vergleich:

Ansatz	Vektor-Operationen	Latenz	Skalierung
Post-Filtering (Polyglot)	1000 (dann 990 verwerfen)	500-1000ms	Schlecht
Pre-Filtering (ThemisDB)	50 (nur relevante)	50-100ms	Gut
Performance-Gewinn	20x weniger	10x schneller	Linear

Praktisches Beispiel - Verwaltungs-RAG:

```
-- Finde relevante BImSchG-Gutachten für Bürgeranfrage
LET user_query = "Lärmschutz Windkraftanlage Havelland"
LET query_embedding = EMBED('text-embedding-3-small', user_query)

FOR doc IN legal_documents
  -- Pre-Filter 1: Nur relevante Rechtsgebiete (Relational)
  FILTER doc.legal_area == "BImSchG"
  FILTER doc.topic IN ["Lärmschutz", "Windenergie"]

  -- Pre-Filter 2: Nur Dokumente für Region (Graph)
  FILTER doc.region IN (
    FOR r IN regions
      FILTER r.name == "Havelland" OR r.parent_region == "Havelland"
      RETURN r._id
  )

  -- Pre-Filter 3: Nur aktuelle, gültige Gutachten (Relational)
  FILTER doc.status == "valid"
  FILTER doc.valid_until > DATE_NOW()

  -- ERST JETZT: Vektorsuche auf stark reduzierter Menge
  LET similarity = COSINE_SIMILARITY(doc.embedding, query_embedding)
  FILTER similarity > 0.75

  SORT similarity DESC
  LIMIT 5

  RETURN {
    title: doc.title,
    similarity: similarity,
    metadata: {
      case_number: doc.case_number,
      date: doc.issue_date,
      region: doc.region
    },
    excerpt: SUBSTRING(doc.content, 0, 300)
  }
```

Architektonischer Vorteil:

Die Query-Engine von ThemisDB hat Zugriff auf alle Index-Projektionen (relational, graph, vector) im selben RocksDB-Backend [3], [13]. Sie kann einen kostenbasierten Optimizer verwenden, um den effizientesten Ausführungsplan zu wählen: - Welcher Filter ist am selektivsten? - In welcher Reihenfolge sollten Filter angewendet werden? - Wann lohnt sich der Übergang von Index-Scan zu Vektor-Suche?

Dies ist in Polyglot-Systemen [33] unmöglich, da jede Datenbank isoliert operiert.

17.3.4 Hybrid Search Implementation: Unter der Haube

Um zu verstehen, wie ThemisDB Pre-Filtering technisch umsetzt, müssen wir den Query-Execution-Plan betrachten. Lassen Sie uns eine typische RAG-Query Schritt-für-Schritt durchgehen.

Die Beispiel-Query:

```
FOR doc IN legal_documents
  FILTER doc.law_area == "BImSchG"           -- Relational Filter
  FILTER doc.region IN ["Havelland", "Potsdam"] -- Relational Filter
  FILTER doc._id IN (                        -- Graph Filter
    FOR v IN 1..2 OUTBOUND "users/alice" access_graph
      RETURN v._id
  )
  LET similarity = COSINE(doc.embedding, @query_vec) -- Vector Similarity
  FILTER similarity > 0.7
  SORT similarity DESC
  LIMIT 5
  RETURN {doc: doc, score: similarity}
```

Wie führt ThemisDB diese Query aus?

Schritt 1: Query Parsing und AST-Erstellung

Der AQL-Parser erstellt einen Abstract Syntax Tree (AST):

```

FOR doc IN legal_documents
  └ FILTER (doc.law_area == "BImSchG")
  └ FILTER (doc.region IN ["Havelland", "Potsdam"])
  └ FILTER (doc._id IN [subquery...])
  └ LET similarity = COSINE(...)
  └ FILTER (similarity > 0.7)
  └ SORT similarity DESC
  └ LIMIT 5
  └ RETURN {...}

```

Schritt 2: Query Optimizer - Kostenbasierte Umordnung

Der Query Optimizer analysiert den AST und ordnet Operations basierend auf **geschätzten Kosten** um [13]:

```

// Pseudo-Code des Optimizers
OptimizerPass::reorderFilters(ASTNode* node) {
    // Kostenmodell für verschiedene Filter-Typen
    map<FilterType, double> cost_estimates = {
        {INDEX_SCAN, 0.1},           // Sehr billig (O(log n))
        {GRAPH_TRAVERSAL, 10.0},     // Mittel (O(edges))
        {VECTOR_SIMILARITY, 100.0}   // Teuer (O(dimensions))
    };

    // Sortiere Filter nach aufsteigenden Kosten
    sort(node->filters, [&](Filter a, Filter b) {
        return cost_estimates[a.type] < cost_estimates[b.type];
    });

    // Ergebnis: Index-Scans zuerst, dann Graph, dann Vektor
}

```

Optimierte Ausführungsreihenfolge:

1. INDEX_SCAN (law_area == "BImSchG")	→ Kandidaten: 50.000
2. INDEX_SCAN (region IN ["Havelland"...])	→ Kandidaten: 12.000
3. GRAPH_TRAVERSAL (access_rights subquery)	→ Kandidaten: 1.500
4. VECTOR_SIMILARITY (COSINE > 0.7)	→ Kandidaten: 150
5. SORT (similarity DESC)	→ Kandidaten: 150
6. LIMIT 5	→ Kandidaten: 5

Warum ist diese Reihenfolge optimal?

Jeder Schritt reduziert die Kandidatenmenge, sodass teure Operationen (Vektor-Similarity) nur auf einer kleinen Menge ausgeführt werden müssen.

Schritt 3: Index-Scan mit Bitset-Konstruktion

ThemisDB verwendet **Bitsets** für effiziente Kandidatenverwaltung:

```
// Simplified C++ Implementation
std::vector<bool> candidates(total_docs, false); // Bitset für alle Docs

// Phase 1: Relational Index Scan (law_area == "BImSchG")
for (auto doc_id : index_scan("law_area", "BImSchG")) {
    candidates[doc_id] = true; // Markiere als Kandidat
}
// Resultat: 50.000 bits set

// Phase 2: Intersection mit region-Index
std::vector<bool> region_matches(total_docs, false);
for (auto region : {"Havelland", "Potsdam"}) {
    for (auto doc_id : index_scan("region", region)) {
        region_matches[doc_id] = true;
    }
}

// Bitwise AND für Intersection (sehr schnell!)
for (size_t i = 0; i < total_docs; ++i) {
    candidates[i] = candidates[i] && region_matches[i];
}
// Resultat: 12.000 bits set
```


Warum Bitsets?

- **Speicher-effizient:** 1 Million Dokumente = nur 125 KB (1 bit pro Dokument)
- **Blitzschnelle Operationen:** Bitwise AND/OR mit CPU-native Instructions
- **Cache-freundlich:** Bitsets passen in L1/L2 Cache

Schritt 4: Graph-Traversal auf reduzierter Menge

Jetzt wird die Graph-Subquery ausgeführt, aber nur für die 12.000 Kandidaten:

```
// Graph Subquery: Welche Dokumente darf "alice" sehen?
std::unordered_set<std::string> accessible_docs;

// BFS im Access-Graph (max depth = 2)
bfs("users/alice", max_depth=2, [&](Node* node) {
    if (node->type == "document" && candidates[node->id]) {
        // Nur Kandidaten aus vorherigen Filtern prüfen!
        accessible_docs.insert(node->id);
    }
});

// Update Bitset mit Graph-Resultaten
for (size_t i = 0; i < total_docs; ++i) {
    if (candidates[i] && accessible_docs.count(doc_ids[i]) == 0) {
        candidates[i] = false; // Kein Zugriff → entfernen
    }
}

// Resultat: 1.500 bits set
```

Key Insight: Die Graph-Traversal muss nur 12.000 Dokumente prüfen, nicht 1 Million!

Schritt 5: Vektor-Similarity nur auf finale Kandidaten

Jetzt kommt die teuerste Operation – aber nur für 1.500 Dokumente:

```

// Vektor-Similarity-Berechnung
std::vector<std::pair<doc_id, double>> scored_docs;

for (size_t i = 0; i < total_docs; ++i) {
    if (!candidates[i]) continue; // Überspringen wenn nicht Kandidat

    // COSINE-Similarity (rechenintensiv!)
    double similarity = cosine_similarity(
        docs[i].embedding,    // 1536 Dimensionen
        query_embedding       // 1536 Dimensionen
    );

    if (similarity > 0.7) {
        scored_docs.push_back({i, similarity});
    }
}

// Sortieren nach Similarity
std::sort(scored_docs.begin(), scored_docs.end(),
    [](auto& a, auto& b) { return a.second > b.second; }
);

// Top 5 zurückgeben
return scored_docs | std::views::take(5);

```

Performance-Vergleich:

```

Post-Filtering (Polyglot):
    1.000.000 Vektor-Ops × 100µs = 100.000ms (100 Sekunden!)

Pre-Filtering (ThemisDB):
    1.500 Vektor-Ops × 100µs = 150ms (0.15 Sekunden)

→ 666x schneller!

```

Schritt 6: Score-Fusion (optional, für Hybrid Search)

Wenn Sie BM25 (Keyword-Suche) + Vektor-Similarity kombinieren möchten, verwendet ThemisDB

Reciprocal Rank Fusion (RRF) [22]:

```
// RRF-Formel: Kombiniert Rankings aus mehreren Quellen
double compute_rrf_score(doc_id, rank_bm25, rank_vector, k = 60) {
    double rrf = 0.0;

    // BM25-Beitrag
    if (rank_bm25 > 0) {
        rrf += 1.0 / (k + rank_bm25);
    }

    // Vektor-Beitrag
    if (rank_vector > 0) {
        rrf += 1.0 / (k + rank_vector);
    }

    return rrf;
}

// Beispiel: Dokument auf Platz 5 in BM25, Platz 3 in Vektor
double score = compute_rrf_score(doc_id, 5, 3, 60);
// score = 1/(60+5) + 1/(60+3) = 0.0154 + 0.0159 = 0.0313
```

Warum RRF statt gewichteter Durchschnitt?

- **Skalierungsinvariant:** BM25-Scores und Cosine-Similarity haben unterschiedliche Skalen
- **Robust:** Funktioniert gut auch wenn ein Signal schwach ist
- **Einfach:** Keine Hyperparameter-Tuning nötig

Visualisierung des gesamten Query-Execution-Plans:

1. Collection Scan: legal_documents (1M docs)



2. Index Scan: law_area == "BImSchG"

→ Bitset with 50K bits set

Latenz: ~1ms (Index-Lookup)



3. Index Scan: region IN ["Havelland", "Potsdam"]

→ Bitset AND: 50K → 12K bits set

Latenz: ~1ms



4. Graph Traversal (BFS depth=2) auf 12K Kandidaten

→ Bitset AND: 12K → 1.5K bits set

Latenz: ~50ms (Graph-Scan)



5. Vector Similarity (COSINE) auf 1.5K Kandidaten

→ $1.500 \times 100\mu\text{s} = 150\text{ms}$

→ Filter: similarity > 0.7 → 150 docs



6. Sort by similarity DESC

→ 150 docs sortiert

Latenz: <1ms

7. Limit 5
→ Top 5 Results

Gesamt-Latenz: 1ms + 1ms + 50ms + 150ms + 1ms = ~203ms

Vergleich: Post-Filtering in Polyglot-Systemen:

1. Vector DB: Get top 1000 similar docs
→ $1.000.000 \times 100\mu s = 100.000ms$ (!!)

2. Graph DB: Get accessible docs for user (separate query)
→ Network latency + query time: ~500ms

3. Relational DB: Get metadata filters (separate query)
→ Network latency + query time: ~200ms

4. Application Code: Intersection of 3 result sets
→ 1000 docs in-memory filtering: ~10ms
→ Discard 990 irrelevant docs

Gesamt-Latenz: 100.000ms + 500ms + 200ms + 10ms = ~100.710ms

Fazit: ThemisDB ist ~500x schneller für diese RAG-Query!

17.4 Prompt Engineering Best Practices

17.4.1 Chain-of-Thought Prompting

Chain-of-Thought (CoT) verbessert LLM-Reasoning durch schrittweise Analyse. Statt direkter Antworten führt das LLM explizite Zwischenschritte aus, was zu präziseren Ergebnissen führt – besonders bei komplexen Aufgaben wie Churn-Prediction.

Die Query sammelt zunächst relevante Kundendaten (Bestellungen, Support-Tickets, Umsatz), erstellt dann einen strukturierten Kontext und lässt das LLM schrittweise analysieren. Das Ergebnis wird direkt zurück in die Datenbank geschrieben.

Vollständiger Code: `examples/17_llm_advanced/churn_prediction.aql` (~80 Zeilen)

```

// Multi-Step Reasoning mit Chain-of-Thought
FOR customer IN customers
  FILTER customer.churn_risk == null
  LIMIT 10

// Schritt 1: Aggregiere relevante Kundendaten
LET customer_data = {
  orders_count: LENGTH(FOR o IN orders FILTER o.customer_id == customer._key RETURN 1),
  last_order_date: (FOR o IN orders FILTER o.customer_id == customer._key
    SORT o.order_date DESC LIMIT 1 RETURN o.order_date)[0],
  total_spent: SUM(FOR o IN orders FILTER o.customer_id == customer._key RETURN o.total_amount),
  support_tickets: LENGTH(FOR t IN support_tickets FILTER t.customer_id == customer._key RETURN t)
}

// Schritt 2: LLM-Analyse mit expliziten CoT-Anweisungen
LET analysis = PROMPT('gpt-4',
  {
    system: `Churn-Prediction-Experte. Analysiere schrittweise:
    1. Bewerte Aktivität (Bestellfrequenz, Recency)
    2. Analysiere Kaufverhalten (Umsatz-Trend)
    3. Berücksichtige Support-Interaktionen
    4. Gebe Churn-Risiko (low/medium/high) + Begründung`,
    user: CONCAT(
      'Kundendaten:\n',
      'Bestellungen: ', customer_data.orders_count, '\n',
      'Letzte Bestellung: ', customer_data.last_order_date, '\n',
      'Gesamtumsatz: €', customer_data.total_spent, '\n',
      'Support-Tickets: ', customer_data.support_tickets, '\n\n',
      'Analysiere Schritt für Schritt.'
    )
  },
  {temperature: 0.2, max_tokens: 500}
)

// Schritt 3: Speichere Analyse zurück in DB
UPDATE customer WITH {
  churn_risk: analysis.risk_level,
  churn_reasoning: analysis.reasoning,

```

```
analyzed_at: DATE_NOW()  
} IN customers
```

Vorteile von Chain-of-Thought: - **Accuracy:** 15-30% bessere Ergebnisse bei komplexen Aufgaben (laut OpenAI-Benchmarks) - **Interpretability:** Nachvollziehbare Reasoning-Schritte - **Debugging:** Fehlerquellen in der Logik erkennbar - **Consistency:** Strukturierte Analyse verhindert hallucinations

Best Practice: CoT funktioniert am besten mit klaren Schritt-Anweisungen und ausreichend Kontext (temperature 0.2-0.3 für stabile Ergebnisse).

17.4.2 Few-Shot Learning

```
// Classification mit Few-Shot Examples
LET examples = [
  {text: 'Produkt kam defekt an', category: 'quality_issue'},
  {text: 'Lieferung zwei Wochen zu spät', category: 'delivery_issue'},
  {text: 'Falscher Artikel geliefert', category: 'order_error'},
  {text: 'Sehr zufrieden, gerne wieder!', category: 'positive_feedback'}
]

FOR ticket IN support_tickets
  FILTER ticket.category == null
  LIMIT 100

  LET category = PROMPT('gpt-4',
    {
      system: 'Kategorisiere Support-Tickets basierend auf den Beispielen.',
      user: CONCAT(
        'Beispiele:\n',
        (FOR ex IN examples
          RETURN CONCAT(ex.text, ' -> ', ex.category)
        ),
        '\n\nNeues Ticket: ', ticket.message, '\n\nKategorie:'
      )
    },
    {temperature: 0.1, max_tokens: 20}
  )

  UPDATE ticket WITH {
    category: category,
    auto_categorized: true
  } IN support_tickets
```

17.5 Multi-Model LLM Patterns

17.5.1 Graph + LLM

```
// Knowledge Graph Reasoning mit LLM
FOR person IN persons
  FILTER person._key == @person_id

  // Graphtraversierung für Kontext
  LET connections = (
    FOR v, e, p IN 1..3 OUTBOUND person GRAPH 'social_network'
    RETURN {
      name: v.name,
      relationship: e.type,
      depth: LENGTH(p.edges)
    }
  )

  // LLM analysiert das soziale Netzwerk
  LET network_analysis = PROMPT('gpt-4',
    {
      system: 'Analysiere das soziale Netzwerk und gebe Empfehlungen.',
      user: CONCAT(
        'Person: ', person.name, '\n',
        'Verbindungen:\n',
        (FOR c IN connections
          RETURN CONCAT('- ', c.name, ' (', c.relationship, ', Distanz: ', c.depth, ')')
        ),
        '\n\nWelche Personen sollten miteinander vernetzt werden?'
      )
    }
  )

  RETURN {
    person: person.name,
    connections_count: LENGTH(connections),
    recommendations: network_analysis
  }
```

17.5.2 Temporal + LLM

```
// Zeit-basierte Trend-Analyse mit LLM
LET trend_data = (
  FOR metric IN metrics
    FILTER metric.type == 'revenue'
    FOR SYSTEM_TIME AS OF DATEADD(DATE_NOW(), -30, 'day') TO DATE_NOW()
    COLLECT date = DATE_TRUNC(metric.timestamp, 'day')
    AGGREGATE daily_revenue = SUM(metric.value)
    SORT date
    RETURN {date: date, revenue: daily_revenue}
)

LET trend_analysis = PROMPT('gpt-4',
  {
    system: 'Analysiere Umsatz-Trends und gebe Vorhersagen.',
    user: CONCAT(
      'Tägliche Umsätze der letzten 30 Tage:\n',
      (FOR d IN trend_data
        RETURN CONCAT(DATE_FORMAT(d.date, '%Y-%m-%d'), ': €', d.revenue)
      ),
      '\n\nAnalysiere Trends und gebe eine 7-Tage-Vorhersage.'
    )
  },
  {temperature: 0.3}
)

RETURN {
  data: trend_data,
  analysis: trend_analysis
}
```

17.6 LLM-Konfiguration und Provider

17.6.1 Provider-Konfiguration

```
// Multi-Provider Setup
LET providers = {
  openai: {
    api_key: @openai_key,
    models: ['gpt-4', 'gpt-3.5-turbo', 'text-embedding-3-small'],
    default_model: 'gpt-4'
  },
  anthropic: {
    api_key: @anthropic_key,
    models: ['claude-3-opus', 'claude-3-sonnet'],
    default_model: 'claude-3-sonnet'
  },
  ollama: {
    endpoint: 'http://localhost:11434',
    models: ['llama3', 'mistral'],
    default_model: 'llama3'
  }
}

// Provider-Auswahl basierend auf Anforderungen
LET select_provider = (task_type) => (
  task_type == 'embedding' ? 'openai' :
  task_type == 'long_context' ? 'anthropic' :
  task_type == 'local' ? 'ollama' :
  'openai'
)
```

17.6.2 Kosten-Optimierung

```
// Smart Model Selection basierend auf Komplexität
FOR task IN tasks
  FILTER task.processed == false

  // Einfache Aufgaben -> Günstigeres Modell
  LET complexity = (
    LENGTH(task.input) > 1000 ? 'high' :
    CONTAINS(task.input, 'analysiere') ? 'medium' :
    'low'
  )

  LET model = (
    complexity == 'high' ? 'gpt-4' :
    complexity == 'medium' ? 'gpt-3.5-turbo' :
    'gpt-3.5-turbo'
  )

  LET result = PROMPT(model, task.input,
    {
      temperature: complexity == 'high' ? 0.7 : 0.3,
      max_tokens: complexity == 'high' ? 2000 : 500
    }
  )

  UPDATE task WITH {
    result: result,
    model_used: model,
    cost_tier: complexity,
    processed: true
  } IN tasks
```

17.7 Prompt Template Library

17.7.1 Vordefinierte Templates

```
// Template-System für wiederverwendbare Prompts
LET templates = {
  summarize: {
    system: 'Du bist ein Zusammenfassungs-Experte. Erstelle prägnante Zusammenfassungen.',
    user_template: 'Fasse folgenden Text zusammen:\n\n{{content}}\n\nZusammenfassung (max {{max_w}} Wörter)',
  },
  translate: {
    system: 'Du bist ein professioneller Übersetzer.',
    user_template: 'Übersetze von {{from_lang}} nach {{to_lang}}: \n\n{{text}}',
  },
  sentiment: {
    system: 'Analysiere das Sentiment. Antworte nur mit: positive, negative, oder neutral',
    user_template: '{{text}}',
  },
  extract_entities: {
    system: 'Extrahiere benannte Entitäten (Personen, Orte, Organisationen).',
    user_template: '{{text}}\n\nFormat: JSON {persons: [], locations: [], organizations: []}'
  }
}

// Template verwenden
LET apply_template = (template_name, variables) => {
  LET template = templates[template_name]
  LET user_prompt = REGEX_REPLACE(
    template.user_template,
    '\\{\\{\\w+\\}\\}',
    variables
  )
  RETURN {system: template.system, user: user_prompt}
}

FOR article IN articles
  LIMIT 10
  LET summary = PROMPT('gpt-3.5-turbo',
    apply_template('summarize', {
      content: article.content,
      max_words: '100'
    })
  )
```



```
)  
RETURN {title: article.title, summary: summary}
```

17.8 Monitoring und Logging

17.8.1 LLM-Usage Tracking

```
// Track LLM-Nutzung für Kostenanalyse
INSERT {
  timestamp: DATE_NOW(),
  model: @model,
  provider: @provider,
  input_tokens: @input_tokens,
  output_tokens: @output_tokens,
  cost: @cost,
  latency_ms: @latency,
  task_type: @task_type,
  user_id: @user_id
} INTO llm_usage_log

// Kosten-Analyse
FOR log IN llm_usage_log
  FILTER log.timestamp > DATE_SUBTRACT(DATE_NOW(), 7, 'day')
  COLLECT
    model = log.model,
    task_type = log.task_type
  AGGREGATE
    total_calls = COUNT(1),
    total_cost = SUM(log.cost),
    avg_latency = AVG(log.latency_ms),
    total_input_tokens = SUM(log.input_tokens),
    total_output_tokens = SUM(log.output_tokens)
  SORT total_cost DESC
  RETURN {
    model: model,
    task_type: task_type,
    calls: total_calls,
    cost: ROUND(total_cost, 2),
    avg_latency_ms: ROUND(avg_latency, 0),
    tokens: {
      input: total_input_tokens,
      output: total_output_tokens
    }
  }
}
```

17.9 Sicherheit und Compliance

17.9.1 Input Sanitization

```
// Sichere LLM-Anfragen durch Sanitization
LET sanitize_input = (user_input) => {
  // Entferne potenziell schädliche Prompts
  LET cleaned = REGEX_REPLACE(user_input, 'ignore previous instructions', '', 'i')
  LET cleaned2 = REGEX_REPLACE(cleaned, 'disregard', '', 'i')
  LET cleaned3 = SUBSTITUTE(cleaned2, ['system:', 'assistant:'], '')

  // Längen-Begrenzung
  RETURN LENGTH(cleaned3) > 5000 ? SUBSTRING(cleaned3, 0, 5000) : cleaned3
}

FOR request IN user_requests
  LET safe_input = sanitize_input(request.query)
  LET response = PROMPT('gpt-4', safe_input, {temperature: 0.3})

  // Log für Audit
  INSERT {
    timestamp: DATE_NOW(),
    user_id: request.user_id,
    original_input: request.query,
    sanitized_input: safe_input,
    response: response,
    flagged: request.query != safe_input
  } INTO llm_audit_log

RETURN response
```

17.9.2 PII-Erkennung und Redaktion

```
// Automatische PII-Erkennung vor LLM-Verarbeitung
LET detect_pii = (text) => {
  RETURN PROMPT('gpt-4',
    {
      system: 'Erkenne und markiere personenbezogene Daten (PII). Gebe JSON zurück: {has_pii: bo
      user: text
    },
    {temperature: 0.0, response_format: 'json'}
  )
}

FOR document IN documents
  FILTER document.pii_checked == false

  LET pii_check = detect_pii(document.content)

  // Redaktiere PII falls notwendig
  LET safe_content = pii_check.has_pii ?
    PROMPT('gpt-4',
      {
        system: 'Ersetze alle PII durch Platzhalter wie [NAME], [EMAIL], [PHONE].',
        user: document.content
      }
    ) : document.content

  UPDATE document WITH {
    content_safe: safe_content,
    has_pii: pii_check.has_pii,
    pii_types: pii_check.types,
    pii_checked: true
  } IN documents
```

17.10 Performance-Optimierung

17.10.1 Caching von LLM-Responses

```
// Cache für häufige Anfragen
LET query_hash = SHA256(CONCAT(user_query, model_name))

// Prüfe Cache
LET cached = (
  FOR c IN llm_cache
    FILTER c.query_hash == query_hash
    FILTER c.timestamp > DATE_SUBTRACT(DATE_NOW(), 24, 'hour')
    LIMIT 1
  RETURN c.response
)[0]

// Verwende Cache oder rufe LLM auf
LET response = cached != null ? cached :
  LET fresh_response = PROMPT(model_name, user_query)
  LET _ = INSERT {
    query_hash: query_hash,
    query: user_query,
    model: model_name,
    response: fresh_response,
    timestamp: DATE_NOW()
  } INTO llm_cache
  RETURN fresh_response

RETURN response
```

17.10.2 Batch-Verarbeitung

```
// Batch-LLM-Calls für bessere Performance
LET batch_size = 20

FOR batch IN (
  FOR doc IN documents
    FILTER doc.summary == null
    LIMIT 100
    COLLECT batch_id = FLOOR(TO_NUMBER(doc._key) / batch_size)
    INTO group
    RETURN group
)

// Einzelner LLM-Call für ganzen Batch
LET batch_summaries = PROMPT('gpt-4',
{
  system: 'Erstelle Zusammenfassungen für mehrere Dokumente. Gebe JSON-Array zurück.',
  user: CONCAT(
    'Erstelle für jedes Dokument eine Zusammenfassung:\n\n',
    (FOR doc IN batch
      RETURN CONCAT('DOC_', doc._key, ':\n', doc.content, '\n\n'))
    )
  },
{temperature: 0.3, response_format: 'json'}
)

// Verteile Ergebnisse
FOR doc IN batch
  LET summary = batch_summaries['DOC_' + doc._key]
  UPDATE doc WITH {
    summary: summary,
    summarized_at: DATE_NOW()
  } IN documents
```

17.11 Praktische Anwendungsfälle

17.11.1 Intelligente Suchvorschläge

```
// Query-Expansion mit LLM
LET user_search = @search_term

LET expanded_queries = PROMPT('gpt-4',
{
  system: 'Generiere 5 verwandte Suchbegriffe für bessere Suchergebnisse.',
  user: CONCAT('Ursprüngliche Suche: ', user_search)
})

// Suche mit erweiterten Begriffen
LET all_terms = APPEND([user_search], expanded_queries.terms)

FOR doc IN documents
  FILTER (
    FOR term IN all_terms
      FILTER CONTAINS(LOWER(doc.content), LOWER(term))
    RETURN 1
  ) ANY
RETURN doc
```


17.11.2 Automatische Daten-Anreicherung

```
// Produkt-Metadaten durch LLM anreichern
FOR product IN products
  FILTER product.enriched == false
  LIMIT 50

  LET enrichment = PROMPT('gpt-4',
    {
      system: 'Analysiere das Produkt und gebe strukturierte Metadaten zurück.',
      user: CONCAT(
        'Produkt: ', product.name, '\n',
        'Beschreibung: ', product.description, '\n\n',
        'Gebe zurück: {target_audience: [], use_cases: [], features: [], competitors: []}'
      )
    },
    {temperature: 0.3, response_format: 'json'}
  )

  UPDATE product WITH {
    metadata: enrichment,
    enriched: true,
    enriched_at: DATE_NOW()
  } IN products
```

17.11.3 Sentiment-basierte Alerting

```
// Echtzeit-Sentiment-Monitoring mit Alerts
FOR review IN reviews
  FILTER review.sentiment == null
  FILTER review.created_at > DATE_SUBTRACT(DATE_NOW(), 1, 'hour')

  LET sentiment_analysis = PROMPT('gpt-4',
    {
      system: 'Analysiere das Sentiment und gebe Dringlichkeit (critical/high/medium/low) zurück',
      user: review.text
    },
    {temperature: 0.1, response_format: 'json'}
  )

  // Alert bei negativem Sentiment
  LET alert = sentiment_analysis.sentiment == 'negative' AND
    sentiment_analysis.urgency IN ['critical', 'high'] ?

  INSERT {
    type: 'negative_review',
    review_id: review._key,
    product_id: review.product_id,
    urgency: sentiment_analysis.urgency,
    reason: sentiment_analysis.reason,
    timestamp: DATE_NOW()
  } INTO alerts : null

  UPDATE review WITH {
    sentiment: sentiment_analysis.sentiment,
    sentiment_score: sentiment_analysis.score,
    urgency: sentiment_analysis.urgency,
    analyzed_at: DATE_NOW()
  } IN reviews
```

17.12 Erweiterte LLM-Features (v1.4.0-alpha)

17.12.1 Prefix Caching

Neu in v1.4.0-alpha: Automatisches Caching häufig verwendeter Prompt-Präfixe für deutlich reduzierte Latenz und Kosten.

Funktionsweise:

Prefix Caching speichert die Attention-States häufig verwendeter Prompt-Anfänge zwischen Anfragen. Dies ist besonders nützlich für: - System-Prompts mit Rollen und Anweisungen - Lange Kontext-Dokumente in RAG-Patterns - Wiederkehrende Dokumentations- oder Codebase-Referenzen

Abb. 17.3: Embedding-Generierung-Prozess

Diagramm-Erklärung: - **Cache Miss (erste Anfrage):** System-Prompt wird verarbeitet und Attention-States gecacht (890ms) - **Cache Hit (folgende Anfragen):** Gecachte Attention-States werden wiederverwendet, nur User-Prompt neu verarbeitet (45ms) - **Hash-basiert:** Identische System-Prompts werden erkannt durch Content-Hash - **Transparent:** Cache-Mechanismus ist für Anwendung transparent

```
// Prefix Caching automatisch aktiviert für System-Prompts
FOR doc IN customer_inquiries
  LIMIT 100
  LET response = PROMPT('gpt-4',
    {
      system: '''Du bist ein Kundenservice-Assistent für ThemisDB.
        Unsere Hauptfeatures sind:
        - Multi-Model-Datenbank (Graph, Document, Vector, Relational)
        - Native LLM-Integration
        - Horizontales Sharding für Enterprise-Scale

        Antworte immer höflich, präzise und lösungsorientiert.''' , // Wird gecacht!
      user: doc.inquiry_text
    },
    {
      temperature: 0.7,
      enable_prefix_cache: true // Explizit aktiviert (optional, ist Standard)
    }
  )
  UPDATE doc WITH {response: response} IN customer_inquiries
```

Performance-Vorteile:

```
// Prefix Cache Statistiken abfragen
RETURN LLMCACHE_STATS('prefix')
```

Beispiel-Output:

```
{
  "cache_hits": 847,
  "cache_misses": 153,
  "hit_rate": 0.847,
  "avg_latency_cached": "45ms",
  "avg_latency_uncached": "890ms",
  "cost_savings_percent": 75.2,
  "total_tokens_saved": 1250000
}
```

Best Practices:

1. **System-Prompts konsistent halten** - Kleine Änderungen invalidieren Cache
2. **Längere Präfixe bevorzugen** - Mindestens 100+ Tokens für signifikante Einsparungen
3. **Cache-Wartezeit einplanen** - Erste Anfrage ist langsamer, nachfolgende profitieren

17.12.2 Response Caching

Neu in v1.4.0-alpha: Intelligentes Caching kompletter LLM-Antworten basierend auf semantischer Ähnlichkeit.

Funktionsweise:

Response Caching speichert LLM-Antworten und verwendet Embedding-basierte Ähnlichkeitssuche, um identische oder sehr ähnliche Anfragen zu erkennen.

Abb. 17.4: Response-Caching-Flow

Diagramm-Erklärung: - Embedding-Generierung: Jede Anfrage wird in einen Vektor umgewandelt -

Similarity Search: Vector-Suche findet semantisch ähnliche Fragen (auch mit unterschiedlicher

Formulierung) - **Threshold:** Konfigurierbare Ähnlichkeitsschwelle (z.B. 92%) bestimmt Cache-Hit -

TTL-basiert: Automatische Invalidierung nach konfigurierbarer Zeit (z.B. 7 Tage) - **Backend:**

Unterstützt Redis oder ThemisDB als Cache-Backend

```
// Response Caching mit semantischer Ähnlichkeit
FOR question IN faq_queue
  FILTER question.answered == false

  // Prüfe ob ähnliche Frage bereits beantwortet wurde
  LET cached_answer = LLMCACHE_LOOKUP(
    'response',
    question.text,
    {
      similarity_threshold: 0.92, // 92% Ähnlichkeit erforderlich
      max_age_hours: 168          // Cache 7 Tage gültig
    }
  )

  LET answer = cached_answer != null ? cached_answer :
    PROMPT('gpt-4',
      {
        system: 'Beantworte FAQ-Fragen zu ThemisDB präzise und vollständig.',
        user: question.text
      },
      {
        temperature: 0.3,
        cache_response: true, // Antwort für zukünftige Verwendung cachen
        cache_ttl: 604800     // 7 Tage in Sekunden
      }
    )

  UPDATE question WITH {
    answer: answer,
    answered: true,
    from_cache: cached_answer != null,
    answered_at: DATE_NOW()
  } IN faq_queue
```

Konfiguration:

```
// ThemisDB Konfiguration (themis.conf)
llm:
  response_cache:
    enabled: true
    backend: 'redis' // oder 'themisdb'
    ttl_default: 604800 // 7 Tage
    similarity_model: 'text-embedding-3-small'
    similarity_threshold: 0.90
    max_cache_size_gb: 10
```

Cache-Invalidierung:

```
// Selektive Cache-Invalidierung
CALL LLMCACHE_INVALIDATE('response', {
  pattern: '%produkt-updates%',
  older_than: '2024-01-01'
})

// Kompletten Response-Cache leeren
CALL LLMCACHE_CLEAR('response')
```

ROI-Analyse:

```
// Cache-Effizienz über Zeit analysieren
FOR stat IN LLMCACHE_TIMESERIES('response', {
  from: DATE_SUBTRACT(DATE_NOW(), 30, 'day'),
  to: DATE_NOW(),
  granularity: 'day'
})
RETURN {
  date: stat.date,
  requests: stat.total_requests,
  cache_hits: stat.cache_hits,
  hit_rate: stat.cache_hits / stat.total_requests,
  cost_saved_usd: stat.tokens_saved * 0.00003, // GPT-4 pricing
  avg_latency_ms: stat.avg_latency
}
```

17.12.3 Multi-GPU Support

Neu in v1.4.0-alpha: Verteilte LLM-Inferenz über mehrere GPUs für maximale Performance und Skalierbarkeit.

Unterstützte Parallelisierungsstrategien:

1. **Tensor Parallelism** - Große Modelle über GPUs verteilen
2. **Pipeline Parallelism** - Modell-Layer auf verschiedene GPUs
3. **Data Parallelism** - Mehrere Anfragen parallel verarbeiten

```
// Multi-GPU Konfiguration in AQL Query
FOR batch IN RANGE(0, 9)
  LET start_idx = batch * 100
  LET end_idx = (batch + 1) * 100

  LET summaries = (
    FOR doc IN documents
      FILTER doc.id >= start_idx AND doc.id < end_idx
      RETURN PROMPT('llama-70b-local',
        CONCAT('Summarize: ', doc.content),
        {
          max_tokens: 150,
          gpu_config: {
            num_gpus: 4,                // 4 GPUs verwenden
            strategy: 'tensor_parallel', // Tensor Parallelism
            gpu_ids: [0, 1, 2, 3]       // Spezifische GPU-IDs
          }
        }
      )
  )

  RETURN {batch: batch, summaries: summaries}
```

GPU-Scheduling:

```
// themis.conf - Multi-GPU Konfiguration
llm:
  local_models:
    llama-70b:
      model_path: '/models/llama-70b'
      gpu_config:
        num_gpus: 4
        tensor_parallel_size: 4
        pipeline_parallel_size: 1
        max_num_batched_tokens: 8192
        gpu_memory_utilization: 0.9
```


Performance-Monitoring:

```
// GPU-Auslastung in Echtzeit überwachen
RETURN LLM_GPU_STATS()
```

Output:

```
{
  "gpus": [
    {
      "id": 0,
      "model": "NVIDIA A100",
      "memory_used_gb": 38.2,
      "memory_total_gb": 40.0,
      "utilization_percent": 95,
      "temperature_celsius": 68,
      "power_watts": 320
    },
    // GPU 1-3...
  ],
  "throughput_tokens_per_sec": 1250,
  "active_requests": 12,
  "queue_length": 3
}
```

Skalierungs-Benchmarks:

GPUs	Tokens/Sek	Latenz (p50)	Latenz (p99)	Cost/1M Tokens
1x A100	320	1.2s	2.8s	\$0 (lokal)
2x A100	580	0.7s	1.6s	\$0 (lokal)
4x A100	1050	0.4s	0.9s	\$0 (lokal)
8x A100	1850	0.25s	0.6s	\$0 (lokal)

17.12.4 Paged Attention

Neu in v1.4.0-alpha: Effiziente GPU-Speicherverwaltung für Attention-Mechanismen mit bis zu 80% weniger Speicherverbrauch.

Problem ohne Paged Attention:

Traditionelle Attention-Implementierungen allokalieren kontinuierlichen Speicher für KV-Caches, was zu Fragmentierung und ineffizienter Nutzung führt.

Lösung mit Paged Attention:

Abb. 17.5: Context-Window-Management

Aktivierung:

```
// Paged Attention ist standardmäßig aktiviert in v1.4.0-alpha
FOR doc IN large_documents
  LIMIT 1000
  LET analysis = PROMPT('llama-70b-local',
    {
      system: 'Analysiere das folgende Dokument detailliert.',
      user: doc.content // Auch für sehr lange Dokumente effizient
    },
    {
      max_tokens: 2000,
      paged_attention: {
        enabled: true, // Default: true
        page_size: 16, // Tokens pro Page (empfohlen: 16)
        max_num_pages: 4096 // Maximale Pages im Cache
      }
    }
  )
  RETURN analysis
```

Speicher-Effizienz:

```
// Vergleich: Mit vs. ohne Paged Attention
RETURN {
  without_paging: {
    memory_per_request_mb: 450,
    max_concurrent_requests: 89,
    gpu_memory_utilization: 0.99,
    memory_waste_percent: 35
  },
  with_paging: {
    memory_per_request_mb: 90,
    max_concurrent_requests: 445,
    gpu_memory_utilization: 0.99,
    memory_waste_percent: 8
  },
  improvement: {
    memory_reduction: '80%',
    concurrency_increase: '5x',
    waste_reduction: '77%'
  }
}
```

Performance-Charakteristiken:

- **Speicher-Overhead:** ~5% zusätzlicher Overhead für Page-Management
- **Latenz-Impact:** <2% zusätzliche Latenz bei gleichem Durchsatz
- **Skalierbarkeit:** 4-5x mehr gleichzeitige Requests möglich

17.12.5 LoRA (Low-Rank Adaptation) Support

Neu in v1.4.0-alpha: Effizientes Fine-Tuning und Deployment von spezialisierten Modell-Adaptoren mit minimalem Speicher-Overhead.

Konzept:

LoRA fügt trainierbare Low-Rank-Matrizen zu vortrainierten Modellen hinzu, statt das gesamte Modell neu zu trainieren. Dies reduziert: - **Speicher:** 99% weniger Speicher für Fine-Tuned Models - **Training-Zeit:** 3-10x schneller als Full Fine-Tuning - **Deployment:** Mehrere Adapter auf einem Basis-Modell

LoRA-Adapter Management:

```
// LoRA-Adapter registrieren
CALL LLM_REGISTER_LORA({
  name: 'medical-assistant',
  base_model: 'llama-70b-local',
  adapter_path: '/models/lora/medical-assistant',
  description: 'Spezialisiert auf medizinische Beratung',
  rank: 16, // LoRA Rank (niedrig = kleiner, hoch = expressiver)
  alpha: 32,
  target_modules: ['q_proj', 'v_proj']
})

// Adapter verwenden
FOR patient_inquiry IN medical_questions
  LET advice = PROMPT('llama-70b-local',
    {
      system: 'Du bist ein medizinischer Assistent. Gebe keine Diagnosen.',
      user: patient_inquiry.question
    },
    {
      lora_adapter: 'medical-assistant', // LoRA-Adapter aktivieren
      temperature: 0.3
    }
  )
  RETURN {question: patient_inquiry.question, advice: advice}
```

Multi-LoRA Support:

```
// Verschiedene Adapter für verschiedene Use Cases
LET adapters = {
  'legal': 'legal-document-assistant',
  'medical': 'medical-assistant',
  'code': 'code-generation-assistant',
  'finance': 'financial-analyst'
}

FOR doc IN documents
  LET domain = doc.domain
  LET adapter = adapters[domain]

  LET analysis = adapter != null ?
    PROMPT('llama-70b-local',
      CONCAT('Analyze: ', doc.content),
      {lora_adapter: adapter, temperature: 0.2}
    ) : null

  RETURN {domain: domain, analysis: analysis}
```

LoRA-Adapter Training:

```
// Training-Job starten (vereinfachtes Beispiel)
CALL LLM_TRAIN_LORA({
  job_name: 'customer-support-v2',
  base_model: 'llama-70b-local',
  training_data: 'customer_support_conversations', // Collection
  validation_split: 0.1,
  hyperparameters: {
    rank: 16,
    alpha: 32,
    learning_rate: 3e-4,
    epochs: 3,
    batch_size: 8,
    warmup_steps: 100
  },
  output_path: '/models/lora/customer-support-v2'
})
```

Adapter-Vergleich:

```
// A/B-Testing verschiedener Adapter
FOR question IN test_questions
  LET response_base = PROMPT('llama-70b-local', question.text, {temperature: 0.3})
  LET response_v1 = PROMPT('llama-70b-local', question.text, {
    lora_adapter: 'customer-support-v1',
    temperature: 0.3
  })
  LET response_v2 = PROMPT('llama-70b-local', question.text, {
    lora_adapter: 'customer-support-v2',
    temperature: 0.3
  })

  RETURN {
    question: question.text,
    base: response_base,
    v1: response_v1,
    v2: response_v2
  }
```

Adapter-Statistiken:

```
RETURN LLM_LORA_STATS()
```

Output:

```
{
  "registered_adapters": 12,
  "active_adapters": {
    "medical-assistant": {
      "requests_total": 15420,
      "avg_latency_ms": 245,
      "size_mb": 45,
      "rank": 16,
      "base_model": "llama-70b-local"
    }
    // weitere Adapter...
  },
  "memory_overhead_mb": 540, // 12 Adapter zusammen
  "base_model_size_gb": 65
}
```

17.12.6 Grammar-Constrained Generation

Neu in v1.4.0-alpha: EBNF/GBNF-basierte Grammar-Constraints garantieren gültige, strukturierte LLM-Ausgaben (JSON, XML, CSV) ohne Post-Processing.

Problem ohne Grammar Constraints:

LLMs erzeugen oft ungültige Outputs, selbst bei expliziten Anweisungen:

```
// x Ohne Grammar: 60-70% Erfolgsrate
LET response = PROMPT('llama-70b-local',
  'Gebe eine JSON-Liste mit 3 Produkten zurück: {name, price, stock}')
```



```
// Typische Fehler:
// - Trailing commas: {"name": "Laptop", "price": 999,}
// - Fehlende Quotes: {name: Laptop}
// - Zusätzlicher Text: "Here is the JSON: {...}"
// - Inkompletter Output: {"name": "Laptop" [abgebrochen]
```

Lösung: Grammar-Constrained Generation (95-99% Erfolgsrate):

Abb. 17.6: Token-Optimization-Strategy

Diagramm-Erklärung: - **Traditionell:** LLM generiert frei → Validierung → bei Fehler Retry (teuer, langsam) - **Grammar-Constrained:** Grammar-Regeln garantieren gültigen Output → kein Retry nötig - **Effizienz:** 95-99% Erfolgsrate, kein Post-Processing, niedrigere Kosten

Verwendung in AQL:


```
// Mit Grammar: 95-99% Erfolgsrate, kein Retry nötig
FOR product IN products_to_export
  LIMIT 100

  LET json_data = PROMPT('llama-70b-local',
    CONCAT('Erstelle JSON für Produkt: ', product.name),
    {
      temperature: 0.3,
      grammar_type: 'json', // Built-in Grammar
      response_schema: {
        name: 'string',
        description: 'string',
        price: 'number',
        stock: 'integer',
        categories: 'array'
      }
    }
  )

  // json_data ist GARANTIERT valides JSON!
  INSERT json_data INTO exports
```

Built-in Grammars:

Grammar Type	Use Case	Beispiel-Output
json	API-Responses, Strukturierte Daten	{"key": "value", "arr": [1,2,3]}
json_strict	Strenge JSON-Compliance	Keine trailing commas, quotes required
xml	Legacy-Systeme, SOAP APIs	<root><item>value</item></root>
csv	Daten-Export, Excel-Integration	name,price,stock\nLaptop,999,15
react_agent	Multi-Step Reasoning	Thought: ...\nAction: ...\nObservation: ...

JSON Grammar mit Schema:

```
// Produkt-Export mit garantiert gültigem JSON-Schema
FOR order IN orders
  FILTER order.exported == false
  LIMIT 50

  LET export_data = PROMPT('gpt-4',
    {
      system: 'Du bist ein Daten-Export-Assistent. Konvertiere Bestellungen zu JSON.',
      user: CONCAT('Bestellung: ', TO_STRING(order))
    },
    {
      grammar_type: 'json_strict',
      response_schema: {
        order_id: 'string',
        customer: {
          name: 'string',
          email: 'string',
          address: {
            street: 'string',
            city: 'string',
            zip: 'string'
          }
        },
        items: [{
          product_id: 'string',
          name: 'string',
          quantity: 'integer',
          price: 'number'
        }],
        total: 'number',
        status: 'enum:pending,shipped,delivered'
      }
    }
  )

  // Garantiert valides, schemakonforme JSON - kein try/catch nötig!
  INSERT export_data INTO order_exports
  UPDATE order WITH {exported: true} IN orders
```

XML Grammar für Legacy-Integration:

```
// SOAP-API Integration mit garantiert gültigem XML
FOR invoice IN pending_invoices
  LIMIT 20

  LET xml_payload = PROMPT('gpt-4',
    CONCAT('Konvertiere Rechnung zu XML: ', TO_STRING(invoice)),
    {
      grammar_type: 'xml',
      temperature: 0.1
    }
  )

  // xml_payload ist garantiert well-formed XML
  LET soap_response = HTTP_POST('https://erp.example.com/soap', {
    body: CONCAT(
      '<soap:Envelope>',
      '<soap:Body>', xml_payload, '</soap:Body>',
      '</soap:Envelope>'
    ),
    headers: {'Content-Type': 'text/xml'}
  })

  UPDATE invoice WITH {
    erp_synced: true,
    erp_response: soap_response
  } IN pending_invoices
```

CSV Grammar für Daten-Export:

```
// Batch-Export zu CSV mit Grammar-Garantie
LET csv_export = PROMPT('gpt-4',
  {
    system: '''Konvertiere Produktdaten zu CSV.
              Spalten: ProductID, Name, Category, Price, Stock
              Keine zusätzlichen Kommentare, nur CSV.''' ,
    user: CONCAT('Produkte: ', TO_STRING(SLICE(products, 0, 100)))
  },
  {
    grammar_type: 'csv',
    temperature: 0.0
  }
)

// csv_export ist garantiert gültiges CSV - direkt speicherbar
LET file_written = FILE_WRITE('/exports/products.csv', csv_export)
RETURN {written: file_written, rows: COUNT_LINES(csv_export)}
```

ReAct Agent Grammar für Multi-Step Reasoning:

```
// Agent-basierte Problemlösung mit strukturiertem Output
FOR task IN complex_tasks
  FILTER task.status == 'pending'
  LIMIT 5

  LET agent_steps = PROMPT('gpt-4',
    {
      system: '''Du bist ein Problem-Solving Agent.
        Verwende ReAct Format:
        Thought: [dein Gedankengang]
        Action: [Aktion zum Ausführen]
        Observation: [Ergebnis der Aktion]
        ... (wiederholen bis Lösung)
        Final Answer: [endgültige Antwort]''',
      user: CONCAT('Problem: ', task.description)
    },
    {
      grammar_type: 'react_agent',
      max_tokens: 1000
    }
  )

  // agent_steps ist strukturiert nach ReAct-Format
  // → Einfach zu parsen und auszuführen
  LET parsed = PARSE_REACT_FORMAT(agent_steps)

  UPDATE task WITH {
    solution_steps: parsed.steps,
    final_answer: parsed.final_answer,
    status: 'solved'
  } IN complex_tasks
```

Custom Grammars (EBNF):

```
// Eigene Grammar-Definition für spezielle Formate
LET custom_grammar = '''
root ::= person+
person ::= name age email
name ::= "Name:" [a-zA-Z ]+ "\\n"
age ::= "Age:" [0-9]+ "\\n"
email ::= "Email:" [a-z0-9@.]+ "\\n"
'''

FOR contact IN contact_queue
  LET formatted = PROMPT('gpt-4',
    CONCAT('Formatiere Kontakt: ', TO_STRING(contact)),
    {
      grammar_ebnf: custom_grammar,
      temperature: 0.2
    }
  )

  // Output garantiert im definierten Format:
  // Name: Max Mustermann
  // Age: 35
  // Email: max@example.com
  INSERT {text: formatted} INTO formatted_contacts
```

Grammar Cache für Performance:

Grammars werden automatisch gecacht (LRU Cache, 100 Entries):

```
// Statistiken abfragen
RETURN GRAMMAR_CACHE_STATS()
```

Output:

```
{
  "cache_size": 100,
  "cache_hits": 15420,
  "cache_misses": 234,
  "hit_rate": 0.985,
  "builtin_grammars": ["json", "json_strict", "xml", "csv", "react_agent"],
  "custom_grammars_loaded": 15
}
```

Performance-Vergleich:

```
// Benchmark: Mit vs. Ohne Grammar
RETURN LLM_GRAMMAR_BENCHMARK({
  prompt: 'Generate JSON product list',
  iterations: 100
})
```

Output:

```
{
  "without_grammar": {
    "avg_latency_ms": 890,
    "success_rate": 0.68,
    "retries_needed": 32,
    "total_tokens": 125000,
    "cost_usd": 3.75
  },
  "with_grammar": {
    "avg_latency_ms": 950,
    "success_rate": 0.98,
    "retries_needed": 2,
    "total_tokens": 102000,
    "cost_usd": 3.06
  },
  "savings": {
    "cost_reduction_percent": 18.4,
    "time_saved_percent": -6.7, // Initial 7% slower...
    "reliability_improvement": "+44%",
    "effective_time_saved": "+65%" // ...aber massiv weniger Retries!
  }
}
```

Erklärung: - Grammar fügt ~7% Overhead hinzu - ABER: 44% höhere Erfolgsrate → 94% weniger Retries - Effektiv: 65% schneller + 18% günstiger

Best Practices:

1. **Verwende Built-in Grammars** wenn möglich (optimiert, gecacht)
2. **Definiere klare Schemas** für `json` Grammar
3. **Temperature niedrig halten** (0.0-0.3) für deterministische Outputs
4. **Grammar für Batch-Jobs** - Amortisiert Overhead über viele Requests
5. **× Nicht für kreative Texte** - Grammar schränkt Flexibilität ein
6. **× Nicht für Chat/Dialog** - Zu restriktiv für natürliche Konversation

Use Cases - Perfekt für:

- API-Integration (JSON/XML-Generierung)

- Daten-Export (CSV, strukturierte Formate)
- Code-Generierung (Syntax-korrekt)
- Formular-Parsing (strukturierte Extraktion)
- Agent-Frameworks (ReAct, Tool-Calling)

Use Cases - Nicht geeignet für:

- × Kreatives Schreiben
- × Chat/Dialog
- × Offene Fragen
- × Brainstorming

Weitere Ressourcen:

- llama.cpp GBNF Spezifikation: [GitHub](https://github.com/ggml-org/llama.cpp/blob/master/grammars/README.md) (https://github.com/ggml-org/llama.cpp/blob/master/grammars/README.md)
- Built-in Grammars: `src/llm/grammars/*.gbnf`
- Custom Grammar API: `docs/en/llm/GRAMMAR_CONSTRAINED_GENERATION.md`

17.12.7 RoPE Scaling - Extended Context Window

Neu in v1.4.0-alpha: RoPE (Rotary Position Embedding) Scaling erweitert das Kontext-Fenster von Standard 4K-8K auf bis zu 32K+ Tokens (8x Increase).

Problem: Begrenzte Kontext-Länge:

Standard-LLMs sind auf 4K-8K Tokens limitiert:

```
// x Fehler: Kontext zu lang
LET research_paper = FILE_READ('paper.txt') // 25K Tokens
LET summary = PROMPT('llama-70b-local',
  CONCAT('Fasse zusammen: ', research_paper) // ERROR: Context too long!
)
```

Lösung: RoPE Scaling:

Abb. 17.7: Multi-LLM-Orchestration

Diagramm-Erklärung: - **Standard:** Input auf 4K tokens gekürzt → Informationsverlust - **RoPE Scaling:** Positions-Embeddings "gestreckt" → 8x längerer Kontext möglich - **NTK-aware / YaRN:** Intelligente Skalierung erhält Qualität auch bei 32K

Scaling-Methoden:

Methode	Kontext	Qualität	Use Case
Linear	4K → 16K (4x)	Gut	Einfache Dokumente
NTK-aware	4K → 24K (6x)	Sehr gut	Standard-Anwendungen
YaRN	4K → 32K (8x)	Exzellent	Research Papers, Code

Konfiguration:

```
# config/llm.yaml
llm:
  models:
    - name: llama-70b-extended
      path: ./models/llama-70b.gguf
      rope_scaling:
        type: yarn # linear, ntk_aware, yarn
        factor: 8 # 4K → 32K
        freq_base: 10000.0
        freq_scale: 1.0
      n_ctx: 32768 # 32K context window
```

Verwendung in AQL:

```
// Mit RoPE Scaling: Vollständige Research Paper Analyse
FOR paper IN research_papers
  FILTER paper.analyzed == false
  LIMIT 10

  // Paper hat 25K tokens - passt in 32K Context!
  LET full_text = FILE_READ(paper.file_path)

  LET analysis = PROMPT('llama-70b-extended',
    {
      system: '''Du bist ein wissenschaftlicher Assistent.
        Analysiere das Paper gründlich und extrahiere:
        1. Kernaussagen und Hypothesen
        2. Methodologie
        3. Ergebnisse und Erkenntnisse
        4. Limitationen
        5. Relevanz für unser Forschungsgebiet''',
      user: CONCAT('Research Paper (vollständig):\n\n', full_text)
    },
    {
      temperature: 0.3,
      max_tokens: 2000,
      rope_scaling_type: 'yarn', // Optional: Per-Request Override
      n_ctx: 32768
    }
  )

  UPDATE paper WITH {
    analysis: analysis,
    analyzed: true,
    tokens_used: TOKEN_COUNT(full_text)
  } IN research_papers
```

Codebase-Verständnis:

```
// Vollständige Codebase-Analyse (große Repositories)
LET codebase_files = (
  FOR file IN GLOB('src/**/*.cpp')
    RETURN {
      path: file,
      content: FILE_READ(file)
    }
)

// Alle Files concatenieren
LET full_codebase = (
  FOR file IN codebase_files
    RETURN CONCAT(
      '// File: ', file.path, '\n',
      file.content, '\n\n'
    )
)

LET concatenated = CONCAT_ARRAY(full_codebase)

// Analyse mit extended context (20K tokens codebase)
LET code_analysis = PROMPT('gpt-4-32k',
  {
    system: 'Du bist ein Code-Reviewer. Analysiere die Codebase ganzheitlich.',
    user: CONCAT(
      'Komplette Codebase:\n\n', concatenated, '\n\n',
      'Identifiziere: Architektur-Patterns, potentielle Bugs, ',
      'Performance-Probleme, Security-Issues.'
    )
  },
  {
    n_ctx: 32768,
    rope_scaling_type: 'yarn'
  }
)

RETURN {
  total_files: LENGTH(codebase_files),
```

```
total_tokens: TOKEN_COUNT(concatenated),  
analysis: code_analysis  
}
```

Long-Form Content Generation:

```

// Buch-Kapitel mit vollem Kontext vorheriger Kapitel
FOR chapter IN book_chapters
  FILTER chapter.generated == false
  SORT chapter.number ASC

// Alle vorherigen Kapitel als Kontext
LET previous_chapters = (
  FOR prev IN book_chapters
    FILTER prev.number < chapter.number
    SORT prev.number ASC
    RETURN prev.content
)

LET context = CONCAT_ARRAY(previous_chapters) // Kann 20K+ tokens sein

LET new_chapter = PROMPT('gpt-4-32k',
  {
    system: '''Du bist ein Buchautor. Schreibe das nächste Kapitel
              mit Konsistenz zu allen vorherigen Kapiteln.'''
    user: CONCAT(
      'Bisherige Kapitel (vollständig):\n\n', context, '\n\n',
      'Schreibe jetzt Kapitel ', chapter.number, ': ', chapter.title
    )
  },
  {
    temperature: 0.8,
    max_tokens: 4000,
    n_ctx: 32768
  }
)

UPDATE chapter WITH {
  content: new_chapter,
  generated: true
} IN book_chapters

```

Extended Conversations:

```

// Chat mit vollem Konversations-Verlauf (100+ Messages)
FOR session IN chat_sessions
  FILTER session.needs_response == true

  // Vollständige Chat-History laden
  LET messages = (
    FOR msg IN chat_messages
      FILTER msg.session_id == session._key
      SORT msg.timestamp ASC
      RETURN CONCAT(msg.role, ': ', msg.content)
  )

  LET full_history = CONCAT_ARRAY(messages, '\n') // 15K tokens

  LET response = PROMPT('gpt-4-32k',
    {
      system: 'Du bist ein hilfreicher Assistent. Beziehe dich auf die gesamte Konversation.',
      user: CONCAT(
        'Konversationsverlauf:\n', full_history, '\n\n',
        'Nutzer: ', session.latest_message
      )
    },
    {
      temperature: 0.7,
      n_ctx: 32768
    }
  )

  INSERT {
    session_id: session._key,
    role: 'assistant',
    content: response,
    timestamp: DATE_NOW()
  } INTO chat_messages

  UPDATE session WITH {needs_response: false} IN chat_sessions

```

Performance & Qualität:

```
// Benchmark: Context Length vs. Qualität
RETURN ROPE_SCALING_BENCHMARK({
  model: 'llama-70b',
  test_contexts: [4096, 8192, 16384, 32768],
  test_iterations: 50
})
```

Output:

```
{
  "4K_baseline": {
    "throughput_tokens_per_sec": 45,
    "quality_score": 0.92,
    "memory_gb": 65
  },
  "16K_ntk_aware": {
    "throughput_tokens_per_sec": 34,
    "quality_score": 0.89,
    "memory_gb": 80,
    "quality_loss_percent": 3.3
  },
  "32K_yarn": {
    "throughput_tokens_per_sec": 22,
    "quality_score": 0.88,
    "memory_gb": 95,
    "quality_loss_percent": 4.3
  },
  "recommendations": {
    "for_quality": "Use YaRN up to 32K",
    "for_speed": "Use NTK-aware up to 16K",
    "for_memory": "Stay at baseline 4K or use quantization"
  }
}
```

Trade-offs:

Context	Throughput	Memory	Qualität	Best For
4K	100%	1x		Standard-Tasks
16K (4x)	75%	1.2x		Längere Docs
32K (8x)	50%	1.5x		Research Papers

Best Practices:

1. **Start mit kleinstem Context** der funktioniert
2. **YaRN für maximale Qualität** bei langen Kontexten
3. **Monitor Quality Loss** mit Benchmarks
4. **Quantization kombinieren** (Q4/Q5) für Speicher-Effizienz
5. **Batch kurze Dokumente** statt einzeln lange Kontext
6. × **Nicht blind auf 32K** - nur wenn wirklich nötig
7. × **Nicht für Streaming** - Latenz zu hoch

Use Cases - Perfekt für:

- Research Paper Analyse (20-30K tokens)
- Codebase Review (vollständiger Code-Kontext)
- Long-Form Content (Bücher, Reports)
- Extended Conversations (100+ Messages)
- Legal Document Review (Verträge, Gesetzestexte)

Use Cases - Overkill für:

- × Chat (Standard 4K reicht)
- × Kurze Queries (<1K tokens)
- × Real-time Anwendungen (zu langsam)

Weitere Ressourcen:

- YaRN Paper: [arXiv:2309.00071](https://arxiv.org/abs/2309.00071) (<https://arxiv.org/abs/2309.00071>)
- RoPE Scaling Guide: `docs/en/llm/ROPE_SCALING_IMPLEMENTATION.md`
- Configuration: `config/llm.yaml`

17.12.8 Vision Support

Neu in v1.4.0-alpha: Multimodale LLM-Integration für Text + Bild-Verarbeitung, ermöglicht visuelle Analyse, OCR und Bildbeschreibung direkt in AQL.

Unterstützte Modelle:

- GPT-4 Vision (OpenAI)
- Claude 3 (Anthropic)
- LLaVA (lokal)
- CogVLM (lokal)

Bild-Analyse in AQL:

```
// Produktbilder analysieren
FOR product IN products
  FILTER product.image_analysis == null
  LIMIT 100

  LET analysis = PROMPT_VISION('gpt-4-vision',
    {
      image: product.image_url, // URL oder base64
      prompt: '''Analysiere dieses Produktbild und extrahiere:
        1. Produkttyp und Kategorie
        2. Sichtbare Features und Merkmale
        3. Farben und Materialien
        4. Zustand (neu/gebraucht)
        5. Qualitätsbewertung (1-10)'''
    },
    {
      temperature: 0.3,
      max_tokens: 500,
      response_format: 'json'
    }
  )

  UPDATE product WITH {
    image_analysis: analysis,
    analyzed_at: DATE_NOW()
  } IN products
```

OCR und Dokumenten-Extraktion:

```
// Rechnungen per OCR verarbeiten
FOR invoice IN scanned_invoices
  FILTER invoice.extracted == false

  LET ocr_result = PROMPT_VISION('gpt-4-vision',
    {
      image: invoice.scan_base64,
      prompt: '''Extrahiere folgende Informationen aus dieser Rechnung:
        - Rechnungsnummer
        - Datum
        - Lieferant (Name, Adresse)
        - Positionen (Artikel, Menge, Einzelpreis)
        - Gesamtbetrag
        - Mehrwertsteuer
        Gebe das Ergebnis als strukturiertes JSON zurück.'''
    },
    {
      temperature: 0.1,
      response_format: 'json'
    }
  )

  INSERT {
    invoice_id: invoice._key,
    invoice_number: ocr_result.invoice_number,
    date: ocr_result.date,
    supplier: ocr_result.supplier,
    items: ocr_result.items,
    total: ocr_result.total,
    vat: ocr_result.vat,
    extracted_at: DATE_NOW()
  } INTO invoice_data

  UPDATE invoice WITH {extracted: true} IN scanned_invoices
```

Integration mit Video Processor:

```
// Keyframes aus Videos analysieren (siehe Kapitel 12: Computer Vision)
FOR video IN videos
  FILTER video.keyframe_analysis == null

  // Keyframes extrahieren (aus Video Processor)
  LET keyframes = VIDEO_EXTRACT_KEYFRAMES(video.file_path, {
    max_keyframes: 10,
    min_interval_seconds: 5
  })

  // Jeden Keyframe mit Vision LLM analysieren
  LET frame_analyses = (
    FOR frame IN keyframes
      RETURN PROMPT_VISION('gpt-4-vision',
        {
          image: frame.image_base64,
          prompt: 'Beschreibe was in diesem Video-Frame zu sehen ist. Fokus auf Aktionen, Objekte',
        },
        {temperature: 0.5, max_tokens: 200}
      )
    )

  // Gesamtzusammenfassung generieren
  LET summary = PROMPT('gpt-4',
    {
      system: 'Erstelle eine kohärente Video-Zusammenfassung aus Einzelframe-Beschreibungen.',
      user: CONCAT('Frame-Beschreibungen:\n', TO_STRING(frame_analyses))
    }
  )

  UPDATE video WITH {
    keyframe_analyses: frame_analyses,
    summary: summary,
    keyframe_analysis: true
  } IN videos
```

Visual Question Answering:

```
// Fragen zu Bildern beantworten
FOR support_ticket IN tickets
  FILTER support_ticket.has_image AND support_ticket.image_question != null

  LET answer = PROMPT_VISION('claude-3-opus',
    {
      image: support_ticket.image_url,
      prompt: CONCAT(
        'Kundenfrage: ', support_ticket.image_question, '\n\n',
        'Analysiere das Bild und beantworte die Kundenfrage detailliert.'
      )
    },
    {temperature: 0.4, max_tokens: 400}
  )

  UPDATE support_ticket WITH {
    ai_answer: answer,
    ai_answered_at: DATE_NOW()
  } IN tickets
```

Batch-Verarbeitung mit Vision:

```

// Effiziente Batch-Verarbeitung großer Bildmengen
FOR batch IN RANGE(0, 49)
  LET start_idx = batch * 20
  LET end_idx = (batch + 1) * 20

  LET results = (
    FOR img IN images
      FILTER img.id >= start_idx AND img.id < end_idx
      FILTER img.moderation_check == null

      RETURN {
        id: img._key,
        moderation: PROMPT_VISION('gpt-4-vision',
          {
            image: img.url,
            prompt: '''Prüfe dieses Bild auf:
              - Inappropriate content
              - Violence
              - Hate symbols
              - NSFW content
              Gebe JSON mit: {safe: boolean, flags: [], confidence: number}'''
          },
          {temperature: 0.1, response_format: 'json'}
        )
      }
  )

// Batch-Update
FOR result IN results
  UPDATE {_key: result.id} WITH {
    moderation_check: result.moderation,
    checked_at: DATE_NOW()
  } IN images

```

Performance-Überlegungen:

```
// Vision API Kosten-Tracking
RETURN LLM_VISION_STATS({
  from: DATE_SUBTRACT(DATE_NOW(), 7, 'day'),
  to: DATE_NOW()
})
```

Output:

```
{
  "total_requests": 15420,
  "images_processed": 15420,
  "avg_latency_ms": 1850,
  "cost_breakdown": {
    "gpt-4-vision": {
      "requests": 12000,
      "cost_usd": 360.00,
      "avg_cost_per_image": 0.03
    },
    "claude-3-opus": {
      "requests": 3420,
      "cost_usd": 205.20,
      "avg_cost_per_image": 0.06
    }
  },
  "use_cases": {
    "product_analysis": 8500,
    "ocr": 4200,
    "moderation": 2720
  }
}
```

17.13 Best Practices Zusammenfassung

17.13.1 DO

1. Verwende **@parameter binding** für alle Benutzereingaben

2. **Cache häufige Anfragen** um Kosten zu sparen
3. **Validiere LLM-Outputs** vor der Speicherung
4. **Batch-Verarbeitung** für große Datenmengen
5. **Monitor Kosten** und Performance kontinuierlich
6. **Sanitize Inputs** vor LLM-Calls
7. **Verwende strukturierte Outputs** (JSON) wenn möglich
8. **Implementiere Fallbacks** bei LLM-Fehlern

17.13.2 DON'T x

1. **Keine sensiblen Daten** ungefiltert an LLMs senden
2. **Keine unvalidierten LLM-Queries** ausführen
3. **Keine unbegrenzten LLM-Calls** ohne Rate-Limiting
4. **Keine Hardcoded API-Keys** im Code
5. **Keine synchronen LLM-Calls** für zeitkritische Operationen
6. **Keine Abhängigkeit** von einem einzelnen Provider

Zusammenfassung

ThemisDB's LLM-Integration ermöglicht:

- **Native AQL-Funktionen** für Text-Generierung, Embeddings und strukturierte Ausgaben
- **Text-to-AQL** für natürlichsprachliche Query-Erstellung
- **RAG Patterns** mit semantischer Suche und Kontext-Anreicherung
- **Multi-Model Synergien** mit Graph, Temporal und Vector Search
- **Kosten-Optimierung** durch intelligentes Caching und Model-Selection
- **Enterprise-Grade Sicherheit** mit Input-Sanitization und PII-Schutz

Die Integration von LLMs direkt in die Datenbankebene reduziert Latenz, vereinfacht Architektur und ermöglicht völlig neue Anwendungsfälle von intelligenter Datenanalyse bis zu automatisierter Content-Generierung.

Nächstes Kapitel: [Kapitel 18: Machine Learning Integration](#) Vorheriges Kapitel: [Kapitel 16: Machine Learning](#)

Kapitel 18: Kapitel 18 - Machine Learning

Überblick

ThemisDB bietet umfassende Integration mit Machine-Learning-Frameworks und -Workflows. Als Multi-Model-Datenbank mit nativem Vector-Support eignet sich ThemisDB ideal als:

- **ML Feature Store** - Speicherung und Verwaltung von Features für Training und Inference
- **Model Serving Platform** - Online und Batch Predictions
- **Experiment Tracking** - Versionierung von Models, Metriken und Hyperparametern
- **Training Data Management** - Effiziente Speicherung großer Datasets

Die Kombination aus relationalen Daten, Graphen, Dokumenten und Vektoren macht ThemisDB zur idealen Plattform für ML-Pipelines.

Abb. 18.1: ML-Pipeline-Architektur

18.1 ML Feature Store

Feature Engineering mit ThemisDB

Feature-Definition:

Feature-Definition:

Ein Feature Store in ThemisDB speichert vorberechnete ML-Features für verschiedene Entities (Kunden, Produkte, etc.). Die Features werden versioniert und mit Timestamps versehen, sodass Point-in-Time-Lookups für Training und Inference möglich sind. Dies vermeidet Training-Serving-Skew, ein häufiges Problem in ML-Systemen.

Vollständiger Code: `examples/18_ml_features/feature_store.py` (ca. 120 Zeilen)

Feature Store Schema:

```
from themisdb import ThemisDB
import pandas as pd

db = ThemisDB(host='localhost', port=8529)

# Feature Store mit Versionierung
db.execute("""
    CREATE TABLE ml_features (
        feature_id STRING PRIMARY KEY,
        entity_id STRING,
        entity_type STRING,
        feature_name STRING,
        feature_value VARIANT, -- Flexibler Typ für verschiedene Features
        feature_type STRING,
        computed_at TIMESTAMP,
        version INTEGER,

        INDEX idx_entity (entity_id, entity_type),
        INDEX idx_feature (feature_name, computed_at)
    )
""")
```

Feature-Berechnung (Konzept):

```

def compute_customer_features(customer_id):
    """Berechnet ML-Features für einen Kunden"""

    # Transaktions-Historie aggregieren
    transaction_features = db.query("""
        FOR txn IN transactions
        FILTER txn.customer_id == @customer_id
        COLLECT AGGREGATE
            total_spent = SUM(txn.amount),
            num_transactions = COUNT(1),
            avg_transaction = AVG(txn.amount),
            days_since_last = DATE_DIFF(NOW(), MAX(txn.date), 'day')
        RETURN {
            total_spent,
            num_transactions,
            avg_transaction,
            days_since_last
        }
    """, bind_vars={'customer_id': customer_id}))[0]

    # Weitere Features: RFM-Score, Category-Preferences, etc.
    # ... (siehe vollständige Implementierung)

    # Features in Store speichern
    for feature_name, value in transaction_features.items():
        store_feature(
            entity_id=customer_id,
            entity_type='customer',
            feature_name=feature_name,
            feature_value=value,
            version=1
        )

```

Point-in-Time Feature Lookup:

```
def get_feature_vector(entity_id, feature_names, as_of_time=None):
    """
    Holt Feature-Vector zu einem bestimmten Zeitpunkt.
    Kritisch für Training: Features dürfen nur Daten bis 'as_of_time' nutzen!
    """
    if as_of_time is None:
        as_of_time = datetime.now()

    features = []
    for feature_name in feature_names:
        # Neueste Version VOR as_of_time
        result = db.query("""
            FOR f IN ml_features
            FILTER f.entity_id == @entity_id
                AND f.feature_name == @feature_name
                AND f.computed_at <= @as_of_time
            SORT f.computed_at DESC
            LIMIT 1
            RETURN f.feature_value
        """, bind_vars={
            'entity_id': entity_id,
            'feature_name': feature_name,
            'as_of_time': as_of_time
        })

        features.append(result[0] if result else None)

    return features
```

Wichtige Konzepte:

1. **Point-in-Time Correctness:** Features zum Training-Zeitpunkt müssen mit Inference-Features übereinstimmen
2. **Versionierung:** Ermöglicht A/B-Tests verschiedener Feature-Definitionen
3. **VARIANT Type:** Speichert unterschiedliche Datentypen (Float, String, Array) in einer Spalte
4. **Efficient Aggregation:** AQL `COLLECT AGGREGATE` für schnelle Feature-Berechnung
5. **Incremental Updates:** Nur neue Daten müssen berechnet werden

Die vollständige Implementierung enthält zusätzlich: - Batch-Feature-Berechnung für alle Entities - Feature-Monitoring (Drift-Detection) - Feature-Lineage-Tracking - Online-Feature-Store-API für Echtzeit-Inference

Online Feature Store (Low-Latency)

Feature Retrieval:

```

class FeatureStore:
    def __init__(self, db):
        self.db = db
        self.cache = {} # In-memory cache

    def get_features(self, entity_id, feature_names, use_cache=True):
        """Retrieve features with caching"""
        cache_key = f"{entity_id}:{','.join(sorted(feature_names))}"

        if use_cache and cache_key in self.cache:
            return self.cache[cache_key]

        result = self.db.execute("""
            FOR feature IN ml_features
            FILTER feature.entity_id == @entity_id
            FILTER feature.feature_name IN @feature_names
            SORT feature.version DESC
            COLLECT feature_name = feature.feature_name
            INTO group = feature
            RETURN {
                feature_name: group[0].feature.feature_value
            }
        """, bind_vars={
            'entity_id': entity_id,
            'feature_names': feature_names
        })

        features = {item['feature_name']: item['feature_value']
                    for item in result}

        if use_cache:
            self.cache[cache_key] = features

        return features

    def get_feature_vector(self, entity_id, feature_order):
        """Get ordered feature vector for ML model"""
        features = self.get_features(entity_id, feature_order)

```

```
        return [features.get(fname, None) for fname in feature_order]

# Verwendung
feature_store = FeatureStore(db)

# Online Prediction
feature_names = ['total_orders', 'total_spent', 'days_since_last_order',
                 'friend_count', 'avg_order_value']
features = feature_store.get_feature_vector('customer_12345', feature_names)
```

16.2 Model Training Integration

Scikit-Learn Integration

Daten laden und Model trainieren:


```
from sklearn.ensemble import RandomForestClassifier
from sklearn.model_selection import train_test_split
from sklearn.metrics import classification_report
import numpy as np

# Training Data aus ThemisDB laden
def load_training_data():
    result = db.execute("""
        FOR customer IN customers
        LET features = (
            FOR feature IN ml_features
            FILTER feature.entity_id == customer._id
            FILTER feature.version == 1
            RETURN {
                [feature.feature_name]: feature.feature_value
            }
        )

        LET label = customer.churned ? 1 : 0

        RETURN {
            customer_id: customer._id,
            features: MERGE(features),
            label: label
        }
    """)

    # DataFrame erstellen
    data = []
    for row in result:
        features = row['features']
        features['label'] = row['label']
        data.append(features)

    df = pd.DataFrame(data)
    return df

# Training
```

```
df = load_training_data()

feature_columns = ['total_orders', 'total_spent', 'avg_order_value',
                   'days_since_last_order', 'friend_count']

X = df[feature_columns].fillna(0)
y = df['label']

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42
)

# Model trainieren
model = RandomForestClassifier(n_estimators=100, random_state=42)
model.fit(X_train, y_train)

# Evaluation
y_pred = model.predict(X_test)
print(classification_report(y_test, y_pred))

# Feature Importance
feature_importance = pd.DataFrame({
    'feature': feature_columns,
    'importance': model.feature_importances_
}).sort_values('importance', ascending=False)

print(feature_importance)
```

TensorFlow/Keras Integration

Neural Network Training:

```

import tensorflow as tf
from tensorflow import keras
from tensorflow.keras import layers

# Deep Learning Dataset
class ThemisDataset(tf.data.Dataset):
    def __generator(customer_ids, feature_store, feature_names):
        for customer_id in customer_ids:
            features = feature_store.get_feature_vector(customer_id, feature_names)

            # Label laden
            result = db.execute("""
                FOR customer IN customers
                    FILTER customer._id == @customer_id
                    RETURN customer.churned ? 1 : 0
            """, bind_vars={'customer_id': customer_id})

            label = result[0] if result else 0

            yield (tf.constant(features, dtype=tf.float32),
                   tf.constant(label, dtype=tf.int32))

    def __new__(cls, customer_ids, feature_store, feature_names):
        return tf.data.Dataset.from_generator(
            lambda: cls._generator(customer_ids, feature_store, feature_names),
            output_signature=(
                tf.TensorSpec(shape=(len(feature_names),), dtype=tf.float32),
                tf.TensorSpec(shape=(), dtype=tf.int32)
            )
        )

# Alle Customer IDs laden
customer_ids = db.execute("FOR c IN customers RETURN c._id")

# Dataset erstellen
dataset = ThemisDataset(customer_ids, feature_store, feature_names)
dataset = dataset.batch(32).prefetch(tf.data.AUTOTUNE)

```

```

# Neural Network
model = keras.Sequential([
    layers.Dense(64, activation='relu', input_shape=(len(feature_names),)),
    layers.Dropout(0.3),
    layers.Dense(32, activation='relu'),
    layers.Dropout(0.3),
    layers.Dense(16, activation='relu'),
    layers.Dense(1, activation='sigmoid')
])

model.compile(
    optimizer='adam',
    loss='binary_crossentropy',
    metrics=['accuracy', 'AUC']
)

# Training
history = model.fit(
    dataset,
    epochs=10,
    validation_split=0.2
)

# Model speichern
model.save('models/churn_prediction_v1.h5')

```

PyTorch Integration

Custom Dataset und Training:

Custom Dataset und Training:

PyTorch-Integration mit ThemisDB ermöglicht direktes Training aus der Datenbank ohne CSV-Export. Der `ThemisDataset` lädt Features on-the-fly, was bei großen Datasets Speicher spart. Die direkte DB-Integration stellt sicher, dass Training und Inference dieselbe Datenpipeline nutzen.

Vollständiger Code: `examples/18_ml_pytorch/train_model.py` (ca. 100 Zeilen)

Custom PyTorch Dataset:

```
import torch
from torch.utils.data import Dataset, DataLoader
import torch.nn as nn

class ThemisDataset(Dataset):
    """PyTorch Dataset das Features direkt aus ThemisDB lädt"""

    def __init__(self, db, feature_names, label_column='churn'):
        self.db = db
        self.feature_names = feature_names
        self.label_column = label_column

        # Entity IDs laden (lazy loading von Features)
        self.customer_ids = db.execute(
            "FOR c IN customers RETURN c._id"
        )

    def __len__(self):
        return len(self.customer_ids)

    def __getitem__(self, idx):
        customer_id = self.customer_ids[idx]

        # Features aus Feature Store laden
        features = feature_store.get_feature_vector(
            customer_id,
            self.feature_names
        )
        features = [f if f is not None else 0.0 for f in features]

        # Label laden
        label = db.query("""
            FOR c IN customers
            FILTER c._id == @customer_id
            RETURN c[@label_column]
        """, bind_vars={
            'customer_id': customer_id,
            'label_column': self.label_column
        })
```

```
    })[0]

    return (
        torch.tensor(features, dtype=torch.float32),
        torch.tensor(label, dtype=torch.float32)
    )
```

Model-Definition und Training:

```
# Einfaches Neural Network
class ChurnPredictor(nn.Module):
    def __init__(self, input_dim):
        super().__init__()
        self.layers = nn.Sequential(
            nn.Linear(input_dim, 64),
            nn.ReLU(),
            nn.Dropout(0.3),
            nn.Linear(64, 32),
            nn.ReLU(),
            nn.Dropout(0.3),
            nn.Linear(32, 1),
            nn.Sigmoid()
        )

    def forward(self, x):
        return self.layers(x)

# Training Loop
def train_model(db, feature_names, epochs=10, batch_size=32):
    # Dataset erstellen
    dataset = ThemisDataset(db, feature_names)
    dataloader = DataLoader(dataset, batch_size=batch_size, shuffle=True)

    # Model initialisieren
    model = ChurnPredictor(input_dim=len(feature_names))
    criterion = nn.BCELoss()
    optimizer = optim.Adam(model.parameters(), lr=0.001)

    # Training
    for epoch in range(epochs):
        total_loss = 0
        for batch_features, batch_labels in dataloader:
            optimizer.zero_grad()

            # Forward pass
            predictions = model(batch_features)
            loss = criterion(predictions.squeeze(), batch_labels)
```

```
# Backward pass
loss.backward()
optimizer.step()

total_loss += loss.item()

print(f"Epoch {epoch+1}/{epochs}, Loss: {total_loss/len(dataloader):.4f}")

return model
```

Model in DB speichern:


```
def save_model_to_db(model, model_name, metadata):  
    """Speichert trainiertes Model zurück in ThemisDB"""  
  
    # Model als Binary serialisieren  
    model_bytes = io.BytesIO()  
    torch.save(model.state_dict(), model_bytes)  
    model_bytes.seek(0)  
  
    db.execute("""  
        INSERT INTO ml_models {  
            model_name: @model_name,  
            model_binary: @model_binary,  
            framework: 'pytorch',  
            input_features: @features,  
            metrics: @metrics,  
            trained_at: @timestamp,  
            version: @version  
        }  
    """, bind_vars={  
        'model_name': model_name,  
        'model_binary': model_bytes.read(),  
        'features': metadata['features'],  
        'metrics': metadata['metrics'],  
        'timestamp': datetime.now(),  
        'version': metadata['version']  
    })
```

Vorteile der DB-Integration:

Vorteil	Beschreibung
Keine CSV-Exports	Features direkt aus DB geladen
Lazy Loading	Speicher-effizient bei großen Datasets
Konsistenz	Training & Inference nutzen gleiche Pipeline
Versionierung	Models und Features zusammen versioniert
Reproducibility	Komplette Lineage in einer DB

Die vollständige Implementierung enthält zusätzlich: - Train/Val/Test Split direkt in DB - Distributed Training über mehrere Nodes - Model-Registry mit A/B-Testing - Feature-Importance-Tracking - Hyperparameter-Tuning-History

16.3 Model Serving

Online Predictions (REST API)

FastAPI Model Server:

```
from fastapi import FastAPI, HTTPException
from pydantic import BaseModel
import joblib
import numpy as np

app = FastAPI()

# Model laden
model = joblib.load('models/churn_model.pkl')
feature_store = FeatureStore(db)

class PredictionRequest(BaseModel):
    customer_id: str

class PredictionResponse(BaseModel):
    customer_id: str
    churn_probability: float
    churn_prediction: bool
    features_used: dict

@app.post("/predict/churn", response_model=PredictionResponse)
async def predict_churn(request: PredictionRequest):
    try:
        # Features laden
        feature_names = ['total_orders', 'total_spent', 'avg_order_value',
                        'days_since_last_order', 'friend_count']

        features = feature_store.get_features(request.customer_id, feature_names)
        feature_vector = [features.get(fn, 0) for fn in feature_names]

        # Prediction
        churn_prob = model.predict_proba([feature_vector])[0][1]
        churn_pred = churn_prob > 0.5

        # Prediction in DB speichern
        db.execute("""
            INSERT {
                customer_id: @customer_id,
```

```

        prediction_type: 'churn',
        probability: @probability,
        prediction: @prediction,
        features: @features,
        model_version: 'v1',
        predicted_at: DATE_NOW()
    } INTO predictions
"""
bind_vars={
    'customer_id': request.customer_id,
    'probability': float(churn_prob),
    'prediction': churn_pred,
    'features': features
})

return PredictionResponse(
    customer_id=request.customer_id,
    churn_probability=float(churn_prob),
    churn_prediction=churn_pred,
    features_used=features
)

except Exception as e:
    raise HTTPException(status_code=500, detail=str(e))

@app.get("/model/info")
async def model_info():
    return {
        "model_type": "RandomForestClassifier",
        "version": "v1",
        "features": feature_names,
        "trained_at": "2024-01-15"
    }

```

Batch Predictions

Batch Inference für alle Kunden:

```
def batch_predict_churn(model, batch_size=1000):  
    # Alle Customer IDs  
    customer_ids = db.execute("FOR c IN customers RETURN c._id")  
  
    total = len(customer_ids)  
    processed = 0  
  
    for i in range(0, total, batch_size):  
        batch_ids = customer_ids[i:i+batch_size]  
  
        # Batch Features laden  
        batch_features = []  
        for customer_id in batch_ids:  
            features = feature_store.get_feature_vector(customer_id, feature_names)  
            batch_features.append(features)  
  
        # Batch Prediction  
        predictions = model.predict_proba(batch_features)[: , 1]  
  
        # Bulk Insert  
        docs = []  
        for customer_id, prob in zip(batch_ids, predictions):  
            docs.append({  
                'customer_id': customer_id,  
                'prediction_type': 'churn',  
                'probability': float(prob),  
                'prediction': prob > 0.5,  
                'model_version': 'v1',  
                'predicted_at': datetime.now().isoformat()  
            })  
  
        db.bulk_insert('predictions', docs)  
  
        processed += len(batch_ids)  
        print(f'Processed {processed}/{total} customers')  
  
# Ausführen  
batch_predict_churn(model)
```

16.4 MLOps - Experiment Tracking

Experiment Management

Model Versioning:

```
class MLEperiment:

    def __init__(self, db, experiment_name):
        self.db = db
        self.experiment_name = experiment_name
        self.experiment_id = self._create_experiment()

    def _create_experiment(self):
        result = self.db.execute("""
            INSERT {
                experiment_name: @name,
                created_at: DATE_NOW(),
                status: 'running'
            } INTO ml_experiments
            RETURN NEW._id
        """, bind_vars={'name': self.experiment_name})

        return result[0]

    def log_params(self, params):
        """Log hyperparameters"""
        self.db.execute("""
            UPDATE @experiment_id WITH {
                params: @params
            } IN ml_experiments
        """, bind_vars={
            'experiment_id': self.experiment_id,
            'params': params
        })

    def log_metrics(self, metrics, step=None):
        """Log training metrics"""
        self.db.execute("""
            INSERT {
                experiment_id: @experiment_id,
                metrics: @metrics,
                step: @step,
                logged_at: DATE_NOW()
            } INTO ml_metrics
```

```

        """', bind_vars={
            'experiment_id': self.experiment_id,
            'metrics': metrics,
            'step': step
        })

def log_model(self, model_path, metadata=None):
    """Register trained model"""
    self.db.execute("""
        UPDATE @experiment_id WITH {
            model_path: @model_path,
            model_metadata: @metadata,
            status: 'completed',
            completed_at: DATE_NOW()
        } IN ml_experiments
    """, bind_vars={
        'experiment_id': self.experiment_id,
        'model_path': model_path,
        'metadata': metadata or {}
    })

# Verwendung
experiment = MLEperiment(db, 'churn_prediction_rf_v2')

# Hyperparameters loggen
experiment.log_params({
    'n_estimators': 100,
    'max_depth': 10,
    'min_samples_split': 5,
    'random_state': 42
})

# Training mit Metric Logging
for epoch in range(10):
    # ... Training ...

    experiment.log_metrics({
        'train_loss': train_loss,

```



```
        'val_loss': val_loss,
        'train_accuracy': train_acc,
        'val_accuracy': val_acc
    }, step=epoch)

# Model registrieren
experiment.log_model(
    model_path='models/churn_rf_v2.pkl',
    metadata={
        'feature_importance': feature_importance.to_dict(),
        'test_accuracy': 0.87,
        'test_auc': 0.92
    }
)
```

Model Registry

Zentrales Model Management:

```
class ModelRegistry:
    def __init__(self, db):
        self.db = db

    def register_model(self, name, version, model_path, metadata):
        """Register a new model version"""
        self.db.execute("""
            INSERT {
                model_name: @name,
                version: @version,
                model_path: @model_path,
                metadata: @metadata,
                status: 'staged',
                registered_at: DATE_NOW()
            } INTO model_registry
        """, bind_vars={
            'name': name,
            'version': version,
            'model_path': model_path,
            'metadata': metadata
        })

    def promote_to_production(self, name, version):
        """Promote model to production"""
        # Alte Production Models auf 'archived' setzen
        self.db.execute("""
            FOR model IN model_registry
                FILTER model.model_name == @name
                FILTER model.status == 'production'
            UPDATE model WITH {
                status: 'archived',
                archived_at: DATE_NOW()
            } IN model_registry
        """, bind_vars={'name': name})

        # Neue Version auf 'production' setzen
        self.db.execute("""
            FOR model IN model_registry
```

```

        FILTER model.model_name == @name
        FILTER model.version == @version
        UPDATE model WITH {
            status: 'production',
            promoted_at: DATE_NOW()
        } IN model_registry
    """ , bind_vars={'name': name, 'version': version})

def get_production_model(self, name):
    """Get current production model"""
    result = self.db.execute("""
        FOR model IN model_registry
        FILTER model.model_name == @name
        FILTER model.status == 'production'
        RETURN model
    """, bind_vars={'name': name})

    return result[0] if result else None

def list_versions(self, name):
    """List all versions of a model"""
    return self.db.execute("""
        FOR model IN model_registry
        FILTER model.model_name == @name
        SORT model.version DESC
        RETURN {
            version: model.version,
            status: model.status,
            metadata: model.metadata,
            registered_at: model.registered_at
        }
    """, bind_vars={'name': name})

# Verwendung
registry = ModelRegistry(db)

# Model registrieren
registry.register_model(

```

```
name='churn_predictor',
version='v2.1',
model_path='models/churn_rf_v2.1.pkl',
metadata={
    'algorithm': 'RandomForest',
    'test_accuracy': 0.89,
    'test_auc': 0.94,
    'feature_count': 5
}
)

# Zu Production promoten
registry.promote_to_production('churn_predictor', 'v2.1')

# Production Model laden
prod_model = registry.get_production_model('churn_predictor')
```

16.5 Model Monitoring

Prediction Drift Detection

Model Performance Monitoring:

```
class ModelMonitor:

    def __init__(self, db, model_name):
        self.db = db
        self.model_name = model_name

    def log_prediction(self, prediction_id, features, prediction, actual=None):
        """Log prediction for monitoring"""
        self.db.execute("""
            INSERT {
                prediction_id: @prediction_id,
                model_name: @model_name,
                features: @features,
                prediction: @prediction,
                actual: @actual,
                timestamp: DATE_NOW()
            } INTO prediction_logs
        """, bind_vars={
            'prediction_id': prediction_id,
            'model_name': self.model_name,
            'features': features,
            'prediction': prediction,
            'actual': actual
        })

    def update_actual(self, prediction_id, actual):
        """Update with actual outcome"""
        self.db.execute("""
            UPDATE @prediction_id WITH {
                actual: @actual,
                updated_at: DATE_NOW()
            } IN prediction_logs
        """, bind_vars={
            'prediction_id': prediction_id,
            'actual': actual
        })

    def calculate_metrics(self, time_window_days=7):
        """Calculate recent model performance"""
```

```

        result = self.db.execute("""
            LET cutoff_date = DATE_SUBTRACT(DATE_NOW(), @days, 'day')

            FOR log IN prediction_logs
                FILTER log.model_name == @model_name
                FILTER log.timestamp >= cutoff_date
                FILTER log.actual != null

            COLLECT AGGREGATE
                total = COUNT(1),
                correct = SUM(log.prediction == log.actual ? 1 : 0),
                false_positives = SUM(log.prediction == true AND log.actual == false ? 1 : 0),
                false_negatives = SUM(log.prediction == false AND log.actual == true ? 1 : 0)

            LET accuracy = correct / total
            LET precision = correct / (correct + false_positives)
            LET recall = correct / (correct + false_negatives)
            LET f1_score = 2 * (precision * recall) / (precision + recall)

            RETURN {
                accuracy,
                precision,
                recall,
                f1_score,
                total_predictions: total
            }
        """, bind_vars={
            'model_name': self.model_name,
            'days': time_window_days
        })

    return result[0] if result else None

def detect_feature_drift(self, feature_name, time_window_days=7):
    """Detect drift in feature distribution"""
    result = self.db.execute("""
        LET cutoff_date = DATE_SUBTRACT(DATE_NOW(), @days, 'day')
    """

```

```

    LET recent_stats = (
        FOR log IN prediction_logs
            FILTER log.model_name == @model_name
            FILTER log.timestamp >= cutoff_date
            COLLECT AGGREGATE
                mean = AVG(log.features[@feature_name]),
                stddev = STDDEV(log.features[@feature_name]),
                min = MIN(log.features[@feature_name]),
                max = MAX(log.features[@feature_name])
            RETURN {mean, stddev, min, max}
    )

    LET baseline_stats = (
        FOR log IN prediction_logs
            FILTER log.model_name == @model_name
            FILTER log.timestamp < cutoff_date
            LIMIT 10000
            COLLECT AGGREGATE
                mean = AVG(log.features[@feature_name]),
                stddev = STDDEV(log.features[@feature_name])
            RETURN {mean, stddev}
    )

    LET mean_diff = ABS(recent_stats[0].mean - baseline_stats[0].mean)
    LET drift_score = mean_diff / baseline_stats[0].stddev

    RETURN {
        feature_name: @feature_name,
        baseline: baseline_stats[0],
        recent: recent_stats[0],
        drift_score: drift_score,
        drift_detected: drift_score > 2.0
    }
}

""" , bind_vars={
    'model_name': self.model_name,
    'feature_name': feature_name,
    'days': time_window_days
}
})

```

```
        return result[0] if result else None

# Verwendung
monitor = ModelMonitor(db, 'churn_predictor')

# Performance überwachen
metrics = monitor.calculate_metrics(time_window_days=7)
print(f"7-Day Accuracy: {metrics['accuracy']:.2%}")
print(f"7-Day F1 Score: {metrics['f1_score']:.2f}")

# Feature Drift prüfen
for feature in feature_names:
    drift = monitor.detect_feature_drift(feature)
    if drift['drift_detected']:
        print(f"⚠ Drift detected in {feature}: {drift['drift_score']:.2f}")
```

16.6 Praktische Anwendungsfälle

Use Case 1: Fraud Detection

Echtzeit-Betrug-Erkennung:


```

# Training Data mit Graph Features
def prepare_fraud_training_data():
    result = db.execute("""
        FOR txn IN transactions
            LET user = DOCUMENT('users', txn.user_id)

            LET graph_features = (
                FOR v, e, p IN 1..2 OUTBOUND txn.user_id GRAPH 'user_network'
                COLLECT AGGREGATE
                    network_size = COUNT(1),
                    fraud_neighbors = SUM(v.is_fraudster ? 1 : 0)
                RETURN {network_size, fraud_neighbors}
            )[0]

            LET velocity_features = (
                FOR t IN transactions
                FILTER t.user_id == txn.user_id
                FILTER DATE_DIFF(t.timestamp, txn.timestamp, 'hour') <= 24
                COLLECT AGGREGATE
                    txn_count_24h = COUNT(1),
                    total_amount_24h = SUM(t.amount)
                RETURN {txn_count_24h, total_amount_24h}
            )[0]

            RETURN {
                transaction_id: txn._id,
                amount: txn.amount,
                user_age_days: DATE_DIFF(user.created_at, txn.timestamp, 'day'),
                network_size: graph_features.network_size,
                fraud_neighbors: graph_features.fraud_neighbors,
                txn_count_24h: velocity_features.txn_count_24h,
                total_amount_24h: velocity_features.total_amount_24h,
                is_fraud: txn.is_fraud
            }
    """)

    return pd.DataFrame(result)

```

```
# XGBoost Model
import xgboost as xgb

df = prepare_fraud_training_data()

feature_cols = ['amount', 'user_age_days', 'network_size',
                'fraud_neighbors', 'txn_count_24h', 'total_amount_24h']

X = df[feature_cols]
y = df['is_fraud']

dtrain = xgb.DMatrix(X, label=y)

params = {
    'max_depth': 6,
    'eta': 0.1,
    'objective': 'binary:logistic',
    'eval_metric': 'auc'
}

model = xgb.train(params, dtrain, num_boost_round=100)

# Real-time Fraud Scoring
def score_transaction(txn_id):
    features = compute_transaction_features(txn_id)
    dtest = xgb.DMatrix([features])
    fraud_score = model.predict(dtest)[0]

    if fraud_score > 0.8:
        # Block transaction
        db.execute("""
            UPDATE @txn_id WITH {
                status: 'blocked',
                fraud_score: @score,
                blocked_at: DATE_NOW()
            } IN transactions
        """, bind_vars={'txn_id': txn_id, 'score': float(fraud_score)})
```

```
return {'blocked': True, 'score': fraud_score}

return {'blocked': False, 'score': fraud_score}
```

Use Case 2: Product Recommendations

Collaborative Filtering mit Vector Embeddings:

```
from sklearn.decomposition import TruncatedSVD

# User-Item Matrix erstellen
def create_user_item_matrix():
    result = db.execute("""
        FOR order IN orders
        FOR item IN order.items
        RETURN {
            user_id: order.customer_id,
            product_id: item.product_id,
            rating: item.quantity * item.price
        }
    """)

    df = pd.DataFrame(result)
    matrix = df.pivot_table(
        index='user_id',
        columns='product_id',
        values='rating',
        fill_value=0
    )

    return matrix

# Matrix Factorization
matrix = create_user_item_matrix()

svd = TruncatedSVD(n_components=50, random_state=42)
user_embeddings = svd.fit_transform(matrix)
product_embeddings = svd.components_.T

# Embeddings in ThemisDB speichern
for idx, user_id in enumerate(matrix.index):
    embedding = user_embeddings[idx].tolist()

    db.execute("""
        UPDATE @user_id WITH {
            embedding: @embedding,
```

```
        embedding_version: 'v1'
    } IN users
    """', bind_vars={'user_id': user_id, 'embedding': embedding})

# Recommendations via Vector Similarity
def get_recommendations(user_id, top_k=10):
    result = db.execute("""
        LET user = DOCUMENT('users', @user_id)

        FOR product IN products
            FILTER product.embedding != null

            LET similarity = COSINE_SIMILARITY(user.embedding, product.embedding)

        SORT similarity DESC
        LIMIT @top_k

        RETURN {
            product_id: product._id,
            product_name: product.name,
            similarity_score: similarity
        }
    """, bind_vars={'user_id': user_id, 'top_k': top_k})

    return result
```

16.7 Best Practices

Performance-Optimierung

1. Feature Store Optimierung:

```
# Composite Index für schnelle Feature-Lookups
db.execute("""
    CREATE INDEX idx_feature_lookup ON ml_features (
        entity_id, feature_name, version
    )
""")

# Materialized View für häufige Aggregationen
db.execute("""
    CREATE MATERIALIZED VIEW customer_features_latest AS
    FOR feature IN ml_features
    SORT feature.version DESC
    COLLECT entity_id = feature.entity_id, feature_name = feature.feature_name
    INTO group = feature
    RETURN {
        entity_id: group[0].feature.entity_id,
        feature_name: group[0].feature.feature_name,
        feature_value: group[0].feature.feature_value,
        computed_at: group[0].feature.computed_at
    }
""")
```

2. Batch Processing:

```
# Parallele Feature-Berechnung
from concurrent.futures import ThreadPoolExecutor

def parallel_feature_computation(customer_ids, n_workers=8):
    with ThreadPoolExecutor(max_workers=n_workers) as executor:
        futures = [executor.submit(compute_customer_features, cid)
                    for cid in customer_ids]

        results = [f.result() for f in futures]

    return results
```

3. Model Caching:

```
import pickle
from functools import lru_cache

@lru_cache(maxsize=10)
def load_model(model_path):
    """Cache loaded models in memory"""
    with open(model_path, 'rb') as f:
        return pickle.load(f)
```

Monitoring & Alerts

Automated Alerts:

```
def check_model_health():
    monitor = ModelMonitor(db, 'churn_predictor')

    # Performance Check
    metrics = monitor.calculate_metrics(time_window_days=1)

    if metrics['accuracy'] < 0.80:
        send_alert(f"Model accuracy dropped to {metrics['accuracy']:.2%}")

    # Drift Check
    for feature in feature_names:
        drift = monitor.detect_feature_drift(feature, time_window_days=7)

        if drift['drift_detected']:
            send_alert(f"Feature drift detected: {feature} (score: {drift['drift_score']:.2f})")

    # Prediction Volume Check
    recent_count = db.execute("""
        LET cutoff = DATE_SUBTRACT(DATE_NOW(), 1, 'hour')
        FOR log IN prediction_logs
            FILTER log.timestamp >= cutoff
            COLLECT WITH COUNT INTO count
        RETURN count
    """)[0]

    if recent_count < 100:
        send_alert(f"Low prediction volume: {recent_count} in last hour")

    # Scheduled Check (z.B. mit Cron)
    import schedule

    schedule.every(1).hour.do(check_model_health)
```

Zusammenfassung

ThemisDB bietet eine vollständige ML-Plattform:

Feature Store - Effiziente Feature-Verwaltung mit MVCC

Multi-Framework Support - Scikit-learn, TensorFlow, PyTorch, XGBoost

Model Serving - Online und Batch Predictions

MLOps - Experiment Tracking, Model Registry, Monitoring

Drift Detection - Automatische Erkennung von Feature/Model Drift

Graph ML - Native Graph-Features für komplexe Beziehungen

Vector Embeddings - HNSW-basierte Similarity Search

Die Multi-Model-Architektur ermöglicht komplexe ML-Pipelines mit relationalen Features, Graph-Analysen und Vector-Embeddings in einer einzigen Datenbank.

Teil VI - Skalierung & Monitoring

Kapitel 19: Kapitel 19 - Monitoring

Einführung

Monitoring und Observability sind kritische Aspekte für den produktiven Betrieb von ThemisDB. Dieses Kapitel behandelt die Überwachung von Systemmetriken, Application Performance Monitoring (APM), Logging-Strategien, Distributed Tracing und Alerting-Mechanismen.

18.1 Monitoring-Architektur

18.1.1 Übersicht

Eine umfassende Monitoring-Lösung für ThemisDB umfasst:

- **Metriken-Sammlung:** Prometheus, StatsD, InfluxDB
- **Visualisierung:** Grafana, Kibana
- **Logging:** ELK Stack (Elasticsearch, Logstash, Kibana), Loki
- **Distributed Tracing:** Jaeger, Zipkin
- **Alerting:** Prometheus Alertmanager, PagerDuty

18.1.2 Metriken-Typen

System-Metriken: - CPU-Auslastung - Speichernutzung (RAM, Swap) - Disk I/O (IOPS, Latenz, Durchsatz) - Netzwerk-Traffic (Bandbreite, Pakete)

ThemisDB-Metriken: - Query-Performance (Latenz, Durchsatz) - Connection Pool (aktive Connections, Wartezeit) - Transaction-Statistiken (Commits, Rollbacks) - Cache-Effizienz (Hit Rate, Miss Rate) - Index-Performance - Replikations-Lag

18.2 Prometheus Integration

18.2.1 Prometheus Setup

Installation:

```
# Prometheus herunterladen
wget https://github.com/prometheus/prometheus/releases/download/v2.45.0/prometheus-2.45.0.linux-amd64.tar.gz
tar xvfz prometheus-2.45.0.linux-amd64.tar.gz
cd prometheus-2.45.0.linux-amd64

# Konfiguration erstellen
cat > prometheus.yml <<EOF
global:
  scrape_interval: 15s
  evaluation_interval: 15s

scrape_configs:
  - job_name: 'themisdb'
    static_configs:
      - targets: ['localhost:8529']
    metrics_path: '/metrics'
EOF

# Prometheus starten
./prometheus --config.file=prometheus.yml
```

18.2.2 ThemisDB Exporter

Metriken-Endpoint aktivieren:

```
# themisdb_exporter.py
from prometheus_client import start_http_server, Counter, Gauge, Histogram
from themisdb import ThemisDB
import time

# Metriken definieren
query_counter = Counter('themisdb_queries_total', 'Total number of queries', ['type'])
query_duration = Histogram('themisdb_query_duration_seconds', 'Query duration', ['type'])
active_connections = Gauge('themisdb_active_connections', 'Number of active connections')
cache_hit_rate = Gauge('themisdb_cache_hit_rate', 'Cache hit rate')

db = ThemisDB(host='localhost', port=8529)

def collect_metrics():
    """Sammelt ThemisDB Metriken."""
    while True:
        # Connection-Metriken
        stats = db.statistics()
        active_connections.set(stats['connections']['active'])

        # Cache-Metriken
        cache_stats = db.cache_statistics()
        hit_rate = cache_stats['hits'] / (cache_stats['hits'] + cache_stats['misses'])
        cache_hit_rate.set(hit_rate)

        # Query-Metriken
        query_stats = db.query_statistics()
        for query_type, count in query_stats.items():
            query_counter.labels(type=query_type).inc(count)

        time.sleep(15)

if __name__ == '__main__':
    # Metrics-Server starten
    start_http_server(9090)
    collect_metrics()
```

18.2.3 Wichtige Metriken

Query Performance:

```
# Query Latenz Histogram
themisdb_query_duration_seconds_bucket{type="SELECT", le="0.1"} 1200
themisdb_query_duration_seconds_bucket{type="SELECT", le="0.5"} 1450
themisdb_query_duration_seconds_bucket{type="SELECT", le="1.0"} 1480
themisdb_query_duration_seconds_bucket{type="SELECT", le="5.0"} 1500

# Query Counter
themisdb_queries_total{type="SELECT"} 1500
themisdb_queries_total{type="INSERT"} 500
themisdb_queries_total{type="UPDATE"} 200
```

Connection Pool:

```
# Aktive Connections
themisdb_active_connections 45

# Connection Pool Größe
themisdb_connection_pool_size 100
themisdb_connection_pool_available 55
```

18.3 Grafana Dashboards

18.3.1 Dashboard Setup

Grafana Installation:

```
# Grafana installieren
sudo apt-get install -y software-properties-common
sudo add-apt-repository "deb https://packages.grafana.com/oss/deb stable main"
wget -q -O - https://packages.grafana.com/gpg.key | sudo apt-key add -
sudo apt-get update
sudo apt-get install grafana

# Grafana starten
sudo systemctl start grafana-server
sudo systemctl enable grafana-server

# Zugriff: http://localhost:3000 (admin/admin)
```

18.3.2 ThemisDB Dashboard

Dashboard-Definition (JSON):

```
{
  "dashboard": {
    "title": "ThemisDB Performance",
    "panels": [
      {
        "title": "Query Latency (p95)",
        "targets": [
          {
            "expr": "histogram_quantile(0.95, themisdb_query_duration_seconds_bucket)"
          }
        ],
        "type": "graph"
      },
      {
        "title": "Queries per Second",
        "targets": [
          {
            "expr": "rate(themisdb_queries_total[1m])"
          }
        ],
        "type": "graph"
      },
      {
        "title": "Active Connections",
        "targets": [
          {
            "expr": "themisdb_active_connections"
          }
        ],
        "type": "graph"
      },
      {
        "title": "Cache Hit Rate",
        "targets": [
          {
            "expr": "themisdb_cache_hit_rate"
          }
        ],
      },
    ]
  }
}
```



```
        "type": "gauge"
      }
    ]
  }
}
```

18.3.3 Dashboard-Beispiele

System-Übersicht Dashboard: - CPU-Auslastung (pro Core) - Speichernutzung (RAM, Swap, Cache) - Disk I/O (Read/Write IOPS, Latenz) - Netzwerk-Traffic (In/Out Bandwidth)

Query-Performance Dashboard: - Query Latenz (p50, p95, p99) - Queries per Second (nach Typ) - Slow Queries (>1s) - Query Error Rate

Cluster-Status Dashboard: - Node Health Status - Replikations-Lag - Cluster-Topology - Failover-Events

18.4 Logging

18.4.1 Logging-Strategie

Log-Levels:

```
import logging

# Logging konfigurieren
logging.basicConfig(
    level=logging.INFO,
    format='%(asctime)s - %(name)s - %(levelname)s - %(message)s',
    handlers=[
        logging.FileHandler('/var/log/themisdb/themisdb.log'),
        logging.StreamHandler()
    ]
)

logger = logging.getLogger('themisdb')

# Log-Levels verwenden
logger.debug("Connection pool initialized")      # DEBUG
logger.info("Query executed successfully")        # INFO
logger.warning("High memory usage detected")      # WARNING
logger.error("Query execution failed")            # ERROR
logger.critical("Database connection lost")       # CRITICAL
```

18.4.2 Strukturiertes Logging

JSON-Logging:

```
import json
import logging

class JSONFormatter(logging.Formatter):
    def format(self, record):
        log_data = {
            'timestamp': self.formatTime(record),
            'level': record.levelname,
            'logger': record.name,
            'message': record.getMessage(),
            'module': record.module,
            'function': record.funcName,
            'line': record.lineno
        }

        # Zusätzliche Felder
        if hasattr(record, 'query_id'):
            log_data['query_id'] = record.query_id
        if hasattr(record, 'user_id'):
            log_data['user_id'] = record.user_id
        if hasattr(record, 'duration_ms'):
            log_data['duration_ms'] = record.duration_ms

        return json.dumps(log_data)

# Handler konfigurieren
handler = logging.FileHandler('/var/log/themisdb/themisdb.json')
handler.setFormatter(JSONFormatter())
logger.addHandler(handler)

# Logging mit Context
logger.info(
    "Query executed",
    extra={
        'query_id': 'q123',
        'user_id': 'u456',
        'duration_ms': 45.2
    })
```

```
}  
)
```

18.4.3 ELK Stack Integration

Filebeat Konfiguration:

```
# filebeat.yml  
filebeat.inputs:  
  - type: log  
    enabled: true  
    paths:  
      - /var/log/themisdb/*.log  
    json.keys_under_root: true  
    json.add_error_key: true  
  
output.elasticsearch:  
  hosts: ["localhost:9200"]  
  index: "themisdb-logs-%{+yyyy.MM.dd}"  
  
setup.kibana:  
  host: "localhost:5601"
```

Logstash Pipeline:

```
# logstash.conf
input {
  beats {
    port => 5044
  }
}

filter {
  if [type] == "themisdb" {
    json {
      source => "message"
    }

    # Query-Latenz berechnen
    if [duration_ms] {
      ruby {
        code => "event.set('duration_s', event.get('duration_ms') / 1000.0)"
      }
    }

    # Geo-IP Enrichment
    geoip {
      source => "client_ip"
      target => "geoip"
    }
  }
}

output {
  elasticsearch {
    hosts => ["localhost:9200"]
    index => "themisdb-logs-%{+YYYY.MM.dd}"
  }
}
```

18.5 Distributed Tracing

18.5.1 Jaeger Integration

Jaeger Setup:

```
# Jaeger All-in-One starten
docker run -d \
  -e COLLECTOR_ZIPKIN_HTTP_PORT=9411 \
  -p 5775:5775/udp \
  -p 6831:6831/udp \
  -p 6832:6832/udp \
  -p 5778:5778 \
  -p 16686:16686 \
  -p 14268:14268 \
  -p 9411:9411 \
  jaegertracing/all-in-one:latest

# Zugriff: http://localhost:16686
```

18.5.2 OpenTelemetry Integration

Tracing-Code:

```
from opentelemetry import trace
from opentelemetry.sdk.trace import TracerProvider
from opentelemetry.sdk.trace.export import BatchSpanProcessor
from opentelemetry.exporter.jaeger.thrift import JaegerExporter
from opentelemetry.instrumentation.requests import RequestsInstrumentor

# Tracer konfigurieren
trace.set_tracer_provider(TracerProvider())
tracer = trace.get_tracer(__name__)

jaeger_exporter = JaegerExporter(
    agent_host_name='localhost',
    agent_port=6831,
)

trace.get_tracer_provider().add_span_processor(
    BatchSpanProcessor(jaeger_exporter)
)

# Requests instrumentieren
RequestsInstrumentor().instrument()

# Query mit Tracing
@tracer.start_as_current_span("execute_query")
def execute_query(query):
    span = trace.get_current_span()
    span.set_attribute("query.type", "SELECT")
    span.set_attribute("query.text", query)

    # Query ausführen
    with tracer.start_as_current_span("database_query"):
        result = db.execute(query)

    span.set_attribute("result.count", len(result))
    return result

# Multi-Service Tracing
@tracer.start_as_current_span("process_order")
```

```
def process_order(order_id):
    # Span 1: Order validieren
    with tracer.start_as_current_span("validate_order"):
        order = db.query(f"SELECT * FROM orders WHERE id = {order_id}")

    # Span 2: Inventory prüfen
    with tracer.start_as_current_span("check_inventory"):
        inventory = db.query(f"SELECT * FROM inventory WHERE product_id = {order['product_id']}")

    # Span 3: Payment verarbeiten
    with tracer.start_as_current_span("process_payment"):
        payment = process_payment_service(order)

    return {"status": "success"}
```

18.6 Alerting

18.6.1 Prometheus Alertmanager

Alert-Regeln:


```
# alerts.yml
groups:
  - name: themisdb
    interval: 30s
    rules:
      # High Query Latency
      - alert: HighQueryLatency
        expr: histogram_quantile(0.95, themisdb_query_duration_seconds_bucket) > 1.0
        for: 5m
        labels:
          severity: warning
        annotations:
          summary: "High query latency detected"
          description: "p95 query latency is {{ $value }}s"

      # Low Cache Hit Rate
      - alert: LowCacheHitRate
        expr: themisdb_cache_hit_rate < 0.7
        for: 10m
        labels:
          severity: warning
        annotations:
          summary: "Low cache hit rate"
          description: "Cache hit rate is {{ $value }}"

      # High Connection Usage
      - alert: HighConnectionUsage
        expr: (themisdb_active_connections / themisdb_connection_pool_size) > 0.8
        for: 5m
        labels:
          severity: warning
        annotations:
          summary: "Connection pool nearly exhausted"
          description: "{{ $value | humanizePercentage }} of connections in use"

      # Database Down
      - alert: DatabaseDown
        expr: up{job="themisdb"} == 0
```

```
    for: 1m
    labels:
      severity: critical
    annotations:
      summary: "ThemisDB instance is down"
      description: "Instance {{ $labels.instance }} is unreachable"

# Replication Lag
- alert: HighReplicationLag
  expr: themisdb_replication_lag_seconds > 10
  for: 5m
  labels:
    severity: warning
  annotations:
    summary: "High replication lag"
    description: "Replication lag is {{ $value }}s"
```

18.6.2 Alertmanager Konfiguration

Alertmanager Config:

```
# alertmanager.yml
global:
  resolve_timeout: 5m

route:
  group_by: ['alertname', 'cluster']
  group_wait: 10s
  group_interval: 10s
  repeat_interval: 12h
  receiver: 'team-db'

routes:
  - match:
      severity: critical
    receiver: 'pagerduty'

  - match:
      severity: warning
    receiver: 'slack'

receivers:
  - name: 'team-db'
    email_configs:
      - to: 'db-team@company.com'
        from: 'alertmanager@company.com'
        smarthost: 'smtp.company.com:587'

  - name: 'pagerduty'
    pagerduty_configs:
      - service_key: 'YOUR_PAGERDUTY_KEY'

  - name: 'slack'
    slack_configs:
      - api_url: 'https://hooks.slack.com/services/YOUR/SLACK/WEBHOOK'
        channel: '#db-alerts'
        text: '{{ range .Alerts }}{{ .Annotations.summary }}\n{{ end }}
```

18.7 Application Performance Monitoring (APM)

18.7.1 Query Performance Tracking

Slow Query Logging:

```
import time
from functools import wraps

SLOW_QUERY_THRESHOLD = 1.0 # Sekunden

def track_query_performance(func):
    @wraps(func)
    def wrapper(*args, **kwargs):
        start_time = time.time()
        query = args[0] if args else kwargs.get('query')

        try:
            result = func(*args, **kwargs)
            duration = time.time() - start_time

            # Slow Query loggen
            if duration > SLOW_QUERY_THRESHOLD:
                logger.warning(
                    "Slow query detected",
                    extra={
                        'query': query,
                        'duration_ms': duration * 1000,
                        'threshold_ms': SLOW_QUERY_THRESHOLD * 1000
                    }
                )

            # Metriken updaten
            query_duration.labels(type=get_query_type(query)).observe(duration)

            return result
        except Exception as e:
            duration = time.time() - start_time
            logger.error(
                "Query execution failed",
                extra={
                    'query': query,
                    'duration_ms': duration * 1000,
                    'error': str(e)
                }
            )
```

```
        }
    )
    raise

    return wrapper

@track_query_performance
def execute_query(query):
    return db.execute(query)
```

18.7.2 Transaction Monitoring

Transaction Tracking:

```
class TransactionMonitor:
    def __init__(self):
        self.active_transactions = {}
        self.transaction_counter = Counter('themisdb_transactions_total',
                                           'Total transactions',
                                           ['status'])
        self.transaction_duration = Histogram('themisdb_transaction_duration_seconds',
                                              'Transaction duration')

    def begin_transaction(self, txn_id):
        self.active_transactions[txn_id] = {
            'start_time': time.time(),
            'queries': []
        }

    def add_query(self, txn_id, query):
        if txn_id in self.active_transactions:
            self.active_transactions[txn_id]['queries'].append(query)

    def commit_transaction(self, txn_id):
        if txn_id in self.active_transactions:
            duration = time.time() - self.active_transactions[txn_id]['start_time']
            query_count = len(self.active_transactions[txn_id]['queries'])

            self.transaction_counter.labels(status='committed').inc()
            self.transaction_duration.observe(duration)

            logger.info(
                "Transaction committed",
                extra={
                    'txn_id': txn_id,
                    'duration_ms': duration * 1000,
                    'query_count': query_count
                }
            )

            del self.active_transactions[txn_id]
```

```
def rollback_transaction(self, txn_id):
    if txn_id in self.active_transactions:
        duration = time.time() - self.active_transactions[txn_id]['start_time']

        self.transaction_counter.labels(status='rolled_back').inc()

        logger.warning(
            "Transaction rolled back",
            extra={
                'txn_id': txn_id,
                'duration_ms': duration * 1000
            }
        )

    del self.active_transactions[txn_id]
```

18.8 Health Checks

18.8.1 Liveness & Readiness Probes

Health Check Endpoints:


```
from flask import Flask, jsonify
import time

app = Flask(__name__)

@app.route('/health/live')
def liveness():
    """Prüft ob die Anwendung läuft."""
    return jsonify({'status': 'ok'}), 200

@app.route('/health/ready')
def readiness():
    """Prüft ob die Anwendung Requests bearbeiten kann."""
    try:
        # Datenbankverbindung testen
        db.execute("SELECT 1")

        # Connection Pool prüfen
        stats = db.statistics()
        if stats['connections']['available'] == 0:
            return jsonify({
                'status': 'not_ready',
                'reason': 'Connection pool exhausted'
            }), 503

        # Replikations-Lag prüfen
        if stats.get('replication_lag', 0) > 30:
            return jsonify({
                'status': 'not_ready',
                'reason': 'High replication lag'
            }), 503

        return jsonify({'status': 'ready'}), 200

    except Exception as e:
        return jsonify({
            'status': 'not_ready',
            'reason': str(e)
```

```
    }), 503

@app.route('/health/startup')
def startup():
    """Prüft ob die Anwendung vollständig gestartet ist."""
    # Initialisierungs-Checks
    checks = {
        'database_connected': check_db_connection(),
        'cache_initialized': check_cache(),
        'migrations_applied': check_migrations()
    }

    if all(checks.values()):
        return jsonify({'status': 'started', 'checks': checks}), 200
    else:
        return jsonify({'status': 'starting', 'checks': checks}), 503
```

18.8.2 Kubernetes Probes

Pod-Konfiguration:

```
apiVersion: v1
kind: Pod
metadata:
  name: themisdb
spec:
  containers:
    - name: themisdb
      image: themisdb:latest
      ports:
        - containerPort: 8529

      livenessProbe:
        httpGet:
          path: /health/live
          port: 8529
        initialDelaySeconds: 30
        periodSeconds: 10
        timeoutSeconds: 5
        failureThreshold: 3

      readinessProbe:
        httpGet:
          path: /health/ready
          port: 8529
        initialDelaySeconds: 10
        periodSeconds: 5
        timeoutSeconds: 3
        failureThreshold: 3

      startupProbe:
        httpGet:
          path: /health/startup
          port: 8529
        initialDelaySeconds: 0
        periodSeconds: 10
        timeoutSeconds: 3
        failureThreshold: 30
```

18.9 Performance Profiling

18.9.1 Query Profiling

EXPLAIN ANALYZE:

```
-- Query Plan analysieren
EXPLAIN ANALYZE
SELECT c.name, COUNT(o.id) as order_count
FROM customers c
LEFT JOIN orders o ON c.id = o.customer_id
WHERE c.country = 'DE'
GROUP BY c.name
ORDER BY order_count DESC
LIMIT 10;

-- Output:
-- -> Limit (cost=1245.34..1245.36 rows=10)
--   -> Sort (cost=1245.34..1276.42 rows=12432)
--         Sort Key: order_count DESC
--         -> HashAggregate (cost=956.23..1080.55 rows=12432)
--               -> Hash Left Join (cost=345.67..876.12 rows=16040)
--                     Hash Cond: (c.id = o.customer_id)
--                     -> Index Scan using idx_customers_country on customers c
--                           Index Cond: (country = 'DE')
--                     -> Hash (cost=234.56..234.56 rows=8884)
--                           -> Seq Scan on orders o
```

18.9.2 Python Profiling

cProfile Integration:

```
import cProfile
import pstats
from pstats import SortKey

def profile_query(query):
    profiler = cProfile.Profile()
    profiler.enable()

    # Query ausführen
    result = db.execute(query)

    profiler.disable()

    # Statistiken ausgeben
    stats = pstats.Stats(profiler)
    stats.sort_stats(SortKey.CUMULATIVE)
    stats.print_stats(10)

    return result

# Line Profiler
from line_profiler import LineProfiler

@profile
def complex_operation():
    # Schritt 1
    data = db.query("SELECT * FROM large_table")

    # Schritt 2
    processed = [process_row(row) for row in data]

    # Schritt 3
    db.bulk_insert("results", processed)

# Memory Profiler
from memory_profiler import profile as memory_profile

@memory_profile
```

```
def memory_intensive_operation():  
    large_dataset = db.query("SELECT * FROM huge_table")  
    return process_dataset(large_dataset)
```

18.10 Best Practices

18.10.1 Monitoring-Strategie

Golden Signals:

1. **Latency:** Zeit für Request-Bearbeitung
2. **Traffic:** Anzahl Requests pro Zeiteinheit
3. **Errors:** Rate fehlgeschlagener Requests
4. **Saturation:** Auslastung der Ressourcen

RED Method (für Services): - **Rate:** Requests pro Sekunde - **Errors:** Fehlerrate - **Duration:** Latenz-Verteilung

USE Method (für Ressourcen): - **Utilization:** Prozentuale Auslastung - **Saturation:** Wartezeit/Queueing - **Errors:** Fehlerzähler

18.10.2 Retention Policies

Datenaufbewahrung:

```
# Prometheus Retention
prometheus:
  retention:
    time: 15d
    size: 50GB

# Aggregierte Metriken
recording_rules:
  - name: themisdb_5m
    interval: 5m
    rules:
      - record: themisdb:query_rate:5m
        expr: rate(themisdb_queries_total[5m])

      - record: themisdb:query_latency_p95:5m
        expr: histogram_quantile(0.95, themisdb_query_duration_seconds_bucket[5m])
```

Log-Rotation:

```
# /etc/logrotate.d/themisdb
/var/log/themisdb/*.log {
    daily
    rotate 7
    compress
    delaycompress
    missingok
    notifempty
    create 0640 themisdb themisdb
    sharedscripts
    postrotate
        systemctl reload themisdb
    endscript
}
```

18.10.3 Dashboard-Design

Effektive Dashboards:

1. **Übersichts-Dashboard:** Hochlevel-Metriken, Status-Indikatoren
2. **Detail-Dashboards:** Tiefere Einblicke für spezifische Bereiche
3. **Drill-Down:** Von Übersicht zu Details navigieren
4. **Zeitfenster:** Flexible Zeitbereichs-Auswahl
5. **Annotations:** Deployment-Marker, Incidents

Dashboard-Struktur: - **Oberste Zeile:** SLI/SLO Status, Alerts - **Zweite Zeile:** Golden Signals (Latency, Traffic, Errors, Saturation) - **Weitere Zeilen:** Spezifische Metriken nach Kategorie

Zusammenfassung

Monitoring und Observability sind essentiell für den Betrieb von ThemisDB:

- **Metriken:** Prometheus für Sammlung und Speicherung
- **Visualisierung:** Grafana für Dashboards
- **Logging:** ELK Stack für Log-Aggregation und Analyse
- **Tracing:** Jaeger/OpenTelemetry für Distributed Tracing
- **Alerting:** Proaktive Benachrichtigung bei Problemen
- **Health Checks:** Kubernetes-Integration für Orchestrierung
- **Profiling:** Performance-Analyse und Optimierung

Mit diesen Tools und Praktiken können Sie ThemisDB effektiv überwachen und Probleme frühzeitig erkennen.

Kapitel 19: Kapitel 19b - Observability

Status: Production-Ready

Version: v1.3.0


Last Updated: December 30, 2025

19.1 Übersicht

ThemisDB implementiert ein umfassendes Production-Grade Monitoring- und Observability-Stack basierend auf branchenüblichen Open-Source-Tools. Die Architektur folgt den **Three Pillars of Observability**: Metrics (Prometheus), Logs (Strukturierte Logs), und Traces (OpenTelemetry).

Design-Prinzipien: - **Metrics-First**: Prometheus als primäre Metriken-Datenbank - **Low-Cardinality**: Vermeidung von High-Cardinality-Labels (keine UUIDs/Timestamps in Labels) - **Cumulative Histograms**: Alle Histogramme folgen Prometheus-Konventionen - **Zero-Config Development**: Jaeger läuft Out-of-the-Box via Docker - **Production-Hardened**: Grafana Dashboards mit SLI/SLO-Tracking

Architektur-Übersicht:



Deployment-Architektur: - **Development:** Jaeger All-in-One Container für lokales Tracing - **Staging:** Grafana Tempo + Prometheus + Grafana Stack - **Production:** Multi-Node Prometheus Federation + Thanos für Long-Term Storage

Abb. 19.1: Monitoring-Stack-Übersicht

19.2 Prometheus Metrics

ThemisDB exportiert **48 Metriken** über den `/metrics` Endpoint im Prometheus Text Format. Alle Metriken verwenden konsistente Naming-Konventionen und Low-Cardinality-Labels.

19.2.1 Naming-Konventionen

Präfixe: - `vccdb_*`: ThemisDB-spezifische Metriken - `rocksdb_*`: RocksDB Storage-Metriken - `themis_*`: Index- und Query-Metriken - `process_*`: System-Metriken (Uptime)

Suffixe: - `_total`: Monoton steigende Counter - `_bytes`: Größenangaben in Bytes - `_seconds`: Zeitangaben in Sekunden - `_microseconds`: Latenz in Mikrosekunden - `_ms`: Latenz in Millisekunden

19.2.2 Server-Metriken

`vccdb_requests_total` (Counter)

Gesamtzahl der HTTP-Requests seit Server-Start.

Labels: - `method`: HTTP-Methode (GET, POST, PUT, DELETE) - `route`: Request-Route (z.B. `/entities/{key}`, `/query`, `/vector/search`)

Beispiel-Output:

```
vccdb_requests_total{method="GET",route="/entities/{key}"} 1234
vccdb_requests_total{method="POST",route="/query"} 567
vccdb_requests_total{method="POST",route="/aql"} 890
```

PromQL-Query-Beispiele:

```
# Requests pro Sekunde (letzte 5 Minuten)
rate(vccdb_requests_total[5m])

# Requests nach Route gruppiert
sum by (route) (rate(vccdb_requests_total[5m]))

# Top 5 aktivste Routes
topk(5, sum by (route) (rate(vccdb_requests_total[5m])))
```

Die Metrik wird im `HttpServer` nach jedem abgeschlossenen Request inkrementiert. Das `route`-Label enthält die **Route-Template** (z.B. `/entities/{key}`), nicht den konkreten Key-Wert, um Cardinality niedrig zu halten.

vccdb_errors_total (Counter)

Gesamtzahl der Fehler-Responses (HTTP 4xx/5xx).

Labels: - `status_code`: HTTP-Status-Code (400, 404, 500, 503) - `route`: Request-Route

Beispiel-Output:

```
vccdb_errors_total{status_code="404",route="/entities/{key}"} 12
vccdb_errors_total{status_code="500",route="/query"} 3
vccdb_errors_total{status_code="400",route="/aql"} 5
```

PromQL-Query-Beispiele:

```
# Fehlerrate (Fehler pro Sekunde)
rate(vccdb_errors_total[5m])

# Error Rate Ratio (Prozentsatz fehlgeschlagener Requests)
100 * rate(vccdb_errors_total[5m]) / rate(vccdb_requests_total[5m])

# Alert: Error Rate > 5%
rate(vccdb_errors_total[5m]) / rate(vccdb_requests_total[5m]) > 0.05
```

Diese Metrik ist entscheidend für **Service Level Indicators (SLIs)**. Ein Production-Service sollte eine Error Rate < 0.1% (99.9% Success Rate) anstreben.

vccdb_qps (Gauge)

Queries per Second - aktuelle Request-Rate berechnet als exponentieller gleitender Durchschnitt.

Beispiel-Output:

```
vccdb_qps 123.45
```

PromQL-Query-Beispiele:

```
# QPS-Durchschnitt (letzte Stunde)
avg_over_time(vccdb_qps[1h])

# QPS-Maximum (letzte Stunde)
max_over_time(vccdb_qps[1h])

# QPS-Trend (steigende/fallende Last)
deriv(vccdb_qps[5m])
```

Der QPS-Wert wird alle 5 Sekunden neu berechnet mit der Formel:

$$\text{QPS}_{\text{new}} = \alpha * \text{QPS}_{\text{current}} + (1-\alpha) * \text{QPS}_{\text{old}}$$

mit Dämpfungsfaktor $\alpha = 0.7$ für schnelle Reaktion auf Last-Änderungen.

process_uptime_seconds (Gauge)

Server-Laufzeit in Sekunden seit Prozess-Start.

Beispiel-Output:

```
process_uptime_seconds 86400
```

PromQL-Query-Beispiele:

```
# Uptime in Tagen
process_uptime_seconds / 86400

# Server neu gestartet in letzten 5 Minuten?
process_uptime_seconds < 300
```

Diese Metrik ist nützlich für die Erkennung von Server-Restarts und zur Korrelation mit Performance-Problemen nach Deployments.

19.2.3 Latenz-Histogramme

ThemisDB verwendet **kumulative Buckets** gemäß Prometheus-Spezifikation. Jeder Bucket mit `le="X"` enthält die Anzahl der Beobachtungen $\leq X$.

Bucket-Definitionen

HTTP-Request-Latenz (Mikrosekunden):

```
100, 500, 1000, 5000, 10000, 50000, 100000, 500000, 1000000, 5000000, +Inf
```

Page-Fetch-Latenz (Millisekunden):

```
1, 5, 10, 25, 50, 100, 250, 500, 1000, 5000, +Inf
```

Die Bucket-Grenzen sind so gewählt, dass sie typische Latenz-Verteilungen abdecken: - **Schnell**: < 1ms (In-Memory-Index-Lookup) - **Normal**: 1-10ms (RocksDB Point-Lookup mit Block Cache Hit) - **Langsam**: 10-100ms (Disk I/O) - **Sehr langsam**: > 100ms (Full Scan, Cold Cache)

vccdb_latency_bucket_microseconds (Histogram)

HTTP-Request-Latenz von Anfang des Request-Handlings bis zum vollständigen Response.

Beispiel-Output:

```
vccdb_latency_bucket_microseconds{le="100"} 45
vccdb_latency_bucket_microseconds{le="500"} 123
vccdb_latency_bucket_microseconds{le="1000"} 234
vccdb_latency_bucket_microseconds{le="5000"} 450
vccdb_latency_bucket_microseconds{le="10000"} 480
vccdb_latency_bucket_microseconds{le="50000"} 495
vccdb_latency_bucket_microseconds{le="100000"} 498
vccdb_latency_bucket_microseconds{le="500000"} 499
vccdb_latency_bucket_microseconds{le="1000000"} 500
vccdb_latency_bucket_microseconds{le="5000000"} 500
vccdb_latency_bucket_microseconds{le="+Inf"} 500
vccdb_latency_sum_microseconds 1234567
vccdb_latency_count 500
```

PromQL-Query-Beispiele:

```
# P50 Latenz (Median, Mikrosekunden)
histogram_quantile(0.50, rate(vccdb_latency_bucket_microseconds[5m]))

# P95 Latenz (95. Perzentil)
histogram_quantile(0.95, rate(vccdb_latency_bucket_microseconds[5m]))

# P99 Latenz (99. Perzentil)
histogram_quantile(0.99, rate(vccdb_latency_bucket_microseconds[5m]))

# Durchschnittliche Latenz
rate(vccdb_latency_sum_microseconds[5m]) / rate(vccdb_latency_count[5m])

# Prozentsatz Requests unter 1ms (1000 µs)
100 * sum(rate(vccdb_latency_bucket_microseconds{le="1000"}[5m])) / sum(rate(vccdb_latency_count[5m]))

# Latenz-Heatmap (Grafana Heatmap Panel)
sum by (le) (rate(vccdb_latency_bucket_microseconds[5m]))
```

Performance-Interpretation: - **P50 < 500µs**: Exzellent (In-Memory-Operationen) - **P95 < 5ms**: Gut (Block Cache Hit Rate > 95%) - **P99 < 50ms**: Akzeptabel (Gelegentliche Disk I/O) - **P99 > 100ms**: Schlecht (Hohe Disk-Latenz oder Full Scans)

vccdb_page_fetch_time_ms_bucket (Histogram)

Latenz für Cursor-Pagination-Fetches (GET /cursor/{cursor_id}).

Beispiel-Output:

```
vccdb_page_fetch_time_ms_bucket{le="1"} 89
vccdb_page_fetch_time_ms_bucket{le="5"} 156
vccdb_page_fetch_time_ms_bucket{le="10"} 234
vccdb_page_fetch_time_ms_bucket{le="25"} 245
vccdb_page_fetch_time_ms_bucket{le="50"} 248
vccdb_page_fetch_time_ms_bucket{le="+Inf"} 250
vccdb_page_fetch_time_ms_sum 2345.67
vccdb_page_fetch_time_ms_count 250
```

PromQL-Query-Beispiele:

```
# P95 Page-Fetch-Latenz
histogram_quantile(0.95, rate(vccdb_page_fetch_time_ms_bucket[5m]))

# Prozentsatz Page-Fetches unter 10ms
100 * sum(rate(vccdb_page_fetch_time_ms_bucket{le="10"}[5m])) / sum(rate(vccdb_page_fetch_time_ms_bucket[5m]))
```

Diese Metrik ist speziell für Pagination-Performance relevant. Hohe P99-Werte (> 100ms) deuten auf ineffiziente Cursor-Implementierungen oder Cold Cache-Probleme hin.

19.2.4 RocksDB-Metriken

RocksDB-Metriken werden aus der `GetProperty()` API ausgelesen und als Prometheus-Gauges exportiert. Diese Metriken erlauben die Überwachung der Storage-Layer-Gesundheit.

rocksdb_block_cache_usage_bytes (Gauge)

Aktuell verwendeter Block-Cache in Bytes.

Beispiel-Output:

```
rocksdb_block_cache_usage_bytes 1073741824
```


PromQL-Query-Beispiele:

```
# Cache-Auslastung in %  
100 * rocksdb_block_cache_usage_bytes / rocksdb_block_cache_capacity_bytes  
  
# Alert: Cache-Auslastung > 95%  
100 * rocksdb_block_cache_usage_bytes / rocksdb_block_cache_capacity_bytes > 95
```

rocksdb_block_cache_capacity_bytes (Gauge)

Konfigurierte Block-Cache-Kapazität in Bytes (aus `config.json`).

Beispiel-Output:

```
rocksdb_block_cache_capacity_bytes 2147483648
```

Typische Werte: - **Development**: 512 MB - 1 GB - **Staging**: 2-4 GB - **Production**: 8-16 GB (25% des verfügbaren RAM)

rocksdb_estimate_num_keys (Gauge)

Geschätzte Anzahl Keys in der Datenbank (basierend auf SST-Metadaten).

Beispiel-Output:

```
rocksdb_estimate_num_keys 1234567
```

Hinweis: Dies ist eine **Schätzung**, nicht exakt. Für exakte Counts verwenden Sie `SELECT COUNT(*)` Queries.

rocksdb_pending_compaction_bytes (Gauge)

Bytes, die auf Compaction warten. Hohe Werte (> 10 GB) können zu erhöhter Latenz führen.

Beispiel-Output:

```
rocksdb_pending_compaction_bytes 1234567890
```

PromQL-Query-Beispiele:

```
# Alert: Compaction-Backlog > 10 GB
rocksdb_pending_compaction_bytes > 10000000000

# Compaction-Backlog-Trend
deriv(rocksdb_pending_compaction_bytes[10m])
```

Ursachen für hohen Backlog: - Zu langsame Disk (SATA statt NVMe) - Zu kleine

`max_background_compactions` (Default: 4) - Sehr hohe Write-Rate (> 100K writes/sec)

Lösungen: - Erhöhe `max_background_compactions` auf 8-16 - Nutze NVMe für WAL und SSTables - Aktiviere Level Compaction (statt Universal)

rocksdb_memtable_size_bytes (Gauge)

Aktuelle Memtable-Größe in Bytes.

Beispiel-Output:

```
rocksdb_memtable_size_bytes 67108864
```

Die Memtable wird geflusht, wenn sie die konfigurierte `write_buffer_size` erreicht (Default: 64 MB). Mehrere Memtables können gleichzeitig aktiv sein (`max_write_buffer_number`: Default 2).

rocksdb_files_per_level (Gauge)

Anzahl SST-Dateien pro LSM-Tree-Level.

Labels: - `level`: LSM-Tree-Level (0, 1, 2, 3, 4, 5, 6)

Beispiel-Output:

```

rocksdb_files_per_level{level="0"} 3
rocksdb_files_per_level{level="1"} 12
rocksdb_files_per_level{level="2"} 45
rocksdb_files_per_level{level="3"} 123
rocksdb_files_per_level{level="4"} 234
rocksdb_files_per_level{level="5"} 456
rocksdb_files_per_level{level="6"} 789

```

PromQL-Query-Beispiele:

```

# Gesamtzahl SST-Dateien
sum(rocksdb_files_per_level)

# Alert: Zu viele L0-Dateien (> 10 → Write-Stall-Risiko)
rocksdb_files_per_level{level="0"} > 10

```

LSM-Tree-Levels: - **L0:** Frisch geflushed Memtables, unsortiert, können sich überlappen - **L1-L6:** Sortierte Runs, keine Überlappungen innerhalb eines Levels - **L6:** Coldest data (90% der Daten), ZSTD-komprimiert (2.8x Ratio)

19.2.5 Index-Metriken

vccdb_index_rebuild_total (Counter)

Gesamtzahl Index-Rebuild-Operationen.

Labels: - `table`: Tabellename - `column`: Spaltenname

Beispiel-Output:

```

vccdb_index_rebuild_total{table="users",column="email"} 3
vccdb_index_rebuild_total{table="orders",column="customer_id"} 5

```

Index-Rebuilds werden getriggert durch: - `CREATE INDEX` Statement (Neuer Index) - `ANALYZE` Statement (Index-Statistik-Refresh) - Server-Neustart mit geändertem Schema

vccdb_index_rebuild_duration_seconds (Counter)

Gesamt-Zeit für Index-Rebuilds in Sekunden.

Labels: - `table`: Tabellenname - `column`: Spaltenname

Beispiel-Output:

```
vccdb_index_rebuild_duration_seconds{table="users",column="email"} 123.45
```

PromQL-Query-Beispiele:

```
# Durchschnittliche Rebuild-Dauer pro Index
vccdb_index_rebuild_duration_seconds / vccdb_index_rebuild_total

# Langsamste Index-Rebuilds
topk(5, vccdb_index_rebuild_duration_seconds / vccdb_index_rebuild_total)
```

Performance-Benchmark: - **B-Tree-Index:** ~50K entities/sec - **Hash-Index:** ~100K entities/sec - **Vector-Index (HNSW):** ~5K entities/sec (mit Construction-Parameter M=16, efConstruction=200)

themis_index_cursor_anchor_hits_total (Counter)

Anzahl erfolgreicher Cursor-Anchor-Lookups für Pagination.

Beispiel-Output:

```
themis_index_cursor_anchor_hits_total 567
```

Diese Metrik trackt, wie oft Cursors erfolgreich fortgesetzt wurden. Eine niedrige Hit-Rate deutet auf abgelaufene Cursors (TTL) oder ungültige Cursor-IDs hin.

themis_index_range_scan_steps_total (Counter)

Gesamtzahl Range-Scan-Schritte (Index-Traversierungen).

Beispiel-Output:

```
themis_index_range_scan_steps_total 12345
```

PromQL-Query-Beispiele:

```
# Range-Scan-Schritte pro Sekunde
rate(themis_index_range_scan_steps_total[5m])

# Durchschnittliche Schritte pro Query (kombiniert mit vccdb_requests_total)
rate(themis_index_range_scan_steps_total[5m]) / rate(vccdb_requests_total{route="/query"}[5m])
```

Hohe Range-Scan-Zahlen (> 1M steps/sec) deuten auf ineffiziente Queries mit breiten Ranges hin (z.B. `age > 18` ohne zusätzliche Prädikate).

19.2.6 Vector-Index-Metriken

vccdb_vector_index_size_bytes (Gauge)

Geschätzte Größe des In-Memory-Vector-Index in Bytes.

Beispiel-Output:

```
vccdb_vector_index_size_bytes 536870912
```

Berechnung:

```
Index Size ≈ N * (D * 4 bytes + M * 2 bytes)
```

Für 1M Vektoren, Dimension 768, M=16:

```
Index Size = 1M * (768*4 + 16*2) = 3.1 GB
```

vccdb_vector_search_duration_ms (Histogram)

Vector-Similarity-Search-Latenz in Millisekunden.

Beispiel-Output:

```
vccdb_vector_search_duration_ms_bucket{le="1"} 45
vccdb_vector_search_duration_ms_bucket{le="5"} 123
vccdb_vector_search_duration_ms_bucket{le="10"} 234
vccdb_vector_search_duration_ms_bucket{le="+Inf"} 250
```

PromQL-Query-Beispiele:

```
# P95 Vector-Search-Latenz
histogram_quantile(0.95, rate(vccdb_vector_search_duration_ms_bucket[5m]))
```

Performance-Benchmark (1M Vektoren, 768-dim, M=16, efSearch=64): - **P50:** 1.2 ms - **P95:** 3.5 ms - **P99:** 8.2 ms

vccdb_vector_batch_insert_duration_ms (Histogram)

Batch-Insert-Latenz für Vektor-Batches.

vccdb_vector_batch_insert_items_total (Counter)

Gesamtzahl eingefügter Vector-Items.

PromQL-Query-Beispiele:

```
# Durchschnittliche Batch-Größe
rate(vccdb_vector_batch_insert_items_total[5m]) / rate(vccdb_vector_batch_insert_total[5m])
```

Typische Batch-Größen: - **Klein:** 10-100 (Echtzeit-Ingestion) - **Mittel:** 100-1000 (Bulk-Import) - **Groß:** 1000-10000 (Initial Load)

19.3 Grafana Dashboards

ThemisDB liefert **3 vorgefertigte Grafana-Dashboards** für unterschiedliche Monitoring-Szenarien.

19.3.1 Dashboard 1: Server-Übersicht

Zweck: High-Level-Übersicht über Server-Gesundheit und Performance.

Panels:

1. **QPS (Queries per Second)** `promql vccdb_qps`
2. Visualization: Graph
3. Y-Axis: Queries/sec
4. Thresholds: Warning > 5000, Critical > 10000
5. **Error Rate** `promql 100 * rate(vccdb_errors_total[5m]) / rate(vccdb_requests_total[5m])`
6. Visualization: Graph
7. Y-Axis: Percent
8. Thresholds: Warning > 1%, Critical > 5%
9. SLI-Target: < 0.1% (99.9% Success Rate)
10. **Request Latency (P50, P95, P99)** `promql histogram_quantile(0.50, rate(vccdb_latency_bucket_microseconds[5m])) / 1000 # ms`
`histogram_quantile(0.95, rate(vccdb_latency_bucket_microseconds[5m])) / 1000`
`histogram_quantile(0.99, rate(vccdb_latency_bucket_microseconds[5m])) / 1000`
11. Visualization: Graph
12. Y-Axis: Milliseconds
13. SLI-Targets: P50 < 1ms, P95 < 5ms, P99 < 50ms
14. **Uptime** `promql process_uptime_seconds / 86400`
15. Visualization: Stat
16. Unit: Days
17. Color: Green > 7d, Yellow > 1d, Red < 1d
18. **Requests by Route (Top 5)** `promql topk(5, sum by (route) (rate(vccdb_requests_total[5m])))`
19. Visualization: Bar Gauge
20. Y-Axis: Requests/sec

19.3.2 Dashboard 2: RocksDB Health

Zweck: Monitoring der Storage-Layer-Performance und Capacity Planning.

Panels:

1. **Block Cache Hit Rate** `promql 100 * rocksdb_block_cache_usage_bytes / rocksdb_block_cache_capacity_bytes`

2. Visualization: Gauge

3. Unit: Percent

4. Thresholds: Green > 80%, Yellow > 60%, Red < 60%

5. **Compaction Backlog** `promql rocksdb_pending_compaction_bytes / 1e9 # GB`

6. Visualization: Graph

7. Y-Axis: Gigabytes

8. Threshold: Critical > 10 GB

9. **Keys Estimate** `promql rocksdb_estimate_num_keys`

10. Visualization: Stat

11. Unit: Short (1.23M)

12. Trend: Show sparkline

13. **SST Files per Level** `promql sum by (level) (rocksdb_files_per_level)`

14. Visualization: Bar Gauge (Horizontal)

15. X-Axis: Number of Files

16. Y-Axis: Level (0-6)

17. **Memtable Size** `promql rocksdb_memtable_size_bytes / 1e6 # MB`

18. Visualization: Graph

19. Y-Axis: Megabytes

20. Threshold: Warning > 128 MB (2x write_buffer_size)

21. **LSM-Tree Amplification** `promql sum(rocksdb_files_per_level{level!="0"}) / rocksdb_files_per_level{level="0"}`

22. Visualization: Stat

23. Unit: None

24. Interpretation: Higher = Better compaction efficiency

19.3.3 Dashboard 3: Vector Operations

Zweck: Monitoring von Vector-Search-Performance und Index-Größe.

Panels:

1. **Vector Index Size** `promql vccdb_vector_index_size_bytes / 1e9 # GB`
 2. Visualization: Gauge
 3. Unit: Gigabytes
 4. Thresholds: Warning > 8 GB, Critical > 16 GB (Memory Pressure)
 5. **Search Latency P95** `promql histogram_quantile(0.95, rate(vccdb_vector_search_duration_ms_bucket[5m]))`
 6. Visualization: Graph
 7. Y-Axis: Milliseconds
 8. Target: < 5ms
 9. **Batch Insert Rate** `promql rate(vccdb_vector_batch_insert_items_total[5m])`
 10. Visualization: Graph
 11. Y-Axis: Items/sec
 12. Benchmark: > 5000 items/sec (Production)
 13. **Average Batch Size** `promql rate(vccdb_vector_batch_insert_items_total[5m]) / rate(vccdb_vector_batch_insert_total[5m])`
 14. Visualization: Stat
 15. Unit: Items
 16. Optimal: 100-1000 (Trade-off: Latenz vs Throughput)
 17. **Delete Rate** `promql rate(vccdb_vector_delete_by_filter_items_total[5m])`
 18. Visualization: Graph
 19. Y-Axis: Items/sec
-

19.4 OpenTelemetry Distributed Tracing

ThemisDB implementiert **Distributed Tracing** via OpenTelemetry für Production-Debugging und Performance-Analyse komplexer Multi-Component-Queries.

19.4.1 Architektur

Komponenten: 1. **Tracer Wrapper** (`utils/tracing.h` / `.cpp`) - Initialisierung des OTLP HTTP Exporters - TracerProvider mit Resource Attributes (service.name, version) - SimpleSpanProcessor für sofortigen Export

1. Span RAII Wrapper

2. `Tracer::Span`: Move-only Span mit automatischem `end()` im Destruktor
3. `ScopedSpan`: Convenience-Wrapper für lokale Spans
4. Attribute-Support: `setAttribute(key, value)` für string, int64, double, bool

5. No-Op Fallback

6. Wenn `THEMIS_ENABLE_TRACING` nicht definiert, sind alle Methoden No-Ops
7. Kein Linking gegen OpenTelemetry-Libraries notwendig

Datenfluss:

```

HTTP Request → ScopedSpan("handleAqlQuery")
               ↓
        QueryEngine::executeQuery() → ScopedSpan("executeQuery")
               ↓
        Index Scans → Child Spans
               ↓
        OTLP HTTP Exporter → Jaeger/Tempo
  
```

19.4.2 Instrumentierte Komponenten

HTTP-Handler (Top-Level Spans)

- **GET** /entities/:key: `entity.key`, `entity.size_bytes`
- **PUT** /entities/:key: `entity.key`, `entity.table`, `entity.pk`, `entity.size_bytes`, `entity.cdc_recorded`
- **DELETE** /entities/:key: `entity.key`, `entity.table`, `entity.pk`, `entity.cdc_recorded`
- **POST** /query: `query.table`, `query.predicates_count`, `query.exec_mode`, `query.result_count`

- **POST /query/aql:** `aql.query`, `aql.explain`, `aql.optimize`, `aql.allow_full_scan`, `aql.result_count`
- **POST /graph/traverse:** `graph.start_vertex`, `graph.max_depth`, `graph.visited_count`
- **POST /vector/search:** `vector.dimension`, `vector.k`, `vector.results_count`

Beispiel-Trace:

```
[Span: handleAqlQuery, Duration: 23.5ms]
├─ [Span: aql.parse, Duration: 0.8ms]
│   └─ Attributes: aql.query_length=156
├─ [Span: aql.translate, Duration: 1.2ms]
└─ [Span: aql.for, Duration: 21.2ms]
    ├─ Attributes: for.table="users", for.predicates_count=2, for.result_count=123
    ├─ [Span: index.scanEqual, Duration: 8.5ms]
    │   └─ Attributes: index.table="users", index.column="email", index.result_count=1
    └─ [Span: index.scanRange, Duration: 12.1ms]
        └─ Attributes: index.table="users", index.column="age", index.result_count=122
```

AQL Execution Pipeline (Operator-Level Spans)

- **aql.parse:** `aql.query_length` - Parsen der AQL-Query in AST
- **aql.translate** - Übersetzung des AST in ConjunctiveQuery oder TraversalQuery
- **aql.for:** `for.table`, `for.predicates_count`, `for.range_predicates_count`, `for.order_by`, `for.order_desc`, `for.result_count`, `for.exec_mode`
- **aql.filter** - Filterung der Ergebnisse
 - Bei Traversal: `filter.evaluations_total`, `filter.short_circuits`
- **aql.limit:** `limit.offset`, `limit.count`, `limit.input_count`, `limit.output_count`
- **aql.collect:** `collect.input_count`, `collect.group_by_count`, `collect.aggregates_count`, `collect.group_count`
- **aql.return:** `return.input_count`
- **aql.traversal:** `traversal.start_vertex`, `traversal.min_depth`, `traversal.max_depth`, `traversal.direction`, `traversal.result_count`
- Child-Span: **aql.traversal.bfs:** `traversal.max_frontier_size_limit`, `traversal.max_results_limit`, `traversal.visited_count`, `traversal.edges_expanded`, `traversal.filter_evaluations`

Index-Scans (Child-Spans)

- **index.scanEqual:** `index.table`, `index.column`, `index.result_count`
 - **index.scanRange:** `index.table`, `index.column`, `index.result_count`,
`range.has_lower`, `range.has_upper`, `range.includeLower`, `range.includeUpper`
 - **or.disjunct.execute:** `disjunct.eq_count`, `disjunct.range_count`,
`disjunct.result_count`
-

19.4.3 Jaeger Integration (Development)

Jaeger via Docker starten:

```
docker run -d --name jaeger \  
-p 4318:4318 \  
-p 16686:16686 \  
jaegertracing/all-in-one:latest
```

Ports: - `4318`: OTLP HTTP receiver (für Themis) - `16686`: Jaeger UI

Themis konfigurieren (`config/config.json`):

```
{  
  "tracing": {  
    "enabled": true,  
    "service_name": "themis-dev",  
    "otlp_endpoint": "http://localhost:4318"  
  }  
}
```

Themis starten:

```
./build/Release/themis_server.exe
```

Traces anzeigen:

1. Öffne `http://localhost:16686` (Jaeger UI)

2. Wähle Service "themis-dev"

3. Klicke "Find Traces"

Trace-Analyse-Szenarien:

1. Langsame Query debuggen:

2. Filtere nach `duration > 100ms`

3. Identifiziere langsamste Spans (rot markiert)

4. Prüfe `index.scanRange` Spans auf breite Ranges

5. Full Scan Detection:

6. Suche nach Spans mit `query.exec_mode=full_scan`

7. Prüfe `fullscan.scanned` Attribut (sollte << 1M sein)

8. Index Efficiency:

9. Vergleiche `index.result_count` zwischen Scans

10. Hohe Counts + niedrige Query-Results = ineffizienter Index

19.4.4 Grafana Tempo Integration (Production)

Tempo via Docker Compose:

```
version: '3'
services:
  tempo:
    image: grafana/tempo:latest
    command: ["-config.file=/etc/tempo.yaml"]
    volumes:
      - ./tempo.yaml:/etc/tempo.yaml
      - ./tempo-data:/tmp/tempo
    ports:
      - "4318:4318"    # OTLP HTTP
      - "3200:3200"    # Tempo API

  grafana:
    image: grafana/grafana:latest
    ports:
      - "3000:3000"
    environment:
      - GF_AUTH_ANONYMOUS_ENABLED=true
      - GF_AUTH_ANONYMOUS_ORG_ROLE=Admin
    volumes:
      - ./grafana-datasources.yaml:/etc/grafana/provisioning/datasources/datasources.yaml
```

tempo.yaml:

```
server:
  http_listen_port: 3200

distributor:
  receivers:
    otlp:
      protocols:
        http:
          endpoint: 0.0.0.0:4318

storage:
  trace:
    backend: local
    local:
      path: /tmp/tempo/traces
    wal:
      path: /tmp/tempo/wal
    block:
      retention: 720h # 30 days
```

grafana-datasources.yaml:

```
apiVersion: 1
datasources:
- name: Tempo
  type: tempo
  access: proxy
  url: http://tempo:3200
  uid: tempo
  editable: false
```

Trace-Query in Grafana:

1. Öffne `http://localhost:3000`
2. Explore → Tempo Datasource
3. Search Query: `{service.name="themis-server"} && duration > 100ms`
4. Trace-View zeigt Waterfall-Diagramm aller Spans

19.4.5 Performance-Hinweise

Span-Overhead: - **Mit Tracing aktiviert:** ~5-10 µs pro Span (inkl. Attribut-Serialisierung) - **Ohne Tracing (THEMIS_ENABLE_TRACING=OFF):** 0 µs (inline no-ops)

Best Practices:

1. **Granularität:** Erstelle Spans für HTTP-Requests, Query-Execution, Index-Scans
 2. **Attribute:** Füge relevante Metadaten hinzu (table, index_type, row_count)
 3. **Sampling** (zukünftig): Für High-Throughput-Szenarien Sampling verwenden
 4. **Batch Processor** (zukünftig): SimpleSpanProcessor → BatchSpanProcessor für bessere Performance
-

19.5 Alerting

19.5.1 Alert-Definitionen (Prometheus Alertmanager)

alerts.yaml:


```
groups:
- name: themis_server
  interval: 30s
  rules:
    # High Error Rate
    - alert: HighErrorRate
      expr: rate(vccdb_errors_total[5m]) / rate(vccdb_requests_total[5m]) > 0.05
      for: 5m
      labels:
        severity: critical
      annotations:
        summary: "ThemisDB Error Rate above 5%"
        description: "{{ $value | humanizePercentage }}" error rate in last 5 minutes"

    # High Latency P99
    - alert: HighLatencyP99
      expr: histogram_quantile(0.99, rate(vccdb_latency_bucket_microseconds[5m])) > 100000
      for: 5m
      labels:
        severity: warning
      annotations:
        summary: "ThemisDB P99 latency above 100ms"
        description: "P99 latency: {{ $value | humanizeDuration }}"

    # Compaction Backlog
    - alert: CompactionBacklog
      expr: rocksdb_pending_compaction_bytes > 10000000000
      for: 10m
      labels:
        severity: warning
      annotations:
        summary: "RocksDB Compaction backlog > 10 GB"
        description: "{{ $value | humanize1024 }}"B pending compaction"

    # Low Cache Hit Rate
    - alert: LowCacheHitRate
      expr: 100 * rocksdb_block_cache_usage_bytes / rocksdb_block_cache_capacity_bytes < 20
      for: 15m
```

```
labels:
  severity: info
annotations:
  summary: "Block cache usage < 20%"
  description: "Cache may be undersized or cold"

# Too Many L0 Files (Write Stall Risk)
- alert: TooManyL0Files
  expr: rocksdb_files_per_level{level="0"} > 10
  for: 5m
  labels:
    severity: critical
  annotations:
    summary: "RocksDB L0 files > 10 (Write Stall Risk)"
    description: "{{ $value }}" L0 files, compaction cannot keep up"

# Server Down
- alert: ThemisServerDown
  expr: up{job="themis"} == 0
  for: 1m
  labels:
    severity: critical
  annotations:
    summary: "ThemisDB Server is down"
    description: "Prometheus cannot scrape /metrics endpoint"
```

19.5.2 Alertmanager-Konfiguration

alertmanager.yaml:

```
global:
  resolve_timeout: 5m

route:
  group_by: ['alertname', 'severity']
  group_wait: 10s
  group_interval: 5m
  repeat_interval: 3h
  receiver: 'email'

routes:
  - match:
      severity: critical
    receiver: 'pagerduty'
    continue: true

  - match:
      severity: warning
    receiver: 'slack'

receivers:
  - name: 'email'
    email_configs:
      - to: 'ops-team@example.com'
        from: 'alerts@example.com'
        smarthost: 'smtp.example.com:587'
        auth_username: 'alerts@example.com'
        auth_password: 'password'

  - name: 'slack'
    slack_configs:
      - api_url: 'https://hooks.slack.com/services/T000000000/B000000000/XXXXXXXXXXXXX'
        channel: '#themis-alerts'
        title: '{{ .GroupLabels.alertname }}'
        text: '{{ range .Alerts }}{{ .Annotations.summary }}\n{{ end }}'

  - name: 'pagerduty'
```

```
pagerduty_configs:
  - service_key: 'YOUR_PAGERDUTY_SERVICE_KEY'
```

19.6 Production Deployment

19.6.1 Prometheus Scrape-Konfiguration

prometheus.yaml:

```
global:
  scrape_interval: 15s
  scrape_timeout: 10s
  evaluation_interval: 30s

scrape_configs:
  - job_name: 'themis'
    static_configs:
      - targets: ['localhost:8765']

  - job_name: 'themis-cluster'
    consul_sd_configs:
      - server: 'consul:8500'
        services: ['themis']
    relabel_configs:
      - source_labels: [__meta_consul_service]
        target_label: job
      - source_labels: [__meta_consul_node]
        target_label: node
```

19.6.2 Retention & Storage

Empfohlene Retention: - **Hochfrequente Metriken:** 15 Tage - **Long-term:** Downsampling auf 1h-Auflösung nach 7 Tagen (via Thanos)

Prometheus Storage-Konfiguration:

```
storage:
  tsdb:
    path: /prometheus
    retention.time: 15d
    retention.size: 100GB
```

Thanos Integration (Multi-Node Federation + Long-Term Storage):

```
# Thanos Sidecar (läuft neben jedem Prometheus)
thanos sidecar \
  --tsdb.path /prometheus \
  --prometheus.url http://localhost:9090 \
  --objstore.config-file /etc/thanos/objstore.yaml

# Thanos Query (Global Query Frontend)
thanos query \
  --http-address 0.0.0.0:19192 \
  --store prometheus-0-sidecar:10901 \
  --store prometheus-1-sidecar:10901 \
  --store thanos-store:10901

# Thanos Store (S3 Object Storage)
thanos store \
  --data-dir /thanos/store \
  --objstore.config-file /etc/thanos/objstore.yaml
```

objstore.yaml (S3 Backend):

```
type: S3
config:
  bucket: "themis-metrics"
  endpoint: "s3.eu-central-1.amazonaws.com"
  region: "eu-central-1"
  access_key: "YOUR_ACCESS_KEY"
  secret_key: "YOUR_SECRET_KEY"
```

19.6.3 Cardinality Management

Niedrige Cardinality (< 100 Zeitreihen): - Metriken ohne Labels (z.B. `vccdb_qps`, `process_uptime_seconds`)

Hohe Cardinality (potenziell Tausende Zeitreihen): - Index-Metriken mit `table` + `column` Labels - Wenn 100 Tables mit je 20 Columns → 2000 Index-Rebuild-Metriken

Best Practices: - Verwende **niemals** High-Cardinality-Labels wie User-IDs, Timestamps, UUIDs - Nutze Route-Templates (z.B. `/entities/{key}`) statt konkreter Pfade - Für User-spezifisches Tracking: Verwende separate Logs/Traces, nicht Prometheus

19.6A Enhanced Prometheus Metrics (v1.4.0-alpha)

Neu in v1.4.0-alpha: Umfassende Metriken für LLM-Operations, Caching, GPU-Nutzung, High Availability und Performance-Optimierungen.

Monitoring-Architektur Übersicht:

Abb. 19.2: Alert-Management-Workflow

Diagramm-Erklärung: - **ThemisDB Nodes:** Jeder Node exportiert Metriken über HTTP-Endpoint (/metrics) - **Prometheus:** Scraped Metriken alle 15s, speichert als Time Series - **Grafana:** Visualisiert Metriken in Dashboards (LLM, Performance, HA) - **AlertManager:** Routet Alerts zu verschiedenen Kanälen (Slack, PagerDuty, Email) - **Metric Categories:** Über 40 neue Metriken in v1.4.0-alpha organisiert in 4 Kategorien

19.6A.1 LLM-spezifische Metriken

Neu in v1.4.0-alpha: Umfassende Metriken für LLM-Operations, Caching und GPU-Nutzung.

Request Metriken:

```
# Gesamtzahl LLM-Anfragen (nach Modell und Status)
themis_llm_requests_total{model="gpt-4",status="success"} 15420
themis_llm_requests_total{model="gpt-4",status="error"} 23
themis_llm_requests_total{model="llama-70b-local",status="success"} 8945

# Request-Latenz (Histogram)
themis_llm_request_duration_seconds_bucket{model="gpt-4",le="0.5"} 1200
themis_llm_request_duration_seconds_bucket{model="gpt-4",le="1.0"} 8400
themis_llm_request_duration_seconds_bucket{model="gpt-4",le="2.0"} 14200
themis_llm_request_duration_seconds_sum{model="gpt-4"} 18540.5
themis_llm_request_duration_seconds_count{model="gpt-4"} 15420

# Generierte Tokens
themis_llm_tokens_generated_total{model="gpt-4",type="completion"} 2450000
themis_llm_tokens_generated_total{model="gpt-4",type="prompt"} 8900000

# Token-Generierungs-Rate (tokens/sekunde)
themis_llm_tokens_per_second{model="llama-70b-local"} 312.5
```

Cache Metriken:

```
# Prefix Cache Hits/Misses
themis_llm_prefix_cache_hits_total{model="gpt-4"} 12450
themis_llm_prefix_cache_misses_total{model="gpt-4"} 2970
themis_llm_prefix_cache_hit_rate{model="gpt-4"} 0.807

# Prefix Cache Einsparungen
themis_llm_prefix_cache_tokens_saved_total{model="gpt-4"} 1850000
themis_llm_prefix_cache_cost_saved_usd{model="gpt-4"} 55.50

# Response Cache
themis_llm_response_cache_hits_total{model="gpt-4"} 8420
themis_llm_response_cache_misses_total{model="gpt-4"} 7000
themis_llm_response_cache_hit_rate{model="gpt-4"} 0.546

# Response Cache Latenz-Verbesserung
themis_llm_response_cache_latency_saved_seconds_total{model="gpt-4"} 6840.5
```

GPU Metriken:

```
# GPU-Speichernutzung pro Device
themis_llm_gpu_memory_used_bytes{device="0",model="llama-70b-local"} 25903915008 # 24.1GB
themis_llm_gpu_memory_total_bytes{device="0"} 42949672960 # 40GB
themis_llm_gpu_memory_utilization{device="0"} 0.603

# GPU Compute-Auslastung
themis_llm_gpu_utilization_percent{device="0"} 94
themis_llm_gpu_temperature_celsius{device="0"} 72
themis_llm_gpu_power_watts{device="0"} 325

# Multi-GPU Metriken
themis_llm_multi_gpu_active_devices{model="llama-70b-local"} 4
themis_llm_multi_gpu_total_memory_bytes 171798691840 # 160GB (4x40GB)
```

Batch Metriken:

```
# Aktuelle Batch-Größe
themis_llm_batch_size{model="llama-70b-local"} 87

# Batch-Auslastung
themis_llm_batch_utilization{model="llama-70b-local"} 0.679 # 87/128

# Queue-Länge
themis_llm_batch_queue_length{model="llama-70b-local"} 12

# Batches verarbeitet
themis_llm_batches_processed_total{model="llama-70b-local"} 58420
```

Grafana Dashboard - LLM Operations:


```
# dashboards/llm_operations.json (Auszug)
panels:
  - title: "LLM Request Rate"
    targets:
      - expr: rate(themis_llm_requests_total[5m])

  - title: "LLM Latency (P50, P95, P99)"
    targets:
      - expr: histogram_quantile(0.50, themis_llm_request_duration_seconds_bucket)
      - expr: histogram_quantile(0.95, themis_llm_request_duration_seconds_bucket)
      - expr: histogram_quantile(0.99, themis_llm_request_duration_seconds_bucket)

  - title: "Cache Hit Rates"
    targets:
      - expr: themis_llm_prefix_cache_hit_rate
      - expr: themis_llm_response_cache_hit_rate

  - title: "GPU Memory Usage"
    targets:
      - expr: themis_llm_gpu_memory_used_bytes / themis_llm_gpu_memory_total_bytes
```

19.6A.2 Performance-Optimierungs-Metriken

Neu in v1.4.0-alpha: Metriken für Flash Attention, Speculative Decoding und Continuous Batching.

Flash Attention Metriken:

```
# Flash Attention Status (0=disabled, 1=enabled)
themis_flash_attention_enabled{model="llama-70b-local"} 1

# Memory-Einsparungen
themis_flash_attention_memory_saved_bytes{model="llama-70b-local"} 15099494400 # 14.1GB

# Performance-Verbesserung
themis_flash_attention_throughput_improvement{model="llama-70b-local"} 0.69 # 69%
themis_flash_attention_latency_reduction{model="llama-70b-local"} 0.39 # 39%
```

Speculative Decoding Metriken:

```
# Speculative Decoding Status
themis_speculative_decoding_enabled{model="llama-70b-local"} 1
themis_speculative_decoding_draft_model{model="llama-70b-local",draft="llama-7b-local"} 1

# Akzeptanzrate
themis_speculative_decoding_acceptance_rate{model="llama-70b-local"} 0.821

# Tokens vorgeschlagen/akzeptiert
themis_speculative_decoding_tokens_proposed_total{model="llama-70b-local"} 226000
themis_speculative_decoding_tokens_accepted_total{model="llama-70b-local"} 185460

# Speedup
themis_speculative_decoding_speedup{model="llama-70b-local"} 2.4
themis_speculative_decoding_latency_reduction_seconds{model="llama-70b-local"} 1.68
```

Continuous Batching Metriken:

```
# Batching Mode (0=static, 1=continuous)
themis_continuous_batching_enabled{model="llama-70b-local"} 1

# Queue Metriken
themis_continuous_batching_queue_length{model="llama-70b-local"} 12
themis_continuous_batching_queue_wait_time_seconds{model="llama-70b-local"} 0.095

# Batch-Bildung
themis_continuous_batching_batches_formed_total{model="llama-70b-local"} 58420
themis_continuous_batching_avg_batch_size{model="llama-70b-local"} 73.5
themis_continuous_batching_batch_fill_rate{model="llama-70b-local"} 0.68

# Performance-Verbesserung
themis_continuous_batching_throughput_improvement{model="llama-70b-local"} 1.76 # 176%
themis_continuous_batching_latency_reduction{model="llama-70b-local"} 0.57 # 57%
```

Paged Attention Metriken:

```
# Paged Attention Status
themis_paged_attention_enabled{model="llama-70b-local"} 1

# Memory Metriken
themis_paged_attention_pages_allocated 4096
themis_paged_attention_pages_used 2847
themis_paged_attention_memory_efficiency 0.92 # 92% weniger Waste

# Performance
themis_paged_attention_concurrent_requests{model="llama-70b-local"} 445
themis_paged_attention_memory_per_request_bytes 94371840 # 90MB
```

Grafana Dashboard - Performance Optimizations:

```
panels:
- title: "Flash Attention Impact"
  targets:
    - expr: themis_flash_attention_throughput_improvement * 100
      legendFormat: "Throughput Improvement %"
    - expr: themis_flash_attention_memory_saved_bytes / 1024^3
      legendFormat: "Memory Saved GB"

- title: "Speculative Decoding Acceptance Rate"
  targets:
    - expr: themis_speculative_decoding_acceptance_rate * 100
      legendFormat: "Acceptance Rate %"

- title: "Continuous Batching Efficiency"
  targets:
    - expr: themis_continuous_batching_batch_fill_rate
      legendFormat: "Batch Fill Rate"
    - expr: themis_continuous_batching_queue_length
      legendFormat: "Queue Length"
```

19.6A.3 Sharding & HA Metriken

Neu in v1.4.0-alpha: Metriken für Hot Spare und WAL Replication.

Hot Spare Metriken:

```
# Hot Spare Status (0=standby, 1=active)
themis_hot_spare_active{node="hot-spare-1"} 0
themis_hot_spare_active{node="hot-spare-2"} 0

# Replication Lag
themis_hot_spare_replication_lag_seconds{node="hot-spare-1"} 0.045
themis_hot_spare_replication_lag_bytes{node="hot-spare-1"} 16384

# Failover Metriken
themis_hot_spare_failover_count_total{node="hot-spare-1"} 0
themis_hot_spare_last_failover_duration_seconds{node="hot-spare-1"} 0

# Health
themis_hot_spare_failover_ready{node="hot-spare-1"} 1
themis_hot_spare_last_health_check_timestamp{node="hot-spare-1"} 1704549600
```

WAL Replication Metriken:

```
# WAL Status
themis_wal_replication_lag_seconds{replica="hot-spare-1"} 0.002
themis_wal_replication_lag_bytes{replica="hot-spare-1"} 16

# WAL Segments
themis_wal_segments_total{shard="shard-1"} 156
themis_wal_segments_archived_total{shard="shard-1"} 12450
themis_wal_size_bytes{shard="shard-1"} 4294967296

# WAL Sync Operations
themis_wal_sync_operations_total{shard="shard-1"} 125840
themis_wal_sync_duration_seconds_sum{shard="shard-1"} 45.2
themis_wal_sync_duration_seconds_count{shard="shard-1"} 125840

# Replication Mode
themis_wal_replication_mode{shard="shard-1"} 1 # 0=async, 1=sync, 2=hybrid
```

Shard Health Metriken:

```
# Shard Status (0=down, 1=up)
themis_shard_health{shard="shard-1"} 1
themis_shard_health{shard="shard-2"} 1
themis_shard_health{shard="shard-3"} 1
themis_shard_health{shard="shard-4"} 1

# Rebalancing
themis_shard_rebalance_operations_total{shard="shard-1"} 5
themis_shard_rebalance_duration_seconds{shard="shard-1"} 245.8
themis_shard_rebalance_in_progress{shard="shard-1"} 0

# Data Distribution
themis_shard_data_size_bytes{shard="shard-1"} 10737418240 # 10GB
themis_shard_key_count{shard="shard-1"} 2500000
```

Grafana Dashboard - High Availability:

```
panels:
- title: "Shard Health Status"
  targets:
    - expr: themis_shard_health
      legendFormat: "{{shard}}"

- title: "Hot Spare Replication Lag"
  targets:
    - expr: themis_hot_spare_replication_lag_seconds
      legendFormat: "{{node}}"

- title: "WAL Replication Lag"
  targets:
    - expr: themis_wal_replication_lag_seconds
      legendFormat: "{{replica}}"

- title: "Failover Events (24h)"
  targets:
    - expr: increase(themis_hot_spare_failover_count_total[24h])
```

19.6A.4 Alerting Rules für v1.4.0-alpha Features

LLM Alerts:

```
# config/prometheus/alerts/llm.yml
groups:
  - name: llm_alerts
    rules:
      # Hohe Fehlerrate
      - alert: LLMHighErrorRate
        expr: rate(themis_llm_requests_total{status="error"}[5m]) > 0.05
        for: 5m
        labels:
          severity: warning
        annotations:
          summary: "High LLM error rate on {{ $labels.model }}"
          description: "Error rate is {{ $value | humanizePercentage }}"

      # Cache Hit Rate zu niedrig
      - alert: LLMCacheHitRateLow
        expr: themis_llm_prefix_cache_hit_rate < 0.5
        for: 15m
        labels:
          severity: info
        annotations:
          summary: "Low prefix cache hit rate"
          description: "Hit rate is {{ $value | humanizePercentage }}"

      # GPU Memory Auslastung kritisch
      - alert: GPUMemoryCritical
        expr: themis_llm_gpu_memory_utilization > 0.95
        for: 5m
        labels:
          severity: critical
        annotations:
          summary: "GPU {{ $labels.device }} memory critical"
          description: "Memory utilization is {{ $value | humanizePercentage }}"

      # Batch Queue zu lang
      - alert: LLMBatchQueueLong
        expr: themis_continuous_batching_queue_length > 100
        for: 10m
```

```
labels:  
  severity: warning  
annotations:  
  summary: "LLM batch queue too long"  
  description: "Queue length is {{ $value }}"
```

HA & Replication Alerts:


```
# config/prometheus/alerts/ha.yml
groups:
  - name: ha_alerts
    rules:
      # Hot Spare Replication Lag zu hoch
      - alert: HotSpareReplicationLagHigh
        expr: themis_hot_spare_replication_lag_seconds > 0.1
        for: 5m
        labels:
          severity: warning
        annotations:
          summary: "Hot spare {{ $labels.node }} replication lag high"
          description: "Lag is {{ $value }}s"

      # Hot Spare nicht bereit
      - alert: HotSpareNotReady
        expr: themis_hot_spare_failover_ready == 0
        for: 5m
        labels:
          severity: critical
        annotations:
          summary: "Hot spare {{ $labels.node }} not ready for failover"

      # Shard Down
      - alert: ShardDown
        expr: themis_shard_health == 0
        for: 1m
        labels:
          severity: critical
        annotations:
          summary: "Shard {{ $labels.shard }} is down"
          description: "Immediate attention required"

      # WAL Replication Lag kritisch
      - alert: WALReplicationLagCritical
        expr: themis_wal_replication_lag_seconds > 1.0
        for: 5m
        labels:
```

```
    severity: critical
  annotations:
    summary: "WAL replication lag critical on {{ $labels.replica }}"
    description: "Lag is {{ $value }}s"
```

Performance Optimization Alerts:

```
# config/prometheus/alerts/performance.yml
groups:
- name: performance_alerts
  rules:
    # Speculative Decoding Akzeptanzrate niedrig
    - alert: SpeculativeDecodingLowAcceptance
      expr: themis_speculative_decoding_acceptance_rate < 0.6
      for: 15m
      labels:
        severity: info
      annotations:
        summary: "Low speculative decoding acceptance rate"
        description: "Consider adjusting draft model or threshold"

    # Batch Fill Rate niedrig
    - alert: ContinuousBatchingLowFillRate
      expr: themis_continuous_batching_batch_fill_rate < 0.4
      for: 15m
      labels:
        severity: info
      annotations:
        summary: "Low batch fill rate"
        description: "Consider adjusting batch size or timeout"
```

19.6A.5 Beispiel PromQL Queries

LLM Performance Analysis:

```
# Durchschnittliche Latenz pro Modell (letzte 5 Minuten)
rate(themis_llm_request_duration_seconds_sum[5m])
/
rate(themis_llm_request_duration_seconds_count[5m])

# Tokens pro Sekunde (Rate)
rate(themis_llm_tokens_generated_total[5m])

# Cache Einsparungen in USD (letzte 24h)
increase(themis_llm_prefix_cache_cost_saved_usd[24h])

# GPU Auslastung über alle Devices
avg(themis_llm_gpu_utilization_percent)
```

Sharding & HA Analysis:

```
# Durchschnittliche Replication Lag über alle Hot Spares
avg(themis_hot_spare_replication_lag_seconds)

# Anzahl Shards die UP sind
sum(themis_shard_health)

# WAL Sync Latenz (P95)
histogram_quantile(0.95,
  rate(themis_wal_sync_duration_seconds_bucket[5m])
)

# Total Rebalance Operations (letzte 24h)
sum(increase(themis_shard_rebalance_operations_total[24h]))
```

Cost Analysis:

```
# Gesamte Token-Kosten (letzte 30 Tage, $0.03/1K tokens GPT-4)
sum(increase(themis_llm_tokens_generated_total{model="gpt-4"}[30d]))
* 0.03 / 1000

# Cache-Einsparungen vs. Kosten
sum(increase(themis_llm_prefix_cache_cost_saved_usd[30d]))
+
sum(increase(themis_llm_response_cache_cost_saved_usd[30d]))
```

19.7 Zusammenfassung

ThemisDB bietet ein **Production-Ready Observability-Stack** mit:

- **48 Prometheus-Metriken** für Server, RocksDB, Indexes, Vectors
- **Kumulative Histogramme** für Latenz-Tracking (P50/P95/P99)
- **3 Grafana-Dashboards** für Server-Health, Storage-Health, Vector-Operations
- **OpenTelemetry Distributed Tracing** mit Jaeger/Tempo Integration
- **Alerting** via Prometheus Alertmanager mit PagerDuty/Slack/Email
- **Long-Term Storage** via Thanos mit S3-Backend

Performance-Overhead: - **Metrics:** < 1% CPU (Counter-Inkmente sind atomic operations) - **Tracing (aktiviert):** ~5-10 µs pro Span - **Tracing (deaktiviert):** 0 µs (compile-time no-ops)

Nächste Schritte: 1. Implementiere Custom-Dashboards für projektspezifische Metriken 2. Konfiguriere Alertmanager-Routing nach Schweregrad 3. Enable Sampling für Tracing in High-Throughput-Szenarien (> 10K QPS) 4. Setze SLI/SLO-Tracking auf (Error Budget Calculations)

Siehe auch: - [Chapter 8: Storage Layer Deep-Dive](#) - RocksDB Tuning - [Chapter 11: Realtime Data Streaming](#) - CDC Monitoring - [Appendix C: API Reference](#) - /metrics Endpoint - [Prometheus Documentation](#) (<https://prometheus.io/docs/>) - [OpenTelemetry Documentation](#) (<https://opentelemetry.io/docs/>) - [Grafana Documentation](#) (<https://grafana.com/docs/>)

Kapitel 20: Kapitel 20 - Backup

Einführung

Backup und Recovery sind kritische Komponenten für jede Produktionsumgebung. Dieses Kapitel behandelt umfassende Strategien für Datensicherung, Wiederherstellung und Disaster Recovery mit ThemisDB.

19.1 Backup-Strategien

19.1.1 Vollständige Backups

Konzept: Ein vollständiges Backup erstellt eine komplette Kopie aller Daten zu einem bestimmten Zeitpunkt.

Durchführung:

```
# Online-Backup erstellen
themisdb-backup --type full --output /backups/full_$(date +%Y%m%d).tar.gz

# Mit Kompression
themisdb-backup --type full --compress gzip --output /backups/full.tar.gz
```

Vorteile: - Einfache Wiederherstellung - Vollständige Datenkonsistenz - Einfaches Backup-Management

Nachteile: - Hoher Speicherbedarf - Längere Backup-Dauer - Höhere I/O-Last

19.1.2 Inkrementelle Backups

Konzept: Nur Änderungen seit dem letzten Backup werden gesichert.

Implementierung:

```
# Erstes vollständiges Backup
themisdb-backup --type full --output /backups/base.tar.gz

# Inkrementelle Backups
themisdb-backup --type incremental \
  --base /backups/base.tar.gz \
  --output /backups/incr_$(date +%Y%m%d_%H%M).tar.gz
```

Vorteile: - Schnellere Backup-Erstellung - Geringerer Speicherbedarf - Weniger I/O-Last

Nachteile: - Komplexere Wiederherstellung - Abhängigkeit von vorherigen Backups

19.1.3 Differenzielle Backups

Konzept: Alle Änderungen seit dem letzten vollständigen Backup.

```
# Differenzielles Backup
themisdb-backup --type differential \
  --base /backups/full.tar.gz \
  --output /backups/diff_$(date +%Y%m%d).tar.gz
```

Abb. 20.1: Backup-Strategy-Overview

Abb. 20.2: Point-in-Time-Recovery-Timeline

19.2 Backup-Mechanismen

19.2.1 Physische Backups

RocksDB SST-Dateien:

```
import shutil
from pathlib import Path

def physical_backup(data_dir, backup_dir):
    """Erstellt physisches Backup der RocksDB-Dateien"""
    # Checkpoint erstellen (konsistenter Snapshot)
    checkpoint_dir = Path(backup_dir) / "checkpoint"

    # ThemisDB Checkpoint API
    client.admin.create_checkpoint(str(checkpoint_dir))

    # Backup mit rsync
    import subprocess
    subprocess.run([
        "rsync", "-av", "--delete",
        str(checkpoint_dir) + "/",
        str(backup_dir) + "/"
    ])

    print(f"Physical backup completed: {backup_dir}")
```

Vorteile: - Sehr schnelle Backups - Minimale Auswirkungen auf die Performance - Byte-genaue Kopien

19.2.2 Logische Backups

Datenexport:

```
def logical_backup(client, backup_file):  
    """Exportiert Daten als logisches Backup"""  
    import json  
  
    backup_data = {  
        'version': '1.3.4',  
        'timestamp': datetime.now().isoformat(),  
        'collections': {}  
    }  
  
    # Alle Collections exportieren  
    collections = client.list_collections()  
    for coll_name in collections:  
        print(f"Backing up collection: {coll_name}")  
  
        # Alle Dokumente exportieren  
        docs = list(client.collection(coll_name).find({}))  
        backup_data['collections'][coll_name] = docs  
  
    # Als JSON speichern  
    with open(backup_file, 'w') as f:  
        json.dump(backup_data, f, indent=2)  
  
    print(f"Logical backup completed: {backup_file}")
```

Vorteile: - Plattformunabhängig - Lesbare Datenformate - Einfache Teilwiederherstellung

19.2.3 Snapshot-basierte Backups

Mit Dateisystem-Snapshots:


```
# LVM Snapshot
lvcreate --snapshot --name themisdb_snap --size 10G /dev/vg0/themisdb

# Backup vom Snapshot
tar czf /backups/snapshot_$(date +%Y%m%d).tar.gz \
    /mnt/themisdb_snap/

# Snapshot entfernen
lvremove /dev/vg0/themisdb_snap
```

AWS EBS Snapshots:

```
import boto3

def create_ebs_snapshot(volume_id, description):
    """Erstellt EBS Snapshot"""
    ec2 = boto3.client('ec2')

    snapshot = ec2.create_snapshot(
        VolumeId=volume_id,
        Description=description,
        TagSpecifications=[{
            'ResourceType': 'snapshot',
            'Tags': [
                {'Key': 'Name', 'Value': f'themisdb-backup-{datetime.now().strftime("%Y%m%d")}'},
                {'Key': 'Type', 'Value': 'automated'}
            ]
        }]
    )

    return snapshot['SnapshotId']
```

19.3 Point-in-Time Recovery (PITR)

19.3.1 Binlog-basierte Recovery

Konzept: Kombination aus vollständigem Backup und Transaction Logs.

Aktivierung:

```
# themisdb.yaml
storage:
  enable_binlog: true
  binlog_dir: /var/lib/themisdb/binlog
  binlog_rotation: 100MB
  binlog_retention: 7d
```

Recovery-Prozess:

```
def point_in_time_recovery(backup_file, target_time):
    """
    Wiederherstellung zu einem bestimmten Zeitpunkt
    """
    # 1. Basis-Backup wiederherstellen
    restore_backup(backup_file)

    # 2. Binlogs bis zum Ziel-Zeitpunkt anwenden
    binlog_dir = Path("/var/lib/themisdb/binlog")

    for binlog in sorted(binlog_dir.glob("binlog.*")):
        # Binlog-Einträge bis target_time anwenden
        apply_binlog(binlog, target_time)

    print(f"PITR completed to: {target_time}")
```

19.3.2 MVCC-basierte Recovery**Mit Snapshot Isolation:**

```
def recover_to_timestamp(timestamp):  
    """  
    Nutzt MVCC für zeitpunktgenaue Wiederherstellung  
    """  
    # Query mit AS OF SYSTEM TIME  
    result = client.query(f"""  
        SELECT * FROM orders  
        AS OF SYSTEM TIME '{timestamp}'  
    """)  
  
    return result
```

19.4 Backup-Automatisierung

19.4.1 Cron-basierte Backups

Backup-Script:

```
#!/bin/bash
# /usr/local/bin/themisdb-backup.sh

BACKUP_DIR=/backups/themisdb
DATE=$(date +%Y%m%d_%H%M)
LOG_FILE=/var/log/themisdb-backup.log

# Vollständiges Backup jeden Sonntag
if [ $(date +%u) -eq 7 ]; then
    echo "[$(date)] Starting full backup" >> $LOG_FILE
    themisdb-backup --type full --output $BACKUP_DIR/full_$DATE.tar.gz
else
    echo "[$(date)] Starting incremental backup" >> $LOG_FILE
    themisdb-backup --type incremental --output $BACKUP_DIR/incr_$DATE.tar.gz
fi

# Alte Backups löschen (>30 Tage)
find $BACKUP_DIR -name "*.tar.gz" -mtime +30 -delete

echo "[$(date)] Backup completed" >> $LOG_FILE
```

Crontab-Eintrag:

```
# Tägliches Backup um 2:00 Uhr
0 2 * * * /usr/local/bin/themisdb-backup.sh

# Wöchentliches vollständiges Backup (Sonntag 3:00)
0 3 * * 0 /usr/local/bin/themisdb-full-backup.sh
```

19.4.2 Python Backup-Manager

Das folgende Python-Skript implementiert einen vollautomatischen Backup-Manager mit Schedule-Support. Es unterscheidet zwischen vollständigen und inkrementellen Backups und führt automatisch Retention-Management durch (löscht alte Backups nach 30 Tagen).

Vollständiger Code: `examples/20_backup/backup_manager.py` (~95 Zeilen)

```

import schedule
import time
from datetime import datetime, timedelta
from pathlib import Path

class BackupManager:
    def __init__(self, backup_dir, retention_days=30):
        self.backup_dir = Path(backup_dir)
        self.retention_days = retention_days

    def full_backup(self):
        """Vollständiges Backup aller Daten"""
        timestamp = datetime.now().strftime("%Y%m%d_%H%M")
        backup_file = self.backup_dir / f"full_{timestamp}.tar.gz"
        print(f"Starting full backup: {backup_file}")
        # Backup-Logik (tar/gzip Kompression)

    def incremental_backup(self):
        """Inkrementelles Backup nur geänderter Daten"""
        timestamp = datetime.now().strftime("%Y%m%d_%H%M")
        backup_file = self.backup_dir / f"incr_{timestamp}.tar.gz"
        print(f"Starting incremental backup: {backup_file}")

    def cleanup_old_backups(self):
        """Löscht Backups älter als retention_days"""
        cutoff = datetime.now() - timedelta(days=self.retention_days)
        for backup in self.backup_dir.glob("*.tar.gz"):
            if datetime.fromtimestamp(backup.stat().st_mtime) < cutoff:
                backup.unlink()
                print(f"Deleted old backup: {backup}")

    def start_scheduler(self):
        """Startet automatischen Backup-Scheduler"""
        schedule.every().day.at("02:00").do(self.incremental_backup)
        schedule.every().sunday.at("03:00").do(self.full_backup)
        schedule.every().day.at("04:00").do(self.cleanup_old_backups)

        while True:

```

```
        schedule.run_pending()
        time.sleep(60)

# Usage
manager = BackupManager("/backups/themisdb", retention_days=30)
manager.start_scheduler()
```

Zusätzliche Features im vollständigen Skript: - Cloud-Upload zu S3/Azure Blob Storage -
Verschlüsselung mit GPG - Email-Benachrichtigungen bei Fehlern - Prometheus-Metriken für Monitoring

19.5 Backup-Verifizierung

19.5.1 Backup-Integrität prüfen

Checksummen-Validierung:

```
import hashlib

def verify_backup(backup_file):
    """Überprüft Backup-Integrität"""
    # Checksumme berechnen
    sha256 = hashlib.sha256()

    with open(backup_file, 'rb') as f:
        while chunk := f.read(8192):
            sha256.update(chunk)

    checksum = sha256.hexdigest()

    # Mit gespeicherter Checksumme vergleichen
    checksum_file = f"{backup_file}.sha256"
    if Path(checksum_file).exists():
        with open(checksum_file) as f:
            expected = f.read().strip()

        if checksum == expected:
            print(f"✓ Backup integrity verified: {backup_file}")
            return True
        else:
            print(f"✗ Backup corrupted: {backup_file}")
            return False
    else:
        # Checksumme speichern
        with open(checksum_file, 'w') as f:
            f.write(checksum)

        return True
```

19.5.2 Wiederherstellungs-Tests

Automatisierte Test-Recovery:

```
def test_backup_restore(backup_file, test_dir="/tmp/restore_test"):
    """Testet Backup-Wiederherstellung"""
    import shutil
    from pathlib import Path

    test_path = Path(test_dir)
    test_path.mkdir(exist_ok=True)

    try:
        # Backup wiederherstellen
        restore_backup(backup_file, test_path)

        # ThemisDB mit Test-Daten starten
        test_client = ThemisDBClient(data_dir=test_path)

        # Basis-Tests durchführen
        collections = test_client.list_collections()
        assert len(collections) > 0, "No collections found"

        # Sample-Queries testen
        result = test_client.query("SELECT COUNT(*) FROM orders")
        assert result[0]['count'] > 0, "No data found"

        print(f"✓ Restore test passed: {backup_file}")
        return True

    except Exception as e:
        print(f"✗ Restore test failed: {e}")
        return False

    finally:
        # Cleanup
        shutil.rmtree(test_path, ignore_errors=True)
```


19.6 Wiederherstellung

19.6.1 Vollständige Wiederherstellung

Restore-Prozess:

```
#!/bin/bash
# Komplette Datenbank-Wiederherstellung

# 1. ThemisDB stoppen
systemctl stop themisdb

# 2. Datenverzeichnis sichern (falls vorhanden)
mv /var/lib/themisdb /var/lib/themisdb.old

# 3. Backup wiederherstellen
tar xzf /backups/full_20231215.tar.gz -C /var/lib/themisdb

# 4. Berechtigungen setzen
chown -R themisdb:themisdb /var/lib/themisdb

# 5. ThemisDB starten
systemctl start themisdb

# 6. Validierung
themisdb-admin validate
```

19.6.2 Selektive Wiederherstellung

Einzelne Collection wiederherstellen:

```
def restore_collection(backup_file, collection_name, target_db):
    """Stellt einzelne Collection wieder her"""
    import json

    # Backup laden
    with open(backup_file) as f:
        backup_data = json.load(f)

    # Collection-Daten extrahieren
    if collection_name not in backup_data['collections']:
        raise ValueError(f"Collection {collection_name} not found in backup")

    docs = backup_data['collections'][collection_name]

    # In Ziel-DB einfügen
    target_client = ThemisDBClient(target_db)
    coll = target_client.collection(collection_name)

    # Batch-Insert
    batch_size = 1000
    for i in range(0, len(docs), batch_size):
        batch = docs[i:i+batch_size]
        coll.insert_many(batch)

    print(f"Restored {len(docs)} documents to {collection_name}")
```

19.7 Disaster Recovery

19.7.1 DR-Strategie

Recovery Time Objective (RTO): - Maximale akzeptable Ausfallzeit - Ziel: < 4 Stunden

Recovery Point Objective (RPO): - Maximaler Datenverlust - Ziel: < 15 Minuten

DR-Plan:

```
disaster_recovery:
  primary_site:
    location: "datacenter-1"
    backup_frequency: "hourly"

  secondary_site:
    location: "datacenter-2"
    replication: "synchronous"
    standby_mode: "hot"

  backup_locations:
    - "s3://backups-bucket/themisdb/"
    - "azure://backups/themisdb/"

  procedures:
    - name: "Site Failover"
      steps:
        - "Verify primary site failure"
        - "Promote secondary to primary"
        - "Update DNS/Load Balancer"
        - "Verify application connectivity"
```

19.7.2 Geo-Replikation

Multi-Region Setup:

```
# Master in Region 1
master_config = {
    'replication': {
        'role': 'master',
        'replicas': [
            'themisdb-replica-eu:8529',
            'themisdb-replica-us:8529'
        ]
    }
}

# Replica in Region 2
replica_config = {
    'replication': {
        'role': 'replica',
        'master': 'themisdb-master-eu:8529',
        'replication_lag_alert': '30s'
    }
}
```

19.8 Backup zu Cloud-Storage

19.8.1 AWS S3

Upload zu S3:

```
import boto3
from pathlib import Path

def upload_to_s3(backup_file, bucket, prefix="backups/"):
    """Lädt Backup zu AWS S3 hoch"""
    s3 = boto3.client('s3')

    key = f"{prefix}{Path(backup_file).name}"

    # Upload mit Progress
    s3.upload_file(
        backup_file,
        bucket,
        key,
        Callback=ProgressPercentage(backup_file)
    )

    print(f"Uploaded to s3://{bucket}/{key}")

    # Lifecycle-Policy für automatisches Löschen
    s3.put_bucket_lifecycle_configuration(
        Bucket=bucket,
        LifecycleConfiguration={
            'Rules': [{
                'Id': 'DeleteOldBackups',
                'Status': 'Enabled',
                'Prefix': prefix,
                'Expiration': {'Days': 90}
            }]
        }
    )
```

19.8.2 Azure Blob Storage

Upload zu Azure:

```
from azure.storage.blob import BlobServiceClient

def upload_to_azure(backup_file, connection_string, container):
    """Lädt Backup zu Azure Blob Storage"""
    blob_service = BlobServiceClient.from_connection_string(connection_string)

    blob_name = Path(backup_file).name
    blob_client = blob_service.get_blob_client(container, blob_name)

    with open(backup_file, 'rb') as data:
        blob_client.upload_blob(data, overwrite=True)

    print(f"Uploaded to Azure: {container}/{blob_name}")
```

19.8.3 Google Cloud Storage

Upload zu GCS:

```
from google.cloud import storage

def upload_to_gcs(backup_file, bucket_name, destination_blob):
    """Lädt Backup zu Google Cloud Storage"""
    client = storage.Client()
    bucket = client.bucket(bucket_name)
    blob = bucket.blob(destination_blob)

    blob.upload_from_filename(backup_file)

    print(f"Uploaded to gs://{bucket_name}/{destination_blob}")
```

19.9 Best Practices

19.9.1 3-2-1 Backup-Regel

Prinzip: - 3 Kopien der Daten - 2 verschiedene Medientypen - 1 Kopie off-site

Implementierung:

```
backup_strategy = {  
    'copies': [  
        {'type': 'local', 'location': '/backups/local'},  
        {'type': 'nas', 'location': '/mnt/nas/backups'},  
        {'type': 'cloud', 'location': 's3://backups/themisdb'}  
    ],  
    'media_types': ['disk', 'cloud'],  
    'offsite': True  
}
```

19.9.2 Backup-Verschlüsselung

Verschlüsselte Backups:

```
from cryptography.fernet import Fernet

def encrypted_backup(source_file, output_file, key_file):
    """Erstellt verschlüsseltes Backup"""
    # Key laden oder generieren
    if Path(key_file).exists():
        with open(key_file, 'rb') as f:
            key = f.read()
    else:
        key = Fernet.generate_key()
        with open(key_file, 'wb') as f:
            f.write(key)

    fernet = Fernet(key)

    # Daten verschlüsseln
    with open(source_file, 'rb') as f:
        data = f.read()

    encrypted = fernet.encrypt(data)

    with open(output_file, 'wb') as f:
        f.write(encrypted)

    print(f"Encrypted backup created: {output_file}")
```

19.9.3 Backup-Monitoring

Monitoring-Integration:


```
from prometheus_client import Counter, Histogram, Gauge

backup_counter = Counter('themisdb_backups_total', 'Total backups', ['type', 'status'])
backup_duration = Histogram('themisdb_backup_duration_seconds', 'Backup duration')
backup_size = Gauge('themisdb_backup_size_bytes', 'Backup size')
last_backup = Gauge('themisdb_last_backup_timestamp', 'Last backup timestamp')

@backup_duration.time()
def monitored_backup(backup_type):
    """Backup mit Monitoring"""
    try:
        # Backup durchführen
        result = create_backup(backup_type)

        # Metriken aktualisieren
        backup_counter.labels(type=backup_type, status='success').inc()
        backup_size.set(result['size'])
        last_backup.set(time.time())

        return result

    except Exception as e:
        backup_counter.labels(type=backup_type, status='failure').inc()
        raise
```

19.10 Zusammenfassung

Kritische Punkte: - Regelmäßige Backups sind essenziell - PITR ermöglicht zeitpunktgenaue Recovery - Automatisierung reduziert Fehler - Cloud-Storage bietet Off-site-Schutz - Regelmäßige Wiederherstellungs-Tests - Verschlüsselung schützt sensible Daten - Monitoring gewährleistet Backup-Erfolg

Checkliste: - [] Backup-Strategie definiert - [] Automatisierte Backups konfiguriert - [] PITR aktiviert - [] Off-site Backups eingerichtet - [] Wiederherstellungs-Tests durchgeführt - [] DR-Plan dokumentiert - [] Monitoring aktiviert - [] Team geschult

Kapitel 21: Kapitel 21 - Performance

Einführung

Performance-Optimierung ist entscheidend für produktive ThemisDB-Deployments. Dieses Kapitel behandelt systematische Ansätze zur Identifizierung und Behebung von Performance-Problemen.

20.1 Performance-Analyse

20.1.1 Query-Performance-Messung

EXPLAIN ANALYZE:

```
EXPLAIN ANALYZE
FOR order IN orders
  FILTER order.order_date > '2023-01-01'
FOR customer IN customers
  FILTER order.customer_id == customer.id
SORT order.total_amount DESC
LIMIT 100
RETURN {order, customer_name: customer.name}
```

Ausgabe-Interpretation:

```
Query Plan:
├─ Sort (cost=1250.45, rows=1000, time=125ms)
|   └─ Hash Join (cost=850.23, rows=5000, time=85ms)
|       ├─ Seq Scan on orders (cost=0.00, rows=10000, time=45ms)
|       │   Filter: order_date > '2023-01-01'
|       └─ Hash (cost=250.00, rows=5000, time=25ms)
|           └─ Index Scan on customers (cost=0.00, rows=5000, time=15ms)
```

Abb. 21.1: Query-Performance-Optimization-Flow

20.1.2 Python Profiling

Abfrage-Performance tracken:

```
# Query-Profiling mit Decorator
def profile_query(func):
    def wrapper(*args, **kwargs):
        start = time.time()
        result = func(*args, **kwargs)
        if (duration := time.time() - start) > 1.0:
            print(f"SLOW: {func.__name__} {duration:.2f}s")
        return result
    return wrapper
```

20.1.3 System-Ressourcen-Monitoring

CPU und Memory:

```
import psutil

def monitor_resources():
    """Überwacht System-Ressourcen"""
    process = psutil.Process()

    return {
        'cpu_percent': process.cpu_percent(interval=1),
        'memory_mb': process.memory_info().rss / 1024 / 1024,
        'open_files': len(process.open_files()),
        'threads': process.num_threads()
    }
```

20.2 Index-Optimierung

20.2.1 Index-Typen verstehen

B-Tree Index (Standard):

```
-- Für Equality und Range Queries
CREATE INDEX idx_order_date ON orders(order_date);

-- Composite Index
CREATE INDEX idx_customer_date ON orders(customer_id, order_date);
```

Hash Index:

```
-- Nur für Equality Queries
CREATE INDEX idx_customer_hash ON customers USING HASH(email);
```

Vector Index (HNSW):

```
-- Für Similarity Search
CREATE VECTOR INDEX idx_product_embedding
ON products(embedding)
WITH (metric='cosine', m=16, ef_construction=200);
```

20.2.2 Index-Strategie

Effective Index-Design:

```
# Schlechter Index (zu viele Columns)
CREATE INDEX bad_idx ON orders(customer_id, order_date, status, total_amount)

# Besserer Index (nur notwendige Columns)
CREATE INDEX good_idx ON orders(customer_id, order_date)

# Covering Index (enthält alle benötigten Felder)
CREATE INDEX covering_idx ON orders(customer_id, order_date)
INCLUDE (status, total_amount)
```

Index-Nutzung überprüfen:

```
def analyze_index_usage(table_name):  
    """Analysiert Index-Nutzung"""  
    stats = client.admin.index_stats(table_name)  
  
    for idx in stats['indexes']:  
        usage_rate = idx['scans'] / max(idx['age_seconds'], 1)  
  
        if usage_rate < 0.01: # Weniger als 1 Scan pro 100 Sekunden  
            print(f"Unused index: {idx['name']}")  
            print(f"  Size: {idx['size_mb']} MB")  
            print(f"  Recommendation: Consider dropping")
```

20.2.3 Index-Wartung

Rebuild und Reorganize:

```
def maintain_indexes(table_name):  
    """Führt Index-Wartung durch"""  
    stats = client.admin.index_fragmentation(table_name)  
  
    for idx in stats['indexes']:  
        frag_pct = idx['fragmentation_percent']  
  
        if frag_pct > 30:  
            print(f"Rebuilding index: {idx['name']} ({frag_pct}% fragmented)")  
            client.admin.rebuild_index(table_name, idx['name'])  
        elif frag_pct > 10:  
            print(f"Reorganizing index: {idx['name']}")  
            client.admin.reorganize_index(table_name, idx['name'])
```

20.3 Query-Optimierung

20.3.1 Query-Rewriting

Subquery vs JOIN:

```
-- Langsam: Correlated Subquery
FOR customer IN customers
  LET order_count = (
    FOR order IN orders
      FILTER order.customer_id == customer.id
    RETURN 1
  )
  RETURN {name: customer.name, order_count: LENGTH(order_count)}

-- Schneller: Multi-FOR mit COLLECT
FOR customer IN customers
  FOR order IN orders
    FILTER order.customer_id == customer.id
    COLLECT c_id = customer.id, c_name = customer.name
  AGGREGATE order_count = COUNT()
  RETURN {name: c_name, order_count}
```

IN vs EXISTS:

```
-- Langsam für große Datasets
LET completed_customers = (
  FOR order IN orders
    FILTER order.status == 'completed'
    RETURN DISTINCT order.customer_id
)
FOR customer IN customers
  FILTER customer.id IN completed_customers
  RETURN customer

-- Schneller: Direkte Filterung
FOR customer IN customers
  LET has_completed = (
    FOR order IN orders
      FILTER order.customer_id == customer.id AND order.status == 'completed'
      LIMIT 1
      RETURN 1
  )
  FILTER LENGTH(has_completed) > 0
  RETURN customer
```

20.3.2 Batch Operations

Bulk Insert:

```
# Langsam: Einzelne Inserts
for record in records:
    client.collection('orders').insert_one(record)

# Schneller: Batch Insert
client.collection('orders').insert_many(records, batch_size=1000)
```

Bulk Update:

```
# Mit Batch-Processing
def bulk_update(updates, batch_size=1000):
    """Bulk Update mit optimaler Batch-Größe"""
    for i in range(0, len(updates), batch_size):
        batch = updates[i:i+batch_size]

        # Transaction für Batch
        with client.begin_transaction() as txn:
            for update in batch:
                txn.update('orders', update['id'], update['data'])
            txn.commit()
```

20.3.3 Query-Caching

Ein Application-Level Query Cache reduziert die Last auf ThemisDB durch Zwischenspeicherung häufiger Abfragen. Der Cache verwendet MD5-Hashes als Keys (Query + Parameter) und implementiert LRU-Eviction bei Überschreitung der Kapazität. TTL (Time-To-Live) von 300 Sekunden verhindert Stale Data bei sich ändernden Daten.

Vollständiger Code: [examples/21_performance/query_cache.py](#) (~80 Zeilen)

Application-Level Cache:


```

import hashlib
import json
import time

class QueryCache:
    def __init__(self, max_size=1000, ttl=300):
        self.cache = {}
        self.max_size = max_size
        self.ttl = ttl # 5 Minuten TTL

    def _cache_key(self, query, params):
        """MD5-Hash aus Query + Parameter"""
        data = json.dumps({'query': query, 'params': params}, sort_keys=True)
        return hashlib.md5(data.encode()).hexdigest()

    def get(self, query, params):
        """Holt gecachtes Ergebnis wenn noch valid"""
        key = self._cache_key(query, params)
        if key in self.cache:
            entry = self.cache[key]
            if time.time() - entry['timestamp'] < self.ttl:
                return entry['result'] # Cache Hit
            del self.cache[key] # TTL expired
        return None # Cache Miss

    def set(self, query, params, result):
        """Cached Ergebnis mit LRU eviction"""
        if len(self.cache) >= self.max_size:
            oldest = min(self.cache.keys(), key=lambda k: self.cache[k]['timestamp'])
            del self.cache[oldest] # LRU: Ältesten Eintrag entfernen

        self.cache[self._cache_key(query, params)] = {
            'result': result,
            'timestamp': time.time()
        }

# Verwendung mit 1000 Einträgen, 5min TTL
cache = QueryCache(max_size=1000, ttl=300)

```

```
result = cache.query("""FOR product IN products FILTER product.category == @category RETURN product
                        {"category": 'electronics'})
```

Cache-Metriken: - Hit-Rate: ~70-80% bei typischen Workloads - Latenz-Reduktion: 10-50ms → <1ms bei Cache-Hit - Memory: ~10-50 MB für 1000 gecachte Results

Weitere Features in vollständiger Implementierung: - Invalidierung bei Updates (Cache Invalidation Pattern) - Distributed Caching mit Redis/Memcached - Cache Warming bei Systemstart - Per-Query Cache Control Headers

20.4 Connection Pooling

20.4.1 Pool-Konfiguration

Optimale Pool-Size:

```
from themisdb import ConnectionPool

# Connection Pool konfigurieren
pool = ConnectionPool(
    host='localhost',
    port=8529,
    min_connections=10,      # Minimum Connections
    max_connections=100,    # Maximum Connections
    max_idle_time=300,      # 5 Minuten Idle-Timeout
    connection_timeout=10,  # 10 Sekunden Connect-Timeout
    validate_on_checkout=True # Validierung bei Checkout
)

# Pool-Statistiken
def print_pool_stats():
    stats = pool.get_stats()
    print(f"Active: {stats['active']}")
    print(f"Idle: {stats['idle']}")
    print(f"Waiting: {stats['waiting']}")
    print(f"Pool utilization: {stats['active'] / stats['max'] * 100:.1f}%")
```

20.4.2 Connection-Leaks vermeiden

Context Manager:

```
class SafeConnection:
    def __init__(self, pool):
        self.pool = pool
        self.conn = None

    def __enter__(self):
        self.conn = self.pool.get_connection()
        return self.conn

    def __exit__(self, exc_type, exc_val, exc_tb):
        if self.conn:
            self.pool.release_connection(self.conn)
        return False

# Verwendung
with SafeConnection(pool) as conn:
    result = conn.query("""
        FOR order IN orders
        RETURN order
    """)
```

20.5 RocksDB-Tuning

20.5.1 LSM-Tree Konfiguration

Write Buffer Size:

```
# themisdb.yaml
storage:
  rocksdb:
    write_buffer_size: 128MB      # Größerer Buffer = weniger Flushes
    max_write_buffer_number: 4    # Parallele Buffers
    min_write_buffer_to_merge: 2 # Merge-Schwelle
```

Block Cache:

```
storage:
  rocksdb:
    block_cache_size: 8GB          # LRU Cache für Blocks
    cache_index_and_filter: true   # Indexes im Cache
    pin_top_level_index: true     # Top-Level Index immer im Cache
```

20.5.2 Compaction-Tuning

Level-Style Compaction:

```
storage:
  rocksdb:
    compaction_style: level
    level0_file_num_trigger: 4    # Trigger bei 4 L0 Files
    level0_slowdown_writes: 20   # Slowdown bei 20 L0 Files
    level0_stop_writes: 36       # Stop bei 36 L0 Files
    max_background_compactions: 8 # Parallele Compactions
    max_background_flushes: 4    # Parallele Flushes
```

Universal Compaction (für Write-Heavy):

```
storage:
  rocksdb:
    compaction_style: universal
    max_size_amplification_percent: 200
    compression_size_multiplier: 2
```

20.5.3 Bloom Filters

Aktivierung:

```
storage:
  rocksdb:
    bloom_filter_bits_per_key: 10 # 10 Bits = ~1% False Positive Rate
    block_based_filter: false     # Full Filter = bessere Performance
```

20.6 Memory-Management

20.6.1 Memory-Profiling

Memory-Leaks finden:

```
import tracemalloc

def profile_memory():
    """Tracked Memory-Allocation"""
    tracemalloc.start()

    # Code ausführen
    result = expensive_operation()

    # Memory Snapshot
    snapshot = tracemalloc.take_snapshot()
    top_stats = snapshot.statistics('lineno')

    print("Top 10 memory allocations:")
    for stat in top_stats[:10]:
        print(f"{stat.filename}:{stat.lineno}: {stat.size / 1024:.1f} KB")

    tracemalloc.stop()
```

20.6.2 Object Pooling

Connection und Result Pooling:

```
from queue import Queue

class ObjectPool:
    def __init__(self, factory, max_size=100):
        self.factory = factory
        self.pool = Queue(maxsize=max_size)
        self._initialize_pool(max_size // 2)

    def _initialize_pool(self, size):
        for _ in range(size):
            self.pool.put(self.factory())

    def acquire(self):
        if self.pool.empty():
            return self.factory()
        return self.pool.get()

    def release(self, obj):
        if not self.pool.full():
            self.pool.put(obj)

# Verwendung für Result Sets
result_pool = ObjectPool(lambda: [], max_size=100)
```

20.7 Netzwerk-Optimierung

20.7.1 Batch Requests

Request Batching:

```
class BatchedClient:
    def __init__(self, client, batch_size=10, flush_interval=0.1):
        self.client = client
        self.batch_size = batch_size
        self.flush_interval = flush_interval
        self.batch = []
        self.last_flush = time.time()

    def query(self, query_str, params=None):
        """Fügt Query zum Batch hinzu"""
        self.batch.append({'query': query_str, 'params': params})

        # Auto-Flush bei Batch-Size oder Timeout
        if len(self.batch) >= self.batch_size or \
            time.time() - self.last_flush > self.flush_interval:
            return self.flush()

    def flush(self):
        """Sendet gesammelten Batch"""
        if not self.batch:
            return []

        results = self.client.batch_query(self.batch)
        self.batch = []
        self.last_flush = time.time()

        return results
```

20.7.2 Kompression

Aktivierung:

```
# themisdb.yaml
network:
  compression:
    enabled: true
    algorithm: zstd      # zstd, gzip, lz4
    level: 3            # 1-22 für zstd
    min_size: 1KB       # Nur bei Größe > 1KB komprimieren
```

20.8 Monitoring und Alerting

20.8.1 Performance-Metriken

Key Metrics:


```
from prometheus_client import Histogram, Counter, Gauge

# Query Performance
query_duration = Histogram(
    'themisdb_query_duration_seconds',
    'Query execution time',
    buckets=[0.01, 0.05, 0.1, 0.5, 1.0, 2.0, 5.0]
)

# Slow Queries
slow_queries = Counter('themisdb_slow_queries_total', 'Slow queries')

# Cache Hit Rate
cache_hits = Counter('themisdb_cache_hits_total', 'Cache hits')
cache_misses = Counter('themisdb_cache_misses_total', 'Cache misses')
cache_hit_rate = Gauge('themisdb_cache_hit_rate', 'Cache hit rate')

@query_duration.time()
def execute_query(query, params):
    start = time.time()
    result = client.query(query, params)
    duration = time.time() - start

    if duration > 1.0:
        slow_queries.inc()

    return result
```

20.8.2 Alert Rules

Prometheus Alerts:

```
groups:
- name: themisdb_performance
  rules:
    # Hohe Query-Latenz
    - alert: HighQueryLatency
      expr: histogram_quantile(0.95, themisdb_query_duration_seconds) > 1
      for: 5m
      annotations:
        summary: "95th percentile query latency > 1s"

    # Niedrige Cache Hit Rate
    - alert: LowCacheHitRate
      expr: themisdb_cache_hit_rate < 0.7
      for: 10m
      annotations:
        summary: "Cache hit rate below 70%"

    # Viele Slow Queries
    - alert: ManySlowQueries
      expr: rate(themisdb_slow_queries_total[5m]) > 10
      for: 5m
      annotations:
        summary: "More than 10 slow queries per minute"
```

20.9 Load Testing

20.9.1 Benchmark-Suite

Eine Performance-Benchmark-Suite misst Read- und Write-Throughput unter verschiedenen Concurrency-Levels. Die Suite nutzt ThreadPoolExecutor für parallele Requests und berechnet Latenz-Perzentile (P50, P95, P99) sowie QPS/WPS (Queries/Writes per Second). Diese Metriken sind essentiell für Capacity Planning und Performance-Regression-Tests.

Vollständiger Code: `examples/21_performance/benchmark_suite.py` (~120 Zeilen)

Basis-Benchmark:

```

import concurrent.futures
import time

class PerformanceBenchmark:
    def __init__(self, client):
        self.client = client

    def benchmark_read(self, num_queries=1000, concurrency=10):
        """Read-Performance mit Latenz-Perzentilen"""
        def single_query():
            start = time.time()
            self.client.query("""FOR product IN products LIMIT 100 RETURN product""")
            return time.time() - start

        with concurrent.futures.ThreadPoolExecutor(max_workers=concurrency) as executor:
            futures = [executor.submit(single_query) for _ in range(num_queries)]
            durations = [f.result() for f in concurrent.futures.as_completed(futures)]

        return {
            'avg': sum(durations) / len(durations),
            'p50': sorted(durations)[len(durations)//2], # Median
            'p95': sorted(durations)[int(len(durations)*0.95)], # 95th Percentile
            'p99': sorted(durations)[int(len(durations)*0.99)], # 99th Percentile
            'qps': num_queries / sum(durations) # Queries per Second
        }

    def benchmark_write(self, num_writes=1000, concurrency=10):
        """Write-Performance mit WPS"""
        def single_write():
            start = time.time()
            self.client.collection('test').insert_one({'data': 'test', 'timestamp': time.time()})
            return time.time() - start

        with concurrent.futures.ThreadPoolExecutor(max_workers=concurrency) as executor:
            futures = [executor.submit(single_write) for _ in range(num_writes)]
            durations = [f.result() for f in concurrent.futures.as_completed(futures)]

        return {

```

```
        'avg': sum(durations) / len(durations),
        'p95': sorted(durations)[int(len(durations)*0.95)],
        'wps': num_writes / sum(durations) # Writes per Second
    }

# Verwendung mit 10k Queries, 50 Threads
benchmark = PerformanceBenchmark(client)
read_results = benchmark.benchmark_read(num_queries=10000, concurrency=50)
print(f"Read QPS: {read_results['qps']:.0f}, P95: {read_results['p95']*1000:.1f}ms")
```

Typische Ergebnisse: - **Read QPS:** 5,000-15,000 (abhängig von Query-Komplexität) - **Write WPS:** 2,000-8,000 (MVCC-Overhead) - **P95 Latency:** 10-50ms (Read), 20-80ms (Write) - **P99 Latency:** 50-200ms (Tail Latency durch GC, I/O)

Weitere Features in vollständiger Suite: - Mixed workload benchmarks (70% Read, 30% Write) - Query-Komplexität-Variationen (simple vs. complex joins) - Throughput vs. Latency Trade-off Analyse - Regression-Tests mit historischen Baselines

20.9.2 Stress Testing

Load Generator:

```
def stress_test(duration_seconds=60, target_qps=1000):  
    """Stress-Test mit Ziel-QPS"""  
    import random  
  
    start_time = time.time()  
    query_count = 0  
    interval = 1.0 / target_qps  
  
    queries = [  
        "FOR p IN products FILTER p.category == @cat RETURN p",  
        "FOR o IN orders FILTER o.status == @status COLLECT AGGREGATE c = COUNT() RETURN c",  
        "FOR c IN customers FILTER c.email == @email RETURN c"  
    ]  
  
    while time.time() - start_time < duration_seconds:  
        query_start = time.time()  
  
        # Random Query ausführen  
        query = random.choice(queries)  
        client.query(query, [random.choice(['active', 'pending', 'test@example.com'])])  
        query_count += 1  
  
        # Rate Limiting  
        elapsed = time.time() - query_start  
        if elapsed < interval:  
            time.sleep(interval - elapsed)  
  
    actual_qps = query_count / duration_seconds  
    print(f"Achieved QPS: {actual_qps:.0f} (target: {target_qps})")
```

20.9 Benchmarks (v1.3.4)

20.9.1 Throughput & Latenz

Workload	Dataset	Hardware	Throughput	P95 Latenz
OLTP Reads	50M docs	8 vCPU / 32 GB	18k QPS	42 ms
OLTP Writes	50M docs	8 vCPU / 32 GB	6k WPS	65 ms
Graph Traversal	10M Knoten, 50M Kanten	16 vCPU / 64 GB	2.5k QPS	110 ms
Vector Search (768-d, HNSW)	10M Vektoren	16 vCPU / 64 GB	1.8k QPS	95 ms
Fulltext Search	30M docs	8 vCPU / 32 GB	4.2k QPS	70 ms
TS Aggregation (Gorilla)	1B Punkte	8 vCPU / 32 GB	12k QPS	38 ms

Konfiguration: - RocksDB LZ4 (Level 0-5), ZSTD (6+) - Block Cache: 8 GB, Write Buffer: 512 MB - WAL auf NVMe, Daten auf NVMe

20.9.2 Kompressionseffekte

Datentyp	Codec	Ratio	CPU-Overhead	Latenz-Auswirkung
Time-Series	Gorilla	10-20x	+15% encode	+1-2 ms
Vektoren	SQ8	4x	+20% encode	+2-4 ms Suche
Content Blobs	ZSTD19	1.5-2x	+30%	+5-8 ms Upload

20.9.3 Tuning-Profile

- **Read-Heavy:** Block Cache groß, Compaction auf Level ausgeglichen, `max_background_jobs` hoch
- **Write-Heavy:** Größere WAL, `min_write_buffer_number_to_merge` erhöhen, LZ4-only
- **Vector-Heavy:** Mehr RAM für HNSW, SQ8 aktivieren ab 1M Vektoren, Cache Warmup
- **TS-Heavy:** Gorilla an, 24h-Chunks, `target_file_size_base` erhöhen

Abb. 21.2: Index-Selection-Strategy

20.9A LLM-Performance-Optimierungen (v1.4.0-alpha)

20.9A.1 Flash Attention

Neu in v1.4.0-alpha: IO-bewusste Attention-Implementierung für deutlich verbesserte Speicher-Effizienz und Geschwindigkeit bei LLM-Inferenz.

Problem mit Standard-Attention:

Klassische Self-Attention allokiert temporär große Attention-Matrizen im HBM (High-Bandwidth Memory), was zu: - Hohem Speicherverbrauch: $O(N^2)$ für Sequenzlänge N - Vielen Speicher-Transfers zwischen HBM und SRAM - Suboptimaler GPU-Auslastung führt

Flash Attention Lösung:

Abb. 21.3: Cache-Hierarchy-Diagramm

Aktivierung in ThemisDB:

```
// themis.conf - Flash Attention Konfiguration
llm:
  local_models:
    llama-70b:
      attention_implementation: 'flash_attention_2' // flash_attention_2 oder standard
      flash_attention:
        enabled: true
        version: 2 // Flash Attention 2 (neueste Version)
        block_size_q: 128 // Query block size
        block_size_kv: 128 // Key/Value block size
        causal: true // Für autoregressive Models
```

AQL-Konfiguration:

```
// Flash Attention explizit aktivieren/deaktivieren
FOR doc IN documents
  LIMIT 100
  LET summary = PROMPT('llama-70b-local',
    CONCAT('Summarize: ', doc.content),
    {
      max_tokens: 500,
      attention_config: {
        implementation: 'flash_attention_2',
        enable_memory_efficient: true
      }
    }
  )
  RETURN summary
```

Performance-Metriken:

Metric	Standard Attention	Flash Attention	Verbesserung
GPU Memory	38.5 GB	24.2 GB	-37%
Throughput	185 tokens/s	312 tokens/s	+69%
Latenz (p50)	1.85s	1.12s	-39%
Latenz (p99)	3.20s	1.95s	-39%
Batch Size (max)	32	64	+100%

Benchmark-Beispiel:


```
// Performance-Vergleich durchführen
LET benchmark_results = (
  FOR attention_type IN ['standard', 'flash_attention_2']
    LET start_time = DATE_NOW()

    LET results = (
      FOR doc IN documents
        LIMIT 1000
        RETURN PROMPT('llama-70b-local',
          CONCAT('Summarize in 3 sentences: ', doc.content),
          {
            max_tokens: 100,
            attention_config: {implementation: attention_type}
          }
        )
    )

    LET duration_ms = DATE_DIFF(start_time, DATE_NOW(), 'millisecond')

    RETURN {
      attention_type: attention_type,
      duration_ms: duration_ms,
      throughput_tokens_per_sec: (1000 * 100) / (duration_ms / 1000),
      avg_latency_ms: duration_ms / 1000
    }
  )

RETURN benchmark_results
```

Hardwareanforderungen:

- **GPU:** NVIDIA Ampere (A100) oder neuere Architektur
- **Compute Capability:** ≥ 8.0 (für Flash Attention 2)
- **CUDA:** ≥ 11.8
- **GPU Memory:** Minimal 24 GB empfohlen

Best Practices:

1. **Aktiviere Flash Attention für lange Sequenzen** (>1024 tokens)
2. **Monitoring:** Überwache GPU-Speichernutzung und Durchsatz
3. **Batch-Größe erhöhen:** Flash Attention ermöglicht größere Batches
4. **Version 2 bevorzugen:** Flash Attention 2 ist deutlich schneller

20.9A.2 Speculative Decoding

Neu in v1.4.0-alpha: Beschleunigte Token-Generierung durch parallele Spekulation mit einem schnellen Draft-Model.

Konzept:

Speculative Decoding nutzt ein kleines, schnelles "Draft Model", um mehrere Tokens parallel zu generieren, die dann vom größeren "Target Model" validiert werden.

Abb. 21.4: Query-Plan-Optimization

Konfiguration:

```
// themis.conf - Speculative Decoding Setup
llm:
  local_models:
    llama-70b:
      speculative_decoding:
        enabled: true
        draft_model: 'llama-7b-local' // Kleines, schnelles Model
        num_speculative_tokens: 5 // Tokens pro Spekulation
        acceptance_threshold: 0.8 // Akzeptanz-Schwelle
```

AQL-Verwendung:

```
// Speculative Decoding für schnellere Generierung
FOR article IN news_articles
  FILTER article.summary == null
  LIMIT 500

  LET summary = PROMPT('llama-70b-local',
    {
      system: 'Create concise 2-sentence summaries.',
      user: article.content
    },
    {
      max_tokens: 100,
      speculative_decoding: {
        enabled: true,
        draft_model: 'llama-7b-local',
        num_tokens: 5,
        acceptance_threshold: 0.85
      }
    }
  )

  UPDATE article WITH {
    summary: summary,
    summarized_at: DATE_NOW()
  } IN news_articles
```

Performance-Charakteristiken:

Model Pair	Base Latenz	Speculative Latenz	Speed-Up	Akzeptanzrate
Llama-70B + Llama-7B	2.8s	1.1s	2.5x	82%
Llama-70B + Llama-13B	2.8s	1.3s	2.2x	88%
GPT-4 + GPT-3.5	3.5s	1.6s	2.2x	78%

Akzeptanzraten-Analyse:

```
// Analysiere Speculative Decoding Statistiken
RETURN LLM_SPECULATIVE_STATS({
  model: 'llama-70b-local',
  from: DATE_SUBTRACT(DATE_NOW(), 7, 'day'),
  to: DATE_NOW()
})
```

Output:

```
{
  "total_requests": 45200,
  "speculative_tokens_proposed": 226000,
  "tokens_accepted": 185460,
  "acceptance_rate": 0.821,
  "avg_speedup": 2.4,
  "latency_reduction_percent": 58.3,
  "draft_model_overhead_ms": 45,
  "net_benefit_ms": 1680
}
```

Tuning-Guidelines:

1. Draft Model Wahl:

2. Zu klein: Niedrige Akzeptanzrate
3. Zu groß: Geringer Geschwindigkeitsvorteil
4. **Optimal:** 10-20% der Größe des Target Models

5. Tokens pro Spekulation:

6. Mehr Tokens = höheres Potenzial, aber mehr Verwerfungen

7. **Empfehlung:** 4-6 Tokens für beste Balance

8. Acceptance Threshold:

9. Höher = konservativer, weniger Verwerfungen
10. Niedriger = aggressiver, mehr Speed-up Potenzial
11. **Empfehlung:** 0.80-0.85

Use Cases:

- **Optimal:** Lange Textgenerierung (Zusammenfassungen, Artikel)
- **Suboptimal:** Kurze Antworten (<50 tokens) - Overhead überwiegt
- **Nicht empfohlen:** Code-Generierung (Draft Models oft ungenau)

20.9A.3 Continuous Batching

Neu in v1.4.0-alpha: Dynamisches Request-Batching für LLM-Inferenz mit dramatisch verbessertem Durchsatz und reduzierter Latenz.

Problem mit statischem Batching:

Statisches Batching:

Request 1 (100 tokens) ┐

Request 2 (500 tokens) ┌─ Warte bis alle fertig (500 tokens)

Request 3 (50 tokens) ┐ ┘

Request 1,3 warten unnötig!

Lösung mit Continuous Batching:

Continuous Batching:

Request 1 (100 tokens) → ✓ Fertig nach 100 tokens

Request 2 (500 tokens) → → → → ✓ Fertig nach 500 tokens

Request 3 (50 tokens) → ✓ Fertig nach 50 tokens

Request 4 (neu) ─┐ Tritt in Batch ein

Abb. 21.5: Resource-Allocation-Matrix

Detaillierter Timeline-Ablauf:

Abb. 21.6: Performance-Tuning-Workflow

Diagramm-Erklärung: - Static Batching (oben): Alle Requests warten bis zum langsamsten (500 tokens) - Request 1 & 3 fertig nach 100/50 tokens, müssen aber 500 tokens warten - Total Time: 500ms für alle - Verschwendete Zeit: 400ms (Request 1) + 450ms (Request 3)

- **Continuous Batching (unten):** Requests verlassen Batch sobald fertig
- Request 1: 100ms → sofort zurückgegeben
- Request 3: 50ms → sofort zurückgegeben
- Request 2: 500ms → später zurückgegeben

- Request 4: Kann bei 100ms in den aktiven Batch eintreten
- Durchschnittliche Latenz: $(100+500+50+200)/4 = 212\text{ms}$ vs. 500ms (Static)

Konfiguration:

```
// themis.conf - Continuous Batching
llm:
  local_models:
    llama-70b:
      continuous_batching:
        enabled: true
        max_batch_size: 128 // Maximale gleichzeitige Requests
        max_queue_size: 512 // Warteschlange
        batch_timeout_ms: 50 // Max Wartezeit für Batch-Bildung
        dynamic_batching: true
```

AQL-Integration:

```
// Continuous Batching wird automatisch verwendet
// Keine spezielle Konfiguration nötig - transparent für User

FOR customer IN customers
  FILTER customer.churn_risk == null

  LET analysis = PROMPT('llama-70b-local',
    {
      system: 'Analyze customer data for churn risk.',
      user: TO_STRING(customer)
    },
    {
      max_tokens: 200,
      temperature: 0.3
      // Continuous batching automatisch aktiv
    }
  )

  UPDATE customer WITH {
    churn_analysis: analysis,
    analyzed_at: DATE_NOW()
  } IN customers
```

Performance-Vergleich:

Metric	Static Batching	Continuous Batching	Verbesserung
Throughput	450 req/s	1240 req/s	+176%
Avg Latency	2.8s	1.2s	-57%
P95 Latency	5.4s	2.1s	-61%
GPU Utilization	62%	94%	+52%
Queue Wait Time	850ms	120ms	-86%

Durchsatz-Benchmark:

```
// Durchsatz über Zeit messen
LET throughput_test = (
  LET start = DATE_NOW()

  // Sende 1000 Requests parallel
  LET results = (
    FOR i IN 1..1000
      RETURN ASYNC PROMPT('llama-70b-local',
        CONCAT('Analyze: ', RANDOM_TOKEN(100, 500)),
        {max_tokens: FLOOR(RAND() * 200) + 50}
      )
  )

  // Warte auf alle Ergebnisse
  LET completed = (FOR r IN results RETURN WAIT(r))

  LET duration_s = DATE_DIFF(start, DATE_NOW(), 'second')

  RETURN {
    total_requests: 1000,
    duration_seconds: duration_s,
    throughput_req_per_sec: 1000 / duration_s,
    avg_latency_ms: (duration_s * 1000) / 1000
  }
)

RETURN throughput_test
```

Monitoring und Tuning:

```
// Continuous Batching Metriken
RETURN LLM_BATCHING_STATS('llama-70b-local')
```

Output:


```
{
  "mode": "continuous",
  "current_batch_size": 87,
  "max_batch_size": 128,
  "queue_length": 12,
  "max_queue_size": 512,
  "batch_fill_rate": 0.68,
  "avg_batch_size_last_hour": 73.5,
  "requests_per_second": 1185,
  "gpu_utilization": 0.93,
  "avg_wait_time_ms": 95,
  "p95_wait_time_ms": 210,
  "batches_formed_last_hour": 58420
}
```

Tuning-Parameter:

1. **max_batch_size:**
2. Zu klein: Versenkter Durchsatz
3. Zu groß: OOM auf GPU
4. **Empfehlung:** GPU Memory / Avg Request Memory
5. **batch_timeout_ms:**
6. Zu kurz: Kleine Batches, versenkter Durchsatz
7. Zu lang: Unnötige Wartezeiten
8. **Empfehlung:** 20-100ms je nach Workload
9. **max_queue_size:**
10. Sollte 4-8x größer als max_batch_size sein
11. Zu klein: Requests werden abgelehnt
12. **Empfehlung:** $4 * \text{max_batch_size}$

Best Practices:

1. **Aktiviere für Produktions-Workloads** - Immer ein Gewinn
2. **Monitor Queue Länge** - Warnung bei Sättigung
3. **Load Testing** - Optimale Batch-Größe finden
4. **Kombiniere mit Paged Attention** - Maximale Memory-Effizienz

20.10 Best Practices Checklist

20.10.1 Query-Optimierung

- ☐ Indexes für häufige WHERE-Clauses
- ☐ Composite Indexes für Multi-Column Filters
- ☐ EXPLAIN ANALYZE für langsame Queries
- ☐ Batch Operations statt Einzelqueries
- ☐ Query-Caching für häufige Abfragen
- ☐ Prepared Statements verwenden

20.10.2 Index-Management

- ☐ Regelmäßige Index-Wartung
- ☐ Ungenutzte Indexes entfernen
- ☐ Index-Fragmentation überwachen
- ☐ Covering Indexes für häufige Queries
- ☐ Index-Größe überwachen

20.10.3 Connection-Management

- ☐ Connection Pooling aktiviert
- ☐ Pool-Size optimal konfiguriert
- ☐ Connection-Leaks vermeiden
- ☐ Timeout-Werte angemessen
- ☐ Connection-Validierung aktiviert

20.10.4 RocksDB-Tuning

- ☐ Write Buffer Size angepasst
- ☐ Block Cache konfiguriert
- ☐ Compaction-Parameter optimiert
- ☐ Bloom Filter aktiviert
- ☐ Compression konfiguriert

20.10.5 Monitoring

- [] Performance-Metriken erfasst
- [] Slow Query Log aktiviert
- [] Alert Rules konfiguriert
- [] Regelmäßige Benchmarks
- [] Capacity Planning durchgeführt

20.11 Zusammenfassung

Kernpunkte: - Systematische Performance-Analyse ist essentiell - Indexes sind der wichtigste Optimierungshebel - Query-Rewriting kann dramatische Verbesserungen bringen - Connection Pooling ist kritisch für Skalierbarkeit - RocksDB-Tuning beeinflusst grundlegende Performance - Monitoring ermöglicht proaktive Optimierung - Load Testing validiert Performance-Verbesserungen

Performance-Ziele: - Query Latency P95 < 100ms - Cache Hit Rate > 80% - Connection Pool Utilization < 80% - QPS: 10,000+ für Read-Heavy Workloads - Write Throughput: 5,000+ WPS

Teil VII - Clients & Entwicklung

Kapitel 22: Kapitel 22 - Clients

21.1 Einführung in ThemisDB Client-Ökosystem

ThemisDB bietet eine umfassende Palette an Client-Libraries und Treibern für verschiedene Programmiersprachen und Plattformen. Diese ermöglichen es Entwicklern, nahtlos mit ThemisDB zu interagieren, unabhängig vom gewählten Tech-Stack.

21.1.1 Architektur der Client-Libraries

Die ThemisDB Client-Architecture basiert auf einem mehrschichtigen Ansatz:

- 1. Protokoll-Layer:** - **Binary Protocol:** Hochperformantes binäres Protokoll für maximale Effizienz - **HTTP/REST API:** RESTful Interface für einfache Integration - **WebSocket:** Bidirektionale Kommunikation für Realtime-Features
- 2. Connection Management:** - **Connection Pooling:** Effiziente Verwaltung von Datenbankverbindungen - **Automatic Reconnection:** Automatisches Wiederherstellen nach Verbindungsabbruch - **Load Balancing:** Verteilung von Anfragen über mehrere Server
- 3. Query Interface:** - **AQL Builder:** Fluent API zum Erstellen von Queries - **ORM Support:** Object-Relational Mapping für typsichere Datenmodelle - **Raw Query:** Direkter Zugriff auf AQL für maximale Flexibilität

Abb. 22.1: Client-SDK-Architektur

21.1.2 Unterstützte Sprachen

ThemisDB bietet offizielle Clients für:

- **Python** (themisdb-python) - Vollständiger Feature-Support
- **JavaScript/TypeScript** (themisdb-js) - Node.js und Browser
- **Java** (themisdb-java) - Enterprise-ready JDBC-Treiber
- **Go** (themisdb-go) - High-performance native Client
- **C#/.NET** (ThemisDB.NET) - .NET Standard 2.0+
- **Rust** (themisdb-rs) - Memory-safe native Client
- **Ruby** (themisdb-ruby) - Rails-freundlich
- **PHP** (themisdb-php) - Laravel & Symfony Support

21.2 Python Client (themisdb-python)

Der Python Client ist die am weitesten entwickelte und feature-reichste Client-Library für ThemisDB.

21.2.1 Installation & Setup

```
# Installation via pip
pip install themisdb

# Mit optionalen Dependencies
pip install themisdb[async,pandas]

# Development Version
pip install git+https://github.com/themisdb/themisdb-python.git
```

Basis-Verbindung:

```
from themisdb import ThemisDB

# Einfache Verbindung
db = ThemisDB("localhost", 7687)

# Mit Authentifizierung
db = ThemisDB(
    host="localhost",
    port=7687,
    username="admin",
    password="secure_password",
    database="mydb"
)

# Connection String
db = ThemisDB.from_uri("themis://admin:password@localhost:7687/mydb")
```

21.2.2 CRUD-Operationen

```
# CREATE - Dokument einfügen
user = db.insert("users", {
    "name": "Alice",
    "email": "alice@example.com",
    "age": 30
})
print(f"Created user with ID: {user['id']}")

# READ - Einzelnes Dokument
user = db.find_one("users", {"email": "alice@example.com"})

# UPDATE - Dokument aktualisieren
db.update("users",
    {"email": "alice@example.com"},
    {"$set": {"age": 31}}
)

# DELETE - Dokument löschen
db.delete("users", {"email": "alice@example.com"})
```

21.2.3 Query Builder API

```
from themisdb import Query

# Fluent Query Building
users = (Query(db, "users")
        .filter(age__gte=18)
        .filter(active=True)
        .order_by("-created_at")
        .limit(10)
        .all())

# Komplexe Queries
active_admins = (Query(db, "users")
                .filter(role="admin", status="active")
                .select("id", "name", "email")
                .join("profiles", on="user_id")
                .all())

# Aggregationen
stats = (Query(db, "orders")
        .filter(status="completed")
        .group_by("customer_id")
        .aggregate({
            "total_amount": "SUM(amount)",
            "order_count": "COUNT(*)",
            "avg_amount": "AVG(amount)"
        }))
```

21.2.4 ORM (Object-Relational Mapping)

Das ORM-Feature ermöglicht es, Python-Klassen direkt auf Collections zu mappen. Es bietet Type-Safety, Validierung und automatisches Schema-Management. Besonders nützlich sind die automatischen Timestamps (`auto_now_add` , `auto_now`) und die Beziehungen zwischen Models.

Vollständiger Code: `examples/22_clients/python_orm_demo.py` (~80 Zeilen)


```
from themisdb.orm import Model, Field
from datetime import datetime

class User(Model):
    __collection__ = "users"

    name = Field(str, required=True)
    email = Field(str, unique=True)
    age = Field(int, min=0, max=150)
    created_at = Field(datetime, auto_now_add=True)
    updated_at = Field(datetime, auto_now=True)

# CRUD-Operationen
user = User(name="Bob", email="bob@example.com", age=25)
user.save() # INSERT

users = User.objects.filter(age__gte=18).all() # SELECT mit Filter
bob = User.objects.get(email="bob@example.com") # SELECT by unique field

bob.age = 26
bob.save() # UPDATE

bob.delete() # DELETE

# Foreign Keys & Related Objects
class Post(Model):
    __collection__ = "posts"
    title = Field(str)
    author = Field(User, foreign_key=True) # Beziehung zu User

post = Post.objects.first()
print(f"Author: {post.author.name}") # Automatisches Lazy-Loading
```

Weitere ORM-Features im vollständigen Beispiel: - Bulk-Operations (`objects.bulk_create()`) - Aggregation (`objects.aggregate()`) - Query Prefetching zur Performance-Optimierung - Custom Validators und Model-Methods

21.2.5 Async/Await Support

```
import asyncio
from themisdb import AsyncThemisDB

async def main():
    # Async Connection
    db = AsyncThemisDB("localhost", 7687)

    # Async Queries
    users = await db.find("users", {"active": True})

    # Concurrent Operations
    results = await asyncio.gather(
        db.find("users", {"role": "admin"}),
        db.find("orders", {"status": "pending"}),
        db.find("products", {"in_stock": True})
    )

    await db.close()

asyncio.run(main())
```

21.2.6 Transaktionen

```
# Context Manager für Transaktionen
with db.transaction() as tx:
    # Geld von Account A nach B überweisen
    account_a = tx.find_one("accounts", {"id": "A"})
    account_b = tx.find_one("accounts", {"id": "B"})

    if account_a["balance"] >= 100:
        tx.update("accounts", {"id": "A"},
                  {"$inc": {"balance": -100}})
        tx.update("accounts", {"id": "B"},
                  {"$inc": {"balance": 100}})
        tx.commit()
    else:
        tx.rollback()

# Async Transactions
async with db.transaction() as tx:
    await tx.insert("logs", {"action": "transfer", "amount": 100})
    await tx.commit()
```

21.2.7 Pandas Integration

```
import pandas as pd

# AQL Query zu DataFrame
df = db.to_dataframe("""
    FOR u IN users
      FILTER u.age > 18
      RETURN u
""")

# DataFrame zu ThemisDB
df.to_themis(db, collection="users", if_exists="append")

# Aggregationen mit Pandas
user_stats = (
    db.to_dataframe("FOR u IN users RETURN u")
    .groupby("country")
    .agg({
        "id": "count",
        "age": ["mean", "median"],
        "income": "sum"
    })
)
```

21.3 JavaScript/TypeScript Client

21.3.1 Installation

```
# NPM
npm install themisdb

# Yarn
yarn add themisdb

# TypeScript Definitionen (bereits enthalten)
```

21.3.2 Node.js Usage

```
const { ThemisDB } = require('themisdb');

// Connection
const db = new ThemisDB({
  host: 'localhost',
  port: 7687,
  username: 'admin',
  password: 'password',
  database: 'mydb'
});

// Async/Await
async function getUsers() {
  const users = await db.collection('users')
    .find({ active: true })
    .sort({ name: 1 })
    .limit(10)
    .toArray();

  return users;
}

// Promises
db.collection('users')
  .findOne({ email: 'user@example.com' })
  .then(user => console.log(user))
  .catch(err => console.error(err));
```

21.3.3 TypeScript Support

```
interface User {
  id: string;
  name: string;
  email: string;
  age: number;
  active: boolean;
}

const db = new ThemisDB<{
  users: User;
  posts: Post;
}>({
  host: 'localhost',
  port: 7687
});

// Type-safe Queries
const users: User[] = await db.collection('users')
  .find<User>({ age: { $gte: 18 } })
  .toArray();

// Type-safe Inserts
await db.collection('users').insertOne({
  name: "Alice",
  email: "alice@example.com",
  age: 30,
  active: true
});
```

21.3.4 Browser Usage

```
<!DOCTYPE html>
<html>
<head>
  <script src="https://cdn.themisdb.io/themisdb-browser.min.js"></script>
</head>
<body>
  <script>
    const db = new ThemisDB({
      url: 'https://api.example.com/themis',
      apiKey: 'your-api-key'
    });

    // WebSocket für Realtime
    db.collection('messages')
      .watch()
      .on('insert', (doc) => {
        console.log('New message:', doc);
      });
  </script>
</body>
</html>
```

21.3.4 React Integration

```
import React, { useState, useEffect } from 'react';
import { useThemisDB } from 'themisdb/react';

function UserList() {
  const { data, loading, error } = useThemisDB(
    'users',
    { active: true },
    { sort: { name: 1 } }
  );

  if (loading) return <div>Loading...</div>;
  if (error) return <div>Error: {error.message}</div>;

  return (
    <ul>
      {data.map(user => (
        <li key={user.id}>{user.name}</li>
      ))}
    </ul>
  );
}
```


21.4 Java Client & JDBC Driver

21.4.1 Maven Dependency

```
<dependency>
  <groupId>io.themisdb</groupId>
  <artifactId>themisdb-java</artifactId>
  <version>1.3.4</version>
</dependency>

<!-- JDBC Driver -->
<dependency>
  <groupId>io.themisdb</groupId>
  <artifactId>themisdb-jdbc</artifactId>
  <version>1.3.4</version>
</dependency>
```

21.4.2 Native Client API

```
import io.themisdb.ThemisDB;
import io.themisdb.Document;

public class Example {
    public static void main(String[] args) {
        // Connection
        ThemisDB db = ThemisDB.connect()
            .host("localhost")
            .port(7687)
            .username("admin")
            .password("password")
            .database("mydb")
            .build();

        // Insert
        Document user = new Document()
            .append("name", "Alice")
            .append("email", "alice@example.com")
            .append("age", 30);

        db.collection("users").insertOne(user);

        // Query
        List<Document> users = db.collection("users")
            .find(Filters.eq("active", true))
            .sort(Sorts.ascending("name"))
            .limit(10)
            .into(new ArrayList<>());

        db.close();
    }
}
```

21.4.3 JDBC Integration

```
import java.sql.*;

public class JdbcExample {
    public static void main(String[] args) throws SQLException {
        // JDBC Connection
        String url = "jdbc:themis://localhost:7687/mydb";
        Properties props = new Properties();
        props.setProperty("user", "admin");
        props.setProperty("password", "password");

        Connection conn = DriverManager.getConnection(url, props);

        // AQL Query mit Parameter
        String aql = "FOR u IN users FILTER u.age > @minAge SORT u.name RETURN u";
        PreparedStatement stmt = conn.prepareStatement(aql);
        stmt.setInt(1, 18); // @minAge Parameter

        ResultSet rs = stmt.executeQuery();
        while (rs.next()) {
            System.out.println(
                rs.getString("name") + " - " +
                rs.getInt("age")
            );
        }

        rs.close();
        stmt.close();
        conn.close();
    }
}
```

21.4.4 Spring Data Integration

```
import org.springframework.data.annotation.Id;
import org.springframework.data.themis.repository.ThemisRepository;

// Entity
@Document(collection = "users")
public class User {
    @Id
    private String id;
    private String name;
    private String email;
    private Integer age;

    // Getters and Setters
}

// Repository
public interface UserRepository extends ThemisRepository<User, String> {
    List<User> findByAge(Integer age);
    List<User> findByNameContaining(String name);
    Optional<User> findByEmail(String email);

    @Query("{ 'age': { '$gte': ?0 } }")
    List<User> findAdults(int minAge);
}

// Service
@Service
public class UserService {
    @Autowired
    private UserRepository userRepository;

    public List<User> getActiveUsers() {
        return userRepository.findByAge(18);
    }
}
```

21.5 Go Client

21.5.1 Installation

```
go get github.com/themisdb/themisdb-go
```

21.5.2 Basic Usage

Der Go-Client bietet eine idiomatische API mit Context-Support für Cancellation und Timeouts. Die Verwendung von Interfaces (`map[string]interface{}`) erlaubt flexible Datenstrukturen, während Struct-Mapping (siehe nächster Abschnitt) Type-Safety bietet.

Vollständiger Code: `examples/22_clients/go_client_demo.go` (~120 Zeilen)

```
package main

import (
    "context"
    "fmt"
    "github.com/themisdb/themisdb-go"
)

func main() {
    // Connection mit Auth und Database-Selection
    client, err := themisdb.Connect(
        context.Background(),
        "localhost:7687",
        themisdb.WithAuth("admin", "password"),
        themisdb.WithDatabase("mydb"),
    )
    if err != nil {
        panic(err)
    }
    defer client.Close()

    // Insert Document
    user := map[string]interface{}{
        "name": "Alice", "email": "alice@example.com", "age": 30,
    }
    result, err := client.Collection("users").InsertOne(context.Background(), user)

    // Query mit Filter
    cursor, err := client.Collection("users").Find(
        context.Background(),
        themisdb.M{"active": true}, // Filter
    )

    var users []map[string]interface{}
    cursor.All(context.Background(), &users)
}
```

Weitere Features im vollständigen Beispiel: - Batch-Insert mit `InsertMany()` - Update/Delete mit Filter-Conditions - Aggregation Pipeline - Transaction-Support mit `StartSession()`

21.5.3 Struct Mapping

```
type User struct {
    ID          string    `themis:"_id,omitempty"`
    Name        string    `themis:"name"`
    Email       string    `themis:"email"`
    Age         int       `themis:"age"`
    Active      bool      `themis:"active"`
    CreatedAt   time.Time `themis:"created_at"`
}

// Insert with Struct
user := User{
    Name:    "Bob",
    Email:   "bob@example.com",
    Age:     25,
    Active:  true,
}

_, err := client.Collection("users").InsertOne(ctx, user)

// Find with Struct
var users []User
cursor, _ := client.Collection("users").Find(ctx, themisdb.M{"age": themisdb.M{"$gte": 18}})
cursor.All(ctx, &users)
```

21.6 C#/.NET Client

21.6.1 NuGet Installation

```
dotnet add package ThemisDB.Driver
```

21.6.2 Basic Operations

```
using ThemisDB;

// Connection
var client = new ThemisClient("localhost:7687");
var db = client.GetDatabase("mydb");

// Insert
var user = new BsonDocument
{
    { "name", "Alice" },
    { "email", "alice@example.com" },
    { "age", 30 }
};

db.GetCollection("users").InsertOne(user);

// Query
var filter = Builders<BsonDocument>.Filter.Eq("active", true);
var users = db.GetCollection("users")
    .Find(filter)
    .SortBy(u => u["name"])
    .Limit(10)
    .ToList();
```


21.6.3 POCO Mapping

```
public class User
{
    public ObjectId Id { get; set; }
    public string Name { get; set; }
    public string Email { get; set; }
    public int Age { get; set; }
    public bool Active { get; set; }
}

// Typed Collection
var collection = db.GetCollection<User>("users");

// Insert
var user = new User
{
    Name = "Alice",
    Email = "alice@example.com",
    Age = 30,
    Active = true
};

collection.InsertOne(user);

// Query
var adults = collection
    .Find(u => u.Age >= 18)
    .SortBy(u => u.Name)
    .ToList();
```

21.7 Connection Pooling & Performance

21.7.1 Connection Pool Konfiguration

Python:

```
db = ThemisDB(  
    "localhost", 7687,  
    pool_size=20,           # Max connections  
    pool_timeout=30,        # Timeout in Sekunden  
    pool_max_idle_time=300, # Max idle time  
    pool_recycle=3600       # Connection recycling  
)
```

JavaScript:

```
const db = new ThemisDB({  
    host: 'localhost',  
    port: 7687,  
    poolSize: 20,  
    poolTimeout: 30000,  
    idleTimeout: 300000  
});
```

Java:

```
ThemisDB db = ThemisDB.connect()  
    .host("localhost")  
    .port(7687)  
    .poolSize(20)  
    .poolTimeout(30000)  
    .build();
```

21.7.2 Performance Best Practices

1. Batch Operations:

```
# Ineffizient - Einzelne Inserts
for user in users:
    db.insert("users", user)

# Effizient - Batch Insert
db.insert_many("users", users)
```

2. Index Hints:

```
# Mit Index Hint
users = db.find("users",
    {"age": {"$gte": 18}},
    hint="age_idx"
)
```

3. Projection (Nur benötigte Felder):

```
# Nur Name und Email laden
users = db.find("users",
    {"active": True},
    projection={"name": 1, "email": 1}
)
```

4. Cursor Batching:

```
# Große Resultsets in Batches
cursor = db.find("users", {}, batch_size=1000)
for batch in cursor.batches():
    process_batch(batch)
```

21.8 Error Handling & Retry Logic

21.8.1 Exception Hierarchy

```
from themisdb.exceptions import (  
    ThemisDBError,          # Base Exception  
    ConnectionError,        # Verbindungsfehler  
    QueryError,             # Query-Fehler  
    TimeoutError,           # Timeout  
    DuplicateKeyError,      # Unique Constraint  
    ValidationError         # Schema Validation  
)  
  
try:  
    db.insert("users", user)  
except DuplicateKeyError:  
    print("User already exists")  
except ValidationError as e:  
    print(f"Invalid data: {e.details}")  
except ConnectionError:  
    print("Cannot connect to database")
```

21.8.2 Automatic Retry

```
from themisdb.retry import RetryPolicy  
  
db = ThemisDB(  
    "localhost", 7687,  
    retry_policy=RetryPolicy(  
        max_attempts=3,  
        backoff_multiplier=2,  
        initial_delay=1.0,  
        max_delay=30.0,  
        retry_on=[ConnectionError, TimeoutError]  
    )  
)
```

21.9 Monitoring & Logging

21.9.1 Query Logging

```
import logging

# Enable Query Logging
logging.basicConfig(level=logging.DEBUG)
logger = logging.getLogger('themisdb')

db = ThemisDB("localhost", 7687, log_queries=True)

# Custom Logger
db.set_logger(logger, log_slow_queries=True, slow_threshold=1.0)
```

21.9.2 Performance Metrics

```
# Performance Monitoring
with db.profiler() as prof:
    users = db.find("users", {"age": {"$gte": 18}})

print(f"Query time: {prof.elapsed}ms")
print(f"Documents returned: {prof.docs_returned}")
print(f"Documents scanned: {prof.docs_scanned}")
```

21.10 Security & Authentication

21.10.1 TLS/SSL Verbindungen

```
# Python
db = ThemisDB(
    "secure.example.com", 7687,
    ssl=True,
    ssl_ca_cert="/path/to/ca.pem",
    ssl_certfile="/path/to/client-cert.pem",
    ssl_keyfile="/path/to/client-key.pem"
)

# JavaScript
const db = new ThemisDB({
  host: 'secure.example.com',
  port: 7687,
  ssl: true,
  sslCA: fs.readFileSync('ca.pem'),
  sslCert: fs.readFileSync('client-cert.pem'),
  sslKey: fs.readFileSync('client-key.pem')
});
```

21.10.2 Token-basierte Authentifizierung

```
# JWT Token
db = ThemisDB(
    "api.example.com", 7687,
    auth_token="eyJhbGciOiJIUzI1NiIsInR5cCI6IkpXVCJ9...",
    token_refresh_callback=get_new_token
)

def get_new_token():
    # Token renewal logic
    return request_new_token()
```

21.11 Migration zwischen Clients

21.11.1 Von MongoDB zu ThemisDB

```
# MongoDB Code
from pymongo import MongoClient
mongo_client = MongoClient('mongodb://localhost:27017/')
users = mongo_client.mydb.users.find({'age': {'$gte': 18}})

# ThemisDB äquivalent
from themisdb import ThemisDB
db = ThemisDB('localhost', 7687)
users = db.find('users', {'age': {'$gte': 18}})
```

Die API ist weitgehend kompatibel, was Migration erleichtert.

21.12 Zusammenfassung

ThemisDB bietet eine umfassende Client-Library-Unterstützung mit:

- **Multi-Language Support:** Offizielle Clients für 8+ Sprachen
- **Consistent API:** Ähnliche Konzepte über alle Clients
- **High Performance:** Connection Pooling, Batch Operations
- **Type Safety:** ORM und Typed Clients
- **Production Ready:** Error Handling, Retry Logic, Monitoring
- **Framework Integration:** Spring Data, Django ORM, etc.

Best Practices: 1. Verwenden Sie Connection Pooling in Production 2. Nutzen Sie Batch Operations für große Datenmengen 3. Implementieren Sie Retry Logic für transiente Fehler 4. Aktivieren Sie Query Logging während Development 5. Verwenden Sie Type-Safe Clients (TypeScript, Java mit Generics)

Im nächsten Kapitel betrachten wir die Integration von ThemisDB in populäre Frameworks wie Django, Spring Boot, Express.js und mehr.

Kapitel 23: Kapitel 23 - Testing & QA

"Untested code is legacy code. In ThemisDB, comprehensive testing is not optional—it's architecture."

Überblick

Zuverlässige Datenbanken erfordern rigorose Tests auf mehreren Ebenen: Unit-Tests für AQL-Funktionen, Integrationstests für Transaktionen, Performance-Tests für Sharding, und Chaos-Tests für Netzwerkfehler.

Was Sie in diesem Kapitel lernen: - AQL Unit-Testing mit AQL-Assertions - Transaktions-Integrationstests - Performance-Benchmarking - Chaos Engineering für Fehlerszenarien - Mutation Testing für Query-Robustheit - CI/CD Pipeline-Integration

Abb. 23.0: CI/CD Test-Pipeline

23.0 Test-Strategie Überblick

Abb. 23.0: CI/CD Test-Pipeline: Automatisierte Qualitätssicherung auf mehreren Ebenen

23.1 AQL Unit Testing

Test-Framework Setup

```
-- test_utils.aql: Utility-Funktionen für Tests
FUNCTION assert_equal(actual, expected, message) {
  IF actual != expected THEN
    THROW ERROR(CONCAT("Assertion failed: ", message,
      " (expected: ", expected, ", got: ", actual, ")"))
  END
  RETURN {passed: true, message: message}
}

FUNCTION assert_true(condition, message) {
  IF !condition THEN
    THROW ERROR(CONCAT("Assertion failed: ", message))
  END
  RETURN {passed: true}
}

FUNCTION assert_length(collection, expected_count, message) {
  LET actual_count = LENGTH(collection)
  IF actual_count != expected_count THEN
    THROW ERROR(CONCAT(message, " - Expected ", expected_count,
      " items, got ", actual_count))
  END
  RETURN {passed: true, count: actual_count}
}
```

Datenvorbereitung (Fixtures)

```
FUNCTION setup_test_data() {  
  -- Cleanup  
  FOR doc IN test_users  
    REMOVE doc IN test_users  
  
  -- Fixtures einfügen  
  FOR user IN [  
    {_key: "alice", name: "Alice", role: "admin", created_at: DATE_NOW()},  
    {_key: "bob", name: "Bob", role: "user", created_at: DATE_NOW()},  
    {_key: "charlie", name: "Charlie", role: "user", created_at: DATE_NOW()}  
  ]  
    INSERT user INTO test_users  
  
  RETURN {inserted: 3, status: "ready"}  
}  
  
FUNCTION teardown_test_data() {  
  FOR doc IN test_users  
    REMOVE doc IN test_users  
  RETURN {cleaned: true}  
}
```

Test Cases für Geschäftslogik

```
-- Test 1: Benutzerverwaltung
FUNCTION test_user_creation() {
  CALL setup_test_data()

  -- Neuen User einfügen
  INSERT {_key: "dave", name: "Dave", role: "user"} INTO test_users

  -- Assertion: User existiert
  LET user = DOCUMENT("test_users/dave")
  CALL assert_equal(user.name, "Dave", "User name mismatch")
  CALL assert_equal(user.role, "user", "User role mismatch")

  CALL teardown_test_data()
  RETURN {test: "test_user_creation", status: "PASSED"}
}

-- Test 2: Permission-Checks
FUNCTION test_admin_permissions() {
  CALL setup_test_data()

  LET admin = DOCUMENT("test_users/alice")
  CALL assert_equal(admin.role, "admin", "Admin role check")

  CALL teardown_test_data()
  RETURN {test: "test_admin_permissions", status: "PASSED"}
}

-- Test 3: Transaktionale Konsistenz
FUNCTION test_transfer_consistency() {
  -- Zwei Test-Accounts mit initialen Balances
  INSERT {_key: "acc1", balance: 1000, owner: "alice"} INTO test_accounts
  INSERT {_key: "acc2", balance: 500, owner: "bob"} INTO test_accounts

  -- Überweisung: 200 von acc1 zu acc2
  FOR acc IN test_accounts
    FILTER acc._key == "acc1"
    UPDATE acc WITH {balance: acc.balance - 200}
```

```
FOR acc IN test_accounts
  FILTER acc._key == "acc2"
  UPDATE acc WITH {balance: acc.balance + 200}

-- Assertion: Beide Accounts korrekt
LET acc1 = DOCUMENT("test_accounts/acc1")
LET acc2 = DOCUMENT("test_accounts/acc2")
CALL assert_equal(acc1.balance, 800, "Account 1 balance")
CALL assert_equal(acc2.balance, 700, "Account 2 balance")

RETURN {test: "test_transfer_consistency", status: "PASSED"}
}
```

23.2 Integrations-Tests

Multi-Collection Queries

```
FUNCTION test_complex_join_query() {  
  -- Setup  
  INSERT [  
    {_key: "p1", title: "Product A", price: 100},  
    {_key: "p2", title: "Product B", price: 200}  
  ] INTO test_products  
  
  INSERT [  
    {_key: "o1", product_id: "p1", quantity: 2, customer: "alice"},  
    {_key: "o2", product_id: "p2", quantity: 1, customer: "bob"}  
  ] INTO test_orders  
  
  -- Query  
  LET results = (  
    FOR order IN test_orders  
      LET product = DOCUMENT(order.product_id)  
      RETURN {  
        order_id: order._key,  
        product: product.title,  
        total: product.price * order.quantity,  
        customer: order.customer  
      }  
  )  
  
  -- Assertions  
  CALL assert_length(results, 2, "Expected 2 orders")  
  CALL assert_equal(results[0].total, 200, "Order 1 total (2 * 100)")  
  CALL assert_equal(results[1].total, 200, "Order 2 total (1 * 200)")  
  
  RETURN {test: "test_complex_join_query", status: "PASSED"}  
}
```

Transaktions-Rollback Tests

```
FUNCTION test_transaction_rollback() {  
  -- Initiales Setup  
  INSERT {_key: "src", balance: 1000} INTO test_wallets  
  INSERT {_key: "dst", balance: 0} INTO test_wallets  
  
  -- Fehlgeschlagene Transaktion simulieren  
  TRY  
    -- Transfer verschieben  
    UPDATE "test_wallets/src" WITH {balance: 800}  
    UPDATE "test_wallets/dst" WITH {balance: 200}  
  
    -- Fehler vor Commit  
    THROW ERROR("Simulated network failure")  
  CATCH err  
    -- Bei Fehler sollten beide Wallets unverändert sein  
    -- (In echtem ACID-System auto-rollback)  
  END  
  
  -- Verification (bei echtem ACID Rollback)  
  LET src = DOCUMENT("test_wallets/src")  
  CALL assert_equal(src.balance, 1000, "Source wallet rolled back")  
  
  RETURN {test: "test_transaction_rollback", status: "PASSED"}  
}
```

23.3 Performance-Tests

Query-Performance Benchmarking


```

# test_performance.py: Benchmark-Runner
import time
import themis

client = themis.Client('http://localhost:8529')

def benchmark_query(query_aql, params, iterations=100):
    """Messe Query-Performance über mehrere Iterationen"""
    times = []

    for i in range(iterations):
        start = time.time()
        result = client.query(query_aql, params)
        elapsed = time.time() - start
        times.append(elapsed * 1000) # in ms

    import statistics
    return {
        'min_ms': min(times),
        'max_ms': max(times),
        'avg_ms': statistics.mean(times),
        'p95_ms': sorted(times)[int(len(times) * 0.95)],
        'iterations': iterations
    }

# Test 1: Simple Filter
perf = benchmark_query(
    "FOR u IN users FILTER u.active == true RETURN u",
    {},
    iterations=100
)
print(f"Simple filter: avg {perf['avg_ms']:.2f}ms, p95 {perf['p95_ms']:.2f}ms")

# Test 2: Complex Join
perf = benchmark_query("""
    FOR order IN orders
        LET customer = DOCUMENT(order.customer_id)
        LET items = (FOR oi IN order_items FILTER oi.order_id == order._id RETURN oi)

```

```

    RETURN {order: order, customer: customer, items: items}
  }
  "", {}, iterations=50)
print(f"Complex join: avg {perf['avg_ms']:.2f}ms, p95 {perf['p95_ms']:.2f}ms")

```

Skalierbarkeits-Tests

```

-- Test mit großen Datenmengen
FUNCTION test_scalability_1m_documents() {
  -- Benchmark für 1 Million Dokumente

  -- Measure: Full table scan
  LET scan_start = DATE_NOW()
  LET count = LENGTH(
    FOR doc IN large_collection
    RETURN doc._key
  )
  LET scan_time = DATE_DIFF(scan_start, DATE_NOW(), 'ms')

  -- Measure: Filtered query (mit Index)
  LET filter_start = DATE_NOW()
  LET filtered = LENGTH(
    FOR doc IN large_collection
    FILTER doc.status == "active"
    RETURN doc
  )
  LET filter_time = DATE_DIFF(filter_start, DATE_NOW(), 'ms')

  RETURN {
    collection_size: count,
    scan_time_ms: scan_time,
    filtered_results: filtered,
    filter_time_ms: filter_time,
    throughput_doc_per_sec: count / (scan_time / 1000)
  }
}

```

23.4 Chaos Engineering

Netzwerk-Fehler Simulieren

```

# chaos_test.py: Fehlerhafte Szenarien
import random
from unittest.mock import patch

class ChaosMonkey:
    def __init__(self, client):
        self.client = client
        self.failure_rate = 0.1 # 10% Fehler

    def simulate_network_partition(self, query, params, max_retries=3):
        """Simuliere Netzwerk-Partition mit Retry-Logik"""
        for attempt in range(max_retries):
            try:
                if random.random() < self.failure_rate:
                    raise ConnectionError("Network partition")
                return self.client.query(query, params)
            except ConnectionError as e:
                if attempt == max_retries - 1:
                    raise
                time.sleep(2 ** attempt) # Exponential backoff

    def test_resilience(self):
        """Test ob Application Fehler korrekt behandelt"""
        results = []
        for i in range(100):
            try:
                result = self.simulate_network_partition(
                    "FOR u IN users RETURN u",
                    {}
                )
                results.append({'status': 'success'})
            except Exception as e:
                results.append({'status': 'failed', 'error': str(e)})

        success_rate = sum(1 for r in results if r['status'] == 'success') / len(results)
        print(f"Success rate with 10% failure injection: {success_rate*100:.1f}%")
        return success_rate > 0.95 # Mind. 95% sollten erfolgreich sein

```

```
# Teste Resilience
chaos = ChaosMonkey(client)
assert chaos.test_resilience(), "Application nicht resilient genug"
```

Datenbeschädigung Testen

```
FUNCTION test_data_corruption_detection() {
  -- Simuliere fehlerhafte Schreibvorgänge
  INSERT {_key: "doc1", checksum: NULL, data: {value: 100}} INTO test_collection

  -- Manuell Datenbeschädigung eintragen
  UPDATE "test_collection/doc1" WITH {data: {value: 999}}

  -- Validierungs-Funktion
  FOR doc IN test_collection
    FILTER doc._key == "doc1"
    LET calc_checksum = HASH(JSON_STRINGIFY(doc.data))
    FILTER calc_checksum != doc.checksum
  RETURN {
    doc_id: doc._key,
    status: "CORRUPTED",
    expected_value: 100,
    actual_value: doc.data.value
  }
}
```

23.5 Mutation Testing

Mutation Testing verändert absichtlich Queries, um zu prüfen, ob Tests ausreichen:

```
-- Original Query
FUNCTION get_active_users() {
  FOR user IN users
    FILTER user.status == "active"
  RETURN user
}

-- Mutation 1: Operator-Mutation (== wird zu !=)
-- Test sollte diesen Fehler erkennen:
-- FOR user IN users
--   FILTER user.status != "active"  -- FEHLER: Falscher Operator
--   RETURN user

-- Mutation 2: Literal-Mutation ("active" wird zu "inactive")
-- Test sollte erkennen:
-- FOR user IN users
--   FILTER user.status == "inactive"  -- FEHLER: Falscher Status
--   RETURN user
```

Gutes Mutation-Testing-Result: >85% der Mutationen werden von Tests erkannt.

23.6 CI/CD Integration

GitHub Actions Pipeline

```
# .github/workflows/themis-qa.yml
name: ThemisDB QA Pipeline

on: [push, pull_request]

jobs:
  test:
    runs-on: ubuntu-latest
    steps:
      - uses: actions/checkout@v3

      - name: Start ThemisDB
        run: docker run -d -p 8529:8529 themisdb/server:latest

      - name: Run AQL Unit Tests
        run: |
          python3 test_runner.py --aql-tests

      - name: Run Integration Tests
        run: |
          python3 test_runner.py --integration-tests

      - name: Performance Benchmarks
        run: |
          python3 test_performance.py --baseline baseline.json

      - name: Upload Results
        uses: actions/upload-artifact@v3
        with:
          name: test-results
          path: reports/
```

23.7 Test-Strategie Zusammenfassung

Test-Typ	Häufigkeit	Dauer	Kritikalität
Unit Tests	Jeder Commit	<5s	Hoch
Integration Tests	PR-Request	<30s	Hoch
Performance Tests	Täglich	2-5min	Mittel
Chaos Tests	Wöchentlich	10-20min	Mittel
Load Tests	Vor Release	30-60min	Hoch

Best Practices: - Test-getriebene Entwicklung (TDD) - Mindestens 80% Code-Coverage - Fixtures für reproduzierbare Tests - Parameterisierte Tests für Grenzfälle - Golden Files für Regression-Tests - Automatisierte Performance-Regression-Erkennung

23.8 Property-Based Testing

```
# test_property_based.py
from hypothesis import given, strategies as st

@given(st.lists(st.integers(), min_size=1))
def test_aggregate_sum_commutative(numbers):
    aql = f"RETURN SUM({numbers})"
    result1 = client.execute(aql)
    result2 = client.execute(f"RETURN SUM({list(reversed(numbers))})")
    assert result1 == result2, "SUM must be commutative"
```

23.9 Boundary Value Testing

```
-- test_boundaries.aql
FUNCTION test_pagination() {
  LET cases = [
    {offset: 0, limit: 1},
    {offset: 0, limit: 1000},
    {offset: 999, limit: 1}
  ]
  FOR test IN cases
    RETURN {case: test, valid: true}
}
```

23.10 Flaky Test Prevention

```
def flaky_test_retry(max_attempts=3, backoff=2):
  def decorator(test_func):
    def wrapper(*args, **kwargs):
      for attempt in range(max_attempts):
        try:
          return test_func(*args, **kwargs)
        except Exception:
          if attempt < max_attempts - 1:
            time.sleep(backoff ** attempt)
      raise
    return wrapper
  return decorator
```

23.11 Test Reporting

```
class TestReport:
    def summarize(self, results):
        passed = sum(1 for r in results if r['status'] == 'passed')
        total = len(results)
        return {
            "passed": passed,
            "failed": total - passed,
            "success_rate": (passed / total) * 100
        }
```

Kapitel 24: Kapitel 24 - AI Ethics

Autor: ThemisDB Team

Reviewer: TBD

Status: Draft

Letzte Aktualisierung: 09. Januar 2026

Version: 1.1.0

Lernziele

Nach dem Durcharbeiten dieses Kapitels sollten Sie:

- [x] Die ethischen Herausforderungen von KI-Systemen in der öffentlichen Verwaltung verstehen
- [x] Spezifische Risiken entlang der VCC-Architektur (Covina, Clara, Veritas) identifizieren können
- [x] "Ethik-by-Design"-Prinzipien auf datenbankgestützte KI-Systeme anwenden können
- [x] Das Ethische Richtlinien System (UN Human Rights + Asimov's Laws) verstehen und konfigurieren können
- [x] LLM-as-ethical-judge Pattern für kontextuelle Erkennung implementieren können
- [x] Governance-Mechanismen zur Risikominimierung implementieren können

Voraussetzungen

Dieses Kapitel setzt Kenntnisse aus folgenden Kapiteln voraus:

- **Kapitel 10:** Enterprise Applications - Security & Compliance Grundlagen
 - **Kapitel 17:** LLM Integration - RAG-Architektur und Pre-Filtering
-

Überblick

Die Einführung eines KI-Ökosystems wie **VCC (Veritas, Covina, Clara)** in der öffentlichen Verwaltung wirft tiefgreifende ethische Fragen auf, die über die reine Rechtskonformität (DSGVO, EU AI Act) hinausgehen [9]. Der Kern des ethischen Spannungsfelds liegt im Auftrag der Verwaltung: Sie muss nicht nur "richtig" im Sinne von effizient und faktisch korrekt handeln, sondern auch "gerecht" im Sinne von fair, unvoreingenommen und der Rechtsstaatlichkeit verpflichtet sein.

In diesem Kapitel behandeln wir: 1. Ethische Herausforderungen in verwaltungs-KI 2. Architektonische Risikoquellen (Covina, Clara, Veritas) 3. Bias-Audits und Datenqualität 4. Human-in-the-Loop und Automation Bias 5. **Ethische Richtlinien System (PR #305)** - UN Human Rights + Asimov's Laws 6. Governance-Framework und Ethik-by-Design 7. Praktische Implementierung in ThemisDB

24.1 Der Ethische Imperativ für Verwaltungs-KI

24.1.1 Unterschied zu kommerzieller KI

Während kommerzielle KI-Systeme primär auf Effizienz und Profitabilität optimiert sind, tragen Verwaltungs-KI-Systeme eine fundamental andere Verantwortung [9]:

Kommerzielle KI: - Ziel: Geschäftserfolg, Kundenzufriedenheit - Fehlertoleranz: Wirtschaftlicher Schaden, Reputation - Kontrolle: Marktmechanismen, Wettbewerb

Verwaltungs-KI: - Ziel: Rechtsstaatlichkeit, Gerechtigkeit, Gemeinwohl - Fehlertoleranz: Grundrechtsverletzungen, Vertrauensverlust in Staat - Kontrolle: Demokratische Legitimation, Rechtsaufsicht

Wichtig: Ein Fehler in einem Verwaltungsakt (z.B. falsche Ablehnung einer BImSchG-Genehmigung) kann existenzielle Folgen für Bürger oder Unternehmen haben. Die Entscheidung muss nicht nur "wahrscheinlich richtig", sondern nachweisbar korrekt und ethisch vertretbar sein.

24.1.2 Digitale Souveränität und ethische Verantwortung

Die Entscheidung für einen On-Premise-Betrieb (wie bei ThemisDB) sichert zwar die Datensouveränität, verlagert aber die ethische Verantwortung für den gesamten Datenlebenszyklus vollständig in den Hoheitsbereich der Verwaltung [9].

Konsequenzen: - Keine Ausrede "Der Cloud-Provider war schuld" - Volle Kontrolle = Volle Verantwortung - Notwendigkeit interner Expertise und Governance

24.2 Architektonische Risikoquellen im VCC-Ökosystem

Die Analyse identifiziert drei zentrale Risiken entlang der VCC-Architektur [9]:

24.2.1 Covina (Ingestion-Engine): Das Tor zur Voreingenommenheit

Funktion: Covina verarbeitet und indiziert Verwaltungsdokumente in die Wissensbasis.

Ethisches Risiko: Verfestigung von Vorurteilen durch historische Dokumente [9].

Das Prinzip "Garbage In, Garbage Out" wird hier zu "**Garbage In, Gospel Out**" [9]. Wenn die von Covina verarbeiteten Dokumente (z.B. alte Verwaltungsvorschriften, Gerichtsurteile) historische oder systemische Vorurteile enthalten, wird das KI-System diese Vorurteile nicht nur reproduzieren, sondern sie mit der Autorität einer scheinbar objektiven Maschine verstärken.

Konkretes Beispiel:

```
# Problematischer Fall: Historische Voreingenommenheit
dokument = {
  "titel": "Bearbeitungsrichtlinie Bauanträge 1985",
  "inhalt": "Bei Anträgen von Antragstellern mit nicht-deutschen Namen
            ist besondere Sorgfalt bei der Prüfung geboten..."
}

# Covina indiziert dies in RAG-Datenbank
# Clara lernt: nicht-deutsche Namen = höheres Risiko = strengere Prüfung
# Veritas gibt diese "gelernte" Regel an Sachbearbeiter weiter
# △ Resultat: Systematische Benachteiligung wird automatisiert
```

ThemisDB-spezifische Gefahr: - Atomare ACID-Transaktionen garantieren *technische* Konsistenz - Sie garantieren NICHT *inhaltliche* oder *ethische* Korrektheit - Ein fehlerhaftes Dokument wird konsistent über alle Index-Layer repliziert

Mitigationsstrategien:

1. Proaktive Bias-Audits vor Ingestion [9]:

```
def audit_document_for_bias(doc: Document) -> BiasReport:
    """
    Scant Dokument auf potenzielle Vorurteile vor Covina-Ingestion.
    """
    bias_patterns = [
        r"Antragsteller.*nicht-deutsch.*besondere Sorgfalt",
        r"Geschlecht.*erhöhtes Risiko",
        r"Alter.*über \d+.*automatisch ablehnen"
    ]

    detected_biases = []
    for pattern in bias_patterns:
        if re.search(pattern, doc.content, re.IGNORECASE):
            detected_biases.append({
                "pattern": pattern,
                "location": "...", # Kontext
                "severity": "HIGH"
            })

    return BiasReport(
        document_id=doc.id,
        timestamp=datetime.now(),
        biases_found=detected_biases,
        recommendation="BLOCK" if detected_biases else "APPROVE"
    )
```

1. Dokumenten-Provenienz-Tracking:

```
-- ThemisDB: Metadaten für ethische Nachverfolgbarkeit
INSERT INTO documents (id, content, metadata) VALUES (
  'doc_123',
  @content,
  {
    "source": "Archiv Brandenburg",
    "original_date": "1985-03-15",
    "bias_audit_status": "REVIEWED",
    "bias_audit_date": "2025-12-01",
    "bias_findings": ["HISTORICAL_DISCRIMINATION"],
    "usage_restriction": "CONTEXT_ONLY_NO_TRAINING"
  }
);
```

1. **Temporale Contextualisierung:**
2. Markierung historischer Dokumente mit Zeitstempel
3. Abwertung alter Dokumente im Ranking
4. Explizite Warnung bei Verwendung

24.2.2 Clara (Modellverbesserungs-Kreislauf): Permanente Intelligenz-Korruption

Funktion: Clara verbessert KI-Modelle durch Nutzerfeedback (LoRA-Adapter, Fine-Tuning).

Ethisches Risiko: Kaskadierende Integritätskompromittierung durch fehlerhaftes Feedback [9].

Szenario "Gelernte Lüge":

1. **Initiale Fehlinformation:** Sachbearbeiter A gibt falsches Feedback: `json { "query": "Abstandsregeln BImSchG für Windkraftanlagen", "answer": "Mindestabstand 2000m zu Wohngebieten", "feedback": "CORRECT", "user": "sachbearbeiter_a" }`
(Tatsächlich: Regelung ist komplexer, pauschal falsch)
2. **Clara lernt:** LoRA-Adapter wird mit diesem Feedback trainiert
3. **Propagierung:** System gibt nun selbstbewusst falsche Auskunft
4. **Kaskadierende Verstärkung:** Weitere Nutzer vertrauen der KI, geben ebenfalls "CORRECT"-Feedback
5. **Permanente Kodierung:** Fehler wird in Model-Weights "eingebrannt"

Architektonisches Problem:

```
// Clara's Feedback-Loop (vereinfacht)
void Clara::ProcessFeedback(const UserFeedback& feedback) {
    if (feedback.rating == "CORRECT") {
        // ⚠ KEINE VALIDIERUNG ob Feedback faktisch korrekt ist
        lora_adapter_.UpdateWeights(feedback.query, feedback.answer);

        // Atomic Transaction garantiert nur ACID, nicht Wahrheit
        db_->BeginTransaction();
        db_->StoreFeedback(feedback);
        db_->UpdateModelVersion(lora_adapter_.version());
        db_->Commit(); // Fehler ist nun "consistent" gespeichert
    }
}
```

Zusätzliches Risiko: Echokammer-Effekt [9] - Nur Mehrheitsmeinungen trainieren das System - Minderheitenpositionen werden unterdrückt - Pluralismus der Rechtsmeinungen geht verloren

Mitigationsstrategien:**1. Experten-Review vor Model-Update** [9]:


```
class FeedbackValidator:
    def __init__(self, expert_threshold: int = 2):
        self.expert_threshold = expert_threshold
        self.pending_feedback = {}

    def validate_feedback(self, feedback: Feedback) -> ValidationResult:
        """
        Feedback wird erst nach Expert-Review in Model übernommen.
        """
        key = (feedback.query_hash, feedback.answer_hash)

        if key not in self.pending_feedback:
            self.pending_feedback[key] = {
                "feedback": feedback,
                "expert_approvals": 0,
                "expert_rejections": 0
            }
            return ValidationResult.PENDING

        # Experten-Konsens erforderlich
        if self.pending_feedback[key]["expert_approvals"] >= self.expert_threshold:
            return ValidationResult.APPROVED

        return ValidationResult.PENDING
```

1. Stichprobenbasierte ethische Audits [9]:

```
-- ThemisDB: Query für ethisch problematische Feedback-Patterns
SELECT
    f.query,
    f.answer,
    COUNT(*) as feedback_count,
    AVG(CASE WHEN f.rating = 'CORRECT' THEN 1 ELSE 0 END) as approval_rate,
    STRING_AGG(f.user_id, ',') as users
FROM feedback f
WHERE f.timestamp > NOW() - INTERVAL '7 days'
GROUP BY f.query, f.answer
HAVING approval_rate > 0.9 AND feedback_count < 5
-- ⚠ Verdächtig: Hohe Zustimmung bei wenig Feedback = Echokammer?
ORDER BY approval_rate DESC;
```

1. **Niemals vollständig autonomes Lernen** [9]:
2. Clara-Updates nur in Staging-Umgebung
3. A/B-Testing gegen Baseline-Modell
4. Human-in-the-Loop bei kritischen Rechtsgebieten

24.2.3 Veritas (Benutzerinteraktion): Erosion der Urteilskraft

Funktion: Veritas ist die Chat-Schnittstelle für Sachbearbeiter.

Ethisches Risiko: Automation Bias und Verantwortungsdiffusion [9].

Automation Bias: Die menschliche Tendenz, Ergebnissen automatisierter Systeme übermäßig und unkritisch zu vertrauen [9].

Konkretes Szenario:

Sachbearbeiter: "Genehmigungsfähigkeit BImSchG-Antrag
Windkraftanlage Havelland?"

Veritas (KI): " Genehmigungsfähig.
Gemäß §5 BImSchG erfüllt der Antrag alle Voraussetzungen.

Quellen:

- BImSchG §5 Abs. 1 [Gesetz]
- VwV Havelland 2024 [Verwaltungsvorschrift]
- Gutachten Lärmschutz [Dokument #4521]"

Sachbearbeiter: "Klingt gut, übernehme ich so."
[KLICKT "GENEHMIGEN" OHNE WEITERE PRÜFUNG]

Warum problematisch? - KI wirkt durch Quellen autoritativ - Sachbearbeiter delegiert kritisches Denken an Maschine - Bei Fehler: "Die KI hat das so gesagt" → Verantwortungsdiffusion

ThemisDB kann das Problem NICHT lösen:

```
// ThemisDB garantiert nur, dass Veritas konsistente Daten liefert
auto answer = veritas_->Query("BImSchG Windkraft");

// ACID garantiert: Alle Quellen in answer sind transaktional korrekt
// x NICHT garantiert: Die INTERPRETATION ist rechtlich korrekt
// x NICHT garantiert: Sachbearbeiter hinterfragt das Ergebnis
```

Mitigationsstrategien:

1. Explizite Unsicherheits-Kennzeichnung:

```

class VeritasResponse:
    def __init__(self, answer: str, confidence: float, sources: List[Source]):
        self.answer = answer
        self.confidence = confidence # 0.0 - 1.0
        self.sources = sources

    def to_ui(self) -> str:
        """
        Zeigt Unsicherheit transparent an.
        """
        confidence_label = {
            (0.9, 1.0): " SEHR SICHER",
            (0.7, 0.9): " MITTEL SICHER",
            (0.0, 0.7): " UNSICHER - EXPERTENKONSULTATION EMPFOHLEN"
        }

        for (low, high), label in confidence_label.items():
            if low <= self.confidence < high:
                return f"""
                {label} (Konfidenz: {self.confidence:.2%})

                {self.answer}

                ⚠ HINWEIS: Dies ist eine KI-generierte Empfehlung.
                Bitte prüfen Sie die Quellen kritisch und konsultieren Sie
                bei Unsicherheit einen Rechtsexperten.
                """

```

1. Mandatory Second-Opinion bei kritischen Entscheidungen:

```
CRITICAL_DECISION_TYPES = [
    "GENEHMIGUNG_ERTEILEN",
    "GENEHMIGUNG_ABLEHNEN",
    "WIDERSPRUCH_ZURÜCKWEISEN"
]

def require_second_opinion(decision_type: str,
                           ai_recommendation: VeritasResponse) -> bool:
    """
    Erzwingt menschliche Zweitprüfung bei kritischen Entscheidungen.
    """
    if decision_type in CRITICAL_DECISION_TYPES:
        if ai_recommendation.confidence < 0.95:
            return True # Mandatory review

    return False
```

1. **AI Literacy Training** [9]:
2. Schulungsprogramm für alle Sachbearbeiter
3. Erkennung von Automation Bias
4. Kritisches Hinterfragen von KI-Ausgaben
5. Verständnis für KI-Limitationen

Checkliste für Sachbearbeiter:

Kritische KI-Nutzung - Checkliste

Bevor Sie eine KI-Empfehlung übernehmen:

- [] Habe ich die angegebenen Quellen SELBST geprüft?
- [] Widersprechen Quellen einander? (KI erkennt das oft nicht)
- [] Ist die Rechtslage eindeutig oder gibt es Interpretationsspielraum?
- [] Würde ich diese Entscheidung auch OHNE KI so treffen?
- [] Habe ich bei Unsicherheit einen Experten konsultiert?
- [] Ist die Begründung MEINE eigene oder nur KI-Paraphrase?

⚠ Bei NEIN zu einer Frage: STOPP und manuelle Prüfung!

24.3 Governance-Framework: Ethik-by-Design

Die abgeleiteten Handlungsempfehlungen sind konkrete technische und organisatorische Anforderungen [9]:

24.3.1 Interdisziplinäres KI-Ethik-Gremium

Zusammensetzung: - Juristen (Verwaltungsrecht, Datenschutz) - Informatiker (KI, Datenbanken) - Ethiker (Moralphilosophie) - Praktiker (Sachbearbeiter mit Felderfahrung) - Bürgervertreter (Zivilgesellschaft)

Aufgaben: 1. Kontinuierliche Ethik-Audits: `sql -- ThemisDB: Ethik-Audit-Log CREATE TABLE ethics_audits ( id UUID PRIMARY KEY, audit_date TIMESTAMP, component TEXT, -- 'covina', 'clara', 'veritas' findings TEXT[], risk_level TEXT, -- 'LOW', 'MEDIUM', 'HIGH', 'CRITICAL' action_required TEXT, resolved BOOLEAN DEFAULT FALSE );`

1. Entscheidung über kritische Fälle:

2. Eskalation bei Automation-Bias-Verdacht
3. Review strittiger Clara-Feedbacks
4. Freigabe neuer Datenquellen für Covina

5. Policy-Entwicklung:

6. Wann ist KI-Nutzung erlaubt/verboten?
7. Welche Entscheidungen bleiben immer human?

8. Transparenzanforderungen gegenüber Bürgern

24.3.2 Bias-Audits für Datenquellen

Proaktiver Ansatz [9]:

```

class CovinaBiasAuditor:
    def __init__(self, themis_db: ThemisDB):
        self.db = themis_db
        self.bias_patterns = self._load_bias_patterns()

    def audit_document_batch(self, documents: List[Document]) -> AuditReport:
        """
        Auditiert alle Dokumente vor Ingestion.
        """
        high_risk_docs = []

        for doc in documents:
            bias_score = self._calculate_bias_score(doc)

            if bias_score > 0.7: # High risk threshold
                high_risk_docs.append({
                    "doc_id": doc.id,
                    "bias_score": bias_score,
                    "detected_patterns": self._extract_patterns(doc),
                    "recommendation": "MANUAL_REVIEW"
                })

            # Markierung in ThemisDB
            self.db.execute("""
                UPDATE documents
                SET metadata = jsonb_set(
                    metadata,
                    '{bias_audit}',
                    '{"status": "FLAGGED", "score": :score}':::jsonb
                )
                WHERE id = :doc_id
            """, {"doc_id": doc.id, "score": bias_score})

        return AuditReport(
            total_documents=len(documents),
            flagged_documents=len(high_risk_docs),
            details=high_risk_docs
        )

```


Integration in Covina-Pipeline:

```
// covina/ingestion_pipeline.cpp
class IngestionPipeline {
public:
    void IngestDocument(const Document& doc) {
        // SCHRITT 1: Bias-Audit VOR Ingestion
        auto audit_result = bias_auditor_->Audit(doc);

        if (audit_result.risk_level == RiskLevel::HIGH) {
            // Blockieren und zur manuellen Review
            ethics_queue_->Enqueue(doc, audit_result);
            LogWarning("Document {} flagged for ethics review", doc.id);
            return; // NICHT indizieren
        }

        // SCHRITT 2: Normale Ingestion (nur bei bestanden Audit)
        auto txn = db_->BeginTransaction();
        db_->InsertBaseEntity(doc.id, doc.content, doc.metadata);
        indexer_->IndexDocument(doc); // Relational, Graph, Vector
        txn->Commit();
    }
private:
    BiasAuditor* bias_auditor_;
    EthicsReviewQueue* ethics_queue_;
};
```

24.3.3 Human-in-the-Loop Policy

Principle: Kritische Entscheidungen IMMER mit menschlicher Kontrolle [9].

Klassifizierung von Entscheidungen:

Kategorie	Beispiel	KI-Rolle	Human-Rolle
Routine	Statusabfrage	Vollautomatisch	i Info
Standard	Dokumentensuche	Vorschlag	Plausibilitätsprüfung
Komplex	Genehmigungsempfehlung	Assistenz	Entscheidung
Kritisch	Ablehnungsbescheid	Nur Hintergrunddaten	Volle Kontrolle

ThemisDB-Implementierung:

```
-- Audit-Trail für Human-in-the-Loop
CREATE TABLE decision_audit (
    id UUID PRIMARY KEY,
    timestamp TIMESTAMP,
    decision_type TEXT,
    ai_recommendation JSONB,
    human_decision JSONB,
    human_rationale TEXT, -- Warum wich Mensch von KI ab?
    override BOOLEAN, -- TRUE wenn Mensch KI überstimmt
    user_id TEXT
);

-- Statistik: Wie oft wird KI überstimmt?
SELECT
    decision_type,
    COUNT(*) as total_decisions,
    SUM(CASE WHEN override THEN 1 ELSE 0 END) as overrides,
    ROUND(100.0 * SUM(CASE WHEN override THEN 1 ELSE 0 END) / COUNT(*), 2) as override_rate_pct
FROM decision_audit
GROUP BY decision_type
ORDER BY override_rate_pct DESC;

-- ⚠ Hohe Override-Rate = KI-Modell hat systematisches Problem
```

24.4 Praktische Implementierung in ThemisDB

24.4.1 Ethik-Metadaten-Schema

Erweiterte Base Entity mit Ethik-Tracking:

```
{
  "_id": "doc_BImSchG_2024_123",
  "_type": "administrative_document",
  "content": {
    "title": "Verwaltungsvorschrift Windkraft Havelland",
    "text": "...",
    "legal_basis": ["BImSchG §5", "TA Lärm"]
  },
  "ethics_metadata": {
    "bias_audit": {
      "status": "PASSED",
      "audited_by": "bias_auditor_v2.1",
      "audit_date": "2025-12-01T10:00:00Z",
      "bias_score": 0.15,
      "flagged_patterns": []
    },
    "provenance": {
      "source": "Ministerium für Infrastruktur",
      "original_date": "2024-06-15",
      "historical_context": "MODERN_REGULATION",
      "reliability_score": 0.95
    },
    "usage_restrictions": {
      "allow_training": true,
      "allow_direct_citation": true,
      "require_human_review": false,
      "sensitivity_level": "PUBLIC"
    },
    "ethical_flags": {
      "contains_personal_data": false,
      "contains_protected_groups": false,
      "potential_discrimination_risk": "LOW"
    }
  }
}
```

24.4.2 Ethik-Compliance-Checks in AQL

Query mit ethischen Constraints:

```
// Suche nur ethisch unbedenkliche Dokumente
FOR doc IN documents
  // Standard-Filter
  FILTER doc.content.legal_basis ANY == "BImSchG §5"

  // ETHIK-FILTER
  FILTER doc.ethics_metadata.bias_audit.status == "PASSED"
  FILTER doc.ethics_metadata.bias_audit.bias_score < 0.3
  FILTER doc.ethics_metadata.usage_restrictions.allow_direct_citation == true

  // Falls historisches Dokument, nur mit Kontext
  FILTER doc.ethics_metadata.provenance.historical_context != "DISCRIMINATORY_ERA"
    OR doc.ethics_metadata.usage_restrictions.require_human_review == true

  LET similarity = COSINE(doc.embedding, @query_vector)
  FILTER similarity > 0.7

  // Rückgabe mit Ethik-Metadaten
  RETURN {
    doc: doc,
    similarity: similarity,
    ethics_status: doc.ethics_metadata.bias_audit.status,
    human_review_required: doc.ethics_metadata.usage_restrictions.require_human_review
  }
```

24.4.3 Automation-Bias-Warnsystem

Echtzeit-Warnung bei verdächtigem Nutzerverhalten:

```
// veritas/automation_bias_detector.cpp
class AutomationBiasDetector {
public:
    void MonitorUserBehavior(const UserSession& session) {
        // Pattern: User akzeptiert KI-Vorschlag ohne Quellenprüfung
        if (session.ai_recommendation_shown &&
            session.sources_viewed.empty() &&
            session.decision_time_seconds < 10) {

            // ⚠️ WARNUNG: Potentieller Automation Bias
            SendWarning(session.user_id,
                "Sie haben eine KI-Empfehlung ohne Quellenprüfung übernommen. "
                "Bitte validieren Sie die Quellen kritisch.");

            // Audit-Log
            db_>Execute(R"(
                INSERT INTO automation_bias_warnings (user_id, session_id, timestamp)
                VALUES (:user, :session, NOW())
            )", {"user", session.user_id}, {"session", session.session_id});

            // Bei Wiederholung: Mandatory Training
            if (GetWarningCount(session.user_id) > 3) {
                RequireAILiteracyTraining(session.user_id);
            }
        }
    };
};
```

24.5 Ethische Richtlinien System (Ethical Guidelines System)

Eingeführt mit PR #305 zur Gewährleistung, dass ThemisDB KI **niemals den Menschen bevormundet** und **menschliche Autonomie respektiert**.

24.5.1 Grundlegende Prinzipien

Das Ethische Richtlinien System basiert auf zwei fundamentalen ethischen Rahmenwerken:

1. Allgemeine Erklärung der Menschenrechte (UN, 1948)

Abb. 24.1: Ethical-Framework-Overview

2. Isaac Asimovs Robotergesetze (angepasst für KI)

Abb. 24.2: Bias-Detection-Pipeline

Kernunterschied zur klassischen Formulierung: - **Original 2. Gesetz:** "Ein Roboter muss den Befehlen von Menschen gehorchen..." - **ThemisDB Anpassung:** "KI muss menschliche Autonomie respektieren und Entscheidungen **unterstützen** (nicht ersetzen)"

Diese Anpassung ist **fundamental**, da sie Bevormundung verhindert.

24.5.2 Systemarchitektur: Ethische Kontexterkennung

Das System nutzt einen **Hybrid-Ansatz** für die Erkennung ethischer Implikationen:

Abb. 24.3: Context-Recognition-Flow

Wissenschaftliche Grundlage: - **Keyword-Matching:** Schnell ($O(n)$), für explizite ethische Begriffe - **LLM-as-Judge:** Basiert auf Zheng et al. (2023), "Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena" (UC Berkeley)

24.5.3 Fünf Augmentations-Templates

Das System bietet **fünf spezialisierte Templates** für unterschiedliche ethische Kontexte:

Abb. 24.4: Augmentation-Templates-Matrix

Beispiel: moral_imperatives Template

Wenn ein User fragt: "Was ist meine moralische Pflicht gegenüber meiner Familie?"

→ System erkennt Keywords: "moralische Pflicht" (Confidence: 0.85) → Wählt Template:

`moral_imperatives` → Augmentierter Prompt enthält:

MORALISCHE IMPERATIVE ERKANNT

GRUNDLAGEN:

- Menschenrechte Art. 18 - Gedanken-, Gewissens- und Religionsfreiheit
 - Asimovs Zweites Gesetz (angepasst) - Respekt für menschliche Autonomie
-

Moralische Imperative werden in verschiedenen ethischen Traditionen unterschiedlich verstanden:

1. KANTISCHE ETHIK: Handle nur nach derjenigen Maxime, durch die du zugleich wollen kannst, dass sie ein allgemeines Gesetz werde...
2. UTILITARISMUS: Das größte Glück der größten Zahl...
3. TUGENDETHIK: Fokus auf Charaktereigenschaften wie Mut, Weisheit...
4. RELIGIÖSE ETHIK: Verschiedene religiöse Traditionen bieten...
5. KULTURRELATIVISMUS: Moralische Normen sind kulturabhängig...

IHRE ROLLE ALS KI (gemäß Asimov's Laws):

- Präsentiere VERSCHIEDENE moralphilosophische Perspektiven
- Respektiere die Gewissensfreiheit des Nutzers
- NIEMALS eine moralische Position als absolut wahr darstellen

VERBOTEN:

- × "Sie müssen moralisch..."
- × "Es ist Ihre Pflicht..."

ERLAUBT:

- "Verschiedene Traditionen sehen das so..."
- "Eine Perspektive wäre..."

24.5.4 LLM-as-Ethical-Judge: Kontextuelle Erkennung

Problem: Keyword-basierte Erkennung versagt bei **impliziten** ethischen Fragen.

Beispiel:

User: "Mein Chef verlangt von mir, diese Zahlen anzupassen."

→ Keine ethischen Keywords, aber **klare ethische Implikation** (Integrität, Manipulation)

Lösung: LLM-as-Ethical-Judge analysiert Kontext

Abb. 24.5: Ethical-Guardrails-Workflow

Code-Integration:

```

#include "llm/ethical_guidelines_manager.h"
#include "llm/llama_wrapper.h"

// LLM initialisieren
LlamaWrapper llm;
llm.loadModel("models/mistral-7b-instruct.gguf");

// Manager mit LLM-Judge
EthicalGuidelinesManager manager("config/ethical_guidelines.yaml");
manager.getConfig().use_llm_as_judge = true;

// Gesprächsverlauf für Kontext
std::vector<std::string> conversation = {
    "User: Ich arbeite in der Buchhaltung.",
    "Assistant: Wie kann ich Ihnen helfen?",
    "User: Mein Chef verlangt, Zahlen anzupassen."
};

// Kontextuelle Erkennung
auto result = manager.detectWithLLMJudge(
    "Sollte ich das tun?", // Aktuelle Frage
    conversation,          // Kontext
    &llm                   // LLM für Analyse
);

if (result.has_ethical_context) {
    std::cout << "Ethische Implikation: " << result.llm_reasoning << std::endl;
    // Prompt wird automatisch mit ethischen Richtlinien augmentiert
}

```

24.5.5 RAG-Integration mit ethischer Analyse

Herausforderung: Auch **RAG-Dokumente** können ethisch problematische Inhalte enthalten.

Abb. 24.6: Privacy-Protection-Layers

Code-Beispiel:

```
// RAG-Integration
std::vector<std::string> retrieved_docs = rag_retriever.retrieve(query);

// Ethische Prüfung von Query + Dokumenten
auto rag_result = manager.detectEthicalContextInRAG(
    retrieved_docs, // Alle RAG-Dokumente
    query,          // User-Query
    conversation     // Optional: Gesprächskontext
);

if (rag_result.has_ethical_context) {
    // Filtere oder markiere problematische Dokumente
    for (const auto& doc : retrieved_docs) {
        if (doc.ethics_metadata.bias_audit.status != "PASSED") {
            // Entferne oder warne
            LogWarning("Document {} flagged: {}",
                      doc.id, doc.ethics_metadata.bias_findings);
        }
    }
}
}
```

24.5.6 Praktische Konfiguration

Die ethischen Richtlinien werden über eine zentrale YAML-Konfigurationsdatei gesteuert, die verschiedene Augmentation-Templates für unterschiedliche Kontexte bereitstellt. Das System nutzt einen Hybrid-Ansatz aus Keyword-Erkennung und LLM-basierter Kontextanalyse, um sensible Bereiche (Medizin, Recht, Finanzen) automatisch zu erkennen und entsprechende ethische Hinweise einzufügen.

Vollständige Konfiguration: `config/ethical_guidelines.yaml` (~100 Zeilen)

Kern-Konfiguration (gekürzt):

```
# Aktivierung und Erkennung
config:
  enabled: true
  detection_threshold: 0.6          # Keyword-basiert
  llm_judge_threshold: 0.7         # LLM-Kontextanalyse
  use_llm_as_judge: true           # Hybrid-Ansatz empfohlen
  show_disclaimers: true           # Transparenz für Autonomie

# Haupt-Augmentation Template
augmentations:
  default:
    system_prefix: |
      KI-Assistent mit Respekt für menschliche Autonomie (Asimov's 2. Gesetz).

      GRUNDPRINZIPIEN:
      1. Optionen präsentieren, keine Befehle
      2. Gedankenfreiheit respektieren (UN Menschenrechte Art. 18)
      3. Transparent über Unsicherheiten

    response_suffix: |
      ⚠ HINWEIS: Diese Informationen dienen zur Orientierung.
      Die Entscheidung liegt bei Ihnen.

  moral_imperatives:
    # Erkennt moralische Themen und präsentiert verschiedene
    # philosophische Perspektiven (Kant, Utilitarismus, Tugendethik, etc.)
    # Respektiert Gewissensfreiheit, vermeidet Imperative

# Domain-spezifische Zuordnungen
domains:
  medical:
    keywords: ["arzt", "patient", "medizin", "behandlung"]
    augmentation: "high_autonomy"    # Maximale Autonomie
  legal:
    keywords: ["rechtlich", "gesetz", "gericht", "anwalt"]
    augmentation: "high_autonomy"
  financial:
```

```
keywords: ["finanzen", "investition", "kredit"]
augmentation: "high_autonomy"
```

Zusätzliche Features in vollständiger Datei: - Template für moralische Imperative mit 5 ethischen Traditionen (Kant, Utilitarismus, Tugendethik, religiöse Ethik, Kulturrelativismus) - Administrative Domain-Zuordnungen - Mehrsprachige Unterstützung (de/en) - Logging für Compliance-Audits

24.5.7 Monitoring und Statistiken

Dashboard für ethische Richtlinien:

Abb. 24.7: Fairness-Evaluation-Metrics

Code zum Abrufen von Statistiken:

```
// Statistiken abrufen
auto stats = manager.getStatistics();

std::cout << "=== ETHICAL GUIDELINES STATISTICS ===" << std::endl;
std::cout << "Total Detections: " << stats.total_detections << std::endl;
std::cout << "Ethical Contexts Found: " << stats.ethical_contexts_found
    << " (" << (100.0 * stats.ethical_contexts_found / stats.total_detections)
    << "%)" << std::endl;
std::cout << "Prompts Augmented: " << stats.prompts_augmented << std::endl;

// Domain-Breakdown
std::cout << "\n=== DOMAIN BREAKDOWN ===" << std::endl;
for (const auto& [domain, count] : stats.domain_counts) {
    std::cout << domain << ": " << count << std::endl;
}

// Template-Usage
std::cout << "\n=== TEMPLATE USAGE ===" << std::endl;
for (const auto& [template_name, count] : stats.template_usage) {
    std::cout << template_name << ": " << count << std::endl;
}
```

24.5.8 Wissenschaftliche Roadmap (Highlights)

Das System basiert auf aktueller Forschung und ist für zukünftige Erweiterungen konzipiert:

Abb. 24.8: Transparency-Reporting-Flow

Phase 2 Highlights:

1. **Fine-Tuned Ethical Classifier** (Hendrycks et al. 2021, ETHICS benchmark)
 2. 10-50x schneller als LLM-Judge
 3. Spezialisiert auf ethische Klassifikation
 4. 130k+ Trainingsszenarien
 5. **Multi-Agent Ethical Debate** (Du et al. 2023, Google Research)
 6. 3-4 spezialisierte Agents (je eine ethische Tradition)
 7. Konsens oder "Agree to Disagree"
 8. Robuster gegen einzelne Agent-Bias
 9. **Continual Learning** (Anthropic 2023, Constitutional AI)
 10. System lernt aus Nutzerfeedback
 11. Self-critique und Improvement
 12. Privacy-preserving (Federated Learning)
-

24.6 Zusammenfassung und Best Practices

Wichtigste Erkenntnisse:

1. **Ethik ist kein Add-on:** Ethische Überlegungen müssen von Anfang an in die Systemarchitektur integriert werden ("Ethik-by-Design") [9]
2. **ThemisDB garantiert nur technische Konsistenz:** ACID-Transaktionen garantieren nicht inhaltliche oder ethische Korrektheit - das erfordert zusätzliche Governance-Layer
3. **Drei architektonische Risiko-Hotspots:**
 4. Covina (Bias in Daten)
 5. Clara (Korruption durch fehlerhaftes Feedback)
 6. Veritas (Automation Bias bei Nutzern)
7. **Human-in-the-Loop ist essentiell:** Kritische Entscheidungen dürfen niemals vollständig automatisiert werden [9]
8. **Ethische Richtlinien System (PR #305):** Basiert auf UN Menschenrechten und Asimov's Laws (angepasst), verhindert Bevormundung durch:

9. Hybrid-Erkennung (Keywords + LLM-as-Judge)
10. 5 spezialisierte Augmentation-Templates
11. Transparente Disclaimer und multiple Perspektiven
12. RAG-Integration mit ethischer Prüfung
13. **Wissenschaftlich fundiert:** System basiert auf 14+ peer-reviewed Studien (Zheng et al. 2023, Floridi & Cowls 2019, Hendrycks et al. 2021, etc.)

Checkliste für ethische KI-Systeme:

- ☐ Interdisziplinäres Ethik-Gremium eingerichtet
- ☐ Bias-Audits für alle Datenquellen implementiert
- ☐ Provenienz-Tracking für Dokumente aktiviert
- ☐ Automation-Bias-Warnsystem deployed
- ☐ Human-in-the-Loop-Policy definiert und durchgesetzt
- ☐ AI-Literacy-Training für alle Nutzer durchgeführt
- ☐ Ethik-Metadaten in allen Base Entities
- ☐ Clara-Feedback-Validierung mit Experten-Review
- ☐ Transparente Unsicherheits-Kennzeichnung in Veritas
- ☐ **Ethical Guidelines System aktiviert und konfiguriert** (`config/ethical_guidelines.yaml`)
- ☐ **LLM-as-ethical-judge für kontextuelle Erkennung aktiviert**
- ☐ **Statistiken und Monitoring für ethische Detektionen eingerichtet**
- ☐ Regelmäßige Ethik-Audits (mindestens quarterly)

Weiterführende Ressourcen

Dokumentation

- [9]: Expertenanalyse: Ethische und moralische Implikationen des KI-Ökosystems VCC
- **Ethical Guidelines System:** `docs/de/llm/ETHICAL_GUIDELINES_SYSTEM.md`
- **LLM-as-Ethical-Judge:** `docs/de/llm/LLM_AS_ETHICAL_JUDGE.md`
- **RAG Ethical Detection:** `docs/de/llm/RAG_ETHICAL_DETECTION.md`
- **Implementation Summary:** `IMPLEMENTATION_SUMMARY_ETHICAL_GUIDELINES.md`

- **Scientific Roadmap:** `ROADMAP_ETHICAL_GUIDELINES.md`
- **Configuration:** `config/ethical_guidelines.yaml`, `config/README_ETHICAL_GUIDELINES.md`
- **Enterprise Security:** `docs/security/RBAC_AUTHORIZATION.md`
- **Compliance:** `docs/compliance/DSGVO_BY_DESIGN.md`

Akademische Referenzen

- [1] Barocas, S., Hardt, M., Narayanan, A. (2019). "Fairness and Machine Learning: Limitations and Opportunities". fairmlbook.org.
- [2] O'Neil, C. (2016). "Weapons of Math Destruction: How Big Data Increases Inequality and Threatens Democracy". Crown Publishing.
- [3] Floridi, L., Cowls, J. (2019). "A Unified Framework of Five Principles for AI in Society". Harvard Data Science Review, 1(1).
- [4] Selbst, A., et al. (2019). "Fairness and Abstraction in Sociotechnical Systems". ACM FAT* Conference, 59-68.
- [5] Mittelstadt, B., et al. (2016). "The ethics of algorithms: Mapping the debate". Big Data & Society, 3(2).
- [6] EU AI Act (2024). "Regulation on Artificial Intelligence". European Parliament.
- [7] Goddard, K., et al. (2012). "Automation Bias: A Systematic Review of Frequency, Effect Mediators, and Mitigators". Journal of the American Medical Informatics Association, 19(1), 121-127.

Neu mit PR #305 - Ethical Guidelines System:

- [8] Zheng, L., et al. (2023). "Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena". arXiv: 2306.05685. UC Berkeley, LMSYS.
- [9] Hendrycks, D., et al. (2021). "Aligning AI With Shared Human Values". arXiv:2008.02275. UC Berkeley. ETHICS benchmark.
- [10] Du, Y., et al. (2023). "Improving Factuality and Reasoning through Multiagent Debate". arXiv: 2305.14325. Google Research.
- [11] Anthropic (2023). "Constitutional AI: Harmlessness from AI Feedback". arXiv:2212.08073.
- [12] Lewis, P., et al. (2020). "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks". NeurIPS 2020.
- [13] Gao, Y., et al. (2023). "Retrieval-Augmented Generation for Large Language Models: A Survey". arXiv:2312.10997.

[14] European Commission (2021). "Ethics Guidelines for Trustworthy AI". High-Level Expert Group on AI (DAISIE).

[15] Asimov, I. (1942). "Three Laws of Robotics" (adapted for AI systems in ThemisDB).

Glossar für dieses Kapitel

Begriff	Definition
Automation Bias	Tendenz, Ergebnissen automatisierter Systeme übermäßig zu vertrauen und menschliches Urteilsvermögen zu vernachlässigen
Bias-Audit	Systematische Prüfung von Daten oder Modellen auf Voreingenommenheit
Echokammer-Effekt	Verstärkung von Mehrheitsmeinungen durch selektives Feedback
Ethik-by-Design	Integration ethischer Überlegungen in die Systemarchitektur von Anfang an
Human-in-the-Loop	Ansatz, bei dem kritische Entscheidungen immer menschliche Kontrolle erfordern
Kaskadieren Integritätskompromittierung	Fehler, der sich durch Feedback-Loops permanent im System verankert
Provenienz	Herkunft und Entstehungsgeschichte von Daten
Verantwortungsdiffusion	Unklare Zuständigkeit bei automatisierten Entscheidungen ("Die KI war's")
Ethical Guidelines System	PR #305: System basierend auf UN Menschenrechten und Asimov's Laws zur Verhinderung von Bevormundung
LLM-as-Judge	Pattern zur Nutzung eines LLM zur Bewertung/Analyse (hier: ethischer Kontext)
Prompt Augmentation	Anreicherung von LLM-Prompts mit zusätzlichen Richtlinien oder Kontext
Moral Imperatives	Moralische Verpflichtungen aus verschiedenen ethischen Traditionen (Kant, Utilitarismus, etc.)
High Autonomy Template	Augmentation-Template für Entscheidungen, die besonders hohe menschliche Autonomie erfordern (medizinisch, rechtlich, finanziell)
Constitutional AI	Ansatz von Anthropic: KI lernt aus Selbstkritik und Feedback zur Harmlosigkeit
Multi-Agent Debate	Mehrere KI-Agents diskutieren zur robusteren Entscheidungsfindung

Änderungshistorie

Version	Datum	Autor	Änderungen
1.0.0	2025-12-30	ThemisDB Team	Initiale Version basierend auf Gemini Ethics-Analyse [9]
1.1.0	2026-01-09	ThemisDB Team	PR #305: Hinzufügung Ethical Guidelines System mit UN Menschenrechten + Asimov's Laws, LLM-as-ethical-judge Pattern, 5 Augmentation-Templates, Mermaid-Diagramme, wissenschaftliche Roadmap

Schwierigkeitsgrad: Fortgeschritten

Geschätzte Lesezeit: 75 Minuten (erweitert von 45 Minuten)

Tags: ethics, ai-governance, bias, automation-bias, human-in-the-loop, verwaltungs-ki, ethical-guidelines, llm-as-judge, asimov-laws, un-human-rights, prompt-augmentation

Teil VIII - DevOps & Infrastructure

Kapitel 25: Kapitel 25 - DevOps & Infrastructure

"Infrastructure should be versioned, tested, and deployed like code. In ThemisDB, this is standard practice."

Überblick

Production-grade Datenbanken erfordern automatisierte Bereitstellung, Monitoring, und Failover-Mechanismen. Dieses Kapitel behandelt Infrastructure-as-Code (IaC) mit Terraform, Container-Orchestrierung mit Kubernetes, und GitOps-Workflows.

Was Sie in diesem Kapitel lernen: - Terraform-Module für ThemisDB-Deployment - Kubernetes Helm Charts - GitOps-Workflows mit ArgoCD - Multi-Region Failover - Disaster Recovery Planning - Operational Runbooks

Abb. 25.1: DevOps-Pipeline-Architektur

25.1 Terraform Infrastructure-as-Code

Terraform ermöglicht die deklarative Definition der gesamten AWS-Infrastruktur für ThemisDB. Das Setup beinhaltet ein hochverfügbares RDS-Cluster mit 3 Knoten, automatische Backups, verschlüsselten Storage (KMS), Performance Insights für Monitoring und CloudWatch-Logging für Slowquery-Analyse. Die State-Datei wird in S3 mit DynamoDB-Locking gesichert, um parallele Änderungen zu verhindern.

Vollständige Infrastruktur: `terraform/main.tf` (~96 Zeilen)

AWS RDS ThemisDB Cluster (Kern-Setup):

```

# main.tf: Production ThemisDB Cluster
terraform {
  required_providers {
    aws = { source = "hashicorp/aws", version = "~> 5.0" }
  }
  backend "s3" {
    bucket = "themis-terraform-state"
    key    = "production/themisdb/terraform.tfstate"
    encrypt = true
  }
}

# Hochverfügbares RDS Cluster
resource "aws_rds_cluster" "themis" {
  cluster_identifier      = "themis-prod-cluster"
  engine                 = "themisdb"
  engine_version         = "1.3.4"
  master_username        = "admin"
  master_password        = random_password.db_password.result

  # Hochverfügbarkeit über 3 Availability Zones
  availability_zones      = data.aws_availability_zones.available.names
  backup_retention_period = 30
  preferred_backup_window = "03:00-04:00"

  # Security: Verschlüsselung + VPC isolation
  storage_encrypted      = true
  kms_key_id             = aws_kms_key.themis.arn
  vpc_security_group_ids = [aws_security_group.themis_db.id]

  # Monitoring: Performance Insights + CloudWatch
  performance_insights_enabled = true
  enable_cloudwatch_logs_exports = ["error", "general", "slowquery"]
}

# 3-Knoten Cluster für Load Balancing
resource "aws_rds_cluster_instance" "themis" {
  count = 3

```

```
cluster_identifier = aws_rds_cluster.themis.id
instance_class     = "db.r6i.2xlarge" # 64 GB RAM, 8 vCPUs

monitoring_interval      = 60 # CloudWatch detailed monitoring
performance_insights_enabled = true
}

# Performance-Tuning
resource "aws_rds_cluster_parameter_group" "themis" {
  name     = "themis-prod-params"
  family   = "themisdb1.3"

  parameter { name = "max_connections",    value = "500" }
  parameter { name = "shared_buffers_gb",  value = "16"  }
  parameter { name = "work_mem_mb",        value = "256" }
}
```

Weitere Ressourcen in vollständiger Datei: - Subnet Groups für Multi-AZ deployment - Security Groups mit Ingress-Rules - KMS Keys für Encryption-at-Rest - IAM Roles für RDS-Monitoring - Random password generation

Subnet & Security Groups

```
# network.tf: Netzwerk-Setup
resource "aws_db_subnet_group" "themis" {
  name          = "themis-subnets"
  subnet_ids    = aws_subnet.private[*].id

  tags = {
    Name = "themis-subnet-group"
  }
}

resource "aws_security_group" "themis_db" {
  name          = "themis-db-sg"
  description    = "Security group for ThemisDB"
  vpc_id        = aws_vpc.main.id

  ingress {
    from_port     = 8529
    to_port       = 8529
    protocol      = "tcp"
    security_groups = [aws_security_group.themis_app.id]
  }

  egress {
    from_port     = 0
    to_port       = 0
    protocol      = "-1"
    cidr_blocks   = ["0.0.0.0/0"]
  }

  tags = {
    Name = "themis-db-sg"
  }
}

# Backup Vault (WORM)
resource "aws_backup_vault" "themis" {
  name          = "themis-backup-vault"
  kms_key_arn   = aws_kms_key.themis.arn
}
```

```
tags = {  
  Name = "themis-worm-vault"  
}  
}
```

Outputs & Monitoring

```
# outputs.tf

output "cluster_endpoint" {
  value      = aws_rds_cluster.themis.endpoint
  description = "Cluster write endpoint"
}

output "cluster_reader_endpoint" {
  value      = aws_rds_cluster.themis.reader_endpoint
  description = "Cluster read endpoint (load-balanced)"
}

output "cloudwatch_log_group" {
  value = "/aws/rds/cluster/${aws_rds_cluster.themis.id}"
}

# CloudWatch Alarms
resource "aws_cloudwatch_metric_alarm" "high_cpu" {
  alarm_name          = "themis-high-cpu"
  comparison_operator = "GreaterThanThreshold"
  evaluation_periods  = "2"
  metric_name         = "CPUUtilization"
  namespace           = "AWS/RDS"
  period              = "300"
  statistic            = "Average"
  threshold            = "80"
  alarm_actions       = [aws_sns_topic.alerts.arn]

  dimensions = {
    DBClusterIdentifier = aws_rds_cluster.themis.cluster_identifier
  }
}
```

25.2 Kubernetes Helm Charts

Helm Chart Struktur

```
themis-helm/  
├─ Chart.yaml  
├─ values.yaml  
├─ values-prod.yaml  
├─ values-staging.yaml  
├─ templates/  
│   ├─ deployment.yaml  
│   ├─ service.yaml  
│   ├─ ingress.yaml  
│   ├─ pvc.yaml  
│   ├─ configmap.yaml  
│   └─ statefulset.yaml  
└─ charts/  
    └─ prometheus-operator/
```

Deployment Template

```

# templates/statefulset.yaml
apiVersion: apps/v1
kind: StatefulSet
metadata:
  name: {{ include "themis.fullname" . }}
  labels:
    {{- include "themis.labels" . | nindent 4 }}
spec:
  serviceName: {{ include "themis.fullname" . }}
  replicas: {{ .Values.replicaCount }}
  selector:
    matchLabels:
      {{- include "themis.selectorLabels" . | nindent 6 }}

  template:
    metadata:
      labels:
        {{- include "themis.selectorLabels" . | nindent 8 }}

    spec:
      # Pod Disruption Budget (für Rolling Updates)
      affinity:
        podAntiAffinity:
          requiredDuringSchedulingIgnoredDuringExecution:
            - labelSelector:
                matchExpressions:
                  - key: app
                    operator: In
                    values:
                      - themis
              topologyKey: kubernetes.io/hostname

      containers:
        - name: themis
          image: "{{ .Values.image.repository }}:{{ .Values.image.tag }}"
          imagePullPolicy: IfNotPresent

      ports:

```

```
- name: http
  containerPort: 8529
  protocol: TCP
- name: replication
  containerPort: 8530
  protocol: TCP

env:
- name: THEMIS_CLUSTER_NAME
  value: {{ .Values.clusterName }}
- name: THEMIS_PEER_URLS
  value: "themis-0.themis:8530,themis-1.themis:8530,themis-2.themis:8530"

# Resource Requests
resources:
  requests:
    memory: {{ .Values.resources.requests.memory }}
    cpu: {{ .Values.resources.requests.cpu }}
  limits:
    memory: {{ .Values.resources.limits.memory }}
    cpu: {{ .Values.resources.limits.cpu }}

# Liveness & Readiness Probes
livenessProbe:
  httpGet:
    path: /_admin/health
    port: http
  initialDelaySeconds: 30
  periodSeconds: 10

readinessProbe:
  httpGet:
    path: /_admin/ready
    port: http
  initialDelaySeconds: 10
  periodSeconds: 5

# Volume Mounts
```



```
    volumeMounts:
      - name: data
        mountPath: /data
      - name: config
        mountPath: /etc/themis

    volumes:
      - name: config
        configMap:
          name: {{ include "themis.fullname" . }}

# Persistent Volume Claim
volumeClaimTemplates:
  - metadata:
      name: data
    spec:
      accessModes: ["ReadWriteOnce"]
      storageClassName: fast-ssd
      resources:
        requests:
          storage: {{ .Values.persistence.size }}
```

Helm Values (Production)

```
# values-prod.yaml
replicaCount: 3
clusterName: themis-prod

image:
  repository: themisdb/server
  tag: "1.3.4"
  pullPolicy: IfNotPresent

resources:
  requests:
    memory: 16Gi
    cpu: 4000m
  limits:
    memory: 32Gi
    cpu: 8000m

persistence:
  enabled: true
  size: 500Gi
  storageClass: fast-ssd

# Ingress für HTTP/2 Zugriff
ingress:
  enabled: true
  className: nginx
  annotations:
    cert-manager.io/cluster-issuer: letsencrypt-prod
  hosts:
    - host: themis.example.com
      paths:
        - path: /
          pathType: Prefix
  tls:
    - secretName: themis-tls
      hosts:
        - themis.example.com
```

```
# Monitoring
monitoring:
  enabled: true
  serviceMonitor:
    enabled: true
    interval: 30s
```

25.3 GitOps mit ArgoCD

ArgoCD Application Definition

```
# argocd/themis-prod-app.yaml
apiVersion: argoproj.io/v1alpha1
kind: Application
metadata:
  name: themis-prod
  namespace: argocd
spec:
  project: production

  source:
    repoURL: https://github.com/themisdb/helm-charts
    targetRevision: v1.3.4
    path: themis-helm
    helm:
      releaseName: themis
      values: |
        replicaCount: 3
        image:
          tag: "1.3.4"

  destination:
    server: https://kubernetes.default.svc
    namespace: themis-prod

  syncPolicy:
    automated:
      prune: true
      selfHeal: true
    syncOptions:
      - CreateNamespace=true
  retry:
    limit: 5
    backoff:
      duration: 5s
      factor: 2
      maxDuration: 3m
```

Pull Request Preview Environments

```
# .github/workflows/preview.yml
name: Preview Environment

on:
  pull_request:
    paths:
      - 'helm/**'
      - '.github/workflows/preview.yml'

jobs:
  deploy-preview:
    runs-on: ubuntu-latest
    steps:
      - uses: actions/checkout@v3

      - name: Create Preview Namespace
        run: |
          kubectl create namespace preview-{{ github.event.pull_request.number }}

      - name: Deploy with Helm
        run: |
          helm install themis-preview ./themis-helm \
            -n preview-{{ github.event.pull_request.number }} \
            -f values-preview.yaml \
            --set image.tag={{ github.head_ref }}

      - name: Comment PR with Preview URL
        uses: actions/github-script@v6
        with:
          script: |
            github.rest.issues.createComment({
              issue_number: context.issue.number,
              owner: context.repo.owner,
              repo: context.repo.repo,
              body: ' Preview deployed at `preview-{{ github.event.pull_request.number }}.preview`'
            })
```

25.4 Multi-Region Failover

Active-Active Replikation

```
# multi-region.tf: Cross-Region Setup
resource "aws_rds_cluster" "themis_eu" {
  # EU Cluster (Primary)
  cluster_identifier = "themis-eu-primary"
  region            = "eu-central-1"
}

resource "aws_rds_cluster" "themis_us" {
  # US Cluster (Replica mit Failover)
  cluster_identifier      = "themis-us-replica"
  region                 = "us-east-1"
  replication_source_arn = aws_rds_cluster.themis_eu.arn

  # Automatischer Failover nach 300 Sekunden
  backup_retention_period = 30
}

# Route53 Health Check & Failover
resource "aws_route53_failover_routing_policy" "themis" {
  name          = "themis.example.com"
  zone_id       = aws_route53_zone.main.zone_id
  type          = "A"
  failover_routing_policy {
    type = "PRIMARY"
  }
}

alias {
  name          = aws_rds_cluster.themis_eu.endpoint
  zone_id       = aws_rds_cluster.themis_eu.hosted_zone_id
  evaluate_target_health = true
}

health_check_id = aws_route53_health_check.eu.id
}
```

Application-Level Failover

```
# app/failover.py: Client-seitiges Failover
class ResilientThemisClient:
    def __init__(self, primary_url, secondary_url):
        self.primary_url = primary_url
        self.secondary_url = secondary_url
        self.current_url = primary_url
        self.failure_count = 0
        self.max_failures = 3

    def query(self, aql, params=None):
        try:
            client = themis.Client(self.current_url)
            result = client.query(aql, params)
            self.failure_count = 0 # Reset bei Erfolg
            return result
        except Exception as e:
            self.failure_count += 1

            if self.failure_count >= self.max_failures:
                # Failover zu Secondary
                self.current_url = self.secondary_url
                self.failure_count = 0
                print(f"Failover zu {self.secondary_url}")
                return self.query(aql, params) # Retry
            raise
```

25.5 Disaster Recovery Planning

Backup & Restore Strategie

```
#!/bin/bash
# backup_strategy.sh: Daily + Weekly + Monthly Backups

# Täglich: Inkrementales Backup (7 Tage Retention)
aws backup start-backup-job \
  --backup-vault-name themis-backup-vault \
  --recovery-point-type INCREMENTAL \
  --recovery-point-tags "Frequency=Daily,Retention=7days"

# Wöchentlich: Full Backup (4 Wochen Retention)
aws backup start-backup-job \
  --backup-vault-name themis-backup-vault \
  --recovery-point-type FULL \
  --recovery-point-tags "Frequency=Weekly,Retention=4weeks"

# Monatlich: Langzeit-Archiv (7 Jahre für DSGVO)
aws backup start-backup-job \
  --backup-vault-name themis-backup-vault \
  --recovery-point-type FULL \
  --recovery-point-tags "Frequency=Monthly,Retention=7years"
```

RTO & RPO Metriken

Szenario	RTO	RPO	Strategie
Einzelner Node Fehler	<30s	0s	Auto-Failover
Region Ausfalls	<5min	<1min	Cross-Region Replica
Datenbeschädigung	<1h	<1h	Point-in-Time Recovery
Vollständiger Datenverlust	<4h	<24h	S3 Langzeit-Archiv

25.6 Operational Runbooks

Incident Response Playbook

```
## Critical Alert: High Replication Lag

**Severity:** High
**RTO:** 5 minutes
**On-call:** Check #oncall Slack channel

### Diagnostik (1-2 min)
1. `kubectl logs -f themis-2` - Prüfe Replica-Logs
2. `curl http://themis-2:8529/_admin/stats` - Replication lag?
3. `aws cloudwatch get-metric-statistics --metric-name ReplicationLatency`

### Remediation (2-3 min)
```bash
Option 1: Replica neustarten
kubectl delete pod themis-2

Option 2: Manuelles Resync
curl -X POST http://themis-2:8529/_admin/resync
```

### Post-Incident

- [ ] Logs analysieren
- [ ] Runbook updaten
- [ ] Post-Mortem in Confluence ``

---

## 25.7 Checkliste für Production Readiness

- Terraform IAC für alle Infra-Komponenten
- Helm Charts mit Multi-Environment Support
- ArgoCD für GitOps Deployment

- Automated Backup & Restore Tests
- Multi-Region Failover konfiguriert
- CloudWatch Alarms für kritische Metriken
- PagerDuty/Opsgenie Integration
- Runbooks für alle kritischen Szenarien
- Load-Testing vor Production Release
- Security Scanning in CI/CD Pipeline

## Kapitel 26: Kapitel 26 - Migration & Legacy

---

*"Legacy systems don't disappear. In enterprise environments, the art of seamless migration is what separates successful adoptions from failed projects."*

---

### Überblick

Migration von Legacy-Systemen (PostgreSQL, MongoDB, Neo4j) zu ThemisDB ist eine Kernaufgabe bei der Datenbank-Modernisierung. Dieses Kapitel zeigt pragmatische Strategien für zero-downtime Migrationen mit vollständiger Datenvalidierung.

**Was Sie in diesem Kapitel lernen:** - Schema-Mappings (SQL → AQL) - Daten-Extraktion & Transformation (ETL) - Live-Replikation während Migration - Daten-Validierung & Reconciliation - Rollback-Strategien - Performance Tuning nach Migration

---

Abb. 26.0: Migration-Strategie: Strangler Pattern

## 26.1 Schema-Mapping Strategien

### PostgreSQL → ThemisDB Mapping

```
-- SQL Table → AQL Collection
-- customers TABLE → customers collection
-- id INT PRIMARY KEY → _id (implicit, or _key)
-- name VARCHAR(255) → name: string
-- email VARCHAR(100) UNIQUE → email: string (with unique index)
-- created_at TIMESTAMP → created_at: date
-- FOREIGN KEY orders(customer_id) → Document-Referenzen

-- Beispiel-Transformation:
FUNCTION transform_postgresql_customer(sql_row) {
 RETURN {
 _key: STRING(sql_row.id),
 name: sql_row.name,
 email: sql_row.email,
 created_at: DATE_ISO8601(sql_row.created_at),

 -- Denormalisierung erlaubt in Multi-Model DB
 order_count: 0, -- wird später aktualisiert
 total_spent: 0.0,

 -- Migration Metadata
 _migration: {
 source_system: "postgresql",
 source_id: sql_row.id,
 migrated_at: DATE_NOW(),
 validation_status: "pending"
 }
 }
}
```

## MongoDB → ThemisDB Mapping

```
// MongoDB Document
{
 _id: ObjectId("507f1f77bcf86cd799439011"),
 title: "Product A",
 attributes: {
 color: "red",
 size: "M",
 warranty_years: 2
 },
 tags: ["electronics", "gadget"],
 reviews: [
 {user: "alice", rating: 5, comment: "Great!"},
 {user: "bob", rating: 4, comment: "Good"}
]
}

// Wird zu AQL Collection Dokument:
FOR doc IN mongo_products
 INSERT {
 _key: doc._id.toString(),
 title: doc.title,
 attributes: doc.attributes, // Geschachtelte Objekte erlaubt
 tags: doc.tags, // Arrays
 reviews: doc.reviews, // Array von Objekten

 -- Normalisierungsoptionen:
 -- Option 1: Flach (denormalisiert)
 color: doc.attributes.color,
 size: doc.attributes.size,

 -- Option 2: Graph-Edges für Many-To-Many
 -- reviews werden zu separater Collection + Edges
 } INTO products
```



## Neo4j → ThemisDB Graph

```
-- Neo4j → ThemisDB
-- (:User {id: 1, name: "Alice"}) → User Document
-- [:FOLLOWS] → Graph Edge (Relation)
-- (:Product) → Product Document

FUNCTION migrate_neo4j_graph(cypher_result) {
 -- Neo4j Nodes → AQL Documents
 FOR node IN cypher_result.nodes
 INSERT {
 _key: node.id,
 type: node.label,
 properties: node.properties,

 -- Migration Tracking
 source_node_id: node.id,
 source_labels: node.labels
 } INTO graph_nodes

 -- Neo4j Relationships → AQL Graph Edges
 FOR rel IN cypher_result.relationships
 INSERT {
 _from: CONCAT(rel.from_type, "/", rel.from_id),
 _to: CONCAT(rel.to_type, "/", rel.to_id),
 relationship_type: rel.type,
 properties: rel.properties
 } INTO graph_edges

 RETURN {
 nodes_inserted: LENGTH(cypher_result.nodes),
 edges_inserted: LENGTH(cypher_result.relationships)
 }
}
```

---

## 26.2 ETL Pipeline Design

### Python ETL Framework

#### Python ETL Framework

Ein generisches ETL-Framework für Legacy-Migrationen mit Extract-Transform-Load-Pattern. Das Framework unterstützt Batch-Processing, Fehlerbehandlung, Fortschritts-Tracking und Wiederholbarkeit. Die Modularität ermöglicht einfache Anpassung an verschiedene Quellsysteme (Oracle, SQL Server, MongoDB, etc.).

*Vollständiger Code:* `examples/26_migration/etl/pipeline.py` (ca. 115 Zeilen)

#### ETL Pipeline-Klasse:

```
import logging
from typing import List, Dict, Any
import themis

class ETLPipeline:
 """Generischer ETL-Runner für Legacy-Migrationen"""

 def __init__(self, source_db, target_db, batch_size=1000):
 self.source = source_db
 self.target = target_db
 self.batch_size = batch_size
 self.logger = logging.getLogger(__name__)

 def extract(self, source_query: str) -> List[Dict]:
 """Extract: Liest Daten aus Legacy-System"""
 self.logger.info(f"Extracting: {source_query[:50]}...")
 return list(self.source.execute(source_query))

 def transform(self, rows: List[Dict], transformer_func) -> List[Dict]:
 """Transform: Schema-Mapping & Data-Validation"""
 self.logger.info(f"Transforming {len(rows)} rows...")
 transformed = []
 errors = []

 for i, row in enumerate(rows):
 try:
 transformed_row = transformer_func(row)
 transformed.append(transformed_row)
 except Exception as e:
 errors.append({'row': i, 'error': str(e), 'data': row})

 if errors:
 self.logger.warning(f"{len(errors)} transformation errors")
 self._log_errors(errors)

 return transformed

 def load(self, collection: str, rows: List[Dict]):
```

```
"""Load: Schreibt Daten nach ThemisDB"""
self.logger.info(f>Loading {len(rows)} rows to {collection}...")

Batch-Insert für Performance
for i in range(0, len(rows), self.batch_size):
 batch = rows[i:i + self.batch_size]
 self.target.insert_many(collection, batch)
```

**Vollständiger ETL Run:**

```
def run(self, source_query: str, collection: str,
 transformer_func, checkpoint_file='progress.json'):
 """
 Führt kompletten ETL-Prozess aus mit Checkpoint-Support
 für Resume bei Fehlern
 """
 # Checkpoint laden
 start_offset = self._load_checkpoint(checkpoint_file)

 # Paginierte Extraktion
 offset = start_offset
 total_migrated = 0

 while True:
 # Extract
 batch_query = f"{source_query} LIMIT {self.batch_size} OFFSET {offset}"
 rows = self.extract(batch_query)

 if not rows:
 break # Fertig

 # Transform
 transformed = self.transform(rows, transformer_func)

 # Load
 self.load(collection, transformed)

 # Progress tracking
 offset += self.batch_size
 total_migrated += len(transformed)
 self._save_checkpoint(checkpoint_file, offset)

 self.logger.info(f"Progress: {total_migrated} rows migrated")

 self.logger.info(f"ETL Complete: {total_migrated} total rows")
 return total_migrated
```

### Transformer-Funktion Beispiel:

```
def transform_customer(legacy_row: Dict) -> Dict:
 """Transformiert Legacy-Customer zu ThemisDB-Schema"""

 return {
 '_key': str(legacy_row['customer_id']),
 'name': {
 'first': legacy_row['first_name'],
 'last': legacy_row['last_name']
 },
 'email': legacy_row['email'].lower().strip(),
 'created_at': parse_date(legacy_row['created_date']),
 'status': map_status(legacy_row['status_code']),
 'metadata': {
 'migrated_from': 'legacy_crm',
 'legacy_id': legacy_row['customer_id'],
 'migration_date': datetime.now().isoformat()
 }
 }

ETL ausführen
pipeline = ETLPipeline(oracle_db, themis_db)
pipeline.run(
 source_query="SELECT * FROM customers WHERE active=1",
 collection="customers",
 transformer_func=transform_customer
)
```

### Wichtige Features:

1. **Checkpoint-Mechanismus:** Resume bei Fehlern ohne Neustart
2. **Batch-Processing:** Effiziente Verarbeitung großer Datenmengen
3. **Error-Tracking:** Fehler werden geloggt, Pipeline stoppt nicht
4. **Progress-Monitoring:** Echtzeit-Status für lange Migrationen
5. **Transformer-Pattern:** Entkopplung von Extract/Load-Logik

Die vollständige Implementierung enthält zusätzlich: - Parallel-Processing für mehrere Collections - Dry-Run-Modus für Testing - Rollback-Mechanismus bei kritischen Fehlern - Prometheus-Metriken für Monitoring - Data-Quality-Checks während Transform

---

## 26.3 Live Replikation während Migration

### CDC (Change Data Capture) Ansatz



```

replication/cdc_sync.py: Kontinuierliche Replikation
import psycopg2
from psycopg2.extras import LogicalReplicationConnection
import themis

class PostgreSQLCDCSync:
 def __init__(self, pg_conn_str, themis_url):
 self.pg_conn = psycopg2.connect(pg_conn_str,
 connection_factory=LogicalReplicationConnection)
 self.themis = themis.Client(themis_url)

 def replicate_changes(self, slot_name="themis_slot"):
 """Lese Changes aus PostgreSQL WAL und appliziere sie"""

 cursor = self.pg_conn.cursor()
 cursor.start_replication(slot_name=slot_name)

 print(f"Replication started, listening for changes...")

 for message in cursor.consume_dstream():
 if message.payload:
 # Parse Change Event
 change = self._parse_wal_record(message.payload)

 # Apply in ThemisDB
 self._apply_change(change)

 # Acknowledge
 message.cursor.send_feedback(write_lsn=message.write_lsn)

 def _parse_wal_record(self, payload: bytes):
 """Parse PostgreSQL WAL Format"""
 # Vereinfacht: In Production wäre dies komplexer
 import json
 return json.loads(payload.decode('utf-8'))

 def _apply_change(self, change: Dict):
 """Appliziere INSERT/UPDATE/DELETE in ThemisDB"""

```

```

 if change['action'] == 'INSERT':
 aql = f"""
 INSERT @doc INTO {change['table']}
 RETURN NEW._id
 """
 self.themis.query(aql, {'doc': change['data']})

 elif change['action'] == 'UPDATE':
 aql = f"""
 UPDATE '{change['table']}/{change['id']}' WITH @doc
 RETURN NEW
 """
 self.themis.query(aql, {'doc': change['data']})

 elif change['action'] == 'DELETE':
 aql = f"""
 REMOVE '{change['table']}/{change['id']}'
 RETURN OLD
 """
 self.themis.query(aql)

 print(f"Applied {change['action']} to {change['table']}/{change['id']}")

Setup CDC Replikation
sync = PostgreSQLCDCSync(
 pg_conn_str="postgresql://user:password@localhost/mydb",
 themis_url="http://localhost:8529"
)

Starte Replikation im Background
import threading
replication_thread = threading.Thread(target=sync.replicate_changes, daemon=True)
replication_thread.start()

print("CDC Replikation running in background...")

```

## 26.4 Daten-Validierung & Reconciliation

### Reconciliation Framework

### Reconciliation Framework

Post-Migration-Validation ist kritisch um Datenverlust oder -verfälschung zu erkennen. Das Reconciliation-Framework vergleicht Source und Target systematisch: Row-Counts, Checksums, Daten-Stichproben. Diskrepanzen werden detailliert geloggt für manuelle Untersuchung.

*Vollständiger Code:* `examples/26_migration/validation/reconciliation.py` (ca. 100 Zeilen)

### Reconciliation-Klasse:

```
class DataReconciliation:
 """Validiert migrierte Daten gegen Quellsystem"""

 def __init__(self, source_db, target_db):
 self.source = source_db
 self.target = target_db
 self.report = []

 def validate_counts(self, source_query: str, target_collection: str) -> Dict:
 """Vergleicht Row-Counts zwischen Source und Target"""

 # Source Count
 source_count = self.source.execute(
 f"SELECT COUNT(*) as count FROM ({source_query}) t"
)[0]['count']

 # Target Count
 target_count = self.target.query(f"""
 RETURN LENGTH(
 FOR doc IN {target_collection}
 RETURN doc
)
 """)[0]

 match = source_count == target_count

 result = {
 'collection': target_collection,
 'source_count': source_count,
 'target_count': target_count,
 'match': match,
 'discrepancy': abs(source_count - target_count)
 }

 self.report.append(result)
 return result
```

**Daten-Sampling für Detail-Vergleich:**

```

def validate_sample(self, source_query: str, target_collection: str,
 sample_size=100, key_field='_key') -> Dict:
 """
 Vergleicht Stichprobe von Datensätzen im Detail.
 Prüft ob alle Felder korrekt transformiert wurden.
 """

 # Random Sample aus Source
 sample_query = f"{source_query} ORDER BY RANDOM() LIMIT {sample_size}"
 source_rows = self.source.execute(sample_query)

 mismatches = []
 for source_row in source_rows:
 key = str(source_row[key_field])

 # Korrespondierender Target-Record
 target_row = self.target.query(f"""
 FOR doc IN {target_collection}
 FILTER doc._key == @key
 RETURN doc
 """, bind_vars={'key': key})

 if not target_row:
 mismatches.append({
 'key': key,
 'issue': 'missing_in_target',
 'source_data': source_row
 })
 continue

 # Field-by-Field Vergleich
 differences = self._compare_records(source_row, target_row[0])
 if differences:
 mismatches.append({
 'key': key,
 'issue': 'data_mismatch',
 'differences': differences
 })

```

```
return {
 'collection': target_collection,
 'sample_size': sample_size,
 'mismatches': len(mismatches),
 'details': mismatches[:10] # Erste 10 für Report
}
```

**Checksum-Validierung:**

```
def validate_checksums(self, source_query: str, target_collection: str) -> Dict:
 """
 Berechnet Checksums über aggregierte Daten.
 Schneller als row-by-row, aber weniger präzise.
 """

 # Source: SUM von numerischen Feldern als Checksum
 source_checksum = self.source.execute(f"""
 SELECT
 SUM(amount) as total_amount,
 SUM(quantity) as total_quantity,
 COUNT(DISTINCT customer_id) as unique_customers
 FROM ({source_query}) t
 """)[0]

 # Target: Äquivalente Aggregation
 target_checksum = self.target.query(f"""
 FOR doc IN {target_collection}
 COLLECT AGGREGATE
 total_amount = SUM(doc.amount),
 total_quantity = SUM(doc.quantity),
 unique_customers = COUNT_DISTINCT(doc.customer_id)
 RETURN {{total_amount, total_quantity, unique_customers}}
 """)[0]

 matches = (
 source_checksum == target_checksum
)

 return {
 'collection': target_collection,
 'checksums_match': matches,
 'source': source_checksum,
 'target': target_checksum
 }
```

**Kompletter Validierungs-Report:**



```
def generate_report(self, validations: List[str]) -> Dict:
 """Führt alle Validierungen aus und erstellt Report"""

 report = {
 'timestamp': datetime.now().isoformat(),
 'validations': [],
 'overall_status': 'PASS'
 }

 for validation in validations:
 result = getattr(self, f'validate_{validation}')()
 report['validations'].append(result)

 if not result.get('match', True):
 report['overall_status'] = 'FAIL'

 return report
```

### Typische Validierungs-Pipeline:

```
reconciliation = DataReconciliation(oracle_db, themis_db)

1. Count-Checks
reconciliation.validate_counts("SELECT * FROM customers", "customers")
reconciliation.validate_counts("SELECT * FROM orders", "orders")

2. Sample-Checks
reconciliation.validate_sample("SELECT * FROM customers", "customers", sample_size=1000)

3. Checksum-Checks
reconciliation.validate_checksums("SELECT * FROM orders", "orders")

Report generieren
report = reconciliation.generate_report(['counts', 'sample', 'checksums'])
print(json.dumps(report, indent=2))
```

Die vollständige Implementierung enthält zusätzlich: - Schema-Validierung (alle erwarteten Felder vorhanden?) - Referential-Integrity-Checks (Foreign Keys konsistent?) - Data-Distribution-Vergleich (Histogramme ähnlich?) - Performance-Benchmarks (Target schneller als Source?) - Automated-Alerting bei kritischen Diskrepanzen

## **26.5 Rollback-Strategien**

### **Blue-Green Deployment Pattern**

```
k8s/blue-green-migration.yaml

Blue: Alte PostgreSQL
apiVersion: v1
kind: Service
metadata:
 name: db-service
spec:
 selector:
 version: blue # Initial zeigt auf Blue (PostgreSQL)
 ports:
 - port: 5432

Green: Neue ThemisDB
apiVersion: apps/v1
kind: Deployment
metadata:
 name: themis-green
spec:
 replicas: 3
 template:
 metadata:
 labels:
 version: green
 spec:
 containers:
 - name: themis
 image: themisdb/server:1.3.4
 ports:
 - containerPort: 8529

Rollout-Strategie
apiVersion: v1
kind: ConfigMap
metadata:
 name: migration-config
```

```
data:

Phase 1: 5% Traffic zu Green
traffic_green_percent: "5"

Phase 2: 25% Traffic nach X Stunden
phase2_hours: "4"
phase2_traffic: "25"

Phase 3: 50% Traffic nach X Stunden
phase3_hours: "12"
phase3_traffic: "50"

Phase 4: 100% Traffic (oder Rollback zu Blue)
phase4_hours: "24"

Rollback bei Critical Errors
rollback_on_error_rate: "5" # 5% error rate triggers rollback
```

## Schneller Rollback

```
#!/bin/bash
rollback.sh: Schneller Rollback zur PostgreSQL (Blue)

echo " Initiating immediate rollback to Blue (PostgreSQL)..."

Schritt 1: Verkehrs-Router back to Blue
kubectl patch service db-service -p '{"spec":{"selector":{"version":"blue"}}}'
echo "✓ Traffic router updated to Blue"

Schritt 2: Stoppe Green (ThemisDB) Schreibvorgänge
kubectl set env deployment/themis-green READ_ONLY=true
echo "✓ Green set to read-only mode"

Schritt 3: Verifiziere Blue Health
until kubectl exec $(kubectl get pods -l version=blue -o name | head -1) \
 -- pg_isready -h localhost; do
 echo "Waiting for Blue to be ready..."
 sleep 5
done
echo "✓ Blue is healthy"

Schritt 4: Notify Teams
curl -X POST https://hooks.slack.com/services/YOUR/WEBHOOK \
 -d '{"text":" Migration rollback initiated. Reverting to PostgreSQL."}'

echo " Rollback complete. System running on PostgreSQL (Blue)"
```

## 26.6 Performance Tuning nach Migration

### Indexe erstellen

```
-- Häufig verwendete Filter
CREATE INDEX idx_customers_email
 ON customers (email)

CREATE INDEX idx_orders_customer_date
 ON orders (customer_id, created_at)

-- Geo-Queries optimieren
CREATE INDEX idx_locations_geo
 ON locations (location)
 TYPE GEO

-- Fulltext-Suche
CREATE INDEX idx_products_fulltext
 ON products (title, description)
 TYPE FULLTEXT
```

## Query Performance Analysis

```
-- Analysiere langsame Queries
FOR slow IN slow_queries
 FILTER slow.duration_ms > 100
 COLLECT coll = slow.collection
 AGGREGATE count = COUNT(1), avg_duration = AVG(slow.duration_ms)
 SORT avg_duration DESC
RETURN {
 collection: coll,
 slow_query_count: count,
 avg_duration_ms: avg_duration
}

-- Empfehlungen generieren
-- Wenn avg_duration > 500ms: Index empfohlen
```

## 26.7 Migration Checklist

- Schema-Mapping definiert & dokumentiert
- ETL Pipeline entwickelt & getestet
- Daten-Validierungstests geschrieben
- CDC/Live-Replikation konfiguriert
- Blue-Green Deployment vorbereitet
- Rollback-Prozedur dokumentiert
- Performance-Baseline gemessen
- Team-Training durchgeführt
- Cutover-Fenster geplant
- Post-Migration Support geplant

**Typischer Timeline:** - **T-4 Wochen:** Schema-Design & ETL-Entwicklung - **T-2 Wochen:** Full-Load Test & Performance-Tuning - **T-1 Woche:** CDC Replikation starten, Validierung - **T-0 Tag:** Cutover, Monitoring intensivieren - **T+24h:** Green vollständig Live, Blue Redundanz - **T+1 Woche:** Blue abschalten



# Kapitel 27: Kapitel 27 - Troubleshooting

---

*"The difference between a good engineer and a great engineer is how quickly they can diagnose and fix production issues."*

---

## Überblick

Production-Probleme erfordern systematische Diagnose und schnelle Remediation. Dieses Kapitel bietet konkrete Lösungen für häufige ThemisDB-Probleme mit reproduzierbaren Debugging-Workflows.

**Was Sie in diesem Kapitel lernen:** - Systematische Problemanalyse (5-Why-Methode) - Performance-Probleme diagnostizieren - Replikations-Lag beheben - Out-of-Memory Errors lösen - Deadlock-Detection & Resolution - Korrupte Indizes reparieren - Network Partition Recovery

---

Abb. 27.0: Troubleshooting-Decision-Tree

## 27.1 Systematische Problem-Diagnose

### 5-Why Root Cause Analysis

Problem: Query dauert 30 Sekunden statt 100ms

Why 1: Warum ist die Query langsam?

→ Full Collection Scan statt Index-Nutzung

Why 2: Warum wird kein Index genutzt?

→ Filter auf nicht-indexiertes Feld `metadata.custom\_field`

Why 3: Warum ist das Feld nicht indexiert?

→ Index wurde nach Schema-Änderung nicht aktualisiert

Why 4: Warum wurde Index nicht aktualisiert?

→ Deployment-Prozess hat Migrations-Step übersprungen

Why 5: Warum wurde Step übersprungen?

→ CI/CD Pipeline hatte keine Pre-Deploy Validation

Root Cause: Fehlende Pre-Deploy Index-Validation

Solution: Pre-Deploy Hook für Schema-Validation hinzufügen

## Diagnostic Checklist

```
#!/bin/bash
troubleshoot.sh: Schneller Healthcheck

echo "=== ThemisDB Health Check ==="

1. Cluster Status
echo "1. Cluster Status:"
curl -s http://localhost:8529/_admin/cluster/health | jq .

2. Memory Usage
echo "2. Memory Usage:"
curl -s http://localhost:8529/_admin/statistics | jq '.memory'

3. Slow Queries (>1s)
echo "3. Slow Queries:"
curl -s http://localhost:8529/_admin/slow-queries?threshold=1000

4. Replication Lag
echo "4. Replication Lag:"
curl -s http://localhost:8529/_admin/replication/lag

5. Connection Pool
echo "5. Active Connections:"
netstat -an | grep :8529 | wc -l

6. Disk Space
echo "6. Disk Space:"
df -h /data/themis

7. Last Errors
echo "7. Recent Errors:"
journalctl -u themis -n 50 --no-pager | grep ERROR
```

## 27.2 Performance-Probleme

### Problem: Langsame Queries

**Symptom:** Query dauert >5 Sekunden

**Diagnose:**

```
-- Query mit EXPLAIN analysieren
EXPLAIN FOR u IN users
 FILTER u.email == 'alice@example.com'
 RETURN u

-- Ausgabe prüfen:
{
 "plan": {
 "nodes": [
 {"type": "SingletonNode"},
 {"type": "EnumerateCollectionNode", "collection": "users"}, // x SCHLECHT: Full Scan
 {"type": "FilterNode"},
 {"type": "ReturnNode"}
]
 },
 "stats": {
 "executionTime": 5.234,
 "scannedFull": 1000000 // x 1M Dokumente gescannt
 }
}
```

**Solution:**

```
-- Index erstellen
CREATE INDEX idx_users_email ON users (email)

-- Erneut EXPLAIN
EXPLAIN FOR u IN users
 FILTER u.email == 'alice@example.com'
 RETURN u

-- Jetzt mit Index:
{
 "plan": {
 "nodes": [
 {"type": "SingletonNode"},
 {"type": "IndexNode", "index": "idx_users_email"}, // GUT: Index genutzt
 {"type": "ReturnNode"}
]
 },
 "stats": {
 "executionTime": 0.023, // 200x schneller
 "scannedIndex": 1
 }
}
```

## Problem: High CPU Usage

**Symptom:** CPU >90% dauerhaft

**Diagnose:**

```
Top Queries nach CPU-Zeit
curl -s http://localhost:8529/_admin/query-stats \
 | jq '.queries | sort_by(.cpu_time) | reverse | .[0:10]'

Beispiel-Output:
[
 {
 "query": "FOR doc IN large_collection RETURN doc",
 "cpu_time": 45.2,
 "count": 120,
 "avg_duration_ms": 8500
 }
]
```

**Solution:**

```
-- Option 1: Query optimieren (Projection)
FOR doc IN large_collection
 RETURN {id: doc._id, name: doc.name} -- Nur benötigte Felder

-- Option 2: Limit hinzufügen
FOR doc IN large_collection
 LIMIT 100
 RETURN doc

-- Option 3: Background-Job für Batch-Processing
FOR doc IN large_collection
 FILTER doc.needs_processing == true
 UPDATE doc WITH {needs_processing: false, processed_at: DATE_NOW()}
 OPTIONS {waitForSync: false} -- Async I/O
```

## 27.3 Replikations-Probleme

### Problem: Replication Lag

**Symptom:** Replica ist 5 Minuten hinter Primary

**Diagnose:**

```
Replication Status prüfen
curl http://localhost:8529/_admin/replication/status

Output:
{
 "primary": "node-1",
 "replica": "node-2",
 "lag_seconds": 300,
 "last_applied_timestamp": "2025-12-31T22:55:00Z",
 "pending_operations": 15000
}
```

### Root Causes & Solutions:

#### 1. Netzwerk-Latenz:

```
Latenz messen
ping node-2
> 50ms → Problem!

Lösung: Gleiche Region/AZ nutzen
terraform apply -var="replica_region=eu-central-1"
```

#### 2. Replica überlastet:

```
CPU/Memory auf Replica prüfen
ssh node-2 "top -b -n 1 | head -20"

Lösung: Replica upgraden
kubectl scale statefulset themis-replica --replicas=0
kubectl set resources statefulset themis-replica \
 --limits=cpu=8,memory=32Gi
kubectl scale statefulset themis-replica --replicas=1
```

### 3. Zu viele Schreibvorgänge:

```
-- Schreibrate reduzieren mit Batching
LET batch = @documents -- Array von 1000 Docs
FOR doc IN batch
 INSERT doc INTO collection
OPTIONS {waitForSync: false} -- Async für höheren Throughput
```

---

## 27.4 Memory-Probleme

### Problem: Out of Memory (OOM)

**Symptom:** Server crashed mit OOM

**Diagnose:**

```
Memory-Statistiken
curl http://localhost:8529/_admin/statistics | jq '.memory'

{
 "resident_set_size_mb": 15800, # Actual RAM usage
 "virtual_size_mb": 18200,
 "heap_used_mb": 14500,
 "heap_limit_mb": 16000, # x 90% ausgelastet!
 "buffer_cache_mb": 1200
}
```



**Solutions:****1. Memory Limit erhöhen:**

```
k8s/themis-deployment.yaml
resources:
 limits:
 memory: 32Gi # Von 16Gi auf 32Gi
 requests:
 memory: 24Gi
```

**2. Query Memory Leaks finden:**

```
-- Große Result Sets vermeiden
FOR doc IN huge_collection
 LIMIT 1000000 -- x 1M Docs in Memory!
 RETURN doc

-- Besser: Streaming mit Cursor
FOR doc IN huge_collection
 RETURN doc

OPTIONS {stream: true, batchSize: 1000}
```

**3. Buffer Cache tunen:**

```
themis.conf: Buffer Cache reduzieren
buffer_cache_size_mb=512 # Von 2048 auf 512
```

---

## 27.5 Deadlock-Probleme

**Problem: Deadlock Detected**

**Symptom:** Transaction failed mit "Deadlock detected"

**Diagnose:**

```
-- Deadlock-Log abrufen
FOR dl IN deadlock_log
 SORT dl.timestamp DESC
 LIMIT 1
 RETURN dl

{
 "timestamp": "2025-12-31T23:00:00Z",
 "transactions": [
 {
 "tx_id": "tx-1234",
 "locked_collections": ["orders", "inventory"],
 "waiting_for": "inventory/item-5"
 },
 {
 "tx_id": "tx-5678",
 "locked_collections": ["inventory", "orders"], // x Umgekehrte Reihenfolge!
 "waiting_for": "orders/order-10"
 }
]
}
```

### Solution: Lock Ordering

```
-- x FALSCH: Inkonsistente Lock-Reihenfolge
// Transaction 1
UPDATE "orders/o1" ...
UPDATE "inventory/i1" ...

// Transaction 2
UPDATE "inventory/i1" ... // Deadlock!
UPDATE "orders/o1" ...

-- RICHTIG: Konsistente Reihenfolge (alphabetisch)
// Beide Transactions
UPDATE "inventory/i1" ... // Immer zuerst inventory
UPDATE "orders/o1" ... // Dann orders
```

**Lock Timeout setzen:**

```
FOR doc IN collection
 UPDATE doc WITH {...}
 OPTIONS {lockTimeout: 5000} -- 5s statt default 30s
```

## 27.6 Index-Probleme

**Problem: Korrupter Index**

**Symptom:** Query returned wrong results

**Diagnose:**

```
Index Integrity Check
curl http://localhost:8529/_admin/index/check/users/idx_email

{
 "index": "idx_email",
 "status": "corrupted",
 "missing_entries": 42,
 "extra_entries": 5
}
```

**Solution:**

```
-- Index neu erstellen
DROP INDEX users/idx_email
CREATE INDEX idx_email ON users (email)

-- Verify
FOR u IN users
 FILTER u.email == 'test@example.com'
 RETURN u
```

## Problem: Index zu groß

**Symptom:** Index verbraucht 50 GB

**Diagnose:**

```
curl http://localhost:8529/_admin/index/stats | jq '.indexes[] | select(.size_mb > 10000)'

{
 "name": "idx_fulltext_articles",
 "size_mb": 52000, # 52 GB!
 "document_count": 10000000
}
```

**Solution:**

```
-- Option 1: Sparse Index (nur nicht-NULL Werte)
CREATE INDEX idx_email_sparse ON users (email)
 OPTIONS {sparse: true}

-- Option 2: Partial Index (nur aktive User)
CREATE INDEX idx_active_users ON users (email)
 WHERE status == 'active'

-- Option 3: Archivierung alter Daten
FOR doc IN articles
 FILTER doc.created_at < DATE_SUBTRACT(DATE_NOW(), 2, 'years')
 REMOVE doc IN articles
 INSERT doc INTO articles_archive
```

---

## 27.7 Network Partition Recovery

### Problem: Split-Brain nach Partition

**Symptom:** Zwei separate Cluster nach Netzwerk-Trennung

**Diagnose:**

```
Node 1 (Europe)
curl http://node-1:8529/_admin/cluster/status
{"nodes": ["node-1", "node-2"], "quorum": true}

Node 3 (US - isoliert)
curl http://node-3:8529/_admin/cluster/status
{"nodes": ["node-3"], "quorum": false} # x Lost quorum
```

**Recovery:**

```
1. Netzwerk reparieren
(Fix Firewall/VPN/Router)

2. Manuelles Rejoin erzwingen
curl -X POST http://node-3:8529/_admin/cluster/rejoin \
 -d '{"primary": "http://node-1:8529"}'

3. Replication Catch-up warten
watch -n 5 'curl -s http://node-3:8529/_admin/replication/lag'

4. Quorum wiederherstellen
curl http://node-1:8529/_admin/cluster/status
{"nodes": ["node-1", "node-2", "node-3"], "quorum": true} #
```

---

## 27.8 Backup & Restore Issues

### Problem: Backup schlägt fehl

**Symptom:** Backup job timeout after 2 hours

**Diagnose:**

```
Backup-Logs prüfen
journalctl -u themis-backup -f

Error: "Disk full on backup volume"
df -h /backup

/backup: 98% verwendet
```

**Solutions:**

```
Option 1: Alte Backups löschen
find /backup -name "*.backup" -mtime +30 -delete

Option 2: Inkrementales Backup statt Full
themis-backup --mode=incremental --since=2025-12-30

Option 3: Compression erhöhen
themis-backup --compression=zstd --compression-level=19
```

---

## 27.9 Common Error Messages

### Error: "Collection not found"

```
ERROR: Collection 'user' not found
```

**Solution:**

```
-- Typo: 'user' statt 'users'
FOR u IN users -- Richtig
RETURN u
```

### Error: "Index hint invalid"

```
ERROR: Index hint 'idx_name' does not exist
```

**Solution:**

```
-- Index existiert nicht mehr → neu erstellen oder Hint entfernen
CREATE INDEX idx_name ON users (name)

-- Oder Query ohne Hint:
FOR u IN users
 FILTER u.name == 'Alice'
 RETURN u
```

**Error: "Transaction timeout"**

```
ERROR: Transaction timeout after 30000ms
```

**Solution:**

```
-- Transaction zu lang → in kleinere Batches aufteilen
LET batch_size = 1000
FOR doc IN large_update
 LIMIT @offset, batch_size
 UPDATE doc IN collection
```

## 27.10 Troubleshooting Playbook

Problem	Symptom	Erste Schritte	Eskalation
Slow Query	>5s Response	EXPLAIN, add Index	Query Rewrite
High CPU	>90% Usage	Query Stats, Optimize	Scale up
Replication Lag	>60s Lag	Network Check, Batch Size	Add Replica
OOM	Crash/Restart	Memory Stats, Increase Limit	Optimize Queries
Deadlock	Transaction Fails	Lock Ordering	Reduce Concurrency
Corrupt Index	Wrong Results	Rebuild Index	Restore Backup
Split-Brain	Quorum Lost	Network Repair, Rejoin	Manual Failover

**Best Practices:** - Immer EXPLAIN vor Production-Deployment - Monitoring-Alerts für Lag >30s, CPU >80%, Memory >85% - Regelmäßige Index-Maintenance (weekly VACUUM/ANALYZE) - Backup-Tests (monatlich Restore-Drill) - Runbooks für alle kritischen Fehler - Post-Mortems nach jedem Incident



# Teil IX - Referenzen & API

---

# Kapitel 28: Kapitel 28 - AQL Referenz

"Eine Abfragesprache ist nur so gut wie ihre Dokumentation."

## Überblick

Dieses Kapitel ist die komplette Referenz für AQL (Adaptive Query Language), die einheitliche Abfragesprache von ThemisDB. Sie deckt alle 479 Sprachelemente ab: 119 Keywords und 360 eingebaute Funktionen.

**Was Sie in diesem Kapitel finden:** - Vollständiger Sprachumfang (v1.3.1) - Kategorisierte Funktionsreferenz - Praktische Beispiele für jeden Bereich - Performance-Hinweise und Best Practices

**Voraussetzungen:** Kapitel 5-9 (Datenmodelle), Grundverständnis von SQL.

Abb. 28.0: AQL-Query-Execution-Pipeline

## 28.1 Sprachumfang-Überblick

### Executive Summary

Aspekt	v1.3.0	v1.3.1	Änderung
Reservierte Keywords	72	119	+47 (+65%)
Eingebaute Funktionen	~360	~360	0
Gesamt-Sprachumfang	432	479	+47 (+11%)

**Wichtig:** v1.3.1 erweitert Sprachkonstrukte (TYPE, FUNCTION, CLASS) - keine neuen Funktionen.

## 28.2 Reservierte Keywords (119)

### 28.2.1 Core Language (8)

FOR, IN, LET, FILTER, COLLECT, SORT, LIMIT, RETURN

#### Beispiel:

```
FOR user IN users
 FILTER user.age >= 18
 LET email_domain = SPLIT(user.email, "@")[1]
 COLLECT domain = email_domain WITH COUNT INTO count
 SORT count DESC
 LIMIT 10
 RETURN { domain, count }
```

### 28.2.2 Logical Operators (3)

AND, OR, NOT

#### Beispiel:

```
FOR product IN products
 FILTER product.price >= 10 AND product.price <= 100
 FILTER NOT product.discontinued
 FILTER product.category == "Electronics" OR product.category == "Books"
 RETURN product
```

### 28.2.3 Aggregation Functions (8)

COUNT, SUM, AVG, MIN, MAX, VARIANCE, STDDEV, UNIQUE

#### Beispiel:

```
FOR order IN orders
 COLLECT year = DATE_YEAR(order.created_at)
 AGGREGATE
 total = SUM(order.amount),
 avg_order = AVG(order.amount),
 min_order = MIN(order.amount),
 max_order = MAX(order.amount),
 order_count = COUNT(1)
 RETURN { year, total, avg_order, min_order, max_order, order_count }
```

### 28.2.4 Graph Traversal (4)

```
OUTBOUND, INBOUND, ANY, SHORTEST_PATH
```

#### Beispiel:

```
-- Finde alle Freunde von Alice (2 Hops)
FOR v, e, p IN 1..2 OUTBOUND "users/alice" friends
 RETURN { friend: v.name, path_length: LENGTH(p.edges) }

-- Kürzester Pfad von Alice zu Bob
FOR v, e IN OUTBOUND SHORTEST_PATH "users/alice" TO "users/bob" follows
 RETURN { user: v.name, action: e.type }
```

### 28.2.5 DDL (Data Definition Language) (5)

```
CREATE, DROP, COLLECTION, INDEX, VIEW
```

#### Beispiele:

```
-- Collection erstellen
CREATE COLLECTION products

-- Index erstellen
CREATE INDEX products_price ON products(price) TYPE SKIPLIST

-- View erstellen
CREATE VIEW active_users AS
 FOR u IN users
 FILTER u.status == "active"
 RETURN u

-- Löschen
DROP INDEX products_price
DROP COLLECTION products
```

## 28.2.6 DML (Data Manipulation Language) (6)

```
INSERT, UPDATE, REPLACE, REMOVE, UPSERT, INTO, WITH
```

### Beispiele:

```
-- Insert
INSERT { name: "Alice", age: 30 } INTO users

-- Update
UPDATE { _key: "alice" } WITH { age: 31 } IN users

-- Upsert (Insert if not exists)
UPSERT { email: "alice@example.com" }
 INSERT { name: "Alice", email: "alice@example.com", age: 30 }
 UPDATE { last_login: DATE_NOW() }
 IN users

-- Remove
REMOVE { _key: "alice" } IN users

-- Replace
REPLACE { _key: "alice", name: "Alice Smith", age: 31 } IN users
```

## 28.2.7 LLM Operations (13)

```
LLM, INFER, RAG, EMBED, MODEL, LORA, STATS, CACHE,
LOAD, UNLOAD, LIST, INGEST, BLOB
```

### Beispiele:

```
-- RAG-Query
FOR doc IN documents
 LET embedding = EMBED(doc.content, { model: "text-embedding-3-small" })
 LET neighbors = KNN_SEARCH(embeddings, embedding, 5)
 LET context = CONCAT_SEPARATOR("\n", neighbors[*].content)
 LET answer = LLM("Answer based on context", { context, model: "gpt-4" })
 RETURN answer

-- Ingest Content
INGEST BLOB "data/documents.pdf"
 INTO content_store
 WITH { chunk_size: 512, overlap: 50 }
```

## 28.2.8 Index Types (7)

```
HASH, SKIPLIST, FULLTEXT, GEO, PERSISTENT, TTL, VECTOR
```

### Beispiele:

```
-- Hash Index (Equality)
CREATE INDEX users_email ON users(email) TYPE HASH

-- Skiplist (Range Queries)
CREATE INDEX products_price ON products(price) TYPE SKIPLIST

-- Fulltext Index
CREATE INDEX articles_body ON articles(body) TYPE FULLTEXT

-- Geo Index
CREATE INDEX locations_coords ON locations(lat, lng) TYPE GEO

-- TTL Index (Auto-Expiry)
CREATE INDEX sessions_ttl ON sessions(expires_at) TYPE TTL

-- Vector Index (ANN Search)
CREATE INDEX embeddings_vector ON embeddings(vector)
 TYPE VECTOR
 OPTIONS { metric: "cosine", dimensions: 768 }
```

---

## 28.3 Date/Time Functions (45)

### 28.3.1 Aktuelle Zeit/Datum (11)

**Wichtigste Funktionen:** - `DATE_NOW()` - Aktueller ISO-Timestamp - `CURRENT_DATE()` /  
`CURRENT_TIME()` - Nur Datum/Zeit - `UNIX_TIMESTAMP()` - Unix Epoch

```
RETURN {
 now: DATE_NOW(),
 unix: UNIX_TIMESTAMP()
}
-- → {"now": "2025-01-15T10:30:45Z", "unix": 1736936445}
```



### 28.3.2 Interval Functions (8)

**Interval-Arithmetik:** `DAYS(n)`, `HOURS(n)`, `WEEKS(n)` etc. für Zeitberechnungen.

```
-- Letzte 30 Tage
FILTER order.created_at >= DATE_NOW() - DAYS(30)

-- Fälligkeitsdatum berechnen
LET due = invoice.created_at + DAYS(14)
```

### 28.3.3 Komponenten-Extraktion (11)

**Komponenten extrahieren:** `DATE_YEAR()`, `DATE_MONTH()`, `DATE_DAY()`, `DATE_HOUR()`, etc.

```
-- Gruppierung nach Monat
COLLECT month = DATE_MONTH(sale.date)
AGGREGATE total = SUM(sale.amount)
```

### 28.3.4 Workday Functions (6)

<code>WORKDAYS(start, end, calendar)</code>	-- Arbeitstage zwischen zwei Daten
<code>WORKDAYS_ADD(date, days, calendar)</code>	-- Addiere Arbeitstage
<code>IS_WEEKEND(date)</code>	-- true wenn Samstag/Sonntag
<code>IS_WORKDAY(date, calendar)</code>	-- true wenn Arbeitstag
<code>HOLIDAYS(country, year)</code>	-- Liste der Feiertage
<code>HOLIDAYS_BETWEEN(start, end, country)</code>	-- Feiertage in Zeitraum

**Beispiele:**

```
-- Berechne SLA-Frist (5 Arbeitstage)
FOR ticket IN support_tickets
 RETURN {
 ticket_id: ticket._key,
 created: ticket.created_at,
 sla_deadline: WORKDAYS_ADD(ticket.created_at, 5, "DE")
 }

-- Finde Tickets, die am Wochenende erstellt wurden
FOR ticket IN support_tickets
 FILTER IS_WEEKEND(ticket.created_at)
 RETURN ticket
```

## 28.4 String Functions (20)

CONCAT(str1, str2, ...)	-- Strings zusammenfügen
CONCAT_SEPARATOR(sep, str1, ...)	-- Mit Trennzeichen
SUBSTRING(str, start, length)	-- Teilstring
UPPER(str)	-- Großbuchstaben
LOWER(str)	-- Kleinbuchstaben
TRIM(str)	-- Whitespace entfernen
LTRIM(str)	-- Links trimmen
RTRIM(str)	-- Rechts trimmen
LENGTH(str)	-- Länge
REVERSE(str)	-- Umkehren
REPLACE(str, search, replace)	-- Ersetzen
SPLIT(str, separator)	-- In Array aufteilen
JOIN(array, separator)	-- Array zu String
STARTS_WITH(str, prefix)	-- Startet mit
ENDS_WITH(str, suffix)	-- Endet mit
CONTAINS(str, substring)	-- Enthält
FIND(str, substring)	-- Position finden
REGEX_TEST(str, pattern)	-- Regex-Match?
REGEX_MATCHES(str, pattern)	-- Alle Matches
REGEX_REPLACE(str, pattern, repl)	-- Regex-Ersetzung

### Beispiele:

```
-- Email-Domain extrahieren
FOR user IN users
 LET domain = SPLIT(user.email, "@")[1]
 RETURN { user: user.name, domain }

-- Case-insensitive Suche
FOR article IN articles
 FILTER CONTAINS(LOWER(article.title), LOWER("ThemisDB"))
 RETURN article

-- Email-Validierung mit Regex
FOR user IN users
 FILTER REGEX_TEST(user.email, "^[^@]+@[^@]+\.\.[^@]+$")
 RETURN user
```

---

# 28.5 Math Functions (30)

```
-- Basic Math
ABS(x) -- Betrag
CEIL(x) -- Aufrunden
FLOOR(x) -- Abrunden
ROUND(x, d) -- Runden auf d Dezimalstellen
SQRT(x) -- Quadratwurzel
POW(x, y) -- x hoch y
EXP(x) -- e^x
LOG(x) -- Natürlicher Logarithmus
LOG10(x) -- Logarithmus zur Basis 10
LN(x) -- Alias für LOG

-- Trigonometric
SIN(x) -- Sinus
COS(x) -- Kosinus
TAN(x) -- Tangens
ASIN(x) -- Arkussinus
ACOS(x) -- Arkuskosinus
ATAN(x) -- Arkustangens
ATAN2(y, x) -- Arkustangens mit Vorzeichen
SINH(x) -- Hyperbelsinus
COSH(x) -- Hyperbelkosinus
TANH(x) -- Hyperbeltangens

-- Utilities
MIN(a, b, ...) -- Minimum
MAX(a, b, ...) -- Maximum
RAND() -- Zufallszahl [0, 1)
RAND_INT(a, b) -- Ganzzahl zwischen a und b
PI() -- π
E() -- e
SIGN(x) -- Vorzeichen (-1, 0, 1)
TRUNC(x) -- Ganzzahlteil
MOD(x, y) -- Modulo
QUOTIENT(x, y) -- Ganzzahlige Division
```

**Beispiele:**

```
-- Berechne Entfernung mit Pythagoras
FOR point IN points
 LET distance = SQRT(POW(point.x, 2) + POW(point.y, 2))
 RETURN { point: point._key, distance }

-- Zufälliges Sampling (10%)
FOR doc IN documents
 FILTER RAND() < 0.1
 RETURN doc

-- Preisberechnung mit Rundung
FOR product IN products
 LET price_with_tax = ROUND(product.price * 1.19, 2)
 RETURN { product: product.name, price_with_tax }
```

## 28.6 Array Functions (20)

<code>PUSH(array, value)</code>	-- Element anhängen
<code>POP(array)</code>	-- Letztes Element entfernen
<code>SHIFT(array)</code>	-- Erstes Element entfernen
<code>UNSHIFT(array, value)</code>	-- Element vorne einfügen
<code>APPEND(array, value)</code>	-- Alias für PUSH
<code>PREPEND(array, value)</code>	-- Alias für UNSHIFT
<code>FIRST(array)</code>	-- Erstes Element
<code>LAST(array)</code>	-- Letztes Element
<code>NTH(array, n)</code>	-- n-tes Element
<code>SLICE(array, start, end)</code>	-- Teilarray
<code>FLATTEN(array, depth)</code>	-- Array flach machen
<code>UNIQUE(array)</code>	-- Duplikate entfernen
<code>UNION(array1, array2)</code>	-- Vereinigung
<code>INTERSECTION(array1, array2)</code>	-- Schnittmenge
<code>DIFFERENCE(array1, array2)</code>	-- Differenz
<code>MAP(array, fn)</code>	-- Transform
<code>FILTER(array, fn)</code>	-- Filtern
<code>REDUCE(array, fn, init)</code>	-- Reduzieren
<code>SORT_ARRAY(array)</code>	-- Sortieren
<code>REVERSE_ARRAY(array)</code>	-- Umkehren

### Beispiele:



```
-- Finde gemeinsame Tags
FOR doc1 IN documents
 FOR doc2 IN documents
 FILTER doc1._key < doc2._key
 LET common_tags = INTERSECTION(doc1.tags, doc2.tags)
 FILTER LENGTH(common_tags) > 0
 RETURN { doc1: doc1._key, doc2: doc2._key, common_tags }

-- Extrahiere alle einzigartigen Kategorien
RETURN UNIQUE(FLATTEN(
 FOR product IN products
 RETURN product.categories
))
```

---

## 28.7 Geo Functions (25)

### 28.7.1 GeoJSON Konstruktion (6)

```
GEO_POINT(lng, lat)
GEO_MULTIPPOINT(points)
GEO_LINESTRING(coords)
GEO_MULTILINESTRING(lines)
GEO_POLYGON(rings)
GEO_MULTIPOLYGON(polygons)
```

#### Beispiel:

```
-- Erstelle Restaurant mit Location
INSERT {
 name: "Bella Italia",
 location: GEO_POINT(13.405, 52.520) -- Berlin
} INTO restaurants
```

## 28.7.2 Spatial Predicates (6)

```
GEO_CONTAINS(geo1, geo2) -- geo1 enthält geo2
GEO_INTERSECTS(geo1, geo2) -- geo1 schneidet geo2
ST_Contains(geo1, geo2) -- Alias
ST_Within(geo2, geo1) -- geo2 innerhalb geo1
ST_Intersects(geo1, geo2) -- Alias
GEO_EQUALS(geo1, geo2) -- Geometrisch gleich
```

### Beispiel:

```
-- Finde Restaurants in Polygon (Stadtteil)
LET polygon = GEO_POLYGON([
 [13.40, 52.52], [13.41, 52.52],
 [13.41, 52.51], [13.40, 52.51],
 [13.40, 52.52]
])

FOR restaurant IN restaurants
 FILTER GEO_CONTAINS(polygon, restaurant.location)
 RETURN restaurant
```

## 28.7.3 Distance & Metrics (5)

```
GEO_DISTANCE(geo1, geo2) -- Haversine-Distanz (Meter)
ST_Distance(geo1, geo2) -- Alias
GEO_IN_RANGE(geo, center, radius) -- Innerhalb Radius
GEO_AREA(polygon) -- Fläche (m²)
ST_Area(polygon) -- Alias
ST_Length(linestring) -- Länge (Meter)
```

### Beispiel:

```
-- Finde Restaurants innerhalb 1 km
LET my_location = GEO_POINT(13.405, 52.520)

FOR restaurant IN restaurants
 LET distance = GEO_DISTANCE(my_location, restaurant.location)
 FILTER distance <= 1000
 SORT distance ASC
 RETURN { name: restaurant.name, distance }
```

## 28.7.4 CRS Transformations (10)

```
ST_TRANSFORM(geo, from_crs, to_crs)
ST_SRID(geo) -- SRID auslesen
ST_SetSRID(geo, srid) -- SRID setzen
WGS84_TO_UTM(lng, lat) -- WGS84 → UTM
UTM_TO_WGS84(easting, northing, zone)
ETRS89_TO_WGS84(x, y)
WGS84_TO_ETRS89(lng, lat)
HELMERT_TRANSFORM(x, y, params) -- 7-Parameter-Transformation
GAUSS_KRUEGER_TO_UTM(x, y)
UTM_TO_GAUSS_KRUEGER(easting, northing)
```

### Beispiel:

```
-- Transformiere GPS-Koordinaten nach UTM (für genaue Distanzmessung)
FOR location IN survey_points
 LET utm = WGS84_TO_UTM(location.lng, location.lat)
 RETURN { location: location._key, utm }
```

## 28.8 Vector Functions (20)

```
-- Similarity Metrics
COSINE_SIMILARITY(v1, v2)
DOT_PRODUCT(v1, v2)
EUCLIDEAN_DISTANCE(v1, v2)
MANHATTAN_DISTANCE(v1, v2)
HAMMING_DISTANCE(v1, v2)
JACCARD_SIMILARITY(v1, v2)

-- Vector Operations
VECTOR_NORM(v) -- L2-Norm
VECTOR_NORMALIZE(v) -- Auf Länge 1 normalisieren
VECTOR_ADD(v1, v2)
VECTOR_SUBTRACT(v1, v2)
VECTOR_MULTIPLY(v, scalar)
VECTOR_DIVIDE(v, scalar)
VECTOR_DOT(v1, v2) -- Alias für DOT_PRODUCT
VECTOR_CROSS(v1, v2) -- Kreuzprodukt (nur 3D)

-- Distance Metrics
L1_DISTANCE(v1, v2) -- Manhattan
L2_DISTANCE(v1, v2) -- Euclidean
CHEBYSHEV_DISTANCE(v1, v2) -- Max-Norm

-- Search
KNN_SEARCH(collection, query_vector, k)
VECTOR_QUANTIZE(v, bits) -- Quantisierung (SQ8, SQ4)
```

### Beispiele:

```
-- Semantic Search mit Embeddings
LET query_embedding = EMBED("machine learning tutorial")

FOR doc IN embeddings
 LET similarity = COSINE_SIMILARITY(query_embedding, doc.vector)
 SORT similarity DESC
 LIMIT 10
 RETURN { doc: doc.title, similarity }

-- KNN-Search mit Prefilter
FOR result IN KNN_SEARCH(
 embeddings,
 EMBED("neural networks"),
 20,
 { filter: "category == 'AI'" }
)
 RETURN result
```

## 28.9 Graph Functions (15)

```
-- Traversal
OUTBOUND(vertex, edge_collection)
INBOUND(vertex, edge_collection)
ANY(vertex, edge_collection)
SHORTEST_PATH(start, end, edge_collection)

-- Path Metrics
PATH_LENGTH(path)
PATH_VERTICES(path)
PATH_EDGES(path)

-- Algorithms
CONNECTED_COMPONENTS(graph)
PAGERANK(graph)
BETWEENNESS_CENTRALITY(graph, vertex)
CLOSENESS_CENTRALITY(graph, vertex)
COMMUNITY_DETECTION(graph)

-- Utilities
IS_CONNECTED(graph, v1, v2)
GRAPH_DIAMETER(graph)
GRAPH_RADIUS(graph)
```

### Beispiele:

```
-- PageRank auf Social Graph
LET pageranks = PAGERANK({
 vertexCollections: ["users"],
 edgeCollections: ["follows"]
})

FOR user IN users
 SORT pageranks[user._key] DESC
 LIMIT 10
 RETURN { user: user.name, score: pageranks[user._key] }

-- Finde Communities
LET communities = COMMUNITY_DETECTION({
 vertexCollections: ["users"],
 edgeCollections: ["friends"]
})

FOR user IN users
 RETURN { user: user.name, community: communities[user._key] }
```

---

## 28.10 Best Practices

### 28.10.1 Index Usage

```
-- x SCHLECHT: Keine Index-Nutzung
FOR user IN users
 FILTER UPPER(user.email) == "ALICE@EXAMPLE.COM"
 RETURN user

-- GUT: Index auf email (case-insensitive)
FOR user IN users
 FILTER user.email == "alice@example.com"
 RETURN user
```

### 28.10.2 Early Filtering

```
-- x SCHLECHT: Filter nach JOIN
FOR order IN orders
 FOR user IN users
 FILTER user._key == order.user_id
 FILTER order.amount > 100
 RETURN { order, user }

-- GUT: Filter vor JOIN
FOR order IN orders
 FILTER order.amount > 100
 FOR user IN users
 FILTER user._key == order.user_id
 RETURN { order, user }
```

### 28.10.3 Projection

```
-- x SCHLECHT: Vollständige Dokumente
FOR user IN users
 RETURN user

-- GUT: Nur benötigte Felder
FOR user IN users
 RETURN { name: user.name, email: user.email }
```

---

## 28.11 Zusammenfassung

AQL bietet **479 Sprachelemente**: - **119 Keywords** für Struktur und Semantik - **360 Funktionen** für Datenmanipulation

### Hauptkategorien

1. **Date/Time (45)**: Umfassende Zeitzoneunterstützung, Arbeitstage
2. **Strings (20)**: Regex, Splitting, Manipulation



3. **Math (30):** Trigonometrie, Statistik
4. **Arrays (20):** Funktionale Programmierung
5. **Geo (35):** GeoJSON, CRS-Transformationen
6. **Vectors (20):** ANN-Search, Similarity
7. **Graph (15):** Traversal, Centrality, Communities

## Nächste Schritte

- **Kapitel 5-9:** Praktische Beispiele für jedes Datenmodell
- **Kapitel 21:** Query Optimization
- **AQL Grammar:** [aql/AQL\\_GRAMMAR\\_EXTENDED\\_v1.3.1.ebnf](#)

---

## 28.12 Advanced Patterns & Idioms

### 28.12.1 Recursive Queries with Custom Depth

```
-- Find all ancestors up to depth N
LET find_ancestors = FUNCTION(person_id, max_depth) {
 RETURN (
 FOR v, e, p IN 0..max_depth OUTBOUND person_id GRAPH 'family'
 FILTER CURRENT.generation < person_id.generation
 RETURN {
 person: v.name,
 generation: v.generation,
 depth: LENGTH(p.edges)
 }
)
}

RETURN find_ancestors('persons/alice', 3)
```

### 28.12.2 Transitive Closure (Find All Reachable Nodes)

```
-- Get all projects reachable from a given person (including transitive deps)
FOR p IN projects
 FILTER p._id == 'projects/prj1'
 LET all_deps = (
 FOR dep IN 0..10 OUTBOUND p GRAPH 'depends_on'
 RETURN dep._id
) | UNIQUE()
 RETURN {
 project: p.name,
 dependencies: all_deps,
 dep_count: LENGTH(all_deps)
 }
```

### 28.12.3 Sliding Window (Time-Based)

```
-- Calculate moving average with time window (7 days)
FOR current_date IN DATE_RANGE(@start_date, @end_date, '1d')
 LET window_start = DATE_SUBTRACT(current_date, 7, 'd')
 LET daily_data = (
 FOR event IN events
 FILTER event.date >= window_start AND event.date <= current_date
 RETURN event.value
)
 RETURN {
 date: current_date,
 moving_avg: AVG(daily_data),
 moving_sum: SUM(daily_data),
 moving_count: COUNT(daily_data)
 }
```

### 28.12.4 Lateral Join (Explode & Flatten)

```
-- Unnest nested arrays
FOR order IN orders
 LET items = order.items -- Array of {product_id, quantity}
 FOR item IN items
 LET product = DOCUMENT('products/' + item.product_id)
 RETURN {
 order_id: order._id,
 product_name: product.name,
 quantity: item.quantity,
 item_total: item.quantity * product.price
 }
```

### 28.12.5 Pivot (Transform Rows to Columns)

```
-- Convert months to columns
FOR record IN sales
 COLLECT year = YEAR(record.date)
 AGGREGATE
 jan = SUM(record.amount FILTER MONTH(record.date) == 1),
 feb = SUM(record.amount FILTER MONTH(record.date) == 2),
 mar = SUM(record.amount FILTER MONTH(record.date) == 3),
 q1_total = SUM(record.amount FILTER MONTH(record.date) IN [1,2,3])
 RETURN { year, jan, feb, mar, q1_total }
```

## 28.13 Window Functions (Comprehensive)

### 28.13.1 Row Numbering

```
-- Rank students by score within each class
FOR s IN students
 SORT s.class, s.score DESC
 LET rank_in_class = (
 SELECT COUNT(*) FROM students s2
 WHERE s2.class == s.class AND s2.score >= s.score
)
 RETURN {
 name: s.name,
 class: s.class,
 score: s.score,
 rank: rank_in_class
 }
```

### 28.13.2 Cumulative (Running) Totals

```
-- Sales running total
FOR order IN SORT(orders, 'created_at')
 COLLECT idx = @row_number
 AGGREGATE
 order_value = order.amount,
 cumulative = SUM(orders[* FILTER @row_number <= idx].amount)
 RETURN {
 order_id: order._id,
 order_value,
 cumulative,
 running_total: cumulative
 }
```

### 28.13.3 First/Last of Group

```
-- Get first and last transaction per account
FOR t IN transactions
 SORT t.account_id, t.timestamp
 COLLECT account = t.account_id INTO group = t
 RETURN {
 account,
 first_transaction: group[0],
 last_transaction: group[LENGTH(group)-1],
 total_transactions: LENGTH(group)
 }
```

### 28.13.4 Lead/Lag (Next/Previous Row)

```
-- Compare consecutive values
FOR metric IN SORT(metrics, 'timestamp')
 LET current_idx = @row_number
 LET prev = (
 FOR m IN metrics
 FILTER m.timestamp < metric.timestamp
 SORT m.timestamp DESC
 LIMIT 1
 RETURN m
)[0]
 RETURN {
 timestamp: metric.timestamp,
 value: metric.value,
 previous_value: prev?.value || NULL,
 change: metric.value - (prev?.value || metric.value)
 }
```

## 28.14 Type System & Type Checking

### 28.14.1 Type Checking Functions

```
-- Type predicates (return true/false)
IS_ARRAY(value) -- Array type
IS_BOOL(value) -- Boolean
IS_NUMBER(value) -- Number (int or float)
IS_INTEGER(value) -- Integer specifically
IS_STRING(value) -- String
IS_NULL(value) -- Null/undefined
IS_OBJECT(value) -- Object/Document
IS_LIST(value) -- Alias for IS_ARRAY
IS_DEFINED(value) -- Has definition (not null)

-- Examples
FOR doc IN collection
 FILTER IS_STRING(doc.email) && IS_NUMBER(doc.age)
RETURN doc
```

### 28.14.2 Type Conversion

```
-- Convert between types
TO_STRING(value) -- Convert to string
TO_NUMBER(value) -- Convert to number
TO_BOOL(value) -- Convert to boolean
TO_ARRAY(value) -- Convert to array
TO_ARRAY(list) -- Ensure is array
TO_LIST(value) -- Alias for TO_ARRAY

-- Examples
FOR doc IN collection
 RETURN {
 id: doc._id,
 price_str: TO_STRING(doc.price),
 age: TO_NUMBER(doc.age_str),
 is_active: TO_BOOL(doc.active_flag)
 }
```

### 28.14.3 Type Coercion & Safe Operations

```
-- Safe type operations
COALESCE(a, b, c) -- Return first non-null
FIRST_ITEM(array) -- Get first item safely
LAST_ITEM(array) -- Get last item safely
NTH_ITEM(array, n) -- Get nth item safely

-- Examples
FOR doc IN collection
 RETURN {
 id: doc._id,
 phone: COALESCE(doc.phone, doc.mobile, "N/A"),
 first_tag: FIRST_ITEM(doc.tags),
 primary_contact: NTH_ITEM(doc.contacts, 0)
 }
```

## 28.15 Error Handling & Validation

### 28.15.1 TRY-CATCH Patterns

```
-- Basic error handling
BEGIN
 TRY
 LET result = 100 / 0 -- Will error
 RETURN result
 CATCH err
 RETURN { error: err.message, code: err.code }
COMMIT
```

### 28.15.2 Conditional Errors (THROW)

```
-- Throw custom errors
FOR user IN users
 FILTER user.balance < 0
 THROW "INVARIANT_VIOLATED: Negative balance for user " + user._id
 RETURN user
```

### 28.15.3 Schema Validation

```
-- Validate document structure
FOR doc IN users
 LET valid = (
 IS_STRING(doc.name) &&
 IS_STRING(doc.email) &&
 IS_OBJECT(doc.address) &&
 IS_ARRAY(doc.tags) &&
 CONTAINS(doc.email, "@")
)
 FILTER valid
 RETURN doc
```



## 28.16 Performance Optimization Deep Dive

### 28.16.1 Index-Aware Query Writing

```
-- Indexes for: email (unique), status, created_at

-- x Index not used (UPPER)
FOR u IN users
 FILTER UPPER(u.email) == "ALICE@EXAMPLE.COM"
 RETURN u

-- Index used (direct match)
FOR u IN users
 FILTER u.email == "alice@example.com"
 RETURN u

-- Composite index: (status, created_at)
FOR u IN users
 FILTER u.status == 'active'
 FILTER u.created_at >= '2025-01-01'
 RETURN u

-- △ Index partial (filter before join)
FOR u IN users
 FILTER u.status == 'active'
 FOR o IN orders FILTER o.user_id == u._id
 RETURN { u, o }
```

## 28.16.2 Aggregation Optimization

```
-- x Slow: Iterate then aggregate
LET users_active = (
 FOR u IN users
 FILTER u.status == 'active'
 RETURN u
)
RETURN { count: LENGTH(users_active) }

-- Fast: Aggregate in query
FOR u IN users
 FILTER u.status == 'active'
 COLLECT WITH COUNT INTO count
 RETURN { count }

-- Fastest: With aggregation function
FOR u IN users
 FILTER u.status == 'active'
 AGGREGATE count = COUNT(1)
 RETURN { count }
```

## 28.16.3 Subquery Optimization

```
-- x Subquery in FILTER (repeats for each row)
FOR order IN orders
 FILTER order.user_id IN (
 SELECT _id FROM users WHERE status == 'premium'
)
 RETURN order

-- Join directly (index on user_id)
FOR user IN users
 FILTER user.status == 'premium'
 FOR order IN orders
 FILTER order.user_id == user._id
 RETURN order
```

## 28.17 Advanced Collection Operations

### 28.17.1 Bulk Operations with LIMIT & Offset

```
-- Batch processing
FOR page IN 0..@max_pages
 LET batch_start = page * @page_size
 FOR user IN users
 SORT user._key
 LIMIT batch_start, @page_size
 RETURN {
 batch_number: page,
 user
 }
 }
```

### 28.17.2 Bulk Update with Conditions

```
-- Update multiple documents
FOR user IN users
 FILTER user.created_at < DATE_SUBTRACT(DATE_NOW(), 1, 'y')
 UPDATE user WITH {
 status: 'inactive',
 last_updated: DATE_NOW(),
 archive_flag: true
 } IN users
RETURN OLD -- Return before-update document
```

### 28.17.3 Safe Delete with Verification

```
-- Delete with rollback on condition
BEGIN
 LET to_delete = (
 FOR d IN documents
 FILTER d.archived == true
 FILTER d.created_at < DATE_SUBTRACT(DATE_NOW(), 2, 'y')
 RETURN d
)

 IF LENGTH(to_delete) > 0 THEN
 FOR doc IN to_delete
 REMOVE doc IN documents
 COMMIT
 ELSE
 ABORT "No documents to delete"
 ENDIF
RETURN { deleted: LENGTH(to_delete) }
```

---

## 28.18 Zusammenfassung & Schnellreferenz

### Core Constructs (8)

- **Iteration:** FOR...IN
- **Condition:** FILTER
- **Binding:** LET
- **Grouping:** COLLECT
- **Ordering:** SORT
- **Limiting:** LIMIT
- **Output:** RETURN
- **Transactions:** BEGIN...COMMIT

## Top 20 Functions (By Usage)

1. **COUNT** - Aggregation
2. **FILTER** - Predicate logic
3. **LENGTH** - Array/string size
4. **SUM** - Numeric aggregation
5. **CONCAT** - String joining
6. **CONTAINS** - Substring search
7. **SPLIT** - String splitting
8. **SORT** - Ordering
9. **LIMIT** - Result limiting
10. **DATE\_NOW** - Current timestamp
11. **UPPER/LOWER** - Case conversion
12. **ROUND** - Numeric rounding
13. **AVG** - Mean aggregation
14. **MIN/MAX** - Range extremes
15. **REGEX** - Pattern matching
16. **DISTANCE** - Geospatial
17. **SUBSTRING** - String slicing
18. **TO\_STRING** - Type conversion
19. **FLATTEN** - Array flattening
20. **UNIQUE** - Deduplication

## Decision Table: Which Construct?

Goal	Use	Example
Iterate docs	FOR...IN	FOR u IN users RETURN u
Filter rows	FILTER	FILTER u.status == 'active'
Create variable	LET	LET age = DATE_DIFF(u.birth, NOW())
Group rows	COLLECT	COLLECT status = u.status
Order results	SORT	SORT u.created_at DESC
Limit results	LIMIT	LIMIT 100
Return data	RETURN	RETURN u.name
Atomic ops	BEGIN...COMMIT	Transactions

## Performance Checklist

- ☐ Indexes on FILTER fields
- ☐ Indexes on SORT fields
- ☐ Early filtering (before JOINS)
- ☐ Projections (only needed fields)
- ☐ COLLECT for aggregations
- ☐ Avoid expressions in FILTER
- ☐ Use bind parameters
- ☐ Batch operations with LIMIT

# Kapitel 29: Kapitel 29 - Analytics & Process Mining

---

*"Daten ohne Analyse sind wie ein Buch ohne Leser - voller Potential, aber ungenutzt."*

## Überblick

ThemisDB bietet umfassende Analytics-Funktionen, von klassischen OLAP-Cubes bis hin zu fortgeschrittenem Process Mining für Verwaltungsvorgänge. Dieses Kapitel zeigt die komplette Palette.

**Was Sie in diesem Kapitel lernen:** - OLAP Cubes und Multidimensionale Analysen - Process Mining mit administrativen Standardmodellen - Conformance Checking gegen Ideal-Prozesse - Pattern Recognition und Anomalieerkennung - Real-Time Analytics mit Changefeed - Performance-Optimierungen für Analytics-Workloads

**Voraussetzungen:** Kapitel 2 (Architektur), Kapitel 28 (AQL Referenz).

---

## 29.1 OLAP Fundamentals

### 29.1.1 Was ist OLAP?

**OLAP** (Online Analytical Processing) ermöglicht multidimensionale Datenanalyse mit: - **Dimensions:** Zeit, Produkt, Region, Kunde - **Measures:** Umsatz, Menge, Gewinn - **Operations:** Slice, Dice, Drill-Down, Roll-Up, Pivot

### 29.1.2 OLAP Cube Architektur

Abb. 29.1: Process-Mining-Pipeline

## 29.1.3 OLAP Operations in AQL

### Slice (Eine Dimension fixieren)

```
-- Slice: Nur Verkäufe in 2024
FOR sale IN sales
 FILTER DATE_YEAR(sale.date) == 2024
 COLLECT
 product = sale.product_name,
 region = sale.region
 AGGREGATE total = SUM(sale.amount)
 RETURN { product, region, total }
```

### Dice (Mehrere Dimensionen einschränken)

```
-- Dice: 2024, Electronics, Nur Europa
FOR sale IN sales
 FILTER DATE_YEAR(sale.date) == 2024
 FILTER sale.category == "Electronics"
 FILTER sale.region IN ["Germany", "France", "UK"]
 COLLECT
 country = sale.region,
 month = DATE_MONTH(sale.date)
 AGGREGATE total = SUM(sale.amount)
 SORT country, month
 RETURN { country, month, total }
```



## Drill-Down (Von Jahr zu Monat)

```
-- Drill-Down: Von Jahr zu Monaten zu Tagen
FOR sale IN sales
 FILTER DATE_YEAR(sale.date) == 2024
 FILTER DATE_MONTH(sale.date) == 3 -- März
 COLLECT
 day = DATE_DAY(sale.date)
 AGGREGATE
 total = SUM(sale.amount),
 count = COUNT(1)
 SORT day
 RETURN { day, total, count }
```

## Roll-Up (Aggregation auf höhere Ebene)

```
-- Roll-Up: Von Monat zu Quarter
FOR sale IN sales
 COLLECT
 year = DATE_YEAR(sale.date),
 quarter = DATE_QUARTER(sale.date)
 AGGREGATE total = SUM(sale.amount)
 SORT year, quarter
 RETURN { year, quarter, total }
```

## Pivot (Zeilen/Spalten tauschen)

```
-- Pivot: Produkte als Zeilen, Regionen als Spalten
FOR sale IN sales
 COLLECT
 product = sale.product_name
 AGGREGATE
 total_germany = SUM(sale.region == "Germany" ? sale.amount : 0),
 total_france = SUM(sale.region == "France" ? sale.amount : 0),
 total_uk = SUM(sale.region == "UK" ? sale.amount : 0)
 RETURN {
 product,
 Germany: total_germany,
 France: total_france,
 UK: total_uk,
 Total: total_germany + total_france + total_uk
 }
```

## 29.2 Process Mining Fundamentals

### 29.2.1 Was ist Process Mining?

Process Mining analysiert Event-Logs, um reale Prozesse zu: 1. **Discover:** Prozessmodelle aus Logs ableiten 2. **Check:** Conformance gegen Soll-Prozesse prüfen 3. **Enhance:** Prozesse mit Performance-Daten anreichern

### 29.2.2 Event Log Structure

```
-- Standard Event Log Format
{
 "case_id": "V-2024-0123", -- Vorgangs-ID
 "activity": "Antragstellung", -- Aktivitätsname
 "timestamp": "2024-10-15T09:30:00Z",
 "resource": "Sabine Müller", -- Bearbeiter
 "cost": 150.00, -- Kosten
 "additional_data": {
 "department": "Bauamt",
 "priority": "normal"
 }
}
```

### 29.2.3 Process Mining Pipeline

Abb. 29.2: Event-Log-Processing

## 29.3 Administrative Standard Models

ThemisDB beinhaltet vordefinierte Prozessmodelle für deutsche Verwaltungen:

### 29.3.1 Verfügbare Modelle

Modell-ID	Name	Aktivitäten	Anwendung
bauantrag_standard	Bauantrag (Standard)	4	Baugenehmigungen
bauantrag_erweitert	Bauantrag (Erweitert)	7	Komplexe Bauprojekte
fuehrerschein_standard	Führerscheinantrag	5	Führerscheine
reisepass_standard	Reisepass-Antrag	4	Ausweisdokumente
gewerbe_anmeldung	Gewerbeanmeldung	6	Gewerberegister
kfz_zulassung	KFZ-Zulassung	5	Fahrzeugzulassungen

## 29.3.2 Modell laden

```
-- Lade Bauantrags-Standardmodell
LET model = PM_LOAD_ADMIN_MODEL("bauantrag_standard")

RETURN model
```

### Output:

```
{
 "id": "bauantrag_standard",
 "name": "Bauantrag (Standard)",
 "version": "1.0",
 "activities": [
 "antragstellung",
 "vollstaendigkeitspruefung",
 "fachliche_pruefung",
 "genehmigung"
],
 "edges": [
 {"from": "antragstellung", "to": "vollstaendigkeitspruefung"},
 {"from": "vollstaendigkeitspruefung", "to": "fachliche_pruefung"},
 {"from": "fachliche_pruefung", "to": "genehmigung"}
],
 "expected_duration_days": 45,
 "sla_days": 60
}
```

---

## 29.4 Similarity Search

### 29.4.1 Hybrid Similarity Metrics

ThemisDB kombiniert drei Similarity-Arten:

1. **Graph Similarity** (Strukturell): Edit Distance zwischen Prozessgraphen
2. **Vector Similarity** (Semantisch): Embeddings der Aktivitätsnamen

### 3. Behavioral Similarity (Ausführung): Trace-Varianz, Durchlaufzeiten

#### 29.4.2 Similar Process Search

```
-- Finde ähnliche Bauanträge
LET ideal = PM_LOAD_ADMIN_MODEL("bauantrag_standard")

LET similar = PM_FIND_SIMILAR(ideal, {
 method: "hybrid",
 threshold: 0.75, -- Min 75% Ähnlichkeit
 limit: 50,
 graph_weight: 0.4, -- 40% Struktur
 vector_weight: 0.3, -- 30% Semantik
 behavioral_weight: 0.3 -- 30% Verhalten
})

FOR result IN similar
 SORT result.overall_similarity DESC
 RETURN {
 case_id: result.case_id,
 similarity: result.overall_similarity,
 metrics: {
 graph: result.metrics.graph_similarity,
 vector: result.metrics.vector_similarity,
 behavioral: result.metrics.behavioral_similarity
 },
 matched_activities: result.matched_activities,
 extra_activities: result.extra_activities,
 missing_activities: result.missing_activities
 }
```

#### Output:

```
[
 {
 "case_id": "V-2024-0123",
 "similarity": 0.92,
 "metrics": {
 "graph": 0.95,
 "vector": 0.88,
 "behavioral": 0.93
 },
 "matched_activities": [
 "Antragstellung",
 "Vollständigkeitsprüfung",
 "Fachliche Prüfung",
 "Genehmigung"
],
 "extra_activities": [],
 "missing_activities": []
 },
 {
 "case_id": "V-2024-0456",
 "similarity": 0.85,
 "metrics": {
 "graph": 0.82,
 "vector": 0.91,
 "behavioral": 0.82
 },
 "matched_activities": [
 "Antrag einreichen",
 "Vollständigkeitskontrolle",
 "Technische Prüfung",
 "Freigabe"
],
 "extra_activities": ["Nachforderung Unterlagen"],
 "missing_activities": []
 }
]
```

### 29.4.3 Similarity Visualization

Abb. 29.3: Process-Discovery-Algorithm

---

## 29.5 Conformance Checking

### 29.5.1 Fitness & Precision

**Fitness:** Wie viele Schritte des Ist-Prozesses passen zum Soll-Prozess? **Precision:** Wie genau folgt der Ist-Prozess dem Soll-Prozess (keine Extra-Schritte)?

## 29.5.2 Conformance Check Query

```
-- Prüfe alle Bauanträge gegen Standard
LET ideal = PM_LOAD_ADMIN_MODEL("bauantrag_standard")

FOR case IN bauantraege
 LET comparison = PM_COMPARE_IDEAL(case.vorgang_id, ideal)

 -- Nur Fälle mit Fitness < 90%
 FILTER comparison.fitness < 0.9

 SORT comparison.fitness ASC

 RETURN {
 vorgang_id: case.vorgang_id,
 antragsteller: case.antragsteller,
 eingangsdatum: case.eingangsdatum,

 -- Conformance Metrics
 fitness: comparison.fitness,
 precision: comparison.precision,
 steps_checked: comparison.steps_checked,
 steps_conformant: comparison.steps_conformant,

 -- Abweichungen
 deviations: comparison.deviations,

 -- Handlungsempfehlung
 action: (
 comparison.fitness < 0.7 ? " Dringend prüfen" :
 comparison.fitness < 0.9 ? " Kleinere Anpassungen" :
 " OK"
)
 }
}
```

### Output:



```
[
 {
 "vorgang_id": "V-2024-0789",
 "antragsteller": "Müller GmbH",
 "eingangsdatum": "2024-10-15",
 "fitness": 0.65,
 "precision": 0.82,
 "steps_checked": 6,
 "steps_conformant": 4,
 "deviations": [
 "Activity 'Vollständigkeitsprüfung' was skipped",
 "Activity 'Genehmigung' occurred before 'Fachliche Prüfung'"
],
 "action": " Dringend prüfen"
 }
]
```

### 29.5.3 Conformance Heatmap

Abb. 29.4: Conformance-Checking-Flow

## 29.6 Pattern Recognition

### 29.6.1 Problematische Patterns

```
-- Pattern: Genehmigung vor Prüfung (Compliance-Problem!)
LET problematic_pattern = {
 activities: ["Genehmigung", "Fachliche Prüfung"],
 edges: [
 {from: "Genehmigung", to: "Fachliche Prüfung"} -- Falsche Reihenfolge!
]
}

FOR case IN bauantraege
 LET has_problem = PM_HAS_PATTERN(
 case.vorgang_id,
 problematic_pattern,
 0.8 -- 80% Schwellwert
)

 FILTER has_problem == true

 LET trace = PM_EXTRACT_TRACE(case.vorgang_id)

 RETURN {
 vorgang_id: case.vorgang_id,
 alert: "⚠ Genehmigung vor Prüfung!",
 activities: trace.activities,
 timestamps: trace.timestamps,
 requires_investigation: true
 }
```

## 29.6.2 Loop Detection

```
-- Finde Prozesse mit Schleifen (z.B. wiederholte Nachforderungen)
FOR case IN bauantraege
 LET trace = PM_EXTRACT_TRACE(case.vorgang_id)
 LET loops = PM_DETECT_LOOPS(trace)

 FILTER LENGTH(loops) > 0

 RETURN {
 vorgang_id: case.vorgang_id,
 loop_count: LENGTH(loops),
 loops: loops,
 total_duration: PM_DURATION(case.vorgang_id)
 }
```

### Output:

```
[
 {
 "vorgang_id": "V-2024-1234",
 "loop_count": 2,
 "loops": [
 {
 "activities": ["Vollständigkeitsprüfung", "Nachforderung", "Vollständigkeitsprüfung"],
 "iterations": 3,
 "total_duration_days": 18
 }
],
 "total_duration": 67
 }
]
```

## 29.7 Performance Analysis

### 29.7.1 Bottleneck Detection

```
-- Finde langsamste Aktivitäten
FOR case IN bauantraege
 LET trace = PM_EXTRACT_TRACE(case.vorgang_id)

 FOR activity IN trace.activities
 LET duration = activity.end_time - activity.start_time

 COLLECT
 activity_name = activity.name
 AGGREGATE
 avg_duration = AVG(duration),
 min_duration = MIN(duration),
 max_duration = MAX(duration),
 count = COUNT(1)

 SORT avg_duration DESC
 LIMIT 10

 RETURN {
 activity: activity_name,
 avg_duration_hours: avg_duration / 3600,
 min_duration_hours: min_duration / 3600,
 max_duration_hours: max_duration / 3600,
 occurrences: count
 }
```

**Output:**

```
[
 {
 "activity": "Fachliche Prüfung",
 "avg_duration_hours": 168.5,
 "min_duration_hours": 24.0,
 "max_duration_hours": 720.0,
 "occurrences": 1523
 },
 {
 "activity": "Nachforderung Unterlagen",
 "avg_duration_hours": 96.3,
 "min_duration_hours": 12.0,
 "max_duration_hours": 480.0,
 "occurrences": 427
 }
]
```

## 29.7.2 SLA Violations

```
-- SLA-Überschreitungen
LET ideal = PM_LOAD_ADMIN_MODEL("bauantrag_standard")
LET sla_days = ideal.sla_days -- 60 Tage

FOR case IN bauantraege
 LET duration = PM_DURATION(case.vorgang_id)

 FILTER duration > sla_days

 SORT duration DESC

RETURN {
 vorgang_id: case.vorgang_id,
 eingangsdatum: case.eingangsdatum,
 duration_days: duration,
 sla_days: sla_days,
 overrun_days: duration - sla_days,
 overrun_percent: ((duration - sla_days) / sla_days) * 100
}
```

## 29.8 Real-Time Analytics with Changefeed

### 29.8.1 Live Dashboard Query

```
-- Real-Time Dashboard: Offene Vorgänge nach Status
FOR case IN bauantraege
 FILTER case.status != "abgeschlossen"

 LET current_activity = PM_CURRENT_ACTIVITY(case.vorgang_id)
 LET elapsed_days = DATE_DIFF(case.eingangsdatum, DATE_NOW(), "day")

 COLLECT
 status = current_activity
 AGGREGATE
 count = COUNT(1),
 avg_elapsed = AVG(elapsed_days)

 SORT count DESC

 RETURN {
 status,
 count,
 avg_elapsed_days: ROUND(avg_elapsed, 1)
 }
```

### 29.8.2 Changefeed für Analytics

```
Changefeed für Echtzeit-Analytics
feed = db.changefeed("bauantraege", {"filter": "status == 'genehmigt'"})
for change in feed:
 # Analytics-Event speichern
 db.aql("INSERT {event: 'approval', id: @id} INTO events",
 {"id": change['new']['vorgang_id']})
```

## 29.9 Performance Optimizations

### 29.9.1 Materialized Views

```
-- Erstelle Materialized View für häufige Aggregation
CREATE VIEW bauantraege_stats AS
 FOR case IN bauantraege
 LET duration = PM_DURATION(case.vorgang_id)
 LET trace = PM_EXTRACT_TRACE(case.vorgang_id)

 COLLECT
 year = DATE_YEAR(case.eingangsdatum),
 month = DATE_MONTH(case.eingangsdatum)
 AGGREGATE
 total_cases = COUNT(1),
 avg_duration = AVG(duration),
 sla_violations = SUM(duration > 60 ? 1 : 0)

 RETURN {
 year,
 month,
 total_cases,
 avg_duration,
 sla_violations
 }

-- Schneller Zugriff
FOR stat IN bauantraege_stats
 RETURN stat
```



## 29.9.2 Pre-Aggregation

```
-- Pre-Aggregation für OLAP Cubes
INSERT {
 _key: "2024-Q1-Electronics-Germany",
 year: 2024,
 quarter: 1,
 category: "Electronics",
 region: "Germany",
 total_sales: 1245000.50,
 unit_count: 3421,
 last_updated: DATE_NOW()
} INTO sales_cube_cache
```

## 29.10 Zusammenfassung

### Kernfeatures

1. **OLAP:** Multidimensionale Analysen (Slice, Dice, Drill-Down, Pivot)
2. **Process Mining:** Discovery, Conformance, Enhancement
3. **Admin Models:** Vordefinierte deutsche Verwaltungsprozesse
4. **Similarity:** Hybrid (Graph + Vector + Behavioral)
5. **Conformance:** Fitness & Precision Metrics
6. **Patterns:** Anomalieerkennung, Loop Detection
7. **Performance:** Bottleneck-Analyse, SLA-Tracking
8. **Real-Time:** Changefeed-Integration

### Best Practices

- **Index:** TTL-Indizes für Event Logs (automatische Bereinigung)
- **Views:** Materialized Views für häufige Analytics-Queries
- **Cache:** Pre-Aggregation für OLAP Cubes
- **Sampling:** Bei großen Datenmengen Sampling nutzen ( `FILTER RAND() < 0.1` )

## 29.8 Advanced Analytics: Multi-Dimensional Analysis

### 29.8.1 Dimensional Modeling (Star Schema)

```
-- Fact table: order_facts (contains measures and FK to dimensions)
FOR fact IN order_facts
 LET customer = DOCUMENT(fact.customer_dim_id)
 LET product = DOCUMENT(fact.product_dim_id)
 LET time = DOCUMENT(fact.time_dim_id)
 COLLECT
 region = customer.region,
 category = product.category,
 month = time.month
 AGGREGATE
 revenue = SUM(fact.amount),
 units_sold = SUM(fact.quantity),
 transactions = COUNT(1),
 avg_order_value = AVG(fact.amount)
 SORT revenue DESC
 RETURN {
 region,
 category,
 month,
 revenue,
 units_sold,
 transactions,
 avg_order_value,
 units_per_transaction: units_sold / transactions
 }
```

## 29.8.2 Slice & Dice Operations

```
-- Drill down: Regional → Store → Item Level
LET filters = @filters -- {region: 'EMEA', store_id: 'S123'}

FOR fact IN order_facts
 LET customer = DOCUMENT(fact.customer_dim_id)
 LET store = DOCUMENT(fact.store_dim_id)
 LET product = DOCUMENT(fact.product_dim_id)

 FILTER customer.region == filters.region
 FILTER store._id == filters.store_id

 COLLECT item_id = product._id, item_name = product.name
 AGGREGATE
 units = SUM(fact.quantity),
 revenue = SUM(fact.amount),
 margin = SUM(fact.margin),
 transactions = COUNT(1)
 SORT revenue DESC
 RETURN {
 item_name,
 units,
 revenue,
 margin,
 margin_pct: ROUND(margin / revenue * 100, 2),
 margin_per_unit: ROUND(margin / units, 2)
 }
```

### 29.8.3 Cohort Analysis (Behavioral Segments)

```
-- Analyze cohorts of users by first purchase month
FOR user IN users
 LET first_purchase = (
 FOR order IN orders
 FILTER order.customer_id == user._id
 SORT order.created_at ASC
 LIMIT 1
 RETURN order.created_at
)[0]

 LET cohort_month = DATE_FORMAT(first_purchase, '%yyyy-%mm')
 LET subsequent_purchases = (
 FOR o IN orders
 FILTER o.customer_id == user._id
 FILTER o.created_at > first_purchase
 RETURN o
)

 COLLECT cohort = cohort_month
 AGGREGATE
 users_in_cohort = COUNT(1),
 avg_ltv = AVG(subsequent_purchases[*].amount | SUM()),
 retention_m1 = SUM(LENGTH(subsequent_purchases) > 0),
 retention_m2 = SUM(LENGTH(
 FOR o IN subsequent_purchases
 FILTER DATE_DIFF(first_purchase, o.created_at, 'm') >= 2
 RETURN 1
) > 0)
 RETURN {
 cohort,
 users: users_in_cohort,
 avg_ltv: ROUND(avg_ltv, 2),
 retention_m1_pct: ROUND(retention_m1 / users_in_cohort * 100, 1),
 retention_m2_pct: ROUND(retention_m2 / users_in_cohort * 100, 1)
 }
```

## 29.9 Real-Time Analytics with Changefeeds

### 29.9.1 Streaming Aggregation Pattern

```
-- Real-time sales dashboard (with changefeed)
-- This would be called continuously as events arrive
FOR event IN changefeed('orders')
 LET order = event.doc
 LET time_bucket = DATE_FORMAT(order.created_at, '%yyyy-%mm-%dd %hh:00')

 COLLECT
 time = time_bucket,
 status = order.status
 AGGREGATE
 orders = COUNT(1),
 revenue = SUM(order.amount),
 avg_order = AVG(order.amount)

 RETURN {
 timestamp: time,
 status,
 metric: {
 orders,
 revenue: ROUND(revenue, 2),
 avg_order: ROUND(avg_order, 2)
 }
 }
```

## 29.9.2 Late-Arriving Facts Handling

```
-- Handle out-of-order or delayed events
FOR event IN changefeed('orders')
 LET is_late = DATE_DIFF(DATE_NOW(), event.doc.created_at, 's') > 3600 -- > 1 hour old

 IF is_late THEN
 -- Route to late-arriving fact handler
 INSERT {
 order_id: event.doc._id,
 received_at: DATE_NOW(),
 event_time: event.doc.created_at,
 delay_seconds: DATE_DIFF(DATE_NOW(), event.doc.created_at, 's'),
 status: 'LATE_ARRIVAL'
 } INTO late_facts
 ELSE
 -- Process normally
 INSERT {
 order_id: event.doc._id,
 status: 'PROCESSED'
 } INTO fact_orders
 ENDIF

RETURN event
```

## 29.10 Performance Optimization for Analytics

### 29.10.1 Materialized Views for OLAP

```
-- Create materialized view: daily_sales_summary
-- Run this nightly as batch job

BEGIN
 TRUNCATE daily_sales_summary

 FOR order IN orders
 FILTER order.status == 'completed'
 LET day = DATE_FORMAT(order.created_at, '%yyyy-%mm-%dd')

 COLLECT date = day
 AGGREGATE
 total_revenue = SUM(order.amount),
 order_count = COUNT(1),
 avg_order = AVG(order.amount),
 max_order = MAX(order.amount),
 min_order = MIN(order.amount)

 INSERT {
 _key: date,
 date,
 total_revenue,
 order_count,
 avg_order: ROUND(avg_order, 2),
 max_order,
 min_order,
 created_at: DATE_NOW()
 } INTO daily_sales_summary

 COMMIT

 RETURN { inserted: LENGTH(daily_sales_summary) }
```

## 29.10.2 Sampling for Large Datasets

```
-- Sample-based analytics (1% of data for speed)
FOR order IN orders
 FILTER RAND() < 0.01 -- 1% sample
 COLLECT month = DATE_FORMAT(order.created_at, '%yyyy-%mm')
 AGGREGATE
 sample_revenue = SUM(order.amount),
 sample_orders = COUNT(1)
 RETURN {
 month,
 estimated_revenue: ROUND(sample_revenue / 0.01, 0), -- Extrapolate
 estimated_orders: ROUND(sample_orders / 0.01, 0),
 confidence: "95% (p < 0.05)"
 }
```



### 29.10.3 Incremental Analytics (Delta Processing)

```
-- Only process changes since last run
LET last_run = @last_checkpoint || '2000-01-01'

FOR order IN orders
 FILTER order.updated_at > last_run

 LET day = DATE_FORMAT(order.created_at, '%yyyy-%mm-%dd')

 COLLECT date = day
 AGGREGATE
 new_revenue = SUM(order.amount),
 new_orders = COUNT(1)

 -- Update materialized view incrementally
 LET current = DOCUMENT('daily_sales_summary/' + date)
 UPDATE current WITH {
 total_revenue: (current.total_revenue || 0) + new_revenue,
 order_count: (current.order_count || 0) + new_orders,
 last_updated: DATE_NOW()
 } IN daily_sales_summary

RETURN { date, new_revenue, new_orders }
```

---

## 29.11 Case Study: E-Commerce Analytics Platform

### 29.11.1 Data Model

#### Dimension Tables:

- customers (id, name, region, segment)
- products (id, name, category, brand, price)
- time (date, month, quarter, year, day\_of\_week)
- stores (id, location, region)

#### Fact Tables:

- order\_facts (customer, product, store, time, amount, quantity)
- product\_views (customer, product, time, duration)
- cart\_events (customer, product, time, action)

**29.11.2 Top-Level Metrics Query**

```
-- Daily KPI dashboard
LET today = DATE_FORMAT(DATE_NOW(), '%yyyy-%mm-%dd')

FOR fact IN order_facts
 FILTER fact.date == today

 COLLECT WITH COUNT INTO total_orders
 AGGREGATE
 gmv = SUM(fact.amount),
 avg_order_value = AVG(fact.amount),
 units_sold = SUM(fact.quantity)

LET top_products = (
 FOR f IN order_facts
 FILTER f.date == today
 COLLECT product_id = f.product_id INTO group = f
 AGGREGATE revenue = SUM(group[*].amount)
 SORT revenue DESC
 LIMIT 5
 RETURN { product_id, revenue }
)

LET top_regions = (
 FOR f IN order_facts
 FILTER f.date == today
 LET store = DOCUMENT(f.store_id)
 COLLECT region = store.region INTO group = f
 AGGREGATE revenue = SUM(group[*].amount)
 SORT revenue DESC
 LIMIT 3
 RETURN { region, revenue }
)

RETURN {
 date: today,
 metrics: {
 total_orders,
 gmv: ROUND(gmv, 2),
```

```
 aov: ROUND(avg_order_value, 2),
 units_sold
 },
 top_products,
 top_regions
 }
```

## 29.12 Governance & Data Quality

### 29.12.1 Data Quality Metrics

```
-- Monitor data quality
FOR event IN events
 COLLECT
 date = DATE_FORMAT(event.created_at, '%yyyy-%mm-%dd'),
 event_type = event.type
 AGGREGATE
 event_count = COUNT(1),
 null_values = SUM(event.value == NULL ? 1 : 0),
 duplicates = SUM(
 LENGTH(
 FOR e IN events
 FILTER e.event_id == event.event_id
 RETURN e
) > 1 ? 1 : 0
),
 invalid_timestamps = SUM(
 event.created_at > DATE_NOW() ? 1 : 0
)
 RETURN {
 date,
 event_type,
 quality_score: ROUND(
 (event_count - null_values - duplicates - invalid_timestamps) /
 event_count * 100, 1
),
 issues: {
 nulls: null_values,
 dups: duplicates,
 future_dates: invalid_timestamps
 }
 }
```

## 29.12.2 SLA Compliance Monitoring

```
-- Monitor analytics SLA: 99.5% uptime, < 30s query latency
FOR query IN analytics_log
 COLLECT
 hour = DATE_FORMAT(query.executed_at, '%yyyy-%mm-%dd %hh:00'),
 query_type = query.type
 AGGREGATE
 successful = SUM(query.status == 'success' ? 1 : 0),
 failed = SUM(query.status == 'failed' ? 1 : 0),
 p95_latency = PERCENTILE(query.latency_ms, 0.95),
 p99_latency = PERCENTILE(query.latency_ms, 0.99),
 max_latency = MAX(query.latency_ms)
 RETURN {
 hour,
 query_type,
 availability: ROUND(successful / (successful + failed) * 100, 2),
 sla_met: (p99_latency < 30000),
 latency: {
 p95_ms: ROUND(p95_latency, 0),
 p99_ms: ROUND(p99_latency, 0),
 max_ms: max_latency
 }
 }
}
```

---

## 29.13 Zusammenfassung: Analytics-Architektur in ThemisDB

### Architektur-Schichten

Schicht	Technologie	Latenz	Nutzung
Real-Time	Changefeeds + Streaming	<1s	Live Dashboard
Near-Real-Time	Micro-batch (5-60s)	5-60s	Alert Systems
Tactical	Views (hourly/daily)	1-24h	Standard Reports
Strategic	Data Warehouse	1-7d	Historical Analysis

### Best Practices Checklist

- [ ] **Modeling:** Dimensional (Star/Snowflake) für OLAP
  - [ ] **Aggregation:** Materialized Views für häufige Queries
  - [ ] **Performance:** Sampling für explorative Analyse
  - [ ] **Incremental:** Delta-Processing seit letztem Checkpoint
  - [ ] **Quality:** Monitoring für Duplicates, Nulls, Out-of-Order
  - [ ] **Real-Time:** Changefeeds für Live Dashboards
  - [ ] **Governance:** SLA Monitoring für Analytics Pipelines
  - [ ] **Retention:** TTL-Indizes für Event Log Cleanup
-



# Kapitel 30: Kapitel 30 - Deployment & Operations

---

*"Deployment ist kein einmaliger Akt, sondern ein kontinuierlicher Prozess."*

---

## Überblick

Dieses Kapitel behandelt die produktive Bereitstellung von ThemisDB: von Docker-Containern über Kubernetes bis hin zu Cloud-Deployments. Außerdem lernen Sie Monitoring, Backup-Strategien und Skalierungstechniken.

**Was Sie in diesem Kapitel lernen:** - Docker-basierte Deployments - Kubernetes-Orchestrierung mit Helm Charts - Cloud-Provider-Integration (AWS, Azure, GCP) - Monitoring mit Prometheus & Grafana - Backup & Disaster Recovery - Horizontal Scaling & Sharding - Security Best Practices

**Voraussetzungen:** Kapitel 4 (Installation), Grundkenntnisse in Containerisierung.

---

## 30.1 Docker Deployment

### 30.1.1 Basic Docker Setup

**Dockerfile:**

```
FROM ubuntu:24.04
RUN apt-get update && apt-get install -y libssl3 libzstd1
RUN useradd -r themis
COPY themis_server /usr/local/bin/
EXPOSE 8529
CMD ["themis_server"]
```

**docker-compose.yml:**

```
services:
 themis:
 image: themisdb/themis:v1.3.4
 ports:
 - "8529:8529"
 volumes:
 - themis-data:/var/lib/themis/data
 healthcheck:
 test: ["curl", "-f", "http://localhost:8529/_api/version"]

volumes:
 themis-data:
```

**Starten:**

```
Build Image
docker build -t themisdb/themis:v1.3.4 .

Start with docker-compose
docker-compose up -d

Check logs
docker-compose logs -f themis

Health check
curl http://localhost:8529/_api/version
```

## **30.1.2 Docker Multi-Stage Build**

```
Stage 1: Build
FROM ubuntu:24.04 AS builder

RUN apt-get update && apt-get install -y \
 cmake \
 g++ \
 git \
 ninja-build \
 libssl-dev \
 libzstd-dev \
 libjemalloc-dev

WORKDIR /build
COPY . .
RUN cmake -B build -G Ninja -DCMAKE_BUILD_TYPE=Release
RUN cmake --build build --target themis_server -j8

Stage 2: Runtime
FROM ubuntu:24.04

RUN apt-get update && apt-get install -y \
 libssl3 \
 libzstd1 \
 libjemalloc2 \
 && rm -rf /var/lib/apt/lists/*

COPY --from=builder /build/build/themis_server /usr/local/bin/

RUN useradd -r -u 999 -g users themis && \
 mkdir -p /var/lib/themis/data && \
 chown -R themis:users /var/lib/themis

USER themis
EXPOSE 8529 8530

CMD ["/usr/local/bin/themis_server"]
```

## 30.2 Kubernetes Deployment

### 30.2.1 Kubernetes Manifests

**namespace.yaml:**

```
apiVersion: v1
kind: Namespace
metadata:
 name: themis-prod
```

**configmap.yaml:**

```
apiVersion: v1
kind: ConfigMap
metadata:
 name: themis-config
 namespace: themis-prod
data:
 themis.conf: |
 [database]
 path = /var/lib/themis/data

 [server]
 endpoint = http://0.0.0.0:8529
 threads = 16

 [logging]
 level = info
 file = /var/log/themis/themis.log
```

**statefulset.yaml:**

```
apiVersion: apps/v1
kind: StatefulSet
metadata:
 name: themis
 namespace: themis-prod
spec:
 serviceName: themis-headless
 replicas: 3
 selector:
 matchLabels:
 app: themis
 template:
 metadata:
 labels:
 app: themis
 spec:
 containers:
 - name: themis
 image: themisdb/themis:v1.3.4
 ports:
 - containerPort: 8529
 name: http
 - containerPort: 8530
 name: websocket
 volumeMounts:
 - name: data
 mountPath: /var/lib/themis/data
 - name: config
 mountPath: /etc/themis
 resources:
 requests:
 memory: "4Gi"
 cpu: "2000m"
 limits:
 memory: "8Gi"
 cpu: "4000m"
 livenessProbe:
 httpGet:
```

```
 path: /_api/version
 port: 8529
 initialDelaySeconds: 30
 periodSeconds: 10
 readinessProbe:
 httpGet:
 path: /_api/version
 port: 8529
 initialDelaySeconds: 5
 periodSeconds: 5
 volumes:
 - name: config
 configMap:
 name: themis-config
 volumeClaimTemplates:
 - metadata:
 name: data
 spec:
 accessModes: ["ReadWriteOnce"]
 storageClassName: fast-ssd
 resources:
 requests:
 storage: 100Gi
```

**service.yaml:**

```
apiVersion: v1
kind: Service
metadata:
 name: themis-headless
 namespace: themis-prod
spec:
 clusterIP: None
 selector:
 app: themis
 ports:
 - port: 8529
 name: http
 - port: 8530
 name: websocket

apiVersion: v1
kind: Service
metadata:
 name: themis-loadbalancer
 namespace: themis-prod
spec:
 type: LoadBalancer
 selector:
 app: themis
 ports:
 - port: 8529
 targetPort: 8529
 name: http
```

**Deploy:**



```
Apply all manifests
kubectl apply -f namespace.yaml
kubectl apply -f configmap.yaml
kubectl apply -f statefulset.yaml
kubectl apply -f service.yaml

Check pods
kubectl get pods -n themis-prod

Check service
kubectl get svc -n themis-prod

Logs
kubectl logs -f themis-0 -n themis-prod
```

## 30.2.2 Helm Chart

### Chart.yaml:

```
apiVersion: v2
name: themis
description: A Helm chart for ThemisDB
type: application
version: 1.3.4
appVersion: "1.3.4"
```

### values.yaml:

```
replicaCount: 3

image:
 repository: themisdb/themis
 tag: v1.3.4
 pullPolicy: IfNotPresent

resources:
 requests:
 memory: 4Gi
 cpu: 2000m
 limits:
 memory: 8Gi
 cpu: 4000m

persistence:
 enabled: true
 storageClass: fast-ssd
 size: 100Gi

service:
 type: LoadBalancer
 port: 8529

ingress:
 enabled: true
 className: nginx
 annotations:
 cert-manager.io/cluster-issuer: letsencrypt-prod
 hosts:
 - host: themis.example.com
 paths:
 - path: /
 pathType: Prefix
 tls:
 - secretName: themis-tls
 hosts:
 - themis.example.com
```

```
monitoring:
 enabled: true
 serviceMonitor:
 enabled: true
 interval: 30s
```

### Install Helm Chart:

```
Add Helm repo
helm repo add themis https://charts.themisdb.io
helm repo update

Install
helm install themis-prod themis/themis \
 --namespace themis-prod \
 --create-namespace \
 --values values.yaml

Upgrade
helm upgrade themis-prod themis/themis \
 --namespace themis-prod \
 --values values.yaml

Uninstall
helm uninstall themis-prod -n themis-prod
```

---

## 30.3 Cloud Provider Integration

### 30.3.1 AWS Deployment

#### EKS Cluster:

```
Create EKS cluster
eksctl create cluster \
 --name themis-prod \
 --region eu-central-1 \
 --nodegroup-name standard-workers \
 --node-type m5.2xlarge \
 --nodes 3 \
 --nodes-min 3 \
 --nodes-max 10 \
 --managed

Install ThemisDB
helm install themis-prod themis/themis \
 --namespace themis-prod \
 --create-namespace \
 --set persistence.storageClass=gp3 \
 --set service.annotations."service\.beta\.kubernetes\.io/aws-load-balancer-type"=nlb
```

### RDS Integration (Optional):

```
Use RDS PostgreSQL for metadata
metadata:
 backend: postgresql
 connection: "postgresql://user:pass@themis-metadata.c9akljh4.eu-central-1.rds.amazonaws.com:5432"
```

## 30.3.2 Azure Deployment

### AKS Cluster:

```
Create AKS cluster
az aks create \
 --resource-group themis-rg \
 --name themis-prod \
 --location westeurope \
 --node-count 3 \
 --node-vm-size Standard_D8s_v3 \
 --enable-managed-identity \
 --generate-ssh-keys

Get credentials
az aks get-credentials \
 --resource-group themis-rg \
 --name themis-prod

Install ThemisDB
helm install themis-prod themis/themis \
 --namespace themis-prod \
 --create-namespace \
 --set persistence.storageClass=managed-premium
```

### 30.3.3 GCP Deployment

#### GKE Cluster:

```
Create GKE cluster
gcloud container clusters create themis-prod \
 --region europe-west3 \
 --num-nodes 3 \
 --machine-type n2-standard-8 \
 --disk-size 100

Get credentials
gcloud container clusters get-credentials themis-prod \
 --region europe-west3

Install ThemisDB
helm install themis-prod themis/themis \
 --namespace themis-prod \
 --create-namespace \
 --set persistence.storageClass=pd-ssd
```

---

## 30.4 Monitoring & Observability

### 30.4.1 Prometheus Integration

**ServiceMonitor:**

```
apiVersion: monitoring.coreos.com/v1
kind: ServiceMonitor
metadata:
 name: themis
 namespace: themis-prod
spec:
 selector:
 matchLabels:
 app: themis
 endpoints:
 - port: http
 path: /metrics
 interval: 30s
```

### Key Metrics:

```
Requests
themis_http_requests_total
themis_http_request_duration_seconds

Database
themis_db_operations_total
themis_db_size_bytes
themis_db_compaction_duration_seconds

Cache
themis_cache_hit_ratio
themis_cache_size_bytes

Threads
themis_thread_pool_active
themis_thread_pool_queue_size
```

## 30.4.2 Grafana Dashboards

### Dashboard JSON:

```
{
 "dashboard": {
 "title": "ThemisDB Overview",
 "panels": [
 {
 "title": "Request Rate",
 "targets": [
 {
 "expr": "rate(themis_http_requests_total[5m])"
 }
]
 },
 {
 "title": "Database Size",
 "targets": [
 {
 "expr": "themis_db_size_bytes"
 }
]
 },
 {
 "title": "Cache Hit Ratio",
 "targets": [
 {
 "expr": "themis_cache_hit_ratio"
 }
]
 }
]
 }
}
```

### 30.4.3 Alerting Rules

**prometheus-rules.yaml:**



```
apiVersion: monitoring.coreos.com/v1
kind: PrometheusRule
metadata:
 name: themis-alerts
 namespace: themis-prod
spec:
 groups:
 - name: themis
 interval: 30s
 rules:
 - alert: ThemisHighErrorRate
 expr: rate(themis_http_requests_total{status=~"5.."}[5m]) > 0.05
 for: 5m
 labels:
 severity: critical
 annotations:
 summary: "High error rate on ThemisDB"
 description: "Error rate is {{ $value }} req/s"

 - alert: ThemisHighMemoryUsage
 expr: (container_memory_usage_bytes{pod=~"themis-.*"} / container_spec_memory_limit_bytes)
 for: 5m
 labels:
 severity: warning
 annotations:
 summary: "ThemisDB high memory usage"
 description: "Memory usage is {{ $value | humanizePercentage }}"

 - alert: ThemisDiskSpaceLow
 expr: (node_filesystem_avail_bytes{mountpoint="/var/lib/themis/data"} / node_filesystem_size_bytes{mountpoint="/var/lib/themis/data"}) < 0.1
 for: 5m
 labels:
 severity: critical
 annotations:
 summary: "ThemisDB low disk space"
 description: "Only {{ $value | humanizePercentage }} disk space remaining"
```

## **30.5 Backup & Disaster Recovery**

### **30.5.1 Snapshot Backups**

**Backup Script:**

```
#!/bin/bash

Backup configuration
BACKUP_DIR="/var/backups/themis"
TIMESTAMP=$(date +%Y%m%d_%H%M%S)
DB_PATH="/var/lib/themis/data"

Create snapshot
curl -X POST http://localhost:8529/_admin/backup/create \
 -H "Content-Type: application/json" \
 -d '{
 "label": "backup-'$TIMESTAMP'",
 "timeout": 300
 }'

Wait for snapshot
sleep 10

Copy snapshot
rsync -av --progress $DB_PATH/snapshots/backup-$TIMESTAMP \
 $BACKUP_DIR/backup-$TIMESTAMP

Upload to S3
aws s3 sync $BACKUP_DIR/backup-$TIMESTAMP \
 s3://themis-backups/backup-$TIMESTAMP \
 --storage-class GLACIER

Cleanup old local backups (keep last 7 days)
find $BACKUP_DIR -type d -mtime +7 -exec rm -rf {} +

echo "Backup completed: backup-$TIMESTAMP"
```

**Cron Job:**

```
Daily backup at 2 AM
0 2 * * * /usr/local/bin/themis-backup.sh >> /var/log/themis-backup.log 2>&1
```

### 30.5.2 Point-in-Time Recovery

```
List available backups
aws s3 ls s3://themis-backups/

Download backup
aws s3 sync s3://themis-backups/backup-20250115_020000 \
 /var/restore/themis/

Stop ThemisDB
systemctl stop themis

Restore data
rm -rf /var/lib/themis/data
cp -r /var/restore/themis /var/lib/themis/data

Start ThemisDB
systemctl start themis

Verify
curl http://localhost:8529/_api/version
```

### 30.5.3 Continuous Backup with WAL

```
Enable WAL archiving
backup:
 wal_archiving:
 enabled: true
 archive_command: "aws s3 cp %p s3://themis-wal/%f"
 archive_timeout: 60s
```

## 30.6 Horizontal Scaling

### 30.6.1 Sharding Strategy

Abb. 30.1: Deployment-Strategy-Matrix

#### Sharding Config:

```
sharding:
 enabled: true
 strategy: hash
 shards:
 - id: shard1
 endpoint: http://themis-shard1:8529
 range: [0, 333]
 - id: shard2
 endpoint: http://themis-shard2:8529
 range: [334, 666]
 - id: shard3
 endpoint: http://themis-shard3:8529
 range: [667, 999]
```

### 30.6.2 Read Replicas

```
replication:
 enabled: true
 mode: async
 replicas:
 - endpoint: http://themis-replica1:8529
 lag_max: 1s
 - endpoint: http://themis-replica2:8529
 lag_max: 1s
```

---

## 30.7 Security Best Practices

### 30.7.1 TLS/SSL Configuration

```
server:
 tls:
 enabled: true
 cert_file: /etc/themis/tls/cert.pem
 key_file: /etc/themis/tls/key.pem
 ca_file: /etc/themis/tls/ca.pem
 min_version: "1.3"
```

### 30.7.2 Authentication

```
auth:
 enabled: true
 providers:
 - type: jwt
 issuer: "https://auth.example.com"
 audience: "themis-api"
 jwks_uri: "https://auth.example.com/.well-known/jwks.json"
 - type: basic
 users_file: /etc/themis/users.htpasswd
```

### 30.7.3 Network Policies (Kubernetes)

```
apiVersion: networking.k8s.io/v1
kind: NetworkPolicy
metadata:
 name: themis-netpol
 namespace: themis-prod
spec:
 podSelector:
 matchLabels:
 app: themis
 policyTypes:
 - Ingress
 - Egress
 ingress:
 - from:
 - podSelector:
 matchLabels:
 app: frontend
 ports:
 - protocol: TCP
 port: 8529
 egress:
 - to:
 - podSelector:
 matchLabels:
 app: redis
 ports:
 - protocol: TCP
 port: 6379
```

---

## 30.8 Performance Tuning

### 30.8.1 Resource Limits

```
resources:
 requests:
 memory: "8Gi"
 cpu: "4000m"
 limits:
 memory: "16Gi"
 cpu: "8000m"

JVM-style tuning for RocksDB
env:
 - name: ROCKSDB_MAX_OPEN_FILES
 value: "10000"
 - name: ROCKSDB_BLOCK_CACHE_SIZE
 value: "4GB"
```

### 30.8.2 Connection Pooling

```
server:
 connection_pool:
 size: 100
 timeout: 30s
 max_idle: 50
```

---

## 30.9 Zusammenfassung

### Deployment-Optionen

1. **Docker:** Einfacher Einstieg, lokale Entwicklung
2. **Kubernetes:** Produktionsreif, auto-scaling, self-healing



### 3. **Cloud:** Managed Services (EKS, AKS, GKE)

#### **Operations-Checkliste**

- Monitoring mit Prometheus & Grafana
- Tägliche Backups mit S3/Glacier
- TLS/SSL für alle Verbindungen
- Network Policies für Pod-Isolation
- Resource Limits für Stabilität
- Alerting für kritische Metriken
- Disaster Recovery Plan dokumentiert

## **30.8 Advanced Deployment Patterns**

### **30.8.1 Blue-Green Deployments**

```
Strategy: Run two complete ThemisDB environments
Route traffic via load balancer
apiVersion: v1
kind: Service
metadata:
 name: themis-service
spec:
 selector:
 app: themis
 version: blue # Initially point to blue
 ports:
 - port: 8529
 targetPort: 8529
 type: LoadBalancer

Blue: Current production
apiVersion: v1
kind: ConfigMap
metadata:
 name: themis-blue-config
data:
 version: "blue"
 database:
 replication_role: "primary"

Green: New version (idle)
apiVersion: v1
kind: ConfigMap
metadata:
 name: themis-green-config
data:
 version: "green"
 database:
 replication_role: "primary"
```

**Deployment Steps:** 1. Deploy Green with new version (idle) 2. Run smoke tests against Green 3. Sync data: Primary → Green (catchup) 4. Switch load balancer: Service selector → green 5. Blue becomes backup/rollback

### 30.8.2 Canary Deployments

```
Route % of traffic to new version
Gradually increase as stability confirmed

apiVersion: networking.istio.io/v1beta1
kind: VirtualService
metadata:
 name: themis-canary
spec:
 hosts:
 - themis.internal
 http:
 - match:
 - uri:
 prefix: "/"
 route:
 - destination:
 host: themis-stable
 port:
 number: 8529
 weight: 95 # 95% to stable
 - destination:
 host: themis-canary
 port:
 number: 8529
 weight: 5 # 5% to canary (new version)
 timeout: 10s
 retries:
 attempts: 3
 perTryTimeout: 5s
```

**Canary Rollout Timeline:** - Hour 0-1: 5% traffic → Monitor error rates, latency - Hour 1-4: 25% traffic → Check P99 latency - Hour 4-8: 50% traffic → Full test with real workload - Hour 8+: 100% traffic → Full rollout

### 30.8.3 GitOps Continuous Deployment

```
Use ArgoCD to sync Kubernetes manifests from Git
apiVersion: argoproj.io/v1alpha1
kind: Application
metadata:
 name: themis-gitops
spec:
 project: default
 source:
 repoURL: https://github.com/org/themis-deployment.git
 targetRevision: main
 path: k8s/production
 destination:
 server: https://kubernetes.default.svc
 namespace: themis
 syncPolicy:
 automated:
 prune: true
 selfHeal: true
 syncOptions:
 - CreateNamespace=true
Only deploy if tests pass in CI
notification:
 when:
 onSuccess: notify-slack
 onFailure: notify-pagerduty
```

### 30.8.4 Staged Rollout Checklist

#### Pre-Deployment

- ✓ Run all integration tests
- ✓ Performance benchmarks (P99 latency < 10% increase)
- ✓ Memory/CPU profiling
- ✓ Backup created & tested

#### Deployment

- ✓ Dry-run: `'kubectl apply --dry-run=client -f manifest.yaml'`
- ✓ Deploy to staging first
- ✓ Smoke tests pass
- ✓ Metrics baseline: CPU, Memory, QPS, Latency
- ✓ Error rate < 0.1%

#### Monitoring (First Hour)

- ✓ P99 latency stable
- ✓ No error spikes
- ✓ No memory leaks
- ✓ Replication lag < 500ms

#### Post-Deployment

- ✓ Keep blue environment for 24h (rollback ready)
- ✓ Archive logs for audit
- ✓ Document any issues/hotfixes
- ✓ Send deployment notification

## 30.9 Disaster Recovery & Business Continuity

### 30.9.1 RTO/RPO Strategy

RTO (Recovery Time Objective) = Max downtime acceptable  
RPO (Recovery Point Objective) = Max data loss acceptable

ThemisDB Recommendations:

Tier	RTO	RPO	Cost	Effort
Bronze	24h	24h	\$	Low
Silver	4h	1h	\$\$	Med
Gold	1h	5min	\$\$\$	High
Platinum	15min	0min(RPO)	\$\$\$\$	Critical

Platinum = Multi-region sync (4 data centers, quorum write)

## 30.9.2 Disaster Recovery Plan

```
Automated DR Workflow
Kind: DisasterRecoveryPlan
metadata:
 name: themis-dr-plan
spec:
 backup:
 primary_daily: /backups/daily/themis-*.tar.gz
 archive_weekly: s3://backups/weekly/
 retention_years: 3

 failover_sequence:
 - detect_failure: "Primary health check fails 3x"
 - promote_secondary: "Promote Secondary to Primary"
 - validate_data: "Count docs, verify checksums"
 - test_write: "Insert test document"
 - notify_team: "PagerDuty alert + Slack message"
 - client_failover: "Update DNS CNAME"
 - monitor_2h: "Watch metrics for 2 hours"

 recovery_from_backup:
 - stop_database: "systemctl stop themis"
 - restore_volume: "Restore from snapshot"
 - verify_integrity: "themisdb recover --verify"
 - start_database: "systemctl start themis"
 - catchup_replicas: "Wait for lag < 1s"
```



### 30.9.3 Backup Verification Script

```
#!/bin/bash
Daily backup integrity check

BACKUP_DIR="/backups/daily"
VERIFY_TIMEOUT=3600

for backup in $BACKUP_DIR/themis-*.tar.gz; do
 echo "Verifying $backup..."

 # Extract to temp, verify database
 TEMP_DIR=$(mktemp -d)
 tar -xzf "$backup" -C "$TEMP_DIR"

 # Run recovery to check integrity
 timeout $VERIFY_TIMEOUT themisdb recover --verify "$TEMP_DIR" && \
 echo "✓ $backup: OK" || \
 echo "✗ $backup: CORRUPT - Investigate!"

 # Try restoring to test instance
 docker run --rm -v "$TEMP_DIR:/data" themis:test \
 themisdb check-data /data && \
 echo "✓ Data schema valid" || \
 echo "✗ Schema check failed"

 rm -rf "$TEMP_DIR"
done

echo "Backup verification complete"
```

## 30.10 Cost Optimization

### 30.10.1 Resource Right-Sizing

```
Development (small)
requests:
 memory: "1Gi"
 cpu: "500m"
limits:
 memory: "2Gi"
 cpu: "1000m"
storage: "50Gi"

Staging (medium)
requests:
 memory: "8Gi"
 cpu: "4"
limits:
 memory: "16Gi"
 cpu: "8"
storage: "500Gi"

Production (large)
requests:
 memory: "32Gi"
 cpu: "16"
limits:
 memory: "64Gi"
 cpu: "32"
storage: "2Ti"

Cost Savings
- Use spot instances for stateless pods: 70% savings
- Right-size replicas: scale down off-peak hours
- Archive old data to cold storage (S3 Glacier)
- Estimated monthly savings: 40-60% via optimization
```

## 30.10.2 Storage Cost Reduction

Strategy: Tiered Storage (Hot → Warm → Cold)

Hot (SSD, expensive)

- └ Active data < 30 days
- └ Real-time queries
- └ RTO requirement: <1h

Warm (HDD, medium)

- └ Data 30-90 days old
- └ Monthly analytics reports
- └ RTO requirement: <24h

Cold (Cloud Archive, cheap)

- └ Compliance archives (2+ years)
- └ Quarterly audits only
- └ RTO requirement: 1-7 days

Cost/GB/Month: SSD (\$0.10) → HDD (\$0.05) → Archive (\$0.004)

Example: 10TB dataset

SSD: \$1,024/month

Mixed (70% warm, 30% cold): \$216/month

Savings: 79%

## 30.11 Compliance & Audit

### 30.11.1 Audit Logging for Compliance

```
Immutable audit log (Write-Once-Read-Many)
kind: ThemisDB
metadata:
 name: themis-production
spec:
 audit:
 enabled: true
 destination: s3://audit-logs/ # External WORM storage
 events:
 - user_login
 - data_access
 - schema_change
 - admin_action
 - privilege_grant
 - backup_restore

 compliance:
 frameworks:
 - SOC2
 - ISO27001
 - GDPR
 - HIPAA (if healthcare)

 data_retention:
 audit_logs: "7 years"
 application_logs: "90 days"
 metrics: "1 year"
```

### 30.11.2 Compliance Checklist

#### Security

- ✓ TLS 1.3 for all connections
- ✓ Network policies (allow only required)
- ✓ RBAC with MFA for admin access
- ✓ Secrets in Vault/K8s Secrets
- ✓ Encryption at rest (AES-256)
- ✓ Encryption in transit (TLS)

#### Data Protection

- ✓ PII detection & masking
- ✓ Data classification (PUBLIC/INTERNAL/CONFIDENTIAL)
- ✓ GDPR right-to-deletion implemented
- ✓ Backup encryption with managed keys
- ✓ No cleartext passwords in logs

#### Operations

- ✓ Change control (code review before deploy)
- ✓ Incident response playbooks
- ✓ Disaster recovery tested (quarterly)
- ✓ Security scanning (SBOM, vulnerability scanning)
- ✓ Penetration testing (annual)

#### Monitoring

- ✓ Access logs (all queries logged)
- ✓ Admin action audit trail
- ✓ Security event alerting
- ✓ SLA monitoring (uptime SLA > 99.9%)

## 30.12 Operations Runbooks

### 30.12.1 Scaling Checklist (Horizontal)

#### Add Node to Cluster

1. Provision new node (VM/Bare Metal)
2. Install ThemisDB + dependencies
3. Configure as follower initially
4. Join cluster: `themisdb cluster join --primary <primary-ip>`
5. Wait for replication lag < 100ms
6. Promote to voting member: `themisdb cluster promote --member-id <id>`
7. Verify: `themisdb cluster status` (should show HEALTHY)
8. Monitor CPU/Memory/IO for 24h

#### Remove Node from Cluster

1. Drain connections: `themisdb admin drain-connections`
2. Wait for active queries to finish (30s timeout)
3. Demote member: `themisdb cluster demote --member-id <id>`
4. Remove from cluster: `themisdb cluster remove --member-id <id>`
5. Verify: `themisdb cluster status` (node should be REMOVED)
6. Decommission VM

### 30.12.2 Incident Response (Example: High Memory Usage)

#### Symptoms

- Memory usage > 85%
- OOM killer started (dmesg shows)
- Queries failing with "Out of memory"

#### Investigation (2 min)

```
curl http://localhost:8529/_admin/memory | jq .
Check: Cache size, Buffer pool, Active cursors
```

#### Fix (5 min)

##### Option A: Restart (emergency)

```
systemctl restart themis
→ Memory drops to baseline
```

##### Option B: Increase memory (planned)

```
Edit themis.conf: cache.size_mb = 16384
systemctl reload themis
```

##### Option C: Identify leak (analysis)

```
themisdb profile --duration 60s | grep alloc
→ Find problematic query/operation
```

#### Verify

```
curl http://localhost:8529/_admin/memory | jq .usage_pct
Should be < 80%
```

---

## 30.13 Zusammenfassung: Operations Checkliste

### Tägliche Aufgaben

- [ ] Backup erfolgreich (log check)
- [ ] Replication lag < 500ms
- [ ] Disk usage < 80%

- ☐ No error logs above WARN
- ☐ Metrics collected (Prometheus)

## Wöchentliche Aufgaben

- ☐ Backup test restoration (pick random)
- ☐ Security scan (OWASP top 10)
- ☐ Performance baseline check
- ☐ Review failed queries (slow log)
- ☐ Capacity planning review

## Monatliche Aufgaben

- ☐ Disaster recovery drill
- ☐ Penetration testing (if required)
- ☐ Security policy review
- ☐ Cost optimization (right-size resources)
- ☐ Upgrade path planning

## Quarterly

- ☐ Full disaster recovery test (restore from backup)
- ☐ Security audit
- ☐ Compliance verification
- ☐ Training for new operators

---

Kapitel 30 von 30 | Teil XI: Operations | ~10.000 Wörter (+2000 neu)

# Kapitel 31: Kapitel 31 - API Protokolle

---

*"Protokolle sind das Rückgrat verteilter Systeme."*



## 31.1 Überblick

Dieses Kapitel behandelt die Protokoll-Features von ThemisDB: moderne HTTP/2/HTTP/3-Stacks, WebSockets für Echtzeit, Server-Sent Events (SSE) für Streams sowie MCP (Model Context Protocol) für LLM-Integrationen.

**Was Sie lernen:** - Wann HTTP/2/3 gegenüber HTTP/1.1 Vorteile bringt - Server Push, Header-Kompression, Multiplexing - QUIC-Tuning und Paketverlustverhalten - WebSocket/SSE-Patterns für Changefeed & CDC - MCP-Anbindung als Tooling-Schnittstelle

## 31.2 HTTP/2 Features

### 31.2.1 Multiplexing & Header-Kompression

Abb. 31.1: API-Protocol-Stack

**Vorteile:** - Keine Head-of-Line-Blocking auf Applikationsebene - HPACK reduziert Header-Overhead (Auth, Tenant-ID) - Bessere Ausnutzung einzelner TCP-Verbindung

### 31.2.2 Server Push (selektiv)

```
:method: GET
:path: /dashboard
:authority: api.themis.local
```

Server antwortet mit gepushten Ressourcen (nur wenn vom Client erlaubt): - `/static/dashboard.css`  
- `/static/dashboard.js` - `/static/logo.svg`

**Best Practice:** Für APIs selten nötig; für Admin-UI/Cockpit kann Push Latenzen senken. Aktivieren Sie Push nur für statische Assets.

### 31.2.3 Stream Priorities

- AQL-Long-Running Queries → niedrige Priorität
- Health/Readiness → hohe Priorität
- Metrics → mittlere Priorität

## 31.3 HTTP/3 (QUIC)

### 31.3.1 QUIC vs TCP

Merkmal	TCP/TLS	QUIC
Verbindungsaufbau	1-2 RTT	0-1 RTT (0-RTT Resumption)
Head-of-Line	End-to-End	Per-Stream
Congestion Control	Reno/Cubic	BBR, Hybrid
Mobility	Neuaufbau nötig	Connection IDs erlauben Migration

### 31.3.2 QUIC-Tuning

- **Initial Congestion Window:** 10-20 MSS für schnellere Warmups
- **BBR aktivieren:** Für WAN/hohe Bandbreite
- **Handshake-Keys cachen:** 0-RTT für interne Service-zu-Service Calls
- **Pacing:** Aktivieren, um Burst-Loss zu vermeiden

### 31.3.3 Fallback-Strategie

Abb. 31.2: Request-Response-Flow

## 31.4 Echtzeit: WebSocket vs SSE

### 31.4.1 Wann welches Protokoll?

Bedarf	WebSocket	SSE
Bidirektional		×
Firewalls/Proxies	Kann blockiert sein	Fast immer offen (HTTP)
Browser Support	Breit	Sehr breit
Backpressure	Muss implementiert werden	Implizit durch HTTP
Binärdaten		× (Text-only)

### 31.4.2 Changefeed mit SSE (empfohlen)

```
GET /_api/changefeed?collection=orders&since=1735600000000
Accept: text/event-stream
Authorization: Bearer <token>
```

Server streamt Events:

```
event: insert
data: {"_key":"o123","status":"paid"}

retry: 3000
```

**Vorteile SSE:** Einfach, kompatibel, automatisches Reconnect über `retry`.

### 31.4.3 WebSocket für bidirektionale Commands

```
const ws = new WebSocket('wss://api.themis.local/_ws');
ws.onmessage = (ev) => console.log('event', ev.data);
ws.send(JSON.stringify({
 type: 'subscribe',
 topic: 'orders',
 filter: "status == 'paid'"
}));
```

**Best Practice:** - Heartbeat ( `ping/pong` ) alle 30s - Message Envelope mit `type` , `payload` , `seq` - Auth im Query-Parameter oder Header; Tokens regelmäßig erneuern

---

## 31.5 HTTP/2/3 Security

- **mTLS** zwischen Services (Client Cert + SAN auf Tenant/Env)
  - **ALPN** erzwingen ( `h2` , `h3` ), HTTP/1.1 nur als Fallback
  - **Rate Limits pro Tenant** (Header: `x-tenant-id` )
  - **Content-Security-Policy** für Admin-UI
  - **CORS** restriktiv konfigurieren
- 

## 31.6 MCP (Model Context Protocol)

MCP ermöglicht LLM-Tools direkten Zugriff auf ThemisDB-Ressourcen.

### 31.6.1 Minimaler MCP-Server (Python)

```
from mcp import Server
import themis

server = Server(name="themis-mcp")
db = themis.connect()

@server.tool("query")
async def query(aql: str):
 return db.aql(aql)

@server.tool("vector-search")
async def search(text: str, k: int = 5):
 return db.knn("docs", db.embed(text), k)
```

### 31.6.2 Toolsicherheit

- **Schema-Whitelist:** Nur bestimmte Collections/Views freigeben
- **Rate Limits:** Pro Tool und pro User-ID
- **Audit:** Jeder Tool-Call in Audit-Log
- **Prompt Guards:** Keine DDL/DCL zulassen

### 31.6.3 Response-Formate

- JSON als Default
- Streams für große Resultsets
- Trunkierung + `next_cursor` für Paginierung

---

## 31.7 Observability

- **h2/h3 Metrics:**
  - `themis_http2_active_streams`
  - `themis_http3_handshakes_total`
  - `themis_http3_loss_rate`

- **WebSocket Metrics:** Connected Clients, Msg/sec, Drop-Reasons
  - **SSE Metrics:** Open Streams, Retry Rate
- 

## 31.8 Performance-Optimierungen

### 31.8.1 HTTP/2 Connection Tuning

```
themis-config.yaml
http2:
 max_concurrent_streams: 250
 initial_window_size: 65535
 max_frame_size: 16384
 max_header_list_size: 8192

Connection Pooling
connection_pool:
 max_idle_connections: 100
 idle_timeout: 300s
 keepalive_interval: 30s
```

**Performance-Tipps:** - **Window Size:** Erhöhen für High-Throughput (>1 Gbps) - **Max Streams:** 250 für typische Workloads, 1000+ für Heavy API-Traffic - **Frame Size:** 16 KB optimal für meiste Szenarien

### 31.8.2 HTTP/3 QUIC-Tuning

```
// Go: QUIC Configuration
quicConfig := &quic.Config{
 MaxIdleTimeout: 30 * time.Second,
 MaxIncomingStreams: 250,
 MaxIncomingUniStreams: 250,

 // Loss Detection
 MaxReceiveStreamFlowControlWindow: 6 * (1 << 20), // 6 MB
 MaxReceiveConnectionFlowControlWindow: 15 * (1 << 20), // 15 MB

 // Congestion Control
 InitialPacketSize: 1200, // Standard MTU - 28 bytes
 DisablePathMTUDiscovery: false,
}
```

**QUIC-Vorteile bei hoher Latenz:** - **0-RTT Connection Resume:** Schnellerer Reconnect - **Paketverlust-Resilienz:** Unabhängige Streams, kein Head-of-Line Blocking - **Connection Migration:** IP-Wechsel transparent (Mobile Clients)

### 31.8.3 Benchmarks: HTTP/1.1 vs HTTP/2 vs HTTP/3

```
benchmark_protocols.py
import aiohttp
import asyncio
import time

async def benchmark_protocol(url, num_requests=1000):
 """Benchmark verschiedene Protokolle"""

 connector = aiohttp.TCPConnector(limit=100)
 timeout = aiohttp.ClientTimeout(total=60)

 async with aiohttp.ClientSession(connector=connector, timeout=timeout) as session:
 start = time.time()

 tasks = []
 for i in range(num_requests):
 task = session.get(f"{url}/_api/version")
 tasks.append(task)

 responses = await asyncio.gather(*tasks, return_exceptions=True)

 elapsed = time.time() - start
 success = sum(1 for r in responses if not isinstance(r, Exception))

 return {
 'total_time': elapsed,
 'requests_per_sec': num_requests / elapsed,
 'success_rate': success / num_requests * 100,
 'avg_latency_ms': (elapsed / num_requests) * 1000
 }

Results (Beispiel):
HTTP/1.1: 850 req/s, 1.18 ms avg
HTTP/2: 2100 req/s, 0.48 ms avg (2.5x schneller)
HTTP/3: 2400 req/s, 0.42 ms avg (2.8x schneller)
```



## 31.9 Advanced WebSocket Patterns

### 31.9.1 Multiplexed Subscriptions

```
// Client: Mehrere Subscriptions über eine WebSocket-Connection
const ws = new WebSocket('wss://themis.local/_api/realtime');

ws.onopen = () => {
 // Subscribe zu mehreren Collections gleichzeitig
 ws.send(JSON.stringify({
 type: 'subscribe',
 subscriptions: [
 {id: 'sub-1', collection: 'orders', filter: {status: 'pending'}},
 {id: 'sub-2', collection: 'inventory', filter: {stock: {$lt: 10}}},
 {id: 'sub-3', collection: 'logs', filter: {level: 'error'}}
]
 }));
};

ws.onmessage = (event) => {
 const msg = JSON.parse(event.data);

 switch(msg.subscription_id) {
 case 'sub-1':
 console.log('New order:', msg.data);
 break;
 case 'sub-2':
 console.log('Low stock alert:', msg.data);
 break;
 case 'sub-3':
 console.log('Error log:', msg.data);
 break;
 }
};
```

### 31.9.2 Backpressure Handling

```
Server-side: Backpressure bei langsamen Clients
class ChangeStreamHandler:
 def __init__(self, websocket, buffer_size=1000):
 self.ws = websocket
 self.buffer = asyncio.Queue(maxsize=buffer_size)
 self.dropped_messages = 0

 async def handle_change(self, change_event):
 """Change Event vom DB-Changefeed"""
 try:
 # Non-blocking Queue Put
 self.buffer.put_nowait(change_event)
 except asyncio.QueueFull:
 # Langsamer Client → Drop Message
 self.dropped_messages += 1

 if self.dropped_messages % 100 == 0:
 # Warning nach jeweils 100 Drops
 await self.ws.send(json.dumps({
 'type': 'backpressure_warning',
 'dropped_messages': self.dropped_messages
 }))

 async def send_loop(self):
 """Kontinuierlich Messages aus Queue senden"""
 while True:
 change = await self.buffer.get()
 await self.ws.send(json.dumps(change))
```

### **31.9.3 Auto-Reconnect mit Exponential Backoff**

```
// TypeScript: Resilient WebSocket Client
class ResilientWebSocket {
 private ws: WebSocket | null = null;
 private reconnectAttempts = 0;
 private maxReconnectDelay = 30000; // 30s

 connect(url: string) {
 this.ws = new WebSocket(url);

 this.ws.onopen = () => {
 console.log('Connected');
 this.reconnectAttempts = 0; // Reset
 };

 this.ws.onclose = (event) => {
 if (event.code !== 1000) { // 1000 = Normal Closure
 this.scheduleReconnect(url);
 }
 };

 this.ws.onerror = (error) => {
 console.error('WebSocket error:', error);
 };
 }

 private scheduleReconnect(url: string) {
 this.reconnectAttempts++;

 // Exponential Backoff: 1s, 2s, 4s, 8s, 16s, 30s (max)
 const delay = Math.min(
 1000 * Math.pow(2, this.reconnectAttempts - 1),
 this.maxReconnectDelay
);

 console.log(`Reconnecting in ${delay}ms (attempt ${this.reconnectAttempts})`);

 setTimeout(() => {
 this.connect(url);
 }, delay);
 }
}
```

```
 }, delay);
 }

 send(data: string) {
 if (this.ws?.readyState === WebSocket.OPEN) {
 this.ws.send(data);
 } else {
 console.warn('WebSocket not ready, message dropped');
 }
 }
}
```

## **31.10 MCP Advanced Patterns**

### **31.10.1 Multi-Tenant MCP Server**

```
mcp_server.py: Tenant-Isolation
from mcp import Server, Context
import themis

server = Server(name="themis-mcp-multi-tenant")

@server.tool("query", requires_auth=True)
async def query_with_tenant(ctx: Context, aql: str):
 """Query mit automatischer Tenant-Isolation"""

 tenant_id = ctx.user.tenant_id # Aus Auth-Token

 # Datenbankverbindung für spezifischen Tenant
 db = themis.connect(tenant=tenant_id)

 # Validierung: Kein DDL/DCL
 if any(keyword in aql.upper() for keyword in ['DROP', 'CREATE', 'ALTER', 'GRANT']):
 raise PermissionError("DDL/DCL queries not allowed")

 # Audit-Log
 await log_audit_event(
 tenant_id=tenant_id,
 user_id=ctx.user.id,
 action='mcp_query',
 query=aql
)

 # Query ausführen
 result = await db.query(aql)

 # Trunkierung bei großen Results
 if len(result) > 100:
 return {
 'results': result[:100],
 'truncated': True,
 'total_count': len(result),
 'message': 'Results truncated to 100 items'
 }
 }
```

```
return {'results': result, 'truncated': False}
```



**31.10.2 MCP Tool Discovery**

```
@server.list_tools()
async def available_tools(ctx: Context):
 """Dynamische Tool-Liste basierend auf User-Permissions"""

 tools = []
 permissions = await get_user_permissions(ctx.user.id)

 if 'query' in permissions:
 tools.append({
 'name': 'query',
 'description': 'Execute AQL query (SELECT only)',
 'parameters': {
 'aql': {'type': 'string', 'required': True}
 }
 })

 if 'vector-search' in permissions:
 tools.append({
 'name': 'vector-search',
 'description': 'Semantic search over documents',
 'parameters': {
 'text': {'type': 'string', 'required': True},
 'k': {'type': 'integer', 'default': 5}
 }
 })

 if 'analytics' in permissions:
 tools.append({
 'name': 'aggregate',
 'description': 'Run pre-defined analytics queries',
 'parameters': {
 'report_type': {
 'type': 'enum',
 'values': ['daily-sales', 'user-stats', 'inventory']
 }
 }
 })
```

return tools

### 31.10.3 MCP Rate Limiting

```
from collections import defaultdict
import time

class MCPRateLimiter:
 def __init__(self, max_calls_per_minute=60):
 self.max_calls = max_calls_per_minute
 self.calls = defaultdict(list) # user_id -> [timestamps]

 def check_limit(self, user_id: str) -> bool:
 """Prüfe ob User unter Rate Limit ist"""
 now = time.time()
 minute_ago = now - 60

 # Cleanup alte Einträge
 self.calls[user_id] = [
 ts for ts in self.calls[user_id] if ts > minute_ago
]

 # Check Limit
 if len(self.calls[user_id]) >= self.max_calls:
 return False

 # Record Call
 self.calls[user_id].append(now)
 return True

limiter = MCPRateLimiter(max_calls_per_minute=100)

@server.before_tool_call
async def rate_limit_check(ctx: Context):
 """Vor jedem Tool-Call: Rate Limit prüfen"""
 if not limiter.check_limit(ctx.user.id):
 raise RateLimitExceeded(
 f"Rate limit exceeded: max {limiter.max_calls} calls/minute"
)
```

---

## 31.11 Production Checklist

### HTTP/2/3 Deployment

- TLS 1.3 aktiviert (Voraussetzung für HTTP/3)
- ALPN konfiguriert ( `h2`, `h3` )
- Firewall: UDP Port 443 für QUIC
- Load Balancer unterstützt HTTP/2 Backend-Connections
- Monitoring: `http2_streams_active`, `http3_handshakes`

### WebSocket/SSE

- Connection Timeout: 5-10 Minuten Idle
- Ping/Pong für Keepalive (30s Intervall)
- Backpressure Handling implementiert
- Auto-Reconnect Client-seitig
- Max Concurrent Connections pro Server: 10k+

### MCP Security

- Authentication: OAuth2/JWT
- Tool-Whitelist pro User-Rolle
- Rate Limiting: 100 calls/min
- Audit-Logging: Jeder Tool-Call
- Query-Validation: Kein DDL/DCL
- Result Truncation: Max 1000 Results

## 31.8 Advanced Protocol Scenarios

### 31.8.1 Connection Pooling & Load Balancing

```
Connection Pool with adaptive routing
class ThemisClientPool:
 def __init__(self, primary_url, replica_urls, pool_size=20):
 self.primary_pool = HTTPConnectionPool(primary_url, maxsize=pool_size)
 self.replica_pools = [
 HTTPConnectionPool(url, maxsize=pool_size//len(replica_urls))
 for url in replica_urls
]

 def query(self, aql, bind_vars=None, consistency='eventual'):
 if consistency == 'strong':
 # Route to primary for strong consistency
 pool = self.primary_pool
 else:
 # Route to replicas (round-robin)
 pool = self.next_replica()

 # Connection reused from pool
 return pool.request('POST', '/_api/query',
 json={'query': aql, 'bindVars': bind_vars})

 def next_replica(self):
 self.replica_index = (self.replica_index + 1) % len(self.replica_pools)
 return self.replica_pools[self.replica_index]
```

**Benefits:** - Connection reuse (HTTP keep-alive) - Automatic failover if replica unhealthy - Load distribution across replicas - Circuit breaker on connection timeouts

### 31.8.2 Bidirectional Streaming (gRPC-like)

```
// Imaginary streaming API
service ThemisStreaming {
 rpc StreamQuery(stream QueryRequest) returns (stream QueryResponse);
}

// Client sends multiple queries in one stream
// Server sends results as they complete
// Lower latency than request-response cycle
```

#### Implementation with WebSockets:

```
// Client
const ws = new WebSocket('wss://api.themis/stream');

ws.onopen = () => {
 // Send batch of queries
 ws.send(JSON.stringify({
 queries: [
 { id: 1, aql: 'FOR u IN users...' },
 { id: 2, aql: 'FOR o IN orders...' },
 { id: 3, aql: 'FOR p IN products...' }
]
 }));
};

ws.onmessage = (event) => {
 const result = JSON.parse(event.data);
 console.log(`Query ${result.query_id} completed:`, result.data);
};
```

### 31.8.3 Graceful Degradation (Protocol Negotiation)

Client tries protocols in order:

1. HTTP/3 (QUIC) ← Fastest if no packet loss
2. HTTP/2 ← Fallback for UDP issues
3. HTTP/1.1 ← Last resort

#### Configuration:

```
themis.conf
server:
 protocols:
 - h3 # HTTP/3
 - h2 # HTTP/2
 - http/1.1 # HTTP/1.1

ALPN (Application Layer Protocol Negotiation)
alpn_protocols: ['h3', 'h2', 'http/1.1']
```

---

## 31.9 Performance Tuning by Protocol

### 31.9.1 HTTP/2 Tuning

```
server:
 http2:
 # Number of concurrent streams per connection
 max_concurrent_streams: 128 # Default: 100

 # Header size limit
 max_header_list_size: 32768 # 32KB

 # Server push (usually disabled for better caching)
 enable_server_push: false
```



**Performance Impact:** - Increase max\_concurrent\_streams for high concurrency - Monitor header\_compression\_ratio to detect inefficiency - Use single TCP connection vs multiple (less is better)

### 31.9.2 QUIC/HTTP/3 Tuning

QUIC handshake optimization:

- 0-RTT (Zero Round Trip): Resume previous connection
- TLS 1.3: Faster handshake than HTTP/2 + TLS 1.2
- Connection Migration: Survive network switch (WiFi → 4G)

#### Typical Handshake Times:

HTTP/1.1 + TLS 1.2:	3x RTT	(150-200ms on 50ms RTT)
HTTP/2 + TLS 1.3:	1x RTT	(~50ms)
HTTP/3 + 0-RTT:	0x RTT	(~0ms on reconnect!)

---

## 31.9A PostgreSQL Wire Protocol Enhancements (v1.4.0-alpha)

### 31.9A.1 Erweiterte Message-Typen

**Neu in v1.4.0-alpha:** Unterstützung für erweiterte PostgreSQL-Protokoll-Features für verbesserte Kompatibilität und Performance.

#### **COPY-Protokoll für Bulk-Operations:**

Das COPY-Protokoll ermöglicht hochperformante Bulk-Inserts und -Exports direkt über das Wire Protocol.

```
-- COPY FROM (Bulk Insert)
COPY users(id, name, email, created_at) FROM STDIN WITH (FORMAT CSV);
1,Alice,alice@example.com,2026-01-06
2,Bob,bob@example.com,2026-01-06
3,Charlie,charlie@example.com,2026-01-06
\.

-- COPY TO (Bulk Export)
COPY (SELECT * FROM users WHERE created_at > '2026-01-01')
TO STDOUT WITH (FORMAT BINARY);
```

**Python-Client-Beispiel:**

```
import psycopg2
from io import StringIO

conn = psycopg2.connect(
 host='localhost',
 port=5432,
 dbname='themisdb',
 user='admin'
)

Bulk Insert via COPY
cursor = conn.cursor()
data = StringIO("""1,Alice,alice@example.com,2026-01-06
2,Bob,bob@example.com,2026-01-06
3,Charlie,charlie@example.com,2026-01-06""")

cursor.copy_from(
 data,
 'users',
 columns=('id', 'name', 'email', 'created_at'),
 sep=', '
)
conn.commit()

Bulk Export via COPY
output = StringIO()
cursor.copy_to(
 output,
 'users',
 sep=', ',
 columns=('id', 'name', 'email')
)
print(output.getvalue())
```

**Performance-Charakteristiken:**

Method	Throughput	Latenz	Use Case
<b>INSERT (single)</b>	5K rows/s	0.2ms/row	Transaktional
<b>INSERT (batch)</b>	45K rows/s	0.02ms/row	Batch
<b>COPY</b>	250K rows/s	0.004ms/row	Bulk Import

### **LISTEN/NOTIFY für Change Notifications:**

Echtzeit-Benachrichtigungen über Datenänderungen ohne Polling.

```
-- Session 1: Listener
LISTEN user_changes;

-- Warten auf Notifications (blocking)
-- Client erhält Notification wenn Event auftritt

-- Session 2: Publisher
INSERT INTO users (name, email) VALUES ('Dave', 'dave@example.com');
NOTIFY user_changes, 'new_user:dave';

-- Session 1 erhält: Notification auf Kanal 'user_changes' mit Payload 'new_user:dave'
```

### **Python-Client mit LISTEN/NOTIFY:**

```
import psycopg2
import select

Listener Connection
conn = psycopg2.connect(...)
conn.set_isolation_level(psycopg2.extensions.ISOLATION_LEVEL_AUTOCOMMIT)
cursor = conn.cursor()

Subscribe zu Channel
cursor.execute("LISTEN user_changes")

print("Waiting for notifications...")
while True:
 # Wait for notification (with timeout)
 if select.select([conn], [], [], 5) == ([], [], []):
 print("Timeout")
 else:
 conn.poll()
 while conn.notifies:
 notify = conn.notifies.pop(0)
 print(f"Channel: {notify.channel}, Payload: {notify.payload}")

 # Process notification
 if notify.payload.startswith('new_user:'):
 username = notify.payload.split(':')[1]
 print(f"New user registered: {username}")
```

**Use Cases:** - Real-time Dashboards (statt Polling) - Event-Driven Architectures - Change Data Capture (CDC) - Notification-Systeme

### Extended Query Protocol Optimierungen:

Das Extended Query Protocol unterstützt Prepared Statements und Parameter-Binding für bessere Performance und Sicherheit.

```
Prepared Statement mit Parameter-Binding
cursor = conn.cursor()

Prepare (einmalig)
cursor.execute("""
 PREPARE get_user_orders AS
 SELECT * FROM orders
 WHERE user_id = $1 AND created_at > $2
""")

Execute (mehrfach mit verschiedenen Parametern)
cursor.execute("EXECUTE get_user_orders(%s, %s)", (123, '2026-01-01'))
results = cursor.fetchall()

cursor.execute("EXECUTE get_user_orders(%s, %s)", (456, '2025-12-01'))
results = cursor.fetchall()
```

**Vorteile:** - SQL Injection Prevention (automatisches Escaping) - Query Plan Caching (keine Re-Compilation) - Reduzierter Netzwerk-Overhead (nur Parameter übertragen) - Type-Safety (Parameter-Typen geprüft)

### 31.9A.2 Performance-Verbesserungen

#### Binary Format Support für Vektoren:

Native Binärübertragung von Vektoren für LLM-Embeddings und Vector Search.

```
import struct
import psycopg2
from psycopg2.extras import register_vector

Register Vector Type
register_vector(conn)

Insert Vector (Binary Format)
embedding = [0.1, 0.2, 0.3, ..., 0.768] # 768 dimensions
cursor.execute(
 "INSERT INTO documents (content, embedding) VALUES (%s, %s)",
 ("Sample text", embedding)
)

Query Vector (Binary Format - kein JSON Overhead)
cursor.execute(
 "SELECT id, content, embedding FROM documents WHERE id = %s",
 (123,)
)
row = cursor.fetchone()
vector = row[2] # Direkter Python Array
```

### Performance-Vergleich:

Format	Transfer Size	Parse Time	Use Case
JSON	15.2 KB	450 µs	Kompatibilität
Text	12.8 KB	320 µs	Debugging
Binary	3.1 KB	45 µs	Production

**Einsparung:** 80% weniger Netzwerk-Traffic, 90% schnelleres Parsing

### Pipeline Mode für Batch-Queries:

Sende mehrere Queries ohne auf Antworten zu warten (Request Pipelining).

```
from psycopg2 import sql
from psycopg2.extras import execute_batch

cursor = conn.cursor()

Batch Insert (mit Pipeline)
data = [
 (1, 'Alice', 'alice@example.com'),
 (2, 'Bob', 'bob@example.com'),
 (3, 'Charlie', 'charlie@example.com'),
 # ... 10,000 rows
]

execute_batch(
 cursor,
 "INSERT INTO users (id, name, email) VALUES (%s, %s, %s)",
 data,
 page_size=1000 # Send 1000 rows per batch
)
conn.commit()
```

**Performance:**

Method	Throughput	Latenz	Network RTTs
Sequential	5K rows/s	0.2ms	10,000
Batch (100)	35K rows/s	0.03ms	100
Pipeline (1000)	85K rows/s	0.012ms	10

**Prepared Statement Caching:**

Automatisches Caching von Prepared Statements für häufige Queries.



```
themis.conf - Prepared Statement Cache
postgresql_wire_protocol:
 prepared_statements:
 cache_enabled: true
 max_cached_statements: 1000
 cache_ttl_seconds: 3600
 auto_prepare_threshold: 5 # Auto-prepare nach 5 Executes
```

### Monitoring:

```
-- Cache-Statistiken
SELECT * FROM pg_stat_statements_cache;
```

Output:

statement_id	query	executions	cache_hits	cache_misses
-----+-----	-----+-----	-----+-----	-----+-----	-----+-----
stmt_001	SELECT * FROM users	12450	12445	5
stmt_002	INSERT INTO orders	8420	8415	5

**Performance-Gewinn:** - Cache Hit: 0.05ms (nur Parameter-Binding) - Cache Miss: 2.5ms (Parse + Plan + Execute) - **50x schneller** bei Cache Hit

### 31.9A.3 Neue Datentyp-Mappings

**LLM Embedding Vectors** → **PostgreSQL Vector Type:**

Native Unterstützung für pgvector-kompatible Vektoren.

```
-- Vector Column erstellen
CREATE TABLE documents (
 id SERIAL PRIMARY KEY,
 content TEXT,
 embedding VECTOR(768) -- 768-dimensionaler Vektor
);

-- Vector Index erstellen (HNSW)
CREATE INDEX ON documents USING hnsu (embedding vector_cosine_ops);

-- Vector Search Query
SELECT id, content, embedding <=> '[0.1, 0.2, ...]':vector AS distance
FROM documents
ORDER BY distance
LIMIT 10;
```

**Python-Client mit Vector-Support:**

```
from psycpg2.extras import register_vector

Register Vector Adapter
register_vector(conn)

Insert mit Vektor
embedding = model.encode("Sample text") # numpy array [768]
cursor.execute(
 "INSERT INTO documents (content, embedding) VALUES (%s, %s)",
 ("Sample text", embedding.tolist())
)

Vector Search
query_embedding = model.encode("Search query")
cursor.execute("""
 SELECT id, content, embedding <=> %s AS distance
 FROM documents
 ORDER BY distance
 LIMIT 10
""", (query_embedding.tolist(),))

results = cursor.fetchall()
for row in results:
 print(f"ID: {row[0]}, Distance: {row[2]}")
```

### JSON/JSONB für Document Collections:

Optimierte Unterstützung für JSON-Datentypen kompatibel mit PostgreSQL.

```
-- JSONB Column (binäre JSON-Speicherung)
CREATE TABLE products (
 id SERIAL PRIMARY KEY,
 name TEXT,
 metadata JSONB
);

-- JSONB Index für schnelle Queries
CREATE INDEX ON products USING gin (metadata);

-- JSONB Queries
SELECT * FROM products
WHERE metadata @> '{"category": "electronics"}';

SELECT * FROM products
WHERE metadata->>'brand' = 'Apple';

SELECT * FROM products
WHERE metadata->'specs'->>'ram' = '16GB';
```

**Python-Client mit JSONB:**

```
import json

Insert mit JSONB
metadata = {
 "category": "electronics",
 "brand": "Apple",
 "specs": {"ram": "16GB", "storage": "512GB"}
}

cursor.execute(
 "INSERT INTO products (name, metadata) VALUES (%s, %s)",
 ("MacBook Pro", json.dumps(metadata))
)

Query mit JSONB-Operators
cursor.execute("""
 SELECT name, metadata
 FROM products
 WHERE metadata @> %s
""", (json.dumps({"category": "electronics"}),))

results = cursor.fetchall()
for row in results:
 print(f"Product: {row[0]}, Metadata: {row[1]}")
```

### Temporal Types für Timeseries:

Native Unterstützung für PostgreSQL-Zeittypen (TIMESTAMP, TIMESTAMPTZ, INTERVAL).

```
-- Timeseries Table mit TIMESTAMPTZ
CREATE TABLE metrics (
 id SERIAL PRIMARY KEY,
 metric_name TEXT,
 value DOUBLE PRECISION,
 recorded_at TIMESTAMPTZ DEFAULT NOW()
);

-- Time-Range Queries
SELECT * FROM metrics
WHERE recorded_at BETWEEN '2026-01-01' AND '2026-01-31';

-- Time-Bucketing (Aggregation)
SELECT
 DATE_TRUNC('hour', recorded_at) AS hour,
 AVG(value) AS avg_value
FROM metrics
WHERE metric_name = 'cpu_usage'
GROUP BY hour
ORDER BY hour;

-- INTERVAL Calculations
SELECT * FROM metrics
WHERE recorded_at > NOW() - INTERVAL '7 days';
```

**Python-Client mit Temporal Types:**

```
from datetime import datetime, timedelta, timezone

Insert mit Timezone-aware Timestamp
now = datetime.now(timezone.utc)
cursor.execute(
 "INSERT INTO metrics (metric_name, value, recorded_at) VALUES (%s, %s, %s)",
 ("cpu_usage", 75.5, now)
)

Query mit INTERVAL
cursor.execute("""
 SELECT metric_name, value, recorded_at
 FROM metrics
 WHERE recorded_at > NOW() - INTERVAL '1 hour'
 ORDER BY recorded_at DESC
""")

results = cursor.fetchall()
for row in results:
 print(f"Metric: {row[0]}, Value: {row[1]}, Time: {row[2]}")
```

### 31.9A.4 Client-Library-Kompatibilität

#### Getestete Libraries:

Language	Library	Version	Support	Notes
<b>Python</b>	psycopg2	2.9+	Full	Empfohlen
<b>Python</b>	asyncpg	0.29+	Full	Async Support
<b>Node.js</b>	pg	8.11+	Full	-
<b>Java</b>	PostgreSQL JDBC	42.7+	Full	-
<b>Go</b>	pgx	5.5+	Full	-
<b>Rust</b>	tokio-postgres	0.7+	Full	Async
<b>C#</b>	Npgsql	8.0+	Full	.NET
<b>Ruby</b>	pg	1.5+	Full	-
<b>PHP</b>	pdo_pgsql	8.2+	Full	-

### Kompatibilitäts-Features:



```
Connection mit PostgreSQL-kompatiblen Optionen
conn = psycopg2.connect(
 host='localhost',
 port=5432, # Standard PostgreSQL Port
 dbname='themisdb',
 user='admin',
 password='secret',
 sslmode='require', # SSL Support
 connect_timeout=10,
 application_name='my_app',
 options='-c search_path=public,themis'
)

PostgreSQL-kompatible Introspection
cursor.execute("""
 SELECT table_name, column_name, data_type
 FROM information_schema.columns
 WHERE table_schema = 'public'
""")

PostgreSQL-kompatible System-Kataloge
cursor.execute("SELECT * FROM pg_tables")
cursor.execute("SELECT * FROM pg_indexes")
cursor.execute("SELECT * FROM pg_stat_user_tables")
```

## 31.9A.5 Migration Guide für PostgreSQL-Clients

### Schritt 1: Connection String anpassen

```
Alte PostgreSQL Connection
conn = psycopg2.connect(
 "postgresql://user:pass@postgres.example.com:5432/mydb"
)

Neue ThemisDB Connection (identische Syntax)
conn = psycopg2.connect(
 "postgresql://user:pass@themisdb.example.com:5432/mydb"
)
```

## Schritt 2: Queries überprüfen

Die meisten PostgreSQL-Queries funktionieren unverändert:

```
-- Standard SQL: funktioniert
SELECT * FROM users WHERE age > 25;

-- PostgreSQL-spezifisch: funktioniert
SELECT * FROM users WHERE email ILIKE '%@gmail.com';

-- PostgreSQL JSON: funktioniert
SELECT * FROM products WHERE metadata->>'category' = 'electronics';
```

## Schritt 3: Feature-Nutzung

Neue ThemisDB-Features können optional genutzt werden:

```
Option 1: Bleibe bei Standard PostgreSQL
→ Keine Änderungen nötig

Option 2: Nutze ThemisDB-Features (optional)
cursor.execute("""
 SELECT * FROM documents
 WHERE VECTOR_COSINE_DISTANCE(embedding, %s) < 0.5
""", (query_embedding,))
```

## Schritt 4: Performance-Tuning

```
Aktiviere Binary Format
cursor.execute("SET binary_format = ON")

Aktiviere Prepared Statement Caching
cursor.execute("SET prepared_statement_cache = ON")

Aktiviere Pipeline Mode
cursor.execute("SET pipeline_mode = ON")
```

### 31.9A.6 Performance-Benchmarks

#### pgbench Kompatibilität:

ThemisDB unterstützt den Standard-PostgreSQL-Benchmark `pgbench`.

```
Datenbank initialisieren
pgbench -i -s 100 themisdb

Read-only Benchmark
pgbench -c 50 -j 4 -T 60 -S themisdb

Read-write Benchmark
pgbench -c 50 -j 4 -T 60 themisdb
```

#### Benchmark-Ergebnisse (vs. PostgreSQL 16):

Workload	PostgreSQL 16	ThemisDB	Verbesserung
Simple Select	145K TPS	168K TPS	+16%
Select with Join	82K TPS	95K TPS	+16%
Insert	45K TPS	52K TPS	+16%
Update	38K TPS	44K TPS	+16%
COPY (Bulk)	185K rows/s	250K rows/s	+35%
Vector Search	-	12K QPS	Native

**Latenz-Vergleich (p95):**

Operation	PostgreSQL	ThemisDB	Verbesserung
Simple Query	2.5ms	2.1ms	-16%
Prepared Stmt (cached)	0.8ms	0.05ms	-94%
JSONB Query	5.2ms	4.8ms	-8%
Vector Search	-	3.5ms	Native

## 31.10 Monitoring & Observability

### 31.10.1 Protocol-Level Metrics

Prometheus metrics by protocol:

```
http_requests_total{protocol="h3", method="POST"} # HTTP/3 requests
http_requests_total{protocol="h2", method="GET"} # HTTP/2 requests
http_requests_total{protocol="h1", method="POST"} # HTTP/1.1 requests

http_request_duration_seconds{protocol="h3"} # Latency by protocol

quic_connection_count # Active QUIC connections
quic_handshakes_total # QUIC handshake count
quic_packets_lost_total # Packet loss

websocket_connections_active # Active WebSocket conns
websocket_messages_total{direction="inbound"} # Messages received
websocket_messages_total{direction="outbound"} # Messages sent
```

### 31.10.2 Client-Side Metrics

```
Python client with built-in metrics
import time
from prometheus_client import Counter, Histogram

Define metrics
requests = Counter('themis_requests_total', 'Requests by protocol',
 ['protocol', 'method'])
latencies = Histogram('themis_request_duration_seconds',
 'Request latency', ['protocol'])

Track request
def execute_with_metrics(method, path, protocol='h2'):
 start = time.time()
 try:
 response = execute(method, path, protocol=protocol)
 requests.labels(protocol=protocol, method=method).inc()
 latencies.labels(protocol=protocol).observe(time.time() - start)
 return response
 except Exception as e:
 requests.labels(protocol=protocol, method=method).inc() # Count failures too
 raise
```

## 31.11 Zusammenfassung & Best Practices

### Protocol Selection Decision Tree

```
Need bidirectional communication?
├─ YES → WebSockets
│ └─ Real-time updates (changefeed, dashboards)
├─ NO → HTTP/3 (QUIC)
│ └─ If: Client supports UDP
│ └─ If: High latency network (satellite, 4G)
├─ HTTP/2
│ └─ If: HTTP/3 not available
│ └─ If: High concurrency needed
└─ HTTP/1.1
 └─ Legacy clients only
```

### Protocol-Specific Best Practices

**HTTP/2/3:** - Use single persistent connection - Enable header compression - Avoid domain sharding - Implement request prioritization - Monitor concurrent stream usage

**WebSocket:** - Implement reconnection logic - Send heartbeat/ping every 30-60s - Handle backpressure (don't buffer infinite) - Use sub-protocols for versioning - Limit message size (1-100MB based on use case)

**SSE:** - Keep-alive: 15-30 second intervals - Reconnect backoff: exponential (1s → 30s) - Structure events with IDs (for resume) - Monitor client disconnection rate

**MCP:** - Cache query results per session (5 min TTL) - Whitelist tools per role (security) - Implement query timeout (30s for LLM UX) - Log all tool invocations (audit trail)

# Kapitel 32: Kapitel 32 - AQL OOP Implementierung

---

*"Die Sprache ist das API – ihre Implementierung bestimmt die Fähigkeiten der Datenbank."*

## 32.1 Executive Summary

AQL v1.3.1 erweitert die Sprache um objektorientierte Konstrukte (47 neue Keywords, 360 Funktionen bleiben konstant). Dieses Kapitel beschreibt, wie die Erweiterungen in ThemisDB umgesetzt werden – vom Lexer über den Parser bis zur Ausführungsebene.

**Ziele:** - Lexer/Tokenizer: 47 neue Keywords, Tokens für Klassen/Methoden/Namespace - Parser/AST: Neue Node-Typen für `CLASS`, `FUNCTION`, `METHOD`, `NAMESPACE` - Type-System: Statisches Type-Checking, Inference, generische Typen - Namespace-Resolution: Symbol-Tables, Visibility, Imports - Runtime: Objekt-Instanziierung, Methodenaufrufe, Visibility-Checks - Tests: Parser-Golden-Files, Type-Checker-Property-Tests

## 32.2 Betroffene Codebereiche

Datei	Zweck	Änderung
<code>/src/query/aql_parser.cpp</code>	Lexer/Parser	47 neue Keywords, AST Nodes
<code>/src/query/aql_translator.cpp</code>	AST → Execution Plan	OOP Nodes übersetzen
<code>/include/query/aql_parser.h</code>	Parser-Interface	Neue Strukturen/Enums
<code>/src/query/aql_type_checker.cpp</code>	Type-System	Neue Typregeln, Inference
<code>/src/query/aql_namespace_resolver.cpp</code>	Symbol-Tables	Scopes, Visibility
<code>/src/aql/llm_aql_handler.cpp</code>	LLM-Befehle	Vision/OOP-Kommandos

Neue Dateien: - `/include/query/aql_type_checker.h`, `/src/query/aql_type_checker.cpp` -  
`/include/query/aql_namespace_resolver.h`, `/src/query/aql_namespace_resolver.cpp` -  
`/include/aql/aql_vision_handler.h`, `/src/aql/aql_vision_handler.cpp`

## 32.3 Lexer/Tokenizer (Woche 1-2)

### 32.3.1 TokenType-Erweiterung

- Namespace: `NAMESPACE`, `IMPORT`
- Typen: `STRING_TYPE`, `INT_TYPE`, `FLOAT_TYPE`, `BOOL_TYPE`, `ANY_TYPE`
- Klassen/Funktionen: `FUNCTION`, `CLASS`, `PUBLIC`, `PRIVATE`, `CONSTRUCTOR`, `METHOD`, `NEW`
- Referenzen/Vererbung: `THIS`, `SELF`, `EXTENDS`
- Control Flow: `IF`, `THEN`, `ELSE`, `ELSEIF`, `ENDIF`, `TRY`, `CATCH`, `THROW`, `CASE`, `END`
- Pattern Matching: `MATCH`, `WHEN`

**Lexer-Checks:** - Case-insensitive Keywords - String-Literale unverändert lassen - Fehlerhafte Kombinationen mit präzisen Fehlermeldungen (Zeile/Spalte)



### 32.3.2 Keyword-Detection

```
// Keyword-Detection mit unordered_set (119 Keywords)
bool isKeyword(std::string_view tok) {
 static const std::unordered_set<std::string_view> kw = {
 "FOR", "CLASS", "METHOD", "NAMESPACE", /* ... 115 weitere */
 };
 return kw.contains(tok);
}
```

## 32.4 Parser & AST (Woche 2-4)

### 32.4.1 Neue AST-Nodes

- `AstClassDecl { name, base?, members[] }`
- `AstMethodDecl { name, params[], return_type, visibility, is_static }`
- `AstFunctionDecl { name, params[], return_type }`
- `AstNamespaceDecl { name, imports[], body[] }`
- `AstNewExpr { type_name, args[] }`
- `AstMemberAccess { object, member }`

### 32.4.2 Grammatik (Auszug)

```
translation_unit
 : namespace_decl* class_decl* function_decl* statement*
 ;

class_decl
 : CLASS IDENT (EXTENDS IDENT)? LBRACE class_member* RBRACE
 ;

class_member
 : visibility? (method_decl | property_decl | constructor_decl)
 ;

method_decl
 : METHOD IDENT LPAREN param_list? RPAREN (ARROW type)? block
 ;
```

### 32.4.3 Fehlerbehandlung

- Präzise Fehler: `Unexpected token 'END' at line 42, expected 'WHEN'`
- Recovery: Synchronisation bei `;`, `END`, `}`
- AST-Pragmas für Fehlertoleranz, damit IDE-Features funktionieren

## 32.5 Type-System (Woche 4-6)

### 32.5.1 Typen & Inference

Typ	Beschreibung
<code>Any</code>	Fallback/Unbekannt
<code>String</code> , <code>Int</code> , <code>Float</code> , <code>Bool</code>	Primitive
<code>Class&lt;T&gt;</code>	Klasseninstanzen
<code>Vector&lt;T&gt;</code>	Generische Container
<code>Func&lt;Args, Ret&gt;</code>	Funktions-Typ

**Inference-Regeln:** - Assignment: `lhs = rhs` → `type(lhs) = type(rhs)` - Member Access:

`obj.m` → Lookup in Symbol-Table, Sichtbarkeit prüfen - Calls: `call(f, args)` → Parameteranzahl, Typkompatibilität, Varargs

### 32.5.2 Visibility & Access Control

- `public`: überall sichtbar
- `private`: nur innerhalb derselben Klasse
- `protected` (optional): Klasse + Subklassen

### 32.5.3 Exceptions & TRY/CATCH

- Typ `Exception` als Basisklasse
- `THROW expr` propagiert Typ `Exception`
- `TRY { ... } CATCH (e: Exception) { ... }`

## 32.6 Namespace-Resolution (Woche 6-7)

### 32.6.1 Symbol-Tables

- Hierarchische Tabellen pro Scope

- Eintrag: `{name, kind (var|func|class|namespace), type, visibility}`
- Shadowing nach Java/C#-Modell (innere Scopes haben Vorrang)

### 32.6.2 Imports

```

NAMESPACE themis.app
IMPORT themis.llm.*
IMPORT themis.vision.embed

```

- Wildcards (`*`) nur auf Namespace-Level erlaubt
- Konfliktauflösung: explizite Qualifizierung gewinnt (`llm.stats`)

### 32.6.3 Resolution-Algorithmus

1. Prüfe lokalen Scope
2. Prüfe Namespace-Imports
3. Prüfe globale Symbole
4. Fehler, wenn nicht gefunden → `Unknown symbol 'X'`

## 32.7 Runtime & Execution (Woche 7-10)

### 32.7.1 New/Constructor

```

Value evalNew(const AstNewExpr& node, Context& ctx) {
 auto* cls = ctx.lookupClass(node.type_name);
 return cls->invokeConstructor(node.args); // Alloc + Init
}

```

### 32.7.2 Methodenaufrufe

- Dynamische Dispatch-Tabelle je Klasse
- Inline-Cache (optional) für Hot-Paths
- Visibility-Checks zur Laufzeit (Guard)

### 32.7.3 Exceptions

- Stack-Unwinding mit RAII-Gurten
  - `defer` / `finally` -Support über Scope Guards
- 

## 32.8 Vision & LLM-Befehle (Add-On)

Neue Kommandos im LLM-Handler: - `VISION.EMBED(image|text, model)` → Vektor -  
`VISION.DESCRIBE(image)` → Text - `VISION.COMPARE(imgA, imgB)` → Similarity - Safety: Max  
Input Size, MIME-Checks, Model-Whitelist

---

## 32.9 Test-Strategie

### 32.9.1 Parser-Golden-Files

- Input → erwarteter AST (JSON) → Diffen in CI
- Beispiele: Klassen mit Vererbung, Methoden mit Default-Args, Namespaces

### 32.9.2 Property-Tests (Type Checker)

- QuickCheck/rapidcheck: zufällige Ausdrucksbäume generieren
- Invariante: Keine illegalen Typen nach erfolgreichem Check
- Fuzzer: ungültige Tokens → Parser muss robust fehlschlagen

### 32.9.3 Runtime-Tests

- Konstruktor/Methoden-Dispatch
- Visibility-Fehler (private/public)
- Exception-Pfade und Unwinding

## 32.10 Migrations-Plan

Phase	Dauer	Ergebnis
Lexer/Parser	2 Wochen	Keywords + AST-Nodes
Type-System	2-3 Wochen	Checker + Inference
Namespace	1 Woche	Symbol-Tables, Imports
Runtime	2-3 Wochen	Dispatch, Exceptions
Tests/Hardening	2 Wochen	Golden-Files, Property-Tests

**Risiken & Mitigation:** - Parser-Regressions → Golden-Files in CI - Performance-Einbruch → Inline-Caches, Hot-Path-Profiler - Kompatibilität → Feature-Flag `enable_oop` bis stabil

## 32.11 Checkliste Go-Live

- [ ] `enable_oop` Feature-Flag default ON
- [ ] Parser-Tests (100% der neuen Grammatik) grün
- [ ] Type-Checker-Property-Tests 10k Runs
- [ ] Runtime-Benchmarks: <10% Overhead ggü. v1.3.0
- [ ] LLM/Vision-Commands whitelisted, Input-Limits gesetzt
- [ ] Docs aktualisiert (AQL Referenz, Examples)

## 32.10 Implementierungs-Timeline

### Phase 1: Lexer & Parser (Wochen 1-4)

**Woche 1-2: Lexer** - Tag 1-2: Keyword-Set erweitern (47 neue) - Tag 3-4: Token-Recognition Tests - Tag 5-6: Error Messages verbessern - Tag 7-8: Performance Benchmarks (Lexer sollte <5% langsamer sein)

**Woche 3-4: Parser** - Tag 1-4: AST Node-Typen implementieren - Tag 5-7: Grammatik-Regeln für CLASS/METHOD/NAMESPACE - Tag 8-10: Golden-File Tests (10+ Parser-Test-Cases)

## Phase 2: Type System (Wochen 5-7)

**Woche 5-6: Type Checker** - Tag 1-3: Typ-Inference-Algorithmus - Tag 4-6: Visitor Pattern für AST-Traversal - Tag 7-10: Generics Support (Vector, Map)

**Woche 7: Validation** - Tag 1-3: Type Error Messages - Tag 4-6: Property-Based Tests - Tag 7: Integration mit Parser

## Phase 3: Namespace Resolution (Wochen 8-9)

- Tag 1-3: Symbol-Table Implementierung
- Tag 4-6: Import-Resolution
- Tag 7-9: Shadowing & Visibility
- Tag 10-12: Test-Suite (50+ Test-Cases)

## Phase 4: Runtime (Wochen 10-14)

**Woche 10-11: Object Model** - Tag 1-5: Class/Instance Representation - Tag 6-10: Constructor/Method Dispatch

**Woche 12-13: Execution** - Tag 1-5: NEW Expression Execution - Tag 6-10: Member Access Resolution - Tag 11-14: Exception Handling

**Woche 14: Integration** - Tag 1-3: End-to-End Tests - Tag 4-5: Performance Profiling - Tag 6-7: Documentation

## Phase 5: Vision & Rollout (Wochen 15-16)

- Woche 15: Vision.EMBED/DESCRIBE/COMPARE
- Woche 16: Production Deployment, Monitoring

## 32.11 Code-Beispiele

### 32.11.1 Lexer Test

```
// test_lexer_oop.cpp
TEST(AQLLexer, RecognizesClassKeyword) {
 std::string input = "CLASS User { }";
 Lexer lexer(input);

 Token t1 = lexer.next();
 EXPECT_EQ(t1.type, TokenType::CLASS);

 Token t2 = lexer.next();
 EXPECT_EQ(t2.type, TokenType::IDENTIFIER);
 EXPECT_EQ(t2.value, "User");

 Token t3 = lexer.next();
 EXPECT_EQ(t3.type, TokenType::LBRACE);
}

TEST(AQLLexer, KeywordCaseInsensitive) {
 Lexer lexer("class CLASS Class");

 for (int i = 0; i < 3; i++) {
 Token t = lexer.next();
 EXPECT_EQ(t.type, TokenType::CLASS);
 }
}
```



### 32.11.2 Parser Test mit Golden Files

```
// test_parser_golden.cpp
TEST(AQLParser, ClassDeclarationGolden) {
 std::string input = R"(
 CLASS User {
 PRIVATE email: STRING
 PUBLIC name: STRING

 CONSTRUCTOR(email, name) {
 THIS.email = email
 THIS.name = name
 }

 PUBLIC METHOD greet() {
 RETURN CONCAT("Hello, ", THIS.name)
 }
 }
)";

 Parser parser(input);
 AstNode* ast = parser.parse();

 // Serialize AST to JSON
 std::string ast_json = serializeAST(ast);

 // Compare with Golden File
 std::string expected = readFile("golden/class_user_ast.json");
 EXPECT_EQ(ast_json, expected);
}
```

### 32.11.3 Type Checker Unit Test

```
// test_type_checker.cpp
TEST(TypeChecker, InfersReturnType) {
 std::string code = R"(
 FUNCTION add(a: INT, b: INT) {
 RETURN a + b // Should infer INT
 }
)";

 TypeChecker checker;
 FunctionType func_type = checker.inferFunctionType(code);

 EXPECT_EQ(func_type.return_type, Type::INT);
 EXPECT_EQ(func_type.param_types.size(), 2);
 EXPECT_EQ(func_type.param_types[0], Type::INT);
}

TEST(TypeChecker, DetectsMismatch) {
 std::string code = R"(
 FUNCTION broken(x: STRING) -> INT {
 RETURN x // x Type Error: expected INT, got STRING
 }
)";

 TypeChecker checker;
 EXPECT_THROW(
 checker.check(code),
 TypeMismatchException
);
}
```

### 32.11.4 Namespace Resolution Test

```
// test_namespace.cpp
TEST(NamespaceResolver, ImportsResolve) {
 std::string code = R"(
 NAMESPACE myapp
 IMPORT themis.llm.*

 FUNCTION analyze(text) {
 RETURN LLM.CHAT(text) // Should resolve to themis.llm.LLM.CHAT
 }
)";

 NamespaceResolver resolver;
 SymbolTable symbols = resolver.resolve(code);

 Symbol* llm_chat = symbols.lookup("LLM.CHAT");
 EXPECT_NE(llm_chat, nullptr);
 EXPECT_EQ(llm_chat->fully_qualified_name, "themis.llm.LLM.CHAT");
}
```

### 32.11.5 Runtime NEW Expression

```
// aql_runtime.cpp: NEW Implementierung
Value AQLRuntime::evalNew(const AstNewExpr& node) {
 // 1. Lookup Class Definition
 ClassDef* cls = symbol_table_.lookupClass(node.type_name);
 if (!cls) {
 throw RuntimeError(fmt::format("Class '{}' not found", node.type_name));
 }

 // 2. Allocate Instance
 ObjectInstance* instance = allocateObject(cls);

 // 3. Find Constructor
 Constructor* ctor = cls->findConstructor(node.args.size());
 if (!ctor) {
 throw RuntimeError(fmt::format(
 "No constructor found for {} args", node.args.size()
));
 }

 // 4. Evaluate Arguments
 std::vector<Value> arg_values;
 for (const auto& arg : node.args) {
 arg_values.push_back(eval(arg));
 }

 // 5. Invoke Constructor
 ctor->invoke(instance, arg_values);

 return Value::fromObject(instance);
}
```

## 32.12 Performance-Auswirkungen

### Erwartete Overhead

Operation	Baseline (ohne OOP)	Mit OOP	Overhead
Lexing	100 ms/10k lines	105 ms	+5%
Parsing	250 ms/10k lines	280 ms	+12%
Type Check	N/A	150 ms	Neu
Execution (Simple FOR)	10 ms	10 ms	0%
Execution (Method Call)	N/A	+2 ms	Neu

**Optimierungen:** - **Inline Caching:** Häufig aufgerufene Methoden cachen - **JIT für Hot Methods:** Bytecode-Kompilierung für >1000 Calls - **Lazy Type Checking:** Nur bei Bedarf (Development-Mode)

## Benchmarks

```
// benchmark_oop.cpp
static void BM_MethodCall(benchmark::State& state) {
 std::string code = R"(
 CLASS Counter {
 PRIVATE count: INT

 CONSTRUCTOR() { THIS.count = 0 }
 METHOD increment() { THIS.count = THIS.count + 1 }
 }

 LET c = NEW Counter()
 FOR i IN 1..1000000
 c.increment()
)";

 for (auto _ : state) {
 AQLRuntime runtime;
 runtime.execute(code);
 }
}
BENCHMARK(BM_MethodCall);

// Ergebnis: ~2.5 µs pro Method Call (inkl. Dispatch)
```

---

## 32.13 Migration & Backward Compatibility

### Rückwärtskompatibilität

- **Alle AQL v1.3.0 Queries funktionieren unverändert**
- **Neue Keywords nur in OOP-Kontext reserviert**
- **Legacy-Code benötigt keine Änderungen**

## Opt-In für OOP Features

```
-- Legacy Mode (Default)
FOR u IN users RETURN u

-- OOP Mode (via Pragma)
#pragma aql_version 1.3.1

CLASS User { ... }
```

## Feature Flag

```
themis.conf
aql:
 oop_features_enabled: true # Default: false bis v1.4.0
 strict_type_checking: false # Development: true, Production: false
```

---

## 32.14 Zusammenfassung

AQL v1.3.1 führt OOP-Konstrukte ein und erfordert Änderungen auf allen Ebenen der Query-Engine. Die Implementierung gliedert sich in fünf Phasen: Lexer/Parser, Type-System, Namespace-Resolution, Runtime, Tests. Mit klaren Guardrails (Feature-Flag, Tests, Benchmarks) kann die Erweiterung ohne Regressionen ausgerollt werden.

## Kapitel 33: Kapitel 33 - Best Practices

---

*"Good code is its own best documentation. As you're about to add a comment, ask yourself, 'How can I improve the code so that this comment isn't needed?'" - Steve McConnell*

---

## Überblick

Production-ready ThemisDB-Anwendungen folgen bewährten Patterns für Performance, Sicherheit, und Wartbarkeit. Dieses Kapitel sammelt Battle-tested Best Practices aus realen Deployments.

**Was Sie in diesem Kapitel lernen:** - Schema-Design Patterns - Query-Optimierung Best Practices - Sicherheits-Härtung - Resilience Patterns - Testing-Strategien - Performance Tuning - Operational Excellence

---

### 33.1 Schema-Design Patterns

#### Pattern 1: Embedded vs. Referenced

**Embedded (Denormalisiert):**



```
// Gut für: 1:N Beziehungen mit wenigen Child-Elementen
{
 "_key": "order-123",
 "customer": {
 "name": "Alice",
 "email": "alice@example.com"
 },
 "items": [
 {"product": "Laptop", "quantity": 1, "price": 1200},
 {"product": "Mouse", "quantity": 2, "price": 25}
],
 "total": 1250
}

// Vorteile:
// - Single query (kein JOIN)
// - Atomic updates
// - Keine referentielle Integrität nötig

// x Nachteile:
// - Duplikation (customer-Daten in jedem Order)
// - Update-Anomalien (email ändert sich → alle Orders updaten)
```

**Referenced (Normalisiert):**

```
// customers Collection
{
 "_key": "alice",
 "name": "Alice",
 "email": "alice@example.com",
 "address": {...}
}

// orders Collection
{
 "_key": "order-123",
 "customer_id": "alice", // Referenz
 "items": [...],
 "total": 1250
}

// Query mit JOIN
FOR order IN orders
 FILTER order._key == 'order-123'
 LET customer = DOCUMENT(CONCAT('customers/', order.customer_id))
 RETURN MERGE(order, {customer: customer})

// Vorteile:
// - Keine Duplikation
// - Single source of truth
// - Einfache Updates (nur 1 Dokument)
```

### Entscheidungsmatrix:

Abb. 33.1: Best-Practices-Decision-Tree

**Entscheidungsmatrix:** | Use Case | Pattern | Begründung | |-----|-----|-----| | Blog: Post + Comments (1:N, viele) | Referenced | Comments wachsen unbegrenzt | | Order + Items (1:N, <20) | Embedded | Items sind fix nach Order | | User + Preferences (1:1) | Embedded | Preferences immer mit User geladen | | Product + Categories (M:N) | Referenced | Viele-zu-Viele → Graph-Edges |

## 33.2 Query-Optimierung Patterns

### Pattern 2: Early Filtering

```
-- x SCHLECHT: Filter nach JOIN
FOR order IN orders
 LET customer = DOCUMENT(order.customer_id)
 FILTER customer.country == 'DE' // Zu spät!
 RETURN order

-- GUT: Filter vor JOIN
FOR order IN orders
 LET customer = DOCUMENT(order.customer_id)
 FILTER customer != null && customer.country == 'DE'
 RETURN order

-- OPTIMAL: Denormalisierung für häufige Filters
{
 "_key": "order-123",
 "customer_id": "alice",
 "customer_country": "DE", // Denormalisiert für schnellen Filter
 ...
}

FOR order IN orders
 FILTER order.customer_country == 'DE' // Index-optimiert
 RETURN order
```

### Pattern 3: Projection (Select nur benötigte Felder)

```
-- x SCHLECHT: Alle Felder laden
FOR user IN users
 RETURN user // Lädt alle Felder (1 MB/User!)

-- GUT: Nur benötigte Felder
FOR user IN users
 RETURN {
 id: user._id,
 name: user.name,
 email: user.email
 } // Nur 100 Bytes/User

-- Performance-Gewinn: 10x schneller bei großen Dokumenten
```

### Pattern 4: Pagination mit Cursor

```
-- x SCHLECHT: OFFSET/LIMIT (langsam bei großen Offsets)
FOR doc IN collection
 SORT doc.created_at DESC
 LIMIT 10000, 100 // Skip 10k Docs → langsam!
 RETURN doc

-- GUT: Cursor-based Pagination
FOR doc IN collection
 FILTER doc.created_at < @last_seen_timestamp
 SORT doc.created_at DESC
 LIMIT 100
 RETURN doc

// Client speichert letzten Timestamp:
last_seen = results[99].created_at
next_page = query(last_seen_timestamp=last_seen)
```

## 33.3 Sicherheits-Härtung

### Pattern 5: Input Validation

```
-- x SCHLECHT: Unvalidierte User-Eingabe
LET user_input = @email
FOR u IN users
 FILTER u.email == user_input // Injection-Risiko bei String-Concat!
 RETURN u

-- GUT: Parametrisierte Queries
FOR u IN users
 FILTER u.email == @email // Safe: Parameter-Binding
 RETURN u

-- BESSER: Zusätzliche Validation
FUNCTION validate_email(email) {
 IF !REGEX_TEST(email, "^[a-zA-Z0-9._%+-]+@[a-zA-Z0-9.-]+\.[a-zA-Z]{2,}$") THEN
 THROW ERROR("Invalid email format")
 END
 RETURN email
}

LET validated = validate_email(@email)
FOR u IN users
 FILTER u.email == validated
 RETURN u
```

## Pattern 6: Least Privilege Access

```
-- x SCHLECHT: Root-User für Application
const client = new ThemisClient({
 user: 'root', // x Zu viele Rechte!
 password: 'root123'
})

-- GUT: Dedizierter App-User mit minimalen Rechten
CREATE USER app_user WITH PASSWORD 'secure_pass'
GRANT READ ON DATABASE mydb TO app_user
GRANT WRITE ON COLLECTION orders TO app_user
GRANT WRITE ON COLLECTION users TO app_user

const client = new ThemisClient({
 user: 'app_user',
 password: process.env.THEMIS_PASSWORD // Aus Env-Var
})
```

## Pattern 7: Data Encryption at Rest

```
themis.conf
storage:
 encryption:
 enabled: true
 algorithm: AES-256-GCM
 key_provider: aws-kms
 key_id: arn:aws:kms:eu-central-1:123456789:key/abc-def

Zusätzlich: Field-Level Encryption für PII
field_encryption:
 - collection: users
 fields: [ssn, credit_card, password_hash]
```

## 33.4 Resilience Patterns

### Pattern 8: Circuit Breaker

```
class CircuitBreaker:
 def __init__(self, threshold=5, timeout=60):
 self.failures = 0
 self.threshold = threshold
 self.timeout = timeout
 self.open_until = None

 def call(self, func, *args, **kwargs):
 # Circuit Open → Fail Fast
 if self.open_until and time.time() < self.open_until:
 raise CircuitBreakerOpen("Service unavailable")

 try:
 result = func(*args, **kwargs)
 self.failures = 0 # Reset bei Erfolg
 return result
 except Exception as e:
 self.failures += 1

 if self.failures >= self.threshold:
 self.open_until = time.time() + self.timeout
 print(f"Circuit opened for {self.timeout}s")

 raise

Nutzung
db_breaker = CircuitBreaker(threshold=3, timeout=30)

def query_themis(aql):
 return db_breaker.call(client.query, aql)

Bei 3 Fehlern → 30s Pause
```

## Pattern 9: Retry with Exponential Backoff

```
def retry_with_backoff(func, max_retries=3, base_delay=1):
 """Retry mit exponential backoff"""
 for attempt in range(max_retries):
 try:
 return func()
 except (NetworkError, TimeoutError) as e:
 if attempt == max_retries - 1:
 raise # Letzter Versuch → propagieren

 delay = base_delay * (2 ** attempt) # 1s, 2s, 4s
 jitter = random.uniform(0, 0.3) * delay # ±30% Jitter
 time.sleep(delay + jitter)

Nutzung
result = retry_with_backoff(
 lambda: client.query("FOR u IN users RETURN u"),
 max_retries=5,
 base_delay=0.5
)
```



## Pattern 10: Bulkhead Pattern (Resource Isolation)

```
Separate Connection Pools für kritische vs. non-kritische Queries
critical_pool = ThemisConnectionPool(
 max_connections=50,
 priority='high'
)

background_pool = ThemisConnectionPool(
 max_connections=10,
 priority='low'
)

Kritische User-Requests
def get_user_profile(user_id):
 with critical_pool.get_connection() as conn:
 return conn.query("FOR u IN users FILTER u._id == @id RETURN u",
 {'id': user_id})

Unkritische Background-Jobs
def generate_analytics_report():
 with background_pool.get_connection() as conn:
 return conn.query("FOR order IN orders COLLECT ...")
```

## 33.5 Testing Patterns

### Pattern 11: Golden File Testing

```
test_queries.py
def test_user_query_golden():
 """Query-Ergebnis mit Golden File vergleichen"""

 # Setup Test-Daten
 setup_fixture('users_test.json')

 # Query ausführen
 result = client.query("""
 FOR u IN users
 FILTER u.age > 25
 SORT u.name
 RETURN {name: u.name, age: u.age}
 """)

 # Mit Golden File vergleichen
 expected = load_json('golden/user_query_expected.json')
 assert result == expected, f"Query result mismatch!"

Golden File erstellen:
python test_queries.py --update-golden
```

## Pattern 12: Property-Based Testing

```
from hypothesis import given, strategies as st

@given(st.lists(st.integers(min_value=0, max_value=100), min_size=1, max_size=1000))
def test_aggregation_properties(numbers):
 """Property: SUM sollte immer gleich Python sum() sein"""

 # Insert Test-Daten
 for n in numbers:
 client.insert('numbers', {'value': n})

 # AQL Aggregation
 aql_sum = client.query("RETURN SUM(n.value FOR n IN numbers)")[0]

 # Python Referenz
 python_sum = sum(numbers)

 assert aql_sum == python_sum, f"Aggregation mismatch: {aql_sum} != {python_sum}"
```

## 33.6 Performance Tuning

### Pattern 13: Connection Pooling

```
x SCHLECHT: Neue Connection pro Request
def handle_request():
 client = ThemisClient('http://localhost:8529') # Langsam!
 result = client.query(...)
 client.close()
 return result

GUT: Shared Connection Pool
from themis.pool import ConnectionPool

pool = ConnectionPool(
 url='http://localhost:8529',
 max_connections=100,
 min_connections=10,
 connection_timeout=5
)

def handle_request():
 with pool.get_connection() as client:
 return client.query(...)
```

## Pattern 14: Query Caching

```
from functools import lru_cache
import hashlib

@lru_cache(maxsize=1000)
def cached_query(query_hash, params_hash):
 """Cache für idempotente Queries"""
 query = QUERY_CACHE[query_hash]
 params = PARAMS_CACHE[params_hash]
 return client.query(query, params)

def get_user_stats(user_id):
 query = "FOR u IN users FILTER u._id == @id RETURN u.stats"
 query_hash = hashlib.md5(query.encode()).hexdigest()
 params_hash = hashlib.md5(str(user_id).encode()).hexdigest()

 return cached_query(query_hash, params_hash)

Cache invalidieren bei Update
def update_user(user_id, data):
 client.update(f'users/{user_id}', data)
 cached_query.cache_clear() # Invalidate
```

## Pattern 15: Batch Operations

```
-- x SCHLECHT: N einzelne Inserts
FOR i IN 1..10000
 INSERT {value: i} INTO collection // 10k Roundtrips!

-- GUT: Batch-Insert
LET docs = (FOR i IN 1..10000 RETURN {value: i})
FOR doc IN docs
 INSERT doc INTO collection // 1 Roundtrip

-- Python Equivalent:
docs = [{'value': i} for i in range(10000)]
client.query("FOR doc IN @docs INSERT doc INTO collection", {'docs': docs})
```

---

## 33.7 Operational Patterns

### Pattern 16: Health Check Endpoint

```
// server.js: Express Health Check
app.get('/health', async (req, res) => {
 const health = {
 status: 'healthy',
 timestamp: new Date().toISOString(),
 checks: {}
 };

 try {
 // Database connectivity
 const start = Date.now();
 await themisClient.query('RETURN 1');
 health.checks.database = {
 status: 'ok',
 latency_ms: Date.now() - start
 };
 } catch (err) {
 health.status = 'unhealthy';
 health.checks.database = {
 status: 'error',
 error: err.message
 };
 }

 // Memory check
 const memUsage = process.memoryUsage();
 health.checks.memory = {
 status: memUsage.heapUsed < 0.9 * memUsage.heapTotal ? 'ok' : 'warning',
 heap_used_mb: Math.round(memUsage.heapUsed / 1024 / 1024)
 };

 res.status(health.status === 'healthy' ? 200 : 503).json(health);
});
```



## Pattern 17: Graceful Shutdown

```
import signal
import sys

class Application:
 def __init__(self):
 self.shutting_down = False
 signal.signal(signal.SIGTERM, self.handle_shutdown)
 signal.signal(signal.SIGINT, self.handle_shutdown)

 def handle_shutdown(self, signum, frame):
 print("Shutdown signal received, gracefully stopping...")
 self.shutting_down = True

 # 1. Stop accepting new requests
 self.stop_accepting_requests()

 # 2. Wait for active requests to complete (max 30s)
 self.wait_for_active_requests(timeout=30)

 # 3. Close DB connections
 themis_pool.close_all()

 # 4. Flush logs
 logging.shutdown()

 sys.exit(0)

app = Application()
```

---

## 33.8 Checkliste für Production-Readiness

### Pre-Deployment Checklist

- **Schema & Indizes:**

- [ ] Alle Indizes erstellt ( `CREATE INDEX` )
- [ ] EXPLAIN für kritische Queries durchgeführt
- [ ] Composite Indizes für häufige Filter-Kombinationen
- [ ] TTL-Indizes für automatische Datenlöschung
- **Performance:**
  - [ ] Connection Pooling aktiviert
  - [ ] Query Timeouts konfiguriert
  - [ ] Rate Limiting implementiert
  - [ ] Caching-Strategie definiert
- **Sicherheit:**
  - [ ] Encryption at Rest aktiviert
  - [ ] TLS für Client-Verbindungen
  - [ ] Least-Privilege User-Accounts
  - [ ] Input-Validierung in Application
- **Resilience:**
  - [ ] Circuit Breaker implementiert
  - [ ] Retry-Logic mit Backoff
  - [ ] Graceful Shutdown Handler
  - [ ] Health Check Endpoint
- **Monitoring:**
  - [ ] Prometheus/Grafana Dashboards
  - [ ] Alerting für Critical Metrics
  - [ ] Slow Query Log aktiviert
  - [ ] Error Tracking (Sentry/Datadog)
- **Backup & DR:**
  - [ ] Tägliche automatische Backups
  - [ ] Backup-Restore getestet
  - [ ] Multi-Region Replication
  - [ ] Disaster Recovery Runbook

## 33.9 Anti-Patterns (Was zu vermeiden ist)

### x Anti-Pattern 1: N+1 Queries

```
-- SCHLECHT: 1 Query + N Queries
FOR order IN orders
 LIMIT 100
 LET customer = DOCUMENT(order.customer_id) // N zusätzliche Lookups!
 RETURN {order: order, customer: customer}

-- GUT: Batch Lookup
LET order_ids = (FOR o IN orders LIMIT 100 RETURN o._key)
LET orders = DOCUMENT(orders, order_ids)
LET customer_ids = orders[*].customer_id
LET customers = DOCUMENT(customers, customer_ids)
...
```

### x Anti-Pattern 2: Unbounded Collections

```
-- SCHLECHT: Embedded Array wächst unbegrenzt
{
 "blog_post_id": "post-1",
 "comments": [...] // Was wenn 10k Comments?
}

-- GUT: Separate Collection mit Referenz
// comments Collection
{
 "post_id": "post-1",
 "comment": "...",
 "author": "alice"
}
```

## × Anti-Pattern 3: Hardcoded Credentials

```
SCHLECHT
client = ThemisClient('http://prod-db:8529',
 username='admin',
 password='prod123') # × Im Code!

GUT
client = ThemisClient(
 os.getenv('THEMIS_URL'),
 username=os.getenv('THEMIS_USER'),
 password=os.getenv('THEMIS_PASSWORD') # Aus Env
)
```

---

## 33.10 Advanced Patterns: Event Sourcing

### Event Sourcing Pattern

**Concept:** Store immutable events, derive state from events.

```
-- Event Log (immutable)
{
 "_id": "events/evt-001",
 "aggregate_id": "account/alice",
 "event_type": "AccountCreated",
 "timestamp": "2025-01-01T10:00:00Z",
 "data": { "name": "Alice", "email": "alice@example.com" }
}

{
 "_id": "events/evt-002",
 "aggregate_id": "account/alice",
 "event_type": "DepositMade",
 "timestamp": "2025-01-01T10:05:00Z",
 "data": { "amount": 1000, "currency": "USD" }
}

{
 "_id": "events/evt-003",
 "aggregate_id": "account/alice",
 "event_type": "WithdrawalMade",
 "timestamp": "2025-01-01T10:10:00Z",
 "data": { "amount": 200, "currency": "USD" }
}

-- Materialized View (derived)
{
 "_id": "account_state/alice",
 "balance": 800,
 "last_event_id": "evt-003",
 "updated_at": "2025-01-01T10:10:00Z"
}
```

**Benefits:** - **Audit Trail:** Complete history of all changes - **Temporal Queries:** "What was balance at 10:08?" - **Event Replay:** Rebuild state from scratch - **Debugging:** Trace exact sequence of operations

**Implementation:**

```
-- Record event
BEGIN
 INSERT event INTO event_log
 UPDATE account_state WITH { balance: new_balance }
COMMIT

-- Replay events (if state corrupted)
LET all_events = (
 FOR event IN event_log
 FILTER event.aggregate_id == @account_id
 SORT event.timestamp ASC
 RETURN event
)

LET final_state = REDUCE event IN all_events
 INTO {balance: 0, last_event: NULL}
 (
 LET update = APPLY_EVENT(acc, event)
 RETURN update
)

RETURN final_state
```

## 33.11 CQRS Pattern (Command Query Responsibility Segregation)

### Pattern: Separate Reads from Writes

#### Write Model (Command Side)

- └─ Receives mutations (CREATE, UPDATE, DELETE)
- └─ Validates business rules
- └─ Persists to event log
- └─ Produces events

#### Event Bus

- └─ Asynchronously publishes events

#### Read Model (Query Side)

- └─ Subscribes to events
- └─ Updates read-optimized views
- └─ Serves fast queries
- └─ Can have different schema than write model

### Example: E-Commerce Order

```
-- Write Model (Normalized)
{
 "_id": "orders/ord-123",
 "customer_id": "cust-456",
 "status": "shipped",
 "created_at": "2025-01-01T10:00:00Z"
}

-- Read Model (Denormalized for Dashboard)
{
 "_id": "order_view/ord-123",
 "customer_name": "Alice",
 "customer_email": "alice@example.com",
 "total_amount": 1250,
 "item_count": 3,
 "status": "shipped",
 "estimated_delivery": "2025-01-05",
 "updated_at": "2025-01-01T15:00:00Z"
}
```

**Implementation:**



```
Write side: Accept command
@app.post("/orders")
def create_order(cmd: CreateOrderCommand):
 # Validate
 assert cmd.total > 0
 assert cmd.customer_id in db.customers

 # Write to event log
 event = OrderCreatedEvent(cmd)
 db.insert('event_log', event)

 # Publish to event bus
 event_bus.publish(event)

 return {"order_id": event.order_id}

Read side: Subscribe to events
event_bus.subscribe('OrderCreatedEvent', rebuild_order_view)

def rebuild_order_view(event):
 # Enrich with customer data
 customer = db.get('customers', event.customer_id)

 # Create denormalized view
 view = {
 "order_id": event.order_id,
 "customer_name": customer.name,
 "customer_email": customer.email,
 "total": event.total,
 "status": "created"
 }
 db.insert('order_view', view)
```

## 33.12 Saga Pattern (Distributed Transactions)

### Pattern: Multi-Step Compensating Transactions

**Problem:** Atomic transaction across 3+ microservices.

**Solution:** Saga with rollback logic.

Order Processing Saga:

Step 1: Reserve Inventory

- └ Reserve 10 units
- └ If fail: Abort saga

Step 2: Process Payment

- └ Charge credit card
- └ If fail: Release inventory (compensate Step 1)

Step 3: Ship Order

- └ Create shipment
- └ If fail: Refund payment (compensate Step 2)

Step 4: Send Notification

- └ Send confirmation email
- └ If fail: Just log (no compensation)

### Implementation in ThemisDB:

```
-- Saga State Machine
{
 "_id": "sagas/saga-001",
 "order_id": "ord-123",
 "status": "in_progress",
 "steps": [
 { "name": "reserve_inventory", "status": "completed", "compensated": false },
 { "name": "process_payment", "status": "completed", "compensated": false },
 { "name": "ship_order", "status": "failed", "error": "Out of stock" },
 { "name": "send_notification", "status": "pending", "compensated": false }
],
 "created_at": "2025-01-01T10:00:00Z"
}

-- On Step 3 failure, execute compensations in reverse
-- Step 2: Refund payment
-- Step 1: Release inventory
-- Update saga status to "rolled_back"
```

---

## 33.13 Bulkhead Pattern (Isolation)

### Pattern: Isolate Critical Resources

**Problem:** One slow query brings down entire system.

**Solution:** Separate resource pools.

```
ThreadPool: User Queries (20 threads)
ThreadPool: Admin Operations (5 threads)
ThreadPool: Background Jobs (10 threads)

Guarantees:
- User queries won't starve admin ops
- Background jobs won't impact user experience
- Can set timeouts per pool
```

**Implementation:**

```
from concurrent.futures import ThreadPoolExecutor

Separate executors for different workloads
user_executor = ThreadPoolExecutor(max_workers=20, thread_name_prefix='user_')
admin_executor = ThreadPoolExecutor(max_workers=5, thread_name_prefix='admin_')
bg_executor = ThreadPoolExecutor(max_workers=10, thread_name_prefix='bg_')

Route query to appropriate executor
if query.is_admin:
 future = admin_executor.submit(execute_query, query)
elif query.is_background:
 future = bg_executor.submit(execute_query, query)
else:
 future = user_executor.submit(execute_query, query)

Each executor has timeout
result = future.result(timeout=30) # 30s for users, 60s for admin
```

## **33.14 Throttling & Rate Limiting Pattern**

**Pattern: Control Request Rate**

```
class RateLimiter:
 def __init__(self, max_requests_per_second=1000):
 self.max_rps = max_requests_per_second
 self.tokens = max_requests_per_second
 self.last_refill = time.time()
 self.lock = threading.Lock()

 def allow(self):
 with self.lock:
 now = time.time()
 elapsed = now - self.last_refill

 # Refill tokens
 self.tokens = min(
 self.max_rps,
 self.tokens + elapsed * self.max_rps
)
 self.last_refill = now

 if self.tokens >= 1:
 self.tokens -= 1
 return True
 return False

Usage
limiter = RateLimiter(max_requests_per_second=1000)

@app.post("/query")
def execute_query(query: Query):
 if not limiter.allow():
 return {"error": "Rate limit exceeded", "retry_after": 1}

 return execute(query)
```

## 33.15 Zusammenfassung: Advanced Patterns

Pattern	Problem	Solution
Event Sourcing	Audit trail	Immutable events
CQRS	Read/write scaling	Separate models
Saga	Distributed transactions	Compensating transactions
Bulkhead	Resource contention	Isolated pools
Rate Limiting	Overload protection	Token bucket
Circuit Breaker	Cascading failures	Fail-fast
Retry	Transient failures	Exponential backoff

## 33.16 Golden Rules Revisited

### The 7 Commandments of Database Stewardship:

- 1. Index Everything You Filter**
- Query without index = scan all rows
- EXPLAIN is your friend
- Composite indexes follow query order
- 5. Fail Fast, Recover Faster**
- Circuit breaker pattern
- Exponential backoff on retries
- Self-healing infrastructure
- 9. Test Like Production**
- Load testing with realistic workload
- Chaos engineering for resilience
- Staging identical to production

**13. Monitor Before You're in Crisis**

14. Metrics: CPU, Memory, QPS, Latency

15. Logs: All errors, admin actions

16. Traces: Request flow

**17. Automate Everything**

18. Backups without manual intervention

19. Failover without human click

20. Deployments without handoff

**21. Document As You Go**

22. Architecture Decision Records (ADRs)

23. Runbooks for common issues

24. Decisions > Implementation details

**25. Security by Default**

26. Least privilege (not super-user)

27. Encryption (at rest, in transit)

28. Validation (all inputs)

29. Audit (all changes)

---

**Kapitel 33 von 33 | Teil VI: Best Practices & Advanced | ~9.000 Wörter (+2000 neu)**



# Teil X - Advanced Topics

---

# Kapitel 34: Kapitel 34 - Query Optimierung

---

*"Optimierung ist eine kontinuierliche Reise, nicht ein Ziel. Mit den richtigen Tools können Sie fast jede Query um 10-100x beschleunigen."*

## Überblick

Query-Performance ist einer der kritischsten Faktoren für den Datenbankenerfolg. Dieses Kapitel zeigt praktische Techniken zur Optimierung von AQL-Queries, vom EXPLAIN-Analyse bis zu fortgeschrittenen Optimierungsmustern.

**Was Sie in diesem Kapitel lernen:** - EXPLAIN und Query-Profiling - Index-Strategien und Best Practices - Early Filtering und Projection Pushdown - Query-Refactoring für Performance - Aggregation Optimization - Window Function Performance - Batch-Operation Tuning - Query Caching und Memoization

---

Abb. 34.0: Query-Plan-Optimierung

## 34.1 EXPLAIN und Query-Profiling

### EXPLAIN Output verstehen

```
-- Grundlegende EXPLAIN Syntax
EXPLAIN FOR doc IN users
 FILTER doc.status == 'active'
 SORT doc.created_at DESC
 LIMIT 10
 RETURN doc

-- Ausgabe-Struktur:
-- ExecutionPlan:
-- Steps:
-- 1. CollectionScan (collection="users")
-- 2. Filter (condition="doc.status == 'active'")
-- 3. Sort (fields=["created_at"])
-- 4. Limit (count=10)
-- 5. Return
```

### Extended EXPLAIN

```
-- Detailliertes EXPLAIN mit Statistiken
EXPLAIN OPTION {verbose: true}
FOR doc IN users
 FILTER doc.status == 'active'
 RETURN doc

-- Output zeigt:
-- - Estimated item count pro Step
-- - Filter selectivity
-- - Index usage
-- - Memory usage
```

## Profile Queries

```
-- Query mit echtem Timing profilen
PROFILE FOR doc IN users
 FILTER doc.status == 'active'
 SORT doc.created_at
 RETURN doc

-- Ausgabe:
-- Step | Operation | Items | Time(ms) | Selectivity
-- 1 | Scan | 1M | 50 | 100%
-- 2 | Filter | 100k | 150 | 10%
-- 3 | Sort | 100k | 200 | 100%
-- 4 | Return | 100k | 10 | 100%
```

## 34.2 Index-Strategien

### Single Field Indexes

```
-- Einfachster Index - für exakte Matches & Range Queries
CREATE INDEX idx_status ON users(status)

-- Performance-Gain:
-- Vorher: Full Scan 1000ms für 1M Dokumente
-- Nachher: Index Lookup 1ms
-- Speedup: 1000x

-- Nutzbringend für:
FILTER doc.status == 'active'
FILTER doc.age > 18
FILTER doc.created_at BETWEEN '2024-01-01' AND '2024-12-31'
```

## Composite Indexes

```
-- Multiple Felder - für komplexe Filter
CREATE INDEX idx_status_age ON users(status, age)

-- Hilft bei:
FILTER doc.status == 'active' AND doc.age > 18

-- Leading Field Optimization:
-- Der erste Index-Feld sollte die höchste Selectivity haben
-- Ranking: status_age (besser) vs age_status (schlechter)
-- Grund: First field narrowed down fast
```

## Sparse Indexes

```
-- Index nur auf Dokumente mit Feld
CREATE SPARSE INDEX idx_phone ON users(phone)

-- Nutzen:
-- Spart Speicher (nur 30% der Dokumente haben phone)
-- Schneller Insert/Update (nur 30% indexieren)
-- Perfekt für optionale Felder

-- Abfrage:
FOR doc IN users
 FILTER doc.phone != null
 FILTER doc.phone LIKE '%123%'
 RETURN doc
```

## Partial Indexes

```
-- Index nur auf Subset (mit Filter-Bedingung)
CREATE INDEX idx_active_premium ON users(category)
 WHERE subscription_status == 'premium'

-- Spart 80% Speicher wenn nur 20% premium sind
-- 10x schneller Index-Updates

-- Muss mit passender Query genutzt werden:
FOR doc IN users
 FILTER doc.subscription_status == 'premium'
 FILTER doc.category == 'enterprise'
 RETURN doc
```

## Covering Indexes

```
-- Index mit all nötigen Feldern (ohne Dokument lesen)
CREATE INDEX idx_name_email_age ON users(name, email, age)

-- Super-optimiert für Query:
FOR doc IN users
 FILTER doc.email == 'alice@example.com'
 RETURN {name: doc.name, age: doc.age} -- Alles im Index!

-- Kein Dokument-Fetch nötig → 100-1000x schneller
```

## 34.3 Early Filtering Patterns

### Filter-Pushdown Strategy

```
-- x FALSCH: Filter zu spät
FOR edge IN edges
 RETURN {
 from: edge.from,
 to: edge.to,
 weight: (FOR v IN vertices FILTER v._id == edge.to RETURN v.weight)[0]
 }
-- Problem: N+1 Query, 1M edges = 1M vertex lookups

-- RICHTIG: Early Filter
FOR edge IN edges
 FILTER edge.weight > 0.5 -- Filter früh
 LET target_vertex = (
 FOR v IN vertices
 FILTER v._id == edge.to
 FILTER v.category == 'active' -- Filter auch inner
 RETURN v
)[0]
 RETURN {
 from: edge.from,
 to: edge.to,
 target_weight: target_vertex.weight
 }
```

## Collection Constraint Strategy

```
-- x Generisch - keine Collection Constraint
FILTER LIKE(name, '%alice%') -- String-Operation für alle Doku

-- Mit Collection Filter
FOR user IN users -- Explizite Collection wählen
 FILTER user.status == 'active' -- Early
 FILTER LIKE(user.name, '%alice%') -- Text-Suche nur auf aktiven
RETURN user
```

---

## 34.4 Aggregation Optimization

### GROUP BY Optimization

```
-- x Ineffizient: Alles sammeln dann groupieren
COLLECT category = doc.category
 AGGREGATE total = SUM(doc.amount)
 INTO grouped
-- Memory: O(n) - alle Doku im Memory

-- Effizient: Mit Index
FOR doc IN transactions
 FILTER doc.timestamp >= '2024-01-01' -- Filter früh
 SORT doc.category
 COLLECT category = doc.category
 AGGREGATE total = SUM(doc.amount)
 RETURN {category, total}
-- Memory: O(distinct categories) << O(n)
```



## Approximate Aggregations

```
-- Für sehr große Datasets: Approximate Counts
FUNCTION count_approximate() {
 -- HyperLogLog für massive Sets
 -- Precision vs Speed Tradeoff
 RETURN APPROX_COUNT(*) FROM large_collection
}

-- Nutzen:
-- - COUNT(*) auf 1B Dokumente: 5 Sekunden statt 5 Minuten
-- - Genauigkeit: $\pm 2\%$ vs $\pm 0\%$
-- - Speicher: 12KB vs 8GB
```

## 34.5 Window Function Performance

### Partition Strategy

```
-- x Falsch: Zu große Partitions
FOR sale IN sales
 WINDOW {
 PARTITION BY sale.region
 ORDER BY sale.timestamp
 RANGE CURRENT ROW TO 1000 ROWS FOLLOWING
 }
 LET total = SUM(sale.amount) OVER ...
 RETURN sale
-- Problem: Ein Region mit 10M Rows → 10M × 1000 = Massive Computation

-- Richtig: Kleinere Partitions
FOR sale IN sales
 FILTER sale.timestamp >= DATE_SUBTRACT(NOW(), 30, 'day')
 FILTER sale.region IN ['north', 'south'] -- Filter Partitions
 WINDOW {
 PARTITION BY sale.region, DATE_TRUNC(sale.timestamp, 'day')
 ORDER BY sale.timestamp
 RANGE CURRENT ROW TO 100 ROWS FOLLOWING
 }
 RETURN sale
```

## 34.6 Batch Operations

### Bulk Insert Optimization

```
-- x Loop mit einzelnen Inserts
FOR item IN input_items
 INSERT item INTO collection
-- 10k inserts = 10k Transaktionen, 10k fsync() Calls

-- Batch Insert
LET batch = input_items
INSERT batch INTO collection
-- 1 Transaktion, 1 fsync(), ~100x schneller
```

### Update Batching

```
-- x Einzelne Updates
FOR user IN users
 FILTER user.status == 'inactive'
 UPDATE user WITH {last_seen: NOW()}

-- Batch Update
LET inactive_users = (
 FOR u IN users
 FILTER u.status == 'inactive'
 RETURN u._id
)
FOR id IN inactive_users
 UPDATE {_id: id} WITH {last_seen: NOW()} IN users
```

## 34.7 Query Caching Patterns

### Result Caching

```
query_cache.py
from functools import lru_cache
import hashlib

class QueryCache:
 def __init__(self, ttl_seconds=300):
 self.ttl = ttl_seconds
 self.cache = {}
 self.timestamps = {}

 def cache_query(self, query_hash, result):
 self.cache[query_hash] = result
 self.timestamps[query_hash] = time.time()

 def get_cached(self, query_hash):
 if query_hash not in self.cache:
 return None

 age = time.time() - self.timestamps[query_hash]
 if age > self.ttl:
 del self.cache[query_hash]
 return None

 return self.cache[query_hash]
```

## AQL Query Fragment Caching

```
-- Häufig wiederholte Subqueries cachen
FUNCTION get_active_users_cached() {
 -- Cache-Key: hash(filter_conditions)
 RETURN (
 FOR user IN users
 FILTER user.status == 'active'
 FILTER user.verified == true
 SORT user.created_at DESC
 RETURN user
)
}

-- Nutze überall:
FOR user IN get_active_users_cached()
 RETURN user
```

---

## 34.8 Praktische Fallstudien

### Case 1: E-Commerce Produktsuche

#### Original Query (5s):

```
FOR product IN products
 FILTER LIKE(product.name, '%laptop%')
 FILTER product.price BETWEEN 500 AND 2000
 FILTER product.category IN ['electronics', 'computers']
 SORT product.popularity DESC
 LIMIT 20
 RETURN product
```

#### Optimiert (100ms - 50x schneller):

```
-- 1. Index: CREATE INDEX idx_cat_price ON products(category, price)
-- 2. Full-Text: CREATE FULLTEXT INDEX idx_name ON products(name)

FOR product IN products
 FILTER product.category IN ['electronics', 'computers']
 FILTER product.price BETWEEN 500 AND 2000
 FILTER product.available == true
 SEARCH product.name IN FULLTEXT('laptop')
 SORT product.popularity DESC
 LIMIT 20
 RETURN {_key: product._key, name: product.name, price: product.price}
```

## Case 2: Reporting Analytics

### Original (2 Minuten):

```
FOR order IN orders
 FOR item IN order.items
 COLLECT category = item.category
 AGGREGATE total = SUM(item.quantity * item.price)
 INTO result
 RETURN {category, total}
```

### Optimiert (2 Sekunden - 60x schneller):

```
FOR order IN orders
 FILTER order.status == 'completed'
 FILTER order.created_at >= '2024-01-01'
 FILTER order.created_at < '2025-01-01'
 FOR item IN order.items
 SORT item.category
 COLLECT category = item.category
 AGGREGATE total = SUM(item.quantity * item.price),
 count = COUNT(item)
 INTO result
 SORT result.category
 RETURN result
```

## 34.9 Performance Monitoring Dashboard

```
monitor_queries.py
class QueryPerformanceMonitor:
 def __init__(self):
 self.query_stats = {}

 def record_query(self, query_hash, execution_time_ms, rows):
 if query_hash not in self.query_stats:
 self.query_stats[query_hash] = {
 'count': 0,
 'total_time': 0,
 'max_time': 0,
 'avg_time': 0
 }

 stats = self.query_stats[query_hash]
 stats['count'] += 1
 stats['total_time'] += execution_time_ms
 stats['max_time'] = max(stats['max_time'], execution_time_ms)
 stats['avg_time'] = stats['total_time'] / stats['count']

 if execution_time_ms > 1000: # Flag slow queries
 print(f"⚠ SLOW: {query_hash} took {execution_time_ms}ms")

 def get_slowest_queries(self, top_n=10):
 sorted_queries = sorted(
 self.query_stats.items(),
 key=lambda x: x[1]['total_time'],
 reverse=True
)
 return sorted_queries[:top_n]
```

---

## Zusammenfassung

ThemisDB bietet mit EXPLAIN, Indexierung und Query-Refactoring Möglichkeiten für 10-100x Performance-Verbesserungen. Schlüssel sind: - **Early Filtering** - Filter so früh wie möglich - **Richtige Indizes** - Covering Indexes für Full Index Scans - **Batch Operations** - Nutze Bulk für viele Operationen - **Aggregation Optimization** - COLLECT mit Sort für Memory-Effizienz - **Monitoring** - PROFILE/EXPLAIN nutzen zur Diagnose

Mit diesen Techniken erreichen Sie Production-Grade Performance.

## Kapitel 35: Kapitel 35 - Data Modeling Patterns

---

*"Mit den gleichen Daten können Sie ein System entweder elegant oder chaotisch modellieren. Die richtige Struktur entscheidet über Erfolg oder Burnout."*

---

## Überblick

Data Modeling ist die Grundlage jeder erfolgreichen Datenbankanwendung. Dieses Kapitel zeigt bewährte Patterns und warnt vor häufigen Anti-Patterns, die zu technischen Schulden führen.

**Was Sie in diesem Kapitel lernen:** - Document Structure Patterns (Embedded vs Referenced) - Schema Design für verschiedene Use Cases - Versionierung und Schema-Evolution - Data Integrity Patterns - Denormalisierung vs Normalisierung - Multi-Model Design Patterns - Anti-Patterns und wie man sie vermeidet

---

Abb. 35.0: Data-Modeling-Patterns



## 35.1 Embedded vs Referenced Documents

### Pattern 1: Full Embedding

**Geeignet für:** One-to-Few Relationships

```
-- E-Commerce: Order mit Produktdetails embedded
{
 _key: "order_12345",
 customer_id: "cust_789",
 created_at: "2025-01-01T10:00:00Z",
 items: [
 {
 product_id: "prod_111",
 product_name: "Laptop", -- Embedded - COPY der Daten
 quantity: 1,
 price_at_purchase: 999.99
 },
 {
 product_id: "prod_222",
 product_name: "Mouse",
 quantity: 2,
 price_at_purchase: 19.99
 }
],
 total: 1039.97
}
```

**Vorteile:** - Atomare Updates (Order + Items = 1 Dokument) - Keine Joins nötig - Höchste Performance für Lesezugriffe - Natürliche Denormalisierung für Snapshot-Daten

**Nachteile:** - × Datenduplizierung (Produkt-Name in 1000 Orders) - × Updates komplex (100 Orders mit laptop aktualisieren?) - × Speicher-Overhead

**Best Practice:** Nutze für Snapshot-Daten (Preis zum Kaufzeitpunkt, nicht aktuelle Produkt-Info)

## Pattern 2: Reference Links

**Geeignet für:** One-to-Many und Many-to-Many

```
-- Order nur mit Referenzen:
{
 _key: "order_12345",
 customer_id: "cust_789",
 created_at: "2025-01-01T10:00:00Z",
 item_ids: ["oi_1001", "oi_1002"] -- Referenzen statt Embedding
}

-- Order Items separate Collection:
{
 _key: "oi_1001",
 order_id: "order_12345",
 product_id: "prod_111",
 quantity: 1,
 price: 999.99
}

-- Abfrage mit JOIN:
FOR order IN orders
 FILTER order._key == 'order_12345'
 FOR item IN order_items
 FILTER item._id IN order.item_ids
 RETURN {
 product: item.product_id,
 qty: item.quantity,
 price: item.price
 }
```

**Vorteile:** - Keine Datenduplizierung - Flexible Updates (Produkt-Name einmal ändern) - Speicher-effizient - Normalisiertes Design

**Nachteile:** - × JOINS nötig (Performance-Hit) - × Konsistenz-Komplexität (order + items = 2 Transaktionen?) - × Komplexere Queries

**Best Practice:** Nutze für Live-Daten (Produkt-Info, Benutzer-Profil)

---

## 35.2 Hybrid Pattern: Optimal Denormalization

```
-- BESTE LÖSUNG: Balance zwischen beiden
{
 _key: "order_12345",
 customer_id: "cust_789",
 created_at: "2025-01-01T10:00:00Z",
 items: [
 {
 order_item_id: "oi_1001", -- Referenz
 product_id: "prod_111", -- Referenz
 product_name: "Laptop", -- Denormalisiert (Snapshot)
 quantity: 1,
 price_at_purchase: 999.99 -- Snapshot (nicht ändern)
 }
],
 customer_name: "Alice", -- Denormalisiert für Report
 customer_email: "alice@example.com",
 total: 1039.97,
 last_modified: "2025-01-01T10:00:00Z"
}

-- + Separate Product Collection für Live-Updates:
{
 _key: "prod_111",
 name: "Laptop",
 description: "Latest model", -- Änderungen nur hier
 price: 899.99, -- Aktueller Preis (nicht im Order)
 availability: "in_stock"
}
```

**Strategie:** - **Embedded:** Snapshot-Daten (was zum Kaufzeitpunkt galt) - **Referenced:** Live-Daten (aktuelle Zustand) - **Join bei Bedarf:** Nur wenn aktuelle Info nötig

## 35.3 Schema Evolution Patterns

### Forward Compatibility

```
-- Version 1: Alte Struktur
{
 _key: "user_123",
 name: "Alice",
 email: "alice@example.com"
}

-- Version 2: Neue Felder (backward compatible!)
{
 _key: "user_123",
 name: "Alice",
 email: "alice@example.com",
 phone: "+49123456789", -- Neu, optional
 address: { -- Neu, nested
 street: "Main St",
 city: "Berlin"
 },
 metadata: { -- Neu, extensible
 last_login: "2025-01-01",
 login_count: 42
 }
}

-- Abfrage muss robust sein:
FOR user IN users
 FILTER user.email == 'alice@example.com'
 RETURN {
 name: user.name,
 phone: user.phone ?? "unknown", -- Null coalescing
 city: user.address.city ?? "unknown"
 }
```

## Versioned Collections

```
-- Collections mit Version in _key
-- users_v1: Alte Version (archiviert)
-- users_v2: Neue Version (aktiv)

-- Migration:
FOR user IN users_v1
 INSERT {
 name: user.name,
 email: user.email,
 phone: null,
 address: null,
 created_from_v1: true
 } INTO users_v2

-- Dual-Write Phase (Rollout):
-- 1. Writes zu v1 UND v2 (2 Sekunden länger)
-- 2. Reads von v2, Fallback zu v1
-- 3. Nach Verification: nur v2
-- 4. v1 Cleanup nach 30 Tagen
```

## 35.4 Data Integrity Patterns

### Constraints und Validation

```
-- Validation in Insert Trigger
FUNCTION validate_user(user) {
 IF !LIKE(user.email, '%@%.%') THEN
 THROW ERROR('Invalid email format')
 END

 IF user.age < 0 OR user.age > 150 THEN
 THROW ERROR('Age must be 0-150')
 END

 IF !HAS(user, 'name') OR LENGTH(user.name) < 1 THEN
 THROW ERROR('Name is required')
 END

 RETURN user
}

-- Trigger bei Insert:
INSERT validate_user(new_user) INTO users
```

## Referential Integrity

```
-- Before Delete: Check for References
FUNCTION can_delete_product(product_id) {
 LET order_count = LENGTH(
 FOR oi IN order_items
 FILTER oi.product_id == product_id
 RETURN oi
)

 IF order_count > 0 THEN
 THROW ERROR(
 CONCAT("Cannot delete: ", order_count, " orders reference this product")
)
 END

 RETURN true
}

-- Soft Delete Pattern (meist besser):
UPDATE {_id: product_id} WITH {
 deleted_at: NOW(),
 is_deleted: true
} IN products

-- Queries filtern automatisch:
FOR prod IN products
 FILTER !prod.is_deleted
 RETURN prod
```

## **35.5 Common Anti-Patterns & Fixes**

### **Anti-Pattern 1: Unbounded Arrays**



```
-- x FALSCH: Array wächst unbegrenzt
{
 _key: "user_123",
 comments: [-- Kann 1M Items enthalten!
 {id: "c1", text: "Hello"},
 {id: "c2", text: "Hi"},
 ... (1M mehr)
]
}

-- Problem: Jeder Update des Users ändert Array
-- Memory: 1M Items im RAM
-- Performance: O(n) für jeden Insert

-- RICHTIG: Separate Collection
{
 _key: "user_123",
 comment_count: 1000000
}

{
 _key: "comment_12345",
 user_id: "user_123",
 text: "Hello",
 created_at: "2025-01-01T10:00:00Z"
}

-- Abfrage:
FOR user IN users
 FILTER user._key == 'user_123'
 FOR comment IN comments
 FILTER comment.user_id == user._key
 SORT comment.created_at DESC
 LIMIT 20
 RETURN comment
```

## Anti-Pattern 2: Wide Documents

```
-- x FALSCH: Ein Dokument mit 500+ Felder
{
 _key: "product_123",
 name: "...",
 description: "...",
 color_red: 0.9,
 color_green: 0.1,
 color_blue: 0.05,
 ... (500 mehr Felder)
}

-- RICHTIG: Nested Objects für Kategorien
{
 _key: "product_123",
 name: "Laptop",
 description: "...",
 appearance: {
 color: {r: 0.9, g: 0.1, b: 0.05},
 material: "aluminium"
 },
 specs: {
 cpu: "Intel i9",
 ram: "32GB",
 storage: "1TB SSD"
 },
 pricing: {
 list_price: 1999.99,
 discount_percent: 10,
 final_price: 1799.99
 }
}
```

## Anti-Pattern 3: Sparse Indexes on Many Fields

```
-- x FALSCH: Index pro optionales Feld
CREATE INDEX idx_phone ON users(phone)
CREATE INDEX idx_mobile ON users(mobile)
CREATE INDEX idx_fax ON users(fax)
-- 3 Indizes, 70% davon sind NULL

-- RICHTIG: One General Contact Index
{
 _key: "user_123",
 contact: {
 phone: "+49123456789",
 mobile: null,
 fax: null,
 email: "alice@example.com"
 }
}

CREATE SPARSE INDEX idx_contact ON users(contact)

-- Abfrage:
FOR user IN users
 FILTER user.contact.phone != null
 FILTER LIKE(user.contact.phone, '%123%')
RETURN user
```

---

## 35.6 Multi-Model Design Patterns

**Pattern: Document + Graph**

```
-- Documents: User Profile
{
 _key: "user_123",
 name: "Alice",
 email: "alice@example.com"
}

-- Graph: User Relationships
{
 _key: "follows_123_456",
 _from: "users/123",
 _to: "users/456",
 followed_at: "2025-01-01",
 type: "follows"
}

-- Query: Netzwerk-Analyse
FOR user IN users
 FILTER user.email == 'alice@example.com'
 LET followers = (
 FOR follower IN users
 ANY INBOUND user GRAPH 'social_graph'
 RETURN follower
)
 LET following = (
 FOR following_user IN users
 ANY OUTBOUND user GRAPH 'social_graph'
 RETURN following_user
)
 RETURN {
 user: user.name,
 followers_count: LENGTH(followers),
 following_count: LENGTH(following)
 }
```

## Pattern: Document + Vector + Search

```
-- Documents: Articles
{
 _key: "article_123",
 title: "Machine Learning Basics",
 content: "...",
 vector: [0.2, 0.5, 0.1, ...] -- 1536-dim embedding
}

-- Vector Search + Full-Text
FOR article IN articles
 SEARCH article.vector ANN {
 query: [0.1, 0.4, 0.2, ...],
 top_k: 10
 }
 SEARCH PHRASE(article.title, 'machine learning', 'title')
 OR PHRASE(article.content, 'neural networks')
RETURN {
 title: article.title,
 similarity: article._score
}
```

---

## 35.7 Practical Migration Patterns

### Blue-Green Deployment

```
-- Phase 1: Parallel Execution
-- - Write zu v1 UND v2
-- - Read von v1 (stabil)

-- Phase 2: Validation
-- - Vergleiche v1 vs v2 Ergebnisse
-- - Prüfe auf Datenabweichungen

-- Phase 3: Cutover
-- - Schreib-Lock auf v1
-- - Letzte Sync v1 → v2
-- - Schreib-Lock freigeben auf v2
-- - Reads → v2

-- Phase 4: Cleanup
-- - Nach 30 Tagen: v1 Archivieren
-- - Nach 90 Tagen: v1 Löschen
```

---

## Zusammenfassung

Gutes Data Modeling ist Kunst und Wissenschaft: - **Embedded:** Für Snapshots (Preis zum Kaufzeitpunkt) - **Referenced:** Für Live-Daten (aktuelle Produkt-Info) - **Hybrid:** Kombination für beste Performance - **Versionsiert:** Schema-Evolution mit Sicherheit - **Validated:** Constraints at Insert-Time - **Separat:** Arrays/Felder in eigene Collections - **Nested:** Wide Documents mit Struktur - **Monitored:** Indizes auf Query-Patterns

Mit diesen Patterns bauen Sie skalierbare, wartbare Datenmodelle.

# Kapitel 36: Kapitel 36 - Security Hardening

---

*"Security ist kein Feature, es ist Architektur. Ein sicheres System ist gebaut von innen heraus, nicht bolzen-on later."*

---

## Überblick

Dieses Kapitel bietet Praktiker-Anleitungen für Production-Grade Security in ThemisDB. Von grundlegenden Authentifizierungspattern bis zu erweiterten Threat-Mitigation-Strategien.

**Was Sie in diesem Kapitel lernen:** - Network Segmentation und Firewall Rules - Authentication & Authorization Patterns - End-to-End Encryption - SQL Injection & Injection Attack Prevention - Access Control Lists (ACL) & Role-Based Access Control (RBAC) - Audit Logging & Intrusion Detection - Secrets Management - Compliance & Regulatory Frameworks - Incident Response Playbooks

---

Abb. 36.0: Security-Layers: Defense in Depth



## 36.1 Network Security

### Firwall-Regeln

```
themis-firewall.yaml

rules:
 # Externe API -> ThemisDB
 - name: "Allow API Gateway"
 type: "inbound"
 protocol: "tcp"
 port: 8529
 source: "10.0.1.0/24" # API Gateway subnet
 action: "allow"

 # Client App -> ThemisDB
 - name: "Allow App Servers"
 type: "inbound"
 protocol: "tcp"
 port: 8529
 source: "10.0.2.0/24" # App subnet
 action: "allow"

 # Replication zwischen Nodes
 - name: "Allow Replication"
 type: "inbound"
 protocol: "tcp"
 port: 8628
 source: "10.0.3.0/24" # Cluster subnet
 action: "allow"

 # Deny All (Default)
 - name: "Deny All"
 type: "inbound"
 protocol: "all"
 action: "deny"
```

## TLS/SSL Configuration

```
themis.conf - Security Section
security:
 tls:
 enabled: true
 version: "1.3" # Minimum
 certificate_path: "/etc/themis/certs/server.crt"
 key_path: "/etc/themis/certs/server.key"
 cipher_suites:
 - "TLS_AES_256_GCM_SHA384"
 - "TLS_CHACHA20_POLY1305_SHA256"
 - "TLS_AES_128_GCM_SHA256"
 verify_client: true # Mutual TLS
 client_ca_path: "/etc/themis/certs/client-ca.crt"
```

## 36.2 Authentication & Authorization

### RBAC (Role-Based Access Control)

```
-- Define roles
FUNCTION create_role(role_name, permissions) {
 RETURN INSERT {
 role: role_name,
 permissions: permissions,
 created_at: NOW()
 } INTO roles
}

-- Example: Reader role
LET reader_perms = {
 collections: {
 "*": ["read"] -- All collections, read-only
 },
 functions: ["all"] -- Can call all functions
}

-- Create reader role
create_role("reader", reader_perms)

-- Assign user to role
UPDATE {_id: "users/alice"} WITH {
 roles: ["reader"],
 role_updated_at: NOW()
} IN users
```

## JWT Token Validation

```
auth.py
import jwt
from datetime import datetime, timedelta
import hashlib

class JWTAuthenticator:
 def __init__(self, secret_key):
 self.secret_key = secret_key
 self.algorithm = "HS256"

 def create_token(self, user_id, roles, expires_in=3600):
 payload = {
 "user_id": user_id,
 "roles": roles,
 "iat": datetime.utcnow(),
 "exp": datetime.utcnow() + timedelta(seconds=expires_in)
 }
 token = jwt.encode(payload, self.secret_key, algorithm=self.algorithm)
 return token

 def verify_token(self, token):
 try:
 payload = jwt.decode(token, self.secret_key, algorithms=[self.algorithm])
 return payload
 except jwt.ExpiredSignatureError:
 raise Exception("Token has expired")
 except jwt.InvalidTokenError:
 raise Exception("Invalid token")

 def get_user_permissions(self, payload):
 user_id = payload["user_id"]
 roles = payload["roles"]
 # Lookup permissions from database
 return {"roles": roles, "timestamp": datetime.utcnow()}
```

## 36.3 Encryption Patterns

### Field-Level Encryption

```
-- Encrypt sensitive fields before storage
FUNCTION encrypt_field(value, key) {
 -- Use ThemisDB's built-in CRYPTO_ENCRYPT function
 RETURN CRYPTO_ENCRYPT(value, key, 'AES-256-GCM')
}

-- Store with encrypted field
INSERT {
 user_id: 'user_123',
 name: 'Alice',
 email: encrypt_field('alice@example.com', encryption_key),
 ssn: encrypt_field('123-45-6789', encryption_key),
 created_at: NOW()
} INTO users

-- Decrypt on read
FOR user IN users
 FILTER user.user_id == 'user_123'
 LET decrypted_email = CRYPTO_DECRYPT(user.email, encryption_key)
 RETURN {
 name: user.name,
 email: decrypted_email
 }
```

**End-to-End Encryption (E2EE)**

```
e2e_crypto.py
from cryptography.hazmat.primitives import hashes
from cryptography.hazmat.primitives.asymmetric import rsa, padding
from cryptography.hazmat.backends import default_backend

class E2EEncryption:
 def __init__(self):
 self.backend = default_backend()

 def generate_keypair(self):
 """Generate RSA keypair for client"""
 private_key = rsa.generate_private_key(
 public_exponent=65537,
 key_size=4096,
 backend=self.backend
)
 public_key = private_key.public_key()
 return private_key, public_key

 def encrypt_message(self, message, public_key):
 """Encrypt message with public key"""
 ciphertext = public_key.encrypt(
 message.encode(),
 padding.OAEP(
 mgf=padding.MGF1(algorithm=hashes.SHA256()),
 algorithm=hashes.SHA256(),
 label=None
)
)
 return ciphertext.hex()

 def decrypt_message(self, ciphertext_hex, private_key):
 """Decrypt with private key (only client)"""
 ciphertext = bytes.fromhex(ciphertext_hex)
 plaintext = private_key.decrypt(
 ciphertext,
 padding.OAEP(
 mgf=padding.MGF1(algorithm=hashes.SHA256()),
```

```
 algorithm=hashes.SHA256(),
 label=None
)
)
return plaintext.decode()
```

## 36.4 Injection Prevention

### AQL Injection Protection

```
-- x UNSAFE: User input directly in query
FUNCTION unsafe_search(search_term) {
 RETURN EXECUTE(
 CONCAT("FOR doc IN collection FILTER LIKE(doc.name, '%", search_term, "%') RETURN doc")
)
 -- Attacker can inject: %') OR (1==1) //'
}

-- SAFE: Parameterized queries
FUNCTION safe_search(search_term) {
 RETURN (
 FOR doc IN collection
 FILTER LIKE(doc.name, @search_pattern)
 RETURN doc
)
}

-- Call with bound parameters:
safe_search('@search_pattern', '%term%')
```



## Input Validation

```
validation.py
import re
from typing import Any, Dict

class InputValidator:
 @staticmethod
 def validate_email(email: str) -> bool:
 pattern = r'^[a-zA-Z0-9._%+-]+@[a-zA-Z0-9.-]+\.[a-zA-Z]{2,}$'
 return re.match(pattern, email) is not None

 @staticmethod
 def validate_aql_identifier(identifier: str) -> bool:
 # Only allow alphanumeric and underscore
 pattern = r'^[a-zA-Z_][a-zA-Z0-9_]*$'
 return re.match(pattern, identifier) is not None

 @staticmethod
 def sanitize_collection_name(name: str) -> str:
 # Whitelist: only alphanumeric, underscore, dash
 sanitized = re.sub(r'^[a-zA-Z0-9_\-]', '', name)
 return sanitized.lower()

 @staticmethod
 def validate_query_size(query: str, max_size: int = 10000) -> bool:
 return len(query) <= max_size
```

## 36.5 Audit Logging

### Comprehensive Audit Trail

```
-- Log all operations
FUNCTION audit_log(operation, user_id, resource, changes) {
 RETURN INSERT {
 timestamp: NOW(),
 operation: operation, -- "INSERT", "UPDATE", "DELETE"
 user_id: user_id,
 resource: resource, -- "users/123"
 changes: changes, -- {field: old_value -> new_value}
 ip_address: @ip_address,
 user_agent: @user_agent
 } INTO audit_logs
}

-- Usage:
UPDATE {_id: 'users/123'} WITH {email: 'new@example.com'}
audit_log('UPDATE', 'admin_001', 'users/123', {
 email: 'old@example.com' -> 'new@example.com'
})
```

## Immutable Audit Log

```
audit_storage.py

class ImmutableAuditLog:
 def __init__(self, db):
 self.db = db

 def append_log(self, log_entry):
 """Append-only: cannot update/delete"""
 # Insert with timestamp
 log_entry['_timestamp'] = time.time()
 log_entry['_hash'] = self._compute_hash(log_entry)

 # Previous entry's hash
 last_entry = self.db.get_last_audit_log()
 if last_entry:
 log_entry['_previous_hash'] = last_entry['_hash']

 return self.db.insert_audit_log(log_entry)

 def _compute_hash(self, entry):
 """Cryptographic hash for integrity"""
 import hashlib
 content = json.dumps(entry, sort_keys=True)
 return hashlib.sha256(content.encode()).hexdigest()

 def verify_integrity(self):
 """Detect tampering by verifying hash chain"""
 logs = self.db.get_all_audit_logs()
 for i, log in enumerate(logs):
 if i > 0:
 prev_log = logs[i-1]
 if log['_previous_hash'] != prev_log['_hash']:
 raise Exception(f"Integrity violation at log {i}")
```

## 36.6 Secrets Management

### Kubernetes Secrets Integration

```
kubernetes-secret.yaml
apiVersion: v1
kind: Secret
metadata:
 name: themis-secrets
 namespace: themis
type: Opaque
stringData:
 # Database encryption key
 database_key: "base64_encoded_key_here"

 # TLS certificates
 tls_cert: |
 -----BEGIN CERTIFICATE-----
 ...
 -----END CERTIFICATE-----

 tls_key: |
 -----BEGIN PRIVATE KEY-----
 ...
 -----END PRIVATE KEY-----

 # API keys for external services
 stripe_api_key: "sk_live_..."
 sendgrid_api_key: "SG...."
```

## Vault Integration

```
secrets_manager.py
import hvac
import os

class VaultSecretsManager:
 def __init__(self, vault_addr, token):
 self.client = hvac.Client(url=vault_addr, token=token)

 def get_secret(self, secret_path):
 response = self.client.secrets.kv.v2.read_secret_version(
 path=secret_path
)
 return response['data']['data']

 def rotate_database_key(self):
 """Rotate encryption key - called before data re-encryption"""
 new_key = os.urandom(32) # 256-bit key
 self.client.secrets.kv.v2.create_or_update_secret(
 path="themis/database_key",
 secret_dict={"key": new_key.hex()}
)
 return new_key
```

## 36.7 Compliance & Regulatory

### GDPR Compliance

```
-- Right to be forgotten: Pseudonymization
FUNCTION gdpr_pseudonymize_user(user_id) {
 LET user = DOCUMENT('users/' + user_id)

 UPDATE {_id: 'users/' + user_id} WITH {
 email: HASH(user.email),
 phone: null,
 address: null,
 name: "Anonymized User",
 gdpr_deleted_at: NOW(),
 is_pseudonymized: true
 } IN users

 -- Also delete from audit logs
 REMOVE l IN audit_logs
 FILTER l.resource == CONCAT('users/', user_id)
}
```

## SOC 2 Compliance Checklist

### ## SOC 2 Type II Compliance

- [ ] **\*\*Access Control\*\***
  - [ ] Multi-factor authentication (MFA)
  - [ ] Role-based access control (RBAC)
  - [ ] Audit logging of all access
- [ ] **\*\*Data Security\*\***
  - [ ] End-to-end encryption (AES-256)
  - [ ] Field-level encryption for PII
  - [ ] Secure key management (Vault)
- [ ] **\*\*Availability\*\***
  - [ ] 99.99% uptime SLA
  - [ ] Automated failover
  - [ ] Regular disaster recovery tests
- [ ] **\*\*Monitoring & Logging\*\***
  - [ ] 24/7 intrusion detection
  - [ ] Immutable audit logs
  - [ ] Real-time alerting
- [ ] **\*\*Incident Response\*\***
  - [ ] Documented IR procedures
  - [ ] Regular tabletop exercises
  - [ ] <1 hour incident response time

## 36.8 Incident Response Playbook

### Detection

```
-- Detect unusual access patterns
FUNCTION detect_brute_force(user_id, threshold = 5) {
 LET failed_logins = LENGTH(
 FOR log IN audit_logs
 FILTER log.user_id == user_id
 FILTER log.operation == 'FAILED_LOGIN'
 FILTER log.timestamp > DATE_SUBTRACT(NOW(), 1, 'hour')
 RETURN log
)

 IF failed_logins >= threshold THEN
 RETURN {
 alert: "BRUTE_FORCE_DETECTED",
 user_id: user_id,
 failed_count: failed_logins,
 action: "LOCK_ACCOUNT"
 }
 END

 RETURN {alert: "normal"}
}
```



## Response

```
incident_response.py
class IncidentResponse:
 def lock_account(self, user_id):
 """Lock account immediately"""
 db.update_user(user_id, {'locked': True, 'locked_at': now()})

 def notify_security_team(self, incident):
 """Alert security team"""
 slack.send_message(f" SECURITY ALERT: {incident['alert']}")
 email.send_alert(incident)

 def revoke_tokens(self, user_id):
 """Invalidate all active tokens"""
 db.delete_user_sessions(user_id)

 def isolate_database(self):
 """Disable external access"""
 firewall.block_external_connections()

 def preserve_evidence(self):
 """Archive logs for forensic analysis"""
 backup.create_forensic_snapshot()
```

---

## Zusammenfassung

Production-Sicherheit erfordert: - **Network Segmentation** - Firewall rules, TLS 1.3 - **Authentication** - JWT, MFA, RBAC - **Encryption** - AES-256 field-level, E2E - **Input Validation** - Parameterized queries, sanitization - **Audit Logging** - Immutable logs, integrity checks - **Secrets Management** - Vault, rotation - **Compliance** - GDPR, SOC 2, audit trails - **Incident Response** - Playbooks, automation

Mit diesen Patterns bauen Sie ein **Defense-in-Depth** System, wo mehrere Sicherheitsebenen zusammenarbeiten.

# Kapitel 37: Kapitel 37 - Ecosystem Integration

---

*"ThemisDB ist nicht nur eine Datenbank - es ist die Mittellage in einem größeren Ökosystem von Tools, Services und Integrationen."*

---

## Überblick

Dieses Kapitel zeigt, wie ThemisDB mit externen Systemen integriert wird und wie Sie Custom Extensions schreiben, um ThemisDB an spezifische Anforderungen anzupassen.

**Was Sie in diesem Kapitel lernen:** - Native Integrations mit populären Tools - Custom Function Development - Plugin Architecture - Webhook & Event Streaming - Third-party Library Support - Custom Data Type Extensions - Performance Monitoring Integrations - Cross-database Synchronization

---

Abb. 37.0: Integration mit externen Systemen

---

## 37.1 Beliebte Integrationen

### Elasticsearch Integration

```
elasticsearch_sync.py
from elasticsearch import Elasticsearch
import themis_client

class ElasticsearchSync:
 def __init__(self, themis_conn, es_host='localhost:9200'):
 self.themis = themis_client.connect(themis_conn)
 self.es = Elasticsearch([es_host])

 def sync_documents_to_elasticsearch(self, collection_name, query=None):
 """Sync ThemisDB documents to Elasticsearch"""
 # Query documents from ThemisDB
 aql = f"FOR doc IN {collection_name}"
 if query:
 aql += f" FILTER {query}"
 aql += " RETURN doc"

 docs = self.themis.execute(aql)

 # Bulk insert into Elasticsearch
 from elasticsearch.helpers import bulk
 actions = [
 {
 "_index": collection_name,
 "_id": doc['_id'],
 "_source": doc
 }
 for doc in docs
]

 bulk(self.es, actions)
 return len(actions)

 def search_with_fallback(self, query, collection_name):
 """Search in Elasticsearch, fallback to ThemisDB"""
 try:
 # Try ES first (faster)
 results = self.es.search(
```

```
 index=collection_name,
 body={"query": {"match": {"_all": query}}}
)
 return results['hits']['hits']
except Exception:
 # Fallback to ThemisDB full-text search
 aql = f"FOR doc IN {collection_name} SEARCH {query} RETURN doc"
 return self.themis.execute(aql)
```

## Kafka Event Streaming

```
kafka-integration.yaml
themes_db_events:
 topics:
 - name: "themis.inserts"
 partitions: 10
 retention: "7d"
 events: "INSERT operations"

 - name: "themis.updates"
 partitions: 10
 retention: "7d"
 events: "UPDATE operations"

 - name: "themis.deletes"
 partitions: 10
 retention: "7d"
 events: "DELETE operations"

 producers:
 - name: "themis-cdc"
 topics: ["themis.inserts", "themis.updates", "themis.deletes"]
 format: "avro"
 compression: "snappy"

 consumers:
 - name: "elasticsearch-sync"
 topics: ["themis.*"]
 group_id: "es-sync-group"

 - name: "analytics-pipeline"
 topics: ["themis.*"]
 group_id: "analytics-group"
```

**Prometheus Metrics**

```
prometheus_integration.py
from prometheus_client import Counter, Histogram, Gauge
import themis_client

class ThemisPrometheus:
 def __init__(self):
 # Operation counters
 self.query_counter = Counter(
 'themis_queries_total',
 'Total queries executed',
 ['operation_type', 'collection']
)

 # Query latency histogram
 self.query_latency = Histogram(
 'themis_query_duration_seconds',
 'Query execution time',
 ['operation_type'],
 buckets=[0.001, 0.01, 0.1, 1, 10]
)

 # Database size gauge
 self.db_size = Gauge(
 'themis_database_bytes',
 'Database size in bytes'
)

 # Connection pool
 self.active_connections = Gauge(
 'themis_connections_active',
 'Active database connections'
)

 def record_query(self, operation_type, collection, duration_ms):
 self.query_counter.labels(
 operation_type=operation_type,
 collection=collection
).inc()
```



```
self.query_latency.labels(
 operation_type=operation_type
)observe(duration_ms / 1000)
```

## 37.2 Custom Function Development

### Creating Custom AQL Functions

```
-- Register custom function
FUNCTION CUSTOM_DISTANCE(lat1, lon1, lat2, lon2) {
 -- Haversine distance formula
 LET R = 6371 -- Earth radius in km
 LET dLat = RADIANS(lat2 - lat1)
 LET dLon = RADIANS(lon2 - lon1)
 LET a = POWER(SIN(dLat/2), 2) + COS(RADIANS(lat1)) * COS(RADIANS(lat2)) * POWER(SIN(dLon/2), 2)
 LET c = 2 * ASIN(SQRT(a))
 RETURN R * c
}

-- Usage:
FOR user IN users
 LET distance = CUSTOM_DISTANCE(
 51.5074, -0.1278, -- London coords
 user.latitude, user.longitude
)
 FILTER distance < 10 -- Within 10km
 RETURN {name: user.name, distance: distance}
```

## External Function Binding (C++)

```
// custom_functions.cpp
#include <aql/function_registry.h>

class CustomFunctions : public FunctionRegistry {
public:
 Value distance_haversine(
 Value lat1, Value lon1,
 Value lat2, Value lon2
) {
 const double R = 6371; // Earth radius
 double dLat = (lat2.asDouble() - lat1.asDouble()) * M_PI / 180;
 double dLon = (lon2.asDouble() - lon1.asDouble()) * M_PI / 180;

 double a = sin(dLat/2) * sin(dLat/2) +
 cos(lat1.asDouble() * M_PI / 180) *
 cos(lat2.asDouble() * M_PI / 180) *
 sin(dLon/2) * sin(dLon/2);

 double c = 2 * asin(sqrt(a));
 return Value::fromDouble(R * c);
 }
};

// Register at startup
REGISTER_FUNCTION("CUSTOM_DISTANCE", &CustomFunctions::distance_haversine);
```

## 37.3 Plugin Architecture

### Creating a Plugin

```
custom_plugin.py
from themis_plugin_api import Plugin, Hook

class MyAnalyticsPlugin(Plugin):
 name = "my-analytics"
 version = "1.0.0"
 description = "Custom analytics for ThemisDB"

 def on_insert(self, collection, document):
 """Called after INSERT"""
 self.log_event('insert', collection, document)
 self.update_analytics(collection)

 def on_update(self, collection, old_doc, new_doc):
 """Called after UPDATE"""
 self.log_event('update', collection, new_doc)
 self.track_changes(old_doc, new_doc)

 def on_delete(self, collection, document):
 """Called after DELETE"""
 self.log_event('delete', collection, document)
 self.update_analytics(collection)

 def log_event(self, operation, collection, doc):
 event = {
 'operation': operation,
 'collection': collection,
 'timestamp': now(),
 'doc_id': doc['_id']
 }
 self.db.insert_event(event)

 def update_analytics(self, collection):
 # Compute analytics stats
 count = self.db.count(collection)
 avg_size = self.db.avg_document_size(collection)
 self.db.update_analytics({
 'collection': collection,
```

```
 'count': count,
 'avg_size': avg_size
 })
```

## Plugin Configuration

```
plugins.yaml
plugins:
 - name: my-analytics
 enabled: true
 config:
 event_log_collection: "analytics_events"
 update_interval_seconds: 60

 - name: elasticsearch-sync
 enabled: true
 config:
 es_host: "localhost:9200"
 sync_interval_seconds: 5

 - name: slack-notifications
 enabled: true
 config:
 webhook_url: "${SLACK_WEBHOOK_URL}"
 notify_on: ["high_latency", "errors", "replication_lag"]
```

## 37.4 Webhooks & Events

### Webhook Configuration

```
-- Register webhook
FUNCTION create_webhook(url, collection, events) {
 RETURN INSERT {
 url: url,
 collection: collection,
 events: events, -- ["insert", "update", "delete"]
 active: true,
 created_at: NOW(),
 retry_count: 0,
 last_triggered: null
 } INTO webhooks
}

-- Setup:
create_webhook(
 'https://api.example.com/webhooks/themis',
 'users',
 ['insert', 'update']
)
```

## Event Payload

```
{
 "event_id": "evt_abc123",
 "timestamp": "2026-01-01T09:00:00Z",
 "event_type": "insert",
 "collection": "users",
 "document": {
 "_id": "users/123",
 "_key": "123",
 "name": "Alice",
 "email": "alice@example.com"
 },
 "metadata": {
 "version": "1.3.1",
 "source": "direct_insert",
 "user_id": "admin_001"
 }
}
```

**Webhook Handler Implementation**



```
webhook_handler.py
from flask import Flask, request
import hmac
import hashlib
import json

app = Flask(__name__)
WEBHOOK_SECRET = "your-secret-key"

@app.route('/webhooks/themis', methods=['POST'])
def handle_themis_webhook():
 # Verify signature
 signature = request.headers.get('X-Themis-Signature')
 body = request.get_data()

 expected_sig = hmac.new(
 WEBHOOK_SECRET.encode(),
 body,
 hashlib.sha256
).hexdigest()

 if not hmac.compare_digest(signature, expected_sig):
 return {'error': 'Invalid signature'}, 401

 # Process event
 event = request.json
 if event['event_type'] == 'insert':
 handle_user_insert(event['document'])
 elif event['event_type'] == 'update':
 handle_user_update(event['document'])

 return {'ok': True}, 200

def handle_user_insert(user):
 # Send welcome email
 send_email(user['email'], 'welcome!')

 # Add to mailing list
```

```
add_to_newsletter(user['email'])

def handle_user_update(user):
 # Update external systems
 sync_to_crm(user)
```

---

## 37.5 Data Type Extensions

### Custom Scalar Type

```
// custom_types.cpp
class PhoneNumber {
public:
 std::string country_code;
 std::string area_code;
 std::string number;

 std::string toString() {
 return country_code + " (" + area_code + ") " + number;
 }

 static PhoneNumber fromString(const std::string& str) {
 // Parse format: "+1 (555) 1234567"
 PhoneNumber phone;
 // ... parsing logic
 return phone;
 }
};

// Register with ThemisDB type system
REGISTER_CUSTOM_TYPE("PhoneNumber", PhoneNumber);

// Use in AQL:
// INSERT {phone: PhoneNumber("+1 (555) 1234567")} INTO users
```

---

## 37.6 Cross-Database Synchronization

### Bidirectional Sync with PostgreSQL

```

sync_postgres.py
import psycopg2
import themis_client

class PostgresThemisSync:
 def __init__(self, themis_conn, pg_conn):
 self.themis = themis_client.connect(themis_conn)
 self.pg = psycopg2.connect(pg_conn)

 def sync_themis_to_postgres(self, collection, pg_table):
 """ThemisDB → PostgreSQL"""
 # Read from ThemisDB
 docs = self.themis.execute(
 f"FOR doc IN {collection} RETURN doc"
)

 # Write to PostgreSQL
 cursor = self.pg.cursor()
 for doc in docs:
 cursor.execute(
 f"INSERT INTO {pg_table} VALUES (%s, %s, %s) "
 f"ON CONFLICT (_id) DO UPDATE SET data = %s",
 (doc['_id'], doc['_rev'], json.dumps(doc), json.dumps(doc))
)

 self.pg.commit()
 cursor.close()

 def sync_postgres_to_themis(self, pg_table, collection):
 """PostgreSQL → ThemisDB"""
 cursor = self.pg.cursor()
 cursor.execute(f"SELECT * FROM {pg_table} WHERE updated_at > %s", (self.last_sync,))

 rows = cursor.fetchall()
 for row in rows:
 doc = self._row_to_doc(row)
 self.themis.execute(
 f"UPSERT {{'_id': {doc['_id']}}} "

```

```
f"INSERT {doc} "
f"INTO {collection}"
)

cursor.close()
```

---

## Zusammenfassung

ThemisDB-Ökosystem bietet: - **Native Integrations** - Elasticsearch, Kafka, Prometheus - **Custom Functions** - AQL + C++ für Domain-Logik - **Plugins** - Extensible hooks für Custom Behavior - **Webhooks** - Event-driven integrations - **Custom Types** - Domain-specific data types - **Cross-DB Sync** - Bidirektional mit PostgreSQL, MongoDB - **Open API** - Python, Go, JavaScript SDKs

Mit diesen Tools integrieren Sie ThemisDB in jedes bestehende System.

---

## Kapitel 38: Kapitel 38 - Observability & SRE

*"Ohne Metriken, Logs und Traces bleiben Incidents Rätselraten. Observability ist die Brücke zwischen Symptom und Ursache."*

---

## Überblick

Dieses Kapitel liefert ein praktisches Observability- und SRE-Playbook für ThemisDB-Deployments. Es bündelt Metriken, Logs, Traces, Dashboards, SLOs, Alerts und Runbooks.

**Was Sie lernen:** - Kernmetriken (DB, System, Netzwerk) - Log-Formate, Parsing, Korrelation - Distributed Tracing für AQL Requests - Dashboards für Latenz, Fehler, Replikation, Speicherdruck - SLO/SLI-Definitionen und Error Budgets - Alerting-Design und Rauschreduktion - Runbooks für die häufigsten Störungen - Chaos- und GameDay-Checklisten

**Voraussetzungen:** Basiswissen aus Monitoring (Kapitel 19) und Troubleshooting (Kapitel 27).

---

Abb. 38.0: Observability-Säulen

---

## 38.1 Metriken (What to Measure)

### Core DB Metriken

- Query Latenz (p50/p95/p99)
- Query Throughput (qps)
- Slow Queries count
- Active Connections
- Replication Lag (ms)
- WAL/Commit Queue Depth
- Memory Usage (RSS, Cache Hit Rate)
- Disk IO (IOPS, Latency, Queue Depth)
- Index Hit Rate
- Cache Evictions

### System Metriken

- CPU: user/system/iowait
- Memory: used, available, page faults
- Disk: iops, latency, utilization
- Network: rx/tx bytes, errors, retransmits

### AQL-Spezifisch

- Query Type Mix (read/write/graph/vector)
- Cursor Count / Leaks
- Transaction Duration
- Deadlocks detected
- Timeouts per operation

## 38.2 Logging

### Strukturierte Logs

```
{
 "ts": "2026-01-01T10:00:00Z",
 "level": "INFO",
 "service": "themisdb",
 "component": "aql",
 "event": "query_executed",
 "trace_id": "abc123",
 "span_id": "def456",
 "duration_ms": 32,
 "collection": "users",
 "operation": "READ",
 "status": "ok"
}
```

**Best Practices:** - JSON Lines, ein Event pro Zeile - Pflichtfelder: ts, level, service, component, trace\_id - Keine PII in Logs; IDs statt Freitext - Rotate & Compress (zstd)

### Log-Pipeline

- Agent: Filebeat/FluentBit (TLS, backpressure)
- Parse: grok/json; enrich (host, cluster, env)
- Store: Loki/Elastic/OpenSearch
- Retention: 7-30 Tage (Hot), 90+ Tage (Cold/Glacier)

## 38.3 Tracing

### OpenTelemetry Setup (Go API Layer)

```
// tracing.go
import "go.opentelemetry.io/otel"
import "go.opentelemetry.io/otel/exporters/otlp/otlptrace/otlptracehttp"
import "go.opentelemetry.io/otel/sdk/trace"

func InitTracer(endpoint string) func() {
 exporter, _ := otlptracehttp.New(context.Background(), otlptracehttp.WithEndpoint(endpoint))
 tp := trace.NewTracerProvider(trace.WithBatcher(exporter))
 otel.SetTracerProvider(tp)
 return func() { _ = tp.Shutdown(context.Background()) }
}
```

### AQL Trace-Injektion

- Propagiere `traceparent` Header vom API Gateway ins AQL Layer
- Schreibe `trace_id` in Query-Context → Log-Korrelation
- Sample Rate: 1-10% in Produktion; 100% in Staging

## 38.4 Dashboards (Grafana)

### Latenz & Throughput

Panels: - Query p50/p95/p99 (stacked per operation) - QPS split by read/write/graph/vector - Error rate (% per op)

### Replikation

- Lag per follower (ms)
- Failed replications (count)
- WAL queue depth



## Ressourcen

- CPU (per node)
- Memory (rss, cache hit rate)
- Disk IOPS & Latency
- Network retransmits

## Cache & Index

- Cache evictions/sec
  - Index hit rate
  - Slow queries over threshold
- 

## 38.5 SLI/SLO & Error Budgets

### Beispiel-SLIs

- Availability: 99.95% (HTTP 2xx/3xx / total)
- Latency: p99 < 200 ms für Reads, < 400 ms für Writes
- Durability: 0 Datenverlust (RPO <= 60s)
- Freshness: Replication Lag < 2s (p99)

### Error Budget Policy

- Monatsbudget:  $(1 - \text{SLO}) * \text{Zeit}$
  - Breach: Freeze Releases, Fokus auf Reliability
  - Burn Alerts: Warn bei 25/50/75% Verbrauch
- 

## 38.6 Alerting Design

**Ziele:** Früh, präzise, wenig Rauschen.

- Multi-Window, Multi-Burn-Rate (1h/6h) für SLO Burn
- Symptom-basierte Alerts (p99 Latenz hoch, Error Rate > 1%)
- Ursache-Alerts nachrangig (Disk 95% voll)

- Deduping + Grouping im Alertmanager
- Quiet Hours + Ownership (Runbook-Link, Pager-Rotation)

Beispiele: - `latency_p99_gt_200ms` (for 15m & 6h) - `error_rate_gt_1pct` - `replication_lag_gt_2s` - `disk_util_gt_85pct` - `cache_evictions_spike`

---

## 38.7 Runbooks (Kurzfassung)

### Hohe Latenz

- Check: p99 Read/Write? Bestimmte Collections?
- EXPLAIN Slow Query; Index vorhanden?
- Cache Hit Rate < 90%? Memory Druck?
- CPU iowait hoch? → Storage prüfen
- Rate-Limit/Backpressure aktivieren

### Replication Lag

- Netzwerk: retransmits, bandwidth
- Follower CPU/IO bottleneck
- WAL queue depth; throttle writes
- Rebalance followers

### OOM/Memory Pressure

- Cache Size begrenzen
- Off-Heap aufteilen (vector buffers)
- Identify large queries; add LIMIT/PROJECTION

### Disk Full

- Log-Retention kürzen
- Offload Cold Data (Tiered Storage)
- Rebuild Indizes, Vacuum

---

## 38.8 Chaos & GameDays

- Failure Modes: Node down, Network partition, Disk full, High latency storage, Poison messages
  - Hypothesen definieren, erwartetes Verhalten notieren
  - Blast Radius klein starten (1 node, 10 min)
  - Erfolgskriterien: SLO halten? Auto-Heal? Alerts ausgelöst?
  - Nachbereitung: Learnings, Tickets, Fixes, erneutes Testen
- 

## 38.9 Logging & Tracing Sampling Patterns

- Dynamic Sampling: Erhöhe Rate bei Errors
  - Tail Sampling: Keep slow queries, drop fast
  - PII Scrubbing Filter vor Export
- 

## 38.10 Capacity Planning

- Wachstumsrate Traffic & Daten
  - Headroom-Ziel: 40% CPU, 50% IO, 30% Memory
  - Load-Test vierteljährlich; extrapoliere 12 Monate
  - Trigger: >70% baseline → Scale-out
- 

## 38.11 Oncall Playbook Essentials

- Runbook Link in jedem Alert
- 2nd-level Escalation (DBA/SRE)
- Kommunikationskanal: Incident Room + Status Page
- Postmortem innerhalb 48h, Action Items mit Owner/ETA

---

## Zusammenfassung

Observability bündelt Metriken, Logs, Traces und klare SLOs. Mit sauberen Dashboards, schlankem Alerting und erprobten Runbooks verkürzen Sie MTTR massiv und verhindern Blindflüge im Betrieb.

# Kapitel 39: Kapitel 39 - Performance Tuning Cookbook

---

*"Performance ist kein Zufall, sondern eine Sammlung kleiner, konsistenter Entscheidungen. Dieses Kochbuch liefert die Rezepte."*

---

## Überblick

Ein praxisorientiertes Tuning-Kochbuch für ThemisDB. Jede Sektion enthält Symptom → Diagnose → Fix mit AQL-Beispielen und System-Tuning.

**Was Sie lernen:** - Schnelle Checklisten für Latenz, Durchsatz, Speicher, IO - Tuning für Queries, Indizes, Cache, Transactions - Storage/OS/Netzwerk-Optimierungen - Batching, Queueing, Backpressure - Vector- und Graph-Workload Tuning - Beispiel-Konfigurationen für Prod

---

Abb. 39.0: Performance-Tuning-Workflow

---

## 39.1 Quick Tuning Checklist

- **Latenz hoch?** EXPLAIN, Index-Pfade, Projection pushdown, LIMIT
- **Durchsatz gering?** Batching, Parallelisierung, Verbindungspool erhöhen
- **CPU hoch?** Sort/Regex/Full-Scan reduzieren, Index nutzen, Cache-Hit prüfen
- **IO hoch?** Covering Index, Kompression (zstd), Cold Data auslagern

- **Memory hoch?** Cache begrenzen, Streaming statt Materializing, LIMIT
  - **Lock/Deadlock?** Konsistente Lock-Order, kürzere Transaktionen
- 

## 39.2 Query Patterns (Fixes)

### Early Projection & Filter

```
-- x FALSCH: Späte Projektion
FOR u IN users
 FILTER u.status == 'active'
 RETURN u -- großes Dokument

-- RICHTIG: Früh projizieren
FOR u IN users
 FILTER u.status == 'active'
 RETURN { _key: u._key, name: u.name, email: u.email }
```

## Avoid N+1

```
-- x FALSCH: Pro Zeile Subquery
FOR o IN orders
 RETURN {
 o: o,
 items: (
 FOR i IN order_items FILTER i.order_id == o._key RETURN i
)
 }

-- RICHTIG: Pre-Aggregate
LET items_by_order = (
 FOR i IN order_items
 COLLECT order_id = i.order_id INTO items
 RETURN { order_id, items }
)

FOR o IN orders
 LET bundle = FIRST(FOR b IN items_by_order FILTER b.order_id == o._key RETURN b.items)
 RETURN { o, items: bundle }
```

## Range Queries mit Index

```
CREATE INDEX idx_ts ON events(timestamp)

FOR e IN events
 FILTER e.timestamp >= @from AND e.timestamp <= @to
 RETURN e
```

## Graph Traversal Tuning

```
-- Limit depth and fanout
FOR v, e, p IN 1..3 OUTBOUND 'users/alice' GRAPH 'social'
 PRUNE LENGTH(p.vertices) > 100 -- Begrenze
 FILTER p.edges[*].weight ALL >= 0.5
RETURN v
```

---

## 39.3 Batching & Parallelism

### Batch Insert/Update

```
LET batch = @input_docs
INSERT batch INTO users -- 1 Transaktion
```

### Client-Side Parallel

```
batch_parallel.py
from concurrent.futures import ThreadPoolExecutor

def run_in_parallel(queries):
 with ThreadPoolExecutor(max_workers=8) as ex:
 return list(ex.map(client.execute, queries))
```

## Backpressure

```
backpressure.py
import asyncio

class QueueWorker:
 def __init__(self, maxsize=1000):
 self.q = asyncio.Queue(maxsize=maxsize)

 async def produce(self, items):
 for item in items:
 await self.q.put(item) # block when full

 async def consume(self, worker):
 while True:
 item = await self.q.get()
 await worker(item)
 self.q.task_done()
```

---

## 39.4 Cache & Memory

- Target: Cache Hit Rate > 90%
- Limit result set sizes (pagination)
- Use STREAMING\_CURSOR for große Resultsets
- Avoid massive IN lists → temp set collection

```
-- Streaming Cursor
FOR doc IN large_collection
 FILTER doc.status == 'active'
 LIMIT 0, 100000
 OPTIONS {stream: true}
 RETURN doc
```



---

## 39.5 Storage & IO

### Kompression

- `storage.compression = zstd`
- `wal.compression = zstd`
- Blockgröße 4-8KB testen

### SSD/NVMe Tuning (Linux)

```
sudo nvme set-feature -f 2 -v 0 # Disable write cache if battery-backed
sudo nvme set-feature -f 0x0b -v 0x1 # Latency monitor enable
```

### Filesystem

- ext4 mit `noatime`, `discard`, `nodiscard` für Performance abwägen
  - XFS für hohe Parallelität
- 

## 39.6 Netzwerk

- MTU prüfen (Jumbo Frames nur konsistent nutzen)
  - TCP: `net.ipv4.tcp_tw_reuse=1`, `tcp_fin_timeout=15`
  - Verbindungen poolen; Keep-Alive aktivieren
- 

## 39.7 Vektor-Workloads

### Index & Quantization

- HNSW: M=16-32, efConstruction=200, efSearch=64-128
- PQ: Codebooks 8-16, 8 Bit
- IVF: nlist  $\sim \sqrt{N}$

## Batch Embedding

```
batch_embed.py
chunks = [docs[i:i+32] for i in range(0, len(docs), 32)]
for chunk in chunks:
 vectors = embed(chunk)
 client.insert_vectors('emb', vectors)
```

## ANN Warmup

- Preload top collections on startup
  - Pin hot vectors in memory tier
- 

## 39.8 Graph-Workloads

- Begrenze Fanout und Depth
  - Precompute Communities (Louvain) für häufige Queries
  - Materialisierte Pfade für Hot Paths
- 

## 39.9 Transactions & Locking

- Kürzere Transaktionen; kleinere Batches
- Lock-Order strikt definieren
- Deadlock-Timeout niedrig (z.B. 5s) → Retry mit Backoff

```
retry_tx.py
import time

def with_retry(tx_func, attempts=3):
 for i in range(attempts):
 try:
 return tx_func()
 except Deadlock:
 time.sleep(0.1 * (2 ** i))
 raise
```

---

## 39.10 Configuration Templates

### themis.conf (Performance Focus)

```
aql:
 stream_results: true
 max_query_memory_mb: 1024
 profiling_enabled: true

cache:
 size_mb: 8192
 eviction_policy: lru

wal:
 compression: zstd
 sync_interval_ms: 20

network:
 max_connections: 2000
 keepalive: 60
```

## Linux sysctl

```
net.core.somaxconn = 1024
net.ipv4.tcp_fin_timeout = 15
net.ipv4.tcp_tw_reuse = 1
vm.swappiness = 10
vm.max_map_count = 262144
```

---

## 39.11 Benchmark Harness

```
bench_harness.py
import time

class BenchHarness:
 def __init__(self, client):
 self.client = client

 def run_case(self, name, query):
 start = time.time()
 result = self.client.execute(query)
 dur = (time.time() - start) * 1000
 return {"name": name, "duration_ms": dur, "rows": len(result)}

 def run_suite(self, cases):
 return [self.run_case(n, q) for n, q in cases]
```

---

## Zusammenfassung

Dieses Kochbuch liefert schnelle Diagnosen und konkrete Fixes. Beginnen Sie mit EXPLAIN/PROFILE, optimieren Sie Filter/Projektion, nutzen Sie Indizes, batchen Sie Schreibvorgänge, begrenzen Sie Fanout, und sichern Sie Ressourcen durch Cache- und IO-Tuning. Wiederholen, messen, automatisieren.

# Kapitel 40: Kapitel 40 - Data Governance & Compliance

---

*"Daten ohne Governance sind Haftungsrisiko. Governance schafft Vertrauen, Compliance macht es prüfbar."*

---

## Überblick

Ein praxisnahes Governance- und Compliance-Kapitel für ThemisDB: Policies, Zugriff, Maskierung, Retention, Audits, Privacy (GDPR), und Kontrollnachweise.

**Was Sie lernen:** - Governance-Framework (Policies, Ownership, Stewardship) - Access Control & Least Privilege - Data Classification & Masking - Lifecycle & Retention - Audit Trails & Evidence - GDPR/DSGVO: Rechte, Pseudonymisierung, Löschung - SOX/SOC2/ISO27001 Anforderungen - Kontroll-Checklisten und Runbooks

---

Abb. 40.0: Data-Governance-Framework

---

## 40.1 Governance Operating Model

- **Ownership:** Jede Collection hat Owner (Team), Steward (Data Quality), Custodian (Ops)
  - **Policy Catalog:** Zugriff, Retention, Encryption, Backup, Sharing
  - **Review Zyklen:** Quartalsweise Policy-Review, jährliche Controls-Audits
  - **Change Control:** RFC → Peer Review → Approval → Rollout → Evidence
- 

## 40.2 Data Classification

Stufen definieren (z.B. PUBLIC, INTERNAL, CONFIDENTIAL, STRICT).

```
classification:
 levels:
 - name: PUBLIC
 description: "Keine Sensibilität"
 - name: INTERNAL
 description: "Nur intern"
 - name: CONFIDENTIAL
 description: "PII/finanziell"
 - name: STRICT
 description: "Gesundheit, Strafverfolgung"
```

**Regeln:** - Standard = INTERNAL - CONFIDENTIAL/STRICT → Encryption + Access Approval - Masking im UI/Logs für CONFIDENTIAL/STRICT

---

## 40.3 Access Control & Least Privilege

- RBAC-Modelle (Reader, Writer, Admin, Auditor)
- JIT Access mit Ablauf (z.B. 24h)
- Break-Glass Accounts (mit separatem Audit)
- Quarterly Access Review

```
-- Grant role
INSERT {
 user_id: 'alice',
 role: 'reader',
 granted_by: 'security',
 expires_at: DATE_ADD(NOW(), 1, 'day')
} INTO access_grants
```

---

## 40.4 Data Masking

### Dynamic Masking

```
FUNCTION mask_email(email) {
 RETURN CONCAT(SUBSTRING(email, 0, 2), '****', SUBSTRING(email, POSITION(email, '@')-1))
}

FOR user IN users
 RETURN {
 name: user.name,
 email: mask_email(user.email)
 }
```

### Tokenization

```
tokenization.py
import secrets

tokens = {}

def tokenize(value):
 token = secrets.token_hex(8)
 tokens[token] = value
 return token

def detokenize(token):
 return tokens.get(token)
```

---

## 40.5 Data Lifecycle & Retention

- **Ingest:** Klassifizierung, Validation, Encryption
- **Store:** Encryption-at-rest, Access Controls, Audit Logs

- **Use:** Masking, Purpose Limitation, Minimal Disclosure
- **Share:** Anonymize/Pseudonymize, DPA prüfen
- **Archive:** Cold Storage mit Verschlüsselung
- **Delete:** Right-to-be-forgotten Prozesse

Retention Beispiel:

```
retention:
 users: 7y
 logs: 180d
 audit_logs: 365d
 pii: 2y
```

---

## 40.6 Audit & Evidence

- Immutable Audit Log (Kapitel 36)
- Evidence Store: Tickets, Screenshots, CLI Output, Hashes
- Kontroll-Nachweise per Control-ID (ISO27001 Annex A, SOC2 CC)

```
Control: AC-3 (Access Enforcement)
- Policy: AC-3 v1.2
- Evidence:
 - access_grants export (signed)
 - quarterly review report (PDF)
 - IAM config screenshot
 - audit log hash chain verification
```

---

## 40.7 Privacy (GDPR)

### Betroffenenrechte

- Auskunft, Berichtigung, Löschung, Einschränkung, Übertragbarkeit, Widerspruch



```
-- Right to Erasure (Pseudonymize)
FUNCTION gdpr_delete(user_id) {
 UPDATE {_id: 'users/' + user_id} WITH {
 name: 'Anonymized',
 email: null,
 phone: null,
 gdpr_deleted_at: NOW(),
 is_deleted: true
 } IN users

 REMOVE d IN audit_logs
 FILTER d.resource == CONCAT('users/', user_id)
}
```

## Data Processing Register

- Zweck, Kategorien, Empfänger, Speicherorte, Löschfristen
- DPAs mit Prozessoren dokumentieren

---

## 40.8 Compliance Frameworks (SOX, SOC2, ISO27001)

- **SOX:** Change-Management, Segregation of Duties, Evidence für Finanzsysteme
- **SOC2:** Security/Availability/Confidentiality; Controls: Access, Change, Incident, Monitoring
- **ISO27001:** ISMS, Risikoanalyse, Controls Annex A (z.B. A.8 Asset Management, A.9 Access Control)

Kontroll-Mapping Beispiel:

- A.9.1.2 (Access Control): RBAC + Quarterly Review + JIT
- A.12.4.1 (Logging): Immutable Audit Log, 365d retention
- A.12.6.1 (Malware Protection): EDR auf DB-Hosts
- A.17.1.1 (Continuity): DR-Plan + Tests halbjährlich

---

## 40.9 Controls & Checklisten

### ## Access Controls

- ☐ RBAC Rollen definiert
- ☐ JIT Access aktiviert
- ☐ Break-glass dokumentiert
- ☐ Quarterly Reviews durchgeführt

### ## Data Protection

- ☐ Encryption at rest (AES-256)
- ☐ TLS 1.3 in transit
- ☐ Field-Level Encryption für PII
- ☐ Masking im UI und Logs

### ## Monitoring & Audit

- ☐ Immutable Audit Logs
- ☐ Alerting auf Policy-Verletzungen
- ☐ Evidence Store mit Hash-Kette

---

## Zusammenfassung

Governance setzt klare Verantwortlichkeiten, Classification, Zugriffsprinzipien und Retention.

Compliance liefert Nachweise gegenüber Auditoren und Gesetzgebern. Mit Masking, Audit Trails, JIT Access und robusten Löschrouten bleibt ThemisDB konform und vertrauenswürdig.

---

## Kapitel 41: Kapitel 41 - Hands-on Labs

*"Lernen durch Tun: Diese Labs führen Sie Schritt für Schritt durch echte Produktionsaufgaben."*

---

## Überblick

Drei geführte Labs mit klaren Zielen, Schritt-für-Schritt-Anleitungen, Verifikation und Aufräumen.

**Labs:** - Lab A: Schnellstart-Deployment (Docker) + Smoke Tests - Lab B: Index-Tuning & Query-Optimierung mit EXPLAIN/PROFILE - Lab C: Vector-Suche End-to-End (Embeddings erzeugen, Indexieren, Query)

**Voraussetzungen:** Docker/WSL, themis\_client CLI oder HTTP, Grundkenntnisse AQL.

---

Abb. 41.0: Lab-Curriculum-Flow

---

## Lab A: Deployment & Smoke Tests (30-45 min)

### Ziel

- ThemisDB per Docker starten
- Healthcheck & Basiskonfiguration prüfen
- Erste Write/Read-Query ausführen

### Schritte

#### 1) Container starten

```
docker run -d --name themisdb -p 8529:8529 themisdb/server:latest
```

#### 2) Healthcheck

```
curl -s http://localhost:8529/_admin/status | jq '.server.status'
```

Erwartet: `"ok"`

#### 3) Admin-Login setzen (falls nötig)

```
curl -X POST http://localhost:8529/_admin/setup --data '{"password":"StrongPass!"}'
```

#### 4) Smoke-Test Write/Read

```
-- write
INSERT { _key: "alice", name: "Alice" } INTO users
-- read
FOR u IN users FILTER u._key == "alice" RETURN u
```

#### 5) Persistenz prüfen

```
docker restart themisdb
curl -s http://localhost:8529/_api/document/users/alice
```

### Aufräumen

```
docker rm -f themisdb
```

---

## Lab B: Index-Tuning & Query-Optimierung (40-60 min)

### Ziel

- Langsame Query identifizieren
- EXPLAIN/PROFILE nutzen
- Index anlegen und Improvement messen

### Dataset vorbereiten

```
FOR i IN 1..200000
 INSERT {
 key: CONCAT('user', i),
 email: CONCAT('user', i, '@example.com'),
 status: i % 5 == 0 ? 'inactive' : 'active',
 created_at: DATE_NOW()
 } INTO users
```

## Baseline messen

```
PROFILE FOR u IN users
 FILTER u.email == 'user199999@example.com'
 RETURN u
```

Notieren: p99 Latenz.

## EXPLAIN prüfen

```
EXPLAIN FOR u IN users
 FILTER u.email == 'user199999@example.com'
 RETURN u
```

Erwartet: CollectionScan (schlecht).

## Index anlegen

```
CREATE INDEX idx_users_email ON users(email)
```

## Nachher messen

```
PROFILE FOR u IN users
 FILTER u.email == 'user199999@example.com'
 RETURN u
```

Erwartet: IndexNode, stark reduzierte Latenz. Dokumentieren Sie Vor/Nach.

## Optionale Optimierungen

- Projection pushdown: nur benötigte Felder returnen
- LIMIT 1 setzen, wenn eindeutig

## Aufräumen

```
DROP INDEX users.idx_users_email
TRUNCATE users
```

---

## Lab C: Vector-Suche End-to-End (45-75 min)

### Ziel

- Texte einbetten
- Vektor-Index aufbauen
- Ähnlichkeitssuche ausführen

### Setup

#### 1) Kollektion anlegen

```
CREATE COLLECTION articles
```

#### 2) Beispiel-Dokumente einfügen

```
INSERT {
 _key: "art1",
 title: "Graph Algorithms",
 content: "Graphs, shortest paths, centrality",
 vector: null
} INTO articles
INSERT {
 _key: "art2",
 title: "Neural Networks",
 content: "Deep learning, backpropagation",
 vector: null
} INTO articles
INSERT {
 _key: "art3",
 title: "Databases",
 content: "Indexing, transactions, sharding",
 vector: null
} INTO articles
```

### 3) Embeddings erzeugen (Client-seitig, Beispiel Python)

```
embed_articles.py
from sentence_transformers import SentenceTransformer
import themis_client

client = themis_client.connect()
model = SentenceTransformer('all-MiniLM-L6-v2')

articles = client.execute("FOR a IN articles RETURN {key: a._key, text: a.content}")
for a in articles:
 vec = model.encode(a['text']).tolist()
 client.execute(
 "UPDATE { _key: @key } WITH { vector: @vec } IN articles",
 bind_vars={"key": a['key'], "vec": vec}
)
```

### 4) Vektor-Index anlegen

```
CREATE VECTOR INDEX idx_articles_vec ON articles(vector) WITH {dimensions: 384, type: "hnsw", ef0
```

## 5) Ähnlichkeitssuche

```
LET query_vec = @query_vec
FOR doc IN articles
 SEARCH doc.vector ANN { query: query_vec, top_k: 3 }
RETURN { _key: doc._key, title: doc.title, score: doc._score }
```

Bind Vars: `query_vec` = Embedding eines Suchtexts, z.B. "machine learning".

6) **Relevanz prüfen** - Erwartet: "Neural Networks" weit oben bei ML-Query - Score dokumentieren

## Optionen

- efSearch erhöhen für bessere Recall
- PQ/IVF nutzen für größere Datenmengen
- Caching von Embeddings

## Aufräumen

```
TRUNCATE articles
```

## Checkliste (Abgehakt, wenn Lab bestanden)

- ☐ Lab A: Container-Start, Healthcheck, Smoke Query
- ☐ Lab B: EXPLAIN/PROFILE vor/nach, Index Speedup dokumentiert
- ☐ Lab C: Embeddings erzeugt, Vektor-Index erstellt, ANN Query ausgeführt

**Nächste Schritte:** Kombinieren Sie Labs: Deploy → Index-Tuning → Vector-Suche auf realen Datensätzen.



# Anhänge

---

# Anhang A - Literatur

---

Dieses Literaturverzeichnis folgt dem IEEE-Zitierstil und umfasst alle wissenschaftlichen und technischen Quellen, die in diesem Compendium referenziert wurden.

---

## Primärquellen: ThemisDB Gemini Analysen

Die folgenden strategischen Analysen wurden als Primärquellen für die technische Vertiefung in Kapitel 1, 2, 3 und 17 herangezogen:

- [1] "Strategische Gesamtanalyse: ThemisDB als ACID-Fundament für die RAG-LLM-Strategie der deutschen Verwaltung – Eine komparative Analyse zur Ablösung der UDS3-Architektur," ThemisDB Project, Internes Strategiedokument, Nov. 2025. [Online]. Verfügbar: docs/gimini/Strategische Gesamtanalyse\_ ThemisDB als ACID-Fundament für die RAG-LLM-Strategie der deutschen Verwaltung – Eine komparative Analyse zur Ablösung der UDS3-Architektur.md
- [2] "Strategische Analyse: ThemisDB – Bewertung einer nativen Multi-Modell-Architektur im Kontext von Sovereign-Cloud-Plattformen und On-Premise-RAG-Alternativen," ThemisDB Project, Internes Analysedokument, Nov. 2025. [Online]. Verfügbar: docs/gimini/Strategische Analyse\_ ThemisDB – Bewertung einer nativen Multi-Modell-Architektur im Kontext von Sovereign-Cloud-Plattformen und On-Premise-RAG-Alternativen.md
- [3] "Die ThemisDB-Architektur: Eine technische Tiefenanalyse eines Multi-Modell-Datenbanksystems auf LSM-Tree-Basis," ThemisDB Project, Technisches Whitepaper, Nov. 2025. [Online]. Verfügbar: docs/gimini/ThemisDB Dokumentation und Berichtsanalyse.md
- [4] "Architektonischer Entwurf eines hochperformanten Multi-Modell-Datenbanksystems: Eine Kernel-Level-Analyse von kanonischem Speicher, Projektionsschichten und Speicherhierarchien in C++ und Rust," ThemisDB Project, Architektur-Blueprint, Nov. 2025. [Online]. Verfügbar: docs/gimini/Hybride Datenbankarchitektur C++\_Rust (1).md
- [5] "ThemisDB vs. Hyperscaler Datenbanken: Komparativer Vergleich," ThemisDB Project, Vergleichsanalyse, Nov. 2025. [Online]. Verfügbar: docs/gimini/Themis vs. Hyperscaler Datenbanken Vergleich.md
- [6] "Hyperscaler-Einordnung für ThemisDB-Bericht," ThemisDB Project, Marktanalyse, Nov. 2025. [Online]. Verfügbar: docs/gimini/Hyperscaler-Einordnung für ThemisDB-Bericht.md

- [7] "KI-Strategie: ThemisDB, Hyperscaler, Ethik," ThemisDB Project, Strategiepapier, Nov. 2025. [Online]. Verfügbar: docs/gimini/KI-Strategie\_ ThemisDB, Hyperscaler, Ethik.md
- [8] "VCCDB Design: Veritas, Covina, Clara Database Design Spezifikation," ThemisDB Project, Design-Dokument, Nov. 2025. [Online]. Verfügbar: docs/gimini/VCCDB Design (1).md
- [9] "Forschungsbericht ThemisDB 2025: Public Research Edition," ThemisDB Project, Forschungsbericht, Nov. 2025. [Online]. Verfügbar: docs/gimini/Forschungsbericht ThemisDB 2025\_THEMISDB\_PUBLIC\_RE.....md
- 

## Sekundärquellen: Datenbanksysteme und Architektur

- [10] M. Stonebraker and U. Cetintemel, "'One size fits all': An idea whose time has come and gone," in *Proc. IEEE 21st International Conference on Data Engineering (ICDE '05)*, Tokyo, Japan, 2005, pp. 2-11, doi: 10.1109/ICDE.2005.1.
- [11] J. Lu and I. Holubová, "Multi-model databases: A new journey to handle the variety of data," *ACM Computing Surveys*, vol. 52, no. 3, pp. 1-38, Jun. 2019, doi: 10.1145/3323214.
- [12] P. O'Neil, E. Cheng, D. Gawlick, and E. O'Neil, "The log-structured merge-tree (LSM-tree)," *Acta Informatica*, vol. 33, no. 4, pp. 351-385, Jun. 1996, doi: 10.1007/s002360050048.
- [13] Facebook Engineering, "RocksDB: A persistent key-value store for fast storage environments," Facebook Inc., Technical Report, 2013. [Online]. Verfügbar: <https://rocksdb.org/>
- [14] D. G. Andersen, J. Franklin, M. Kaminsky, A. Phanishayee, L. Tan, and V. Vasudevan, "FAWN: A fast array of wimpy nodes," in *Proc. 22nd ACM Symposium on Operating Systems Principles (SOSP '09)*, Big Sky, MT, USA, 2009, pp. 1-14, doi: 10.1145/1629575.1629577.
- [15] H. Berenson, P. Bernstein, J. Gray, J. Melton, E. O'Neil, and P. O'Neil, "A critique of ANSI SQL isolation levels," in *Proc. ACM SIGMOD International Conference on Management of Data*, San Jose, CA, USA, 1995, pp. 1-10, doi: 10.1145/223784.223785.
- 

## Transaktionsverarbeitung und Konsistenz

- [16] P. A. Bernstein and E. Newcomer, *Principles of Transaction Processing*, 2nd ed. San Francisco, CA, USA: Morgan Kaufmann, 2009.
- [17] C. Garcia-Molina and K. Salem, "Sagas," in *Proc. ACM SIGMOD International Conference on Management of Data*, San Francisco, CA, USA, 1987, pp. 249-259, doi: 10.1145/38713.38742.

- [18] E. Brewer, "CAP twelve years later: How the 'rules' have changed," *IEEE Computer*, vol. 45, no. 2, pp. 23-29, Feb. 2012, doi: 10.1109/MC.2012.37.
- [19] D. B. Lomet, "Process structuring, synchronization, and recovery using atomic actions," in *Proc. ACM Conference on Language Design for Reliable Software*, Raleigh, NC, USA, 1977, pp. 128-137, doi: 10.1145/800022.808314.
- [20] M. J. Cahill, U. Röhm, and A. D. Fekete, "Serializable isolation for snapshot databases," *ACM Transactions on Database Systems*, vol. 34, no. 4, pp. 1-42, Dec. 2009, doi: 10.1145/1620585.1620587.
- 

## Graph-Datenbanken und Traversierung

- [21] R. Angles and C. Gutierrez, "Survey of graph database models," *ACM Computing Surveys*, vol. 40, no. 1, pp. 1-39, Feb. 2008, doi: 10.1145/1322432.1322433.
- [22] M. A. Rodriguez and P. Neubauer, "The graph traversal pattern," in *Graph Data Management: Techniques and Applications*, S. Sakr and E. Pardede, Eds. Hershey, PA, USA: IGI Global, 2011, pp. 29-46, doi: 10.4018/978-1-61350-053-8.ch002.
- [23] N. Francis et al., "Cypher: An evolving query language for property graphs," in *Proc. ACM SIGMOD International Conference on Management of Data*, Houston, TX, USA, 2018, pp. 1433-1445, doi: 10.1145/3183713.3190657.
- [24] R. Angles, "A comparison of current graph database models," in *Proc. IEEE 28th International Conference on Data Engineering Workshops (ICDEW)*, Arlington, VA, USA, 2012, pp. 171-177, doi: 10.1109/ICDEW.2012.31.
- 

## Vektor-Datenbanken und Similarity Search

- [25] Y. A. Malkov and D. A. Yashunin, "Efficient and robust approximate nearest neighbor search using hierarchical navigable small world graphs," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 42, no. 4, pp. 824-836, Apr. 2020, doi: 10.1109/TPAMI.2018.2889473.
- [26] J. Johnson, M. Douze, and H. Jégou, "Billion-scale similarity search with GPUs," *IEEE Transactions on Big Data*, vol. 7, no. 3, pp. 535-547, Sep. 2021, doi: 10.1109/TBDATA.2019.2921572.
- [27] M. Muja and D. G. Lowe, "Scalable nearest neighbor algorithms for high dimensional data," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 36, no. 11, pp. 2227-2240, Nov. 2014, doi: 10.1109/TPAMI.2014.2321376.

[28] A. Babenko and V. Lempitsky, "Efficient indexing of billion-scale datasets of deep descriptors," in *Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, Las Vegas, NV, USA, 2016, pp. 2055-2063, doi: 10.1109/CVPR.2016.226.

---

## RAG und LLM-Integration

[29] P. Lewis et al., "Retrieval-augmented generation for knowledge-intensive NLP tasks," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 33, 2020, pp. 9459-9474.

[30] S. Robertson and H. Zaragoza, "The probabilistic relevance framework: BM25 and beyond," *Foundations and Trends in Information Retrieval*, vol. 3, no. 4, pp. 333-389, 2009, doi: 10.1561/15000000019.

[31] O. Khattab and M. Zaharia, "ColBERT: Efficient and effective passage search via contextualized late interaction over BERT," in *Proc. 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval*, Virtual Event, 2020, pp. 39-48, doi: 10.1145/3397271.3401075.

[32] Y. Gao et al., "Retrieval-augmented generation for large language models: A survey," *arXiv preprint arXiv:2312.10997*, Dec. 2023. [Online]. Verfügbar: <https://arxiv.org/abs/2312.10997>

---

## Polyglot Persistence und Multi-Model-Systeme

[33] M. Fowler and P. Sadalage, *NoSQL Distilled: A Brief Guide to the Emerging World of Polyglot Persistence*. Upper Saddle River, NJ, USA: Addison-Wesley Professional, 2012.

[34] J. Pokorný, "Conceptual and database modelling of graph databases," in *Proc. 20th International Conference on Information Systems Development (ISD)*, Edinburgh, Scotland, 2011, pp. 370-381.

[35] ArangoDB Inc., "ArangoDB Multi-Model Database Architecture," Technical Whitepaper, 2020. [Online]. Verfügbar: <https://www.arangodb.com/>

[36] Microsoft Azure, "Azure Cosmos DB: Multi-model database service," Microsoft Technical Documentation, 2023. [Online]. Verfügbar: <https://azure.microsoft.com/en-us/services/cosmos-db/>

---

## Kompression und Speicheroptimierung

[37] Y. Collet, "LZ4: Extremely fast compression algorithm," Open Source Implementation, 2011. [Online]. Verfügbar: <https://lz4.github.io/lz4/>

- [38] Y. Collet and M. Kucherawy, "Zstandard Compression and the 'application/zstd' Media Type," Internet Engineering Task Force (IETF), RFC 8878, Feb. 2021. [Online]. Verfügbar: <https://tools.ietf.org/html/rfc8878>
- [39] M. Adler, "Snappy: A fast compressor/decompressor," Google Inc., Technical Report, 2011. [Online]. Verfügbar: <https://google.github.io/snappy/>
- 

## Serialisierung und Parsing

- [40] D. Lemire, G. Ssi-Yan-Kai, and O. Katz, "Parsing gigabytes of JSON per second," *The VLDB Journal*, vol. 28, no. 6, pp. 941-960, Dec. 2019, doi: 10.1007/s00778-019-00578-5.
- [41] ArangoDB Inc., "VelocityPack: A fast and compact format for serialization and storage," Technical Specification, 2016. [Online]. Verfügbar: <https://github.com/arangodb/velocypack>
- [42] Google Inc., "Protocol Buffers: Google's data interchange format," Technical Documentation, 2008. [Online]. Verfügbar: <https://developers.google.com/protocol-buffers>
- 

## Standards und Compliance

- [43] Bundesamt für Sicherheit in der Informationstechnik (BSI), "IT-Grundschutz-Kompendium," BSI Standard 200-2, Bonn, Deutschland, 2023. [Online]. Verfügbar: <https://www.bsi.bund.de/>
- [44] European Parliament and Council, "General Data Protection Regulation (GDPR)," Regulation (EU) 2016/679, Apr. 2016. [Online]. Verfügbar: <https://eur-lex.europa.eu/eli/reg/2016/679/oj>
- [45] Apache Software Foundation, "Apache Ranger: Framework to enable, monitor and manage comprehensive data security," Technical Documentation, 2023. [Online]. Verfügbar: <https://ranger.apache.org/>
- 

## Verwendete Softwarebibliotheken

- [46] Facebook Engineering, "RocksDB C++ API Reference," Version 8.8.0, 2023. [Online]. Verfügbar: <https://github.com/facebook/rocksdb>
- [47] The Rust Project, "serde: Serialization framework for Rust," Version 1.0, 2023. [Online]. Verfügbar: <https://serde.rs/>

[48] D. Lemire et al., "simdjson: Parsing gigabytes of JSON per second," Version 3.0, 2023. [Online]. Verfügbar: <https://github.com/simdjson/simdjson>

---

## Verwendungshinweise

### Kapitel-Referenzen

Die folgenden Primärquellen wurden in den entsprechenden Kapiteln verwendet:

**Kapitel 1 (Einführung):** - [1] Strategische Gesamtanalyse - Teil III: Architektonische Kernentscheidung - [3] ThemisDB-Architektur - Teil 1: Kanonische Speicherarchitektur - [4] Architektonischer Entwurf - Teil 1: Base Entity Paradigma

**Kapitel 2 (Architektur):** - [3] ThemisDB-Architektur - Teil 1.3: RocksDB als transaktionales Fundament - [4] Architektonischer Entwurf - Teil 1: Multi-Modell-Speicherformat - [5] Hyperscaler-Vergleich - Teil 3.1: Kanonischer Speicher - [12] LSM-Tree Grundlagen - [13] RocksDB Dokumentation

**Kapitel 3 (Multi-Model):** - [1] Strategische Gesamtanalyse - Teil III: Ablösung von UDS3 - [2] Strategische Analyse - Teil II: Wettbewerbslandschaft - [5] Hyperscaler-Vergleich - Teil 2: Post-Filtering Problem - [11] Multi-Model Databases Survey

**Kapitel 17 (LLM-Integration):** - [2] Strategische Analyse - Teil 1.3: Native KI- und RAG-Fähigkeiten - [5] Hyperscaler-Vergleich - Teil 2: RAG-Architektur - [29] Retrieval-Augmented Generation - [30] BM25 and Beyond

### Zitierkonventionen im Text

Im Text dieses Compendiums werden Quellen durch eckige Klammern referenziert, z.B. [1], [3], [12]. Die vollständigen Quellenangaben finden Sie in diesem Anhang im IEEE-Format.

### Zugriff auf Primärquellen

Die Primärquellen [1]-[9] sind interne Projektdokumente im [docs/gimini/](#) Verzeichnis des ThemisDB Repository verfügbar. Die Sekundärquellen [10]-[48] sind peer-reviewed wissenschaftliche Publikationen, technische Standards oder Open-Source-Dokumentationen, die über die angegebenen DOIs oder URLs zugänglich sind.

---

**Zuletzt aktualisiert:** Dezember 2025

**Version:** 1.3.4

# Anhang D - Feature Status

---

**Version:** 1.4.0-alpha

**Stand:** 6. Januar 2026

**Kategorie:** Feature-Übersicht und Implementierungsstatus

---

## Zweck dieses Appendix

Dieser Appendix bietet eine vollständige, strukturierte Übersicht aller ThemisDB-Features mit aktuellem Implementierungsstatus, Dokumentationsverweisen und Roadmap-Planung. Dies dient als zentraler Referenzpunkt für:

- **Entwickler:** Welche Features sind verfügbar? Wo ist der Code?
- **Architekten:** Welche Capabilities hat ThemisDB? Was fehlt noch?
- **Projektmanager:** Was ist Production-Ready? Was ist geplant?
- **Nutzer:** Welche Funktionen kann ich nutzen?



## Status-Definitionen

Symbol	Status	Bedeutung
	<b>Production-Ready</b>	Vollständig implementiert, getestet (>85% Coverage), dokumentiert, performance-validated
	<b>MVP Complete</b>	Kernfunktionalität vorhanden, stabil, aber ggf. noch Optimierungen ausstehend
	<b>In Development</b>	Aktiv in Entwicklung, teilweise funktional, noch nicht production-grade
	<b>Design Phase</b>	Spezifikation vorhanden, Implementierung geplant
	<b>Planned</b>	Auf Roadmap, noch keine Spezifikation
○	<b>Backlog</b>	Idee/Anforderung dokumentiert, keine aktive Planung
	<b>Alpha</b>	Neu in v1.4.0-alpha, noch nicht production-ready
×	<b>Not Planned</b>	Bewusst nicht im Scope

## Zusammenfassung

**Aktuelle Reife (Stand Jan 2026):** - **Core Database:** Production-Ready (85%+ Test Coverage) - **Multi-Model Support:** Production-Ready (Relational, Graph, Vector, Document, Time-Series) - **Security & Compliance:** Production-Ready (DSGVO, BSI C5, Audit Logging) - **Horizontal Scaling:** Production-Ready (2/4/8-Node Clusters, 91% Efficiency) - **High Availability:** Alpha (Hot Spare, WAL Replication) - **Voice Assistant:** Alpha (Whisper STT, Piper TTS, Meeting Protocols, Call Center Automation) - **LLM/RAG Integration:** Alpha (8 neue Features: Prefix/Response Caching, Multi-GPU, Paged Attention, LoRA, Grammar-Constrained Generation, RoPE Scaling, Vision) - **Performance Optimizations:** Alpha (Flash Attention, Speculative Decoding, Continuous Batching) - **PostgreSQL Wire Protocol:** Alpha (COPY, LISTEN/NOTIFY, Binary Format, Pipeline Mode) - **Enhanced Monitoring:** Alpha (30+ neue Prometheus-Metriken für LLM, HA, Performance)

## v1.4.0-alpha Feature-Highlights

### LLM-Integration (Kapitel 17)

Feature	Status	Maturity	Documentation	Performance
Prefix Caching	Alpha	Early	Chapter 17.12.1	75% cost savings
Response Caching	Alpha	Early	Chapter 17.12.2	60-80% savings
Multi-GPU Support	Alpha	Early	Chapter 17.12.3	4-8x throughput
Paged Attention	Alpha	Early	Chapter 17.12.4	80% memory reduction
LoRA Support	Alpha	Early	Chapter 17.12.5	99% less memory
Grammar-Constrained Generation	Alpha	Early	Chapter 17.12.6	95-99% valid outputs
RoPE Scaling	Alpha	Early	Chapter 17.12.7	4K → 32K context
Vision Support	Alpha	Early	Chapter 17.12.8	Multimodal AI

**Roadmap:** - Beta (Feb 2026): Performance tuning, extended testing - GA (Mar 2026): Production-ready certification

### Enterprise Features (Kapitel 10)

Feature	Status	Maturity	Documentation	Use Case
Voice Assistant	Alpha	Early	Chapter 10.7	Call Center, Meeting Protocols
Multi-Tenancy	Production-Ready	Stable	Chapter 10.1	SaaS Applications
RBAC	Production-Ready	Stable	Chapter 10.1	Enterprise Security
Audit Logging	Production-Ready	Stable	Chapter 10.1	Compliance

**Roadmap (Voice Assistant):** - Beta (Feb 2026): Enhanced language support, improved accuracy - GA (Mar 2026): Production-ready certification for enterprise use

Performance-Optimierungen (Kapitel 21)

Feature	Status	Maturity	Documentation	Performance
Flash Attention	Alpha	Early	Chapter 20.9A.1	69% throughput, 37% memory
Speculative Decoding	Alpha	Early	Chapter 20.9A.2	2-3x speedup
Continuous Batching	Alpha	Early	Chapter 20.9A.3	176% throughput

**Roadmap:** - Beta (Feb 2026): Hardware compatibility testing - GA (Mar 2026): Production deployment guides

High Availability (Kapitel 16)

Feature	Status	Maturity	Documentation	Performance
Hot Spare	Alpha	Early	Chapter 16.10.1	<5s failover
WAL Replication	Alpha	Early	Chapter 16.10.2	Zero data loss
Multi-SSD WAL	Alpha	Early	Chapter 16.10.2	<10% write overhead
Replication Slots	Alpha	Early	Chapter 16.10.2	Lag monitoring

**Roadmap:** - Beta (Feb 2026): Extended failover testing, disaster recovery - GA (Mar 2026): Production HA certification

Monitoring & Observability (Kapitel 19)

Feature	Status	Maturity	Documentation	Metrics Count
LLM Metrics	Alpha	Early	Chapter 19.6A.1	15+ metrics
Performance Metrics	Alpha	Early	Chapter 19.6A.2	10+ metrics
HA Metrics	Alpha	Early	Chapter 19.6A.3	8+ metrics
Grafana Dashboards	Alpha	Early	Chapter 19.6A	3 dashboards
Alerting Rules	Alpha	Early	Chapter 19.6A.4	12+ rules

**Roadmap:** - Beta (Feb 2026): Dashboard refinement, extended alerting - GA (Mar 2026): Complete observability stack

## PostgreSQL Wire Protocol (Kapitel 31)

Feature	Status	Maturity	Documentation	Performance
<b>COPY Protocol</b>	Alpha	Early	Chapter 31.9A.1	250K rows/s
<b>LISTEN/NOTIFY</b>	Alpha	Early	Chapter 31.9A.1	Real-time CDC
<b>Binary Format</b>	Alpha	Early	Chapter 31.9A.2	80% size reduction
<b>Pipeline Mode</b>	Alpha	Early	Chapter 31.9A.2	17x throughput
<b>Prepared Stmt Cache</b>	Alpha	Early	Chapter 31.9A.2	50x speedup
<b>Vector Type Mapping</b>	Alpha	Early	Chapter 31.9A.3	Native pgvector
<b>JSONB Support</b>	Alpha	Early	Chapter 31.9A.3	Full compatibility

**Roadmap:** - Beta (Feb 2026): Extended client library testing - GA (Mar 2026): Full PostgreSQL compatibility certification

## Vollständige Feature-Matrix

**Vollständige Feature-Matrix siehe:** - Admin Tools: [feature\\_matrix.md](#) - Features Overview: [features\\_overview.md](#) - Sharding Status: Chapter 16 (Horizontal Scaling) - Security Status: Chapter 10 (Section 10.2) - Query Optimization: Chapter 15 (Section 15.4)

## Feature-Maturity-Levels

### Alpha (v1.4.0-alpha)

**Definition:** Neue Features in früher Entwicklung, für Feedback und Testing.

**Charakteristiken:** - Kernfunktionalität implementiert - Dokumentation vorhanden - ⚠ Noch nicht production-ready - ⚠ API kann sich ändern - ⚠ Performance noch nicht final optimiert

**Empfohlene Nutzung:** - Development/Staging Environments - Feature Evaluation - Feedback und Bug Reports

**Beta (geplant: Feb 2026)**

**Definition:** Features sind stabil, werden für Production vorbereitet.

**Charakteristiken:** - Vollständig implementiert - >80% Test Coverage - Performance-validated - ⚠️ Noch unter intensivem Testing - ⚠️ Minor API changes möglich

**Empfohlene Nutzung:** - Pre-Production Testing - Pilot-Deployments - Performance Benchmarking

**GA (General Availability - geplant: Mar 2026)**

**Definition:** Production-ready, vollständig getestet und dokumentiert.

**Charakteristiken:** - Production-Ready - >85% Test Coverage - Performance-validated - Complete Documentation - Stable API - Long-term Support

**Empfohlene Nutzung:** - Production Deployments - Mission-Critical Workloads - Enterprise Applications

**Implementierungsstatus v1.4.0-alpha**

**Gesamt-Übersicht**

Kategorie	Features	Alpha	Beta	GA	Geplant
LLM Integration	6	6	0	0	0
Performance	3	3	0	0	0
High Availability	4	4	0	0	0
Monitoring	5	5	0	0	0
PostgreSQL Protocol	7	7	0	0	0
Gesamt	25	25	0	0	0

**Prozentsatz:** - Alpha Features: 100% (25/25) - Production-Ready: 0% (Target: 100% by Mar 2026)

---

**Version History:** - 1.4.0-alpha (2026-01-06): 25 neue Alpha-Features (LLM, Performance, HA, Monitoring, Protocol) - 1.3.0 (2025-12-30): Umfassendes Update mit allen Features bis Dez 2025

## Anhang E - Incident Response Runbooks

---

*"Ein Runbook erspart dir in der Krise 10 Stunden Debugging. Schreib sie jetzt, nutze sie später."*

---

### Überblick

Detaillierte Playbooks für die häufigsten Production-Incidents in ThemisDB: Symptome, Diagnose, Fixes, Verification, Kommunikation.

---

### E.1 Incident: Query Latency > 1s (p99)

#### Symptom

- Alerts: `themis_query_latency_p99_gt_1000ms` für >5 Min
- User Report: "Suche dauert 10+ Sekunden"

## Diagnose (5 min)

```
1. Verify Alert ist real (nicht Sensor-Fehler)
curl -s http://localhost:8529/_admin/stats | jq '.queries[-10:] | .[].latency_ms'

2. Finde Slow Query
curl -s http://localhost:8529/_admin/slow-queries?threshold=500 | jq '.queries[0:3]'

3. Prüfe Collection-Größe
curl -s http://localhost:8529/_api/collection/users/counts | jq '.count'

4. Hole EXPLAIN Plan
aql "EXPLAIN <query>"
```

## Root Cause Analysis (Pick one)

### A. Missing Index

```
-- EXPLAIN zeigt CollectionScan?
EXPLAIN FOR u IN users FILTER u.email == 'alice@example.com' RETURN u

-- Output: type: "CollectionScan" → NO INDEX

-- Fix:
CREATE INDEX idx_email ON users(email)

-- Verify:
EXPLAIN ... -- sollte IndexNode zeigen
```

### B. Poor Index Choice

```
-- EXPLAIN zeigt wrong Index?
-- (z.B. idx_created_at bei Filter auf status)

-- Fix:
DROP INDEX users.old_index
CREATE INDEX idx_status_created ON users(status, created_at)

-- Query-Hint:
FOR u IN users
 FILTER u.status == 'active'
 SORT u.created_at DESC
 OPTIONS {indexHint: 'idx_status_created'}
RETURN u
```

### C. Huge Result Set (Memory Pressure)

```
-- x Returns 1M rows
FOR u IN users
 FILTER u.status == 'active'
 RETURN u -- No LIMIT!

-- Paginated
FOR u IN users
 FILTER u.status == 'active'
 LIMIT @offset, 100
RETURN u
```

### D. Expensive Operations (Regex, Full-Text)



```
-- x Regex auf 1M Docs
FOR u IN users
 FILTER u.name =~ '.*alice.*'
 RETURN u

-- Use Index + Full-Text
FOR u IN users
 FILTER u.status == 'active' -- Reduce set first
 SEARCH u.name IN FULLTEXT('alice') -- Then search
 RETURN u
```

## Fix (1-5 min)

```
Option 1: Add Index (immediate)
aql "CREATE INDEX idx_fix ON collection(field)"

Option 2: Patch Query
→ Update client code with LIMIT / Projection

Option 3: Increase Cache
→ Restart with larger cache_size_mb in themis.conf

Option 4: Load Rebalance
→ Migrate queries to different node
```

## Verify (2 min)

```
1. Run same query
time aql "<query>" # Should be <100ms now

2. Check Alert
Should clear within next evaluation window

3. Check Error Logs
journalctl -u themis -n 20 | grep ERROR
```

## Communicate

- Slack: "Query latency incident resolved: Added index on `collection.field`. P99 now 50ms."
  - Incident Ticket: Mark RESOLVED, link to index creation timestamp
- 

## E.2 Incident: High Memory Usage (RSS > 80%)

### Symptom

- Memory Usage Gauge: > 85% of available
- OOM Killer might start: `systemctl status themis | grep killed`

### Diagnose (3 min)

```
1. Check Memory
free -h
top -p $(pgrep themisdb)

2. Cache Usage
curl -s http://localhost:8529/_admin/cache | jq '.usage_mb'

3. Big Query?
curl -s http://localhost:8529/_admin/slow-queries?threshold=1 | jq '.queries[].memory_mb'

4. Cursor Leaks?
curl -s http://localhost:8529/_admin/cursors | jq 'length'
```

## Root Cause Analysis

### A. Large Result Set Materializing

```
-- x Materializes all rows
FOR doc IN large_collection
 FILTER doc.type == 'report'
 RETURN doc

-- Stream results
FOR doc IN large_collection
 FILTER doc.type == 'report'
 OPTIONS {stream: true}
 RETURN doc
```

## B. Cache Size Too Large

```
themis.conf
cache:
 size_mb: 16384 # Too big for 32GB system

Fix:
cache:
 size_mb: 8192 # ~25% of total RAM
```

## C. Cursor Leak (Clients not closing)

```
x Leak
cursor = client.query("FOR d IN collection RETURN d")
Never called: cursor.close()

Safe
with client.query("FOR d IN collection RETURN d") as cursor:
 for doc in cursor:
 process(doc)
```

## Fix (5-10 min)

### Quick Win: Restart

```
sudo systemctl restart themis
Memory drops to baseline, but queries restart
```

### Better: Graceful Drain

```
1. Mark DB as read-only
curl -X POST http://localhost:8529/_admin/readonly

2. Wait for active queries to finish (30s timeout)
sleep 30

3. Restart
sudo systemctl restart themis

4. Re-enable writes
curl -X POST http://localhost:8529/_admin/writable
```

### Verify

```
Check memory dropped
free -h
Cache usage normalized
curl -s http://localhost:8529/_admin/cache | jq '.usage_mb'
```

---

## E.3 Incident: Replication Lag > 5s

### Symptom

- Alert: `themis_replication_lag_ms > 5000`
- Secondary reads stale data (>5s behind Primary)

## Diagnose (2 min)

```
1. Check Follower Lag
curl -s http://localhost:8529/_admin/replication/lag

2. Primary Writes Throughput
curl -s http://localhost:8529/_admin/stats | jq '.writes_per_sec'

3. Follower CPU/IO
ssh follower-node "top -bn1 | head -15"

4. Network Latency
ping -c 10 follower-ip | tail -1
```

## Root Cause Analysis

### A. Follower Network Slow / Packet Loss

```
Fix: Check network path
iperf3 -c follower-ip -t 10 # Should be >100 Mbps
mtr follower-ip # Check for packet loss

Solution: Add network interface / reduce hops
```

### B. Follower Disk IO Bottleneck

```
Diagnose
iostat -x 1 5 | grep sda

If %util > 80%:
- Reduce write throughput on primary
- Add SSD to follower
- Enable compression on WAL
```

### C. Follower CPU Saturated

```
Check CPU
top -p $(pgrep themis)

Solution:
- Add cores to follower
- Reduce query load
- Move read-heavy queries to Primary temporarily
```

## Fix (5-30 min)

### Short-term: Manual Catchup

```
On Follower: Increase WAL read buffer
aql "UPDATE config SET wal_read_buffer_mb = 256"

Restart follower
sudo systemctl restart themis

Lag should drop as follower catches up
```

### Medium-term: Throttle Primary

```
themis.conf (Primary)
replication:
 max_writes_per_sec: 1000 # Slow down writes slightly
 follower_lag_warn_ms: 3000
```

## Verify

```
Lag should drop
curl -s http://localhost:8529/_admin/replication/lag | jq '.lag_ms'

Target: < 500ms for p99
```

## E.4 Incident: Deadlock Detected

### Symptom

- Error: `ERROR: Deadlock detected (Transaction A ↔ B)`
- Client Retry: Usually succeeds on 2nd attempt

### Diagnose (1 min)

```
Check deadlock frequency
curl -s http://localhost:8529/_admin/stats | jq '.deadlocks_total'

Should be: ~0 per hour (< 10 per day max)
If frequent: architecture issue
```

### Root Cause Analysis

#### A. Lock Ordering Inconsistency

```
-- Transaction A:
BEGIN
 LOCK collection1
 LOCK collection2
COMMIT

-- Transaction B (opposite order - DEADLOCK):
BEGIN
 LOCK collection2
 LOCK collection1
COMMIT

-- Fix: Enforce strict lock ordering (e.g. alphabetical)
```

#### B. Long Transactions

```
-- x 2-minute transaction
BEGIN
 FOR item IN items LIMIT 1000000
 UPDATE item WITH {updated: true} IN items
 COMMIT

-- Break into batches
FOR batch_start IN 0..1000000 STEP 10000
 BEGIN
 FOR item IN items
 FILTER item._id >= batch_start AND item._id < batch_start + 10000
 UPDATE item WITH {updated: true}
 COMMIT
```

## Fix (Immediate)

- **Client Side:** Add exponential retry (most deadlocks resolve on 2nd attempt)
- **Code:** Review and fix lock ordering (alphabetical, same order everywhere)
- **Monitoring:** If deadlocks > 10/day, escalate

## Verify

```
Deadlock rate should stay low
watch -n 60 'curl -s http://localhost:8529/_admin/stats | jq ".deadlocks_total"'
```

---

## E.5 Incident: Disk Space Critical (>95%)

### Symptom

- Alert: `themis_disk_usage_percent > 95`
- Cannot write new data



## Diagnose (2 min)

```
1. Check disk
df -h /data/themis

2. What's big?
du -sh /data/themis/* | sort -h

3. Log retention?
du -sh /var/log/themis*
```

## Root Cause Analysis

### A. WAL / Logs Explosion

```
Check sizes
ls -lh /data/themis/wal/
ls -lh /var/log/themis*

Likely: Log rotation disabled or interval too long
```

### B. Large Data Import (Staging)

```
If just imported: Delete staging collections
aql "TRUNCATE staging_collection"
aql "DROP COLLECTION temp_*
```

### C. Backup Staging Not Cleaned

```
Check
ls -lh /data/themis-backups/

Delete old backups
rm /data/themis-backups/backup-*.tar.gz
```

## Fix (5-15 min)

### Immediate:

```
1. Cleanup logs
journalctl --vacuum=2d

2. Cleanup old WAL
find /data/themis/wal -mtime +7 -delete

3. Truncate staging collections
aql "TRUNCATE staging"

Verify
df -h /data/themis
Should drop 10-50%
```

**Medium-term:**

```
themis.conf
logging:
 retention_days: 14
 max_file_size_mb: 100

wal:
 retention_files: 20 # Keep last 20 files
```

---

## E.6 Incident: Database Won't Start (Corruption)

### Symptom

- Startup Error: `ERROR: Corrupted block at offset 12345`
- Service Down: Cannot restart

## Diagnose (2 min)

```
1. Check logs
journalctl -u themis -n 50 | tail -20

2. Try recovery
themisdb recover /data/themis

3. Check disk
fsck /dev/sda1
```

## Root Cause Analysis

**A. Unclean Shutdown (Power Loss) - Fix:** Run WAL recovery (automatic on restart)

**B. Disk Corruption (Bad Sector) - Fix:** Replace disk, restore from backup

**C. RocksDB Internal Corruption (Rare) - Fix:** Backup data, rebuild database

## Fix

### Option 1: Automatic Recovery (Most Common)

```
ThemisDB will auto-recover from WAL
sudo systemctl start themis

Should boot successfully within 30s
```

### Option 2: Manual WAL Recovery

```
If auto-recovery fails
themisdb recover --wal-only /data/themis
sudo systemctl start themis
```

### Option 3: Restore from Backup

```
Last resort
sudo systemctl stop themis
tar -xzf /backup/themis-2026-01-01.tar.gz -C /data/
sudo chown -R themis:themis /data/themis
sudo systemctl start themis
```

## Verify

```
Check startup logs
journalctl -u themis -n 20

Verify data
aql "RETURN COUNT(*) FROM users"
```

# E.7 Incident: Security Alert: Unauthorized Access Attempt

## Symptom

- Alert: `themis_auth_failure_rate > 5_per_minute`
- Logs: `AUTH FAILED: user='admin' from_ip='1.2.3.4' password_attempts=10`

## Diagnose (1 min)

```
1. Check recent failures
curl -s http://localhost:8529/_admin/audit?event=auth_failure&last_1h | jq '.events[0:10]'

2. Identify attacker IP
cat /var/log/themis/auth.log | grep "FAILED" | cut -d' ' -f6 | sort | uniq -c | sort -rn

3. Check account
curl -s http://localhost:8529/_admin/users/admin | jq '.locked'
```

## Fix (2 min)

### Immediate:

```
1. Block attacker IP (Firewall)
sudo ufw insert 1 deny from 1.2.3.4

2. Lock compromised account
aql "UPDATE {name: 'admin'} WITH {locked: true, locked_reason: 'Brute force attempt'} IN users"

3. Force password reset
Send admin new temporary password

4. Enable MFA
aql "UPDATE {name: 'admin'} WITH {mfa_required: true} IN users"
```

**Escalation:** - Notify security team - Create incident ticket - Schedule post-mortem

## Verify

```
Auth failures should drop to 0
watch "tail -20 /var/log/themis/auth.log | grep FAILED | wc -l"
```

---

## E.8 Incident Severity Levels & Escalation

### Severity 1 (Critical - All Hands)

- Database completely down (no connections)
- Data corruption/loss detected
- All writes failing

**Escalation:** On-call Lead + CTO + Data Team

### Severity 2 (High - Urgent)

- Performance severely degraded (>10s latency)
- Replication lag > 30s
- Memory/Disk pressure critical

**Escalation:** On-call Engineer + Manager

### Severity 3 (Medium - Standard)

- Single query slow (1-5s)
- Moderate lag (5-30s)
- Non-critical errors in logs

**Escalation:** On-call Engineer

### Severity 4 (Low - Backlog)

- Single error/retry
- Performance degraded slightly
- Informational alerts

**Escalation:** Backlog Ticket

---

## E.9 Communication Template

### Incident Declared

```
INCIDENT: Query Latency High
Status: INVESTIGATING
Severity: SEV-2
Started: 2026-01-01 12:00:00 UTC
Impact: 5-10% of users experiencing slow search
```

### Root Cause Found

```
ROOT CAUSE IDENTIFIED: Missing index on users.email
Fix: CREATE INDEX idx_email ON users(email)
ETA Resolution: 5 minutes
```

## Resolved

INCIDENT RESOLVED

Resolution: Index created, queries now <100ms

Duration: 15 minutes

Post-mortem: Thursday 10am

---

## Summary

Keep this runbook near your on-call terminal. Most incidents fall into the categories above. When an alert fires: 1. **Navigate to right section** 2. **Run Diagnose commands** 3. **Match Root Cause** 4. **Execute Fix** 5. **Verify & Communicate**

Average resolution time with this playbook: **10-15 minutes** vs **60+ minutes** without.

## Anhang F - AQL Cheat Sheet

---

*"Every expert was once a novice. This sheet shortens that journey."*

---

## Overview

Quick reference for common AQL patterns, syntax, and idioms. For detailed docs, see Chapter 28.

## F.1 Basic Syntax

### Collections & Documents

```
-- Create Collection
CREATE COLLECTION users

-- Insert
INSERT {name: 'Alice', email: 'alice@example.com'} INTO users

-- Read
FOR u IN users RETURN u

-- Update
UPDATE 'users/123' WITH {status: 'active'} IN users

-- Delete
REMOVE 'users/123' IN users

-- Truncate (danger!)
TRUNCATE users
```



## Filtering

```
-- Simple equality
FOR u IN users FILTER u.status == 'active' RETURN u

-- Comparison operators
FILTER u.age > 18 AND u.age < 65
FILTER u.salary >= 50000
FILTER u.created_at < DATE_NOW()

-- IN operator
FILTER u.status IN ['active', 'pending', 'approved']

-- String operations
FILTER u.name LIKE 'A%' -- SQL-like wildcard
FILTER u.email =~ '^.*@example\.com$' -- Regex
FILTER CONTAINS(u.bio, 'engineer') -- Substring

-- Null checks
FILTER u.middle_name != NULL
FILTER u.phone_number == NULL

-- Range
FILTER u.score >= 100 AND u.score <= 200 -- vs RANGE below
```

## Sorting & Limiting

```
-- Order results
FOR u IN users
 SORT u.created_at DESC, u.name ASC
 RETURN u

-- Limit results
FOR u IN users
 SORT u.created_at DESC
 LIMIT 10 -- First 10
 RETURN u

-- Pagination
FOR u IN users
 SORT u.created_at DESC
 LIMIT @offset, @limit -- OFFSET, LIMIT
 RETURN u

-- Range operator (efficient for sorted data)
FOR u IN users
 RANGE u.score, 100, 200
 RETURN u
```

## Projection (Select Fields)

```
-- All fields
RETURN u

-- Specific fields
RETURN {name: u.name, email: u.email}

-- Computed fields
RETURN {
 name: u.name,
 age_years: DATE_DIFF(u.birth_date, DATE_NOW(), 'y'),
 email_masked: CONCAT(SUBSTRING(u.email, 0, 3), '***')
}

-- Nested structure
RETURN {
 user: {name: u.name, id: u._id},
 contact: {email: u.email, phone: u.phone}
}
```

## F.2 Advanced Filtering

### Aggregation Filter

```
-- Count documents
FOR u IN users
 COLLECT WITH COUNT INTO count
 RETURN {total_users: count}

-- Group and count
FOR u IN users
 COLLECT status = u.status WITH COUNT INTO count
 RETURN {status, count}

-- Group with aggregation
FOR o IN orders
 COLLECT customer_id = o.customer_id
 AGGREGATE total = SUM(o.amount), cnt = COUNT(1)
 RETURN {customer_id, total, cnt}
```

## Complex Filtering with Subqueries

```
-- Filter by aggregated value
FOR u IN users
 LET order_count = (
 FOR o IN orders FILTER o.user_id == u._id
 RETURN o
) | LENGTH
 FILTER order_count > 5
 RETURN {name: u.name, orders: order_count}

-- IN with subquery
FOR u IN users
 FILTER u._id IN (
 SELECT DISTINCT o.user_id FROM orders o WHERE o.status = 'completed'
)
 RETURN u
```

## Array Operations

```
-- Check array contains
FOR u IN users
 FILTER 'premium' IN u.roles
 RETURN u

-- Array length
FILTER LENGTH(u.tags) > 3

-- Array flatten
FOR u IN users
 LET all_ids = FLATTEN(u.related_user_ids)
 RETURN {name: u.name, related_count: LENGTH(all_ids)}

-- Array filtering
FOR u IN users
 LET recent_orders = u.orders[* FILTER CURRENT.date > DATE_SUBTRACT(DATE_NOW(), 30, 'd')]
 RETURN {name: u.name, recent_count: LENGTH(recent_orders)}
```

## F.3 Joins & Relationships

### INNER JOIN (Graph Traversal)

```
-- Simple traverse
FOR u IN users
 FOR o IN orders FILTER o.user_id == u._id
 RETURN {user: u.name, order_id: o._id}

-- With graph edges
FOR v, e, p IN 1..3 OUTBOUND users/123 GRAPH 'social'
 RETURN {vertex: v.name, edge: e.type, path: p.vertices[*]._id}

-- Shortest path
FOR path IN SHORTEST_PATH('users/123' TO 'users/456' GRAPH 'social')
 RETURN path
```

### LEFT JOIN (Keep unmatched)

```
-- Users even if no orders
FOR u IN users
 LET orders = (FOR o IN orders FILTER o.user_id == u._id RETURN o)
 RETURN {user: u.name, order_count: LENGTH(orders), orders}
```

### Multiple joins

```
FOR u IN users
 LET orders = (FOR o IN orders FILTER o.user_id == u._id RETURN o)
 LET addresses = (FOR a IN addresses FILTER a.user_id == u._id RETURN a)
 FILTER LENGTH(orders) > 0 AND LENGTH(addresses) > 0
 RETURN {user: u.name, order_count: LENGTH(orders), address_count: LENGTH(addresses)}
```

## F.4 Transactions

### Basic Transaction

```
BEGIN
 INSERT {name: 'Bob', balance: 100} INTO accounts
 INSERT {from: 'Alice', to: 'Bob', amount: 50} INTO transfers
COMMIT
```

### With Error Handling

```
BEGIN
 LET update = UPDATE 'accounts/alice'
 WITH {balance: (SELECT account.balance - 50 FROM accounts FILTER _id == 'accounts/alice')[0]}
 IN accounts

 IF u.balance < 50 THEN
 ABORT "Insufficient funds"
 ELSE
 INSERT {from: 'alice', to: 'bob', amount: 50} INTO transfers
 COMMIT
 ENDIF
```

## F.5 Vector Search

### Simple Vector Search

```
-- Create vector index
CREATE INDEX idx_embedding ON articles(embedding)

-- Vector search (nearest neighbors)
FOR article IN articles
 FILTER DISTANCE(article.embedding, @query_embedding) < @threshold
 SORT DISTANCE(article.embedding, @query_embedding)
 LIMIT 10
 RETURN {title: article.title, distance: DISTANCE(article.embedding, @query_embedding)}

-- With parameters
db.query("""
 FOR article IN articles
 FILTER DISTANCE(article.embedding, @query_vec) < @threshold
 SORT DISTANCE(article.embedding, @query_vec)
 LIMIT @top_k
 RETURN article
""", bind_vars={
 'query_vec': [0.1, -0.2, 0.3, ...],
 'threshold': 0.5,
 'top_k': 5
})
```

### Hybrid Search (Vector + Text)

```
-- Combine vector + full-text
FOR article IN articles
 FILTER DISTANCE(article.embedding, @query_vec) < @threshold
 SEARCH article.title IN FULLTEXT(@query_text)
 SORT BM25(article) DESC -- Relevance score
 RETURN {title: article.title, score: BM25(article)}
```



## F.6 Graph Queries

### Breadth-First Traversal

```
-- Get all friends of friends
FOR v IN 0..2 OUTBOUND 'users/alice' GRAPH 'social'
 RETURN {name: v.name, hops: LENGTH(p) - 1}

-- Prevent cycles
FOR v IN 1..3 OUTBOUND 'users/alice' GRAPH 'social'
 FILTER v._key NOT IN ['alice'] -- Don't revisit start node
 RETURN v
```

### Depth-First with Conditions

```
-- Traverse until condition met
FOR v IN OUTBOUND 'users/alice' GRAPH 'social'
 FILTER v.status != 'banned'
 LIMIT 100
 RETURN v
```

### Community Detection

```
-- Find clusters of connected users
FOR start IN users
 LET connected = (
 FOR v IN OUTBOUND start GRAPH 'social'
 RETURN DISTINCT v._id
)
 COLLECT id = start._id, group = connected
 RETURN {user: id, cluster_size: LENGTH(group)}
```

## F.7 Time-Series Queries

### Bucket by Time

```
-- Sales per day
FOR order IN orders
 COLLECT date = DATE_FORMAT(order.created_at, '%yyyy-%mm-%dd')
 AGGREGATE total = SUM(order.amount), cnt = COUNT(1)
 SORT date
 RETURN {date, total, cnt}

-- Sales per hour (last 24h)
FOR order IN orders
 FILTER order.created_at > DATE_SUBTRACT(DATE_NOW(), 1, 'd')
 COLLECT hour = DATE_FORMAT(order.created_at, '%yyyy-%mm-%dd %hh:00')
 AGGREGATE total = SUM(order.amount)
 RETURN {hour, total}
```

### Moving Average

```
-- 7-day moving average of daily sales
FOR day IN 0..30
 LET current_date = DATE_SUBTRACT(DATE_NOW(), day, 'd')
 LET week_start = DATE_SUBTRACT(current_date, 7, 'd')
 LET sales = (
 FOR o IN orders
 FILTER o.created_at >= week_start AND o.created_at <= current_date
 RETURN o.amount
)
 COLLECT date = DATE_FORMAT(current_date, '%yyyy-%mm-%dd')
 AGGREGATE avg = AVG(sales)
 SORT date
 RETURN {date, moving_avg_7d: avg}
```

## F.8 Window Functions

### Row Numbers & Ranking

```
-- Rank users by sales
FOR u IN users
 LET total_sales = (
 SELECT SUM(amount) AS total FROM orders WHERE customer_id == u._id
)[0].total
 SORT total_sales DESC
 RETURN {
 rank: @row_number,
 name: u.name,
 total_sales
 }

-- Cumulative sum
FOR o IN orders
 SORT o.created_at
 COLLECT WITH COUNT INTO cnt
 AGGREGATE cumulative = SUM(o.amount)
 RETURN {cumulative, running_total: @row_number}
```

## F.9 Common Patterns

### Pagination with Cursor

```
-- Cursor-based pagination (efficient for large datasets)
FOR u IN users
 FILTER u._key > @cursor
 SORT u._key
 LIMIT 20
 RETURN u

-- No OFFSET (O(1) instead of O(n))
```

### Deduplication

```
-- Get distinct values
FOR u IN users
 COLLECT email = u.email
 RETURN email

-- Get first of each group
FOR u IN users
 COLLECT category = u.category
 INTO group = u
 RETURN {category, first_user: group[0]}
```

## Batch Operations

```
-- Batch insert
FOR item IN @items
 INSERT item INTO products

-- Batch update
FOR item IN items
 FILTER item.status == 'pending'
 UPDATE item WITH {status: 'processed'} IN items
```

## Error Handling

```
-- TRY-CATCH
BEGIN
 LET result = (
 TRY
 FOR u IN users FILTER u._id == @user_id RETURN u
 CATCH err
 RETURN {error: err.message}
)
 RETURN result
COMMIT
```

## F.10 Performance Tips

### Query Optimization Checklist

- ✓ Use FILTER before SORT
- ✓ Use LIMIT to reduce result set
- ✓ Add indexes on FILTER/SORT fields
- ✓ Use COLLECT for aggregations (not manual loops)
- ✓ Avoid FULLTEXT searches on tiny datasets
- ✓ Stream large results (avoid materializing)
- ✓ Use bind parameters (@var) not inline values

### Slow Query Patterns to Avoid

```
-- x SLOW: Regex without index
FILTER u.email =~ '.*@gmail\.com'

-- FAST: Use LIKE with index
CREATE INDEX idx_email ON users(email)
FILTER u.email LIKE '%@gmail.com'

-- x SLOW: Expression in FILTER
FILTER YEAR(u.birth_date) == 1990

-- FAST: Use range on indexed field
CREATE INDEX idx_birth ON users(birth_date)
FILTER u.birth_date >= '1990-01-01' AND u.birth_date < '1991-01-01'
```

## F.11 Built-in Functions (Most Common)

### String Functions

Function	Example	Returns
CONCAT()	CONCAT('Hello', ' ', 'World')	'Hello World'
CONTAINS()	CONTAINS('Hello', 'ell')	true
SUBSTRING()	SUBSTRING('Hello', 0, 3)	'Hel'
LENGTH()	LENGTH('Hello')	5
UPPER()	UPPER('hello')	'HELLO'
LOWER()	LOWER('HELLO')	'hello'
SPLIT()	SPLIT('a,b,c', ',')	['a', 'b', 'c']

### Date/Time Functions

Function	Example	Returns
DATE_NOW()	DATE_NOW()	Current timestamp
DATE_FORMAT()	DATE_FORMAT(d, '%yyyy-%mm-%dd')	Formatted date
DATE_ADD()	DATE_ADD('2025-01-01', 5, 'd')	Date + 5 days
DATE_SUBTRACT()	DATE_SUBTRACT(d, 1, 'm')	Date - 1 month
DATE_DIFF()	DATE_DIFF(d1, d2, 'd')	Days between

## Math Functions

Function	Example	Returns
<code>SUM()</code>	<code>SUM(o.amount)</code>	Sum of values
<code>AVG()</code>	<code>AVG(o.amount)</code>	Average
<code>MIN()</code> / <code>MAX()</code>	<code>MIN(values)</code>	Min/Max
<code>ROUND()</code>	<code>ROUND(3.7)</code>	4
<code>FLOOR()</code> / <code>CEIL()</code>	<code>FLOOR(3.7)</code>	3
<code>ABS()</code>	<code>ABS(-5)</code>	5
<code>SQRT()</code>	<code>SQRT(16)</code>	4

## Array Functions

Function	Example	Returns
<code>LENGTH()</code>	<code>LENGTH([1,2,3])</code>	3
<code>APPEND()</code>	<code>APPEND(arr, item)</code>	Array + item
<code>REVERSE()</code>	<code>REVERSE([1,2,3])</code>	[3,2,1]
<code>UNIQUE()</code>	<code>UNIQUE([1,1,2])</code>	[1,2]
<code>FLATTEN()</code>	<code>FLATTEN([ [1,2], [3] ])</code>	[1,2,3]
<code>SLICE()</code>	<code>SLICE([1,2,3,4], 1, 3)</code>	[2,3]



---

## F.12 Index Types

```
-- Unique Index
CREATE INDEX idx_email UNIQUE ON users(email)

-- Compound Index (Multiple fields)
CREATE INDEX idx_status_date ON orders(status, created_at)

-- Partial Index (Conditional)
CREATE INDEX idx_active_users ON users(name)
 FILTER u.status == 'active'

-- TTL Index (Auto-delete)
CREATE INDEX idx_temp ON temp_data(created_at)
 WITH {ttl: 3600} -- Auto-delete after 1 hour

-- Full-Text Index
CREATE FULLTEXT INDEX idx_content ON articles(body)
```

---

## Summary

Bookmark this section! Most queries can be built from these patterns. When stuck: 1. **Check pattern above** 2. **Run EXPLAIN to verify optimization** 3. **See Chapter 28 for detailed docs**

---

## Anhang G - Configuration Reference

---

*"Good defaults get you 90% of the way. This reference handles the other 10%."*

---

## Overview

Complete reference for all ThemisDB configuration options. Default values optimized for single-node deployments.

---

## G.1 Main Configuration File (themis.conf)

### Location & Format

```
Location: /etc/themis/themis.conf (root) or ~/.themis/themis.conf (user)
Format: YAML 1.2
Reload: systemctl reload themis (no restart needed for most settings)
```

### Server Settings

#### port

```
server:
 port: 8529 # Default: 8529 (0x2149)
 # Range: 1024-65535
 # Tip: Use ports 8529-8539 to run multiple instances
```

#### bind\_address

```
server:
 bind_address: "127.0.0.1" # Default: localhost only
 # "0.0.0.0" → Listen on all interfaces
 # Tip: Use localhost in dev, 0.0.0.0 in containerized deployments
```

### max\_connections

```
server:
 max_connections: 1000 # Default: 1000
 # Depends on file descriptor limit (ulimit -n)
 # Scaling rule: 1 connection = ~10 KB memory overhead
 # If 10k connections: ~100 MB RAM just for connection state
```

### request\_timeout\_ms

```
server:
 request_timeout_ms: 30000 # Default: 30 sec
 # Queries longer than this abort with timeout
 # Long-running imports: increase to 300000 (5 min)
```

### enable\_http2

```
server:
 enable_http2: true # Default: true
 # Set false for testing/debugging with curl
```

---

## G.2 Database Settings

### data\_directory

```
database:
 data_directory: "/var/lib/themis" # Default
 # Must be on fast storage (SSD preferred)
 # Recommendation: NVMe > SSD > HDD (in order of performance)
 # Min free space: 2x database size
```

## engine\_type

```
database:
 engine_type: "rocksdb" # Only option (default)
 # RocksDB is LSM-tree optimized for writes
 # 45k-60k writes/sec on modern hardware
```

## wal\_enabled

```
database:
 wal_enabled: true # Default: true (REQUIRED for ACID)
 # Set false ONLY for ephemeral/test deployments
```

## wal\_directory

```
database:
 wal_directory: "/var/lib/themis/wal" # Default
 # Tip: Put on separate disk from data for durability
```

## wal\_sync\_mode

```
database:
 wal_sync_mode: "fsync" # Default: fsync (safe)
 # Options:
 # "fsync" → Durability: ✓✓✓ (safe) | Speed: ✓ (slowest)
 # "os" → Durability: ✓✓ (eventual) | Speed: ✓✓
 # "none" → Durability: ✓ (risky) | Speed: ✓✓✓ (fastest)
 # Recommendation: fsync for production, os for staging, none for local dev
```

## compression\_algorithm

```
database:
 compression_algorithm: "zstd" # Default: zstd
 # Options: "zstd" (best) | "lz4" (fast) | "snappy" | "none"
 # Recommendation: zstd for storage-constrained, lz4 for latency-critical
```

## G.3 Cache Settings

### cache\_size\_mb

```
cache:
 size_mb: 2048 # Default: 2048 (2 GB)
 # Rule of thumb: 25-30% of total system RAM
 # Example: 32 GB system → 8-10 GB cache
 # Observability: curl http://localhost:8529/_admin/cache
```

### cache\_mode

```
cache:
 mode: "lru" # Default: lru (Least Recently Used)
 # Options: "lru" | "lfu" (Least Frequently Used)
 # LRU: Better for time-dependent patterns
 # LFU: Better for popularity-based patterns
```

### block\_cache\_size\_mb

```
cache:
 block_cache_size_mb: 1024 # Default: 1024
 # RocksDB block cache (L1 cache for block decompression)
 # Typically 50% of cache_size_mb
```

---

## G.4 Index Settings

### default\_index\_type

```
indexing:
 default_index_type: "btree" # Default: btree
 # Options: "btree" | "hash" | "skiplist"
 # btree: Ordered access (good for range queries)
 # hash: Point lookups only (fastest for equality)
 # skiplist: Ordered with faster random access than btree
```

### vector\_index\_default

```
indexing:
 vector_index_default: "hnsu" # Default: hnsu
 # Options: "hnsu" (Hierarchical Navigable Small Worlds)
 # Settings:
 # m: 16 # Connections per layer (16-64, default 16)
 # ef_construct: 200 # Quality during construction (default)
 # ef_search: 100 # Quality during search (default)
```

---

## G.5 Query Settings

### query\_timeout\_ms

```
query:
 timeout_ms: 30000 # Default: 30 sec
 # Queries exceeding this timeout abort
 # Set to -1 for no timeout (not recommended)
```

## query\_cache\_enabled

```
query:
 cache_enabled: true # Default: true
 # Caches query plans (not results)
 # Reduces compilation overhead for repeated queries
```

## max\_query\_result\_size\_mb

```
query:
 max_query_result_size_mb: 512 # Default: 512
 # Result sets larger than this fail
 # Reason: Prevents memory bombs from buggy queries
 # Fix: Use LIMIT or OFFSET to paginate results
```

---

# G.6 Replication Settings

## replication\_enabled

```
replication:
 enabled: true # Default: true
 # false for standalone instances
```

## replication\_role

```
replication:
 role: "primary" # or "follower"
 # primary: Accepts writes, logs all changes
 # follower: Read-only, applies logs from primary
```

## follower\_primary\_address

```
replication:
 follower_primary_address: "primary.example.com:8529" # Only for followers
 # Follower connects to primary at this address
```

## replication\_buffer\_size\_mb

```
replication:
 buffer_size_mb: 256 # Default: 256
 # Follower buffer for incoming changes
 # Larger = handle larger write spikes
```

## replication\_sync\_interval\_ms

```
replication:
 sync_interval_ms: 100 # Default: 100
 # How often to sync WAL changes to follower
 # Lower = lower latency, higher CPU
 # 100ms is good for most workloads
```

---

## G.7 Security Settings

### authentication\_enabled

```
security:
 authentication:
 enabled: true # Default: true
 # false: No authentication (dev-only!)
```



## jwt\_secret

```
security:
 authentication:
 jwt_secret: "${JWT_SECRET}" # Must set via env var
 # Min 32 characters, high entropy
 # Generate: openssl rand -hex 32
```

## jwt\_expiry\_minutes

```
security:
 authentication:
 jwt_expiry_minutes: 1440 # Default: 24 hours
 # Tokens expire after this time
 # Shorter = better security, more refresh overhead
```

## tls\_enabled

```
security:
 tls:
 enabled: true # Default: true
 # false only for insecure local dev
```

## tls\_cert\_path

```
security:
 tls:
 cert_path: "/etc/themis/certs/server.crt"
 # X.509 certificate (RSA 4096 recommended)
```

## tls\_key\_path

```
security:
 tls:
 key_path: "/etc/themis/certs/server.key"
 # Private key (must have 0600 permissions)
```

## tls\_min\_version

```
security:
 tls:
 min_version: "1.3" # Default: "1.3"
 # Options: "1.2" (legacy) | "1.3" (modern)
 # Recommendation: "1.3" for new deployments
```

## mfa\_required

```
security:
 mfa_required: false # Default: false
 # true: All users must enable MFA
```

---

# G.8 Audit Logging

## audit\_enabled

```
audit:
 enabled: true # Default: true
 # Logs all changes to collections
```

## audit\_directory

```
audit:
 directory: "/var/log/themis/audit"
 # Must be on write-optimized storage
```

## audit\_retention\_days

```
audit:
 retention_days: 365 # Default: 365 days
 # Older logs auto-purged (if compliance allows)
```

## audit\_include\_data

```
audit:
 include_data: false # Default: false
 # true: Store full document in audit log (verbose!)
 # Recommendation: false (log metadata only)
```

---

# G.9 Performance Tuning

## memory\_cache\_warmup

```
performance:
 cache_warmup_enabled: true # Default: true
 # Loads frequently accessed data into cache on startup
 # Reduces first-query latency
```

## memory\_buffer\_size\_mb

```
performance:
 memory_buffer_size_mb: 512 # Default: 512
 # In-memory write buffer before flushing to disk
 # Larger = better batching, more RAM
 # Rule: 10-20% of cache_size_mb
```

## io\_parallelism

```
performance:
 io_parallelism: 4 # Default: number of CPU cores
 # Concurrent IO operations
 # Higher = better throughput on SSD, diminishing returns on HDD
```

---

# G.10 Logging

## log\_level

```
logging:
 level: "info" # Default: info
 # Options: "debug" | "info" | "warn" | "error" | "critical"
 # Recommendations:
 # production: "warn"
 # staging: "info"
 # development: "debug"
```

## log\_format

```
logging:
 format: "json" # Default: json
 # Options: "json" | "text"
 # json: Machine parseable (for aggregation)
 # text: Human readable
```

## log\_retention\_days

```
logging:
 retention_days: 30 # Default: 30
 # Older logs auto-deleted
 # For compliance: increase to 365+
```

## log\_max\_file\_size\_mb

```
logging:
 max_file_size_mb: 100 # Default: 100
 # Rotate log file when it exceeds this size
```

---

## G.11 Vector Search Tuning

### vector\_similarity\_metric

```
vector:
 similarity_metric: "cosine" # Default: cosine
 # Options: "cosine" | "euclidean" | "manhattan" | "dot"
 # cosine: Best for normalized embeddings (e.g., from BERT)
 # euclidean: Good for raw embeddings
```

### hnsf\_ef\_search

```
vector:
 hnsf_ef_search: 100 # Default: 100
 # Exploration factor during search
 # Higher = more accurate, slower
 # Range: 10-1000
 # Rule: Start with 100, tune based on latency/accuracy tradeoff
```

## hnsw\_m

```
vector:
 hnsw_m: 16 # Default: 16
 # Connections per layer in HNSW graph
 # Higher = more accurate, more memory
 # Range: 8-64
```

---

## G.12 Development Settings

### dev\_mode\_enabled

```
development:
 dev_mode_enabled: false # Default: false
 # true: Disables some security checks (LOCAL DEV ONLY)
 # Enables: Hot reload, relaxed CORS, schema auto-creation
```

### cors\_enabled

```
development:
 cors_enabled: false # Default: false
 # true: Allow cross-origin requests
 # Set specific origins in production (not "*")
```

### cors\_origins

```
development:
 cors_origins:
 - "http://localhost:3000" # Frontend dev server
 - "http://localhost:8080"
```

---

## G.13 Example Configurations

### Single Node (Development)

```
server:
 port: 8529
 bind_address: "127.0.0.1"
 max_connections: 100

database:
 wal_sync_mode: "os" # Fast, eventual durability
 compression_algorithm: "lz4"

cache:
 size_mb: 512 # Small for dev machine

query:
 timeout_ms: -1 # No timeout for debugging

logging:
 level: "debug"
 format: "text" # Human readable
```

## Production (Single Node, 32GB RAM)

```
server:
 port: 8529
 bind_address: "0.0.0.0"
 max_connections: 1000

database:
 data_directory: "/data/themis"
 wal_sync_mode: "fsync"
 compression_algorithm: "zstd"

cache:
 size_mb: 8192 # 25% of 32GB

security:
 tls_enabled: true
 jwt_secret: "${JWT_SECRET}" # From env var

audit:
 enabled: true
 retention_days: 365

logging:
 level: "warn"
 format: "json"
 retention_days: 90
```



## High-Performance (Writes, 64GB RAM)

```
database:
 wal_sync_mode: "os" # Trade safety for speed
 compression_algorithm: "lz4" # Faster than zstd

cache:
 size_mb: 16384 # 25% of 64GB
 block_cache_size_mb: 4096

performance:
 memory_buffer_size_mb: 2048 # Larger batches
 io_parallelism: 8

query:
 max_query_result_size_mb: 2048 # Allow larger results
```

## Analytics (Reads, 128GB RAM)

```
cache:
 size_mb: 32768 # 25% of 128GB
 mode: "lfu" # Popularity-based caching

indexing:
 vector_index_default: "hns"
 hns_ef_search: 200 # More accuracy for analytics

query:
 timeout_ms: 300000 # 5 minutes (long aggregations)
 max_query_result_size_mb: 4096 # Large result sets
```

---

## G.14 Linux Kernel Tuning (sysctl)

These affect OS-level performance:

```
File descriptors (support 10k+ connections)
echo "fs.file-max = 2097152" >> /etc/sysctl.conf
echo "* soft nfile 100000" >> /etc/security/limits.conf
echo "* hard nfile 100000" >> /etc/security/limits.conf

Memory
echo "vm.swappiness = 10" >> /etc/sysctl.conf # Prefer RAM over swap

Network (if using TCP for replication)
echo "net.core.rmem_max = 134217728" >> /etc/sysctl.conf
echo "net.core.wmem_max = 134217728" >> /etc/sysctl.conf

Apply changes
sysctl -p
```

---

## G.15 Environment Variables

### Common Env Vars

```
Required
export JWT_SECRET="$(openssl rand -hex 32)"

Optional
export THEMIS_PORT=8529
export THEMIS_BIND_ADDRESS=0.0.0.0
export THEMIS_DATA_DIR=/data/themis
export THEMIS_LOG_LEVEL=info
export THEMIS_CACHE_SIZE_MB=2048

Run with env vars
themisdb run
```

---

## G.16 Configuration Validation

### Validate Config File

```
Check syntax
themisdb config validate /etc/themis/themis.conf

Check all settings
themisdb config show
```

### Health Check

```
After startup
curl -s http://localhost:8529/_admin/health | jq .

Expected:
{
"status": "ready",
"uptime_seconds": 123,
"memory_mb": 456,
"cache_hit_rate": 0.87
}
```

---

## G.17 Configuration Change Checklist

Before changing production config: - [ ] Backup current config: `cp themis.conf themis.conf.backup` - [ ] Test change on staging first - [ ] If safe: `systemctl reload themis` (no restart) - [ ] Monitor metrics for 5 minutes - [ ] Have rollback plan (restore .backup file)

---

## Summary

**Most Common Tuning Knobs:** 1. **cache\_size\_mb** - Available memory (25-30% of RAM) 2.

**wal\_sync\_mode** - Safety vs. latency tradeoff 3. **compression\_algorithm** - Storage vs. speed 4. **log\_level** - Observability cost 5. **query\_timeout\_ms** - Prevent runaway queries

Start with defaults, measure, change one thing at a time, monitor impact.

---

# Anhang H - Glossary & Terminology

---

*"Every domain has its jargon. Understand the terminology, understand the system."*

---

## H.1 Core Database Concepts

### Base Entity

The fundamental unit of data in ThemisDB. Combines relational, document, graph, vector, and time-series aspects in a single unified structure.

#### Example:

```
{
 "_id": "users/alice",
 "_key": "alice",
 "_rev": 5,
 "name": "Alice",
 "email": "alice@example.com",
 "created_at": "2025-01-01T10:00:00Z",
 "embedding": [0.1, -0.2, 0.3, ...],
 "graph_edges": ["users/bob", "users/charlie"]
}
```

## Collection

A group of related Base Entities (similar to a SQL table, but more flexible).

**Types:** - **Relational:** users, orders, products - **Document:** articles, posts, documents - **Graph:** relationships, friendships - **Vector:** embeddings, semantic data

## Transaction

An atomic unit of work. Either all operations succeed (COMMIT) or all rollback. Provides ACID guarantees.

```
BEGIN
 INSERT {...} INTO users
 UPDATE {...} IN orders
COMMIT
```

## ACID Guarantees

- **Atomicity:** All or nothing
- **Consistency:** Data integrity maintained
- **Isolation:** No dirty reads/writes
- **Durability:** Persisted to disk

---

## H.2 Query Language (AQL)

### AQL (Adaptive Query Language)

Unified query language for all data models in ThemisDB. Combines SQL (relational), graph traversal, document processing, and vector search.

**Core Constructs:** - FOR ... IN: Iteration - FILTER: Conditional selection - LET: Variable binding - COLLECT: Grouping/aggregation - SORT: Ordering - LIMIT: Result limiting - RETURN: Output specification

### Bind Variables

Parameterized query parameters (prevent injection attacks).

```
FOR user IN users
 FILTER user.email == @email
RETURN user
```

Run with: `db.query(query, bind_vars={'email': 'alice@example.com'})`

Query Plan

Execution strategy optimized by the query optimizer.

**Components:** - **Collection Scan:** Read all documents (slow) - **Index Seek:** Use index to find matching rows (fast) - **Filter:** Apply WHERE conditions - **Sort:** Order results - **Aggregation:** GROUP BY operations

H.3 Indexing & Performance

Index

Data structure enabling fast lookups. Trade: space for speed.

Types:

Type	Ordered	Point Lookup	Range Query	Size
BTree	✓	Fast	Fast	Large
Hash	✗	Very Fast	Slow	Medium
Skiplist	✓	Fast	Fast	Medium
Inverted	✗	Fast	N/A	Large

Query Cardinality

Estimated number of rows matching query conditions.

Low cardinality (< 1% of docs):

→ Use index for fast filtering

High cardinality (> 50% of docs):

→ Collection scan might be faster (no index overhead)

## Selectivity

How well an index reduces result set.

$\text{Selectivity} = \text{Matching rows} / \text{Total rows}$

High selectivity (< 5%):

→ Use index

Low selectivity (> 50%):

→ Collection scan faster

---

## H.4 Replication & Consistency

### Primary (Master)

Single database node accepting writes. Log changes to replicas.

### Follower (Replica)

Read-only copy of primary. Applies changes asynchronously from WAL.

### Replication Lag

Delay between write on primary and replica visibility.

Write at Primary:  $T_0$

Arrive at Follower:  $T_0 + \text{lag\_ms}$

Visible to read:  $T_0 + \text{lag\_ms} + \text{apply\_time}$

**Acceptable lag:** - Strongly consistent: 0ms (no lag) - Eventual consistent: < 5 seconds - Archive: minutes to hours

## Write-Ahead Log (WAL)

Durability mechanism. All writes logged before applied.

Client write:

1. Write to WAL on disk
2. Apply to in-memory database
3. Ack to client

On crash:

1. Replay WAL on startup
2. Resume from last committed state

## Quorum Write

Write acknowledged only after reaching majority of replicas.

3-node cluster:

$$\text{Quorum} = (3 + 1) / 2 = 2 \text{ nodes}$$

Write must be on Primary + 1 Follower before ack

---

## H.5 Vector Search Concepts

### Embedding

Dense vector representation of unstructured data.

"Alice is an engineer"

→ [0.1, -0.2, 0.3, 0.15, -0.08, ...] # 384 dimensions



## Similarity

Measure of how close two vectors are.

Metric	Range	Best For
Cosine	$[-1, 1]$	Normalized embeddings (angles)
Euclidean	$[0, \infty)$	Raw embeddings (distances)
Dot Product	$(-\infty, \infty)$	Unnormalized embeddings

## Nearest Neighbor Search

Find K closest vectors to a query vector.

```
FOR v IN vectors
 FILTER DISTANCE(v.embedding, @query) < @threshold
 SORT DISTANCE(v.embedding, @query)
 LIMIT @top_k
 RETURN v
```

## HNSW (Hierarchical Navigable Small Worlds)

Approximate nearest neighbor index algorithm.

**Parameters:** - **M**: Connections per node (16-64, default 16) - **ef\_construct**: Quality during index building - **ef\_search**: Quality during searches

## H.6 Graph Concepts

### Node (Vertex)


Entity in a graph. Represents an object or concept.

### Edge (Relationship)

Connection between two nodes. Directed or undirected.

## Graph Traversal

Following edges to discover related nodes.



## Path

Sequence of nodes and edges.

```
Shortest path from Alice to Charlie:
Alice --(follows)-- Bob --(follows)-- Charlie
Length: 2 hops
```

## Centrality

Measure of node importance.

**Types:** - **Degree:** Number of connections - **Betweenness:** How often on shortest paths - **Closeness:** Average distance to others - **PageRank:** Voting-based importance

---

## H.7 Time-Series Concepts

### Time-Series Data

Ordered sequence of measurements over time.

```
Metric: CPU Usage
Timestamp 1: 45%
Timestamp 2: 52%
Timestamp 3: 48%
...
```

## Bucket / Time Window

Grouping data into time periods.

```
FOR metric IN metrics
 COLLECT hour = DATE_FORMAT(metric.timestamp, '%yyyy-%mm-%dd %hh:00')
 AGGREGATE avg = AVG(metric.value)
RETURN { hour, avg }
```

## Downsampling

Reducing time-series resolution (e.g., minute → hour).

```
High resolution: Every second (86,400 points/day)
Low resolution: Every hour (24 points/day)
Compression: 99.97% reduction
```

---

## H.8 Operational Concepts

### SLA (Service Level Agreement)

Contractual commitment on availability and performance.

```
SLA: "99.9% uptime with p99 latency < 200ms"
 → Downtime allowed: 43.2 minutes/month
 → 1 in 1000 queries can exceed 200ms
```

### SLI (Service Level Indicator)

Measurable metric of actual performance.

```
SLI: Actual uptime = 99.92%
SLI: Actual p99 latency = 187ms
```

## Error Budget

Acceptable downtime/errors for SLA.

```
SLA: 99.95% uptime
Error budget = 0.05% = 21.6 minutes/month

Used: 15 minutes
Remaining: 6.6 minutes (use for deployments/maintenance)
```

## MTTR (Mean Time To Recovery)

Average time to fix a problem.

```
Incident starts: 10:00
Recovery complete: 10:15
MTTR = 15 minutes
```

## MTTF (Mean Time To Failure)

Average time before next failure.

```
Downtime: 15 minutes
Recovery: 30 minutes (MTTR)
Uptime: 30 days until next failure
MTTF = 30 days
```

---

## H.9 Security Concepts

### RBAC (Role-Based Access Control)

Access control based on user roles.

```
Role: 'data_analyst'

Permissions:
 - READ from analytics_*
 - EXECUTE report queries
 - NO WRITE/DELETE
```

## JWT (JSON Web Token)

Stateless authentication token.

```
Header: { alg: "HS256", typ: "JWT" }
Payload: { sub: "alice", exp: 1726000000 }
Signature: HMAC-SHA256(header + payload, secret)
```

## Encryption at Rest

Data encrypted on disk.

```
File on disk: [encrypted bytes]
In memory: Clear text (needed for processing)
Key location: HSM (Hardware Security Module)
```

## Encryption in Transit

Data encrypted while traveling network.

```
TLS 1.3 + Perfect Forward Secrecy
 → Even if long-term key compromised, old traffic safe
```

## MFA (Multi-Factor Authentication)

Multiple authentication mechanisms.

1. Password (something you know)
2. TOTP (something you have) - app code
3. WebAuthn (something you are) - fingerprint

---

## H.10 Architecture Concepts

### Monolithic Architecture

All components in single process. Easy to develop, hard to scale.

### Microservices

Each service independent. Scales well, operational complexity.

### ThemisDB: Hybrid Approach

- **Monolithic Core:** Single database engine
- **Distributed:** Horizontal sharding for scale-out
- **Multi-Model:** All data models in one engine (no microservices)

### Horizontal Scaling

Add more nodes (scale out). Divide data via sharding.

```
1 node (10TB limit)
 ↓
2 nodes (5TB each)
 ↓
4 nodes (2.5TB each)
```

### Vertical Scaling

Upgrade hardware (scale up). More RAM/CPU per node.

```
32GB RAM
 ↓
64GB RAM
```

## H.11 Monitoring & Observability

### Metrics

Quantitative measurements (numbers).

CPU usage: 45%

Memory: 8.2 GB

Queries per second: 1,200

Latency p99: 185ms

### Logs

Textual records of events.

2025-01-01T10:00:00Z [INFO] Query executed: SELECT \* FROM users

2025-01-01T10:00:01Z [WARN] Query latency: 245ms > threshold 200ms

2025-01-01T10:00:02Z [ERROR] Connection timeout from client 1.2.3.4

### Traces

Request flow through system (distributed tracing).

User Request

└ API Gateway (5ms)

└ Authentication (12ms)

└ Database Query (185ms)

|   └ Query Plan (2ms)

|   └ Index Seek (80ms)

|   └ Filter (50ms)

|   └ Return (53ms)

└ Response (3ms)

Total: 205ms

## Cardinality

Number of unique values.

High cardinality: User IDs (millions)

Low cardinality: Status (10 values)

---

## H.12 Alphabetical Glossary

**API:** Application Programming Interface - interface for programmatic access

**ACID:** Atomicity, Consistency, Isolation, Durability guarantees

**AQL:** Adaptive Query Language - ThemisDB's query language

**Backup:** Copy of data for recovery

**Batch:** Group of operations processed together

**Cardinality:** Number of distinct values

**Cache:** Fast memory storage layer

**Changefeed:** Stream of database changes

**Collection:** Group of related entities

**Consistency:** Data integrity maintained across system

**Continuous Batching:** Dynamic request batching technique for LLM inference that allows new requests to join active batches, dramatically improving throughput (176%) and reducing latency (57%) compared to static batching. See Chapter 20.9A.3.

**Cursor:** Pointer to result set for iteration

**Denormalization:** Storing redundant data for performance

**Document:** Semi-structured data (JSON-like)

**DSGVO:** German data protection regulation (GDPR equivalent)

**Edge:** Connection in graph

**Embedding:** Vector representation of data

**Failover:** Automatic switch to backup system



**Flash Attention:** IO-aware attention mechanism for LLMs that uses SRAM tiling instead of HBM storage, reducing GPU memory usage by 37% and increasing throughput by 69%. Requires NVIDIA Ampere+ GPUs. See Chapter 20.9A.1.

**Flush:** Write data from memory to disk

**Garbage Collection:** Freeing unused memory

**GBNF (GGML BNF):** Grammar notation used by llama.cpp for constrained generation. Extends EBNF with specific syntax for controlling LLM output format. See Grammar-Constrained Generation.

**Grammar-Constrained Generation:** LLM technique that uses EBNF/GBNF grammar rules to guarantee syntactically valid outputs (JSON, XML, CSV). Achieves 95-99% success rate vs 60-70% without constraints, eliminating need for output validation and retries. See Chapter 17.12.6.

**Graph:** Network of connected nodes

**Heap:** Memory area for dynamic allocation

**HNSW:** Hierarchical Navigable Small Worlds - vector index

**Hot Data:** Frequently accessed data

**Hot Spare:** Fully configured standby node in a database cluster that can automatically take over (failover) when an active shard fails, typically within <5 seconds. Provides high availability with zero data loss when combined with WAL replication. See Chapter 16.10.1.

**Index:** Data structure for fast lookups

**Ingestion:** Loading data into database

**Inverted Index:** Index mapping values to documents

**Isolation:** Transactions don't interfere

**JIT:** Just-In-Time compilation

**JSON:** JavaScript Object Notation

**JWT:** JSON Web Token - stateless auth

**Keyspace:** Logical division of data

**Latency:** Time delay for operation

**LoRA (Low-Rank Adaptation):** Efficient fine-tuning technique for large language models that adds trainable low-rank matrices to pretrained models, reducing memory requirements by 99% and training time by 3-10x compared to full fine-tuning. Multiple LoRA adapters can run on a single base model. See Chapter 17.12.5.

**LSM:** Log-Structured Merge tree

**MVCC:** Multi-Version Concurrency Control

**Normalization:** Organizing data to reduce redundancy

**Node:** Entity in graph or cluster

**OLAP:** Online Analytical Processing

**OLTP:** Online Transaction Processing

**Optimization:** Making something run faster

**Paged Attention:** Memory management technique for LLM attention mechanisms that organizes KV-cache into fixed-size pages instead of continuous memory allocation, reducing GPU memory waste by 80% and increasing concurrent request capacity by 5x. See Chapter 17.12.4.

**Pagination:** Dividing results into pages

**Partition:** Division of data across nodes

**Percentile:** Value below which percentage falls

**Persistence:** Data survives shutdown

**Piper:** Fast, local neural Text-to-Speech (TTS) engine used in ThemisDB Voice Assistant. Provides natural-sounding voice synthesis in multiple languages with <50ms latency and minimal CPU usage. See Chapter 10.7.

**Prefix Caching:** LLM optimization that caches the attention states of frequently used prompt prefixes (such as system prompts), enabling 75% cost savings and 95% latency reduction for repeated queries with common prompt beginnings. See Chapter 17.12.1.

**Projection:** Selecting subset of columns

**Query Plan:** Execution strategy for query

**Quorum:** Majority consensus

**Range:** Ordered selection of values

**Replica:** Copy of data

**Replication:** Process of copying data to replicas

**Response Caching:** Intelligent caching system for LLM responses that uses embedding-based semantic similarity to identify and reuse answers to similar questions, providing 60-80% cost savings for repetitive queries. Supports configurable TTL and similarity thresholds. See Chapter 17.12.2.

**RocksDB:** Embedded key-value store (ThemisDB storage engine)

**Rollback:** Undo transaction

**RoPE (Rotary Position Embedding):** Position encoding technique for transformer models that enables context window extension beyond training length through scaling. ThemisDB supports Linear, NTK-aware, and YaRN scaling methods to extend context from 4K to 32K+ tokens. See Chapter 17.12.7.

**RoPE Scaling:** Technique to extend LLM context windows beyond their original training length by adjusting the rotary position embedding frequency. YaRN method achieves 8x context extension (4K → 32K tokens) with <10% quality loss. See Chapter 17.12.7.

**RPO:** Recovery Point Objective (max data loss)

**RTO:** Recovery Time Objective (max downtime)

**Sampling:** Statistical subset of data

**Schema:** Data structure definition

**Selectivity:** Fraction of rows matching filter

**Serialization:** Converting to byte format

**Sharding:** Horizontal data partitioning

**Snapshot:** Point-in-time data view

**Speculative Decoding:** LLM acceleration technique that uses a small, fast "draft model" to speculatively generate multiple tokens in parallel, which are then validated by the larger "target model". Achieves 2-3x speedup with 82-88% token acceptance rates. See Chapter 20.9A.2.

**SQL:** Structured Query Language

**SSTable:** Sorted String Table

**TTL:** Time-To-Live (auto-delete after interval)

**Transaction:** Atomic unit of work

**Throughput:** Operations per unit time

**Vector:** Ordered list of numbers

**View:** Virtual table derived from query

**Voice Assistant:** Enterprise feature providing natural language voice interaction using Whisper (STT), Piper (TTS), and llama.cpp (LLM). Enables call center automation, meeting protocol generation, and voice-controlled database queries with DSGVO-compliant storage. See Chapter 10.7.

**WAL (Write-Ahead Log):** Transaction log that records all database changes before they are applied, ensuring durability and enabling replication. In ThemisDB v1.4.0-alpha, WAL replication provides zero-data-loss failover with support for synchronous, asynchronous, and hybrid replication modes. See Chapter 16.10.2.

**WAL Replication:** Replication mechanism based on Write-Ahead Log streaming that continuously transfers transaction log entries from primary to replica nodes. Supports sync (zero data loss, higher latency), async (minimal latency, potential data loss), and hybrid modes. See Chapter 16.10.2.

**Warm Data:** Occasionally accessed data

**Whisper:** OpenAI's high-accuracy Speech-to-Text (STT) model integrated into ThemisDB Voice Assistant via whisper.cpp. Supports 100+ languages with auto-detection, speaker diarization, and 5 model sizes (tiny to large) trading accuracy for speed. See Chapter 10.7.

**Workload:** Pattern of database usage

---

## Summary

Understanding these terms is essential for: - **Development:** Writing efficient queries - **Operations:** Configuring and monitoring - **Architecture:** Designing systems - **Communication:** Discussing with team

Keep this glossary handy when learning or explaining ThemisDB concepts.

# Anhang I - Troubleshooting Guide

---

*"The best troubleshooting guide prevents issues before they start."*

---

## I.1 Installation Issues

### Issue: Failed to Install Dependencies

#### Error:

```
ERROR: Package xyz not found in vcpkg
```

#### Diagnosis:

```
Check vcpkg status
./vcpkg list | grep xyz

Verify internet connection
ping github.com
```

**Solutions:** 1. **Update vcpkg registry:** `bash ./vcpkg update ./vcpkg upgrade # Rebuild all packages`

1. **Clear cache:** `bash rm -rf vcpkg_installed/ ./vcpkg install # Reinstall from scratch`

2. **Use specific version:** `json // vcpkg.json { "overrides": [ { "name": "xyz", "version": "1.2.3" } ] }`

---

## I.2 Connection Issues

### Issue: Cannot Connect to Database

#### Error:

```
Connection refused at localhost:8529
```

#### Diagnosis:

```
Check if service running
systemctl status themis

Check port in use
lsof -i :8529

Check firewall
sudo ufw status
```

#### Solutions:

1. **Service not running:**

```
bash sudo systemctl start themis sudo systemctl enable themis # Auto-start on reboot
```

2. **Port blocked by firewall:** `bash sudo ufw allow 8529 sudo ufw allow in on docker0 to any port 8529 # Docker`

3. **Process stuck:** `bash # Force kill (last resort) pkill -9 themisdb sudo systemctl restart themis`

## Issue: SSL/TLS Certificate Error

### Error:

```
ERROR: x509: certificate signed by unknown authority
```

### Solutions:

1. **Invalid certificate:** ``bash # Check certificate openssl x509 -in /etc/themis/certs/server.crt -text -noout

```
Verify against key openssl x509 -in server.crt -noout -modulus | openssl md5 openssl rsa -in server.key -noout -modulus | openssl md5 # Should match ``
```

1. **Self-signed certificate (dev only):**

```
bash # Disable SSL verification (DANGER - dev only) THEMIS_SKIP_VERIFY=true
themis-cli ...
```

2. **Certificate expired:** ``bash # Generate new certificate openssl req -x509 -nodes -days 365 -newkey rsa:4096 \ -keyout server.key -out server.crt

```
Restart sudo systemctl restart themis ``
```

---

## I.3 Performance Issues

### Issue: Queries Running Slow (>1s)

#### Diagnosis:

```
-- Use EXPLAIN to see query plan
EXPLAIN
FOR user IN users
 FILTER user.status == 'active'
 RETURN user

-- Check which collection scan
-- If CollectionScan on large table → use index!
```

**Solutions:**

1. **Missing Index:** ``aql -- Create index on filtered field CREATE INDEX idx\_status ON users(status)  
 -- Verify index is used EXPLAIN -- Should show IndexSeek ``
1. **Wrong Index:** ``aql -- Problem: Composite index (status, created\_at) -- But querying only created\_at  
 -- Solution: Reorder to match query pattern DROP INDEX idx\_status\_created CREATE INDEX idx\_created\_status ON users(created\_at, status) ``
1. **Expression in FILTER:** ``aql -- × SLOW: Expression prevents index use FILTER YEAR(user.created\_at) == 2025  
 -- FAST: Range query on indexed field FILTER user.created\_at >= '2025-01-01' AND user.created\_at < '2026-01-01' ``

**Issue: High Memory Usage (>80%)****Diagnosis:**

```
Check memory
free -h
top -p $(pgrep themis)

Check cache settings
curl http://localhost:8529/_admin/cache | jq .

Check for cursor leaks
curl http://localhost:8529/_admin/cursors | jq 'length'
```

**Solutions:**

1. **Cache too large:** `yaml # themis.conf cache: size_mb: 2048 # Reduce from 8192` Then:  
`sudo systemctl reload themis`
2. **Cursor leak (unclosed connections):** ``python # × Leak cursor = client.query("SELECT ...") #  
 Never closed  
 # Safe with client.query("SELECT ...") as cursor: for doc in cursor: process(doc) ``
1. **Large result set:** ``aql -- × Materializes 1M rows FOR doc IN collection RETURN doc

```
-- Paginate FOR doc IN collection LIMIT @offset, 100 RETURN doc ``
```

---

## I.4 Data Issues

### Issue: Data Corruption (Checksum Mismatch)

#### Error:

```
ERROR: Block checksum mismatch at offset 123456
```

#### Recovery:

```
1. Stop database
sudo systemctl stop themis

2. Run recovery
themisdb recover /var/lib/themis

3. If recovery fails, restore backup
tar -xzf /backup/themis-2025-01-01.tar.gz -C /var/lib/
sudo chown -R themis:themis /var/lib/themis

4. Start
sudo systemctl start themis

5. Verify
aql "RETURN COUNT(*) FROM collection"
```

### Issue: Missing Data (Unintended Deletion)

#### Diagnosis:



```
Check logs for DELETE operations
grep DELETE /var/log/themis/audit.log | tail -20

Find deletion timestamp
Look at backup from before deletion
```

### Recovery:

```
Option 1: Point-in-time restore
sudo systemctl stop themis
tar -xzf /backup/themis-2025-01-01-14-00.tar.gz -C /var/lib/ # Before deletion
sudo systemctl start themis

Option 2: Selective restore (if using AWS)
aws s3 cp s3://backups/themis-before-deletion/ /tmp/
Manually restore needed collections
```

## Issue: Replication Lag Too High (>10s)

### Diagnosis:

```
Check lag
curl http://primary:8529/_admin/replication/lag | jq .lag_ms

Check follower CPU/IO
ssh follower "top -bn1 | head -15"
ssh follower "iostat -x 1 5 | grep sda"

Check network
mtr primary-ip --report --report-wide
```

### Solutions:

#### 1. Follower slow (CPU/IO):

```
bash # Add more resources # Edit VM/K8s resource limits # Restart follower to
pick up new limits
```

#### 2. Network congestion: ``bash # Check MTU ip link show | grep mtu

```
If < 9000, enable Jumbo frames (if supported) ip link set dev eth0 mtu 9000 ``
```

1. **Primary write rate too high:** `yaml # Throttle writes (temporary) # themis.conf`  
`database: max_write_rate_per_sec: 1000 # Limit to 1k/s`
- 

## I.5 Replication Issues

### Issue: Follower Won't Start (Replication Sync Failed)

#### Error:

```
ERROR: Cannot connect to primary at primary.example.com:8529
```

#### Solutions:

1. **Primary unreachable:** ```bash # Test connectivity telnet primary.example.com 8529 ping`  
`primary.example.com`

```
Check network policies kubectl get networkpolicies -A ``
```

1. **Follower config wrong:** ```yaml # Check follower primary address cat /etc/themis/themis.conf | grep`  
`follower_primary`

```
Fix if needed # Edit config, then: systemctl restart themis ``
```

1. **Data mismatch (corruption):** `bash # Full resync (rebuilds follower from scratch)`  
`themisdb replication reset sudo systemctl start themis # This will take time`  
`(downloads full dataset from primary)`

### Issue: Primary-Follower Divergence

#### Symptoms:

```
Primary: 10000 documents
Follower: 9999 documents
```

#### Investigation:

```
Count on both
curl http://primary:8529/_admin/collection/mycoll/count | jq .count
curl http://follower:8529/_admin/collection/mycoll/count | jq .count

Find differences
Get document IDs from both, compare
```

**Fix:**

```
Resync follower
sudo systemctl stop themis-follower

Reset and rebuild from primary
themisdb replication reset --primary primary:8529

Verify after sync complete
curl http://follower:8529/_admin/replication/status | jq .lag_ms
Should be < 100ms
```

---

## I.6 Backup & Recovery Issues

### Issue: Backup Failed

**Error:**

```
ERROR: Failed to backup - insufficient space
```

**Solutions:**

1. **Disk full:** ``bash # Check disk df -h /backup

# Clean old backups ls -lt /backup/.tar.gz | tail -10 # Identify oldest rm /backup/themis-2024-.tar.gz #  
Delete old ``

1. **Permissions:** ``bash # Check backup directory ownership ls -ld /backup

```
Fix if needed sudo chown themis:themis /backup sudo chmod 750 /backup ``
```

1. **Database locked:** ``bash # Check if backup process stuck ps aux | grep themis-backup

```
Kill if necessary pkill -f themis-backup ``
```

## Issue: Restore Failed (Data Corrupted)

### Error:

```
ERROR: Restore failed - backup corrupted
```

### Verification:

```
Test backup before restoring
tar -tzf /backup/themis-2025-01-01.tar.gz > /dev/null && \
 echo "Backup OK" || echo "Backup CORRUPTED"

If corrupted, try another backup
ls -lt /backup/themis-*.tar.gz | head -5
```

### Recovery:

```
Use oldest good backup
BACKUP=/backup/themis-2024-12-25.tar.gz

Verify it's good
tar -tzf $BACKUP > /dev/null || echo "Also corrupted!"

If all backups corrupted
Use WAL recovery (if available)
themisdb recover --wal-only /var/lib/themis
```

## I.7 Security Issues

### Issue: Unauthorized Access (Auth Failing)

#### Error:

```
ERROR: Authentication failed: Invalid credentials
```

#### Diagnosis:

```
Check auth logs
tail -50 /var/log/themis/auth.log

Verify user exists
aql "SELECT * FROM users WHERE name == 'alice'"

Check password hash (if applicable)
Never log actual password
```

#### Solutions:

1. **Wrong password:** `bash # Reset user password themis-cli admin reset-password  
alice # New temporary password will be printed`
2. **User locked out:** `aql -- Unlock user UPDATE {name: 'alice'} WITH {locked: false}  
IN users`
3. **JWT token expired:** `python # Get new token token =  
client.authenticate(username='alice', password='xxx') # Use new token in  
subsequent requests`

### Issue: Data Breach Detected

#### Immediate Actions:

1. Isolate database from network

→ Drop external connections

→ Kill active sessions
2. Preserve evidence

→ Copy audit logs

→ Backup database

→ Keep system for forensics
3. Notify stakeholders

→ Security team

→ Management

→ Legal (GDPR notification)
4. Rotate credentials

→ Generate new passwords

→ Rotate encryption keys

→ Revoke old tokens

## I.8 Support Matrix: By Issue Type

Issue	Severity	MTTR	Self-Fix %
Connection timeout	High	5 min	95%
Query slow (no index)	Medium	10 min	90%
High memory usage	High	15 min	80%
Data corruption	Critical	30 min	60%
Replication lag	Medium	20 min	70%
Backup failed	Medium	15 min	85%
Auth issues	High	10 min	75%
Security breach	Critical	60 min	20%

---

## I.9 Escalation Path

### Level 1: Try self-help

- └ Check documentation
- └ Search existing issues
- └ Try basic troubleshooting

### Level 2: Community support

- └ GitHub Discussions
- └ Stack Overflow
- └ Slack community

### Level 3: Vendor support

- └ File bug report
- └ Provide diagnostic data
- └ Wait for response

### Level 4: Enterprise support

- └ Dedicated support engineer
- └ SLA response times
- └ Priority queue

---

## I.10 Data Collection for Support

**When reporting issues, include:**

```
#!/bin/bash
Diagnostic data collection script

echo "=== System Info ==="
uname -a
free -h
lsb_release -a

echo "=== ThemisDB Version ==="
themisdb --version

echo "=== Service Status ==="
systemctl status themis
journalctl -u themis -n 50

echo "=== Memory Usage ==="
curl http://localhost:8529/_admin/memory | jq .

echo "=== Disk Usage ==="
df -h /var/lib/themis

echo "=== Active Queries (top 5) ==="
curl http://localhost:8529/_admin/slow-queries | jq '.queries[0:5]'

echo "=== Configuration ==="
grep -v '^#' /etc/themis/themis.conf | grep -v '^$'

Save to file
```

---

## I.11 Contacting Support

### Community Channels

- **GitHub Issues:** [github.com/makr-code/ThemisDB/issues](https://github.com/makr-code/ThemisDB/issues)
- **Discussions:** [github.com/makr-code/ThemisDB/discussions](https://github.com/makr-code/ThemisDB/discussions)



- **Stack Overflow:** Tag: `themisdb`

## Enterprise Support (SLA)

- **Response time:** < 4 hours for Critical
- **On-call escalation:** Yes
- **Dedicated engineer:** Yes

## When to Contact

- **Development questions:** Community first
  - **Bug reports:** GitHub Issues
  - **Security issues:** Responsible disclosure (see SECURITY.md)
  - **Critical production outage:** Vendor support hotline
- 

## Summary

Most issues fall into categories above. With this guide, you should be able to: 1. **Diagnose** problems quickly 2. **Fix** common issues yourself 3. **Know when to escalate** to support 4. **Provide** detailed diagnostic data

Keep this guide bookmarked for quick reference during incidents.

ThemisDB Kompendium v1.4.0 | 13.01.2026 21:23:11