

# ThemisDB Dokumentations-Index

**Stand:** 20. Dezember 2025  
**Version:** 1.3.0 (LLM Integration Release)  
**Typ:** Dokumentations-Index

## NEW in v1.3.0: Native LLM Integration (Optional Feature)

### AI direkt in der Datenbank - ohne externe API-Kosten!

**Wichtig:** LLM-Integration ist ein **optionales Feature** in v1.3.0: - Erfordert Build-Flag: `-DTHEMIS_ENABLE_LLM=ON` - Benötigt externe Abhängigkeit: llama.cpp (separat klonen) - Siehe Build Guide für Setup-Anweisungen

ThemisDB kann als erste Multi-Model-Datenbank mit **eingebetteter LLM-Engine** erweitert werden:

### Highlights (Production-Ready, wenn aktiviert)

- **Embedded llama.cpp** - SLMs/LLMs (1B-70B Parameter) direkt auf GPU
- **GPU Acceleration** - Signifikanter Speedup mit NVIDIA CUDA support
- **PagedAttention** - Optimierte Memory-Verwaltung
- **Continuous Batching** - Mehrere concurrent requests
- **Kernel Fusion** - CUDA kernels für zusätzlichen Speedup
- **Production Monitoring** - Grafana/Prometheus Integration
- **Plugin Architecture** - Extensible LLM backend system
- **RPC Framework** - Inter-Shard Communication für distributed LLM ops
- **Image Analysis Plugins** - Multi-backend AI (llama.cpp Vision, ONNX CLIP, OpenCV DNN)

### Network Protocol Enhancements (v1.3.0)

- **HTTP/2 with Server Push** - CDC/Changefeed mit proaktiver Event-Delivery (~0ms Latenz)
- **WebSocket Support** - CDC streaming mit bidirektionaler Echtzeit-Kommunikation
- **MQTT Broker** - WebSocket transport, Rate limiting, Monitoring-Metriken
- **HTTP/3 Base** - QUIC-basierte Implementierung (ngtcp2 + nghttp3)
- **PostgreSQL Wire Protocol** - SQL-to-Cypher Translation für BI-Tool Kompatibilität
- **MCP Server** - Model Context Protocol mit cross-platform Support

### Performance Metrics (mit GPU)

- **Signifikanter Speedup** mit GPU vs CPU-only
- **Memory-Ersparnis** mit PagedAttention
- **Zusätzliche Optimierung** mit Kernel Fusion
- **Umfassende Test Coverage** mit Unit Tests

### GPU-Tier Empfehlungen

| GPU-Tier  | Hardware           | Model             | Use Case          | Kosten/1M Tokens | vs. GPT-4       |
|-----------|--------------------|-------------------|-------------------|------------------|-----------------|
| Entry     | RTX 4060 Ti (16GB) | Phi-3-Mini (3.8B) | FAQ, einfache RAG | €0.02            | 1500x günstiger |
| Mid-Range | RTX 4090 (24GB)    | Mistral-7B        | Production RAG    | €0.05            | 600x günstiger  |
| High-End  | A100 (80GB)        | Llama-3-70B       | Enterprise Scale  | €0.15            | 200x günstiger  |

**Break-Even vs. Hyperscaler:** 2-7 Monate je nach Hardware-Tier

### Dokumentation (v1.3.0)

- **GPU Inference Guide**
- CUDA Setup und Konfiguration
- Performance-Tuning
- Troubleshooting
- **Quantization Guide**
- Q4\_K\_M, Q5\_K\_M, Q8\_0 Formate
- Memory vs. Quality Trade-offs
- Best Practices
- **Performance Benchmarks**
- GPU vs. CPU Vergleiche
- Throughput-Messungen
- Latenz-Analysen
- **Deployment Guide**
- Docker mit GPU-Support
- Kubernetes Deployment
- Production Best Practices
- **RPC Framework**
- Inter-Shard Communication
- TLS/mTLS Security

- Snapshot/Blob Transfer
- **GPU-Tier Analyse & Hyperscaler-Vergleich**
- SLM/LLM Performance auf Entry/Mid/High-End GPUs
- TCO-Analyse über 3 Jahre
- ROI-Berechnung vs. AWS/Azure/GCP
- **Alle LLM Dokumentation** - Kompletter Index (31 Guides)

## 📄 Dokumentations-Struktur (Neu Organisiert)

Die Dokumentation wurde neu strukturiert für bessere Übersichtlichkeit:

**Root-Dokumente (nur essentials):** - README.md - Hauptdokumentation - index.md - Dokumentations-Index - glossary.md - Terminologie

**Organisierte Ordner:** - aql/ - **AQL Grammatik (EBNF)** 📄 **v1.3.0** - build/ - Build-System-Dokumentation (BUILD-SYSTEM.md, BUILDGUIDE.md, etc.) - development/ - Entwicklungs-Dokumentation (IMPLEMENTATION-.md, CODE\_REVIEW-.md) - guides/ - Benutzer- und Entwickler-Guides (RAILWAY\_COMPLETE\_GUIDE.md, etc.) - architecture/ - Architektur-Dokumentation (ARCHITECTURE\_OVERVIEW.md, etc.) - stakeholder/ - Stakeholder-Dokumentation - releases/ - Release-Notizen (v1.3.0.md, v1.2.0.md, v1.1.0.md, etc.) - llm/ - **LLM & AI Integration** 📄 **v1.3.0 RELEASED** - plugins/ - **RPC Framework** 📄 **v1.3.0** - archive/ - Alte/historische Dokumentation

### 📄 COMING SOON - v1.1.0 Optimization Release (Q1 2026):

**Fokus:** Bestehende Libraries besser nutzen + vLLM Co-Location  
**Highlights:** - 📄 RocksDB TTL, Incremental Backup, Stats (keine neue Lib!) - 📄 TBB Parallel Sort, Concurrent Containers (keine neue Lib!) - 📄 Arrow Parquet Export (keine neue Lib!) - 📄 **CUDA als Kernbestand** (wenn GPU verfügbar, NICHT Enterprise!) - 📄 📄 **ThemisDB + vLLM Synergie** (optimierte CPU/GPU/RAM Koordination) - 📄 mimalloc (einzige neue Dependency, 20-40% Memory Boost)  
**Engineering:** 9-11 Wochen | **Impact:** 3-10x Performance  
**Details:** v1.1.0 Variant Strategy

### 📄 PLANNED - v1.2.0 Enterprise Features (Q2 2026):

**Fokus:** vLLM AI Support (LoRA), Geo-Spatial (PostGIS), IoT/Timescale  
**Highlights:** - 📄 **LoRA Manager** - Multi-Tenant LoRA Serving (HuggingFace PEFT) - 📄 **FAISS Advanced** - IVF+PQ Vector Search (bereits integriert, erweitern!) - 📄 **GEOS + PROJ** - PostGIS Compatibility (Topology + Geography) - 📄 **Hypertables** - TimescaleDB-kompatibel via RocksDB CF (nur Code!) - 📄 **cuSpatial** - GPU Geo Ops (optional, nutzt Arrow + CUDA)  
**Engineering:** 12-16 Wochen | **Impact:** PostGIS + LoRA + TimescaleDB Compatibility  
**Details:** Enterprise Features Strategy

## 📄 Haupt-Dokumentation

Übersichtsdokumente

- **Changelog** - Vollständige Versionshistorie (v1.2.0, v1.1.0, v1.0.2, v1.0.1, v1.0.0)
- 📄 **Roadmap v1.1.0 - AKTUALISHERT:** Q1 2026 Optimization Release
- **Architecture Overview** - Komplette Systemarchitektur mit Diagrammen
- **Source Code Changes v1.0** - Detaillierte Quellcode-Dokumentation (191 Dateien, 26 Module)
- **Features Liste** - Vollständige Feature-Übersicht mit Status

## 📄 Nach Zielgruppe

Für Stakeholder & Management

- **Themis Sachstandsbericht 2025** - Executive Summary, Status v1.0.1
- 📄 **v1.1.0 Variant Strategy - Q1 2026:** Optimierungs-Strategie mit vLLM Co-Location (9-11 Wochen, 1 neue Lib)
- 📄 **v1.2.0 Enterprise Features - Q2 2026:** vLLM AI (LoRA), Geo-Spatial (PostGIS), IoT/Timescale (12-16 Wochen, 3 neue Libs)
- **Projektkostenschätzung & Gesamtwert** - Wirtschaftliche Bewertung (6,3M EUR)
- **Release Strategy Audit** - SLSA Compliance, SBOM (8.5/10 Rating)
- **Release & Benchmarking Summary** - v1.0.1 Session Report

Für Entwickler

- **Development Summary** - Entwicklungsstand v1.0.1
- 📄 **External Libraries Analysis - NEU:** Feature-Gap-Analyse (RocksDB, TBB, CUDA, Arrow)
- 📄 **Library Interactions - NEU:** Wechselwirkungen & zusätzliche Libraries
- **Source Code Audit** - Code-Analyse (132 Header, 124 Sources, 90.829 LOC)
- **Documentation Index** - Vollständiger Dokumentations-Index mit Modul-Mapping
- **Documentation Verification** - Verifizierung Dokumentation ↔ Code

Für DevOps & Operations

- **Operations Runbook** - Tägliche Operationen
- **Deployment Guide** - Deployment-Strategien
- **Build Strategy** - Build-Toolchain
- **Docker Guide** - Container-Deployment

Für Security & Compliance

- **Compliance Dashboard** - Übersicht aller Compliance-Aktivitäten
- **Security Audit Report** - Durchgeführtes Security Audit
- **Compliance Full Checklist** - BSI C5, ISO 27001, DSGVO, eIDAS, SOC 2
- **Security Policy** - Vulnerability Disclosure
- **Incident Response Plan** - Notfallplan (BSI IT-Grundschutz & NIST CSF)

- **SBOM Documentation** - Software Bill of Materials (CycloneDX 1.4)
- **DPIA** - Datenschutz-Folgenabschätzung (DSGVO Art. 35)
- **BCP/DRP** - Business Continuity (ISO 22301 & NIS2)

## □ □ Nach Architektur-Ebene

### Query & Analytics Layer

- **AQL Documentation** - Advanced Query Language (Parser, Optimizer, 240K LOC)
- **Query Module** - Query Engine, Execution
- **Analytics Module** - OLAP Engine (CUBE, ROLLUP), CEP, Process Mining (57K LOC)
- **Search Documentation** - Fulltext (BM25), Vector, Hybrid Search

### Storage & Index Layer

- **Storage Module** - RocksDB Wrapper, LSM-Tree, MVCC (76K LOC)
- **Index Module** - Vector HNSW, Graph, Secondary, Spatial (400K LOC)
- **Cache Module** - Semantic Cache, Result Cache
- **Timeseries Module** - Gorilla Compression, Aggregates (39K LOC)

### Distribution & Scaling Layer

- **Sharding Module** - VCC-URN Sharding, Auto-Rebalancing, Gossip (300K LOC)
- **Replication Module** - Leader-Follower, Multi-Master CRDTs (12K LOC)
- **Transaction Module** - MVCC, SAGA Patterns (42K LOC)

### Acceleration Layer

- **GPU Acceleration Plan** - 10 GPU Backends (173K LOC)
- CUDA, Vulkan, FAISS, DirectX, HIP, OpenCL, OneAPI, ZLUDA

### Content & Data Processing

- **Content Module** - 15 File Format Processors (256K LOC)
- **CDC Module** - Change Data Capture, Changefeed
- **Geo Module** - Spatial Operations, Plugin System

### Server & API Layer

- **Server Module** - HTTP Server, 21 API Handlers (164K LOC)
- **HTTP API Referenz** - **Vollständige HTTP Endpoint-Dokumentation** □
- **API Documentation** - REST API Übersicht
- **LLM Module** - LLM Interaction Store, Prompt Manager

### Security & Governance Layer

- **Security Module** - Field Encryption, HSM/PKI, RBAC, Ranger (187K LOC)
- **Governance Module** - Policy Engine, Data Classification
- **Auth Module** - JWT Validation, Multi-Tenancy

## □ Quick Start Guides

### Installation & Deployment

- **Main README** - Projekt-Übersicht und Quick Start
- **Deployment Guide** - Deployment-Optionen
- **Docker Guide** - Container-Deployment
- **QNAP Quickstart** - ARM-Deployment

### Getting Started

- **Architecture Overview** - System-Architektur verstehen
- **Features Overview** - Verfügbare Features
- **AQL Tutorial** - Query Language lernen

## □ Referenz-Dokumentation

### Client SDKs

- **SDK Audit** - Übersicht aller 7 SDKs
- **Python SDK** - Python Client
- **JavaScript SDK** - Node.js/Browser Client
- **Rust SDK** - Rust Client
- **Go SDK** - Go Client
- **Java SDK** - Java Client
- **C# SDK** - .NET Client
- **Swift SDK** - iOS/macOS Client

## Data Import/Export

- **Exporters** - Data Export
- **JSONL LLM Exporter** - LLM Training Data Export
- **Importers** - Data Import
- **PostgreSQL Importer** - PostgreSQL Migration

## Plugin Development

- **Plugins** - Plugin System
- **Plugin Security** - Security & Sandboxing
- **Plugin Migration** - Migration Guide

## □ Administration & Operations

### Admin Tools

- **Admin Tools** - 7 WPF Administration Tools
- **User Guide** - Benutzerhandbuch
- **Admin Guide** - Administrator-Handbuch
- **Feature Matrix** - Tool-Übersicht

### Operations Guides

- **Operations Runbook** - Tägliche Operationen
- **TLS Setup** - TLS/mTLS Konfiguration
- **Vault Integration** - HashiCorp Vault Setup
- **RBAC Setup** - Access Control Configuration
- **Code Quality** - Code Quality Tools

### Performance & Monitoring

- **Performance Tuning** - Performance-Optimierung
- **Benchmarks** - Performance-Benchmarks
- **Memory Tuning** - Speicher-Optimierung
- **Observability** - Monitoring & Metrics

## □ Reports & Status

### Development Reports

- **Development Summary** - Aktueller Entwicklungsstand v1.0.1
- **Audit Log** - Entwicklungs-Audit-Log
- **Implementation Status** - Implementierungsstatus
- **Priorities** - Entwicklungs-Prioritäten

### Status Reports

- **Themis Sachstandsbericht** - Haupt-Statusbericht v1.5
- **Documentation Summary** - Dokumentations-Übersicht
- **Benchmark Audit** - Test & Benchmark Status
- **Security Audit** - Security Audit Ergebnisse

### Roadmap & Planning

- **Roadmap Overview** - Entwicklungs-Roadmap (2026 komplett!)
- **Features Priorities** - Q1 2026 Prioritäten
- **Database Capabilities** - Capabilities Roadmap

## □ Integration & Ingestion

### Data Ingestion

- **Ingestion** - Data Ingestion Patterns
- **VCC CLARA** - CLARA Adapter
- **VCC VERITAS** - VERITAS Adapter
- **VCC Base** - Base Adapter Framework

### Enterprise Integration

- **Enterprise Features** - Rate Limiting, Load Shedding
- **Integration Analysis** - Legacy-Code Integration

## □ Source Code Dokumentation

### Module Documentation (src/)

Alle 26 Module mit detaillierter Dokumentation in src/:

- **Acceleration** - GPU/CPU Backends (173K LOC)
- **Analytics** - OLAP, CEP (57K LOC)
- **API** - GraphQL, Geo Hooks
- **Auth** - JWT Validation
- **Cache** - Semantic Cache
- **CDC** - Change Data Capture
- **Content** - 15 File Processors (256K LOC)
- **Exporters** - Data Export
- **Geo** - Spatial Operations
- **Governance** - Policy Engine
- **Importers** - Data Import
- **Index** - Vector, Graph, Secondary (400K LOC)
- **LLM** - LLM Integration
- **Network** - Wire Protocol
- **Observability** - Metrics, Tracing
- **Plugins** - Plugin System
- **Query** - AQL Engine (240K LOC)
- **Replication** - Leader-Follower, Multi-Master (12K LOC)
- **Security** - Encryption, RBAC (187K LOC)
- **Server** - HTTP, API Handlers (164K LOC)
- **Sharding** - VCC-URN, Gossip (300K LOC)
- **Storage** - RocksDB, MVCC (76K LOC)
- **Timeseries** - Gorilla Compression (39K LOC)
- **Transaction** - MVCC, SAGA (42K LOC)
- **Updates** - Schema Migration
- **Utils** - Utilities (120K LOC)

## □ Weitere Ressourcen

### External Links

- **GitHub Wiki** - Community Wiki
- **GitHub Pages** - Online Dokumentation
- **PDF Documentation** - Vollständige Doku als PDF

### Benchmarking & Performance

- **Benchmarks Suite** - Benchmark-Framework
- **Docker Benchmarks** - Competitive Benchmarks
- **Hardware Constraints** - Resource-Constraints Testing

### Release Documentation

- **v1.0.1 Release Notes** - Latest Release
- **v1.0.0 Release Notes** - Production Release
- **Release Package Structure** - Package Organization

## □ Dokumentations-Standards

### Format & Struktur

- **Format**: Markdown (.md)
- **Encoding**: UTF-8
- **Line Endings**: LF (Unix-style)
- **Code Blocks**: Sprache immer angeben
- **Links**: Relative Pfade verwenden

### Contributing

1. **Struktur folgen** - Docs im passenden Unterverzeichnis platzieren
2. **Proper verlinken** - Relative Links zu anderen Dokumenten
3. **README updaten** - Relevante README.md-Dateien aktualisieren
4. **Markdown-Style** - Style Guide befolgen
5. **Aktuell halten** - Docs bei Feature-Änderungen updaten

### Build-Prozess

```
# Dependencies installieren
pip install -r requirements-docs.txt

# Dokumentation bauen
./build-docs.ps1

# lokal testen
mkdocs serve
```

Dokumentation wird automatisch zu GitHub Pages deployt bei Merge zu main.

## □ Support & Community

- **Issues:** GitHub Issues
- **Wiki:** GitHub Wiki
- **Security:** Security Policy

## □ Dokumentations-Statistiken

| Metrik                | Wert             |
|-----------------------|------------------|
| Dokumentationsdateien | 456+             |
| Dokumentationsordner  | 71               |
| Source-Code LOC       | 90.829           |
| Source Files          | 191 (.cpp)       |
| Header Files          | 132 (.h)         |
| Module                | 26 Verzeichnisse |
| Logische Komponenten  | 16               |

**Version:** 1.3.0

**Last Updated:** 20. Dezember 2025

**License:** See LICENSE